

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal de Colombia (ELCO)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización de programas sociales en Colombia, como el SISBEN, identifican pobreza como un estado observado y no anticipan qué hogares no pobres tienen mayor riesgo de caer en esa condición. Este trabajo evalúa si información pública, particularmente, características del entorno físico y económico local, mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Usando tres olas del panel (2010, 2013, 2016), se construye la variable de resultado como la entrada en pobreza de hogares inicialmente no pobres y se estiman distintos algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting), evaluando su capacidad predictiva en un período posterior al utilizado para su estimación: los modelos se entrenan con las transiciones observadas entre 2010 y 2013 y se evalúan con las transiciones entre 2013 y 2016. Este esquema permite evaluar el desempeño de los modelos en datos temporalmente posteriores a aquellos utilizados para su entrenamiento, aproximándose a su capacidad para anticipar transiciones futuras hacia la pobreza. Los modelos se estiman con y sin variables monetarias del hogar. El modelo base, que es lo que se reporta en esta versión del documento, alcanza

un AUC-ROC entre 0.731 y 0.767 según el algoritmo, con una brecha de apenas 0.008–0.028 entre la especificación que incluye ingreso/gasto del hogar y la que no lo hace, lo que sugiere que las covariables no monetarias capturan una fracción sustancial del poder predictivo típicamente atribuido al ingreso. La incorporación de las variables geoespaciales, contribución central de esta tesis, está en construcción. De confirmarse un aporte incremental, los resultados podrían fortalecer instrumentos de focalización con información de mayor frecuencia y menor costo de actualización que las encuestas de hogares tradicionales.

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geoespaciales, ELCA, focalización, Colombia.

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juárez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Beneficiarios de Programas Sociales (SISBEN) opera a través de una encuesta cuya aplicación depende de la solicitud de los hogares y de los recursos de la entidad territorial responsable, lo que genera rezagos en la actualización de la información y dificulta contar con datos recientes sobre el efecto de choques (Consejo Nacional de Política Económica y Social, 2016). La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y ejercicios recientes de aproximación a la vulnerabilidad monetaria en Bogotá mediante pseudo-panel confirman tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Castañeda Castrillón, 2012; Gaitán, 2023).

Esta tesis aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza monetaria. Este abordaje es distinto al de la literatura de la pobreza contemporánea que predice la mayoría de la literatura de aprendizaje de máquinas aplicada a este problema (Ferdausi et al., 2025; Muñetón et al., 2022)–. La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View mejora la predicción de caída en pobreza monetaria de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del

hogar reportadas en encuestas?

El estado actual de este documento cubre la primera mitad de esa pregunta: la construcción rigurosa de la variable de resultado, la auditoría exhaustiva de las covariables socioeconómicas disponibles en la ELCA (más de 4.000 columnas originales revisadas variable por variable a través de cinco módulos), y la estimación y comparación de cinco algoritmos de aprendizaje supervisado: regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting— sobre el modelo *base* (sin variables geoespaciales). La incorporación de las fuentes geoespaciales y la comparación frente al modelo extendido, que es la contribución central de la pregunta de investigación, está en construcción y se documenta como trabajo en curso en la Sección 6.3.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema no abordado directamente por la literatura existente aplicada al país.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje de máquinas aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla la estrategia empírica: construcción del outcome, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados obtenidos hasta el momento. La Sección 6 cierra con una síntesis, implicaciones de política y la agenda de trabajo pendiente.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria suele originarse en fluctuaciones del ingreso asociadas con choques económicos (ej. pérdida de empleo, caídas en precios) o eventos adversos

(ej. desastres naturales, conflictos). Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto al mostrar que en muchos países en desarrollo existe una población significativa de hogares no pobres pero altamente expuestos: su situación actual los ubica por encima de la línea de pobreza, pero su fragilidad patrimonial los hace vulnerables a caer ante afectaciones moderadas. Esta población es precisamente la que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010; Costella et al., 2023).

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juárez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 4.1 de esta tesis. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado de pobreza.

En el contexto colombiano, la aplicación de estos enfoques ha enfrentado restricciones de datos que han limitado su alcance. Castañeda Castrillón (2012) estudió las trampas de pobreza mediante la construcción de un pseudo-panel, y Gaitán (2023) analizó la vulnerabilidad monetaria a nivel de localidades en Bogotá con el mismo enfoque, como una manera para superar la ausencia de un panel de hogares con representatividad y cobertura suficiente; sus resultados –cerca del 23 % de la población bogotana en situación de vulnerabilidad en 2021– confirman la relevancia del problema, pero también evidencian las restricciones que impone el uso de cortes transversales repetidos en lugar de datos longitudinales reales. La disponibilidad de la ELCA, con tres olas de seguimiento a los mismos hogares, ofrece una oportunidad inédita para superar esta limitación en el contexto colombiano. Incluso con datos longitudinales, sin embargo, esta literatura enfrenta una restricción operativa adicional: los métodos desarrollados dependen, casi sin excepción, de encuestas de hogares con información detallada sobre ingresos, activos y consumo, costosas, de levantamiento infrecuente y con rezagos significativos entre la recolección y la disponibilidad de los datos. Esta restricción informacional es la que motiva la exploración de fuentes alternativas de datos que puedan aproximar la vulnerabilidad con mayor frecuencia de actualización y menor costo de recolección (Sección 2.3).

2.2. Aprendizaje de máquinas en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su desarrollo ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar

sustancialmente la precisión de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando la precisión balanceada en hasta 17 puntos porcentuales frente a los métodos tradicionales. Siguiendo esta perspectiva, esta tesis evalúa el desempeño de los modelos fuera de la muestra mediante un *holdout* temporal hacia adelante: los modelos se entrenan con información de períodos anteriores y se evalúan con información de un período posterior. De esta manera, la validación permite aproximarse mejor a la situación en la que el modelo se utilizaría en la práctica, es decir, para predecir la vulnerabilidad de hogares en un período futuro (Sección 4.4). Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2025) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema, logrando una precisión del 96 % con un conjunto reducido de siete variables. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza al resto de la literatura. En Colombia, Muñetón et al. (2022) han aplicado aprendizaje de máquinas a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital, mostrando que la combinación de imágenes satelitales con datos de encuesta permite explicar hasta el 75 % de la variación en consumo o riqueza en contextos africanos, superando lo que cualquiera de las dos fuentes logra de manera aislada. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con precisiones superiores al 82 %, aunque advierten que su capacidad discriminatoria se reduce en contextos de pobreza muy extendida, donde la variabilidad espacial de las imágenes es insuficiente para

distinguir entre hogares con distintos niveles de privación.

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran que la combinación de datos satelitales y de telefonía móvil reduce los errores de exclusión en programas sociales entre 4 % y 21 % frente a los métodos tradicionales. Hall et al. (2023), en una revisión sistemática, documentan que la combinación de múltiples fuentes incrementa el poder predictivo hasta en 15 puntos porcentuales, pero identifican que los datos geoespaciales predicen mejor activos físicos que variables de flujo como ingreso o consumo, y que su desempeño depende críticamente del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que esta tesis busca incorporar (sección 3.2).

2.4. Síntesis y vacío que llena este trabajo

La evidencia revisada muestra que los modelos que combinan variables geoespaciales con información socioeconómica de encuestas superan a los basados exclusivamente en cualquiera de las dos fuentes, con ventajas más pronunciadas cuando la validación se realiza fuera de muestra. Sin embargo, ninguno de los trabajos revisados aborda directamente el problema de predecir la probabilidad de caída en pobreza de hogares actualmente no pobres, y mucho menos en un contexto de datos longitudinales de hogar como el que ofrece la ELCA. Predecir transiciones hacia la pobreza es un problema conceptualmente distinto al de estimar pobreza contemporánea: requiere una variable de resultado definida en términos prospectivos, un horizonte temporal explícito entre olas de panel, y un conjunto de variables predictoras que capture tanto las condiciones del hogar como las del entorno en el momento previo a la transición.

Es en esta brecha donde esta investigación busca contribuir, evaluando si la incorporación de variables del entorno físico y económico local derivadas de fuentes geoespaciales públicas a los datos longitudinales de la ELCA permite mejorar la identificación de hogares en riesgo de caer en pobreza en Colombia. Es importante señalar que, en contextos de política pública, la predicción es valiosa incluso en ausencia de interpretación causal Kleinberg et al. (2015), especialmente porque el objetivo es mejorar la focalización *ex ante* de la política

social. Por esta razón, este trabajo se sitúa en un enfoque predictivo más que causal, donde el objetivo no es identificar efectos estructurales sino mejorar la capacidad de anticipar transiciones hacia la pobreza con miras a mejorar la focalización de políticas públicas de seguridad social.

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCA)

La fuente primaria de datos es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares en tres olas: 2010, 2013 y 2016, en zonas urbana y rural. La ELCA se organiza en en módulos temáticos: hogar, personas, niños, comunidades y choques, además de los módulos de activos y gasto. Existen dos olas más disponibles para 2019 y 2022, que administra el DANE. No obstante, por cuestiones de tiempo no se utilizaron en el marco de esta investigación. El identificador de hogar cambia de nombre entre olas (`consecutivo`→`llave`→`llave_n16`). Para los análisis realizados en esta tesis, se usan exclusivamente coincidencias uno a uno de este identificador entre olas consecutivas, excluyendo los hogares que se dividieron en dos o más sub-hogares (511 casos entre 2010–2013 y 1,190 entre 2013–2016, ver Tabla 3), para no hacer supuestos reespecto de su ubicación entre hogares divididos.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta. La auditoría tuvo cuatro capas, replicadas de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal `¿??` en lugar de vocales acentuadas y la letra ñ); (ii) clasificación exhaustiva de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información evitable.

El resultado es un panel hogar x ola consolidado de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas, que combinan las covariables construidas a partir de los módulos con las variables monetarias (ingreso y gasto per cápita del hogar, nominal y real, y brecha frente a la línea de pobreza). Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas explícitas y documentadas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno” cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano

disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar cuando la literatura lo usa como proxy estándar. Las tasas de mercado laboral se calculan restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

3.2. Fuentes geoespaciales

Este trabajo utiliza información geoespacial disponible públicamente y de manera gratuita como proxy de las condiciones espaciales del entorno y la infraestructura. La idea es que la información geoespacial de los hogares puede capturar características del entorno físico y económico local que afectan la vulnerabilidad de estos hogares a caer en pobreza, pero que no se refleja completamente en las encuestas tradicionales que realizan gobiernos y otras organizaciones. Para esto, a partir de las coordenadas de los hogares de la ELCA, que se encuentran para consulta de manera estrictamente controlada y restringida por parte de la Universidad de los Andes, se consolida la información geoespacial disponible en línea a través de consultas a la API de Google Earth Engine. Esta información se anexa a la base de datos de la ELCA para cada hogar, y se utiliza como covariable adicional en los modelos predictivos de transición hacia la pobreza.

La necesidad fundamental de este proyecto es tener información geoespacial para al menos dos olas: 2010 es la ola para la que se entrenan los modelos que predicen la transición a la pobreza —el ejercicio central de esta tesis—, mientras que la transición 2013→2016 se usa después para determinar el poder predictivo de esas mismas variables fuera de muestra (Sección 4.1).

Inicialmente, se priorizó la utilización de imágenes de Google Street View, sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente. Por esta razón, se evaluaron otras seis fuentes satelitales o aéreas públicas adicionales: —Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), y ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales modernas todavía no operaban)— y se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017) —por lo que no puede existir ninguna imagen real de ellas anterior a esas fechas, en ningún

catálogo—. Por eso se evaluaron específicamente en el marco de este proyecto: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura real anterior a 2014.

La Figura 1 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA, JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los hogares en las tres olas de la ELCA (2010, 2013, 2016). El patrón diagonal marca cobertura real confirmada sobre hogares del proyecto; el resto se revisó cobertura de catálogo sin realizar consultas de los hogares disponibles (Sentinel-2, VIIRS).




Figura 1: Cobertura temporal real de cada fuente geoespacial evaluada, frente a las tres olas de la ELCA con coordenadas disponibles. El patrón diagonal indica corrida real y completa sobre hogares del proyecto; el resto se revisó cobertura según catálogo. En la barra de GSV, la intensidad del color es proporcional a la densidad real de fotos por año —la gran mayoría de las fotos son de 2023 en adelante.

El resultado de la corrida de producción, ya completa sobre las tres, es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013; es la única de las tres con esa cobertura completa en dos olas, lo que permite usarla para la evaluación del poder predictivo en la transición 2013→2016. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014 —no tiene ninguna cobertura de 2013—. Landsat 5 TM cubre solo 65.5 % de los hogares en 2010 (6,269 de 9,573; el resto pierde el año completo por nubosidad persistente, una limitación del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth

Engine confirmó que el sensor dejó de adquirir información utilizable antes de esa fecha, no hay ninguna imagen real de Landsat 5 en 2012 ni en 2013, en ningún punto del planeta. Las tres se incorporan al proyecto.

La Tabla 1 resume, para las tres fuentes nuevas, el mecanismo físico de medición, el nombre de las variables principales que se construyeron, y la interpretación que se les da en este estudio.

Cuadro 1: Qué mide cada fuente nueva, qué variables construye, y qué aproxima cada una.

Fuente	Mecanismo físico	Variables (estado / ventana acum.)	Qué aproxima
DMSP-OLS	Radiancia visible nocturna captada por satélite (aluminado público, vivienda, comercio)	Estado: nivel, log, saturación Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code>)	Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)
ALOS PALSAR	Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación	Estado: HH, HV (dB), razón HH/HV, índice normalizado Acumulada: media, tendencia, crecimiento de cada una	Densidad y consolidación del entorno construido vs. vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)
Landsat 5 TM	Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta)	Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices) Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo	Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada)

3.3. Cobertura, atrición e inventario del panel

La Tabla 2 resume la cobertura de covariables por módulo en el dataset consolidado. Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones)

porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares que cumplen esa condición.

Cuadro 2: Cobertura de covariables por módulo en el dataset consolidado

Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (%) del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	21	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría (Sección 3.1); “usadas en el modelo” es el subconjunto final tras la construcción de *features* – excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (`docs/decisions.md`, “Bloque de features de Hogar”). No incluye llaves de identidad (p. ej. `consecutivo_c` en Comunidades). Fuente: cálculos propios con base en ELCA 2010, 2013, 2016 y `docs/variable_audit/*_construccion.csv`, generados por `src/tabla_cobertura_modulos.py`.

3.3.1. Composición del panel y atrición

Como en toda encuesta longitudinal existe algo de pérdida de datos (atrición) que se caracteriza de la siguiente manera: el panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016 (Figura 2, izquierda) —una atrición de 11.4 % entre 2010 y 2013, 11.4 % entre 2013 y 2016, y 17.9 % acumulada entre 2010 y 2016 (Figura 2, derecha). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2 % de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8 % de los rurales), lo opuesto a la intuición de que la atrición rural sería mayor por dificultad de rastreo geográfico —probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales, dado que son la población de interés original de la encuesta. Por esta razón, en este estudio se utilizan técnicas de balanceo para compensar este sesgo.




Figura 2: Izquierda: hogares únicos por ola. Derecha: tasa de pérdida de hogares entre olas consecutivas y acumulada 2010–2016. Fuente: cálculos propios.

Parte de la aparente estabilidad del panel esconde un fenómeno distinto: la división de hogares. 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016 —típicamente porque un hijo formó su propio hogar en la misma vivienda o predio—. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. El número de personas cubiertas por el panel cae de forma más pronunciada que el de hogares —43,202 personas en 2010, 39,920 en 2013, 35,722 en 2016 (18.7% de caída acumulada, por encima del 17.9% de hogares)— porque los hogares perdidos tienden a ser, en promedio, ligeramente más grandes que los que permanecen en el panel.

3.3.2. Inventario temático de las variables finales

El dataset consolidado que alimenta el modelo (27,932 filas hogar×ola) reúne 181 variables finales: 177 provienen de los cinco módulos de la ELCA ya auditados en la Tabla 2 —excluyendo de ese conteo `consecutivo_c`, que es la llave de unión al módulo Comunidades, no una covariable— y las 4 restantes son las variables geoespaciales. La Figura 3 desagrega ese total por módulo y por tipo de dato. Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario —consistente con que son los módulos que se preguntan a todo hogar sin condición previa (Tabla 2)—, mientras que Comunidades (21), Choques (17), Niños (13) y Geoespacial (4) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra o a una sola ola (Niños, Geoespacial). De las 181, 159 (88%) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas

(los indicadores de pobreza monetaria).




Figura 3: Inventario de las 181 variables finales del dataset consolidado, por módulo temático y tipo de dato. Fuente: cálculos propios.

4. Estrategia empírica

4.1. Construcción de la variable de resultado y dinámica de transiciones

Siguiendo a López-Calva y Ortiz-Juárez (2011, 2014), se construyen matrices de transición de pobreza monetaria e IPM cruzando el estado de un hogar en t (filas) contra $t + 1$ (columnas) –monetaria: ingreso per cápita contra la línea de pobreza (LP) oficial del DANE, específica por año y zona; IPM: Sección 3–, según las cuatro categorías de López-Calva y Ortiz-Juárez (2014) (nunca/siempre pobre, sale/entra en pobreza). El emparejamiento usa solo coincidencias uno a uno del identificador de hogar (Sección 3.1); se excluyen 511 hogares divididos en 2010–2013 y 1,190 en 2013–2016 por no tener un estado inicial y final únicos. El modelo predictivo de esta tesis (Secciones 4.3 en adelante) usa solo una de las cuatro celdas: restringido a hogares no pobres en t , se define la variable dependiente binaria

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

es decir, se estima la probabilidad condicional de *entrar* en pobreza dada la información en t (Ecuación 2). El resto de la sección caracteriza las cuatro celdas completas –“sale de



la pobreza” y “siempre pobre” son el contrafactual necesario para dimensionar el fenómeno que el modelo predice–; incidencia agregada, FGT y cinco ejercicios de robustez de estas cifras –incluida la atrición del panel por perfil de hogar– se documentan en el Apéndice A.2.

Cuadro 3: Matrices de transición de pobreza, monetaria por ingreso vs. IPM (% de fila, panel emparejado 1 a 1). Estado inicial en filas, estado final en columnas.

Periodo	Estado inicial	Monetaria		IPM	
		No pobre	Pobre	No pobre	Pobre
2010 → 2013	No pobre	76.6 %	23.4 %	87.9 %	12.1 %
	Pobre	29.7 %	70.3 %	54.5 %	45.5 %
2013 → 2016	No pobre	80.1 %	19.9 %	90.3 %	9.7 %
	Pobre	38.2 %	61.8 %	52.3 %	47.7 %

Nota: $n = 8,218$ (2010→2013) y $n = 6,911$ (2013→2016) hogares con emparejamiento 1 a 1 – idéntico universo para monetaria e IPM (mismo panel, solo cambia la clasificación de pobreza); excluye 511 (2010–2013) y 1,190 (2013–2016) casos de hogares que se dividieron entre olas. Fuente: cálculos propios con base en ELCA 2010, 2013, 2016, generados por `src/tabla_matriz_transicion_combinada.py` sobre `outputs/tables/pobreza/transicion_{pct,conteo}_{,ipm}_ola*.csv` (`src/04_features/build_pobreza_desagregaciones.py`, `build_matriz_transicion_ipm.py`).

Bajo pobreza monetaria la persistencia es alta pero decrece: 70.3 % de los pobres en 2010 seguían pobres en 2013, cae a 61.8 % entre 2013 y 2016 (la salida condicional sube de 29.7 % a 38.2 %); la persistencia en la no-pobreza mejora de 76.6 % a 80.1 %. Bajo IPM entrar es menos frecuente (12.1 % y 9.7 %, frente a 23.4 % y 19.9 % en monetaria) pero también lo es salir (45.5 % y 47.7 %) –consistente con que el IPM mide privaciones estructurales que cambian más lento que el ingreso corriente en cualquiera de las dos direcciones. Las Figuras 4 y 5 traducen la matriz monetaria a flujos: en 2010–2013 dominan los *siempre pobres* (43.9 %) sobre los *nunca pobres* (28.8 %); en 2013–2016 el orden se invierte (37.0 % vs. 33.3 %), y en ambos periodos la salida casi duplica la entrada –la pobreza monetaria se redujo de forma neta, no solo se redistribuyó entre hogares.

Figura 4: 2010→2013 ($n = 8,218$).Figura 5: 2013→2016 ($n = 6,911$).

Transición de pobreza monetaria por ingreso entre categorías de López-Calva y Ortiz-Juárez (2014), panel emparejado 1 a 1.

Un último ejercicio (Tabla 4) sigue a los mismos hogares no pobres en la ola base a lo largo de las tres olas para distinguir, dentro de quienes *entran* en pobreza, una entrada transitoria de una persistente. Bajo pobreza monetaria, 24.1 % de los no pobres en 2010 entra en pobreza en algún momento: 14.0 puntos salen de nuevo antes de 2016 (“transitorio”) y 10.1 se quedan (“persistente”). Bajo IPM la entrada total es menor (12.2 %) y se reparte parecido (8.2 transitoria, 4.0 persistente): en ambas definiciones, más de la mitad de quienes entran en pobreza no quedan atrapados dentro de la ventana de seis años observada.

Cuadro 4: Trayectorias a 3 olas (2010→2013→2016) de hogares NO pobres en 2010, panel emparejado 1 a 1, monetaria vs. IPM.

Trayectoria	Monetaria		IPM	
	n	%	n	%
Nunca cae	1,700	67.2 %	4,381	81.2 %
Cae tarde (solo en 2016)	220	8.7 %	357	6.6 %
Entra y sale (transitorio)	355	14.0 %	445	8.2 %
Entra y se queda (persistente)	255	10.1 %	214	4.0 %

Nota: $n=2,530$ hogares no pobres en 2010 bajo pobreza monetaria; $n=5,397$ bajo IPM (universos distintos porque no-pobre-monetaria y no-pobre-IPM en 2010 no son el mismo conjunto de hogares). % sobre ese universo, sin ponderar (ver también `pct_ponderado` en los CSV fuente). Fuente: cálculos propios, `outputs/tables/eda_transicion_covariables/trayectorias_3olas_{monetaria,ipm}.csv` (`src/02_build/eda_trayectorias_3olas.py`), generados por `src/tabla_trayectorias_3olas.py`.

4.2. Selección de covariables para el perfil univariado

La Sección 5.1 contrasta los cuatro grupos de la matriz de transición sobre cerca de 185 covariables candidatas de la encuesta. Describirlas todas sin ningún filtro sería demasiado confuso: con muestras muy desiguales entre grupos (723 hogares .^{entra}frente a 3.604 "siempre pobre".^{en} 2010–2013), una simple comparación de promedios o porcentajes no distingue una diferencia real entre grupos de una que aparece por azar de qué hogares fueron encuestados. Se necesita entonces una regla explícita para decidir qué variables merecen contarse, y qué tan fuerte es esa diferencia –no solo si existe–.

La regla, aplicada variable por variable, responde una pregunta simple: ¿qué tan bien predice el valor de esa única variable a cuál de los cuatro grupos pertenece un hogar, en una escala de 0 (no ayuda nada) a 1 (los distingue perfectamente)? Esa capacidad se mide con η^2 (variables numéricas) o V de Cramér (categóricas) –la misma pregunta, la fórmula adecuada según el tipo de dato–, en su versión corregida por sesgo (ambas medidas exageran la asociación en muestras pequeñas, y .^{entra}.^{es} el grupo más pequeño) y ponderada por los factores de expansión de la encuesta. Una variable entra al perfil solo si esa medida supera 0.05 de forma consistente en 300 remuestreos *bootstrap* de los datos, no solo en la muestra original: exige que la señal sea repetible, no una casualidad de qué hogares puntuales aparecen en la encuesta. De las 185 candidatas, 53 (monetaria) y 36 (IPM) pasan el filtro. A diferencia de un modelo predictivo, las variables que pasan no se colapsan aunque estén correlacionadas entre sí: el objetivo aquí es describir, no evitar redundancia, y cada variable retenida puede aportar información al perfil.

4.3. Especificación de modelos

La estrategia empírica se establece mediante la siguiente especificación de modelo:

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1) y $F(\cdot)$ es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se estiman y comparan cinco algoritmos, agrupados en dos familias según cómo tratan las variables categóricas y los datos faltantes (Sección 4.5):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla ($l1_ratio$) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge. Es el algoritmo

designado como referencia por ser interpretable, y por servir de punto de comparación antes de justificar el uso de un modelo más complejo. Es también el más sensible a la multicolinealidad entre covariables –se evaluó explícitamente ese riesgo mediante un análisis de correlación de Pearson entre las 159 variables numéricas del consolidado, con 35 pares por encima de $|r| = 0.7$ (incluida una correlación fuerte de `dmsp_stable_lights` con `lp` y `n_servicios_publicos_hogar`, retomada en la Sección 5.3; detalle completo en el Apéndice A.1)–: la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, la varianza inflada de coeficientes individuales cuando varias variables de un mismo grupo redundante entran juntas al modelo.

- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad, y uno de los más usados en la literatura de focalización de pobreza (McBride & Nichols, 2018)–. Los tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding* (Sección 4.5).

Para evaluar el aporte del nivel de ingreso/gasto del hogar –el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, se estima cada uno de los cinco algoritmos bajo dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante (se mantiene constante a lo largo del tiempo); el **Modelo B** excluye estas cuatro variables y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad).

Finalmente, se establecieron dos variables objetivo para evaluar la robustez de los hallazgos: la transición hacia la pobreza monetaria y la transición hacia la pobreza multidimensional (IPM).

4.4. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño

predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, solo existe la ola base al momento de predecir, y es, siguiendo a McBride y Nichols (2018), la validación más exigente para un modelo de este tipo porque prueba generalización ante un régimen económico distinto al de entrenamiento.

Dentro de ese periodo de entrenamiento (2010 a 2013) –nunca sobre el conjunto de prueba– cada algoritmo pasa por una búsqueda de hiperparámetros: en vez de fijar a mano valores como la profundidad de los árboles o la tasa de aprendizaje, `RandomizedSearchCV` propone 30 combinaciones aleatorias dentro de un rango razonable para cada hiperparámetro (Sección 4.3) y evalúa cada una con validación cruzada estratificada de 10 particiones: el conjunto de entrenamiento se divide en 10 bloques del mismo tamaño y manteniendo la proporción de hogares que entran a la pobreza en cada uno (*estratificada*), se entrena 10 veces dejando un bloque distinto por fuera cada vez y evaluando sobre ese bloque no visto, y se promedian las 10 evaluaciones. Ese promedio castiga a las combinaciones que memorizan particularidades del conjunto de entrenamiento en vez de aprender un patrón que generaliza, sin utilizar el conjunto de prueba, que solo se toca una vez, al final, para evaluar el desempeño del modelo. Se eligen los 30 hiperparámetros por costo computacional –evaluar más combinaciones exhaustivamente (*grid search*) sobre 5 algoritmos $\times$ 4 especificaciones $\times$ 3 estrategias de balanceo (Sección 4.5) y dos variables objetivo, con validación cruzada de 10 particiones, hubiera requerido un tiempo de cómputo prohibitivo, incluso con paralelización y optimizaciones de preprocesamiento. La métrica que decide qué combinación gana esa búsqueda es AUC-ROC. Para verificar que 30 iteraciones no se quedan cortas, se extendió la búsqueda a 50 iteraciones para el caso más ambiguo de la comparación de balanceo (HistGradientBoosting-A, Sección 4.5, `diagnostico_convergencia_busqueda.py`): el mejor puntaje acumulado ya no mejora entre las iteraciones 20 y 40 (0.7603 en ambas), y gana solo 0.0006 adicional hacia la iteración 50 –evidencia de que la búsqueda con 30 iteraciones ya opera cerca de su techo para este caso, no de que se haya interrumpido prematuramente.

Un desbalance de clases pronunciado puede hacer que el AUC-ROC dé una imagen optimista: premia una tasa *relativa* baja de falsos positivos, lo que puede esconder un número *absoluto* alto de falsos positivos cuando la clase positiva es escasa (Davis & Goadrich, 2006; Saito & Rehmsmeier, 2015). Esto no invalida al AUC-ROC como medida de *ranking* –su valor es independiente del umbral de clasificación y no cambia mecánicamente con la proporción de clases–, pero sí limita qué tan bien comunica, por sí solo, la utilidad práctica del modelo para una política con cobertura limitada. Por eso, además de AUC-ROC, se reporta `precision_top10` (Sección 5.3): la precisión en el decil de mayor riesgo no depende

del balance de clases ni de un umbral de clasificación, y responde directamente la pregunta relevante para un programa de focalización real.

El desempeño se reporta mediante AUC-ROC como métrica principal, principalmente porque no depende de un umbral de clasificación arbitrario (se evalúan múltiples umbrales), además, recall, precision y F1 como métricas de referencia al umbral de clasificación elegido por F_2 (Sección 4.5), junto con la matriz de confusión completa; F1 se sigue reportando por ser la referencia más estándar en la literatura, aunque no es la métrica que decide dónde queda el umbral que se elige mediante F_2 . El foco del análisis está en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo a partir de diferencias de AUC-ROC que, como se documenta en la Sección 5.2, resultan pequeños frente a la variabilidad esperable por aleatoriedad del ajuste.

4.5. Tratamiento del desbalance de clases

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4% (Tabla 3), un desbalance que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.

Esa selección, sin embargo, no siempre es robusta al azar del propio particionado de validación cruzada: para HistGradientBoosting-A, repetir la comparación de balanceo con 5 semillas distintas de `StratifiedKFold` (`diagnostico_estabilidad_balanceo.py`) cambia la estrategia ganadora en 3 de 5 corridas —“balanced” gana con dos semillas, “ninguno” con otras dos, y *oversampling* con la restante—, con un AUC-CV que varía apenas en el tercer decimal entre estrategias dentro de cada semilla (rango de 0.0013 a 0.0022). Esto no invalida el procedimiento —la estrategia elegida para cada algoritmo en el resto del documento es siempre la de la semilla base (`RANDOM_STATE=42`), fijada *ex ante*, no elegida *ex post* entre semillas—, pero sí indica que, al menos para este algoritmo y especificación, la diferencia entre estrategias de balanceo está dentro del margen de ruido del particionado,

no es una preferencia robusta del algoritmo por una estrategia en particular.

Un hallazgo metodológico relevante de este ejercicio: en XGBoost y en LightGBM (Modelo B), la estrategia “sin ajuste” ganó la comparación por una diferencia de AUC-ROC frente a la reponderación de apenas 0.001 (estadísticamente indistinguible), pero el modelo resultante, sin corregir el desbalance de clases, produjo probabilidades tan comprimidas hacia valores bajos que casi ninguna observación cruzaba el umbral convencional de 0.5 (recall de 3%–4% en XGBoost, con precision superior a 60%: el modelo ordenaba razonablemente bien los hogares por riesgo, pero era inútil en la práctica al umbral estándar). Esto ilustra que el umbral 0.5 es arbitrario cuando la clase positiva no es 50% de la muestra, y que distintas estrategias de balanceo calibran las probabilidades de forma distinta, por lo que comparar recall/precision/F1 a un umbral fijo entre estrategias no es una comparación válida. La solución adoptada fue elegir el umbral de clasificación de cada modelo por validación cruzada, igual que los hiperparámetros: sobre las probabilidades *out-of-fold* (10 particiones) se evalúa una grilla de umbrales entre 0.02 y 0.98 y se elige el que maximiza una métrica que combina recall y precision –el AUC-ROC, que no depende de umbral, y sigue siendo el criterio que decide la estrategia de balanceo y los hiperparámetros en el paso anterior; el umbral solo determina cómo se reportan recall, precision y F1 una vez el modelo ya está fijo.

La métrica elegida para esa búsqueda de umbral es F_2 (F-beta con $\beta = 2$) en vez del F1 convencional. F1 es la media armónica de recall y precision con el mismo peso para ambos, una elección razonable cuando un falso negativo (un hogar que sí cae en pobreza y el modelo no lo marca como en riesgo) y un falso positivo (un hogar que el modelo marca como en riesgo y no cae) son igual de costosos. En un sistema de focalización de política social eso no es cierto: dejar sin detectar a un hogar que va a entrar en pobreza es muy costoso socialmente –no recibe el apoyo que necesitaría–, es un costo mucho mayor que incluir de más a un hogar que no cae, que en el peor caso implica un gasto de focalización mal dirigido pero no la ausencia de una protección que se necesita. F_2 formaliza esa prioridad ponderando el recall el doble que la precision al elegir el umbral, de modo que el modelo se ajusta para dejar pasar menos casos reales de entrada a la pobreza, a costa de marcar como riesgo a más hogares que finalmente no caen.

Para los algoritmos sin soporte de datos faltantes (regresión logística y Random Forest), la imputación de valores faltantes, que en esta base de datos son mayoritariamente por la estructura de la encuesta, es decir, causados por preguntas filtro del cuestionario (por ejemplo, el monto de una ayuda recibida no se pregunta a quien respondió que no recibió ninguna)– usa sistemáticamente el valor 0 combinado con una columna indicadora binaria de faltante por variable. Esta elección evita que la mediana –calculada únicamente sobre

quienes pasaron el filtro y respondieron— le asigne a los hogares excluidos por el filtro un valor “típico” que en realidad no tienen, y tiene además la propiedad de que, en un modelo lineal, el relleno no aporta ninguna contribución a la predicción más allá de la que capture el propio indicador de faltante. Las variables categóricas se imputan con una categoría explícita “Sin dato” en vez de la moda, para no disfrazar la ausencia estructural como el valor más común. XGBoost, LightGBM y HistGradientBoosting no requieren esta imputación: manejan los datos faltantes de forma nativa en la partición de los árboles, lo que convierte el propio patrón de *missingness* en una señal explotable por el modelo (por ejemplo, la ausencia de datos de vacunación infantil ya codifica indirectamente que el hogar no tiene hijos pequeños) en vez de forzar un supuesto de imputación potencialmente sesgado.

4.6. Importancia de variables e interpretabilidad

Para cada modelo se reporta una medida de importancia de variables acorde a su naturaleza: los coeficientes estandarizados (con signo) de la regresión logística; la importancia por reducción de impureza (`feature_importances_`) de Random Forest, XGBoost y LightGBM; y la importancia por permutación (*permutation importance*, AUC-ROC sobre el conjunto de prueba, 10 repeticiones) de HistGradientBoosting, más costosa computacionalmente pero más robusta a la correlación entre covariables que la importancia basada en impureza. La comparación de estas listas de variables más importantes entre el Modelo A y el Modelo B (Sección 5.2) es la primera aproximación a la pregunta de qué información no monetaria es más predictiva de la transición a la pobreza, antes de la incorporación de las variables geoespaciales (Sección 6.3). Como estas medidas no comparten unidad entre algoritmos (impureza vs. coeficiente estandarizado vs. caída de AUC-ROC), se complementan con valores SHAP (*SHapley Additive exPlanations*) para los cinco algoritmos sobre los Modelos A y B, que sí son comparables en una misma escala —la contribución promedio, en valor absoluto, de cada variable a la predicción de cada hogar— y que además satisfacen aditividad (la suma de los SHAP values de un hogar reconstruye exactamente su predicción) y consistencia (si un modelo pasa a depender más de una variable, su SHAP value nunca puede bajar). Los resultados se presentan en la Sección 5.2.

5. Resultados

A continuación se presentan los resultados en cinco partes, desde dos metodologías distintas, un análisis descriptivo (univariado) y un análisis predictivo (multivariado). La Sección 5.1 es un análisis **univariado e inicial**: perfila al hogar vulnerable —el que entra en pobreza— contra los otros tres grupos de la matriz de transición, variable por variable

(sin controlar por las demás covariables), para las 53 (monetaria) y 36 (IPM) covariables que se hallaron como las más robustas para discriminar entre los grupos. Su función es exploratoria y descriptiva: construir la intuición sobre quién es el hogar vulnerable antes de imponerle cualquier supuesto de modelo. La Sección 5.2 cambia de metodología –pasa a un enfoque **multivariado**– y de objetivo: ya no describe diferencias marginales entre grupos, sino que busca **predecir** la vulnerabilidad a partir del conjunto de covariables, con la mira puesta en generar insumos para una política pública diferenciada (focalización de programas de prevención hacia quienes el modelo señala en mayor riesgo, distinto de los programas de alivio dirigidos a quien ya es pobre). Compara el desempeño fuera de muestra de los cinco algoritmos bajo las especificaciones con y sin ingreso/gasto del hogar. Es de aclarar, que la importancia de las variables puede variar según el algoritmo utilizado, la especificación del modelo y frente al análisis univariado. Las Secciones 5.3 y 5.4 y 5.5 se mantienen en el mismo objetivo de informar posibles insumos para la política pública, pero revisan la utilidad metodológica de otras herramientas bajo ese mismo interés: evalúan si agregar DMS-OLS mejora esa predicción, bajo pobreza monetaria e IPM respectivamente y por qué, y si ese efecto –nulo en promedio bajo monetaria, pequeño bajo IPM– es igual en la población o se concentra en subgrupos específicos.

5.1. Perfil de los hogares vulnerables

Esta sección perfila los hogares que **entran en pobreza** entre 2010 y 2013 –no pobres en la ola inicial, pobres en la siguiente– contra los otros tres grupos de la matriz de transición (Sección 4.1), sobre las 53 covariables que distinguen de forma confiable a los cuatro grupos entre sí (criterio de selección en la Sección 4.2),¹ sin colapsar las correlacionadas entre sí, en una sola tabla consolidada (Tabla 5).

Hay cuatro hallazgos principales de este análisis. **Primero**, el hogar vulnerable se parece mucho más al que *acaba de salir* de la pobreza que al que nunca fue pobre o al que nunca sale de ella: de las 53 variables, 47 lo ubican numéricamente más cerca de “sale de la pobreza” que de “nunca pobre” (en promedio, cerca de cuatro veces más cerca) – Tabla 5. El patrón se repite, y se refuerza, en la transición 2013→2016 (49 de 53 variables más cerca de “sale”): no depende de una sola ola del panel. Tampoco depende de cómo se mida la pobreza: el mismo ejercicio repetido bajo pobreza multidimensional (IPM, 36 variables robustas bajo el mismo criterio de la Sección 4.2, Anexo A.3) confirma el mismo contraste (sale vs. nunca) en 29 de 36 variables en 2010→2013 y 31 de 35 en 2013→2016 – el patrón es robusto tanto a la ola como a la definición de pobreza. Esto es consistente con

¹40 de 53 superan 0.10; las 13 restantes cumplen efecto > 0.05 y robustez en *ambas* transiciones por separado. Las 40 originales no se sometieron a ese chequeo: 2 (`n_ninos_12`, `razon_dependencia_demografica`) caen bajo 0.10 en 2013→2016 (0.105→0.084 y 0.104→0.088), aunque siguen robustas.

pensar “entra” y “sale” como las dos caras de una misma frontera –hogares que cruzan la línea de pobreza en direcciones opuestas, con un perfil similar por estar ambos cerca de ese umbral–, y no como dos tipos de hogar distintos. **Segundo**, cuatro variables (marcadas [†] en la tabla) rompen ese patrón, es decir, diferencian mejor a los hogares vulnerables de los demás grupos, todas en la misma dirección –el hogar vulnerable queda en el extremo *más favorable*, no en el segundo peor–. La más importante es la *formalidad laboral del jefe*, la señal que convencionalmente se usaría para descartar riesgo: 62.3 % de los jefes de hogar vulnerables son asalariados, más que quien sale (52.2 %) y más que quien nunca cae (57.9 %). En 2013→2016 esa ventaja frente a quien sale se mantiene (52.3 % frente a 46.9 %), pero deja de superar a quien nunca cae (55.3 %). Las otras tres son menores pero van en la misma dirección: *deuda informal* (26.0 % frente a 22.7 % de los que salen), *niños al cuidado de terceros* (98.9 % frente a 98.2 % de los que nunca son pobres) y *transporte público comunitario* (79.2 % frente a 78.2 % de los que nunca son pobres). Estas tres no se sostienen en 2013→2016: el vulnerable vuelve al orden esperado, entre “sale” y “siempre pobre”, en las tres –consistente con que su efecto (0.051–0.058) apenas superaba el umbral de robustez, un orden de magnitud por debajo del de formalidad laboral (0.393). Si una política de focalización usara solo la formalidad laboral del jefe en 2010, habría clasificado a los hogares vulnerables como los *menos* necesitados de los cuatro grupos –el ejemplo más concreto de por qué un estado socioeconómico observado no revela el riesgo futuro de un hogar, y en el caso del empleo formal, activamente lo oculta.

Cuadro 5: Perfil por grupo de transición, pobreza monetaria (2010→2013), las 53 variables robustas. [†]variable donde el hogar vulnerable no queda entre “sale” y “siempre pobre”/“nunca pobre” como el resto (ver texto).

Variable	Siempre	Sale	Entra	Nunca	Variable	Siempre	Sale	Entra	Nunca
Educación y empleo del jefe					Geoespacial				
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %	Iluminación nocturna (DMSP)	21.6	32.6	36.4	50.1
Ocupación del jefe: Asalariado [†]	34 %	52 %	62 %	58 %	Activos del hogar				
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %	N.º de bienes durables	4.58	6.00	6.30	9.10
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %	N.º de servicios públicos	2.50	3.30	3.65	4.80
Negocio del jefe: De 20 a 49 personas	9 %	16 %	22 %	25 %	Estrato (verificado)	1.59	2.06	2.07	2.63
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22	Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %	Estrato (autorreportado)	1.60	2.07	2.05	2.58
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72	Tiene internet en el hogar	8 %	16 %	13 %	46 %
Etnia del jefe: Indígena	12 %	6 %	6 %	4 %	N.º de activos financieros	0.10	0.42	0.45	0.86
Jefe cotiza a pensión	6 %	21 %	24 %	43 %	Tiene vehículo	17 %	25 %	23 %	40 %
Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %	Vivienda: hacinamiento				
Afiliación a pensión (hogar)	27 %	51 %	48 %	57 %	Valor del arriendo pagado	144k	226k	240k	354k
Afiliación a salud laboral (hogar)	33 %	55 %	58 %	62 %	Personas por cuarto	2.13	1.65	1.49	1.11
Jefe afiliado a salud laboral	35 %	53 %	61 %	64 %	Personas por dormitorio	2.77	2.25	2.09	1.74
Jefe afiliado a pensión	29 %	49 %	51 %	58 %	Programas sociales y deuda				
Vivienda: materiales y servicios					Beneficiario de Familias en Acción	53 %	29 %	23 %	7 %
Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %	N.º de programas sociales	0.73	0.42	0.34	0.17
Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %	Beneficiario de algún programa social	60 %	37 %	31 %	15 %
Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %	Tiene deuda informal [†]	32 %	23 %	26 %	9 %
Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %	Tiene deuda formal	65 %	75 %	73 %	88 %
Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %	Composición del hogar				
Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %	N.º de niños en el hogar	1.45	0.92	0.79	0.57
Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %	Razón de dependencia demográfica	0.93	0.67	0.56	0.43
Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %	Niños al cuidado de terceros [†]	86 %	94 %	99 %	98 %
Financió la vivienda con crédito formal	13 %	26 %	22 %	43 %	Niños con apoyo alimentario escolar	81 %	72 %	70 %	54 %
Tiene escritura de la vivienda	67 %	81 %	80 %	90 %	Comunidad				
Zona de residencia					N.º de espacios públicos en la comunidad	1.57	1.98	2.13	2.32
Vive en zona rural	69 %	52 %	45 %	21 %	Comunidad con transporte público [†]	55 %	75 %	79 %	78 %
					Ingreso y gasto				
					Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26
					Ingreso per cápita	65k	93k	269k	633k
					Gasto per cápita	154k	210k	247k	662k
					Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36

Tercero, y no visible en el promedio agregado: el grupo “entra en pobreza” no es un solo tipo de hogar, sino dos trayectorias distintas que el análisis de dos olas (2010→2013) no alcanza a distinguir. Siguiendo a esos mismos 723 hogares que entran a pobreza - los vulnerables - hasta la tercera ola (610 con dato en 2016), se pueden separar según qué pasa después: *pobre transitorio* –vuelve a salir antes de 2016– (355 hogares, 58 %) y *pobre persistente* –sigue pobre en 2016– (255 hogares, 42 %; Tabla 6). En ambos subgrupos se mantiene el patrón del primer hallazgo: transitorio se parece más a “sale” que a “nunca cae” en 39 de 53 variables, y persistente en 44 de 53. Pero el promedio de “entra” esconde un gradiente que solo aparece al separarlos: "pobre persistente" se acerca al extremo “siempre

pobre” en 11 de esas 53 variables, frente a solo 2 en “pobre transitorio”. Es decir, dentro de quienes entran a pobreza, quien va a quedar atrapados ya se parece un poco más al hogar crónicamente pobre, aunque el patrón dominante siga siendo el de la frontera con “sale”. Al revisar las variables que caracterizan a estos grupos, el caso más claro es la *deuda informal*: el promedio de “entra” (26.0 %) esconde que pobre transitorio (17.3 %) queda por *debajo* incluso de “sale” (22.7 %), mientras pobre persistente (41.9 %) supera a los cuatro grupos, incluido “siempre pobre” (31.6 %) –separa, dentro del propio grupo vulnerable, a quien va a recuperarse rápido de quien va a quedar atrapado-. Este patrón no es exclusivo de la deuda: *cotizar a pensión* y el *acceso a deuda formal* muestran la misma divergencia (Tabla 6) –la misma frontera de formalidad laboral y financiera que separa a “entra” de “sale” en el Hallazgo 2 reaparece dentro de “entra”(los vulnerables) para separar a quien se recupera (pobre transitorio) de quien queda atrapado (pobre persistente). Este gradiente también se confirma bajo IPM: pobre persistente queda más cerca de “siempre pobre” que de “sale” en 11 de 36 variables, frente a 5 de 36 en pobre transitorio – misma dirección, magnitud comparable.

Cuadro 6: Perfil del hogar vulnerable (“entra en pobreza”, 2010→2013) desagregado por trayectoria a 2016: transitorio ($n = 355$, vuelve a salir) vs. persistente ($n = 255$, se queda pobre). Valores ponderados por grupo; filas superiores, resumen agregado sobre las 53 variables; filas inferiores, ejemplos puntuales donde el promedio agregado (Sección 5.1) ocultaba una divergencia entre subgrupos.

Variable	Siempre	Sale	Transitorio	Persistente	Nunca
Más cerca de “sale” que de “nunca” (de 53)	–		39/53	44/53	–
Más cerca de “siempre” que de “sale” (de 53)	–		2/53	11/53	–
Jefe asalariado	34.4 %	52.2 %	64.9 %	61.7 %	57.9 %
Jefe cotiza a pensión	6.4 %	21.3 %	33.0 %	12.0 %	42.8 %
Tiene deuda informal	31.6 %	22.7 %	17.3 %	41.9 %	9.4 %
Tiene deuda formal	65.2 %	74.6 %	81.4 %	57.5 %	88.3 %
Comunidad con transporte público	54.6 %	75.4 %	84.9 %	78.2 %	78.2 %

Nota: de los 723 hogares que entran en pobreza entre 2010 y 2013, 610 tienen dato de la ola 2016 (113 se pierden por atrición, misma tasa que el resto del panel); de esos 610, 355 (58 %) vuelven a salir de la pobreza para 2016 y 255 (42 %) se quedan pobres. Fuente: cálculos propios, `perfil_split_transitorio_persistente_monetaria.csv` (`src/02_build/eda_perfil_split_trayectoria.py`).

Cuarto, el núcleo del perfil no depende de cómo se mida la pobreza: de las 53 variables robustas bajo monetaria y las 36 bajo IPM, 28 son comunes a ambas definiciones –vivienda, ingreso/gasto, educación y ocupación del jefe, riqueza, bienes durables, servicios públicos, DMSP– (Tabla 7). Que más de la mitad de cada conjunto coincida, pese a partir de

dos definiciones de pobreza y dos criterios de selección independientes, sugiere que el perfil del hogar vulnerable no es una casualidad de cómo se define “pobre”, sino una estructura más estable detrás de ambas medidas. Las 25 variables exclusivas de monetaria son mayoritariamente financieras y comunitarias. Las 8 exclusivas de IPM incluyen, de forma reveladora, la pobreza monetaria del propio hogar en 2010 (**pobre_ingreso** y análogas): ser pobre por ingreso en la ola base es, en sí mismo, uno de los mejores predictores univariados de caer en pobreza multidimensional después, sin que la relación inversa se sostenga con la misma fuerza.

Cuadro 7: Núcleo del perfil de vulnerabilidad: las 28 variables robustas comunes a pobreza monetaria (53 variables, Tabla 5) y a pobreza multidimensional –IPM– (36 variables, Anexo A.3). Valores bajo pobreza monetaria, transición 2010→2013.

Variable	Siempre	Sale	Entra	Nunca
Activos del hogar				
N.º de bienes durables	4.58	6.00	6.30	9.10
N.º de servicios públicos	2.50	3.30	3.65	4.80
Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06
Composición del hogar				
Niños al cuidado de terceros	86 %	94 %	99 %	98 %
Educación y empleo del jefe				
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %
Ocupación del jefe: Asalariado	34 %	52 %	62 %	58 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72
Etnia del jefe: Indígena	12 %	6 %	6 %	4 %
Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %
Geoespacial				
Iluminación nocturna (DMSP)	21.6	32.6	36.4	50.1
Ingreso y gasto				
Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26

Variable	Siempre	Sale	Entra	Nunca
Ingreso y gasto (cont.)				
Ingreso per cápita	65k	93k	269k	633k
Gasto per cápita	154k	210k	247k	662k
Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36
Vivienda: hacinamiento				
Personas por cuarto	2.13	1.65	1.49	1.11
Vivienda: materiales y servicios				
Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %
Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %
Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %
Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %
Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %
Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %
Zona de residencia				
Vive en zona rural	69 %	52 %	45 %	21 %

Fuentes geoespaciales públicas. La luz nocturna del hogar (DMSP-OLS, escala 0–63) separa monotónicamente los cuatro grupos de la matriz de transición, tanto en media como en mediana, bajo pobreza monetaria e IPM, en la transición 2010→2013 (Figura 6): de “siempre pobre” a “nunca pobre”, el valor típico sube en cada paso. Puesto a prueba contra el patrón del Hallazgo 1 (que “entra en pobreza” (vulnerable) se parece más a “sale de la pobreza” que a “nunca pobre”), el resultado depende de qué definición de pobreza y qué estadístico se use. Bajo IPM la mediana confirma el patrón con margen amplio: “entra en pobreza” (vulnerable) (10.7) queda a solo 2.9 puntos de “sale de la pobreza” (7.8) y

a 38.4 de “nunca pobre” (49.1). Bajo monetaria, en cambio, la mediana en 2010→2013 es mucho más débil: “entra en pobreza” (vulnerable) (40.6) queda casi equidistante entre “sale de la pobreza” (19.9, distancia 20.7) y “nunca pobre” (61.5, distancia 20.9). Este resultado débil, sin embargo, no se sostiene en la transición 2013→2016 –verificable porque DMSP-OLS, a diferencia de ALOS PALSAR y Landsat 5 TM, sí tiene cobertura real en ambas olas (Sección 3)–: ahí la mediana de “entra en pobreza” (vulnerable) (21.6) vuelve a quedar mucho más cerca de “sale de la pobreza” (12.7, distancia 8.9) que de “nunca pobre” (59.9, distancia 38.3), replicando el Hallazgo 1. La debilidad de 2010→2013 parece entonces ruido muestral de esa ola, no una excepción real al patrón. ALOS PALSAR (radar) sigue el mismo gradiente que DMSP-OLS y Landsat NDVI lo invierte (más verde en pobreza persistente, por ruralidad), pero ambas fuentes solo tienen datos reales en la ola 2010: a diferencia de DMSP-OLS, no es posible poner a prueba si esos patrones se sostienen en la transición 2013→2016, así que se reportan como exploratorios, con menor respaldo que el resto del perfil. Además, la Sección 5.3 muestra que la separación de DMSP-OLS es en gran parte redundante con servicios públicos y bienes durables ya en la encuesta. En otras palabras, DMSP-OLS separa bien y permite distinguir entre los grupos, pero aporta poca información nueva porque es información que ya se encuentra disponible en la encuesta.




Figura 6: Iluminación nocturna (DMSP-OLS) por grupo de transición, media y mediana, pobreza monetaria e IPM (2010→2013).

El mismo patrón se confirma por región: la pobreza persistente se concentra en microrregiones rurales andinas (Cundi-Boyacense, Centro-Oriente, Atlántica Media, 64–66 % siempre pobres, DMSP<9), mientras Bogotá concentra los nunca pobres (70 %, DMSP=63). La variable *region* de ELCA combina, sin embargo, dos muestras bajo el mismo nombre: Atlántica, Oriental, Central, Pacífica y Bogotá son exclusivamente urbanas; Atlántica Media, Cundi-Boyacense, Eje Cafetero y Centro-Oriente, exclusivamente rurales. *Pacífica*

en la Figura 7 representa entonces solo su muestra urbana, y el diseño rural de ELCA no incluye al Chocó rural ni a La Guajira –las zonas de mayor pobreza persistente del país–: ELCA no permite caracterizar esos bolsones, y las etiquetas *(urbano)/(rural)* de la figura hacen visible la limitación.




Figura 7: Grupo de transición dominante por región e iluminación nocturna (DMSP), pobreza monetaria, 2010→2013.

5.2. Desempeño comparativo de modelos

La Tabla 8 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.4 y 4.5).²

²Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Hist-GradientBoosting y la regresión logística en el Modelo A, y Random Forest y la regresión logística en el Modelo B, donde fue *balanced* (reponderación de clases).

Cuadro 8: Desempeño de los cinco algoritmos, holdout temporal (train 2010→2013, test 2013→2016). Media sobre 5 semillas del ajuste final. Umbral elegido por CV maximizando F-beta ($\beta = 2$), CV_FOLDS=10, N_ITER_BUSQUEDA=30. Precision-top10: precisión entre el 10 % de hogares de mayor riesgo.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precision	Prec.-top10	F1
XGBoost	A	0.11	0.767	0.949	0.264	0.505	0.413
Random Forest	A	0.14	0.766	0.926	0.277	0.486	0.426
HistGradientBoosting	A	0.32	0.763	0.909	0.283	0.512	0.432
LightGBM	A	0.10	0.758	0.903	0.281	0.516	0.428
Logística regularizada	A	0.37	0.747	0.883	0.280	0.506	0.426
Random Forest	B	0.31	0.742	0.892	0.272	0.508	0.416
XGBoost	B	0.13	0.742	0.940	0.250	0.495	0.395
Logística regularizada	B	0.35	0.739	0.890	0.270	0.500	0.414
HistGradientBoosting	B	0.14	0.735	0.879	0.275	0.494	0.418
LightGBM	B	0.15	0.731	0.909	0.259	0.487	0.403

Nota: umbral elegido por validación cruzada maximizando F_2 en cada semilla (Sección 4.5), no fijo en 0.5; se reporta el promedio de las 5 semillas. El umbral es considerablemente más bajo que en una búsqueda equivalente por F1 –al pesar el recall el doble, F_2 empuja el punto de corte hacia abajo para dejar pasar más casos de entrada a la pobreza, a costa de más falsos positivos (columna Recall, sistemáticamente sobre 0.88, frente a un F1 más moderado). Prec.-top10: precisión entre el 10 % de hogares que el modelo señala como de mayor riesgo, la cifra más relevante para un programa de focalización con capacidad fija (Sección 4.4).

Dos patrones organizan esta comparación, más allá de las diferencias puntuales entre algoritmos y especificaciones (Tabla 8). **Primero**, el algoritmo elegido no cambia el poder de discriminación (AUC-ROC 0.731–0.767 en los cinco), pero sí determina cuánta capacidad de cobertura necesita un programa para no perder casos reales –y ese costo, con cualquier algoritmo, ronda los 3–4 hogares atendidos por cada 1 que realmente lo necesitaba (Tabla 9). La comparación entre algoritmos es indicativa, no concluyente: sus intervalos de confianza se traslapan y no se corrió una prueba pareada (DeLong) que la haga formal. El costo de cobertura sí varía de forma notable entre ellos incluso con AUC casi idéntico –HistGradientBoosting identifica correctamente al 40 % de los hogares seguros, XGBoost solo al 26 %–, y en parte es una decisión de diseño: el umbral elegido por F_2 , no solo el algoritmo, determina dónde se cae dentro del techo que impone el AUC. Lo que sí es una restricción real, de la que ninguna combinación de algoritmo y umbral escapa, es que con un AUC-ROC de 0.75 no es posible lograr recall y precision altos simultáneamente. Bajo IPM el mismo techo aparece, en un rango de AUC igual de estrecho (0.725–0.747; Tabla 22, Anexo A.4).

Segundo, ese costo apenas cambia si se excluye el ingreso/gasto del hogar de las

covariables –la ganancia de incluir esa información, la más cara de levantar, es marginal (brecha de AUC de 0.008 a 0.028 entre el Modelo A y B, mucho menor de lo que predeciría un enfoque de vulnerabilidad puramente monetario, Chaudhuri et al. (2002)). Esto no implica que el ingreso no importe –univariadamente es de las variables que más separa a los cuatro grupos de la matriz de transición (Sección 5.1)–, sino que su contenido informativo ya está sustancialmente duplicado por otras variables del núcleo del perfil (riqueza, educación, bienes durables; Hallazgo 4, Sección 5.1). Bajo IPM la brecha es aún menor, y para Random Forest y XGBoost es negativa –el Modelo B supera al A–, lo que descarta que la brecha chica bajo monetaria se deba a la relación mecánica entre ingreso y la definición de esa pobreza: ni siquiera donde el ingreso no define el resultado ayuda incluirlo. La implicación práctica sigue la misma lógica que sustenta focalizar con proxies observables del ingreso en vez de medirlo directamente (McBride & Nichols, 2018): un instrumento más barato, sin ingreso/gasto detallado, rendiría casi lo mismo.

Cuadro 9: Matriz de confusión, Modelo A, holdout temporal (test 2013→2016, $n = 3,191$, semilla 42). VN/FP/FN/VP: hogares verdadero negativo, falso positivo, falso negativo y verdadero positivo al umbral de clasificación de la Tabla 8.

Algoritmo	VN	FP	FN	VP	% muestra marcada	% seguros identificados
XGBoost	668	1888	18	617	78.5 %	26.1 %
Random Forest	984	1572	41	594	67.9 %	38.5 %
HistGradientBoosting	1024	1532	51	584	66.3 %	40.1 %
LightGBM	1202	1354	74	561	60.0 %	47.0 %
Logística regularizada	1112	1444	74	561	62.8 %	43.5 %

Las Figuras 8 y 9 muestran las variables más importantes de Random Forest y los mayores coeficientes –en valor absoluto, en unidades estandarizadas– de la regresión logística, ambos para el Modelo A y ya bajo la metodología final (umbral por F_2 , CV_FOLDS=10, N_ITER_BUSQUEDA=30): en vez de repetir la búsqueda de hiperparámetros –ya decidida y registrada en `registro_modelos_fbeta2_cv10.csv`– `modelo_fbeta2_cv10_importancia.py` reconstruye el pipeline ganador exacto de cada algoritmo/especificación a partir de esa fila y lo reentrena una única vez sobre todo el conjunto de entrenamiento; el resultado es determinista (mismo RANDOM_STATE=42, sin búsqueda aleatoria de por medio) y el propio script verifica, cada vez que corre, que reproduce exactamente el CSV de la corrida anterior. En Random Forest, el índice de riqueza precalculado de la ELCA (`riqueza_pca_hogar`) y el ingreso per cápita real dominan claramente (consistente con Chaudhuri et al. (2002)), seguidos de cerca por la brecha a la LP, el gasto per cápita real y el número de bienes durables del hogar. En la regresión logística, en cambio, el nivel educativo máximo del

hogar tiene el mayor coeficiente en valor absoluto, por encima incluso de la brecha a la LP y el ingreso real –con signo negativo, consistente con que más educación reduce la probabilidad de caer en pobreza–, seguido por el número de bienes durables y de servicios públicos del hogar. Esta diferencia entre algoritmos –qué variable “domina” según se mida por reducción de impureza o por magnitud de coeficiente estandarizado– es en sí misma evidencia de que la importancia de variables no es una propiedad única del problema sino que depende parcialmente de cómo cada algoritmo particiona la información, un matiz relevante para la interpretación de resultados de esta naturaleza.




Figura 8: Variables más importantes, Random Forest, Modelo A (reducción de impureza).




Figura 9: Mayores coeficientes en valor absoluto, regresión logística regularizada, Modelo A (unidades estandarizadas).

En el Modelo B (sin ingreso/gasto), Random Forest ubica el índice de riqueza precalculado y el número de bienes durables del hogar como las dos variables más importantes, seguidas por el nivel educativo máximo del hogar; la regresión logística, en cambio, ubica el nivel educativo máximo del hogar primero, seguido por el número de bienes durables y de servicios públicos y –solo en la regresión logística– la tasa de cotización a pensión del hogar, un proxy de formalidad laboral. Estas variables son consistentes con los determinantes de pobreza documentados en la literatura y no sugieren que el modelo esté capturando relaciones espurias.

Los valores SHAP (`src/05_model/diagnostico_shap_ab.py`, reconstruyendo el pipeline ganador de cada algoritmo/especificación ya registrado, sin repetir la búsqueda de hiperparámetros) confirman el patrón anterior y permiten además compararlo en una misma escala entre los cinco algoritmos. En el Modelo B, `riqueza_pca_hogar` y `nivel_educ_max_hogar` quedan siempre entre las dos variables más importantes en los cinco algoritmos –la primera domina en HistGradientBoosting y Random Forest, la segunda en LightGBM, Logística y XGBoost–, seguidas casi siempre por `n_bienes_durables_hogar` en tercer lugar. En el Modelo A el acuerdo es más parcial: LightGBM, XGBoost, Logística y Random Forest coinciden en que `ingreso_percapita_hogar_real`, `nivel_educ_max_hogar`, `riqueza_pca_hogar` y `brecha_lp_ingreso` son las cuatro variables más importantes (en distinto orden entre sí), pero HistGradientBoosting es una excepción notable: su variable más importante es `pct_adultos_alfabetizados` (SHAP medio 0.394, más del doble que

la segunda), que no aparece entre las 8 primeras de ningún otro algoritmo. Esto no invalida la lectura general –las variables de riqueza, ingreso y educación siguen dominando en 4 de 5 algoritmos–, pero es un recordatorio de que “la variable más importante” puede depender de cómo un algoritmo específico particiona la información, no solo del contenido informativo de la variable en sí.




Figura 10: Valores SHAP, XGBoost, Modelo A (holdout de prueba 2013→2016). Cada punto es un hogar; el color indica el valor de la variable (rojo = alto, azul = bajo) y la posición horizontal su contribución a la probabilidad predicha de entrar en pobreza.




Figura 11: Valores SHAP, XGBoost, Modelo B (sin ingreso/gasto), holdout de prueba 2013→2016.

5.3. Contribución marginal de las variables geoespaciales

Esta subsección evalúa si DMSP-OLS –la única de las tres fuentes nuevas con datos reales tanto en la ola de entrenamiento (2010) como en la de prueba (2013), Sección 3.2– mejora el desempeño del benchmark cuando se agrega a las covariables de la ELCA, bajo el mismo holdout temporal, balanceo de clases y selección de umbral ya usados en la Sección 5.2. Se reentrenaron los cinco algoritmos de esa comparación agregando a los Modelos A y B las 23 variables DMSP-OLS de estado y ventana acumulada (Sección 3.2) –

en el código y en los archivos de resultados esta comparación se identifica como A/AgeoDMSP y B/BgeoDMSP; aquí se usa la forma expandida “A” / “A + DMSP-OLS” por legibilidad. Se agrega además `precision_top10` –la precisión entre el 10 % de hogares que el modelo señala como de mayor riesgo– porque para un programa de focalización con capacidad fija esta cifra es más relevante que `recall`/`precision`/`F1` a un umbral de probabilidad, que no reflejan ninguna restricción real de cobertura. Aun así, para no dejar una lectura incompleta, la Tabla 10 también reporta esas tres métricas al umbral de clasificación ya elegido por validación cruzada maximizando F_2 (Sección 4.5): *recall* es la fracción de hogares que sí cayeron en pobreza y el modelo efectivamente marcó como riesgo (cuánto de la pobreza real se captura); *precision* es la fracción de los hogares marcados como riesgo que efectivamente cayeron en pobreza (cuánta de la alarma es acertada, no falsa alarma); *F1* resume ambas en un solo número (su media armónica) y se reporta como referencia estándar, aunque –a diferencia del umbral, elegido por F_2 – no es la métrica que decide dónde queda el punto de corte.

Cuadro 10: AUC-ROC y precisión en el decil de mayor riesgo, con y sin DMSP-OLS, holdout temporal (train 2010→2013, test 2013→2016). Umbral elegido por CV maximizando F-beta ($\beta = 2$), con CV_FOLDS=10 y N_ITER_BUSQUEDA=30.

Algoritmo	Especificación	AUC-ROC	IC95 %	Precision top-10 %	IC95 %	Umbral	Recall	Precision	F1
Random Forest	A	0.766	[0.765, 0.767]	0.486	[0.476, 0.495]	0.138	0.926	0.277	0.426
Random Forest	A + DMSP-OLS	0.763	[0.762, 0.764]	0.481	[0.470, 0.493]	0.264	0.938	0.271	0.420
XGBoost	A	0.767	[0.766, 0.769]	0.505	[0.496, 0.514]	0.112	0.949	0.264	0.413
XGBoost	A + DMSP-OLS	0.765	[0.764, 0.766]	0.501	[0.488, 0.515]	0.118	0.937	0.272	0.421
LightGBM	A	0.758	[0.758, 0.758]	0.516	[0.516, 0.516]	0.096	0.903	0.281	0.428
LightGBM	A + DMSP-OLS	0.752	[0.752, 0.752]	0.497	[0.497, 0.497]	0.102	0.902	0.277	0.424
HistGradientBoosting	A	0.763	[0.763, 0.763]	0.512	[0.512, 0.512]	0.324	0.909	0.283	0.432
HistGradientBoosting	A + DMSP-OLS	0.763	[0.763, 0.763]	0.500	[0.500, 0.500]	0.312	0.912	0.281	0.429
Logística regularizada	A	0.747	[0.747, 0.747]	0.506	[0.506, 0.506]	0.372	0.883	0.280	0.426
Logística regularizada	A + DMSP-OLS	0.746	[0.746, 0.746]	0.500	[0.500, 0.500]	0.370	0.883	0.281	0.426
Random Forest	B	0.742	[0.741, 0.744]	0.508	[0.497, 0.520]	0.306	0.892	0.272	0.416
Random Forest	B + DMSP-OLS	0.739	[0.737, 0.741]	0.492	[0.482, 0.502]	0.266	0.925	0.255	0.399
XGBoost	B	0.742	[0.742, 0.743]	0.495	[0.487, 0.503]	0.126	0.940	0.250	0.395
XGBoost	B + DMSP-OLS	0.740	[0.740, 0.741]	0.495	[0.491, 0.499]	0.128	0.929	0.254	0.399
LightGBM	B	0.731	[0.731, 0.731]	0.487	[0.487, 0.487]	0.148	0.909	0.259	0.403
LightGBM	B + DMSP-OLS	0.737	[0.737, 0.737]	0.481	[0.481, 0.481]	0.126	0.888	0.271	0.415
HistGradientBoosting	B	0.735	[0.735, 0.735]	0.494	[0.494, 0.494]	0.142	0.879	0.275	0.418
HistGradientBoosting	B + DMSP-OLS	0.736	[0.736, 0.736]	0.487	[0.487, 0.487]	0.142	0.880	0.275	0.419
Logística regularizada	B	0.739	[0.739, 0.739]	0.500	[0.500, 0.500]	0.350	0.890	0.270	0.414
Logística regularizada	B + DMSP-OLS	0.739	[0.739, 0.739]	0.494	[0.494, 0.494]	0.350	0.888	0.273	0.417

Nota: recall, precision y F1 se miden al umbral de clasificación ya elegido para cada algoritmo/especificación por validación cruzada maximizando F_2 (Sección 4.5, sin re-elegirlo al agregar DMSP-OLS). Fuente: cálculos propios, data/processed/benchmark_resultados/registro_modelos_fbata2_cv10.csv, generados por src/05_model/modelo_fbata2_cv10_comparacion.py (XGBoost, HistGradientBoosting, Logística regularizada) y sus variantes modelo_fbata2_cv10_comparacion_rf_lgbm.py (Random Forest, LightGBM) sobre modelo_{A,B,AgeoDMSP,BgeoDMSP}_2010_2013/2013_2016.parquet (construidos por construir_pipeline_geo_dmsp.py), y formateados por src/tabla_marginal_dmsp_fbata2_cv10.py.

Resultado: agregar DMSP-OLS no mejora de forma económicamente significativa el desempeño en ningún algoritmo. El AUC-ROC se mantiene igual o cae ligeramente al agregar DMSP-OLS en 8 de las 10 comparaciones algoritmo/especificación de la Tabla 10 (caídas de 0.001 a 0.006). Las dos excepciones son cambios pequeños y en direcciones opuestas entre sí –HistGradientBoosting-B sube de 0.735 a 0.736 (+0.001) y LightGBM-B, el mayor cambio positivo de toda la tabla, sube de 0.731 a 0.737 (+0.006)–, del mismo orden de magnitud que la variabilidad entre semillas del propio ajuste (Tabla 8) y, sobre todo, sin acompañamiento en precision_top10: esta métrica, más relevante para un programa de focalización de capacidad fija, cae o se mantiene igual en las 10 comparaciones sin una sola excepción –incluida LightGBM-B (0.487 → 0.481)–, la señal más clara de que

agregar DMSP-OLS no mejora la capacidad de priorizar correctamente al grupo de mayor riesgo. Antes de interpretar la ausencia de mejora como ausencia de señal, se descartó explícitamente la explicación de sobreajuste: se comparó, para cada algoritmo, la brecha entre el AUC de validación cruzada (calculado solo sobre entrenamiento) y el AUC de prueba real, con y sin DMSP-OLS (`comparar_auc_cv_vs_test_fbeta2_cv10.py`) – si agregar columnas geoespaciales infla artificialmente el ajuste de entrenamiento sin generalizar, esa brecha debería ensancharse. No fue el caso: el mayor cambio observado fue de +0.008 (LightGBM, Modelo A, el mismo par con la mayor caída de AUC-ROC de toda la tabla), muy por debajo del umbral de alerta (0.03) definido *ex ante*. La ausencia de mejora no es, entonces, un problema de sobreajuste del modelo.

Recall, precision y F1 se mueven poco al agregar DMSP-OLS –menos de 0.02 en cualquier dirección en la inmensa mayoría de las comparaciones– porque el umbral elegido por F_2 ya empuja el recall a valores altos (0.88 a 0.95) en las diez filas de la tabla, dejando poco margen para que un cambio de umbral mueva mucho la aguja. El cambio más grande es en **Random Forest, Modelo B**: el recall sube de 0.892 a 0.925 (+0.033) y la precision cae de 0.272 a 0.255, con F1 cayendo de 0.416 a 0.399 –el umbral que la validación cruzada eligió también baja, de 0.306 sin DMSP-OLS a 0.266 con DMSP-OLS, el mecanismo habitual: un umbral más bajo marca más hogares como riesgo, sube el recall a costa de la precision–. Es, otra vez, una consecuencia del procedimiento de selección de umbral (Sección 4.5), no evidencia de que DMSP-OLS cambie la capacidad predictiva del modelo; el AUC-ROC de este mismo par (0.742 $\rightarrow$ 0.739), que no depende de umbral, apenas se mueve. Ningún caso invierte la conclusión general: DMSP-OLS reordena marginalmente qué hogares específicos caen a cada lado del umbral, sin mejorar la capacidad de discriminación subyacente del modelo.

Por qué DMSP-OLS no aporta: redundancia, no ausencia de señal. Tomada sola, `dmsp_stable_lights` sí correlaciona con la entrada a pobreza ($r = -0.214$ sobre la muestra de entrenamiento) –una magnitud comparable a `ingreso_percapita_hogar_real` ($r = -0.211$) o `estrato_verificado_hogar` ($r = -0.215$)–, así que no se trata de una variable sin contenido informativo. El problema es que esa misma señal ya está capturada, de forma más directa y con mayor correlación con el resultado, por variables que la ELCA ya pregunta al hogar: `n_servicios_publicos_hogar` (número de servicios públicos del hogar) correlaciona 0.865 con `dmsp_stable_lights` –ambas miden, en esencia, el mismo fenómeno de electrificación y consolidación urbana del entorno– y a la vez correlaciona más fuerte con el resultado ($r = -0.250$) que la propia variable satelital; `n_bienes_durables_hogar` muestra el mismo patrón ($r = 0.477$ con DMSP-OLS, $r = -0.256$ con el resultado).

La correlación *residualizada* de `dmsp_stable_lights` contra el resultado –tras controlar por esas dos variables mediante regresión lineal, y correlacionar los residuos de ambas contra los residuos del resultado– confirma directamente la redundancia: cae de $r = -0.214$ (cruda) a $r = +0.021$ (parcial, verificado con dos implementaciones independientes, mínimos cuadrados manual y `sklearn.LinearRegression`) –prácticamente todo el poder predictivo de DMSP-OLS ya está contenido en esas dos preguntas de la encuesta. Esto no implica que la encuesta mida el fenómeno subyacente (electrificación y consolidación urbana del entorno) con menos error que el sensor satelital –ambas son medidas imperfectas de ese mismo constructo, y comparar su error de medición respectivo está fuera del alcance de este ejercicio–; lo que sí muestra la correlación residualizada es que, *para este modelo predictivo específico*, DMSP-OLS no aporta información incremental una vez que `n_servicios_publicos_hogar` y `n_bienes_durables_hogar` ya están en el panel de covariables. Esto es consistente con la regularización elastic net de la logística, que puso en cero 21 de las 23 variables DMSP-OLS agregadas (Sección 3.2), y con la importancia por permutación de HistGradientBoosting, donde las variables DMSP-OLS caen en un rango de -0.0009 a 0.0003 –indistinguible de ruido una vez controlado por el resto del panel.

Redundante en poder predictivo, pero más estable en el tiempo. La sección anterior aclaró que comparar el error de medición *transversal* de DMSP-OLS contra el de la encuesta está fuera de alcance. Una pregunta distinta y sí verificable con los datos del panel es la estabilidad *temporal* de cada medida –qué tanto cambia el valor reportado para el mismo hogar entre 2010 y 2013 más allá del cambio real esperable–, relevante porque una variable más volátil entre olas generaliza peor de un periodo a otro, justo el tipo de error que más le costaría a un sistema de alerta temprana. La correlación *test-retest* de `dmsp_stable_lights` entre 2010 y 2013 es 0.958 ($n = 7,428$), frente a 0.905 de `n_servicios_publicos_hogar` y apenas 0.600 de `n_bienes_durables_hogar` –la variable de encuesta que, junto con servicios públicos, explica casi toda la redundancia de DMSP-OLS–; el cambio absoluto medio estandarizado confirma el mismo orden (0.11 en DMSP-OLS, 0.22 en servicios públicos, 0.61 en bienes durables). Es decir, la variable de encuesta que compite con DMSP-OLS en poder predictivo es casi el doble de volátil entre olas que la señal satelital. Esto no contradice la conclusión de redundancia –dentro de esta muestra y este periodo, DMSP-OLS no añade poder predictivo una vez la encuesta ya está disponible–, pero sí matiza su alcance práctico: si el argumento es que DMSP-OLS puede sustituir información de encuesta cuando esta no está actualizada (Sección 6.2), su mayor estabilidad temporal es evidencia directa a favor de esa función, no solo una intuición razonable.

ALOS PALSAR y Landsat 5 TM: mismo patrón, por un mecanismo distinto.

Estas dos fuentes no tienen datos reales en la ola de prueba (2013, Sección 3.2), así que no pueden evaluarse con el mismo holdout temporal – se probaron, junto con DMSP-OLS, en un ejercicio exploratorio aparte: Modelo A/B **con las tres fuentes juntas** (DMSP-OLS + ALOS PALSAR + Landsat 5 TM), restringido a la transición 2010→2013 y evaluado con validación cruzada agrupada por hogar en vez de un periodo de prueba separado (`construir_pipeline_geo3_cv.py`). Los resultados de ese ejercicio **no son comparables cifra a cifra** con la Tabla 10 –evaluar dentro del mismo periodo que el entrenamiento es una prueba más débil que un holdout a otro momento– pero la correlación bruta de sus variables contra el resultado confirma el mismo patrón de redundancia que DMSP-OLS: `alos_hh_db` correlaciona apenas $r = -0.113$ con la entrada a pobreza (frente a $r = -0.250$ de `n_servicios_publicos_hogar`) y `15_ndvi` $r = 0.160$ –ambas más débiles que cualquiera de los proxies de riqueza ya presentes en la ELCA. La misma correlación residualizada calculada para DMSP-OLS, aplicada a `alos_hh_db` y `15_ndvi` controlando por las mismas dos variables, también colapsa a valores cercanos a cero ($r = +0.010$ y $r = +0.011$ respectivamente, frente a $r = -0.113$ y $r = +0.160$ crudos). Ninguna de las tres fuentes geoespaciales nuevas parece aportar, para este panel de encuesta específico, información que la propia ELCA no capture ya de forma más directa.

¿Ayuda DMSP-OLS cuando la encuesta no pregunta por servicios públicos ni bienes del hogar? Si la redundancia con `n_servicios_publicos_hogar` y `n_bienes_durables_hogar` explica la ausencia de mejora, DMSP-OLS debería aportar más en un escenario donde esas dos preguntas no estuvieran disponibles –el caso realista de datos administrativos sin encuesta de hogar rica, o de una ola de encuesta futura sin ese módulo–. Este ejercicio de *ablation* –a diferencia de la Tabla 10– todavía usa el umbral de clasificación por F_1 y la búsqueda de hiperparámetros con $CV_FOLDS=3/N_ITER_BUSQUEDA=8$ de la corrida original (Sección 4.5), no la versión robusta por F_2 con $CV_FOLDS=10/N_ITER_BUSQUEDA=30$ adoptada para las Tablas 8 y 10 –no se ha vuelto a correr bajo ese criterio–, así que sus cifras de AUC-ROC no son directamente comparables punto a punto con las de esas dos tablas, aunque la lógica del ejercicio (redundancia vs. aporte incremental) no depende de esa elección. Se reentrenaron los tres algoritmos eliminando esas dos columnas de los Modelos A y B (“A sin riqueza” / “B sin riqueza” en lo que sigue; `Anoriq/Bnoriq` en el código) y de sus versiones con DMSP-OLS agregado (“A sin riqueza + DMSP-OLS” / “B sin riqueza + DMSP-OLS”; `AnoriqGeo/BnoriqGeo`). El resultado es mixto y, en conjunto, no confirma la hipótesis con fuerza: Logística regularizada es el único algoritmo con una mejora consistente aunque

pequeña (AUC-ROC: “A sin riqueza” 0.7457 $\rightarrow$ “A sin riqueza + DMSP-OLS” 0.7469; `precision_top10`: “A sin riqueza” 0.497 $\rightarrow$ “A sin riqueza + DMSP-OLS” 0.500, y “B sin riqueza” 0.500 $\rightarrow$ “B sin riqueza + DMSP-OLS” 0.503); XGBoost no mejora en ninguna de las dos comparaciones (“A sin riqueza” 0.7635 $\rightarrow$ “A sin riqueza + DMSP-OLS” 0.7615; “B sin riqueza” 0.7350 $\rightarrow$ “B sin riqueza + DMSP-OLS” 0.7341); HistGradientBoosting mejora en el Modelo B sin riqueza pero empeora en el Modelo A sin riqueza. Que el único algoritmo con mejora consistente sea el lineal –el que, por construcción, no puede aprender automáticamente combinaciones no lineales de otras variables que sustituyan a DMSP-OLS– es coherente con la explicación de redundancia: los modelos de árboles, más flexibles, encuentran sustitutos suficientes en el resto del panel incluso sin las dos preguntas eliminadas, mientras que el modelo lineal sí gana algo al no tener esa alternativa. El efecto es, en cualquier caso, demasiado pequeño y demasiado inconsistente entre algoritmos para sostener una recomendación de política a partir de él.

¿Ayuda DMSP-OLS más cerca del umbral de pobreza? Se dividió el conjunto de prueba de XGBoost (Modelo A) en terciles según la distancia absoluta a la línea de pobreza en la ola base (`|brecha_lp_ingreso|`, `heterogeneidad_cerca_umbral.py`), usando los hiperparámetros ya elegidos (sin volver a tunear, para aislar el efecto de agregar DMSP-OLS). El cambio en AUC-ROC al agregar DMSP-OLS es de -0.0008 en el tercil más cercano al umbral ($n = 1,064$, tasa de entrada 32.7 %), $+0.0011$ en el tercil medio ($n = 1,107$, 19.2 %) y -0.0038 en el tercil más lejano ($n = 1,020$, 7.3 %). Aunque la caída es técnicamente menor cerca del umbral que lejos de él, el cambio sigue siendo negativo o prácticamente nulo en los tres terciles –no hay evidencia de que DMSP-OLS ayude de forma sustantiva ni siquiera en el subgrupo de hogares donde el ingreso reportado discrimina peor–.

5.4. Contribución marginal de las variables geoespaciales bajo pobreza multidimensional (IPM)

El mismo ejercicio de la Sección 5.3 –agregar las 23 variables DMSP-OLS a los Modelos A y B, mismo holdout temporal, mismo umbral por F_2 – se repitió con `pobre_ipm` como variable de resultado en vez de la pobreza monetaria (`registro_modelos_ipm.csv`, mismas covariables X , solo cambia el *target*). A diferencia de monetaria, aquí la pregunta de si el cambio de AUC-ROC es distinguible de ruido de muestreo se responde con un bootstrap pareado sobre el conjunto de prueba (`diagnostico_bootstrap_ipm.py`), con una versión adicional que corrige por correlación intra-comunidad agrupando el remuestreo por `id_comunidad` (`diagnostico_bootstrap_cluster_ipm.py`, 1,696 clusters) –el error

estándar ingenuo por hogar puede subestimar la incertidumbre si hogares de una misma comunidad comparten exposición a la misma señal de iluminación.

Cuadro 11: Contribución marginal de DMSP-OLS bajo pobreza multidimensional (IPM), holdout temporal (train 2010→2013, test 2013→2016). Δ AUC-ROC y su IC95 % son del bootstrap pareado sobre el conjunto de prueba (`diagnostico_bootstrap_ipm.py`); p (hogar) no corrige por correlación intra-comunidad, p (cluster) sí (`diagnostico_bootstrap_cluster_ipm.py`, 1,696 clusters). Filas en **negrita**: IC95 % no cruza cero. AUC base/+DMSP son la media de 5 semillas (Sección 5.2); Δ /IC95 %/ p vienen de un bootstrap sobre una sola semilla (42) del mismo conjunto de prueba, por eso pueden diferir del AUC de 5 semillas en el tercer decimal.

Algoritmo	Esp.	AUC base	AUC +DMSP	Δ AUC	IC95 %	p (hogar)	p (cluster)	Δ top-10 %
XGBoost	A	0.7254	0.7363	+0.0128	[0.0037, 0.0225]	0.006	0.004	+0.022
Random Forest	A	0.7291	0.7291	+0.0012	[-0.0062, 0.0084]	0.754	–	+0.004
LightGBM	A	0.7414	0.7452	+0.0037	[-0.0006, 0.0081]	0.091	–	+0.005
HistGradientBoosting	A	0.7396	0.7378	-0.0018	[-0.0072, 0.0037]	0.541	0.548	+0.002
Logística regularizada	A	0.7300	0.7300	-0.0000	[-0.0012, 0.0011]	0.934	0.954	+0.009
XGBoost	B	0.7276	0.7455	+0.0198	[0.0096, 0.0296]	0.001	0.000	+0.016
Random Forest	B	0.7350	0.7323	-0.0035	[-0.0120, 0.0051]	0.429	–	+0.015
LightGBM	B	0.7304	0.7471	+0.0167	[0.0076, 0.0258]	0.000	–	+0.021
HistGradientBoosting	B	0.7385	0.7401	+0.0016	[-0.0043, 0.0075]	0.595	0.569	-0.007
Logística regularizada	B	0.7296	0.7295	-0.0000	[-0.0012, 0.0012]	0.978	0.926	+0.011

Resultado: a diferencia de monetaria, bajo IPM el efecto de DMSP-OLS es estadísticamente significativo en 3 de las 10 combinaciones algoritmo/especificación –pero sigue siendo económicamente marginal. XGBoost mejora en ambas especificaciones (AUC-ROC +0.0128, $p = 0.006$ en A; +0.0198, $p = 0.001$ en B) y LightGBM mejora en B (+0.0167, $p < 0.001$); las siete combinaciones restantes –incluidas ambas especificaciones de Random Forest, HistGradientBoosting y Logística regularizada– tienen intervalos de confianza que cruzan cero, igual que en monetaria. La corrección por clustering comunitario, disponible para XGBoost, HistGradientBoosting y Logística, no cambia la conclusión: los dos casos significativos de XGBoost lo siguen siendo ($p = 0.004$ y $p < 0.001$ agrupado por comunidad), así que el efecto no es un artefacto de tratar como independientes a hogares que en realidad comparten información espacial. Aun así, una ganancia de 0.013–0.020 en AUC-ROC es pequeña en términos absolutos –del mismo orden que la variabilidad entre semillas de un solo algoritmo (Tabla 8)– y `precision_top10` mejora de forma consistente pero igual de modesta (+0.016 a +0.022 en los dos casos significativos de XGBoost). La lectura más defendible no es “DMSP-OLS no sirve” ni “DMSP-OLS mejora la predicción”: es que el aporte es real y medible bajo IPM, concentrado en un subconjunto

de algoritmos, y demasiado pequeño para cambiar una decisión de focalización por sí solo –la pregunta de *dónde* se concentra ese aporte, más relevante para una recomendación de política que su tamaño promedio, se retoma en la Sección 5.5.

5.5. Heterogeneidad territorial

Las Secciones 5.3 y 5.4 establecen el efecto *promedio* de agregar DMSP-OLS: nulo bajo pobreza monetaria, pequeño pero significativo bajo IPM en algunos algoritmos. Esta subsección pregunta si ese promedio esconde heterogeneidad –si DMSP-OLS ayuda más en subpoblaciones específicas, aunque el efecto agregado sea chico o nulo, una pregunta más relevante para una recomendación de política que la cifra agregada por sí sola–. Se repite el ejercicio de las Secciones anteriores (agregar DMSP-OLS a los Modelos A y B, mismos hiperparámetros ya elegidos, sin volver a tunear) dentro de cada subgrupo de cuatro ejes de heterogeneidad: zona (urbano/rural), cercanía a la línea de pobreza en la ola base (cuartiles de `|brecha_lp_ingreso|`), estrato socioeconómico verificado, y terciles de un índice de riqueza construido con las dos variables de encuesta que hacen redundante a DMSP-OLS en el efecto agregado (`n_servicios_publicos_hogar + n_bienes_durables_hogar` estandarizadas y sumadas, Sección 5.3) –si la redundancia fuera total, el aporte de DMSP-OLS debería ser parejo en los tres terciles; si aporta más donde ese índice discrimina peor, sería evidencia de que la redundancia no es completa–. Es un ejercicio exploratorio (estimaciones puntuales por celda, sin bootstrap específico de cada subgrupo): con algunas celdas de unos pocos cientos de hogares, sirve para identificar candidatos a investigar con más rigor, no para conclusiones definitivas por sí solo.

Cuadro 12: Δ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza monetaria. En **negrita**: $|\Delta| \geq 0.02$. Grupos con $n < 30$ omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios, `diagnostico_heterogeneidad_dmsp.csv` (`src/05_model/diagnostico_heterogeneidad_dmsp.py`).

Eje	Grupo	Esp.	n	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	1,170	-0.004	-0.008	-0.009	-0.003	-0.003
	Rural	B	1,170	-0.001	-0.007	+0.012	-0.000	-0.002
	Urbano	A	2,021	-0.003	+0.001	-0.006	+0.001	-0.000
	Urbano	B	2,021	-0.003	-0.004	+0.003	-0.001	-0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	798	-0.003	-0.006	+0.000	-0.002	-0.000
	Q1 (mas cerca de LP)	B	798	+0.002	-0.008	+0.004	+0.001	-0.000
	Q2	A	798	-0.001	+0.006	+0.006	+0.001	-0.001
	Q2	B	798	-0.001	-0.002	+0.011	+0.001	-0.001
	Q3	A	798	-0.007	-0.008	-0.019	-0.001	-0.002
	Q3	B	798	-0.006	-0.005	-0.000	-0.000	-0.002
	Q4 (mas lejos)	A	797	-0.005	+0.000	-0.022	-0.001	-0.001
	Q4 (mas lejos)	B	797	-0.011	-0.004	-0.011	-0.002	-0.000
Estrato	Estrato 1	A	903	-0.003	-0.001	-0.001	-0.005	-0.002
	Estrato 1	B	903	-0.002	-0.008	+0.018	+0.000	-0.002
	Estrato 2	A	1,390	-0.002	-0.002	-0.005	+0.004	+0.000
	Estrato 2	B	1,390	-0.004	+0.002	+0.004	+0.003	+0.000
	Estrato 3	A	741	-0.003	-0.001	-0.006	+0.000	-0.001
	Estrato 3	B	741	-0.007	-0.016	-0.009	-0.006	-0.001
Proxy de riqueza	Bajo (proxy menos discriminante)	A	1,087	-0.005	-0.009	-0.007	-0.003	-0.003
	Bajo (proxy menos discriminante)	B	1,087	-0.004	-0.009	+0.013	-0.001	-0.003
	Medio	A	1,121	+0.002	+0.002	-0.004	+0.001	+0.001
	Medio	B	1,121	+0.004	-0.004	+0.008	+0.003	+0.001
	Alto (proxy menos discriminante)	A	983	-0.015	-0.005	-0.006	+0.001	-0.001
	Alto (proxy menos discriminante)	B	983	-0.017	-0.009	-0.005	-0.009	+0.000

Bajo pobreza monetaria, el nulo agregado se sostiene en los cuatro ejes: de 70 celdas algoritmo/grupo/especificación, solo una (-0.022 , LightGBM, cuartil más lejano de la LP, Modelo A) supera el umbral de $|\Delta\text{AUC}| \geq 0.02$ –y en la dirección negativa–. No hay zona, nivel de cercanía al umbral, estrato ni tercil de riqueza donde DMSP-OLS aporte de forma sistemática bajo esta definición de pobreza.

Cuadro 13: Δ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza multidimensional (IPM). En **negrita**: $|\Delta| \geq 0.02$. Grupos con $n < 30$ omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios, `diagnostico_heterogeneidad_ipm.csv` (`src/05_model/diagnostico_heterogeneidad_ipm.py`).

Eje	Grupo	Esp.	n	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	2,452	+0.012	+0.006	+0.010	+0.005	+0.001
	Rural	B	2,452	+0.019	+0.004	+0.032	+0.009	+0.001
	Urbano	A	3,119	+0.013	-0.002	+0.000	-0.005	-0.000
	Urbano	B	3,119	+0.018	-0.015	+0.008	-0.004	+0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	1,393	+0.009	-0.005	+0.003	+0.003	-0.001
	Q1 (mas cerca de LP)	B	1,393	+0.015	+0.001	+0.012	+0.003	-0.001
	Q2	A	1,394	+0.024	-0.006	+0.010	-0.012	-0.000
	Q2	B	1,394	+0.039	-0.013	+0.032	-0.006	-0.000
	Q3	A	1,392	+0.025	+0.009	+0.002	+0.009	+0.003
	Q3	B	1,392	+0.025	-0.008	+0.030	+0.006	+0.003
	Q4 (mas lejos)	A	1,392	+0.013	+0.011	+0.003	-0.009	-0.004
	Q4 (mas lejos)	B	1,392	+0.019	-0.015	-0.008	+0.015	-0.003
Estrato	Estrato 1	A	2,046	+0.010	+0.002	+0.005	+0.004	-0.001
	Estrato 1	B	2,046	+0.018	+0.004	+0.024	-0.002	-0.001
	Estrato 2	A	2,439	+0.020	+0.003	+0.007	-0.008	+0.002
	Estrato 2	B	2,439	+0.027	-0.006	+0.015	+0.005	+0.002
	Estrato 3	A	889	-0.007	-0.006	-0.006	-0.005	+0.002
	Estrato 3	B	889	+0.005	-0.031	-0.003	+0.009	+0.003
Proxy de riqueza	Bajo (proxy menos discriminante)	A	1,858	+0.014	+0.003	+0.008	+0.001	+0.001
	Bajo (proxy menos discriminante)	B	1,858	+0.021	-0.003	+0.030	+0.003	+0.000
	Medio	A	1,977	+0.007	+0.004	+0.002	-0.006	+0.000
	Medio	B	1,977	+0.018	-0.004	+0.019	-0.001	+0.000
	Alto (proxy menos discriminante)	A	1,736	+0.034	-0.001	+0.004	+0.001	+0.000
	Alto (proxy menos discriminante)	B	1,736	+0.033	-0.030	+0.009	+0.005	+0.000

Bajo IPM, en cambio, el aporte no está parejo: se concentra en zona rural, hogares de menor riqueza aproximada por encuesta, y estratos bajos –justo donde el argumento de que la luz nocturna complementa a encuestas con menor cobertura o poder discriminante predeciría que debería concentrarse. LightGBM-B es el patrón más claro: +0.032 en zona rural (frente a +0.008 urbano), +0.030 en el tercil de riqueza menos discriminante (frente a +0.009 en el más discriminante), y +0.024 en Estrato 1 (frente a -0.003 en Estrato 3). XGBoost, el otro algoritmo con efecto

agregado significativo (Sección 5.4), muestra el patrón opuesto en el eje de riqueza –mayor ganancia en el tercil *más* discriminante (+0.033/+0.034)– por lo que la heterogeneidad por riqueza-proxy no es uniforme entre algoritmos, pero sí lo es por zona y estrato: en ambos algoritmos con efecto agregado significativo, el aporte marginal es mayor o igual en zona rural que en zona urbana y decrece con el estrato. Random Forest es la única excepción sistemática –su ΔAUC es negativo o nulo en casi todos los subgrupos de ambas definiciones de pobreza, consistente con no tener efecto agregado significativo en ninguna especificación IPM (Tabla 11)–.

Esta heterogeneidad es, hasta ahora, el hallazgo más concreto a favor del argumento de esta tesis sobre el valor de DMSP-OLS: no como sustituto del poder predictivo que ya aporta la encuesta, sino como fuente complementaria cuyo aporte relativo crece precisamente donde la información de encuesta es más débil o menos discriminante –rural, estratos bajos, hogares peor capturados por el proxy de riqueza–, el escenario más parecido al de un sistema de focalización que deba operar con información administrativa incompleta o con encuestas desactualizadas entre rondas (Sección 6.2). Queda como agenda de investigación –Sección 6.3– confirmar estos patrones con un bootstrap específico por celda antes de tratarlos como un resultado robusto.

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento evalúa si las variables geoespaciales públicas mejoran la predicción de la transición hacia la pobreza de hogares colombianos no pobres, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). El ejercicio completo cubre la auditoría sistemática y no muestral de los cinco módulos de la ELCA (más de 4.000 columnas originales), la construcción de la variable de resultado –siguiendo el enfoque de López-Calva y Ortiz-Juárez (2011, 2014), con cinco ejercicios de robustez sobre su construcción–, la estimación y comparación de cinco algoritmos de aprendizaje supervisado bajo dos especificaciones de covariables (monetaria e IPM), y la evaluación del aporte de DMSP-OLS –la única de las tres fuentes geoespaciales nuevas con cobertura temporal suficiente para un holdout real– tanto en su efecto promedio como en su heterogeneidad por subgrupo.

Cinco hallazgos se destacan. **Primero**, la dinámica de la pobreza en el panel ELCA 2010–2016 muestra una reducción sostenida de la incidencia (de 60.7 % a 42.4 % por ingreso) acompañada de una tasa de entrada a la pobreza de 23.4 % entre 2010–2013 y de 19.9 % entre 2013–2016, con una tasa de salida que casi duplica a la de entrada en ambos periodos;

bajo IPM la entrada es menos frecuente pero también lo es la salida, consistente con que las privaciones estructurales cambian más lento que el ingreso corriente (Sección 4.1). **Segundo**, el perfil del hogar vulnerable –el que entra en pobreza– se parece mucho más, en la mayoría de sus características observables, al hogar que *acaba de salir* de la pobreza que al que nunca fue pobre (47 de 53 variables robustas lo ubican más cerca de “sale”), con una excepción sistemática y contraintuitiva: la formalidad laboral del jefe de hogar es *mayor* en quien está a punto de caer que en quien nunca fue pobre, justo la señal que convencionalmente se usaría para descartar el riesgo (Sección 5.1). **Tercero**, los cinco algoritmos evaluados alcanzan un desempeño similar entre sí (AUC-ROC entre 0.731 y 0.767), sin que ninguno domine claramente a los demás, y la brecha de desempeño entre el modelo que incluye ingreso/gasto del hogar y el que no los incluye es sorprendentemente pequeña (0.008–0.028 en AUC-ROC): las covariables no monetarias explican una fracción sustancial del poder predictivo que, bajo el enfoque clásico de vulnerabilidad (Chaudhuri et al., 2002), se atribuiría casi exclusivamente al ingreso (Sección 5.2).

Cuarto, y central para la pregunta de investigación: agregar DMSP-OLS al panel de covariables *no* mejora la predicción de pobreza monetaria (efecto nulo, IC95 % cruza cero, en las 10 combinaciones algoritmo/especificación evaluadas), pero sí lo hace bajo IPM, de forma estadísticamente significativa aunque económicamente pequeña, en 3 de 10 combinaciones (XGBoost en ambas especificaciones, LightGBM en el Modelo B; Δ AUC-ROC de 0.013 a 0.020, Sección 5.4). La correlación residualizada confirma que, bajo monetaria, esta ausencia de aporte es redundancia, no ausencia de señal: `dmsp_stable_lights` cae de $r = -0.214$ a $r = +0.021$ una vez se controla por dos preguntas de la propia encuesta (servicios públicos y bienes durables del hogar), que miden en esencia el mismo fenómeno de urbanización y consolidación del entorno (Sección 5.3). **Quinto**, ni el efecto nulo monetario ni el pequeño efecto IPM son parejos en la población: bajo IPM, el aporte de DMSP-OLS se concentra en zona rural, estratos bajos y hogares peor capturados por el proxy de riqueza de la encuesta –el escenario donde la información de encuesta es más débil– (Sección 5.5), y DMSP-OLS es además casi el doble de estable en el tiempo (correlación test-retest 2010–2013 de 0.958) que la variable de encuesta que compite con ella en poder predictivo (0.600 para bienes durables del hogar). En conjunto, estos dos últimos hallazgos matizan la conclusión de redundancia: DMSP-OLS no aporta poder predictivo incremental donde la ELCA ya tiene buena cobertura, pero sí –y de forma medible– donde esa cobertura es más débil o menos confiable en el tiempo, precisamente el escenario de un sistema de focalización con información administrativa incompleta o encuestas desactualizadas entre rondas.

6.2. Implicaciones para la política pública

Los resultados de este documento sugieren tres implicaciones para el diseño de sistemas de focalización como el SISBEN. Primero, la evidencia de que las covariables no monetarias tienen un poder predictivo casi comparable al del ingreso sugiere que un sistema de alerta temprana no necesita esperar a observar directamente el ingreso de un hogar –la variable más costosa y menos frecuente de actualizar– para identificar candidatos a la vulnerabilidad; características más fáciles de observar o de actualizar administrativamente (educación, activos del hogar, formalidad laboral) ya capturan buena parte de esa señal –con la salvedad de que la formalidad laboral señala riesgo en la dirección *contraria* a la intuitiva (Sección 5.1)–. Segundo, la comparación entre algoritmos (Sección 5.2) muestra que la elección del algoritmo correcto depende de la función de pérdida que le importa al hacedor de política: XGBoost maximiza el recall –relevante si el costo de no detectar un hogar que va a caer en pobreza (error de exclusión) es mucho mayor que el de incluir por error a uno que no cae (error de inclusión)–, mientras que HistGradientBoosting ofrece mejor precisión y el mejor balance entre ambas (mayor F1) al mismo nivel de AUC-ROC. Un sistema real debería fijar explícitamente esa preferencia antes de elegir el modelo, en vez de optimizar únicamente por AUC-ROC. Tercero, DMSP-OLS no justifica su costo de integración como covariable adicional para un sistema que ya se apoya en una encuesta de hogares con buena cobertura –el efecto es nulo bajo pobreza monetaria y económicamente marginal bajo IPM (Secciones 5.3 y 5.4)–, pero la heterogeneidad de ese efecto sí ofrece un argumento de política más específico: su aporte se concentra en zona rural, estratos bajos y hogares peor capturados por los proxies de riqueza de la encuesta (Sección 5.5), y su mayor estabilidad temporal frente a esos mismos proxies (Sección 5.3) la hace más útil como respaldo en escenarios de datos administrativos incompletos o encuestas desactualizadas entre rondas que como insumo de rutina para una encuesta ya vigente y con buena cobertura.

6.3. Limitaciones y agenda de investigación

La agenda de investigación que deja esta tesis tiene tres frentes concretos. Primero, la heterogeneidad territorial del aporte de DMSP-OLS bajo IPM (Sección 5.5) se estableció con estimaciones puntuales por celda, sin bootstrap propio de cada subgrupo –el siguiente paso es exactamente ese bootstrap por celda (zona, estrato, tercil de riqueza) para poder afirmar con un intervalo de confianza, no solo con una estimación puntual, que el aporte se concentra donde la Sección 5.5 sugiere. Segundo, la comparación por región geográfica (más allá de la partición urbano/rural ya explotada) quedó fuera por tamaño de muestra: con 3,089 hogares no pobres en la base de entrenamiento (Tabla 3), partir además por región deja celdas demasiado pequeñas para una estimación confiable bajo el holdout

temporal principal. Tercero, ALOS PALSAR y Landsat 5 TM –evaluadas en esta tesis solo de forma exploratoria, sin holdout real por falta de cobertura temporal (Sección 3.2)– quedan pendientes de una evaluación con el mismo rigor que DMSP-OLS en cuanto existan más olas de estas fuentes con cobertura real.

Fotos de Google Street View como fuente alternativa (exploratorio). Un cuarto frente, más incipiente, es si fotografías a nivel de calle –en vez de una fuente satelital– podrían cumplir una función similar a DMSP-OLS. El diagnóstico disponible separa dos preguntas con calidad de evidencia muy distinta. La primera –¿el contenido visual de una foto de vivienda predice la luz nocturna de esa misma zona?– tiene una respuesta sólida: representaciones vectoriales (*embeddings*) de las fotos de Google Street View (GSV), extraídas con cuatro modelos preentrenados de visión por computador (CLIP, VGG19, ResNet50, Places365), predicen `dmisp_stable_lights` con R^2 fuera de muestra de 0.63 a 0.74 ($n = 830$, $p < 10^{-180}$ en los cuatro modelos; Places365 y ResNet50 son los de mejor ajuste). La muestra se restringió, tras una corrección metodológica –la etiqueta `ola` del pipeline de GSV indica la ola *asignada* a la foto, no su fecha real de captura; de las 6,788 fotos etiquetadas `ola=2013`, solo 13.8 % (939) fueron tomadas realmente en la ventana 2011–2013–, a fotos con fecha de captura verificada dentro de esa ventana. La segunda pregunta –¿esas fotos aportan poder predictivo de pobreza *más allá* de lo que ya aporta DMSP-OLS?– no tiene todavía una respuesta confiable: con $n = 283$ hogares (la intersección de fotos válidas y conjunto de prueba), el coeficiente del primer componente principal de los embeddings en una regresión logística junto con DMSP-OLS cambia de signo entre especificaciones y algoritmos, sin significancia consistente. La conclusión razonable no es que las fotos “no aportan” sino que la pregunta de aporte incremental exige un tamaño de muestra que la cobertura actual de GSV en Colombia –limitada por la disponibilidad histórica de Street View, no por el diseño de esta tesis– todavía no permite responder con rigor. Queda como agenda directa repetir este ejercicio cuando exista mayor cobertura temporal de fotos.

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (inf. téc.). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). Assessing Household Vulnerability to Poverty from Cross-Sectional Data. *Columbia University Department of Economics Discussion Papers*, (0102-52).
- Christiaensen, L., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Davis, J., & Goadrich, M. (2006). The Relationship Between Precision-Recall and ROC Curves. *Proceedings of the 23rd International Conference on Machine Learning*, 233-240. <https://doi.org/10.1145/1143844.1143874>
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/713600071>

- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2025). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of Sustainable Development & World Ecology*. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). *Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature* (ADB Working Paper). Asian Development Bank Institute.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*. <https://doi.org/10.1002/jid.3751>
- Hofer, M., Sako, T., Martinez, A. J., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*. <https://doi.org/10.1111/asej.12349>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Economics*, 61(1), 99-111.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juárez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juárez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.

- Muñetón, G., Escobar, D., López, F., Pérez, P., & Orozco, J. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>
- Newhouse, D., Merfeld, J., Ramakrishnan, A., Swartz, T., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

A.1. Correlación entre covariables y riesgo de multicolinealidad

Complemento de la Sección 4.3: análisis de correlación de Pearson entre las 159 variables numéricas del dataset consolidado –incluidas las 4 geoespaciales–, motivado por el riesgo de multicolinealidad para el modelo de regresión logística regularizada.

Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 2), solo se reportan como “altas” los pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican los 35 pares de la Figura 12.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan sobre 0.97 con su propia brecha a la LP; `lp` y `li` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal correlacionan -0.93 (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmsp_stable_lights` correlaciona 0.87 con la línea de pobreza `lp` y 0.81 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`). Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.2 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la Sección 5.3.



Figura 12: Pares de variables con correlación de Pearson $|r| > 0.7$ (calculados sobre al menos 500 observaciones conjuntas no-nulas), ordenados por magnitud de la correlación. La mayoría corresponde a redundancias esperables (medidas nominal vs. real de un mismo concepto, o un indicador individual y su agregado a nivel de hogar); la más relevante para este trabajo es la de `dmsp_stable_lights` con `lp`, `li` y `n_servicios_publicos_hogar`, que se retoma en la Sección 5.3. Fuente: cálculos propios.

A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria

Complemento de la Sección 4.1: incidencia agregada de pobreza monetaria por ingreso y por gasto, su descomposición Foster-Greer-Thorbecke (FGT), y cinco ejercicios diseñados para evaluar qué tan sensible es la variable de transición a la pobreza –la variable de interés de esta tesis– a decisiones de construcción del ingreso, a la representatividad muestral y al error de medición cerca del umbral de pobreza.

A.2.1. Incidencia y descomposición FGT

La Figura 13 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más *baja* que la de ingreso en los tres puntos del panel (47.6 %, 40.9 % y 33.4 %): la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto. Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no es un artefacto de la medida de bienestar elegida.




Figura 13: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 14 descompone la pobreza por ingreso en sus tres componentes FGT: inciden-

cia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 14: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

A.2.2. Ejercicios de robustez

Se implementaron cinco ejercicios de robustez sobre las cifras de transición de la Sección 4.1: ponderación muestral, dos reclasificaciones del ingreso, sensibilidad al umbral de pobreza, y atrición del panel.

Ponderación muestral. Ninguno de los resultados de la Sección 4.1 usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (`fexhog`, `fexhog_2013`, ambos transversales, y `fexhog_2010`, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % → 60.4 % en 2010, 52.4 % → 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % → 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 %

a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorrateados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de esta tesis. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010→2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se

repite las matrices de transición (Figura 15). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % (LP−10 %) y 49.1 % (LP+10 %) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 15: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 16 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 16: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 17). La atrición total es de 11.4% en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). Esa cifra agregada sí se desagregó por perfil de hogar (`src/02_build/eda_hogares_panel.py`, `analizar_attrition()`): la atrición **no es aleatoria**, se concentra sistemáticamente en hogares urbanos y de estrato más alto. Por zona, la tasa de pérdida es 2.8 veces mayor en zona urbana que en zona rural en 2010–2013 (16.2% vs. 5.8%) y 1.7 veces mayor en 2013–2016 (14.1% vs. 8.2%); por estrato socioeconómico, la pérdida crece monótonamente de 8.9% en estrato 1 a 26.0% en estrato 4 en 2010–2013. Por región, Bogotá tiene la mayor pérdida (24.9%) y Centro-Oriente la menor (3.1%). El patrón es consistente con que los hogares urbanos y de mayor estrato son más móviles (cambian de vivienda con más frecuencia), lo que dificulta su relocalización entre olas del panel –no con una atrición concentrada en los hogares más pobres, que de hecho es la más baja de las cuatro categorías de estrato–. No se investigó si, controlando por zona/estrato/región, la atrición está además asociada al estado de pobreza mismo del hogar (una limitación que se retoma en la Sección 6.3).




Figura 17: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

A.3. Perfil completo de covariables, pobreza multidimensional (IPM)

Complemento de la Sección 5.1: perfil completo de covariables robustas frente a la transición 2010→2013 bajo pobreza multidimensional (mismo criterio de inclusión que en

pobreza monetaria – efecto > 0.10 con bootstrap, sin deduplicar por correlación), una tabla por categoría temática.

Cuadro 14: Ingreso y gasto – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Pobre extremo por ingreso (2010)	67 %	55 %	53 %	26 %
Pobre por ingreso (2010)	90 %	79 %	84 %	52 %
Pobre por gasto (2010)	74 %	58 %	68 %	40 %
Pobre extremo por gasto (2010)	31 %	21 %	27 %	8 %
Gasto per cápita	112k	148k	223k	400k
Ingreso per cápita	74k	101k	104k	332k
Línea de pobreza (referencia)	137k	140k	151k	177k
Línea de indigencia (referencia)	74k	75k	77k	82k
Ingreso (veces la línea de pobreza)	0.54	0.70	0.67	1.73
Gasto (veces la línea de pobreza)	0.83	1.07	1.33	2.12

Cuadro 15: Zona de residencia – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Vive en zona rural	84 %	80 %	67 %	36 %

Cuadro 16: Vivienda: materiales y servicios – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Material de piso: Tierra o arena	61 %	35 %	20 %	5 %
Servicio sanitario: Inodoro conectado a alcantarillado	12 %	16 %	30 %	62 %
Obtención de agua: Acueducto público	14 %	21 %	34 %	64 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	32 %	42 %	65 %	86 %
Combustible de cocina: Leña, madera, carbón de leña	83 %	71 %	60 %	28 %
Recolección de basura: La recogen los servicios de aseo	15 %	20 %	34 %	64 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	40 %	38 %	31 %	20 %
Tipo de vivienda: Apartamento	5 %	6 %	6 %	26 %

Cuadro 17: Vivienda: hacinamiento – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Personas por cuarto	2.56	1.94	2.10	1.44

Cuadro 18: Activos del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
N.º de servicios públicos	1.62	2.07	2.65	4.05
N.º de bienes durables	4.16	4.66	4.61	7.20
Índice de riqueza (PCA)	-0.93	-0.67	-0.87	0.33

Cuadro 19: Educación y empleo del jefe – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Educación del jefe: Ninguno	42 %	17 %	8 %	2 %
Ocupación del jefe: Jornalero	45 %	31 %	25 %	6 %
Adultos alfabetizados en el hogar	53 %	79 %	92 %	98 %
Nivel educativo del jefe (ordinal)	1.21	1.90	2.11	3.10
Sexo del jefe: Hombre	83 %	83 %	71 %	69 %
Estado civil del jefe: En unión libre	60 %	55 %	42 %	35 %
Máx. nivel educativo del hogar	1.69	2.22	2.34	3.42
Registro mercantil del jefe: No lo necesita	72 %	55 %	62 %	49 %
Etnia del jefe: Indígena	15 %	12 %	11 %	6 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	78 %	67 %	63 %	59 %
Cotización a pensión (hogar)	1 %	3 %	6 %	25 %

Cuadro 20: Composición del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Niños al cuidado de terceros	92 %	65 %	79 %	97 %

Cuadro 21: Geoespacial – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Iluminación nocturna (DMSP)	13.8	16.7	23.0	40.7

A.4. Desempeño de los modelos bajo pobreza multidimensional (IPM)

Complemento de la Sección 5.2: mismo benchmark de cinco algoritmos y misma metodología robusta (holdout temporal, CV_FOLDS=10, N_ITER_BUSQUEDA=30, 5 semillas), con pobreza multidimensional (IPM) como variable de resultado en vez de pobreza monetaria – covariables idénticas.³

Cuadro 22: Desempeño de los cinco algoritmos bajo pobreza multidimensional (IPM), holdout temporal (train 2010→2013, test 2013→2016). Misma metodología robusta que la Tabla 8 (monetaria), covariables idénticas – único factor que cambia es la variable de resultado. Prec.-top10: precisión entre el 10 % de hogares de mayor riesgo.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precision	Prec.-top10	F1
LightGBM	Aipm	0.11	0.741	0.670	0.184	0.263	0.288
HistGradientBoosting	Aipm	0.11	0.740	0.603	0.197	0.271	0.295
Logística regularizada	Aipm	0.10	0.730	0.726	0.166	0.258	0.269
Random Forest	Aipm	0.31	0.729	0.645	0.183	0.253	0.285
XGBoost	Aipm	0.11	0.725	0.844	0.139	0.251	0.239
HistGradientBoosting	Bipm	0.10	0.739	0.620	0.189	0.265	0.289
Random Forest	Bipm	0.26	0.735	0.753	0.165	0.260	0.270
LightGBM	Bipm	0.08	0.730	0.721	0.167	0.251	0.270
Logística regularizada	Bipm	0.11	0.730	0.716	0.167	0.255	0.270
XGBoost	Bipm	0.09	0.728	0.901	0.130	0.258	0.228

B. Detalles de construcción de variables geoespaciales

³Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Random Forest (Aipm y Bipm), donde fue *balanced* (reponderación de clases).

Índice

1. Introducción	3
2. Marco conceptual y revisión de literatura	4
2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales	4
2.2. Aprendizaje de máquinas en la predicción de pobreza	6
2.3. Variables geoespaciales como fuente complementaria	7
2.4. Síntesis y vacío que llena este trabajo	8
3. Datos	9
3.1. Encuesta Longitudinal Colombiana (ELCA)	9
3.2. Fuentes geoespaciales	10
3.3. Cobertura, atrición e inventario del panel	12
3.3.1. Composición del panel y atrición	13
3.3.2. Inventario temático de las variables finales	14
4. Estrategia empírica	15
4.1. Construcción de la variable de resultado y dinámica de transiciones	15
4.2. Selección de covariables para el perfil univariado	18
4.3. Especificación de modelos	18
4.4. Validación fuera de muestra y métricas	19
4.5. Tratamiento del desbalance de clases	21
4.6. Importancia de variables e interpretabilidad	23
5. Resultados	23
5.1. Perfil de los hogares vulnerables	24
5.2. Desempeño comparativo de modelos	30
5.3. Contribución marginal de las variables geoespaciales	36
5.4. Contribución marginal de las variables geoespaciales bajo pobreza multidimensional (IPM)	42
5.5. Heterogeneidad territorial	44
6. Conclusiones	47
6.1. Síntesis de hallazgos	47
6.2. Implicaciones para la política pública	49
6.3. Limitaciones y agenda de investigación	49

Referencias	51
A. Tablas y figuras complementarias	54
A.1. Correlación entre covariables y riesgo de multicolinealidad	54
A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria . . .	56
A.2.1. Incidencia y descomposición FGT	56
A.2.2. Ejercicios de robustez	57
A.3. Perfil completo de covariables, pobreza multidimensional (IPM)	60
A.4. Desempeño de los modelos bajo pobreza multidimensional (IPM)	63
B. Detalles de construcción de variables geoespaciales	63