

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal de Colombia (ELCO)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geospaciales, ELCO, focalización, Colombia.

Clasificación JEL: I32, C55, O18, R12.

Índice

1. Introducción	4
2. Marco conceptual y revisión de literatura	4
2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales	4
2.2. Aprendizaje de máquinas en la predicción de pobreza	4
2.3. Variables geoespaciales como fuente complementaria	4
2.4. Síntesis y vacío que llena este trabajo	4
3. Datos	4
3.1. Encuesta Longitudinal Colombiana (ELCO)	4
3.2. Fuentes geoespaciales	4
3.3. Estadísticas descriptivas	4
4. Estrategia empírica	4
4.1. Construcción de la variable de resultado	4
4.2. Especificación de modelos	4
4.3. Validación fuera de muestra y métricas	5
4.4. Tratamiento del desbalance de clases	5
4.5. Importancia de variables e interpretabilidad	5
5. Resultados	5
5.1. Dinámica de transiciones a la pobreza en la ELCO	5
5.1.1. Incidencia de pobreza y matrices de transición	5
5.1.2. Ejercicios de robustez	8
5.1.3. Limitaciones	12
5.2. Desempeño comparativo de modelos	13
5.3. Contribución marginal de las variables geoespaciales	13
5.4. Heterogeneidad territorial	13
6. Conclusiones	13
6.1. Síntesis de hallazgos	13
6.2. Implicaciones para la política pública	13
6.3. Limitaciones y agenda de investigación	13
Referencias	14
A. Tablas y figuras complementarias	15

B. Detalles de construcción de variables geoespaciales

15

1. Introducción

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

2.2. Aprendizaje de máquinas en la predicción de pobreza

2.3. Variables geoespaciales como fuente complementaria

2.4. Síntesis y vacío que llena este trabajo

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCO)

3.2. Fuentes geoespaciales

3.3. Estadísticas descriptivas

4. Estrategia empírica

4.1. Construcción de la variable de resultado

4.2. Especificación de modelos

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (1)$$

donde $F(\cdot)$ es la función logística en el modelo base y una aproximación no paramétrica en los modelos de ML, y X_{it} es el vector de características del hogar i observadas en el periodo t .

4.3. Validación fuera de muestra y métricas

4.4. Tratamiento del desbalance de clases

4.5. Importancia de variables e interpretabilidad

5. Resultados

5.1. Dinámica de transiciones a la pobreza en la ELCO

Esta sección analiza la dinámica de la pobreza monetaria en el panel ELCA 2010–2013–2016 en dos niveles. Primero, la incidencia y las matrices de transición entre olas consecutivas, siguiendo la metodología oficial del DANE (ingreso per cápita nominal del hogar contra la línea de pobreza –LP– y la línea de pobreza extrema –LI– nominales de su año y zona) y la clasificación en cuatro categorías de transición de López-Calva y Ortiz-Juárez (2014) (nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza). Segundo, un conjunto de cinco ejercicios de robustez diseñados específicamente para evaluar qué tan sensible es la variable de resultado de esta tesis –la transición a la pobreza– a decisiones metodológicas de la construcción del ingreso y a la definición del panel. Los detalles de construcción de cada variable, verificados contra los diccionarios de la encuesta y los archivos crudos, están documentados exhaustivamente en el repositorio del proyecto (`docs/decisions.md`); aquí se presentan los resultados y su interpretación para la tesis.

5.1.1. Incidencia de pobreza y matrices de transición

La Figura 1 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más alta que la de ingreso en las tres olas (47.6 %, 40.9 % y 33.4 % en sentido estricto es más *baja*, no más alta, que la de ingreso en los tres puntos del panel: la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto). Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no es un artefacto de la medida de bienestar elegida.




Figura 1: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 2 descompone la pobreza por ingreso en sus tres componentes de Foster-Greer-Thorbecke: incidencia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 2: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

Las matrices de transición cruzan el estado de pobreza inicial (filas) contra el estado final (columnas), en porcentaje de fila, únicamente para hogares con emparejamiento uno a uno vía **consecutivo** entre olas (los hogares que se dividen entre una ola y la siguiente –511 casos en 2010–2013 y 1,190 en 2013–2016, contando ambos lados del emparejamiento– se excluyen de la matriz por no tener un estado inicial y final inequívoco). La Tabla 1 presenta ambas matrices.

Cuadro 1: Matrices de transición de pobreza monetaria por ingreso (% de fila, panel emparejado 1 a 1)

Periodo	Estado inicial	No pobre (final)	Pobre (final)
2010 → 2013 ($n = 8,218$)	No pobre	76.6 %	23.4 %
	Pobre	29.7 %	70.3 %
2013 → 2016 ($n = 6,911$)	No pobre	80.1 %	19.9 %
	Pobre	38.2 %	61.8 %

Nota: n = hogares con emparejamiento 1 a 1; excluye 511 (2010–2013) y 1,190 (2013–2016) casos de hogares que se dividieron entre olas. Fuente: cálculos propios con base en ELCA 2010, 2013, 2016.

Dos patrones se destacan. Primero, la persistencia en la pobreza es alta pero decrece con el tiempo: 70.3 % de los hogares pobres en 2010 seguían pobres en 2013, y esa persistencia

baja a 61.8 % entre 2013 y 2016 –es decir, la probabilidad de salir de la pobreza condicional en ser pobre aumentó de 29.7 % a 38.2 % entre periodos–. Segundo, la persistencia en la no pobreza también mejora (de 76.6 % a 80.1 %), y el riesgo de entrar en pobreza condicional en no ser pobre cae de 23.4 % a 19.9 %. Ambos movimientos son consistentes con la caída de la incidencia agregada documentada en la Figura 1.

La Figura 3 traduce estas matrices a las cuatro categorías de López-Calva y Ortiz-Juárez (2014). En 2010–2013, 43.9 % de los hogares del panel emparejado son *siempre pobres*, 28.8 % *nunca pobres*, 18.6 % *salen* de la pobreza y 8.8 % *entran* en ella. En 2013–2016 el panorama cambia de categoría dominante: *nunca pobre* pasa a ser la categoría más grande (37.0 %, superando por primera vez a *siempre pobre*, que cae a 33.3 %), sale 20.6 % y entra 9.2 %. En los dos periodos la tasa de salida casi duplica a la tasa de entrada, consistente con una economía en la que la pobreza monetaria se redujo de manera neta, no solo se redistribuyó entre hogares.




Figura 3: Distribución de categorías de transición de pobreza monetaria (Lopez-Calva y Ortiz-Juarez, 2014) entre olas consecutivas.

5.1.2. Ejercicios de robustez

La variable de interés de esta tesis es precisamente la transición a la pobreza, por lo que conviene preguntarse qué tan sensibles son las cifras de la Sección 5.1.1 a decisiones de construcción del ingreso, a la representatividad muestral, y al error de medición cerca del umbral de pobreza. Se implementaron cinco ejercicios de robustez con este propósito.

Ponderación muestral. Ninguno de los resultados anteriores usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y

verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (*fexhog*, *fexhog_2013*, ambos transversales, y *fexhog_2010*, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % $\rightarrow$ 60.4 % en 2010, 52.4 % $\rightarrow$ 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % $\rightarrow$ 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 % a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorratados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de esta tesis. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010 $\rightarrow$ 2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o

ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se repitieron las matrices de transición (Figura 4). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % ($LP - 10\%$) y 49.1 % ($LP + 10\%$) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 4: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 5 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 5: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 6). La atrición es de 11.4% en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). La consistencia entre periodos es tranquilizadora en términos de diseño muestral, pero no se investigó si esta atrición es aleatoria o está concentrada en algún perfil de hogar (rural, más pobre, más móvil) —una limitación que se retoma más abajo.




Figura 6: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

5.1.3. Limitaciones

Los ejercicios de robustez anteriores acotan, pero no eliminan, un conjunto de limitaciones de los datos y de la construcción de la variable de resultado que deben tenerse presentes al interpretar los resultados de esta tesis:

- **Error de medición cerca del umbral.** Como muestra la Figura 4, cerca de 10 puntos porcentuales de la distribución de categorías de transición son sensibles a una banda de apenas $\pm 10\%$ alrededor de la LP. Esto es consistente con el problema clásico de regresión a la media en paneles de pobreza (Baulch & Hoddinott, 2000): una fracción de las transiciones observadas puede reflejar error de medición del ingreso más que cambios reales en el bienestar del hogar.
- **Peso muestral no disponible para la ola 2016.** La ola 2016 no tiene un factor de expansión transversal propio en los datos consolidados de la ELCA (solo el longitudinal anclado a 2010); las cifras ponderadas de esa ola usan el factor longitudinal como mejor aproximación disponible, lo cual subrepresenta a cualquier hogar que hubiera entrado a la muestra después de 2010.
- **Arriendo imputado ausente.** La ELCA no permite estimar el valor del arriendo que un hogar propietario “se ahorra” –un componente que el DANE sí incluye en su concepto oficial de ingreso–, por lo que la medida de ingreso de esta tesis omite ese componente de forma sistemática para todos los hogares propietarios (cerca del 77–79 % de la muestra).
- **Ingreso laboral bruto vs. neto en trabajo independiente.** Los hogares con actividad agropecuaria o independiente reportan ingreso laboral sin distinguir si es bruto o neto de costos de producción, ambigüedad que es sistemáticamente más relevante en la zona rural por su mayor tasa de informalidad.
- **Sesgo de recall en la medida de gasto.** La brecha entre pobreza por ingreso y por gasto documentada en la Figura 1 refleja, al menos en parte, el sesgo de recall conocido en módulos de consumo con preguntas de ventana larga (doce meses) frente a preguntas de ventana corta (Beegle et al., 2012), y no debe leerse únicamente como evidencia de subreporte de ingreso.
- **Atrición no caracterizada.** La atrición del panel (Figura 6) es consistente entre periodos (11.4 % en ambos), pero no se estableció si es aleatoria o si está concentrada en hogares más vulnerables –lo típico en paneles de hogares pobres–, lo que de ser el caso sesgaría a la baja las tasas de entrada a la pobreza reportadas en la Figura 3.

Estas limitaciones se retoman en la Sección 6.3 en el contexto de las implicaciones para la interpretación de los modelos predictivos de esta tesis.

5.2. Desempeño comparativo de modelos

5.3. Contribución marginal de las variables geoespaciales

5.4. Heterogeneidad territorial

6. Conclusiones

6.1. Síntesis de hallazgos

Prueba de texto XXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXX

6.2. Implicaciones para la política pública

6.3. Limitaciones y agenda de investigación

Referencias

- Baulch, B., & Hoddinott, J. (2000). Economic Mobility and Poverty Dynamics in Developing Countries. *Journal of Development Studies*, 36(6), 1-24.
- Beegle, K., De Weerd, J., Friedman, J., & Gibson, J. (2012). Methods of Household Consumption Measurement through Surveys: Experimental Results from Tanzania. *Journal of Development Economics*, 98(1), 3-18.
- López-Calva, L. F., & Ortiz-Juárez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.

A. Tablas y figuras complementarias

B. Detalles de construcción de variables geoespaciales