

# ¿Pueden los datos geoespaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal Colombiana (ELCA)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

[j-melo@uniandes.edu.co](mailto:j-melo@uniandes.edu.co)

Bogotá, 2026

## Resumen

Los sistemas de focalización en Colombia, como el SISBEN y el Registro Social de Hogares, clasifican a los hogares según su situación actual y no anticipan qué hogares no pobres caerán en pobreza. Este trabajo evalúa si fuentes geoespaciales públicas mejoran la predicción de la caída en pobreza, monetaria y multidimensional, frente a usar solo la Encuesta Longitudinal Colombiana (ELCA). Se entrenan modelos con cinco algoritmos de aprendizaje supervisado, con y sin ingreso y gasto del hogar, en las transiciones 2010–2013 del panel, y se evalúan en las de 2013–2016. Los modelos identifican a los hogares vulnerables con una capacidad moderada (AUC-ROC de 0.72 a 0.77) que casi no depende del algoritmo ni del ingreso: pocas variables, como riqueza, educación, activos y vivienda, concentran la señal, y el hogar vulnerable se parece más al que acaba de salir de la pobreza que al que nunca fue pobre. Quienes caen reportan más choques posteriores a la predicción, lo que sugiere que parte del riesgo depende de eventos que la ola base no permite anticipar; entre quienes caen, permanecen en la pobreza los que tenían menos activos financieros y menos cotización a pensión. La iluminación nocturna, la única fuente con cobertura suficiente, describe bien la geografía de la pobreza, pero no mejora la predicción monetaria cuando hay una encuesta vigente y aporta poco bajo pobreza multidimensional; su valor está en priorizar territorios donde no hay encuesta o está desactualizada, porque cubre todo el país y cambia poco en el tiempo.

**Palabras clave:** vulnerabilidad a la pobreza, aprendizaje automático, datos geoespaciales, ELCA, focalización, Colombia.

# 1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juarez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Potenciales Beneficiarios de Programas Sociales (SISBEN) es desde hace casi treinta años el principal instrumento de focalización del gasto social. La actualización de su información ha dependido sobre todo de operativos de barrido cada seis o siete años, lo que genera rezagos: en la evaluación del SISBEN III, el 75 % de la información socioeconómica seguía igual que en su recolección inicial (Pabón & Briceño, 2023). El SISBEN IV busca corregir en parte estas limitaciones: combina el estándar de vida con una presunción de la capacidad de generación de ingresos del hogar y se diseñó para interoperar con registros administrativos (Consejo Nacional de Política Económica y Social, 2016; Pabón & Briceño, 2023). Sobre esa base, el Decreto Ley 812 de 2020 creó el Registro Social de Hogares (RSH), que integra la información del SISBEN IV con 28 bases de datos nacionales y 1,832 territoriales para validarla y actualizarla, y permite por primera vez seguir la evolución de las condiciones de vida de los hogares (Pabón & Briceño, 2023). Aun así, el sistema clasifica a los hogares según su situación y capacidad actuales, y no estima la probabilidad de que un hogar hoy no pobre caiga en pobreza. La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y un ejercicio reciente de aproximación a la vulnerabilidad monetaria en Bogotá mediante paneles sintéticos confirma tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Gaitán, 2023).

Este artículo aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza, monetaria y multidimensional. Este abordaje se diferencia de la mayor parte de la literatura de aprendizaje automático aplicada a la pobreza, que predice la condición actual de un hogar y no su transición futura (Ferdausi et al., 2026; Muñetón-Santa et al., 2022).

La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de fuentes geoespaciales públicas mejora la predicción de caída en pobreza de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del hogar reportadas en encuestas?

Para responderla, el documento construye la variable de resultado que es la transición hacia la pobreza, audita las covariables socioeconómicas disponibles en la ELCA y estima modelos con cinco algoritmos de aprendizaje supervisado (regresión logística regularizada *Elastic Net*, Random Forest, XGBoost, LightGBM y HistGradientBoosting), en dos especificaciones: con y sin ingreso y gasto del hogar, bajo dos definiciones de pobreza, monetaria y multidimensional. Sobre esos modelos evalúa el aporte de cuatro fuentes geoespaciales públicas: la iluminación nocturna DMSP-OLS, el radar ALOS PALSAR, las imágenes Landsat 5 TM y las fotografías de Google Street View. Solo DMSP-OLS tiene datos en la ola de entrenamiento y en la de prueba, por lo que es la fuente de la evaluación principal; las demás se evalúan de forma exploratoria (Sección 3.1).

Los resultados muestran que los modelos identifican a los hogares vulnerables con una capacidad moderada (AUC-ROC de 0.72 a 0.77), similar entre algoritmos y casi igual sin el ingreso del hogar; que un núcleo pequeño de variables de acumulación concentra la señal, y que el hogar vulnerable se parece más al que acaba de salir de la pobreza que al que nunca fue pobre; además, que quienes efectivamente caen reportan más choques posteriores a la predicción. La iluminación nocturna no mejora la predicción cuando hay una encuesta vigente, porque su información ya está contenida en la encuesta, pero es más estable en el tiempo y su pequeño aporte bajo pobreza multidimensional se concentra en zonas rurales, lo que la hace útil para priorizar territorios y como respaldo entre rondas de encuesta.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción

de transiciones a la pobreza, un problema que los trabajos previos sobre vulnerabilidad con la ELCA (Hernández & Zuluaga, 2022) no abordan.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje automático aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla la estrategia empírica: construcción de la variable de resultado, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados. La Sección 6 cierra con una síntesis, implicaciones de política, las limitaciones y la agenda de investigación.

## 2. Marco conceptual y revisión de literatura

### 2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria se origina en la variabilidad del consumo del hogar ante choques de ingreso, como la enfermedad de un miembro del hogar o la pérdida de una cosecha por plagas, y aumenta con la volatilidad de su patrimonio. Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto para la Kenya rural: en 1994 los hogares enfrentaban en promedio una probabilidad del 39 % de caer en pobreza en el futuro, mayor en las zonas áridas expuestas a la volatilidad de las lluvias, y los choques idiosincráticos también generaban una volatilidad importante del consumo. Los hogares hoy no pobres pero expuestos a esos choques son precisamente

los que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010). En la práctica, el enfoque clasifica como vulnerable a un hogar cuando dicha probabilidad supera 0.5, un umbral arbitrario cuya capacidad para anticipar la pobreza observada se ha evaluado poco; Hohberg et al. (2018) la evalúan con curvas ROC en un panel alemán y muestran que un umbral elegido según el objetivo de focalización predice mejor.

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juarez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 4.1 de este artículo. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado de pobreza.

En Colombia, la ausencia de un panel de hogares ha llevado a usar pseudo-paneles, tanto para estudiar trampas de pobreza (Castañeda Castrillón, 2012) como para aproximar la vulnerabilidad (Gaitán, 2023); Gaitán (2023) estima que cerca del 23 % de la población bogotana era vulnerable en 2021. La ELCA, con tres olas de seguimiento a los mismos hogares, permite superar esa limitación. Con la misma ELCA, Hernández y Zuluaga (2022) estiman la vulnerabilidad a la pobreza multidimensional con el enfoque de pobreza esperada de Chaudhuri et al. (2002) y encuentran que la proporción de hogares vulnerables supera la de pobres, sobre todo en zona rural (70 % frente a 39 %). Este artículo se diferencia en que no infiere la vulnerabilidad de la media y la varianza esperadas del bienestar, sino que predice la transición observada con modelos validados fuera de muestra. Aun así, estos métodos dependen de encuestas detalladas, costosas y de levantamiento infrecuente, lo que motiva explorar fuentes alternativas de datos (Sección 2.3).

## 2.2. Aprendizaje automático en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su evolución ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar sustancialmente la exactitud fuera de muestra de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando su criterio de exactitud balanceada (BPAC) hasta en 17.5 % frente a los métodos tradicionales. Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2026) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema: sus modelos alcanzan una exactitud del 96 % e identifican siete variables como los principales factores de la pobreza extrema. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza a la mayor parte de la literatura. En Colombia, Muñetón-Santa et al. (2022) han aplicado aprendizaje automático a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada

de manera limitada. Un ejemplo de otro contexto es Burger y van der Laan (2021), que predicen con *gradient boosting* la entrada y la salida de la pobreza al año siguiente a partir de más de 500 variables de registros administrativos de los Países Bajos, y usan valores SHAP para identificar los factores de riesgo; entre los hogares no pobres, el más importante es la propiedad de la vivienda. Sin embargo, ese ejercicio se hace en un país de ingreso alto, con registros administrativos completos y sin fuentes geoespaciales, condiciones muy distintas a las de un país en desarrollo que depende de encuestas.

### 2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital: en cinco países africanos, una red neuronal entrenada con imágenes satelitales diurnas, luz nocturna y datos de encuesta explica hasta el 75 % de la variación local del consumo o la riqueza, y predice mejor que la luz nocturna sola. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con exactitudes globales superiores al 82 %. Sin embargo, en regiones pobres y rurales la luz nocturna rinde menos que las imágenes diurnas, porque varía poco entre zonas (Hall et al., 2023).

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran, para un programa de transferencias de emergencia en Togo, que un modelo de aprendizaje automático entrenado con datos de telefonía móvil reduce los errores de exclusión entre 4 % y 21 % frente a la focalización geográfica, aunque los aumenta frente a un registro social completo. Hall et al. (2023), en una revisión sistemática, documentan que el número de fuentes de datos está entre los factores más asociados con el poder predictivo y que combinar aprendizaje automático y profundo lo aumenta hasta en 15 puntos porcentuales; también encuentran que los estudios que predicen activos físicos superan en 17 puntos a los que predicen variables de flujo como ingreso o consumo, y que el desempeño depende del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas

para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que este artículo busca incorporar (Sección 3.1).

Esta evidencia sugiere que combinar variables geoespaciales con encuestas puede mejorar lo que cada fuente logra por separado, sobre todo donde la encuesta es escasa. Sin embargo, ninguno de estos trabajos, ni los pocos que predicen la entrada en pobreza (Burger & van der Laan, 2021; Hohberg et al., 2018), evalúa si las fuentes geoespaciales públicas mejoran esa predicción en un país en desarrollo, con datos longitudinales de encuesta y una partición temporal hacia adelante, un problema que exige una variable de resultado prospectiva, un horizonte explícito entre olas y predictores medidos antes de la transición. Este trabajo busca llenar ese vacío desde un enfoque predictivo y no causal: en política pública la predicción es valiosa aun sin interpretación causal (Kleinberg et al., 2015), porque el objetivo es mejorar la focalización *ex ante*.

## 3. Datos

### 3.1. Fuentes de datos

El estudio combina un panel de hogares con información geoespacial pública y gratuita. Qué datos se usan de cada fuente lo decide el diseño de evaluación: los modelos se entrenan en la transición 2010→2013 y se evalúan en 2013→2016, así que toda fuente necesita datos en 2010 y en 2013.

**Panel de hogares.** La fuente primaria es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares urbanos y rurales en 2010, 2013 y 2016. Se organiza en módulos temáticos (hogar, personas, niños, comunidades, choques, activos y gasto). Las olas de 2019 y 2022, administradas por el DANE, quedan fuera de esta ventana y se dejan como agenda futura. Se excluyen los hogares que se dividieron en dos o más sub-hogares en olas posteriores (511 casos entre 2010 y 2013, y 1,190 entre 2013 y 2016), para no hacer supuestos sobre su trayectoria. Tras auditar los módulos (codificación de caracteres, cobertura por ola, columnas renombradas y preguntas filtro; Anexo A.9), el resultado es un panel hogar×ola de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas. El panel reúne las covariables de los módulos y las variables monetarias construidas: ingreso y gasto per cápita, nominales y reales, y la brecha frente a la línea de pobreza.

**Información geoespacial.** El supuesto es que el entorno físico y económico local afecta la vulnerabilidad del hogar de maneras que la encuesta no capta por completo. Se evaluaron

siete fuentes (Anexo B.2), agrupadas según lo que miden. La actividad económica y la electrificación del entorno se aproximan con luces nocturnas (DMSP-OLS y VIIRS DNB). La densidad del área construida frente a la vegetación se aproxima con radar (ALOS PALSAR y Sentinel-1) y con reflectancia óptica (Landsat 5 TM y Sentinel-2). La infraestructura cartografiada se aproxima con OpenStreetMap. Además de su nivel, de cada fuente se mide si el entorno se venía densificando o perdiendo cobertura vegetal antes de cada ola (Tabla 23, Anexo B.1). Toda la información se consulta en Google Earth Engine a partir de las coordenadas de los hogares de la ELCA, cuyo acceso es restringido y controlado por la Universidad de los Andes. Sentinel-1, Sentinel-2 y VIIRS DNB empezaron a operar después de 2012, y OpenStreetMap estaba casi vacío en Colombia entre 2010 y 2013. Solo tres fuentes, una por cada tipo de medición, tienen cobertura anterior a 2014: DMSP-OLS cubre el 100 % de los hogares en 2010 y en 2013; ALOS PALSAR cubre 2010 pero no tiene datos entre 2011 y 2014; y Landsat 5 TM cubre solo el 65.5 % de los hogares en 2010, por nubosidad, y dejó de adquirir imágenes útiles antes de 2013. Por eso DMSP-OLS es la fuente de la evaluación principal y las otras dos se usan en una variante complementaria (Sección 3.2). Las imágenes de Google Street View se revisaron solo de forma exploratoria: para las coordenadas de los hogares, no hay fotos anteriores a 2012 y el 61 % de las que se encontraron son posteriores a 2013 (Anexo A.8).

### 3.2. Cobertura, atrición e inventario del panel

Los módulos de Hogar, Personas y Choques cubren todo el panel; Comunidades cubre entre 92 y 96 %, porque se mide por comunidad y no por hogar, y Niños el 55.4 %, la proporción de hogares con niños de 6 a 9 años. El panel pierde 11.4 % de los hogares entre 2010 y 2013 y otro 11.4 % entre 2013 y 2016 (17.9 % acumulado). La atrición no es aleatoria: se concentra en hogares urbanos (16.2 % frente a 5.8 % de los rurales en 2010–2013) y de estratos altos (Anexo A.10).

Las covariables finales suman 177: 164 de los módulos y 13 monetarias (cobertura y detalle por módulo, tipo y tema en el Anexo A.9). Se descartan los indicadores y las líneas de pobreza y el ingreso y gasto nominales, porque definen la variable de resultado. Con eso, el Modelo A usa 169 variables y el Modelo B, sin ingreso ni gasto, usa 165 (Sección 4.3). A cada especificación se le agregan las variables geoespaciales en dos variantes. La principal agrega las 23 variables de DMSP-OLS y se evalúa en 2013→2016 (Sección 5.3). La complementaria agrega las 127 variables de las tres fuentes (23 de DMSP-OLS, 52 de ALOS PALSAR y 52 de Landsat 5 TM) y se evalúa con validación cruzada dentro de 2010→2013.

### 3.3. Dinámica de la pobreza en el panel

Esta sección describe los cuatro grupos de la matriz de transición (*nunca pobre, siempre pobre, entra en pobreza y sale de pobreza*), definidos en la Sección 4.1.<sup>1</sup>




Figura 1: Transición de pobreza entre categorías de López-Calva y Ortiz-Juarez (2014), panel emparejado 1 a 1 (mismo universo para monetaria e IPM; excluye 511 hogares que se dividieron entre olas en 2010–2013 y 1,190 en 2013–2016). Arriba: pobreza monetaria por ingreso; abajo: pobreza multidimensional (IPM).

Los paneles superiores de la Figura 1 traducen la matriz monetaria a flujos (los inferiores

<sup>1</sup>Para establecer la robustez de las estimaciones de pobreza monetaria y sus clasificaciones, se realizó un análisis adicional de la incidencia agregada, FGT, y cinco ejercicios de estimaciones, incluyendo la atrición del panel por perfil de hogar, que se documentan en el Apéndice A.2

hacen lo mismo con la del IPM): en 2010–2013 dominan los *siempre pobres* (43.9 %) sobre los *nunca pobres* (28.8 %); en 2013–2016 el orden se invierte (37.0 % vs. 33.3 %), y en ambos periodos la salida casi duplica la entrada, es decir, la pobreza monetaria se redujo de forma neta, no solo se redistribuyó entre hogares. Bajo pobreza monetaria la persistencia es alta pero decrece: 70.3 % de los pobres en 2010 seguían pobres en 2013, cae a 61.8 % entre 2013 y 2016 (la salida de la pobreza, condicional a ser pobre en la ola base, sube de 29.7 % a 38.2 %); la persistencia en la no-pobreza mejora de 76.6 % a 80.1 %. Bajo IPM entrar es menos frecuente (12.1 % y 9.7 %, frente a 23.4 % y 19.9 % en monetaria) y salir es más frecuente (54.5 % y 52.3 %, frente a 29.7 % y 38.2 %), por lo que la persistencia en la pobreza es menor (45.5 % y 47.7 %, frente a 70.3 % y 61.8 %). La baja entrada es coherente con que el IPM mide privaciones estructurales (educación, materiales de la vivienda, acceso a servicios) que, una vez superadas, rara vez se revierten, a diferencia del ingreso corriente. La alta salida debe leerse con cautela en 2010→2013, porque coincide con un cambio en la medición del indicador de barreras de acceso a salud (Sección 6.3); no obstante, que se mantenga en 2013→2016, donde ese indicador se mide igual, sugiere que no solo se debe a la medición.

Un último ejercicio (Tabla 1) sigue a los mismos hogares no pobres en la ola base a lo largo de las tres olas para distinguir, dentro de quienes *entran* en pobreza, una entrada transitoria de una persistente. Bajo pobreza monetaria, 24.1 % de los no pobres en 2010 entra en pobreza en algún momento: 14.0 % salen de nuevo antes de 2016 (“transitorio”) y 10.1 % se quedan (“persistente”). Bajo IPM la entrada total es menor (12.2 %) y se reparte parecido (8.2 transitoria, 4.0 persistente): en ambas definiciones, más de la mitad de quienes entran en pobreza no quedan atrapados dentro de la ventana de seis años observada.

Tabla 1: Trayectorias a 3 olas (2010→2013→2016) de hogares NO pobres en 2010, panel emparejado 1 a 1, monetaria vs. IPM.

| Trayectoria                    | Monetaria |        | IPM   |        |
|--------------------------------|-----------|--------|-------|--------|
|                                | n         | %      | n     | %      |
| Nunca cae                      | 1,700     | 67.2 % | 4,381 | 81.2 % |
| Cae tarde (solo en 2016)       | 220       | 8.7 %  | 357   | 6.6 %  |
| Entra y sale (transitorio)     | 355       | 14.0 % | 445   | 8.2 %  |
| Entra y se queda (persistente) | 255       | 10.1 % | 214   | 4.0 %  |

*Nota:*  $n=2,530$  hogares no pobres en 2010 bajo pobreza monetaria;  $n=5,397$  bajo IPM (universos distintos porque no-pobre-monetaria y no-pobre-IPM en 2010 no son el mismo conjunto de hogares). % sobre ese universo, sin ponderar. Fuente: cálculos propios.

## 4. Estrategia empírica

### 4.1. Construcción de la variable de resultado

Este estudio sigue la metodología de López-Calva y Ortiz-Juarez (2011, 2014), a partir de la cual se construyen matrices de transición de pobreza monetaria e IPM, cruzando el estado de un hogar en el período inicial  $t$  (filas), contra un periodo posterior  $t + 1$  (columnas). Esta comparación permite observar cómo evoluciona la situación económica de los hogares a lo largo del tiempo y generar una taxonomía de cuatro categorías de acuerdo con la clasificación en dos momentos del tiempo: *nunca pobre*, *siempre pobre*, *entra en pobreza* y *sale de pobreza*.

Ahora bien, la pobreza monetaria en este trabajo se estima a partir del cálculo del ingreso per cápita del hogar, de acuerdo con las preguntas correspondientes en la ELCA, y se compara contra la línea de pobreza (LP) oficial del DANE, específica por año y zona<sup>2</sup>. De otro lado, la pobreza multidimensional se mide con un proxy del Índice de Pobreza Multidimensional (IPM) del DANE (Angulo Salazar et al., 2011), construido con los diez indicadores que la ELCA permite medir de forma comparable en las tres olas. Los indicadores se agrupan en cuatro dimensiones de igual peso (25 % cada una), con igual peso entre los indicadores de cada dimensión: educación (bajo logro educativo y analfabetismo), niñez y juventud (rezago escolar), salud (sin aseguramiento y barreras de acceso) y vivienda y servicios públicos (fuente de agua, eliminación de excretas, pisos, paredes y hacinamiento crítico). Un hogar se clasifica como pobre si su puntaje ponderado de privaciones es de al menos 33.3 %, el mismo corte del IPM oficial.<sup>3</sup>

Los modelos predictivos de este estudio (Secciones 4.3 en adelante) se estiman sobre los hogares no pobres en  $t$  y predicen si caen en pobreza en  $t + 1$ , de acuerdo con la definición de vulnerabilidad (Ecuación 1):

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

<sup>2</sup>Se usa la serie MESEP (línea base ENIG 2006–2007, actualizada anualmente por IPC), la misma metodología para las tres olas (2010, 2013 y 2016), lo que las hace comparables entre sí. Deliberadamente no se usa la actualización metodológica ENPH 2016–2017 con la que el DANE recalculó la serie 2012–2018, porque esa serie no cubre 2010 y adoptarla habría introducido una inconsistencia metodológica justo entre las olas que este estudio compara.

<sup>3</sup>El IPM oficial tiene cinco dimensiones y quince indicadores. Se excluyen cinco por falta de cobertura en la ola 2010: privación en primera infancia (no medible de forma consistente en ninguna ola); inasistencia escolar y trabajo infantil (0.4 %–35.3 % de cobertura en 2010, frente a cerca de 100 % en 2013 y 2016); y empleo informal y desempleo de larga duración (cerca de 20 % de cobertura en 2010, frente a 75–80 % en 2013 y 2016). Con ello la dimensión Trabajo queda sin indicadores y su peso se reparte entre las otras cuatro.

Conviene precisar la terminología. En el sentido de Chaudhuri et al. (2002), la vulnerabilidad es una probabilidad *ex ante*; en este artículo corresponde a la probabilidad predicha por los modelos,  $\hat{P}(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it})$ . La entrada efectiva en pobreza es su realización observada, que se usa para entrenar y evaluar esos modelos. Por brevedad, el texto llama *hogares vulnerables* a los que efectivamente entran en pobreza, entendiendo que son la realización del riesgo y que otros hogares con una probabilidad predicha igual de alta no llegaron a caer.

## 4.2. Metodología de caracterización de los hogares vulnerables

Para caracterizar a los hogares vulnerables se combinan dos análisis. El principal usa los modelos de la Sección 4.3 para identificar qué variables anticipan la entrada en pobreza. El segundo compara a los hogares vulnerables (*entra en pobreza*) con los otros tres grupos de la matriz de transición, incluidos los que ya eran pobres, que los modelos binarios no incluyen.

En el primer análisis se usan valores SHAP, que miden cuánto sube o baja cada variable la probabilidad predicha para cada hogar, con la ventaja de que se miden en la misma escala para los cinco algoritmos. Se calculan para los Modelos A y B (con y sin ingreso y gasto, Sección 4.3), lo que da diez combinaciones de algoritmo y especificación, en las dos definiciones de pobreza y en las dos ventanas. De ahí salen dos resultados. El *núcleo* son las variables que, en al menos cinco de las diez combinaciones, están entre las que suman el 80 % de la importancia total. La *dirección* indica si valores altos de una variable suben o bajan el riesgo, y se mide con la correlación de Spearman entre la variable y su valor SHAP. Se considera que la dirección de una variable es estable si su signo se mantiene en las dos definiciones de pobreza y en las dos ventanas. Ambos criterios se prueban con umbrales alternativos en el Apéndice A.3 para validar los resultados.

Para el segundo análisis se estima un modelo multiclase sobre los cuatro grupos de la matriz de transición (*nunca pobre, entra en pobreza, sale de pobreza y siempre pobre*), con los mismos algoritmos y el mismo esquema de validación que el modelo binario (entrenamiento en 2010→2013 y prueba en 2013→2016). Se estima sin ingreso ni gasto (Modelo B): con ellos la comparación sería trivial, porque el ingreso define la condición de pobreza en la ola base. Para medir qué tan parecidos son dos grupos se usa el AUC-ROC por par: se restringe la muestra a los hogares de esos dos grupos y se toma como puntaje la probabilidad que el modelo asigna al primero. Un AUC cercano a 0.5 indica que, con la información de la ola base, los dos grupos no se distinguen. Su incertidumbre se mide con un *bootstrap* por comunidad sobre la muestra de prueba. El modelo multiclase no reemplaza al binario: la pregunta de vulnerabilidad se refiere solo a los hogares hoy no pobres y, al asignar a

cada hogar su grupo más probable, casi nunca identifica a los que entran en pobreza. Se estima solo bajo pobreza monetaria; su especificación y resultados completos están en el Apéndice A.12.

Finalmente, se separa a los hogares que entran en pobreza según sigan o no pobres en 2016 (transitorios y persistentes) y se comparan sus promedios en las variables del núcleo SHAP.

### 4.3. Especificación de modelos

La estrategia empírica se establece mediante la siguiente especificación de modelo:

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde  $X_{it}$  es el vector de características del hogar  $i$  observadas en el periodo  $t$  (Sección 3.1), incluyendo las variables geoespaciales complementarias, y  $F(\cdot)$  es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se comparan cinco algoritmos de aprendizaje supervisado: una regresión logística regularizada (*elastic net*), cuya fuerza y mezcla de penalización se eligen por validación cruzada y que sirve de referencia por ser interpretable; Random Forest, que McBride y Nichols (2018) emplean para mejorar la focalización fuera de muestra; y tres implementaciones de *gradient boosting* (XGBoost, LightGBM y HistGradientBoosting), que manejan de forma nativa los datos faltantes y las variables categóricas (descripción detallada en el Anexo A.13). El riesgo de multicolinealidad, relevante sobre todo para la regresión logística, se analiza en el Apéndice A.1.

Para evaluar el aporte del nivel de ingreso/gasto del hogar, el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, con cada uno de los cinco algoritmos se estiman dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante (se mantiene constante a lo largo del tiempo); el **Modelo B** excluye estas cuatro variables y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad).

Finalmente, se establecieron dos variables objetivo para evaluar la robustez de los hallazgos: la transición hacia la pobreza monetaria y la transición hacia la pobreza multidimensional bajo el proxy de IPM.

#### 4.4. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, en el que solo existe la ola base al momento de predecir. Es además más exigente que la validación cruzada aleatoria que recomiendan McBride y Nichols (2018), quienes advierten que esta supone que el proceso generador de los datos no cambia entre el desarrollo y la aplicación de la herramienta; la partición temporal pone a prueba ese supuesto, porque evalúa el modelo en un periodo económico distinto al de entrenamiento.

Dentro del periodo de entrenamiento (2010 a 2013), los hiperparámetros de cada algoritmo, como la profundidad de los árboles o la tasa de aprendizaje, no se fijan a mano, sino que se eligen con una búsqueda aleatoria (*randomized search*). Se prueban 30 combinaciones elegidas al azar dentro de un rango razonable para cada hiperparámetro, en lugar de todas las combinaciones posibles (*grid search*), cuyo costo de cómputo habría sido prohibitivo para 5 algoritmos, 4 especificaciones, 3 estrategias de balanceo (Sección 4.5) y dos variables objetivo. Cada combinación se evalúa con validación cruzada estratificada de 10 particiones: el conjunto de entrenamiento se divide en 10 bloques que conservan la proporción de hogares que entran en pobreza, se entrena 10 veces dejando por fuera un bloque distinto y se evalúa sobre él. Promediar las 10 evaluaciones castiga a las combinaciones que memorizan particularidades de los datos en vez de aprender un patrón que generaliza. Los hiperparámetros elegidos para cada uno de los modelos reportados se presentan en la Tabla 22 del Anexo A.13.

Para verificar que 30 iteraciones no se quedan cortas, se extendió la búsqueda a 50 iteraciones para el caso más ambiguo de la comparación de balanceo (HistGradientBoosting-A, Sección 4.5): el mejor puntaje acumulado ya no mejora entre las iteraciones 20 y 40 (0.7603 en ambas), y gana solo 0.0006 adicional hacia la iteración 50 —evidencia de que la búsqueda con 30 iteraciones ya opera cerca de su techo para este caso, no de que se haya interrumpido prematuramente.

La métrica que decide qué combinación gana esa búsqueda es el AUC-ROC: la probabilidad de que, al tomar al azar un hogar que entra en pobreza y uno que no, el modelo le asigne más riesgo al primero (0.5 equivale a adivinar al azar y 1 a ordenar a todos los hogares correctamente). Es apropiada porque lo que se busca es un modelo que ordene bien a los hogares según su riesgo, y el AUC-ROC mide justamente eso, sin depender del umbral a partir del cual se clasifica a un hogar como vulnerable, que se elige después (Sección 4.5).

El AUC-ROC es la métrica principal, pero con clases desbalanceadas puede dar una imagen optimista: premia una tasa *relativa* baja de falsos positivos, que puede esconder un número *absoluto* alto de falsos positivos cuando los hogares que entran en pobreza son pocos (Davis & Goadrich, 2006; Saito & Rehmsmeier, 2015). Esto no lo invalida como medida de ordenamiento, pero sí limita lo que dice, por sí solo, sobre la utilidad del modelo para una política con cobertura limitada. Por eso se reportan también el *recall*, la precisión y el F1 al umbral de clasificación elegido con  $F_2$  (Sección 4.5), junto con la matriz de confusión completa; el F1 se incluye por ser la referencia más usada en la literatura, aunque no es el criterio que fija el umbral. El *recall* es la fracción de los hogares que efectivamente entran en pobreza que el modelo marca como en riesgo (cuánta de la pobreza futura se captura), y la precisión es la fracción de los hogares marcados que efectivamente entran (cuántas de las alertas son acertadas). Ambas dependen del umbral y se mueven en direcciones opuestas: con un mismo modelo, bajar el umbral sube el *recall* a costa de la precisión, y viceversa. El umbral solo elige un punto dentro de lo que la capacidad de ordenamiento del modelo, medida por su AUC-ROC, permite. Además, se reporta la precisión en el decil de mayor riesgo, que no depende de un umbral de clasificación y responde directamente la pregunta de un programa con presupuesto limitado: si solo puede atender al 10 % de los hogares que el modelo considera de mayor riesgo, ¿qué proporción de ellos efectivamente entra en pobreza?

El análisis se centra en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo: como se documenta en la Sección 5.1, las diferencias de AUC-ROC entre modelos son pequeñas frente a la variabilidad esperable por la aleatoriedad del ajuste.

#### 4.5. Tratamiento del desbalance de clases y de los datos faltantes

Los datos faltantes de las covariables reciben un único tratamiento, que depende del algoritmo, y no se elimina ningún hogar por tenerlos. La regresión logística y Random Forest no aceptan valores faltantes: como en la ELCA provienen sobre todo de preguntas filtro (por ejemplo, el monto de una ayuda no se pregunta a quien no recibió ninguna), se rellenan con 0 y se agrega un indicador de faltante por variable, en vez de la mediana, que asignaría a esos hogares un valor típico que no tienen; las variables categóricas reciben la categoría “Sin dato”. XGBoost, LightGBM y HistGradientBoosting los manejan de forma nativa, sin imputación.

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4 % (Figura 1a), un desbalance que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases

(`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.<sup>4</sup>

Con clases desbalanceadas, las probabilidades predichas tienden a concentrarse en valores bajos, de modo que el umbral convencional de 0.5 clasifica a muy pocos hogares como vulnerables. Por eso el umbral de cada modelo también se elige por validación cruzada: sobre las probabilidades *out-of-fold* se prueba una grilla de umbrales entre 0.02 y 0.98 y se elige el que maximiza  $F_2$ . A diferencia del  $F_1$ , que pesa igual el *recall* y la precisión,  $F_2$  pesa el doble el *recall*, porque en focalización dejar sin detectar a un hogar que entrará en pobreza es más costoso que incluir a uno que no caerá. El umbral no cambia el modelo ni su AUC-ROC; solo determina cómo se reportan el *recall*, la precisión y el  $F_1$ .

## 5. Resultados

Los resultados se presentan en tres partes comenzando por los aspectos más generales de los modelos y los perfiles de vulnerabilidad para abordar luego propiamente la pregunta de investigación de este estudio. La Sección 5.1 compara el desempeño fuera de muestra de los cinco algoritmos bajo las especificaciones A y B (con y sin ingreso/gasto) del hogar y analiza los errores de inclusión y exclusión de los modelos. La Sección 5.2 caracteriza a los hogares vulnerables a partir de los valores SHAP de esos modelos y usa un modelo multiclase para compararlos con los otros tres grupos de la matriz de transición, incluidos los que ya eran pobres. La Sección 5.3 analiza el efecto de las variables provenientes de fuentes geoespaciales públicas y evalúa si agregar DMSP-OLS mejora esa predicción, bajo pobreza monetaria e IPM (Secciones 5.3.1 y 5.3.2) y si ese efecto es igual en la población o se concentra en subgrupos específicos (Sección 5.3.2).

---

<sup>4</sup>No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La elección de la estrategia de balanceo es sensible al azar del particionado: para HistGradientBoosting con el Modelo A, repetir la comparación con cinco semillas distintas cambia la estrategia ganadora en tres de ellas, con diferencias de AUC-ROC entre estrategias de entre 0.001 y 0.004 dentro de cada semilla. Se usa siempre la semilla fijada de antemano (42); las diferencias entre estrategias están dentro del ruido del particionado.

## 5.1. Desempeño comparativo de modelos

### 5.1.1. Desempeño de los modelos

La Tabla 2 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.4 y 4.5; la estrategia de balanceo y los hiperparámetros elegidos para cada modelo se reportan en el Anexo A.13).

Tabla 2: Desempeño de los cinco algoritmos en el conjunto de prueba (2013→2016), promedio de 5 semillas. Prec.-top10: precisión en el 10 % de hogares con mayor riesgo predicho; Rec.-top10: fracción de los hogares que entran en pobreza que queda dentro de ese 10 %.

| Algoritmo              | Espec. | Umbral | AUC-ROC | Recall | Precision | Prec.-top10 | Rec.-top10 | F1    |
|------------------------|--------|--------|---------|--------|-----------|-------------|------------|-------|
| XGBoost                | A      | 0.11   | 0.767   | 0.949  | 0.264     | 0.505       | 0.254      | 0.413 |
| Random Forest          | A      | 0.14   | 0.766   | 0.926  | 0.277     | 0.486       | 0.245      | 0.426 |
| HistGradientBoosting   | A      | 0.32   | 0.763   | 0.909  | 0.283     | 0.512       | 0.258      | 0.432 |
| LightGBM               | A      | 0.10   | 0.758   | 0.903  | 0.281     | 0.516       | 0.260      | 0.428 |
| Logística regularizada | A      | 0.37   | 0.747   | 0.883  | 0.280     | 0.506       | 0.255      | 0.426 |
| Random Forest          | B      | 0.31   | 0.742   | 0.892  | 0.272     | 0.508       | 0.256      | 0.416 |
| XGBoost                | B      | 0.13   | 0.742   | 0.940  | 0.250     | 0.495       | 0.249      | 0.395 |
| Logística regularizada | B      | 0.35   | 0.739   | 0.890  | 0.270     | 0.500       | 0.252      | 0.414 |
| HistGradientBoosting   | B      | 0.14   | 0.735   | 0.879  | 0.275     | 0.494       | 0.249      | 0.418 |
| LightGBM               | B      | 0.15   | 0.731   | 0.909  | 0.259     | 0.487       | 0.246      | 0.403 |

Frente al desempeño de los modelos se encontraron dos hallazgos. **Primero**, el algoritmo elegido no cambia el poder de discriminación de los vulnerables (AUC-ROC 0.731–0.767 en los cinco). Bajo IPM ocurre lo mismo, en un rango de AUC-ROC igual de estrecho (0.725–0.747; Tabla 9, Apéndice A.4). Un AUC-ROC de 0.75 significa que, si se toma al azar un hogar que entra en pobreza y uno que no, el modelo correctamente asigna mayor riesgo al primero solo 3 de cada 4 veces. Es un desempeño moderado frente a los pocos trabajos que evalúan la predicción de la entrada en pobreza. Con registros administrativos de los Países Bajos, más de 500 variables y un horizonte de un año, Burger y van der Laan (2021) obtienen un AUC normalizado de 0.90 (donde 0 equivale al azar y 1 a una clasificación perfecta), y con el panel alemán SOEP, Hohberg et al. (2018) identifican al 80 % de quienes caen al año siguiente con menos de 20 % de falsos positivos en la mayoría de los años, proporción que sube a cerca de 30 % con un horizonte de tres años. Aquí la predicción se hace a tres años y con una encuesta, no con registros administrativos, lo que hace esperable un techo más bajo. Que incluso la regresión logística regularizada, el algoritmo más simple, quede cerca de los demás (prácticamente igual sin ingreso (0.739 frente a 0.742) y 0.02

por debajo con ingreso) y que los algoritmos de *boosting* elijan árboles poco profundos (profundidad 3 o 4) sugiere que las interacciones complejas entre variables aportan poco. El límite al desempeño parece estar en la información que contienen las covariables más que en la forma del modelo, lo que no implica afirmar ausencia de efectos no lineales, sino que modelarlos aporta poco a la discriminación. Lo que sí varía es la dirección de algunas variables según la definición de pobreza: la edad del jefe de hogar, por ejemplo, se asocia con menor riesgo bajo pobreza monetaria y con mayor riesgo bajo IPM (Sección 5.2).

**Segundo**, la capacidad de identificar vulnerables apenas cambia si se excluyen las variables de ingreso/gasto del hogar de las covariables que se utilizan en los modelos. La ganancia de incluir esa información, que es la más cara de levantar mediante encuesta, y la menos confiable, es marginal (brecha de AUC de 0.008 a 0.028 entre el Modelo A y B). La brecha es pequeña si se considera que, en el enfoque de Chaudhuri et al. (2002), la vulnerabilidad se deriva directamente de la media y la varianza esperadas del consumo. Esto no implica que el ingreso no importe (Sección 5.2), sino que su contenido informativo ya está sustancialmente capturado por otras variables del núcleo del perfil (Ej. Riqueza, educación, bienes durables Sección 5.2). Este resultado es coherente con dos líneas de la literatura. López-Calva y Ortiz-Juarez (2014) interpretan el ingreso observado como una medida resumen de los activos del hogar y, por eso, construyen un ingreso permanente a partir de esos activos y de características socioeconómicas; y los *proxy means tests* descansan en que un conjunto de características del hogar fáciles de verificar aproxima su bienestar sin medir el ingreso (McBride & Nichols, 2018). Bajo IPM la brecha es aún menor, y para Random Forest y XGBoost es negativa (el Modelo B (sin ingreso/gasto) supera al A), lo que descarta que la pequeña brecha en la capacidad discriminante de los modelos bajo la definición de pobreza monetaria se deba a la relación entre ingreso y la definición de pobreza. La implicación práctica sería mantener la estrategia de focalizar mediante el ingreso/gasto del hogar, pero cuando no sea posible obtener esa información, se encuentre desactualizada o poco confiable, se podría utilizar un instrumento alternativo y confiable: las mismas variables que ofrece la encuesta. Con un particular énfasis en las variables del núcleo del perfil (Sección 5.2), que son las que más contribuyen a la predicción de vulnerabilidad.

### 5.1.2. Análisis de los errores de inclusión y exclusión

Frente a los errores de inclusión y exclusión se encontraron tres hallazgos más. **Tercero**, un programa que no quiera dejar por fuera a los hogares vulnerables tendrá que atender a muchos que no lo necesitan, y cambiar de algoritmo o de umbral no lo evita sin dejar por fuera a más hogares vulnerables; lo que sí mejora su eficiencia sería concentrarse en el 10 % de hogares con mayor riesgo, a costa de cobertura. Con los datos disponibles

para este estudio y de acuerdo con los modelos utilizados, se encontró que con cualquiera de estos, una política pública para la vulnerabilidad atendería entre 2.4 y 3.1 hogares no vulnerables por cada hogar vulnerable identificado (Tabla 3). Asimismo, los modelos descartan correctamente los hogares no vulnerables solo entre el 26 % (XGBoost) y el 47 % (LightGBM). En términos de la Tabla 2, el *recall* es alto (0.88–0.95: casi todos los hogares verdaderamente vulnerables quedan marcados) y la precisión baja (0.25–0.28: uno de cada cuatro marcados como vulnerables lo es).

El umbral elegido por  $F_2$ , que da el doble de peso a no dejar sin detectar a hogares verdaderamente vulnerables que a marcar de más a hogares que no caen, decide en qué punto de ese intercambio se ubica el modelo; pero con un AUC-ROC de 0.75 no es posible tener *recall* y precisión altos a la vez. Es el intercambio que la literatura de focalización llama errores de inclusión y de exclusión (*Type E* y *Type F*, Cornia y Stewart (1993)): para un instrumento dado, reducir uno aumenta el otro, y solo un instrumento con mayor poder de discriminación puede mover esa frontera. Por eso Hohberg et al. (2018) proponen elegir el umbral según el objetivo de focalización y no fijarlo en una probabilidad de 0.5: privilegiar la identificación de quienes caerán conduce a programas más amplios, y minimizar el total de errores, a programas más acotados. El umbral elegido por  $F_2$  y el decil de mayor riesgo corresponden a esas dos opciones. En cambio, en el decil de mayor riesgo la precisión (0.49–0.52) casi duplica la del umbral completo: uno de cada dos hogares atendidos efectivamente cae. El costo es la cobertura: ese decil contiene solo entre el 25 % y el 26 % de los hogares vulnerables (Tabla 2), de modo que un programa así llegaría a uno de cada cuatro vulnerables.

Tabla 3: Matriz de confusión del Modelo A en el conjunto de prueba (2013→2016), pobreza monetaria e IPM.

| Algoritmo              | Monetaria  |             |          |             | IPM       |             |           |             |
|------------------------|------------|-------------|----------|-------------|-----------|-------------|-----------|-------------|
|                        | VP         | FP          | FN       | VN          | VP        | FP          | FN        | VN          |
| XGBoost                | 617 (19 %) | 1888 (59 %) | 18 (1 %) | 668 (21 %)  | 491 (9 %) | 3297 (59 %) | 51 (1 %)  | 1732 (31 %) |
| Random Forest          | 594 (19 %) | 1572 (49 %) | 41 (1 %) | 984 (31 %)  | 343 (6 %) | 1493 (27 %) | 199 (4 %) | 3536 (63 %) |
| HistGradientBoosting   | 584 (18 %) | 1532 (48 %) | 51 (2 %) | 1024 (32 %) | 301 (5 %) | 1124 (20 %) | 241 (4 %) | 3905 (70 %) |
| LightGBM               | 561 (18 %) | 1354 (42 %) | 74 (2 %) | 1202 (38 %) | 415 (7 %) | 2052 (37 %) | 127 (2 %) | 2977 (53 %) |
| Logística regularizada | 561 (18 %) | 1444 (45 %) | 74 (2 %) | 1112 (35 %) | 379 (7 %) | 1862 (33 %) | 163 (3 %) | 3167 (57 %) |

*Nota:* VP, FP, FN y VN: hogares verdadero positivo, falso positivo, falso negativo y verdadero negativo. Entre paréntesis, porcentaje sobre el total de la fila para cada definición de pobreza (monetaria,  $n = 3,191$ ; IPM,  $n = 5,571$ ). Modelos clasificados con los hiperparámetros y el umbral reportados en la Tabla 22 del Anexo A.13. La matriz del Modelo B se reporta en la Tabla 19 del Anexo A.11. Corresponde a una sola corrida de cada modelo, por lo que el *recall* y la precisión que se derivan de ella difieren levemente de los promedios de 5 semillas de la Tabla 2. Fuente: cálculos propios.

**Cuarto**, los falsos positivos no son errores aleatorios, son hogares que no cayeron en

pobreza, pero cuya situación en la ola base es mucho más precaria que la de los hogares que el modelo acierta en no marcar. Para verlo, se compararon los hogares que los modelos marcan como vulnerables pero no caen en pobreza (falsos positivos) con los que tampoco caen y el modelo no marca (verdaderos negativos), para HistGradientBoosting y XGBoost con el Modelo A. Los dos grupos difieren en casi todas las variables del núcleo SHAP: en HistGradientBoosting, los falsos positivos tienen un índice de riqueza mucho menor (0.30 frente a 1.65), menor educación máxima en el hogar (3.2 frente a 5.5), menos bienes durables y servicios públicos, menor estrato, menos acceso a internet y más hacinamiento; solo se parecen en los choques y la edad del jefe. Sin embargo, lo que lleva al modelo a marcarlos se concentra en pocas variables. Según los valores SHAP, en HistGradientBoosting son el índice de riqueza, la educación máxima del hogar y los bienes durables; en XGBoost, el ingreso y el gasto per cápita y su brecha frente a la línea de pobreza, seguidos de la educación.

La riqueza y la educación no elevan el riesgo que los modelos asignan a los falsos positivos: en los verdaderos negativos, su nivel alto reduce con fuerza el riesgo predicho, mientras que en los falsos positivos casi no lo modifica. Es decir, los modelos no los marcan porque tengan una característica que los haga especialmente riesgosos, sino porque no tienen la riqueza y la educación que llevan a los verdaderos negativos a quedar por debajo del umbral. Solo algunas variables sí empujan su riesgo hacia arriba: en HistGradientBoosting, los bienes durables, los servicios públicos, el estrato y tener un jefe jornalero; en XGBoost, sobre todo el ingreso per cápita. Así, los modelos distinguen bien a los hogares precarios de los que no lo son; lo que distingue solo en parte es cuáles de los hogares precarios efectivamente caerán.

**Quinto**, quienes efectivamente caen reportan más choques posteriores a la predicción que quienes no caen. Comparando choques reportados en la ola de destino (2016, posteriores al momento de la predicción y por tanto no usados por el modelo) entre verdaderos positivos y falsos positivos, los primeros reportaron más choques en la ola de 2016: 3.1 choques en promedio frente a 2.2 (ambos algoritmos), y 81–82 % tuvo al menos un choque frente a 71–72 % de los falsos positivos –consistente con el enfoque de vulnerabilidad de Chaudhuri et al. (2002): el modelo identifica correctamente al hogar en el margen, y parte de quién realiza el riesgo podría depender de choques que la ola base no permite anticipar. También coincide con la evidencia de que los choques idiosincráticos y comunes, como la pérdida de la cosecha de un hogar o la falta de lluvias, generan movimientos de corto plazo hacia dentro y fuera de la pobreza que una medición en un solo momento no captura (Dercon & Krishnan, 2000), y de que los choques idiosincráticos producen por sí solos una volatilidad del consumo no despreciable (Christiaensen & Subbarao, 2005). La comparación es descriptiva: los choques

se autorreportan en la misma ola en que se observa la caída, de modo que un hogar que cayó puede recordarlos o reportarlos más, o haberlos sufrido como consecuencia de la caída.

En suma, cualquier modelo, incluso el del algoritmo más simple y aun sin medir el ingreso del hogar, identifica con una capacidad moderada (AUC-ROC cercano a 0.75) a los hogares que están en el margen de la pobreza, pero distingue mal cuáles de ellos efectivamente caerán, un resultado asociado de forma descriptiva a choques posteriores a la predicción. Las implicaciones de este resultado para la focalización se discuten en la Sección 6.2.

## 5.2. Determinantes de la vulnerabilidad y comparación entre grupos

Esta sección responde quiénes son los hogares vulnerables, es decir, los que no son pobres en la ola base y entran en pobreza en la siguiente, y qué los distingue. La evidencia principal son los valores SHAP de los modelos de la Sección 5.1: solo se afirma como determinante lo que se sostiene en los cinco algoritmos, en las dos definiciones de pobreza (monetaria y multidimensional) y en las dos ventanas (2010→2013 y 2013→2016). El modelo multiclase compara a los hogares vulnerables con los otros tres grupos de la matriz de transición (Sección 3.3), incluidos los que ya eran pobres, que los modelos binarios no incluyen.

Hay cuatro hallazgos principales. **Primero**, unas pocas variables concentran casi toda la información para identificar a los hogares vulnerables. De las 165 a 169 covariables, entre 14 y 37 acumulan el 80 % de la importancia SHAP en cada combinación de algoritmo y especificación, y las diez primeras, entre el 44 % y el 72 % (Tabla 7, Apéndice A.3). Las 22 variables que están en ese grupo en al menos la mitad de las combinaciones forman el núcleo del perfil vulnerable (Tabla 4). Cuatro aparecen en todas las combinaciones: servicios públicos, estrato, bienes durables y personas por cuarto. Siete se mantienen en el núcleo bajo las dos definiciones de pobreza y en las dos ventanas: riqueza, educación máxima del hogar, nivel educativo del jefe, personas por cuarto, razón de dependencia, puntaje TVIP<sup>5</sup> y material del piso. El núcleo tampoco depende de los criterios elegidos para definirlo: las 22 variables se conservan con criterios más laxos, y riqueza, educación máxima, razón de dependencia y personas por cuarto sobreviven incluso a los más estrictos (Tabla 8). Esto no implica que la información completa del hogar sobra, porque disponer de todas las variables sigue siendo el escenario preferible. Pero cuando esa información no está

---

<sup>5</sup>Puntaje promedio de los niños del hogar en el Test de Vocabulario en Imágenes Peabody (TVIP), que mide el vocabulario receptivo como indicador del desarrollo cognitivo. Se usa el puntaje bruto, sin ajustar por edad, de modo que refleja en parte la edad de los niños evaluados.

disponible, está desactualizada o es incompleta, por ejemplo entre rondas de una encuesta o para hogares con registros administrativos parciales, un conjunto reducido centrado en el núcleo podría servir como alternativa para identificar a los hogares vulnerables; queda como investigación futura evaluar un modelo restringido a esas variables.

**Segundo**, lo que protege a un hogar de caer en pobreza es lo que ha acumulado, y lo que lo expone es la presión sobre esos recursos. El núcleo tiene una dirección consistente entre algoritmos, definiciones de pobreza y ventanas (Tabla 4). Reducen el riesgo, con dirección estable bajo todos los criterios evaluados, el índice de riqueza, los activos financieros, el estrato, la educación máxima del hogar y el último grado aprobado por el jefe,<sup>6</sup> y, con dirección moderada, el nivel educativo del jefe, el valor del arriendo y los controles médicos preventivos. Lo aumentan el hacinamiento, con dirección estable, y la razón de dependencia, con dirección moderada. Las demás variables del núcleo no tienen una dirección clara: los bienes durables, los servicios públicos y la cotización a pensión tienen signo mayoritariamente negativo pero no estable entre fuentes, y el acceso a internet, el puntaje TVIP, el choque económico, el porcentaje de niños con madre o padre vivo, la edad del jefe y los desplazados en la comunidad cambian de signo entre definiciones o ventanas; por eso se reportan como asociaciones, no como determinantes. Estas direcciones coinciden con las que encuentran Hernández y Zuluaga (2022) con la misma ELCA bajo pobreza multidimensional, donde los años de educación, el empleo asalariado y el acceso al crédito reducen la vulnerabilidad, y con la literatura que asocia el capital humano con la pobreza crónica y la riqueza con una menor pobreza transitoria (Jalan & Ravallion, 2000), y que identifica el ahorro como una forma de autoseguro de los hogares frente a los choques (Dercon, 2002). El signo describe cómo el modelo usa cada variable, no un efecto causal, pero indica dónde tendría más sentido enfocar la prevención: en fortalecer el patrimonio del hogar (ahorro y activos financieros, educación y vivienda) más que en compensar carencias una vez ocurren.

Tabla 4: Núcleo de variables del análisis SHAP y su dirección.

| Variable                   | Comb. | Monetaria<br>2010→13 | Monetaria<br>2013→16 | IPM<br>2010→13 | IPM<br>2013→16 | Dirección |
|----------------------------|-------|----------------------|----------------------|----------------|----------------|-----------|
| <b>Activos del hogar</b>   |       |                      |                      |                |                |           |
| Estrato (verificado)       | 10    | − 10/10              | − 10/10              | − 5/5          | − 10/10        | Estable   |
| N.º de servicios públicos  | 10    | − 10/10              | − 3/5                | − 10/10        | − 9/10         | Inestable |
| N.º de bienes durables     | 10    | − 10/10              | − 10/10              | − 7/8          | − 7/9          | Inestable |
| Tiene internet en el hogar | 9     | − 10/10              | − 7/7                | + 3/5          | + 5/8          | Inestable |

*Continúa en la página siguiente*

<sup>6</sup>Es el último grado aprobado dentro del nivel educativo alcanzado, no los años de escolaridad: va de 1 a 5 en primaria y de 6 a 13 en secundaria, y se reinicia en la educación técnica, universitaria y de posgrado. Por eso se lee como escolaridad sobre todo entre los jefes con primaria o secundaria, que son la gran mayoría de la muestra.

Tabla 4 (continuación)

| Variable                                      | Comb. | Monetaria<br>2010→13 | Monetaria<br>2013→16 | IPM<br>2010→13 | IPM<br>2013→16 | Dirección |
|-----------------------------------------------|-------|----------------------|----------------------|----------------|----------------|-----------|
| Índice de riqueza (PCA)                       | 8     | − 10/10              | − 10/10              | − 8/8          | − 10/10        | Estable   |
| N.º de activos financieros                    | 6     | − 9/9                | − 9/10               | − 10/10        | − 10/10        | Estable   |
| <b>Educación, empleo y seguridad social</b>   |       |                      |                      |                |                |           |
| Máx. nivel educativo del hogar                | 9     | − 10/10              | − 10/10              | − 9/9          | − 9/10         | Estable   |
| Cotización a pensión (hogar)                  | 7     | − 8/9                | − 9/9                | − 7/9          | − 8/8          | Inestable |
| Último grado aprobado por el jefe             | 6     | − 6/6                | − 5/5                | − 9/9          | − 9/9          | Estable   |
| Nivel educativo del jefe (ordinal)            | 5     | − 8/8                | − 8/8                | − 9/10         | − 8/8          | Moderada  |
| <b>Vivienda: materiales y servicios</b>       |       |                      |                      |                |                |           |
| Material de piso del hogar                    | 8     | cat.                 | cat.                 | cat.           | cat.           | −         |
| <b>Vivienda: hacinamiento</b>                 |       |                      |                      |                |                |           |
| Personas por cuarto                           | 10    | + 10/10              | + 9/9                | + 10/10        | + 10/10        | Estable   |
| Valor del arriendo pagado                     | 6     | − 9/10               | − 7/8                | − 10/10        | − 8/8          | Moderada  |
| <b>Composición del hogar</b>                  |       |                      |                      |                |                |           |
| % de niños con madre viva                     | 8     | + 9/9                | + 6/6                | + 8/8          | − 4/6          | Inestable |
| Razón de dependencia demográfica              | 8     | + 8/9                | + 8/9                | + 8/10         | + 8/10         | Moderada  |
| Edad del jefe de hogar                        | 7     | − 8/8                | − 6/7                | + 9/9          | + 7/7          | Inestable |
| % de niños con padre vivo                     | 7     | − 4/6                | + 8/9                | − 5/5          | − 10/10        | Inestable |
| Estado civil del jefe                         | 6     | cat.                 | cat.                 | cat.           | cat.           | −         |
| <b>Desarrollo infantil (6–9 años)</b>         |       |                      |                      |                |                |           |
| Puntaje de vocabulario infantil (test TVIP)   | 6     | − 4/7                | − 4/6                | − 10/10        | − 8/9          | Inestable |
| <b>Salud</b>                                  |       |                      |                      |                |                |           |
| Tasa de controles médicos preventivos (hogar) | 6     | − 9/9                | − 8/8                | − 10/10        | − 8/9          | Moderada  |
| <b>Choques y afrontamiento</b>                |       |                      |                      |                |                |           |
| Tuvo un choque económico (hogar)              | 6     | + 8/9                | + 4/7                | + 8/8          | + 4/6          | Inestable |
| <b>Comunidad</b>                              |       |                      |                      |                |                |           |
| N.º de desplazados en la comunidad            | 5     | − 6/9                | − 7/8                | + 2/3          | + 4/6          | Inestable |

*Nota:* Comb.: combinaciones algoritmo/especificación (de 10) en que la variable está dentro del 80 % de la masa SHAP acumulada (Sección 5.2). Cada celda de signo indica el signo mayoritario y en cuántas ( $n$ ) de las  $m$  combinaciones con dirección clara ( $|p| \geq 0.10$ ) aparece: − significa que valores altos de la variable *reducen* el riesgo de entrar en pobreza; +, que lo *aumentan*. Dirección: Estable = mismo signo en las cuatro fuentes bajo las 12 combinaciones de umbrales evaluadas; Moderada = en al menos 8; Inestable = en menos. “cat.”: variable categórica, sin signo a nivel de variable. Fuente: cálculos propios.

**Tercero**, el hogar que cae en pobreza se parece más al que acaba de salir de ella que al que nunca ha sido pobre. El modelo multiclase sin ingreso, evaluado en 2013→2016, separa “entra” de “nunca pobre” con un AUC de 0.73 a 0.75 según el algoritmo, pero apenas separa “entra” de “sale” (0.53 a 0.56, apenas por encima del azar); los intervalos de confianza de los dos pares no se superponen en ningún algoritmo (Tabla 21, Apéndice A.12). La Figura 2 muestra la misma cercanía variable por variable: en las diez variables del núcleo con dirección estable o moderada, el hogar que entra queda más cerca del que sale que del que nunca fue pobre en ambas ventanas, con una sola excepción (el último grado aprobado por el jefe en 2013→2016). Este resultado se establece bajo pobreza monetaria. “Entra”

y “sale” son dos lados de una misma frontera, no dos tipos de hogar. Es la población que López-Calva y Ortiz-Juarez (2014) identifican en Chile, México y Perú: hogares que superaron la línea de pobreza sin alcanzar seguridad económica y que siguen expuestos a volver a caer; y es coherente con la pobreza transitoria de Jalan y Ravallion (2000), en la que hogares no pobres en tiempos normales pueden caer de repente en la pobreza. Parte de esa cercanía puede reflejar también error de medición del ingreso cerca de la línea, al que las transiciones son sensibles (Anexo A.2). El mismo modelo aporta dos matices. El hogar que entra se distingue de “nunca pobre” con más dificultad que el que sale (AUC de 0.73 a 0.75, frente a 0.81 a 0.83), consistente con que parte de una situación algo mejor. Y con la información de la ola base tampoco se distingue bien a quien sale de la pobreza de quien permanece en ella (0.60 a 0.63): ni la entrada ni la salida se anticipan bien con la información de la ola base. En el contexto de una potencial política pública de vulnerabilidad, esto implica que los hogares que acaban de salir de la pobreza son los siguientes candidatos a caer en ella: retirarlos de los programas en cuanto superan la línea podría devolverlos a la pobreza. Y como la salida tampoco se anticipa con la información de la ola base, las reglas de graduación basadas en características observadas serían menos confiables que un seguimiento periódico de la condición del hogar; una salida gradual, o mantenerlos en seguimiento, sería más coherente con este resultado.




Figura 2: Promedio de cada variable en los hogares que entran en pobreza y en los que salen de ella, expresado en relación con los promedios de los dos grupos extremos: 0 corresponde al promedio de los hogares “siempre pobres” y 1 al de los “nunca pobres” (por ejemplo, 0.5 indica un promedio a medio camino entre ambos). Se muestran las diez variables del núcleo SHAP con dirección estable o moderada. Grupos de López-Calva y Ortiz-Juarez (2014), pobreza monetaria, transiciones 2010→2013 ( $n = 8,218$ ) y 2013→2016 ( $n = 6,911$ ). Fuente: cálculos propios.

**Cuarto**, entre los hogares que caen, quedan atrapados los que cayeron con menos recursos acumulados. La tercera ola permite distinguir dos trayectorias: pobres transitorios (355 hogares, 58 %), que vuelven a salir antes de 2016, y persistentes (255 hogares, 42 %), que siguen pobres en 2016 (Tabla 5). En las variables del núcleo SHAP, los persistentes tenían en 2010 menos activos financieros (0.25 frente a 0.63 en promedio), menor índice de riqueza, estrato y nivel educativo del hogar y del jefe, y más personas por cuarto: son las mismas variables que, con dirección estable, protegen frente a la caída (Segundo hallazgo). También cotizaban menos a pensión (11.6 % frente a 22.8 % de los integrantes del hogar) y tenían menos bienes durables, dos variables del núcleo cuyo signo no es estable. Otras diferencias grandes, como el estado civil del jefe o los desplazados en la comunidad, corresponden a variables sin dirección estable en SHAP y se reportan solo como asociaciones. Lo que protege de caer, el patrimonio acumulado, es también lo que distingue a quienes logran salir. El resultado es coherente con Dercon (2002), para quien el ahorro y los activos funcionan como autoseguro de los hogares frente a los choques, y con la evidencia de trampas de pobreza en Colombia (Castañeda Castrillón, 2012). Estas variables podrían orientar la duración del apoyo: una vez un hogar cae, la falta de activos financieros y de cotización señalaría a quienes necesitan un apoyo más largo, lo que complementa la focalización en dos etapas (Sección 6.2).

Tabla 5: Hogares que entran en pobreza en 2010→2013 según su trayectoria a 2016: transitorios ( $n = 355$ , vuelven a salir) frente a persistentes ( $n = 255$ , siguen pobres), en las variables del núcleo SHAP.

| Variable (ola 2010)                                                                  | Siempre | Sale  | Transitorio | Persistente | Nunca | Dif. estand. |
|--------------------------------------------------------------------------------------|---------|-------|-------------|-------------|-------|--------------|
| N.º de activos financieros                                                           | 0.10    | 0.42  | 0.63        | 0.25        | 0.86  | -0.44        |
| N.º de desplazados en la comunidad <sup>‡</sup>                                      | 187.6   | 125.1 | 82.2        | 173.4       | 144.3 | +0.41        |
| Material de piso del hogar: alfombra, mármol, parqué, madera pulida (%) <sup>‡</sup> | 1.8     | 5.1   | 9.7         | 0.8         | 9.1   | -0.41        |
| Cotización a pensión (hogar) (%) <sup>‡</sup>                                        | 4.5     | 15.8  | 22.8        | 11.6        | 38.4  | -0.38        |
| % de niños con padre vivo (%) <sup>‡</sup>                                           | 60.4    | 62.0  | 66.9        | 50.6        | 63.5  | -0.35        |
| N.º de bienes durables <sup>‡</sup>                                                  | 4.58    | 6.00  | 6.84        | 5.50        | 9.10  | -0.34        |
| Estado civil del jefe: separado(a) o divorciado(a) (%) <sup>‡</sup>                  | 11.2    | 12.9  | 10.4        | 22.9        | 15.0  | +0.34        |
| Estrato (verificado)                                                                 | 1.59    | 2.06  | 2.15        | 1.89        | 2.63  | -0.34        |
| Estado civil del jefe: casado(a) (%) <sup>‡</sup>                                    | 27.7    | 33.7  | 37.5        | 22.9        | 38.2  | -0.32        |
| Máx. nivel educativo del hogar                                                       | 2.28    | 2.79  | 2.89        | 2.57        | 4.22  | -0.27        |
| Personas por cuarto                                                                  | 2.13    | 1.65  | 1.40        | 1.62        | 1.11  | +0.24        |
| Nivel educativo del jefe (ordinal)                                                   | 2.02    | 2.54  | 2.65        | 2.36        | 3.72  | -0.24        |
| Índice de riqueza (PCA)                                                              | -0.83   | -0.02 | 0.48        | -0.20       | 1.06  | -0.23        |
| Material de piso del hogar: cemento, gravilla (%) <sup>‡</sup>                       | 52.7    | 47.8  | 43.9        | 54.0        | 25.3  | +0.20        |

*Nota:* promedios ponderados por el factor de expansión longitudinal, pobreza monetaria. Se muestran los 14 de 31 indicadores del núcleo SHAP (las variables categóricas, un indicador por nivel) cuya diferencia estandarizada entre persistentes y transitorios es de al menos 0.20 en valor absoluto; el signo negativo indica un valor menor en los persistentes. <sup>‡</sup>: variable sin dirección estable o moderada en SHAP (o categórica, sin dirección medida), que se lee solo como asociación. De los 723 hogares que entran en pobreza entre 2010 y 2013, 610 tienen dato de 2016. Fuente: cálculos propios.

En conjunto, el hogar vulnerable es un hogar no pobre con poca riqueza y capital educativo, hacinado y con alta carga de dependencia, que se parece más a quien acaba de salir de la pobreza que a quien nunca la vivió. El núcleo y su dirección se sostienen entre algoritmos, definiciones de pobreza y ventanas; la cercanía con quienes salen, bajo pobreza monetaria.

### 5.3. Contribución marginal de las variables geoespaciales

Esta sección evalúa si la iluminación nocturna DMSP-OLS, la única fuente geoespacial con datos reales en la ola de entrenamiento y en la de prueba (Sección 3.1), mejora la identificación de los hogares vulnerables cuando se agrega a la encuesta. Primero se describe cómo se ubican los grupos de la matriz de transición en esta fuente y se evalúa su aporte bajo pobreza monetaria; luego se repite el ejercicio bajo pobreza multidimensional (IPM) y se examina si el efecto promedio esconde diferencias entre subgrupos.

#### 5.3.1. Perfil geoespacial y aporte bajo pobreza monetaria

Frente a las variables geoespaciales se encontraron cuatro hallazgos. **Primero**, la luz nocturna ordena a los hogares según su trayectoria de pobreza y reproduce lo que muestra la encuesta. En 2010→2013 separa de forma monótona los cuatro grupos, en media y en mediana, bajo pobreza monetaria e IPM: de “siempre pobre” a “nunca pobre”, el valor de iluminación nocturna sube en cada paso (Figura 3). También reproduce el Tercer hallazgo de la Sección 5.2: el hogar que entra en pobreza queda más cerca del que sale que del que nunca fue pobre. Bajo IPM, su mediana (10.7) está a 2.9 puntos de “sale” y a 38.4 de “nunca pobre”; bajo pobreza monetaria el patrón es débil en 2010→2013, con “entra” casi a medio camino, pero se recupera en 2013→2016, donde queda a 8.9 puntos de “sale” y a 38.3 de “nunca pobre”. Por región, la pobreza persistente se concentra en las microrregiones rurales andinas, con 64–66 % de hogares siempre pobres y luz nocturna muy baja, mientras Bogotá concentra los nunca pobres (70 %) con el valor máximo de luz (Figura 4).<sup>7</sup> Que una fuente completamente independiente de la encuesta, medida desde el espacio, reproduzca el gradiente y la cercanía entre “entra” y “sale” indica que ese patrón no depende de cómo se construyó el cuestionario. Para la política, esto hace de la luz nocturna un indicador gratuito y de cobertura universal del gradiente socioeconómico, útil para priorizar territorios donde no hay encuesta (Hofer et al., 2025), aunque no para seleccionar hogares dentro de ellos, como muestra el siguiente hallazgo.

---

<sup>7</sup>La muestra de ELCA es urbana en unas regiones y rural en otras, y no incluye el Chocó rural ni La Guajira (Sección 6.3). ALOS PALSAR sigue el mismo gradiente que DMSP-OLS y el NDVI de Landsat lo invierte, por ruralidad, pero ambas fuentes solo tienen datos en 2010 y no se pueden poner a prueba en 2013→2016.




Figura 3: Iluminación nocturna (DMSP-OLS) por grupo de transición, media y mediana, pobreza monetaria e IPM (2010→2013).




Figura 4: Grupo de transición dominante por región e iluminación nocturna (DMSP), pobreza monetaria, 2010→2013.

**Segundo**, bajo pobreza monetaria, agregar la luz nocturna a la encuesta no mejora la identificación de los hogares vulnerables. Al reentrenar los diez modelos con las 23 variables de DMSP-OLS, el AUC-ROC cambia entre  $-0.006$  y  $+0.006$  en las diez combinaciones de algoritmo y especificación, y la precisión en el decil de mayor riesgo cae o se mantiene en todas; el intervalo de confianza del cambio incluye el cero en las diez (Tablas 10 y 11, Apéndice A.5). No se debe a sobreajuste: la diferencia entre el AUC de validación cruzada y el de prueba prácticamente no cambia al agregar DMSP-OLS (a lo sumo 0.002 en ocho de las diez combinaciones y 0.008 en LightGBM con el Modelo A). El resultado se repite al agregar las tres fuentes geoespaciales juntas (Tabla 14, Apéndice A.7).<sup>8</sup> La razón es que la luz nocturna mide lo mismo que la encuesta ya captura. Su correlación con caer en pobreza ( $r = -0.214$ ) es tan fuerte como la del estrato, pero cae a  $r \approx 0.01$  al descontar cuatro variables del núcleo: servicios públicos, estrato, bienes durables y personas por cuarto (Figura 5). Tampoco ayuda a resolver el problema central de la Sección 5.1.2: en el modelo multiclase, agregar DMSP-OLS cambia el AUC de cada par de grupos en menos de 0.025, sin un patrón consistente entre algoritmos, y en la separación de “entra” frente a “sale” ningún cambio es distinguible de cero (entre  $-0.006$  y  $+0.011$ ; Tabla 21, Apéndice A.12). La luz nocturna distingue, como la encuesta, a los hogares precarios de los que no lo son, pero no a cuáles de los precarios caerán. Un sistema que ya cuenta con una encuesta vigente no ganaría precisión al integrarla. Es coherente con la evidencia previa: en Jean et al. (2016) la luz nocturna sola predice peor que un modelo que la combina con imágenes diurnas y datos de encuesta, y Hall et al. (2023) encuentran que los datos geoespaciales predicen peor variables de flujo, como el ingreso o el consumo, que los activos físicos. Hay, sin embargo, una diferencia práctica: la luz nocturna es mucho más estable en el tiempo que esas variables de la encuesta (correlación entre 2010 y 2013 de 0.958, frente a 0.600 de los bienes durables). Esa estabilidad es la que permite, como proponen Hofer et al. (2025), usar la luz nocturna para estimar entre encuestas.

---

<sup>8</sup>Se probó además si DMSP-OLS aporta más al eliminar de la encuesta las dos preguntas que la vuelven redundante (solo la regresión logística mejora de forma consistente) y si aporta más cerca de la línea de pobreza (sin evidencia en los tres terciles de cercanía).




Figura 5: Correlación de la luz nocturna (DMSP-OLS) con caer en pobreza monetaria, antes y después de descontar cuatro variables del núcleo: servicios públicos, estrato, bienes durables y personas por cuarto. La correlación inicial (gris oscuro) es comparable a la de esas cuatro variables (gris claro), pero cae casi a cero al descontarlas (rojo). La barra roja es una correlación parcial: se residualizan tanto la luz nocturna como el resultado frente a las cuatro variables de referencia, y se correlacionan los residuos (teorema de Frisch–Waugh–Lovell).  $n = 2,150$ , restringido por datos faltantes de estrato. Fuente: cálculos propios.

### 5.3.2. Aporte bajo pobreza multidimensional y por subgrupos

**Tercero**, bajo IPM la luz nocturna sí mejora la predicción, pero poco y solo en dos algoritmos. XGBoost mejora en ambas especificaciones (+0.013 a +0.020 en AUC-ROC,  $p \leq 0.006$ ) y LightGBM en el Modelo B (+0.017,  $p < 0.001$ ); las otras siete combinaciones no son distinguibles de cero (Tabla 6; detalle de la significancia en la Tabla 11 del Apéndice A.5). El aporte es real, pero demasiado pequeño para cambiar por sí solo una decisión de focalización. Una explicación posible de que aparezca bajo IPM y no bajo pobreza monetaria es que el IPM incluye privaciones de vivienda y de servicios públicos, más ligadas a la infraestructura que refleja la luz nocturna que el ingreso. Si un programa focaliza privaciones multidimensionales, la luz nocturna añade algo de información, aunque poca.

Tabla 6: Contribución marginal de DMSP-OLS bajo pobreza multidimensional (IPM) (entrenamiento 2010→2013, prueba 2013→2016).

| Algoritmo              | Esp. | AUC base | AUC +DMSP | $\Delta$ AUC  | $\Delta$ Prec.-top10 |
|------------------------|------|----------|-----------|---------------|----------------------|
| XGBoost                | A    | 0.725    | 0.736     | <b>+0.013</b> | +0.022               |
| Random Forest          | A    | 0.729    | 0.729     | +0.001        | +0.004               |
| LightGBM               | A    | 0.741    | 0.745     | +0.004        | +0.005               |
| HistGradientBoosting   | A    | 0.740    | 0.738     | -0.002        | +0.002               |
| Logística regularizada | A    | 0.730    | 0.730     | -0.000        | +0.009               |
| XGBoost                | B    | 0.728    | 0.746     | <b>+0.020</b> | +0.016               |
| Random Forest          | B    | 0.735    | 0.732     | -0.004        | +0.015               |
| LightGBM               | B    | 0.730    | 0.747     | <b>+0.017</b> | +0.021               |
| HistGradientBoosting   | B    | 0.739    | 0.740     | +0.002        | -0.007               |
| Logística regularizada | B    | 0.730    | 0.730     | -0.000        | +0.011               |

*Nota:* AUC: promedio de 5 semillas.  $\Delta$ AUC: *bootstrap* pareado sobre el conjunto de prueba (una semilla); en **negrita**, diferencias cuyo IC95 % no cruza cero. Intervalos, valores  $p$  y corrección por conglomerados de comunidad en la Tabla 11 del Anexo A.5. Fuente: cálculos propios.

**Cuarto**, en LightGBM, el algoritmo con el patrón más claro, ese aporte se concentra justo donde la encuesta es más débil. Bajo pobreza monetaria no hay diferencias entre subgrupos: solo 1 de 70 combinaciones de algoritmo, grupo y especificación cambia el AUC-ROC en 0.02 o más (Tabla 12, Apéndice A.6). Bajo IPM, LightGBM sin ingreso concentra su ganancia en zona rural (+0.032 frente a +0.008 en la urbana), en estrato 1 (+0.024 frente a -0.003 en estrato 3) y en el tercil de hogares con menos servicios públicos y bienes durables (+0.030 frente a +0.009 en el tercil alto) (Tabla 13, Apéndice A.6). En zona rural y en ese tercil, agregar la luz nocturna marca como en riesgo a 6 a 7 puntos porcentuales más de los hogares que efectivamente caen, sin reducir la precisión. XGBoost, en cambio, gana de forma más pareja entre grupos, y Random Forest no gana en casi ningún subgrupo. Son estimaciones exploratorias, con celdas de unos pocos cientos de hogares y sin intervalos propios por subgrupo. Este patrón contrasta con la evidencia de que la luz nocturna rinde peor en regiones pobres y rurales, donde varía poco (Hall et al., 2023). La diferencia puede estar en el uso: allí la luz nocturna es el único predictor del nivel de bienestar, mientras que aquí complementa una encuesta, de modo que incluso poca variación puede aportar donde las preguntas de la encuesta distinguen menos entre hogares; es una hipótesis que queda por verificar. Si el patrón se confirma, el complemento satelital tendría más sentido focalizado geográficamente, en las zonas rurales y de estratos bajos donde la encuesta es más débil, que como insumo nacional, en línea con Newhouse et al. (2025), para quienes la imagen satelital mejora las estimaciones de pobreza justamente en las áreas donde la encuesta tiene pocas observaciones.

En suma, la luz nocturna describe bien la geografía de la pobreza, pero no reemplaza a la encuesta.

## 6. Conclusiones

### 6.1. Síntesis de hallazgos

Este documento evalúa si las fuentes geoespaciales públicas mejoran la predicción de la caída en pobreza de hogares colombianos no pobres, frente a modelos basados solo en la ELCA. Solo una de las cuatro fuentes consideradas, la iluminación nocturna DMSP-OLS, tiene datos en la ola de entrenamiento y en la de prueba, de modo que es la base de la evaluación principal. El ejercicio estima modelos con cinco algoritmos de aprendizaje supervisado, con y sin ingreso del hogar, bajo pobreza monetaria y multidimensional, con entrenamiento en 2010→2013 y prueba en 2013→2016.

Cinco hallazgos se destacan. **Primero**, la pobreza monetaria cae de 60.7 % a 42.4 % entre 2010 y 2016, pero con mucho movimiento en ambas direcciones: 23.4 % y 19.9 % de los hogares no pobres caen en pobreza en cada ventana, mientras casi el doble de hogares sale de ella (Sección 3.3). **Segundo**, la capacidad de identificar a los vulnerables tiene un techo (AUC-ROC de 0.73 a 0.77) que no depende del algoritmo ni del ingreso; con un umbral que capte casi a todos, un programa atendería entre 2.4 y 3.1 hogares que no caen por cada uno que sí (Sección 5.1). **Tercero**, con la información de la ola base es difícil separar a quien cae de quien no: los hogares marcados que no caen también son precarios, quienes caen reportan más choques posteriores, y la información de la ola base distingue a “entra” de “sale” apenas por encima del azar (Secciones 5.1.2 y 5.2). **Cuarto**, el hogar vulnerable se reconoce por lo que ha acumulado (riqueza, educación, activos y vivienda) y se parece más al que acaba de salir de la pobreza que al que nunca fue pobre; entre los que caen, quedan atrapados los que tenían menos activos financieros, riqueza y cotización a pensión (Sección 5.2). **Quinto**, y en respuesta a la pregunta de investigación, las fuentes geoespaciales públicas describen bien la geografía de la pobreza, pero no mejoran la identificación de los hogares vulnerables cuando hay una encuesta vigente. La iluminación nocturna es redundante con unas pocas preguntas de la encuesta bajo pobreza monetaria y aporta poco bajo IPM, sobre todo en zonas rurales; su ventaja es su estabilidad en el tiempo. ALOS PALSAR, Landsat 5 TM y Street View no tienen cobertura suficiente para una conclusión firme (Sección 5.3).

## 6.2. Implicaciones para la política pública

Los resultados sugieren cinco implicaciones para sistemas de focalización como el SISBEN IV y el Registro Social de Hogares, que hoy clasifican a los hogares por su estándar de vida y su capacidad presunta de generar ingresos; los modelos de este artículo podrían complementarlos con una medida del riesgo de entrada en pobreza de los hogares hoy no pobres. Primero, la focalización puede apoyarse en variables no monetarias, que capturan casi toda la señal; cuando la información del hogar está desactualizada o incompleta, un conjunto reducido centrado en el núcleo podría servir como alternativa. Segundo, el umbral debe depender del costo del instrumento: amplio para intervenciones preventivas de bajo costo, donde los incluidos por error también son precarios, y concentrado en el decil de mayor riesgo para transferencias costosas. Tercero, si la asociación con los choques se confirma, la focalización podría hacerse en dos etapas, en las que el modelo define quién está en riesgo y un choque activa el apoyo, verificando el choque y no el perfil y actualizando la lista con frecuencia. Esto respondería a una limitación de la protección social reactiva a choques en la región, que ha dependido sobre todo de ampliar los beneficios de quienes ya estaban en los programas y ha dejado por fuera a muchos hogares afectados (Costella et al., 2023). Cuarto, como la salida de la pobreza tampoco se anticipa con la información de la ola base, la graduación debería ser gradual y con seguimiento, y la falta de activos financieros y de cotización podría orientar la duración del apoyo. Quinto, la iluminación nocturna no se justifica como covariable de rutina con una encuesta vigente, pero sí para priorizar territorios y como respaldo entre rondas, sobre todo en zonas rurales. Todas son asociaciones, no efectos causales, y requieren evaluación antes de convertirse en intervenciones.

## 6.3. Limitaciones y agenda de investigación

Los principales límites son cuatro. En los determinantes, la importancia SHAP describe cómo el modelo usa cada variable, no un efecto causal ni un aporte fuera de muestra; reparte el crédito entre variables correlacionadas, y el núcleo se eligió con información de ambas ventanas, incluida la de prueba. En los errores del modelo, los choques se reportan en 2016 y su relación con la caída es descriptiva. En DMSP-OLS, la heterogeneidad por subgrupos es exploratoria y la corrección por conglomerados de comunidad no se estimó para todos los algoritmos. En la muestra, la separación entre pobres transitorios y persistentes se apoya en 610 de 723 hogares, y ELCA no cubre el Chocó rural ni La Guajira. La cercanía entre quienes entran y quienes salen de la pobreza se establece solo bajo pobreza monetaria, porque el modelo multiclase no se estimó bajo IPM.

Los resultados bajo IPM tienen además un límite de medición: el indicador de barreras

de acceso a salud se mide en 2010 con un proxy distinto al de 2013 y 2016, y el 79% de los hogares que salen de la pobreza IPM entre 2010 y 2013 lo hacen perdiendo justamente esa privación. Armonizarlo con la pregunta directa tampoco resuelve el problema, por diferencias en quiénes la responden. Por eso, los resultados IPM que dependen de 2010→2013 deben leerse como condicionales al proxy, y la ventana 2013→2016 es la comparación más limpia.

La agenda de investigación tiene seis frentes. Primero, confirmar la heterogeneidad del aporte de DMSP-OLS bajo IPM con *bootstrap* por subgrupo y con la corrección por conglomerados para todos los algoritmos. Segundo, evaluar un modelo restringido al núcleo, seleccionado solo con 2010→2013 y probado en 2013→2016. Tercero, comparar por región, lo que no fue posible porque, con 3,089 hogares no pobres en entrenamiento, las celdas resultan demasiado pequeñas. Cuarto, evaluar si fuentes de alta frecuencia, como la precipitación o los índices de vegetación, anticipan los choques compartidos, dado que la luz nocturna es muy estable y los choques que más distinguen a quien cae son familiares. Quinto, contrastar si las variables de acumulación indican quién es vulnerable y las de actividad económica reciente cuánto dura esa condición. Sexto, evaluar ALOS PALSAR, Landsat 5 TM y Google Street View cuando exista cobertura temporal suficiente: las fotos de Street View predicen bien la luz nocturna de su zona y su señal se asocia con caer en pobreza, pero no hay fotos anteriores a 2012, se concentran en zonas urbanas y son poco estables entre olas (Anexo A.8).

## Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Angulo Salazar, R. C., Díaz Cuervo, Y., & Pardo Pinzón, R. (2011). *Índice de Pobreza Multidimensional para Colombia (IPM-Colombia) 1997-2010* (Archivos de Economía N.º 382). Departamento Nacional de Planeación, Dirección de Estudios Económicos. Bogotá.
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (CPRC Working Paper N.º 170). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Burger, J., & van der Laan, J. (2021). Predicting Transitions into and out of Poverty Using Machine Learning. *Proceedings of Statistics Canada Symposium 2021: Adopting Data Science in Official Statistics to Meet Society's Emerging Needs*.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). *Assessing Household Vulnerability to Poverty from Cross-Sectional Data: A Methodology and Estimates from Indonesia* (Discussion Paper N.º 0102-52). Department of Economics, Columbia University.
- Christiaensen, L. J., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Cornia, G. A., & Stewart, F. (1993). Two Errors of Targeting. *Journal of International Development*, 5(5), 459-496. <https://doi.org/10.1002/jid.3380050503>

- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Davis, J., & Goadrich, M. (2006). The Relationship Between Precision-Recall and ROC Curves. *Proceedings of the 23rd International Conference on Machine Learning*, 233-240. <https://doi.org/10.1145/1143844.1143874>
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/00220380008422653>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2026). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of Sustainable Development & World Ecology*, 33(1), 68-80. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature. En J. Silber & G. Wan (Eds.), *The Asian 'Poverty Miracle': Impressive Accomplishments or Incomplete Achievements?* (pp. 53-83). Edward Elgar.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*, 35, 1753-1768. <https://doi.org/10.1002/jid.3751>
- Hernández, J. E., & Zuluaga, B. (2022). Vulnerability to Multidimensional Poverty: An Application to Colombian Households. *Social Indicators Research*, 164, 345-371. <https://doi.org/10.1007/s11205-022-02961-2>
- Hofer, M., Sako, T., Martinez, A., Jr., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*, 39(1), 98-129. <https://doi.org/10.1111/asej.12349>
- Hohberg, M., Landau, K., Kneib, T., Klasen, S., & Zucchini, W. (2018). Vulnerability to Poverty Revisited: Flexible Modeling and Better Predictive Performance. *The*

- Journal of Economic Inequality*, 16(3), 439-454. <https://doi.org/10.1007/s10888-017-9374-6>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Studies*, 36(6), 82-99. <https://doi.org/10.1080/00220380008422655>
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juarez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juarez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón-Santa, G., Escobar-Grisales, D., López-Pabón, F. O., Pérez-Toro, P. A., & Orozco-Arroyave, J. R. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>
- Newhouse, D., Ramakrishnan, A., Swartz, T., Merfeld, J., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Pabón, L., & Briceño, G. D. (2023). El Registro Social de Hogares: un nuevo sistema de información para la política social. *Planeación & Desarrollo*. <https://colaboracion.dnp.gov.co/CDT/PublishingImages/Planeacion-y-desarrollo/2023/agosto/pdf/nota-registro-social.pdf>
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>

Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

## A. Tablas y figuras complementarias

### A.1. Correlación entre covariables y riesgo de multicolinealidad

Complemento de la Sección 4.3: análisis de correlación de Pearson entre las 159 variables numéricas del dataset consolidado –incluidas las 4 geoespaciales–, motivado por el riesgo de multicolinealidad para el modelo de regresión logística regularizada.

Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 17), solo se reportan como “altas” los pares con  $|r| > 0.7$  calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican los 35 pares de la Figura 6.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan sobre 0.97 con su propia brecha a la LP; `lp` y `li` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal correlacionan  $-0.93$  (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización  $\ell_1/\ell_2$  mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmsp_stable_lights` correlaciona 0.87 con la línea de pobreza `lp` y 0.81 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`). Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.1 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la Sección 5.3.1.



Figura 6: Pares de variables con correlación de Pearson  $|r| > 0.7$  (calculados sobre al menos 500 observaciones conjuntas no-nulas), ordenados por magnitud de la correlación. La mayoría corresponde a redundancias esperables (medidas nominal vs. real de un mismo concepto, o un indicador individual y su agregado a nivel de hogar); la más relevante para este trabajo es la de `dmsp_stable_lights` con `lp`, `li` y `n_servicios_publicos_hogar`, que se retoma en la Sección 5.3.1. Fuente: cálculos propios.

## A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria

Complemento de la Sección 3.3: incidencia agregada de pobreza monetaria por ingreso y por gasto, su descomposición Foster-Greer-Thorbecke (FGT), y cinco ejercicios diseñados para evaluar qué tan sensible es la variable de transición a la pobreza –la variable de interés de este artículo– a decisiones de construcción del ingreso, a la representatividad muestral y al error de medición cerca del umbral de pobreza.

### A.2.1. Incidencia y descomposición FGT

La Figura 7 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más *baja* que la de ingreso en los tres puntos del panel (47.6 %, 40.9 % y 33.4 %): la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto. Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no depende de la medida de bienestar elegida.




Figura 7: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 8 descompone la pobreza por ingreso en sus tres componentes FGT: incidencia

(P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 8: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

### A.2.2. Ejercicios de robustez

Se implementaron cinco ejercicios de robustez sobre las cifras de transición de la Sección 3.3: ponderación muestral, dos reclasificaciones del ingreso, sensibilidad al umbral de pobreza, y atrición del panel.

**Ponderación muestral.** Ninguno de los resultados de la Sección 3.3 usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (`fexhog`, `fexhog_2013`, ambos transversales, y `fexhog_2010`, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % → 60.4 % en 2010, 52.4 % → 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % → 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 %

a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

**Ingreso sin componentes excepcionales.** Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorratedos como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de este artículo. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

**Ingreso sin ayudas en dinero.** La pregunta de ayudas en dinero (*ing\_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing\_ayudas* de las tres olas y se repitió la matriz 2010→2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o ausencia mueve la clasificación de más hogares.

**Sensibilidad a la banda alrededor de la línea de pobreza.** Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando  $LP \times 0.9$  y  $LP \times 1.1$  (una banda de  $\pm 10\%$ ) y se

repite las matrices de transición (Figura 9). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % (LP−10 %) y 49.1 % (LP+10 %) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 9: Sensibilidad de la distribución de categorías de transición a una banda  $\pm 10\%$  alrededor de la línea de pobreza oficial.

La Figura 10 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 10: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

**Atrición del panel.** Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 11). La atrición total es de 11.4% en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). Esa cifra agregada sí se desagregó por perfil de hogar: la atrición **no es aleatoria**, se concentra sistemáticamente en hogares urbanos y de estrato más alto. Por zona, la tasa de pérdida es 2.8 veces mayor en zona urbana que en zona rural en 2010–2013 (16.2% vs. 5.8%) y 1.7 veces mayor en 2013–2016 (14.1% vs. 8.2%); por estrato socioeconómico, la pérdida crece monótonamente de 8.9% en estrato 1 a 26.0% en estrato 4 en 2010–2013. Por región, Bogotá tiene la mayor pérdida (24.9%) y Centro-Oriente la menor (3.1%). El patrón es consistente con que los hogares urbanos y de mayor estrato son más móviles (cambian de vivienda con más frecuencia), lo que dificulta su relocalización entre olas del panel –no con una atrición concentrada en los hogares más pobres, que de hecho es la más baja de las cuatro categorías de estrato–. No se investigó si, controlando por zona/estrato/región, la atrición está además asociada al estado de pobreza mismo del hogar (una limitación que se retoma en la Sección 6.3).




Figura 11: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

### A.3. Soporte del núcleo SHAP

Complemento de la Sección 5.2: concentración de la señal SHAP y sensibilidad del núcleo y de su dirección a los umbrales elegidos.

Tabla 7: Concentración de la señal predictiva (SHAP), variables originales agregadas (dummies *one-hot* e indicadores de faltante sumados a su variable de origen antes de calcular la masa acumulada).

| Algoritmo              | Espec. | Variables (total) | % SHAP en top-10 | Variables para 80 % del SHAP |
|------------------------|--------|-------------------|------------------|------------------------------|
| HistGradientBoosting   | A      | 169               | 69.3 %           | 15                           |
| XGBoost                | A      | 169               | 58.7 %           | 23                           |
| Logística regularizada | A      | 169               | 43.9 %           | 28                           |
| Random Forest          | A      | 169               | 59.8 %           | 32                           |
| LightGBM               | A      | 169               | 44.4 %           | 37                           |
| LightGBM               | B      | 165               | 71.6 %           | 14                           |
| HistGradientBoosting   | B      | 165               | 63.9 %           | 18                           |
| XGBoost                | B      | 165               | 54.7 %           | 26                           |
| Logística regularizada | B      | 165               | 45.8 %           | 28                           |
| Random Forest          | B      | 165               | 54.9 %           | 34                           |

Tabla 8: Sensibilidad del núcleo SHAP y de su dirección a los umbrales elegidos (Sección 5.2). “(base)”: criterio usado en el texto. El núcleo de 22 variables se conserva por completo con criterios más laxos; con los más estrictos queda un subconjunto.

| <b>A. Núcleo: masa SHAP acumulada y mínimo de combinaciones (de 10)</b>      |            |                      |                    |                                     |
|------------------------------------------------------------------------------|------------|----------------------|--------------------|-------------------------------------|
| Masa                                                                         | Mín. comb. | Núcleo               | Conserva de las 22 | Universales en las 4 fuentes (de 7) |
| 70 %                                                                         | 4          | 19                   | 17                 | 6                                   |
| 70 %                                                                         | 5          | 13                   | 13                 | 4                                   |
| 70 %                                                                         | 6          | 11                   | 11                 | 3                                   |
| 80 %                                                                         | 4          | 30                   | 22                 | 7                                   |
| 80 %                                                                         | 5          | 22 (base)            | 22                 | 7                                   |
| 80 %                                                                         | 6          | 20                   | 20                 | 5                                   |
| 90 %                                                                         | 4          | 50                   | 22                 | 7                                   |
| 90 %                                                                         | 5          | 35                   | 22                 | 7                                   |
| 90 %                                                                         | 6          | 31                   | 22                 | 7                                   |
| <b>B. Dirección: <math> \rho </math> mínimo y proporción mínima de signo</b> |            |                      |                    |                                     |
| $ \rho $ mín.                                                                | Prop. mín. | Consistentes (de 20) |                    |                                     |
| 0.05                                                                         | 0.70       | 12                   |                    |                                     |
| 0.05                                                                         | 0.80       | 10                   |                    |                                     |
| 0.05                                                                         | 0.90       | 7                    |                    |                                     |
| 0.10                                                                         | 0.70       | 12                   |                    |                                     |
| 0.10                                                                         | 0.80       | 10 (base)            |                    |                                     |
| 0.10                                                                         | 0.90       | 7                    |                    |                                     |
| 0.15                                                                         | 0.70       | 12                   |                    |                                     |
| 0.15                                                                         | 0.80       | 10                   |                    |                                     |
| 0.15                                                                         | 0.90       | 6                    |                    |                                     |
| 0.20                                                                         | 0.70       | 12                   |                    |                                     |
| 0.20                                                                         | 0.80       | 10                   |                    |                                     |
| 0.20                                                                         | 0.90       | 6                    |                    |                                     |

#### A.4. Desempeño de los modelos bajo pobreza multidimensional (IPM)

Complemento de la Sección 5.1: mismo benchmark de cinco algoritmos y misma metodología robusta (holdout temporal, CV\_FOLDS=10, N\_ITER\_BUSQUEDA=30, 5 semillas), con pobreza multidimensional (IPM) como variable de resultado en vez de pobreza monetaria – covariables idénticas.<sup>9</sup>

<sup>9</sup>Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Random Forest (Aipm y Bipm), donde fue *balanced* (reponderación de clases).

Tabla 9: Desempeño de los cinco algoritmos bajo pobreza multidimensional (IPM), holdout temporal (train 2010→2013, test 2013→2016). Misma metodología robusta que la Tabla 2 (monetaria), covariables idénticas – único factor que cambia es la variable de resultado. Prec.-top10: precisión entre el 10 % de hogares de mayor riesgo.

| Algoritmo              | Espec. | Umbral | AUC-ROC | Recall | Precision | Prec.-top10 | F1    |
|------------------------|--------|--------|---------|--------|-----------|-------------|-------|
| LightGBM               | Aipm   | 0.11   | 0.741   | 0.670  | 0.184     | 0.263       | 0.288 |
| HistGradientBoosting   | Aipm   | 0.11   | 0.740   | 0.603  | 0.197     | 0.271       | 0.295 |
| Logística regularizada | Aipm   | 0.10   | 0.730   | 0.726  | 0.166     | 0.258       | 0.269 |
| Random Forest          | Aipm   | 0.31   | 0.729   | 0.645  | 0.183     | 0.253       | 0.285 |
| XGBoost                | Aipm   | 0.11   | 0.725   | 0.844  | 0.139     | 0.251       | 0.239 |
| HistGradientBoosting   | Bipm   | 0.10   | 0.739   | 0.620  | 0.189     | 0.265       | 0.289 |
| Random Forest          | Bipm   | 0.26   | 0.735   | 0.753  | 0.165     | 0.260       | 0.270 |
| LightGBM               | Bipm   | 0.08   | 0.730   | 0.721  | 0.167     | 0.251       | 0.270 |
| Logística regularizada | Bipm   | 0.11   | 0.730   | 0.716  | 0.167     | 0.255       | 0.270 |
| XGBoost                | Bipm   | 0.09   | 0.728   | 0.901  | 0.130     | 0.258       | 0.228 |

### A.5. Aporte de DMSP-OLS: resultados detallados

Complemento de la Sección 5.3: desempeño de los cinco algoritmos con y sin las variables de DMSP-OLS bajo pobreza monetaria (Tabla 10) y significancia del cambio de AUC-ROC bajo IPM (Tabla 11).

Tabla 10: AUC-ROC y precisión en el decil de mayor riesgo, con y sin DMSP-OLS, pobreza monetaria (entrenamiento 2010→2013, prueba 2013→2016).

| Algoritmo              | Especificación | AUC-ROC | IC95 %         | Precision top-10 % | IC95 %         | Umbral | Recall | Precision | F1    | Brecha CV |
|------------------------|----------------|---------|----------------|--------------------|----------------|--------|--------|-----------|-------|-----------|
| Random Forest          | A              | 0.766   | [0.765, 0.767] | 0.486              | [0.476, 0.495] | 0.138  | 0.926  | 0.277     | 0.426 | +0.000    |
| Random Forest          | A + DMSP-OLS   | 0.763   | [0.762, 0.764] | 0.481              | [0.470, 0.493] | 0.264  | 0.938  | 0.271     | 0.420 | +0.002    |
| XGBoost                | A              | 0.767   | [0.766, 0.769] | 0.505              | [0.496, 0.514] | 0.112  | 0.949  | 0.264     | 0.413 | -0.001    |
| XGBoost                | A + DMSP-OLS   | 0.765   | [0.764, 0.766] | 0.501              | [0.488, 0.515] | 0.118  | 0.937  | 0.272     | 0.421 | +0.000    |
| LightGBM               | A              | 0.758   | [0.758, 0.758] | 0.516              | [0.516, 0.516] | 0.096  | 0.903  | 0.281     | 0.428 | +0.003    |
| LightGBM               | A + DMSP-OLS   | 0.752   | [0.752, 0.752] | 0.497              | [0.497, 0.497] | 0.102  | 0.902  | 0.277     | 0.424 | +0.011    |
| HistGradientBoosting   | A              | 0.763   | [0.763, 0.763] | 0.512              | [0.512, 0.512] | 0.324  | 0.909  | 0.283     | 0.432 | -0.003    |
| HistGradientBoosting   | A + DMSP-OLS   | 0.763   | [0.763, 0.763] | 0.500              | [0.500, 0.500] | 0.312  | 0.912  | 0.281     | 0.429 | -0.002    |
| Logística regularizada | A              | 0.747   | [0.747, 0.747] | 0.506              | [0.506, 0.506] | 0.372  | 0.883  | 0.280     | 0.426 | +0.015    |
| Logística regularizada | A + DMSP-OLS   | 0.746   | [0.746, 0.746] | 0.500              | [0.500, 0.500] | 0.370  | 0.883  | 0.281     | 0.426 | +0.015    |
| Random Forest          | B              | 0.742   | [0.741, 0.744] | 0.508              | [0.497, 0.520] | 0.306  | 0.892  | 0.272     | 0.416 | +0.013    |
| Random Forest          | B + DMSP-OLS   | 0.739   | [0.737, 0.741] | 0.492              | [0.482, 0.502] | 0.266  | 0.925  | 0.255     | 0.399 | +0.015    |
| XGBoost                | B              | 0.742   | [0.742, 0.743] | 0.495              | [0.487, 0.503] | 0.126  | 0.940  | 0.250     | 0.395 | +0.014    |
| XGBoost                | B + DMSP-OLS   | 0.740   | [0.740, 0.741] | 0.495              | [0.491, 0.499] | 0.128  | 0.929  | 0.254     | 0.399 | +0.016    |
| LightGBM               | B              | 0.731   | [0.731, 0.731] | 0.487              | [0.487, 0.487] | 0.148  | 0.909  | 0.259     | 0.403 | +0.024    |
| LightGBM               | B + DMSP-OLS   | 0.737   | [0.737, 0.737] | 0.481              | [0.481, 0.481] | 0.126  | 0.888  | 0.271     | 0.415 | +0.019    |
| HistGradientBoosting   | B              | 0.735   | [0.735, 0.735] | 0.494              | [0.494, 0.494] | 0.142  | 0.879  | 0.275     | 0.418 | +0.017    |
| HistGradientBoosting   | B + DMSP-OLS   | 0.736   | [0.736, 0.736] | 0.487              | [0.487, 0.487] | 0.142  | 0.880  | 0.275     | 0.419 | +0.018    |
| Logística regularizada | B              | 0.739   | [0.739, 0.739] | 0.500              | [0.500, 0.500] | 0.350  | 0.890  | 0.270     | 0.414 | +0.018    |
| Logística regularizada | B + DMSP-OLS   | 0.739   | [0.739, 0.739] | 0.494              | [0.494, 0.494] | 0.350  | 0.888  | 0.273     | 0.417 | +0.018    |

*Nota:* promedio de 5 semillas; IC95 % sobre las semillas. *Recall*, precisión y F1 se miden al umbral ya elegido para cada algoritmo y especificación por validación cruzada maximizando  $F_2$  (Sección 4.5). Brecha CV: AUC de validación cruzada menos AUC en prueba; si agregar DMSP-OLS sobreajustara, se ensancharía frente a la especificación sin DMSP-OLS. Fuente: cálculos propios.

Tabla 11: Significancia del cambio de AUC-ROC al agregar DMSP-OLS, pobreza monetaria y multidimensional (IPM).

| Algoritmo                             | Esp. | $\Delta$ AUC  | IC95 %           | $p$   | $p$ por comunidad |
|---------------------------------------|------|---------------|------------------|-------|-------------------|
| <i>Pobreza monetaria</i>              |      |               |                  |       |                   |
| XGBoost                               | A    | -0.003        | [-0.005, +0.001] | 0.102 | 0.085             |
| Random Forest                         | A    | -0.002        | [-0.006, +0.002] | 0.258 | —                 |
| LightGBM                              | A    | -0.006        | [-0.012, +0.001] | 0.079 | —                 |
| HistGradientBoosting                  | A    | -0.000        | [-0.003, +0.002] | 0.800 | 0.802             |
| Logística regularizada                | A    | -0.001        | [-0.001, +0.000] | 0.138 | 0.163             |
| XGBoost                               | B    | -0.002        | [-0.005, +0.002] | 0.266 | 0.308             |
| Random Forest                         | B    | -0.004        | [-0.008, +0.000] | 0.051 | —                 |
| LightGBM                              | B    | +0.006        | [-0.001, +0.013] | 0.078 | —                 |
| HistGradientBoosting                  | B    | +0.001        | [-0.002, +0.003] | 0.642 | 0.622             |
| Logística regularizada                | B    | -0.001        | [-0.001, +0.000] | 0.138 | 0.154             |
| <i>Pobreza multidimensional (IPM)</i> |      |               |                  |       |                   |
| XGBoost                               | A    | <b>+0.013</b> | [+0.004, +0.022] | 0.006 | 0.004             |
| Random Forest                         | A    | +0.001        | [-0.006, +0.008] | 0.754 | —                 |
| LightGBM                              | A    | +0.004        | [-0.001, +0.008] | 0.091 | —                 |
| HistGradientBoosting                  | A    | -0.002        | [-0.007, +0.004] | 0.541 | 0.548             |
| Logística regularizada                | A    | -0.000        | [-0.001, +0.001] | 0.934 | 0.954             |
| XGBoost                               | B    | <b>+0.020</b> | [+0.010, +0.030] | 0.001 | 0.000             |
| Random Forest                         | B    | -0.004        | [-0.012, +0.005] | 0.429 | —                 |
| LightGBM                              | B    | <b>+0.017</b> | [+0.008, +0.026] | 0.000 | —                 |
| HistGradientBoosting                  | B    | +0.002        | [-0.004, +0.007] | 0.595 | 0.569             |
| Logística regularizada                | B    | -0.000        | [-0.001, +0.001] | 0.978 | 0.926             |

*Nota:* *bootstrap* pareado sobre el conjunto de prueba 2013→2016 (una semilla).  $p$  por comunidad: remuestreo agrupado por comunidad (1,696 comunidades), porque hogares de una misma comunidad comparten en buena medida el mismo píxel de luz nocturna (resolución de  $\sim 1$  km); “—”: corrección no estimada. Fuente: cálculos propios.

## A.6. Heterogeneidad del aporte de DMSP-OLS por subgrupos

Complemento de la Sección 5.3.2: cambio en el AUC-ROC al agregar DMSP-OLS por eje de heterogeneidad, grupo, especificación y algoritmo. Bajo pobreza monetaria el efecto nulo se mantiene parejo en los cuatro ejes explorados (Tabla 12); bajo IPM la ganancia se concentra en algunos subgrupos (Tabla 13).

Tabla 12:  $\Delta$ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza monetaria. En **negrita**:  $|\Delta| \geq 0.02$ . Grupos con  $n < 30$  omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios, `diagnostico_heterogeneidad_dmsp.csv` (`src/05_model/diagnostico_heterogeneidad_dmsp.py`).

| Eje                | Grupo                | Esp. | n     | XGB    | RF     | LGBM          | HGB    | Log.   |
|--------------------|----------------------|------|-------|--------|--------|---------------|--------|--------|
| Zona               | Rural                | A    | 1,170 | -0.004 | -0.008 | -0.009        | -0.003 | -0.003 |
|                    | Rural                | B    | 1,170 | -0.001 | -0.007 | +0.012        | -0.000 | -0.002 |
|                    | Urbano               | A    | 2,021 | -0.003 | +0.001 | -0.006        | +0.001 | -0.000 |
|                    | Urbano               | B    | 2,021 | -0.003 | -0.004 | +0.003        | -0.001 | -0.000 |
| Cercanía a LP      | Q1 (mas cerca de LP) | A    | 798   | -0.003 | -0.006 | +0.000        | -0.002 | -0.000 |
|                    | Q1 (mas cerca de LP) | B    | 798   | +0.002 | -0.008 | +0.004        | +0.001 | -0.000 |
|                    | Q2                   | A    | 798   | -0.001 | +0.006 | +0.006        | +0.001 | -0.001 |
|                    | Q2                   | B    | 798   | -0.001 | -0.002 | +0.011        | +0.001 | -0.001 |
|                    | Q3                   | A    | 798   | -0.007 | -0.008 | -0.019        | -0.001 | -0.002 |
|                    | Q3                   | B    | 798   | -0.006 | -0.005 | -0.000        | -0.000 | -0.002 |
|                    | Q4 (mas lejos)       | A    | 797   | -0.005 | +0.000 | <b>-0.022</b> | -0.001 | -0.001 |
|                    | Q4 (mas lejos)       | B    | 797   | -0.011 | -0.004 | -0.011        | -0.002 | -0.000 |
| Estrato            | Estrato 1            | A    | 903   | -0.003 | -0.001 | -0.001        | -0.005 | -0.002 |
|                    | Estrato 1            | B    | 903   | -0.002 | -0.008 | +0.018        | +0.000 | -0.002 |
|                    | Estrato 2            | A    | 1,390 | -0.002 | -0.002 | -0.005        | +0.004 | +0.000 |
|                    | Estrato 2            | B    | 1,390 | -0.004 | +0.002 | +0.004        | +0.003 | +0.000 |
|                    | Estrato 3            | A    | 741   | -0.003 | -0.001 | -0.006        | +0.000 | -0.001 |
|                    | Estrato 3            | B    | 741   | -0.007 | -0.016 | -0.009        | -0.006 | -0.001 |
| Servicios y bienes | Tercil bajo          | A    | 1,087 | -0.005 | -0.009 | -0.007        | -0.003 | -0.003 |
|                    | Tercil bajo          | B    | 1,087 | -0.004 | -0.009 | +0.013        | -0.001 | -0.003 |
|                    | Tercil medio         | A    | 1,121 | +0.002 | +0.002 | -0.004        | +0.001 | +0.001 |
|                    | Tercil medio         | B    | 1,121 | +0.004 | -0.004 | +0.008        | +0.003 | +0.001 |
|                    | Tercil alto          | A    | 983   | -0.015 | -0.005 | -0.006        | +0.001 | -0.001 |
|                    | Tercil alto          | B    | 983   | -0.017 | -0.009 | -0.005        | -0.009 | +0.000 |

Tabla 13:  $\Delta$ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza multidimensional (IPM). En **negrita**:  $|\Delta| \geq 0.02$ . Grupos con  $n < 30$  omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios, `diagnostico_heterogeneidad_ipm.csv` (`src/05_model/diagnostico_heterogeneidad_ipm.py`).

| Eje                | Grupo                | Esp. | n     | XGB           | RF            | LGBM          | HGB    | Log.   |
|--------------------|----------------------|------|-------|---------------|---------------|---------------|--------|--------|
| Zona               | Rural                | A    | 2,452 | +0.012        | +0.006        | +0.010        | +0.005 | +0.001 |
|                    | Rural                | B    | 2,452 | +0.019        | +0.004        | <b>+0.032</b> | +0.009 | +0.001 |
|                    | Urbano               | A    | 3,119 | +0.013        | -0.002        | +0.000        | -0.005 | -0.000 |
|                    | Urbano               | B    | 3,119 | +0.018        | -0.015        | +0.008        | -0.004 | +0.000 |
| Cercanía a LP      | Q1 (mas cerca de LP) | A    | 1,393 | +0.009        | -0.005        | +0.003        | +0.003 | -0.001 |
|                    | Q1 (mas cerca de LP) | B    | 1,393 | +0.015        | +0.001        | +0.012        | +0.003 | -0.001 |
|                    | Q2                   | A    | 1,394 | <b>+0.024</b> | -0.006        | +0.010        | -0.012 | -0.000 |
|                    | Q2                   | B    | 1,394 | <b>+0.039</b> | -0.013        | <b>+0.032</b> | -0.006 | -0.000 |
|                    | Q3                   | A    | 1,392 | <b>+0.025</b> | +0.009        | +0.002        | +0.009 | +0.003 |
|                    | Q3                   | B    | 1,392 | <b>+0.025</b> | -0.008        | <b>+0.030</b> | +0.006 | +0.003 |
|                    | Q4 (mas lejos)       | A    | 1,392 | +0.013        | +0.011        | +0.003        | -0.009 | -0.004 |
|                    | Q4 (mas lejos)       | B    | 1,392 | +0.019        | -0.015        | -0.008        | +0.015 | -0.003 |
| Estrato            | Estrato 1            | A    | 2,046 | +0.010        | +0.002        | +0.005        | +0.004 | -0.001 |
|                    | Estrato 1            | B    | 2,046 | +0.018        | +0.004        | <b>+0.024</b> | -0.002 | -0.001 |
|                    | Estrato 2            | A    | 2,439 | <b>+0.020</b> | +0.003        | +0.007        | -0.008 | +0.002 |
|                    | Estrato 2            | B    | 2,439 | <b>+0.027</b> | -0.006        | +0.015        | +0.005 | +0.002 |
|                    | Estrato 3            | A    | 889   | -0.007        | -0.006        | -0.006        | -0.005 | +0.002 |
|                    | Estrato 3            | B    | 889   | +0.005        | <b>-0.031</b> | -0.003        | +0.009 | +0.003 |
| Servicios y bienes | Tercil bajo          | A    | 1,858 | +0.014        | +0.003        | +0.008        | +0.001 | +0.001 |
|                    | Tercil bajo          | B    | 1,858 | <b>+0.021</b> | -0.003        | <b>+0.030</b> | +0.003 | +0.000 |
|                    | Tercil medio         | A    | 1,977 | +0.007        | +0.004        | +0.002        | -0.006 | +0.000 |
|                    | Tercil medio         | B    | 1,977 | +0.018        | -0.004        | +0.019        | -0.001 | +0.000 |
|                    | Tercil alto          | A    | 1,736 | <b>+0.034</b> | -0.001        | +0.004        | +0.001 | +0.000 |
|                    | Tercil alto          | B    | 1,736 | <b>+0.033</b> | <b>-0.030</b> | +0.009        | +0.005 | +0.000 |

## A.7. Aporte de las tres fuentes geoespaciales juntas bajo pobreza monetaria

Complemento de la Sección 5.3.1: desempeño de los Modelos A y B al agregar las 127 variables de DMSP-OLS, ALOS PALSAR y Landsat 5 TM juntas, frente a los mismos

modelos sin variables geoespaciales, bajo el mismo esquema de validación cruzada.

Tabla 14: AUC-ROC y precisión en el decil de mayor riesgo, con y sin las 127 variables de las tres fuentes geoespaciales (DMSP-OLS, ALOS PALSAR y Landsat 5 TM), pobreza monetaria. Validación cruzada de 10 particiones dentro de la transición 2010→2013, media e IC95 % sobre 5 semillas.

| Algoritmo              | Especificación | N.º var. | AUC-ROC | IC95 %         | $\Delta$ AUC | Precision top-10 % |
|------------------------|----------------|----------|---------|----------------|--------------|--------------------|
| XGBoost                | A              | 169      | 0.766   | [0.764, 0.767] | –            | 0.577              |
| XGBoost                | A + 3 fuentes  | 296      | 0.765   | [0.763, 0.767] | -0.000       | 0.574              |
| HistGradientBoosting   | A              | 169      | 0.760   | [0.757, 0.762] | –            | 0.583              |
| HistGradientBoosting   | A + 3 fuentes  | 296      | 0.757   | [0.755, 0.759] | -0.003       | 0.560              |
| Logística regularizada | A              | 169      | 0.760   | [0.759, 0.761] | –            | 0.548              |
| Logística regularizada | A + 3 fuentes  | 296      | 0.755   | [0.753, 0.756] | -0.006       | 0.547              |
| XGBoost                | B              | 165      | 0.757   | [0.755, 0.759] | –            | 0.563              |
| XGBoost                | B + 3 fuentes  | 292      | 0.756   | [0.754, 0.757] | -0.001       | 0.581              |
| HistGradientBoosting   | B              | 165      | 0.753   | [0.751, 0.755] | –            | 0.568              |
| HistGradientBoosting   | B + 3 fuentes  | 292      | 0.750   | [0.749, 0.752] | -0.003       | 0.566              |
| Logística regularizada | B              | 165      | 0.755   | [0.753, 0.756] | –            | 0.544              |
| Logística regularizada | B + 3 fuentes  | 292      | 0.751   | [0.750, 0.753] | -0.004       | 0.557              |

*Nota:* ALOS PALSAR y Landsat 5 TM no tienen dato en 2013, por lo que esta variante no admite el holdout temporal de la Tabla 10: las métricas se calculan sobre probabilidades *out-of-fold* y son comparables entre sí, no contra esa tabla. Solo se estimaron modelos con los tres algoritmos mostrados.

N.º var.: covariables que recibe el modelo. Fuente: cálculos propios.

## A.8. Google Street View (exploratorio)

Complemento de las Secciones 3.1 y 6.3: resultados del diagnóstico exploratorio de las fotografías de Google Street View. La Tabla 15 mide qué tan bien predicen las representaciones de las fotos la luz nocturna de su zona y qué tan estables son entre olas; la Tabla 16, su cobertura y su relación con la caída en pobreza.

Tabla 15: Google Street View: predicción de la luz nocturna y estabilidad en el tiempo.

| Modelo de imagen | $R^2$ , ventana<br>2011–2013 | $R^2$ , ventana<br>2011–2015 | Correlación<br>entre olas |
|------------------|------------------------------|------------------------------|---------------------------|
| CLIP             | 0.699                        | 0.737                        | +0.197                    |
| VGG19            | 0.634                        | 0.709                        | -0.160                    |
| ResNet50         | 0.702                        | 0.745                        | -0.152                    |
| Places365        | 0.738                        | 0.771                        | +0.177                    |

*Nota:*  $R^2$  fuera de muestra de predecir la luz nocturna estable (DMSP-OLS) de la zona a partir de la representación de la foto ( $n = 830$  hogares con la ventana original y  $n = 1,280$  con la ampliada). Correlación entre olas: del primer componente de la representación para los mismos hogares ( $n = 87$ ), comparable con 0.958 de la luz nocturna y 0.600 de los bienes durables. Fuente: cálculos propios.

Tabla 16: Google Street View: cobertura y relación con la caída en pobreza (exploratorio).

| Indicador                                                     | Valor                   | $n$   |
|---------------------------------------------------------------|-------------------------|-------|
| <i>Luz nocturna media según cobertura de fotos</i>            |                         |       |
| Sin foto                                                      | 7.0                     | 2,188 |
| Con foto fuera de la ventana de fechas                        | 42.0                    | 5,407 |
| Con foto dentro de la ventana (muestra usada)                 | 42.3                    | 830   |
| <i>Caer en pobreza: regresión logística conjunta (IC95 %)</i> |                         |       |
| Primer componente de la foto (Places365)                      | +0.509 [+0.17, +0.86]   | 283   |
| Luz nocturna                                                  | -0.049 [-0.35, +0.27]   | 283   |
| <i>Caer en pobreza: AUC-ROC con validación cruzada</i>        |                         |       |
| Solo fotos                                                    | 0.619                   | 443   |
| Fotos y luz nocturna                                          | 0.612                   | 443   |
| Cambio (IC95 %)                                               | -0.007 [-0.021, +0.006] | 443   |

*Nota:* Hogares con foto dentro de la ventana de fechas: los que tienen una foto de Street View tomada cerca de la ola de 2013. No hay fotos anteriores a 2012, de modo que no es posible entrenar con 2010 y evaluar en 2016 como en el resto del documento: la regresión logística se estima sobre los hogares del conjunto de prueba con foto, y el AUC-ROC, con validación cruzada de 5 particiones dentro de esa muestra, con los primeros cinco componentes de Places365. Fuente: cálculos propios.

## A.9. Cobertura de covariables por módulo

Complemento de las Secciones 3.1 y 3.2: auditoría de los módulos, reglas de agregación al nivel de hogar, candidatas auditadas, variables finalmente usadas en el modelo y cobertura sobre el panel para cada módulo de la ELCA.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta, replicada de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal ¿??" en lugar de vocales acentuadas y la letra ñ);

(ii) clasificación de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información.

Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno” cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar. Las tasas de mercado laboral se calcularon restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones) porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares que cumplen esa condición. La Tabla 17 resume las variables candidatas auditadas, las usadas en el modelo y la cobertura por módulo.

Tabla 17: Cobertura de covariables por módulo en el dataset consolidado

| Módulo               | Candidatas<br>auditadas | Usadas en el<br>modelo | Cobertura (%)<br>del panel) |
|----------------------|-------------------------|------------------------|-----------------------------|
| Hogar                | 155                     | 103                    | 100 %                       |
| Personas (9 bloques) | 139                     | 57                     | 100 %                       |
| Comunidades          | 212                     | 21                     | 91.9–96.4 %                 |
| Niños (6–9 años)     | 83                      | 13                     | 55.4 % (15,473 /<br>27,932) |
| Choques              | –                       | 17                     | 100 %                       |

*Nota:* “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría descrita arriba; “usadas en el modelo” es el subconjunto final tras la construcción de *features* – excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (ver “Bloque de *features* de Hogar”). No incluye llaves de identidad (p. ej. el consecutivo del hogar en Comunidades). Fuente: cálculos propios con base en ELCA 2010, 2013 y 2016.

El dataset consolidado de la ELCA (27,932 filas hogar×ola) reúne 177 variables finales: 164 provienen de los cinco módulos auditados en la Tabla 17, excluyendo de ese conteo *consecutivo\_c*, que es la llave de unión al módulo Comunidades, no una covariable, y las 13 restantes forman un bloque monetario (ingreso, gasto, líneas de pobreza e indicadores de pobreza). Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario, consistente con que son los módulos que se preguntan a todo hogar sin condición previa (Tabla 17), mientras que Comunidades (21), Choques (17) y Niños (13) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra (Niños). De las 177, 155 (88 %) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas (los indicadores de pobreza monetaria). El desagregado por módulo y tipo de dato se muestra en la Figura 12, y por tema en la Tabla 18.




Figura 12: Inventario de las 177 variables finales del dataset consolidado de la ELCA, por módulo temático y tipo de dato. Fuente: cálculos propios.

Las mismas 177 variables, agrupadas por el tema que cubren en lugar del módulo de la ELCA del que provienen:

Tabla 18: Temas cubiertos por las 177 variables finales del dataset consolidado de la ELCA.

| Tema                                 | N.º        | Ejemplos                                                                                                   |
|--------------------------------------|------------|------------------------------------------------------------------------------------------------------------|
| Educación, empleo y seguridad social | 27         | nivel educativo y categoría ocupacional del jefe, cotización a pensión, tasa de ocupación del hogar        |
| Comunidad                            | 21         | percepción de inseguridad, acceso a agua, puesto de salud, acciones del conflicto armado                   |
| Choques y afrontamiento              | 18         | choques económicos, de salud o agropecuarios; afrontamiento erosivo; desastres naturales                   |
| Ayudas y redes de apoyo              | 18         | ayudas de familiares en Colombia y el exterior, de ONG o de organizaciones religiosas; envío de ayudas     |
| Vivienda: materiales y servicios     | 15         | material de pisos y paredes, servicio sanitario, tenencia, escritura de la vivienda                        |
| Composición del hogar                | 14         | niños menores de 12 años, adultos mayores, razón de dependencia, sexo, edad, etnia y estado civil del jefe |
| Ingreso y gasto                      | 13         | ingreso y gasto per cápita real, brechas frente a la LP, indicadores de pobreza                            |
| Activos del hogar                    | 13         | bienes durables, índice de riqueza (PCA), estrato, vehículo, ahorro                                        |
| Desarrollo infantil (6–9 años)       | 12         | vacunación, talla y peso, oficios y trabajo infantil, puntaje TVIP                                         |
| Salud                                | 10         | afiliación a salud, hospitalización, discapacidad, controles preventivos                                   |
| Programas sociales y deuda           | 8          | Familias en Acción, Red Juntos, apoyo alimentario escolar, deuda formal e informal                         |
| Participación y capital social       | 5          | participación en organizaciones, participación cívica, práctica religiosa                                  |
| Vivienda: hacinamiento               | 3          | personas por cuarto y por dormitorio, valor del arriendo                                                   |
| <b>Total</b>                         | <b>177</b> |                                                                                                            |

*Nota:* clasificación temática propia, independiente del módulo de la ELCA del que proviene cada variable; los temas son los mismos que agrupan el núcleo SHAP (Tabla 4). No incluye las variables geoespaciales (Anexo B.1). Fuente: cálculos propios con base en ELCA 2010, 2013 y 2016.

## A.10. Composición del panel y atrición

Complemento de la Sección 3.2: evolución del número de hogares únicos por ola, tasas de pérdida de hogares entre olas y división de hogares.

El panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016. Esto es una atrición de 11.4% entre 2010 y 2013 y de 11.4% entre 2013 y 2016 (hogares presentes en una ola que no aparecen en la siguiente). La caída neta entre 2013 y 2016 es menor (7.4%) porque 351 hogares que no se encontraron en 2013 volvieron a ser encuestados en 2016. La pérdida acumulada entre 2010 y 2016 es de 17.9%

(Figura 13). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2% de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8% de los rurales), lo opuesto al posible supuesto de que la atrición rural sería mayor por dificultad de rastreo geográfico, probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales (desagregado por zona, estrato y región en el Anexo A.2).

Existe también un fenómeno de división de hogares: 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016. Esto ocurre porque un hijo formó su propio hogar en la misma vivienda o predio o en un predio diferente. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. Estos hogares divididos se excluyeron del análisis para no realizar supuestos adicionales sobre su composición, vulnerabilidad y covariables.




Figura 13: Izquierda: hogares únicos por ola. Derecha: tasa de pérdida de hogares entre olas consecutivas y acumulada 2010–2016. Fuente: cálculos propios.

### A.11. Matriz de confusión del Modelo B

Complemento de la Sección 5.1.2: la misma matriz de confusión de la Tabla 3, para el Modelo B (sin ingreso ni gasto).

Tabla 19: Matriz de confusión del Modelo B en el conjunto de prueba (2013→2016), pobreza monetaria e IPM.

| Algoritmo              | Monetaria  |             |          |             | IPM       |             |           |             |
|------------------------|------------|-------------|----------|-------------|-----------|-------------|-----------|-------------|
|                        | VP         | FP          | FN       | VN          | VP        | FP          | FN        | VN          |
| Random Forest          | 573 (18 %) | 1559 (49 %) | 62 (2 %) | 997 (31 %)  | 414 (7 %) | 2120 (38 %) | 128 (2 %) | 2909 (52 %) |
| XGBoost                | 594 (19 %) | 1770 (55 %) | 41 (1 %) | 786 (25 %)  | 513 (9 %) | 3690 (66 %) | 29 (1 %)  | 1339 (24 %) |
| Logística regularizada | 573 (18 %) | 1575 (49 %) | 62 (2 %) | 981 (31 %)  | 399 (7 %) | 2055 (37 %) | 143 (3 %) | 2974 (53 %) |
| HistGradientBoosting   | 541 (17 %) | 1358 (43 %) | 94 (3 %) | 1198 (38 %) | 342 (6 %) | 1507 (27 %) | 200 (4 %) | 3522 (63 %) |
| LightGBM               | 576 (18 %) | 1622 (51 %) | 59 (2 %) | 934 (29 %)  | 397 (7 %) | 1982 (36 %) | 145 (3 %) | 3047 (55 %) |

*Nota:* VP, FP, FN y VN: hogares verdadero positivo, falso positivo, falso negativo y verdadero negativo.

Entre paréntesis, porcentaje sobre el total de la fila para cada definición de pobreza (monetaria,  $n = 3,191$ ; IPM,  $n = 5,571$ ). Modelos clasificados con los hiperparámetros y el umbral reportados en la Tabla 22 del Anexo A.13. Corresponde a una sola corrida de cada modelo, por lo que el *recall* y la precisión que se derivan de ella difieren levemente de los promedios de 5 semillas de la Tabla 2.

Fuente: cálculos propios.

## A.12. Modelo multiclase

Complemento de las Secciones 5.2 (Tercer hallazgo) y 5.3.1: especificación y desempeño del modelo multiclase mencionado en la Sección 4.2 y AUC-ROC por par de grupos de la matriz de transición, con y sin las variables de DMSP-OLS. Los hiperparámetros se reportan en la Tabla 22 del Anexo A.13.

Si bien se hizo un ejercicio de predicción multiclase con los cuatro grupos y todos los hogares del panel, este no es el principal por cuatro razones. Primero, la pregunta de vulnerabilidad se refiere a quiénes, entre los hogares hoy no pobres, caerán en pobreza. Segundo, con el ingreso entre las covariables, el modelo separa los grupos de forma trivial según la condición de pobreza en la ola base. Tercero, sin el ingreso, el modelo casi no identifica a quienes entran en pobreza: asigna a cada hogar su grupo más probable, sin un umbral que se pueda ajustar como en el modelo binario, y esta clase, la más pequeña, queda absorbida por las demás. Cuarto, se construyó con un propósito más acotado, como diagnóstico: comprobar si quienes entran en pobreza se distinguen de quienes salen, algo que el modelo binario no puede responder (Sección 5.2). El modelo multiclase se estima con los mismos cinco algoritmos y, además, con una red neuronal (perceptrón multicapa), sobre los cuatro grupos de la matriz de transición y sin ingreso ni gasto entre las covariables (Modelo B). Sigue el mismo esquema de validación que el modelo binario (Sección 4.4): entrenamiento en 2010→2013, prueba en 2013→2016 y búsqueda de hiperparámetros y de estrategia de balanceo por validación cruzada. Para medir si dos grupos se distinguen se usa el AUC-ROC por par: se restringe la muestra a los hogares de esos dos grupos y se toma como puntaje la probabilidad que el modelo asigna al primero.

Tabla 20: Desempeño del modelo multiclase (cuatro grupos) en el conjunto de prueba.

| Algoritmo              | Balanceo | Exactitud | Exactitud balanceada | F1 macro | AUC-ROC macro | AUC entra vs. resto | Recall entra | Prec.-top10 entra |
|------------------------|----------|-----------|----------------------|----------|---------------|---------------------|--------------|-------------------|
| XGBoost                | ninguno  | 0.582     | 0.426                | 0.384    | 0.732         | 0.596               | 0.002        | 0.111             |
| LightGBM               | ninguno  | 0.573     | 0.422                | 0.385    | 0.730         | 0.593               | 0.002        | 0.116             |
| HistGradientBoosting   | ninguno  | 0.577     | 0.424                | 0.384    | 0.731         | 0.599               | 0.002        | 0.114             |
| Random Forest          | ninguno  | 0.574     | 0.412                | 0.344    | 0.727         | 0.601               | 0.000        | 0.119             |
| Red neuronal (MLP)     | ninguno  | 0.557     | 0.412                | 0.376    | 0.713         | 0.591               | 0.008        | 0.125             |
| Logística regularizada | ninguno  | 0.545     | 0.398                | 0.348    | 0.703         | 0.576               | 0.005        | 0.127             |

*Nota:* Modelo B (sin ingreso ni gasto), entrenado en 2010→2013 y evaluado en 2013→2016 ( $n = 6,911$  hogares de los cuatro grupos), promedio de 5 semillas. El modelo asigna a cada hogar el grupo más probable, sin umbral ajustable, de modo que casi nunca asigna “entra”, el grupo más pequeño (*recall* cercano a cero); por eso se usa como diagnóstico y no como modelo principal. Prec.-top10 entra: fracción de hogares que efectivamente entran en pobreza entre el 10 % con mayor probabilidad de “entra”. Hiperparámetros en la Tabla 22. Fuente: cálculos propios.

Tabla 21: AUC-ROC del modelo multiclase por par de grupos de la matriz de transición.

| Algoritmo                         | Nunca vs. siempre                       | Nunca vs. entra                         | Nunca vs. sale                          | Entra vs. siempre                       | Sale vs. siempre                        | Entra vs. sale             |
|-----------------------------------|-----------------------------------------|-----------------------------------------|-----------------------------------------|-----------------------------------------|-----------------------------------------|----------------------------|
| <i>AUC-ROC, Modelo B</i>          |                                         |                                         |                                         |                                         |                                         |                            |
| XGBoost                           | 0.927<br>[0.919, 0.935]                 | 0.752<br>[0.731, 0.773]                 | 0.830<br>[0.816, 0.845]                 | 0.676<br>[0.654, 0.698]                 | 0.595<br>[0.574, 0.615]                 | 0.534<br>[0.504, 0.564]    |
| LightGBM                          | 0.927<br>[0.919, 0.935]                 | 0.754<br>[0.733, 0.775]                 | 0.829<br>[0.813, 0.843]                 | 0.685<br>[0.662, 0.708]                 | 0.603<br>[0.582, 0.623]                 | 0.543<br>[0.515, 0.575]    |
| HistGradientBoosting              | 0.925<br>[0.917, 0.933]                 | 0.752<br>[0.730, 0.772]                 | 0.824<br>[0.808, 0.839]                 | 0.675<br>[0.652, 0.697]                 | 0.605<br>[0.584, 0.625]                 | 0.545<br>[0.517, 0.573]    |
| Random Forest                     | 0.919<br>[0.910, 0.927]                 | 0.749<br>[0.728, 0.770]                 | 0.813<br>[0.797, 0.829]                 | 0.702<br>[0.679, 0.724]                 | 0.611<br>[0.591, 0.629]                 | 0.541<br>[0.512, 0.573]    |
| Red neuronal (MLP)                | 0.910<br>[0.901, 0.919]                 | 0.743<br>[0.722, 0.764]                 | 0.820<br>[0.804, 0.835]                 | 0.685<br>[0.662, 0.708]                 | 0.613<br>[0.594, 0.632]                 | 0.554<br>[0.525, 0.582]    |
| Logística regularizada            | 0.896<br>[0.885, 0.906]                 | 0.734<br>[0.714, 0.756]                 | 0.806<br>[0.789, 0.821]                 | 0.688<br>[0.665, 0.710]                 | 0.629<br>[0.608, 0.650]                 | 0.562<br>[0.530, 0.593]    |
| <i>Cambio al agregar DMSP-OLS</i> |                                         |                                         |                                         |                                         |                                         |                            |
| XGBoost                           | -0.001<br>[-0.002, +0.001]              | +0.001<br>[-0.003, +0.005]              | -0.001<br>[-0.004, +0.002]              | +0.005<br>[-0.008, +0.018]              | +0.013 <sup>†</sup><br>[+0.003, +0.023] | +0.011<br>[-0.006, +0.028] |
| LightGBM                          | +0.000<br>[-0.002, +0.002]              | -0.004<br>[-0.008, +0.001]              | +0.003<br>[-0.001, +0.005]              | +0.013<br>[-0.000, +0.025]              | +0.011 <sup>†</sup><br>[+0.000, +0.022] | +0.009<br>[-0.009, +0.026] |
| HistGradientBoosting              | -0.000<br>[-0.003, +0.002]              | -0.004<br>[-0.010, +0.003]              | +0.004 <sup>†</sup><br>[+0.000, +0.009] | -0.008<br>[-0.023, +0.006]              | -0.003<br>[-0.015, +0.009]              | -0.006<br>[-0.026, +0.013] |
| Random Forest                     | -0.002 <sup>†</sup><br>[-0.004, -0.001] | -0.004 <sup>†</sup><br>[-0.008, -0.001] | -0.002<br>[-0.004, +0.000]              | -0.009<br>[-0.018, +0.001]              | -0.004<br>[-0.013, +0.004]              | -0.006<br>[-0.019, +0.007] |
| Red neuronal (MLP)                | -0.002<br>[-0.006, +0.003]              | -0.004<br>[-0.013, +0.004]              | -0.002<br>[-0.009, +0.004]              | +0.024 <sup>†</sup><br>[+0.007, +0.040] | +0.010<br>[-0.007, +0.028]              | +0.005<br>[-0.016, +0.027] |
| Logística regularizada            | +0.001<br>[-0.000, +0.001]              | -0.001<br>[-0.002, +0.001]              | +0.001<br>[-0.000, +0.002]              | -0.001<br>[-0.005, +0.003]              | -0.003<br>[-0.008, +0.002]              | +0.002<br>[-0.003, +0.006] |

*Nota:* AUC-ROC de cada par de grupos: se restringe a los hogares de los dos grupos y se usa como puntaje la probabilidad que el modelo asigna al primero. Modelo B, conjunto de prueba 2013→2016 ( $n = 6,911$  hogares), semilla 42; el promedio de 5 semillas difiere como máximo en 0.007. Entre corchetes, intervalo de confianza del 95 % por *bootstrap* por comunidad (2,000 remuestras de 1,889 comunidades; los hogares sin comunidad identificada cuentan cada uno como una), pareado entre especificaciones en el panel inferior. El panel inferior es la diferencia entre el mismo modelo con las 23 variables de DMSP-OLS y sin ellas; <sup>†</sup>: intervalo que excluye el cero. Fuente: cálculos propios.

### A.13. Hiperparámetros de los modelos reportados

Complemento de las Secciones 4.3 y 4.4: descripción de los algoritmos y sus hiperparámetros finales.

**Descripción de los algoritmos.** Los cinco algoritmos se agrupan en dos familias según cómo tratan las variables categóricas y los datos faltantes (Sección 4.5):

- **Regresión logística regularizada (benchmark).**  $F(\cdot)$  es la función logística; los

coeficientes  $\beta$  se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza ( $C$ ) y mezcla ( $l_1\_ratio$ ) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge. Es el algoritmo designado como referencia por ser interpretable y por servir de punto de comparación antes de justificar el uso de un modelo más complejo. Es también el más sensible a la multicolinealidad entre covariables; se evaluó explícitamente ese riesgo mediante un análisis de correlación de Pearson entre las 159 variables numéricas del consolidado, con 35 pares por encima de  $|r| = 0.7$  (incluida una correlación fuerte de `dmsp_stable_lights` con `lp` y `n_servicios_publicos_hogar`, retomada en la Sección 5.3.1; detalle completo en el Apéndice A.1). La regularización  $\ell_1/\ell_2$  mitiga, pero no elimina, la varianza inflada de coeficientes individuales cuando varias variables de un mismo grupo redundante entran juntas al modelo.

- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad. Los tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding*.

**Hiperparámetros.** La Tabla 22 reporta los hiperparámetros finales, estrategia de balanceo de clases y umbral de clasificación (promedio de las cinco semillas) elegidos por validación cruzada para todos los modelos cuyos resultados se reportan en el documento. Los análisis SHAP, de heterogeneidad y de *bootstrap* usan estos mismos modelos. Varias especificaciones de un mismo algoritmo comparten hiperparámetros porque la búsqueda aleatoria usa una semilla fija: prueba las mismas 30 combinaciones en cada especificación, y a menudo gana la misma.

Tabla 22: Hiperparámetros finales, estrategia de balanceo y umbral de clasificación de todos los modelos reportados.

| Algoritmo                                  | Espec.   | Balanceo | Umbral | Hiperparámetros                                                                                                           |
|--------------------------------------------|----------|----------|--------|---------------------------------------------------------------------------------------------------------------------------|
| <b>Pobreza monetaria, holdout temporal</b> |          |          |        |                                                                                                                           |
| Logística regularizada                     | A        | balanced | 0.37   | C = 0.00603; l1_ratio = 0.156                                                                                             |
| Logística regularizada                     | B        | balanced | 0.35   | C = 0.00603; l1_ratio = 0.156                                                                                             |
| Logística regularizada                     | A + DMSP | balanced | 0.37   | C = 0.00603; l1_ratio = 0.156                                                                                             |
| Logística regularizada                     | B + DMSP | balanced | 0.35   | C = 0.00603; l1_ratio = 0.156                                                                                             |
| Random Forest                              | A        | ninguno  | 0.14   | max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334                                           |
| Random Forest                              | B        | balanced | 0.31   | max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334                                           |
| Random Forest                              | A + DMSP | balanced | 0.26   | max_depth = 8; max_features = 0.234; min_samples_leaf = 25; n_estimators = 493                                            |
| Random Forest                              | B + DMSP | balanced | 0.27   | max_depth = 12; max_features = 0.259; min_samples_leaf = 21; n_estimators = 291                                           |
| XGBoost                                    | A        | ninguno  | 0.11   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| XGBoost                                    | B        | ninguno  | 0.13   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| XGBoost                                    | A + DMSP | ninguno  | 0.12   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| XGBoost                                    | B + DMSP | ninguno  | 0.13   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| LightGBM                                   | A        | ninguno  | 0.10   | learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32     |

| Algoritmo                    | Espec.   | Balanceo | Umbral | Hiperparámetros                                                                                                        |
|------------------------------|----------|----------|--------|------------------------------------------------------------------------------------------------------------------------|
| LightGBM                     | B        | ninguno  | 0.15   | learning_rate = 0.0111; max_depth = 4; min_child_samples = 30; n_estimators = 143; num_leaves = 48; reg_lambda = 0.617 |
| LightGBM                     | A + DMSP | ninguno  | 0.10   | learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32  |
| LightGBM                     | B + DMSP | ninguno  | 0.13   | learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15   |
| HistGradientBoosting         | A        | balanced | 0.32   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                   |
| HistGradientBoosting         | B        | ninguno  | 0.14   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                   |
| HistGradientBoosting         | A + DMSP | balanced | 0.31   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                   |
| HistGradientBoosting         | B + DMSP | ninguno  | 0.14   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                   |
| <b>IPM, holdout temporal</b> |          |          |        |                                                                                                                        |
| Logística regularizada       | A        | ninguno  | 0.10   | C = 0.0362; l1_ratio = 0.52                                                                                            |
| Logística regularizada       | B        | ninguno  | 0.11   | C = 0.0362; l1_ratio = 0.52                                                                                            |
| Logística regularizada       | A + DMSP | ninguno  | 0.11   | C = 0.0362; l1_ratio = 0.52                                                                                            |
| Logística regularizada       | B + DMSP | ninguno  | 0.11   | C = 0.0362; l1_ratio = 0.52                                                                                            |
| Random Forest                | A        | balanced | 0.31   | max_depth = 14; max_features = 0.567; min_samples_leaf = 13; n_estimators = 544                                        |
| Random Forest                | B        | balanced | 0.26   | max_depth = 14; max_features = 0.273; min_samples_leaf = 9; n_estimators = 234                                         |
| Random Forest                | A + DMSP | ninguno  | 0.12   | max_depth = 9; max_features = 0.387; min_samples_leaf = 25; n_estimators = 492                                         |

| Algoritmo            | Espec.   | Balanceo | Umbral | Hiperparámetros                                                                                                            |
|----------------------|----------|----------|--------|----------------------------------------------------------------------------------------------------------------------------|
| Random Forest        | B + DMSP | ninguno  | 0.11   | max_depth = 12; max_features = 0.259; min_samples_leaf = 21; n_estimators = 291                                            |
| XGBoost              | A        | ninguno  | 0.11   | colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658 |
| XGBoost              | B        | ninguno  | 0.09   | colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658 |
| XGBoost              | A + DMSP | ninguno  | 0.10   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801  |
| XGBoost              | B + DMSP | ninguno  | 0.11   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801  |
| LightGBM             | A        | ninguno  | 0.11   | learning_rate = 0.013; max_depth = 5; min_child_samples = 26; n_estimators = 383; num_leaves = 16; reg_lambda = 1.77       |
| LightGBM             | B        | ninguno  | 0.08   | learning_rate = 0.0357; max_depth = 7; min_child_samples = 19; n_estimators = 206; num_leaves = 22; reg_lambda = 1.58      |
| LightGBM             | A + DMSP | ninguno  | 0.10   | learning_rate = 0.013; max_depth = 5; min_child_samples = 26; n_estimators = 383; num_leaves = 16; reg_lambda = 1.77       |
| LightGBM             | B + DMSP | ninguno  | 0.10   | learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15       |
| HistGradientBoosting | A        | ninguno  | 0.11   | l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42                       |
| HistGradientBoosting | B        | ninguno  | 0.10   | l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42                       |
| HistGradientBoosting | A + DMSP | ninguno  | 0.10   | l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42                       |

| Algoritmo                                                         | Espec.        | Balanceo     | Umbral | Hiperparámetros                                                                                                           |
|-------------------------------------------------------------------|---------------|--------------|--------|---------------------------------------------------------------------------------------------------------------------------|
| HistGradientBoosting                                              | B + DMSP      | ninguno      | 0.10   | l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42                      |
| <b>Tres fuentes geoespaciales, validación cruzada (2010→2013)</b> |               |              |        |                                                                                                                           |
| Logística regularizada                                            | A             | balanced     | 0.37   | C = 0.00603; l1_ratio = 0.156                                                                                             |
| Logística regularizada                                            | B             | balanced     | 0.35   | C = 0.00603; l1_ratio = 0.156                                                                                             |
| Logística regularizada                                            | A + 3 fuentes | oversampling | 0.37   | C = 0.00277; l1_ratio = 0.196                                                                                             |
| Logística regularizada                                            | B + 3 fuentes | ninguno      | 0.14   | C = 0.00811; l1_ratio = 0.183                                                                                             |
| XGBoost                                                           | A             | ninguno      | 0.11   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| XGBoost                                                           | B             | ninguno      | 0.13   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| XGBoost                                                           | A + 3 fuentes | ninguno      | 0.13   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| XGBoost                                                           | B + 3 fuentes | ninguno      | 0.13   | colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801 |
| HistGradientBoosting                                              | A             | balanced     | 0.32   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                      |
| HistGradientBoosting                                              | B             | ninguno      | 0.14   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                      |
| HistGradientBoosting                                              | A + 3 fuentes | balanced     | 0.32   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                      |
| HistGradientBoosting                                              | B + 3 fuentes | ninguno      | 0.14   | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                      |

| Algoritmo                         | Espec. | Balanceo | Umbral | Hiperparámetros                                                                                                            |
|-----------------------------------|--------|----------|--------|----------------------------------------------------------------------------------------------------------------------------|
| <b>Multiclase (cuatro grupos)</b> |        |          |        |                                                                                                                            |
| Logística regularizada            | A      | ninguno  | –      | C = 0.0746; l1_ratio = 0.951                                                                                               |
| Logística regularizada            | B      | ninguno  | –      | C = 0.0746; l1_ratio = 0.951                                                                                               |
| Random Forest                     | A      | ninguno  | –      | max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334                                            |
| Random Forest                     | B      | ninguno  | –      | max_depth = 12; max_features = 0.27; min_samples_leaf = 8; n_estimators = 400                                              |
| XGBoost                           | A      | ninguno  | –      | colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658 |
| XGBoost                           | B      | ninguno  | –      | colsample_bytree = 0.824; learning_rate = 0.0368; max_depth = 5; n_estimators = 356; reg_lambda = 2.78; subsample = 0.694  |
| LightGBM                          | A      | ninguno  | –      | learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15       |
| LightGBM                          | B      | ninguno  | –      | learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32      |
| HistGradientBoosting              | A      | ninguno  | –      | l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58                       |
| HistGradientBoosting              | B      | ninguno  | –      | l2_regularization = 2.58; learning_rate = 0.0189; max_depth = 5; max_iter = 227; max_leaf_nodes = 42                       |
| Red neuronal (MLP)                | A      | ninguno  | –      | alpha = 0.0207; hidden_layer_sizes = (64); learning_rate_init = 0.00852                                                    |
| Red neuronal (MLP)                | B      | ninguno  | –      | alpha = 3.08e-05; hidden_layer_sizes = (128, 64); learning_rate_init = 0.00464                                             |

## **B. Detalles de construcción de variables geoespaciales**

### **B.1. Qué mide cada fuente geoespacial**

Complemento de la Sección 3.1: para las tres fuentes incorporadas (DMSP-OLS, ALOS PALSAR y Landsat 5 TM), el mecanismo físico de medición, las variables principales construidas y la interpretación que se les da en este estudio.

Tabla 23: Qué mide cada fuente nueva, qué variables construye, y qué aproxima cada una.

| <b>Fuente</b>                                      | <b>Mecanismo físico</b>                                                                    | <b>Variables (estado / ventana acum.)</b>                                                                              | <b>Qué aproxima</b>                                                                                                                                                  |
|----------------------------------------------------|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| DMSP-OLS<br>(23 var.: 5 estado + 18 acum.)         | Radiancia visible nocturna captada por satélite (alumbrado público, vivienda, comercio)    | Estado: nivel, log, saturación<br>Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code> )         | Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)           |
| ALOS<br>PALSAR<br>(52 var.: 7 estado + 45 acum.)   | Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación                | Estado: HH, HV (dB), razón HH/HV, índice normalizado<br>Acumulada: media, tendencia, crecimiento de cada una           | Densidad y consolidación del entorno construido vs. vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)              |
| Landsat 5<br>TM<br>(52 var.: 16 estado + 36 acum.) | Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta) | Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices)<br>Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo | Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada) |

*Nota:* las especificaciones principales (Modelos A y B con DMSP-OLS, holdout temporal) agregan solo las 23 variables de DMSP-OLS; la variante con las tres fuentes agrega las 127, evaluada con validación cruzada dentro de 2010→2013 (Tabla 14). Cada variable de ventana acumulada se resume en nueve estadísticos: media, desviación estándar, mínimo, máximo, rango, coeficiente de variación, tendencia, crecimiento acumulado y número de años con dato. Se excluyen las variables de cambio entre olas (movimiento del hogar, crecimiento 2010–2013), que no están definidas en la ola base. Fuente: cálculos propios.

## B.2. Cobertura temporal de las fuentes evaluadas

Complemento de la Sección 3.1: ventana de disponibilidad de las siete fuentes geoespaciales evaluadas frente a las tres olas de la ELCA, y criterios con los que se seleccionaron.

Se requirió obtener información geoespacial para al menos dos olas: la transición 2010→2013, que es la ola en la que se entrenan los modelos que predicen la transición a la pobreza, y la transición 2013→2016 que se usa posteriormente para probar el poder predictivo de esas mismas variables en una ola donde no se usaron para entrenar el modelo. Es decir, fuera de muestra (Sección 4.1).

Además de la disponibilidad de fotos de nivel de calle (Google Street View), se evaluaron seis fuentes satelitales: Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales todavía no operaban). Se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017). Por esta razón, las tres fuentes que finalmente se incluyeron en este artículo fueron: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura anterior a 2014.

La Figura 14 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA, JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los hogares en las tres olas de la ELCA (2010, 2013, 2016).

El resultado de la consulta de la información geoespacial sobre las tres fuentes disponibles es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013 y es la única de las tres con esa cobertura completa en dos olas. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014, es decir, no tiene ninguna cobertura de 2013. Landsat 5 TM cubre solo 65.5 % de los hogares en 2010 (6,269 de 9,573; del resto no se obtuvo información por nubosidad persistente, una limitación conocida del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría una cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth Engine confirmó que el sensor dejó de adquirir información utilizable antes de esa fecha. Por lo tanto, estas tres fuentes se incorporaron al

proyecto pero solo DMSP-OLS sirvió como fuente principal en el marco del análisis.

Se hizo un ejercicio adicional con Google Street View, que es la fuente de información geoespacial más cercana a la experiencia humana de observación del entorno, y que podría capturar información relevante para la predicción de vulnerabilidad a la pobreza. Sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente: no se encontró ninguna foto para los hogares de la ELCA que se hubiera tomado antes de 2012 y el 61 % de las fotos disponibles se habían tomado posterior a 2023. Por esta razón, se decidió no incluirla en el análisis principal, aunque se tuvo en cuenta para la construcción de variables geoespaciales complementarias y para la discusión de resultados (Anexo A.8).




Figura 14: Cobertura temporal real de cada fuente geoespacial evaluada, frente a las tres olas de la ELCA con coordenadas disponibles. El patrón diagonal indica corrida real y completa sobre hogares del estudio; el resto se revisó cobertura según catálogo. En la barra de GSV, la intensidad del color es proporcional a la densidad real de fotos por año —la gran mayoría de las fotos son de 2023 en adelante.