

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal de Colombia (ELCO)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización de programas sociales en Colombia, como el SISBEN, identifican pobreza como un estado observado y no anticipan qué hogares no pobres tienen mayor riesgo de caer en esa condición. Este trabajo evalúa si información pública, particularmente, características del entorno físico y económico local derivadas de imágenes provenientes de Google Street View, mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Usando tres olas del panel (2010, 2013, 2016), se construye la variable de resultado como la entrada en pobreza de hogares inicialmente no pobres y se estiman distintos algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting), evaluando su capacidad predictiva en un período posterior al utilizado para su estimación: los modelos se entrenan con las transiciones observadas entre 2010 y 2013 y se evalúan con las transiciones entre 2013 y 2016. Este esquema permite evaluar el desempeño de los modelos en datos temporalmente posteriores a aquellos utilizados para su entrenamiento, aproximándose a su capacidad para anticipar transiciones futuras hacia la pobreza. Los modelos se estiman con y sin variables monetarias del hogar. El modelo base, que es lo que se reporta en esta versión

del documento, alcanza un AUC-ROC entre 0.727 y 0.764 según el algoritmo, con una brecha de apenas 0.008–0.031 entre la especificación que incluye ingreso/gasto del hogar y la que no lo hace, lo que sugiere que las covariables no monetarias capturan una fracción sustancial del poder predictivo típicamente atribuido al ingreso. La incorporación de las variables geoespaciales, contribución central de esta tesis, está en construcción. De confirmarse un aporte incremental, los resultados podrían fortalecer instrumentos de focalización con información de mayor frecuencia y menor costo de actualización que las encuestas de hogares tradicionales.

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geoespaciales, ELCA, focalización, Colombia.

Índice

1. Introducción	5
2. Marco conceptual y revisión de literatura	6
2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales	6
2.2. Aprendizaje de máquinas en la predicción de pobreza	8
2.3. Variables geoespaciales como fuente complementaria	9
2.4. Síntesis y vacío que llena este trabajo	10
3. Datos	11
3.1. Encuesta Longitudinal Colombiana (ELCA)	11
3.2. Fuentes geoespaciales	12
3.2.1. Cobertura, calidad y limitaciones de las imágenes de Google Street View	13
3.2.2. Transfer learning y modelos de extracción de variables visuales . . .	19
3.3. Estadísticas descriptivas	22
4. Estrategia empírica	23
4.1. Construcción de la variable de resultado	23
4.2. Especificación de modelos	23
4.3. Validación fuera de muestra y métricas	24
4.4. Tratamiento del desbalance de clases	25
4.5. Importancia de variables e interpretabilidad	26
5. Resultados	27
5.1. Dinámica de transiciones a la pobreza en la ELCO	27
5.1.1. Incidencia de pobreza y matrices de transición	27
5.1.2. Ejercicios de robustez	30
5.2. Desempeño comparativo de modelos	34
5.3. Contribución marginal de las variables geoespaciales	38
5.4. Heterogeneidad territorial	38
6. Conclusiones	39
6.1. Síntesis de hallazgos	39
6.2. Implicaciones para la política pública	40
6.3. Limitaciones y agenda de investigación	40

Referencias	41
A. Tablas y figuras complementarias	44
B. Detalles de construcción de variables geoespaciales	44

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juárez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Beneficiarios de Programas Sociales (SISBEN) opera a través de una encuesta cuya aplicación depende de la solicitud de los hogares y de los recursos de la entidad territorial responsable, lo que genera rezagos en la actualización de la información y dificulta contar con datos recientes sobre el efecto de choques (Consejo Nacional de Política Económica y Social, 2016). La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y ejercicios recientes de aproximación a la vulnerabilidad monetaria en Bogotá mediante pseudo-panel confirman tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Castañeda Castrillón, 2012; Gaitán, 2023).

Esta tesis aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza monetaria. Este abordaje es distinto al de la literatura de la pobreza contemporánea que predice la mayoría de la literatura de aprendizaje de máquinas aplicada a este problema (Ferdausi et al., 2025; Muñetón et al., 2022)–. La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View mejora la predicción de caída en pobreza monetaria de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del hogar reportadas en encuestas?

El estado actual de este documento cubre la primera mitad de esa pregunta: la construcción rigurosa de la variable de resultado, la auditoría exhaustiva de las covariables socioeconómicas disponibles en la ELCA (más de 4.000 columnas originales revisadas variable por variable a través de cinco módulos), y la estimación y comparación de cinco algoritmos de aprendizaje supervisado: regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting– sobre el modelo *base* (sin variables geoespaciales). La incorporación de las fuentes geoespaciales y la comparación frente al modelo extendido, que es la contribución central de la pregunta de investigación, está en construcción y se documenta como trabajo en curso en la Sección 6.3.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema no abordado directamente por la literatura existente aplicada al país.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje de máquinas aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla la estrategia empírica: construcción del outcome, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados obtenidos hasta el momento. La Sección 6 cierra con una síntesis, implicaciones de política y la agenda de trabajo pendiente.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria suele originarse en fluctuaciones del ingreso asociadas con choques económicos (ej. pérdida de empleo, caídas en precios) o eventos adversos

(ej. desastres naturales, conflictos). Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto al mostrar que en muchos países en desarrollo existe una población significativa de hogares no pobres pero altamente expuestos: su situación actual los ubica por encima de la línea de pobreza, pero su fragilidad patrimonial los hace vulnerables a caer ante afectaciones moderadas. Esta población es precisamente la que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010; Costella et al., 2023).

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juárez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 5.1 de esta tesis. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado de pobreza.

En el contexto colombiano, la aplicación de estos enfoques ha enfrentado restricciones de datos que han limitado su alcance. Castañeda Castrillón (2012) estudió las trampas de pobreza mediante la construcción de un pseudo-panel, y Gaitán (2023) analizó la vulnerabilidad monetaria a nivel de localidades en Bogotá con el mismo enfoque, como una manera para superar la ausencia de un panel de hogares con representatividad y cobertura suficiente; sus resultados –cerca del 23 % de la población bogotana en situación de vulnerabilidad en 2021– confirman la relevancia del problema, pero también evidencian las restricciones que impone el uso de cortes transversales repetidos en lugar de datos longitudinales reales. La disponibilidad de la ELCA, con tres olas de seguimiento a los mismos hogares, ofrece una oportunidad inédita para superar esta limitación en el contexto colombiano. Incluso con datos longitudinales, sin embargo, esta literatura enfrenta una restricción operativa adicional: los métodos desarrollados dependen, casi sin excepción, de encuestas de hogares con información detallada sobre ingresos, activos y consumo, costosas, de levantamiento infrecuente y con rezagos significativos entre la recolección y la disponibilidad de los datos. Esta restricción informacional es la que motiva la exploración de fuentes alternativas de datos que puedan aproximar la vulnerabilidad con mayor frecuencia de actualización y menor costo de recolección (Sección 2.3).

2.2. Aprendizaje de máquinas en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su desarrollo ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar

sustancialmente la precisión de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando la precisión balanceada en hasta 17 puntos porcentuales frente a los métodos tradicionales. Siguiendo esta perspectiva, esta tesis evalúa el desempeño de los modelos fuera de la muestra mediante un *holdout* temporal hacia adelante: los modelos se entrenan con información de períodos anteriores y se evalúan con información de un período posterior. De esta manera, la validación permite aproximarse mejor a la situación en la que el modelo se utilizaría en la práctica, es decir, para predecir la vulnerabilidad de hogares en un período futuro (Sección 4.3). Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2025) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema, logrando una precisión del 96 % con un conjunto reducido de siete variables. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza al resto de la literatura. En Colombia, Muñetón et al. (2022) han aplicado aprendizaje de máquinas a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital, mostrando que la combinación de imágenes satelitales con datos de encuesta permite explicar hasta el 75 % de la variación en consumo o riqueza en contextos africanos, superando lo que cualquiera de las dos fuentes logra de manera aislada. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con precisiones superiores al 82 %, aunque advierten que su capacidad discriminatoria se reduce en contextos de pobreza muy extendida, donde la variabilidad espacial de las imágenes es insuficiente para

distinguir entre hogares con distintos niveles de privación.

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran que la combinación de datos satelitales y de telefonía móvil reduce los errores de exclusión en programas sociales entre 4 % y 21 % frente a los métodos tradicionales. Hall et al. (2023), en una revisión sistemática, documentan que la combinación de múltiples fuentes incrementa el poder predictivo hasta en 15 puntos porcentuales, pero identifican que los datos geoespaciales predicen mejor activos físicos que variables de flujo como ingreso o consumo, y que su desempeño depende críticamente del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que esta tesis busca incorporar (sección 3.2).

2.4. Síntesis y vacío que llena este trabajo

La evidencia revisada muestra que los modelos que combinan variables geoespaciales con información socioeconómica de encuestas superan a los basados exclusivamente en cualquiera de las dos fuentes, con ventajas más pronunciadas cuando la validación se realiza fuera de muestra. Sin embargo, ninguno de los trabajos revisados aborda directamente el problema de predecir la probabilidad de caída en pobreza de hogares actualmente no pobres, y mucho menos en un contexto de datos longitudinales de hogar como el que ofrece la ELCA. Predecir transiciones hacia la pobreza es un problema conceptualmente distinto al de estimar pobreza contemporánea: requiere una variable de resultado definida en términos prospectivos, un horizonte temporal explícito entre olas de panel, y un conjunto de variables predictoras que capture tanto las condiciones del hogar como las del entorno en el momento previo a la transición.

Es en esta brecha donde esta investigación busca contribuir, evaluando si la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View a los datos longitudinales de la ELCA permite mejorar la identificación de hogares en riesgo de caer en pobreza en Colombia. Es importante señalar que, en contextos de política pública, la predicción es valiosa incluso en ausencia de interpretación causal Kleinberg et al. (2015), especialmente porque el objetivo es mejorar la focalización *ex ante* de la política

social. Por esta razón, este trabajo se sitúa en un enfoque predictivo más que causal, donde el objetivo no es identificar efectos estructurales sino mejorar la capacidad de anticipar transiciones hacia la pobreza con miras a mejorar la focalización de políticas públicas de seguridad social.

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCA)

La fuente primaria de datos es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares en tres olas: 2010, 2013 y 2016, en zonas urbana y rural. La ELCA se organiza en en módulos temáticos: hogar, personas, niños, comunidades y choques, además de los módulos de activos y gasto. El identificador de hogar cambia de nombre entre olas (`consecutivo`→`llave`→`llave_n16`). Para los análisis realizados en esta tesis, se usan exclusivamente coincidencias uno a uno de este identificador entre olas consecutivas, excluyendo los hogares que se dividieron en dos o más sub-hogares (511 casos entre 2010–2013 y 1,190 entre 2013–2016, ver Tabla 6), para no hacer supuestos de un mapeo arbitrario entre sub-hogares.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta (más de 4.000 columnas originales en total). La auditoría tuvo cuatro capas, replicadas de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal `¿??`" en lugar de vocales acentuadas y la letra ñ, reconstruidos por coincidencia de patrón dentro de un vocabulario cerrado por columna, con rescate adicional contra los diccionarios en PDF de la encuesta para los casos ambiguos); (ii) clasificación exhaustiva de cada columna según su cobertura en las tres olas (candidata al modelo, casi vacía, ausente en alguna ola, o identificador); (iii) búsqueda de columnas renombradas entre olas que la clasificación automática por nombre pudiera haber pasado por alto; y (iv) verificación explícita, para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro genuina (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información evitable. Esta auditoría, y las decisiones de inclusión o exclusión de cada variable derivadas de ella, están documentadas íntegramente en el repositorio del proyecto (`docs/decisions.md` y `docs/variable_audit/`).

El resultado es un panel hogar x ola consolidado de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas, que combinan las covariables construidas a partir de los módulos con las variables monetarias (ingreso y gasto per cápita del hogar,

nominal y real, y brecha frente a la línea de pobreza). Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas explícitas y documentadas según el tipo de variable: conteos/proporciones para composición demográfica, conteo de .a1 menos unoquando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano disponible (ej.nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar cuando la literatura lo usa como proxy estándar. Las tasas de mercado laboral se calculan restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

3.2. Fuentes geoespaciales

Este trabajo utiliza imágenes de Google Street View disponibles públicamente. Para esto, se usan las coordenadas de los hogares de la ELCA, que se encuentran para consulta de manera estrictamente controlada y restringida por parte de la Universidad de los Andes. Estas imágenes son procesadas con técnicas de visión computacional, a partir de las cuales se extraen variables usando *transfer learning*, metodología que se explica a continuación. Las variables que se extraen de estas imágenes corresponden a indicadores proxy del entorno construido y de calidad del barrio donde viven estos hogares. Al momento de escribir este documento, el pipeline de Google Street View tiene un avance casi total de implementación sobre las tres olas de la ELCA, pero está en proceso de revisión de la anonimización por parte de la universidad.

El pipeline de Google Street View es, deliberadamente, un grupo de variables independientes del usado para la estimación de pobreza monetaria y vulnerabilidad. Su unidad de análisis es la coordenada geográfica del hogar, independiente de las respuestas de estos en la encuesta. Hasta ahora se ha construido: (i) un panel de coordenadas por hogar-ola, con validación de calidad dada por ola (2010 y 2013 traen coordenadas decimales directas y una variable de revisión manual; 2016 requiere reconstruir la coordenada desde componentes grados-minutos-segundos y solo se valida contra un *bounding box* del territorio colombiano, una validación más débil); (ii) un análisis de cobertura de panoramas de la Metadata API de Google Street View en cuatro radios (50, 100, 200 y 500 metros), que documenta una limitación estructural de la API (retorna solo el panorama más cercano, no un listado completo, por lo que las variables de cobertura son indicadores de presencia y no conteos reales); (iii) la descarga reproducible de fotografías formato de (640×640 px) para el panel de hogares con coordenada válida presentes en las tres olas; y (iv) la extracción de *embeddings* de imagen con tres modelos preentrenados sin *fine-tuning* (VGG-19 y ResNet-50

sobre ImageNet, y ResNet-50 sobre Places365, este último especialmente relevante para escenas urbanas), extracción de *embeddings* CLIP y de segmentación semántica con SAM 3. La agregación de estas variables de cada imagen a nivel hogar×ola, y su integración al dataset consolidado de la Sección 3.1, es la tarea inmediatamente siguiente en la agenda de este proyecto y no está reflejada en los resultados de la Sección 5.

3.2.1. Cobertura, calidad y limitaciones de las imágenes de Google Street View

Esta subsección describe, con estadísticas obtenidas directamente de los archivos entregados por el pipeline de Google Street View (`consultas_final.csv`, `descargas_final.csv` y `embeddings_unidos_anonimizado.parquet`, en `data/processed/embeddings/`), qué información se obtuvo, cómo se distribuye entre hogares y olas, y qué limitaciones tiene. El análisis completo, reproducible desde estos tres archivos, está en el script `03f_analisis_calidad_imagenes_gsv.py`, dentro de la carpeta del pipeline de Google Street View en el repositorio; esta sección resume sus resultados. Es importante notar que los reportes de texto generados en corridas anteriores del pipeline (p. ej. `reporte_cobertura_gsv.txt`) usan radios de búsqueda distintos a los de la corrida final y no deben tomarse como referencia; las cifras que siguen provienen exclusivamente de los archivos “_final” vigentes.

Embudo de consulta y descarga, por ola. La consulta a la GSV Metadata API se hace a nivel de `consecutivo` (hogar base de 2010), no de `llave` u `llave_n16`: cuando un hogar se divide en sub-hogares, todos comparten la coordenada del hogar padre en la ola anterior a la división (Sección 3.1), por lo que consultarlos por separado sería redundante. Esto hace que el universo de hogares consultados en Street View (9,853 / 8,729 / 8,086 `consecutivo` únicos en 2010, 2013 y 2016) sea menor que el número de observaciones del panel ELCA reportado en la Sección 3.1 (9,853 / 9,261 / 8,818), que sí cuenta cada sub-hogar por separado. La Tabla 1 y la Figura 1 resumen el embudo completo: de los hogares con coordenada válida, entre 72 % y 75 % tiene al menos un panorama de Street View dentro de alguno de los cuatro radios de búsqueda consultados (50, 100, 200 y 500 metros), y –dato relevante para el uso posterior de estas variables– *todo* hogar con panorama disponible terminó con una imagen efectivamente descargada: no hay pérdida entre “tiene panorama” y “tiene imagen”.

Cuadro 1: Cobertura de Google Street View por ola: hogares (**consecutivo** únicos) consultados, con coordenada válida, con panorama disponible (**status=OK** en algún radio) y con imagen efectivamente descargada.

Ola	Consultados	Coord. válida	Con pano.	Con imagen	Cobertura
2010	9,853	9,573	6,927	6,927	72.4 %
2013	8,729	8,429	6,237	6,237	74.0 %
2016	8,086	8,086	6,054	6,054	74.9 %

Nota: “Cobertura” es el porcentaje de hogares con coordenada válida que terminó con imagen descargada. Fuente: `consultas_final.csv` y `descargas_final.csv`.




Figura 1: Embudo de cobertura de Google Street View por ola: hogares consultados, con coordenada válida, con panorama disponible y con imagen descargada.

La cobertura también es marcadamente desigual entre zona urbana y rural: 97.5 % de las observaciones hogar×ola urbanas tienen panorama disponible, frente a solo 43.4 % de las rurales. Esto introduce un sesgo de selección espacial conocido y esperado dado el patrón de cobertura vial de Google (las variables de entorno visual estarán sistemáticamente menos disponibles, y por tanto pesarán menos en el modelo final, para hogares rurales), que debe tenerse presente al interpretar cualquier resultado que use estas variables como predictor.

¿Qué hogares quedan cubiertos en las tres olas? Restringiendo el análisis a los 7,735 hogares presentes en las tres olas dentro de `consultas_final.csv`, solo el 60.5 % (4,678 hogares) tiene imagen en las *tres* olas; 20.0 % (1,550 hogares) no tiene imagen en *ninguna*, y el resto tiene imagen en una o dos olas únicamente (Tabla 2, Figura 2). Se verificó explícitamente que esta brecha se explica por completo por disponibilidad real de panorama cercano (`status=OK` en algún radio) y no por una regla de deduplicación del pipeline que reasignara una misma fotografía a una sola ola: al cruzar, para cada hogar×ola de este subconjunto, si existió algún panorama OK contra si se descargó efectivamente una imagen, la correspondencia es exacta (1 a 1, sin excepciones). En otras palabras, un hogar que aparece en las tres olas de la ELCA puede legítimamente carecer de variable de entorno visual en una o dos de ellas porque Google Street View, sencillamente, no tiene cobertura en ese punto para ese momento de la consulta.

Cuadro 2: Patrón de cobertura fotográfica dentro del panel de 7,735 hogares presentes en las tres olas de la ELCA.

Combinación de olas con imagen	Hogares	%
2010 + 2013 + 2016	4,678	60.5 %
Ninguna ola	1,550	20.0 %
2013 + 2016	559	7.2 %
Solo 2016	277	3.6 %
Solo 2010	235	3.0 %
2010 + 2016	234	3.0 %
Solo 2013	131	1.7 %
2010 + 2013	71	0.9 %




Figura 2: Patrón de cobertura fotográfica por combinación de olas, dentro del panel de hogares presentes en las tres olas de la ELCA.

Desfase temporal entre la fecha de la foto y la ola encuestada — limitación central. La fecha de captura de los panoramas de Street View descargados va de 2012 a 2026, con una mediana de 2023 (Figura 3); es decir, la mitad de las imágenes usadas para caracterizar el entorno de un hogar fueron tomadas siete años o más *después* de la ola más reciente de la ELCA (2016), y muchas más de una década después de la ola que dicen representar. El pipeline (`01_analisis_cobertura_gsv.py`) define en su código actual una ventana temporal de elegibilidad por ola (foto de año ≤ 2010 para la ola 2010, 2011–2013 para 2013, 2014–2016 para 2016), pero al contrastar esa regla contra las imágenes efectivamente entregadas (Tabla 3) se encuentra que 93.0 % de ellas cae fuera de esa ventana —para la ola 2010, prácticamente 0 %, porque la cobertura histórica de Street View con fecha verificable en Colombia es casi inexistente antes de 2012—. Esto indica que los datos finales entregados no se generaron aplicando ese filtro de elegibilidad temporal (sí está en el código del repositorio, pero no se refleja en el resultado final), y, de forma independiente del origen de esa discrepancia, confirma que la mayoría de las variables visuales de esta tesis describen el entorno construido *actual* u observado en años recientes, no el entorno en el momento de la encuesta. Para un ejercicio que busca predecir transiciones a la pobreza a partir del entorno físico contemporáneo a la ola, este desfase es una limitación de validez que debe declararse explícitamente y tenerse en cuenta al interpretar cualquier coeficiente o importancia de variable asociada a estas covariables: una asociación entre una variable visual y pobreza en la ola t puede reflejar en parte condiciones del entorno posteriores a t , no solo contemporáneas.

Cuadro 3: Contraste entre la fecha real de captura del panorama y la ventana temporal que el código del pipeline define como elegible para cada ola.

Ola	Imágenes	Dentro de ventana	%
2010	7,488	0	0.0 %
2013	6,788	939	13.8 %
2016	6,659	523	7.9 %




Figura 3: Año de captura de las fotos descargadas frente al año de la ola encuestada (línea roja), por ola.

Duplicación de fotografías entre hogares. De las 20,935 imágenes con embedding extraído, solo 12,963 (61.9 %) son fotografías físicamente distintas (mismo panorama y mismo ángulo de cámara); el 45.4 % restante de las observaciones hogar×ola comparte su fotografía –y por tanto su embedding– con al menos otra observación, típicamente porque ambos hogares tienen como panorama más cercano el mismo punto de Street View. En el caso más extremo, una sola fotografía queda asignada a 21 observaciones hogar×ola distintas (Tabla 4, Figura 4). Esto no es un error de construcción del pipeline –es la consecuencia esperable de la limitación ya documentada de la Metadata API, que solo devuelve el panorama más cercano– pero sí implica que una fracción importante de las observaciones no aporta información visual independiente: dos hogares con la misma fotografía tendrán, necesariamente, el mismo valor en cualquier variable derivada de la imagen, lo que reduce la variación efectiva disponible para el modelo por debajo de lo que sugiere el conteo bruto de 20,935 imágenes.

Cuadro 4: Duplicación de fotografías entre observaciones hogar×ola.

Concepto	N	%
Observaciones hogar×ola con imagen	20,935	100.0 %
Fotografías físicamente distintas	12,963	61.9 %
Observaciones con foto compartida (repetida)	9,509	45.4 %




Figura 4: Número de observaciones hogar×ola que comparten cada fotografía física distinta (escala logarítmica en el eje vertical).

Adicionalmente, dentro de un mismo **consecutivo** y ola puede haber más de una imagen (hasta 5) cuando el hogar se dividió en sub-hogares con coordenadas propias; en promedio cada hogar con al menos una imagen tiene 2.6 imágenes contando las tres olas (mediana 3, máximo 9). La distancia entre la coordenada del hogar y el panorama utilizado tiene mediana de 15.9 metros pero cola larga (percentil 90 de 256.9 metros, máximo 926.2 metros): para ese 10 % de casos más alejados, la fotografía puede corresponder a un segmento de calle distinto al frente real del hogar (por ejemplo, una vía principal cercana en vez de la calle interna).

Otras limitaciones e inconsistencias de datos documentadas. La auditoría de estos archivos encontró además: (i) 7 filas de `descargas_final.csv` —todas correspondientes a descargas fallidas, sin efecto sobre las imágenes usadas— con comas sin comillar en el mensaje de error, lo que rompe el parser por defecto de **pandas** y probablemente el de Stata/R si se usa ese archivo sin cuidado; (ii) el mismo campo de error muestra indicios

de doble codificación de caracteres (*mojibake*); (iii) 4.6 % de las observaciones de 2016 no tienen *llave* (identificador de panel 2013) pese a no ser hogares de la ola base, posiblemente sub-hogares nuevos sin contraparte directa en 2013, que debe verificarse antes de fusionar con el panel principal de la Sección 3.1; y (iv) los tres radios de búsqueda documentados en el código del repositorio, en el reporte de una corrida anterior, y en los datos finalmente entregados no coinciden entre sí, lo que confirma que los reportes de texto históricos de `data/processed/embeddings/` no deben citarse como fuente y que la única fuente autoritativa son los archivos “_final”. Ninguna de estas inconsistencias afecta las cifras de cobertura reportadas arriba (que se calcularon depurando explícitamente las filas corruptas), pero se documentan aquí porque condicionan cómo debe leerse y reutilizarse esta base en las siguientes etapas del proyecto.

3.2.2. Transfer learning y modelos de extracción de variables visuales

Esta subsección explica, qué es el *transfer learning* y qué hace cada uno de los modelos usados para convertir una fotografía de Google Street View en información numérica utilizable en un modelo estadístico.

¿Qué es el *transfer learning*? Una red neuronal convolucional, que es el tipo de modelo usado para procesar imágenes, aprende a reconocer patrones visuales (bordes, texturas, formas, objetos completos) a partir de la estimación de una probabilidad de dichos patrones de pertenecer a una clase específica, a una etiqueta. En la práctica, esto significa mostrándole millones de fotografías ya etiquetadas y ajustando internamente millones de parámetros numéricos hasta que aprende a distinguir, por ejemplo, un árbol de un carro. Entrenar una red así desde cero para esta tesis –con fotografías de fachadas de vivienda en Colombia– sería inviable: requeriría millones de fotos etiquetadas manualmente y semanas de cómputo especializado, recursos que no están disponibles para una investigación de este tipo.

El *transfer learning* (“aprendizaje por transferencia”) resuelve este problema reutilizando una red que *ya* fue entrenada por otros investigadores sobre un problema distinto pero relacionado, por ejemplo, reconocer 1.000 categorías de objetos cotidianos en millones de fotos de internet, y aprovechando lo que esa red ya “sabe ver” sin volver a entrenarla. En concreto, se le muestra a la red ya entrenada cada fotografía de la ELCA y se le pide, no la clasificación final (“esto es un árbol”), sino la representación numérica interna que la red construyó justo antes de tomar esa decisión, un vector de unos pocos miles de números, llamado *embedding*. Ese vector no es interpretable número por número, pero funciona como una huella digital compacta de lo que hay en la imagen: dos fotos que se *parecen* visualmente (misma textura de fachada, mismo tipo de calle, vegetación similar) van a tener *embeddings* numéricamente parecidos, aunque nunca se le haya enseñado a la red el

concepto de “pobreza” o “calidad del barrio”. Es esa propiedad –similitud visual se traduce en similitud numérica– la que permite usar el *embedding* como insumo (covariable) de los modelos predictivos de la Sección 4.2, en vez de la imagen cruda.

Los tres modelos usados en esta tesis se dejan “congelados” –sin reentrenarlos ni ajustarlos con fotos colombianas (*sin fine-tuning*)–, lo cual es menos demandante computacionalmente, pero tiene una limitación importante que se discute más abajo: la red ve las fotos de la ELCA con los mismos “ojos” con que fue entrenada originalmente, que no necesariamente están calibrados para el contexto colombiano. En otras palabras, la red puede no reconocer bien patrones visuales que son relevantes para la pobreza en Colombia, como asentamientos informales o tipologías constructivas propias de zonas rurales, porque nunca los vio en su entrenamiento original.

VGG-19 (entrenada sobre ImageNet). ImageNet es una base de datos de referencia en visión computacional con más de un millón de fotos etiquetadas en 1.000 categorías de objetos (animales, vehículos, muebles, utensilios, etc.). VGG-19 es una de las arquitecturas más influyentes entrenadas sobre esa base: apila 19 capas de procesamiento, cada una aplicando filtros simples y uniformes (ventanas de 3×3 píxeles) que, en conjunto, van desde detectar bordes y texturas simples en las primeras capas hasta reconocer objetos completos en las últimas. El *embedding* usado es la salida de la penúltima capa, con 4.096 números por imagen. Tiene como ventaja que es una arquitectura simple y ampliamente validada en la literatura, lo que facilita comparar resultados con otros estudios. Su principal desventaja es que es una arquitectura relativamente pesada (más de 140 millones de parámetros) y antigua (2014) frente a las alternativas siguientes. Adicionalmente, al estar entrenada para reconocer *objetos* discretos (un perro, una silla), su noción de “similitud visual” está sesgada hacia la presencia de objetos reconocibles y no hacia el paisaje urbano como un todo (una calle pavimentada frente a una sin pavimentar no es una distinción que ImageNet le enseñó a valorar); y su *embedding* de 4.096 números es grande frente al tamaño de la muestra de hogares de esta tesis ($n \approx 3.000$), lo que puede dificultar su uso estadístico directo sin alguna reducción de dimensionalidad.

ResNet-50 (entrenada sobre ImageNet). Misma base de datos de entrenamiento que VGG-19 (ImageNet), pero con una arquitectura más moderna (2015) que resuelve un problema técnico real de las redes muy profundas: a medida que se apilan más capas, la señal de aprendizaje se “diluye” y la red deja de mejorar o incluso empeora. ResNet introduce “conexiones residuales” –atajos que le permiten a la información saltarse capas cuando no aportan nada nuevo– lo que permite entrenar redes de 50 capas (de ahí el

nombre) de forma estable y con mejor precisión que VGG-19, usando además muchos menos parámetros (25 millones frente a 140 millones). El *embedding* usado tiene 2.048 números por imagen. Su principal ventaja frente a VGG-19 es que es más preciso, más liviano computacionalmente, y un *embedding* de menor dimensión, por lo que es más manejable estadísticamente. **Limitación:** comparte con VGG-19 el mismo sesgo hacia el reconocimiento de objetos discretos en vez de escenas completas, por estar entrenada sobre la misma base de datos.

ResNet-50 (entrenada sobre Places365). Misma arquitectura que la anterior, pero entrenada sobre una base de datos distinta, Places365, con 1,8 millones de fotos etiquetadas en 365 categorías de *escenas*, no objetos individuales, como “calle residencial”, “zona industrial”, “mercado al aire libre” o “autopista”. Esta diferencia es la más relevante de las tres para esta tesis: una fotografía de fachada de vivienda es, ante todo, una escena urbana completa, no un objeto aislado, por lo que un modelo entrenado para distinguir *tipos de lugar* está más alineado conceptualmente con lo que se busca medir –calidad y características del entorno construido, que uno entrenado para distinguir, por ejemplo, perros de gatos. Su mayor ventaja es la pertinencia semántica para el problema de esta tesis, sin costo computacional adicional frente a la versión ImageNet (misma arquitectura, mismo tamaño de *embedding*). Por su lado, su principal desventaja es que las 365 categorías de Places365 fueron definidas y etiquetadas mayoritariamente sobre fotografías de Estados Unidos y Europa; es una base de datos de dominio distinto al colombiano, y no es evidente que sus categorías o los patrones visuales que la red aprendió a asociar con ellas capturen bien fenómenos específicos del contexto local, como asentamientos informales o tipologías propias de zonas rurales colombianas, este es el mismo riesgo de generalización entre contextos documentado por Usmanova et al. (2022) para modelos de aprendizaje automático en general (Sección 2.2)–.

CLIP y SAM 3. CLIP (*Contrastive Language-Image Pretraining*) es un modelo entrenado no para clasificar imágenes en una lista fija de categorías, sino para relacionar imágenes con descripciones de texto libre. Esta red ^aaprendió^a partir de cientos de millones de pares: fotos y su descripción, tomados de internet. Es decir, a partir ubicar imágenes y frases en un mismo espacio numérico compartido. Esto permitiría, por ejemplo, buscar directamente qué tan bien una fotografía coincide con una descripción como “una calle sin pavimentar con viviendas de materiales precarios”, sin depender de una lista cerrada de categorías como las de ImageNet o Places365. Esta flexibilidad es relevante para capturar nociones de vulnerabilidad del entorno que no encajan naturalmente en ninguna categoría

predefinida. SAM 3 (*Segment Anything Model*) resuelve un problema distinto: en vez de resumir toda la imagen en un único vector de números, identifica y delinea los objetos y regiones individuales dentro de ella (la acera, un vehículo, la fachada, la vegetación), lo que permitiría construir variables directamente interpretables, como el porcentaje del área de la imagen cubierta por pavimento o por zonas verdes, en lugar de depender de un *embedding* opaco. Ninguno de los dos aporta todavía resultados a esta tesis y es la única parte que no ha sido implementada aún.

3.3. Estadísticas descriptivas

La Tabla 5 resume la cobertura de covariables por módulo en el dataset consolidado. Los módulos de Hogar, Personas, Comunidades y Choques cubren la totalidad del panel (27,932 observaciones); el módulo de Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, y por eso su cobertura efectiva es menor sin que ello represente un problema de calidad del dato (ver discusión de *missingness* estructural en la Sección 4.4).

Cuadro 5: Cobertura de covariables por módulo en el dataset consolidado

Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (%) del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	22	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría (Sección 3.1); “usadas en el modelo” es el subconjunto final tras la construcción de *features*, documentado columna por columna en `docs/decisions.md`.
Fuente: cálculos propios con base en ELCA 2010, 2013, 2016.

Las matrices de transición de pobreza (Tabla 6, Sección 5.1) constituyen la estadística descriptiva central de la variable de resultado y se presentan en la Sección de Resultados junto con su interpretación.

4. Estrategia empírica

4.1. Construcción de la variable de resultado

Siguiendo a López-Calva y Ortiz-Juárez (2011, 2014), se construyen matrices de transición de pobreza monetaria cruzando el estado de pobreza de un hogar en la ola inicial t (filas) contra su estado en la ola siguiente $t + 1$ (columnas), usando el ingreso per cápita del hogar contra la línea de pobreza (LP) oficial del DANE, específica por año y zona (urbana/rural). El análisis empírico se restringe a la submuestra de hogares que se encuentran por encima de la LP en el periodo inicial t . En otras palabras, un hogar que ya es pobre no puede “caer” en pobreza, esa corresponde a la categoría *siempre pobre*, no *entra en pobreza*. Sobre esta población se define la variable dependiente binaria

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

y el objetivo es estimar la probabilidad condicional de caer en pobreza en el periodo siguiente dada la información observada en t (Ecuación 2). El emparejamiento de hogares entre olas usa exclusivamente coincidencias uno a uno del identificador de hogar (Sección 3.1); los hogares que se dividieron entre olas se excluyen de la construcción de la variable de resultado por no tener un estado inicial y final únicos. Las matrices de transición resultantes, su interpretación, y los cinco ejercicios de robustez realizados sobre esta construcción (ponderación muestral, especificación del ingreso, sensibilidad al umbral de pobreza, atrición del panel) se presentan en la Sección 5.1.

4.2. Especificación de modelos

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1) y $F(\cdot)$ es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se estiman y comparan cinco algoritmos, agrupados en dos familias según cómo tratan las categóricas y los datos faltantes (Sección 4.4):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla (l_1_ratio) se eligen

por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge puro. Es el algoritmo designado como referencia por ser interpretable, con coeficientes de signo económicamente interpretable, y por servir de punto de comparación antes de justificar el uso de un modelo más complejo.

- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad, y uno de los más usados en la literatura de focalización de pobreza (McBride & Nichols, 2018)–, que difieren en el algoritmo de construcción del histograma de particiones (*level-wise* en XGBoost y HistGradientBoosting, *leaf-wise* en LightGBM) y en el mecanismo de regularización. Las tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding* (Sección 4.4).

Para evaluar el aporte relativo del nivel de ingreso/gasto del hogar –el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, se estima cada uno de los cinco algoritmos bajo dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante por lo que se mantiene constante a lo largo del tiempo; el **Modelo B** excluye estas cuatro columnas y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad). Este ejercicio, diez modelos en total (cinco algoritmos por dos especificaciones) establece además el marco de referencia frente al cual se evaluará, en una etapa posterior de este proyecto, si las variables geoespaciales aportan más donde la brecha a la LP ya no distingue bien (hogares cerca del umbral) que en general.

4.3. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado

en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, solo existe la ola base al momento de predecir, y es, siguiendo a McBride y Nichols (2018), la validación más exigente para un modelo de este tipo porque prueba generalización ante un régimen económico distinto al de entrenamiento. El ajuste de hiperparámetros de cada algoritmo (mediante `RandomizedSearchCV`, 15 combinaciones aleatorias, validación cruzada estratificada de 3 particiones, optimizando AUC-ROC) se realiza estrictamente dentro del periodo de entrenamiento (2010 a 2013); el conjunto de prueba (2013 a 2016) no se toca hasta la evaluación final reportada en la Sección 5.2. Como ejercicios de robustez adicionales, planeados pero aún no ejecutados, se contempla invertir los roles de entrenamiento y prueba (*backtest*) y agrupar ambas transiciones con validación cruzada agrupada por hogar (Sección 6.3).

El desempeño se reporta mediante AUC-ROC como métrica principal, principalmente porque no depende de un umbral de clasificación arbitrario, además, recall, precision y F1 como métricas de referencia al umbral de clasificación elegido (Sección 4.4), junto con la matriz de confusión completa. El foco del análisis está en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo a partir de diferencias de AUC-ROC que, como se documenta en la Sección 5.2, resultan pequeñas frente a la variabilidad esperable por aleatoriedad del ajuste.

4.4. Tratamiento del desbalance de clases

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4% (Tabla 6), un desbalance moderado que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.

Un hallazgo metodológico relevante de este ejercicio: en XGBoost y en LightGBM (Modelo B), la estrategia “sin ajuste” ganó la comparación por una diferencia de AUC-ROC frente a la reponderación de apenas 0.001 (estadísticamente indistinguible), pero el modelo

resultante, sin corregir el desbalance de clases, produjo probabilidades tan comprimidas hacia valores bajos que casi ninguna observación cruzaba el umbral convencional de 0.5 (recall de 3%–4% en XGBoost, con precision superior a 60%: el modelo ordenaba razonablemente bien los hogares por riesgo, pero era inútil en la práctica al umbral estándar). Esto ilustra que el umbral 0.5 es arbitrario cuando la clase positiva no es 50% de la muestra, y que distintas estrategias de balanceo calibran las probabilidades de forma distinta, por lo que comparar recall/precision/F1 a un umbral fijo entre estrategias no es una comparación válida. La solución adoptada fue elegir el umbral de clasificación de cada modelo por validación cruzada (maximizando F1 sobre las probabilidades *out-of-fold*) en lugar de fijarlo en 0.5 –el AUC-ROC, que no depende de umbral, sigue siendo el criterio que decide la estrategia de balanceo y los hiperparámetros; el umbral solo determina cómo se reportan las métricas restantes.

Para los algoritmos sin soporte de datos faltantes (regresión logística y Random Forest), la imputación de valores faltantes, que en esta base de datos son mayoritariamente por la estructura de la encuesta, es decir, causados por preguntas filtro del cuestionario (por ejemplo, el monto de una ayuda recibida no se pregunta a quien respondió que no recibió ninguna)– usa sistemáticamente el valor 0 combinado con una columna indicadora binaria de faltante por variable. Esta elección evita que la mediana –calculada únicamente sobre quienes pasaron el filtro y respondieron– le asigne a los hogares excluidos por el filtro un valor “típico” que en realidad no tienen, y tiene además la propiedad de que, en un modelo lineal, el relleno no aporta ninguna contribución a la predicción más allá de la que capture el propio indicador de faltante. Las variables categóricas se imputan con una categoría explícita “Sin dato” en vez de la moda, para no disfrazar la ausencia estructural como el valor más común. XGBoost, LightGBM y HistGradientBoosting no requieren esta imputación: manejan los datos faltantes de forma nativa en la partición de los árboles, lo que convierte el propio patrón de *missingness* en una señal explotable por el modelo (por ejemplo, la ausencia de datos de vacunación infantil ya codifica indirectamente que el hogar no tiene hijos pequeños) en vez de forzar un supuesto de imputación potencialmente sesgado.

4.5. Importancia de variables e interpretabilidad

Para cada modelo se reporta una medida de importancia de variables acorde a su naturaleza: los coeficientes estandarizados (con signo) de la regresión logística; la importancia por reducción de impureza (`feature_importances_`) de Random Forest, XGBoost y LightGBM; y la importancia por permutación (*permutation importance*, AUC-ROC sobre el conjunto de prueba, 10 repeticiones) de HistGradientBoosting, más costosa computa-

cionalmente pero más robusta a la correlación entre covariables que la importancia basada en impureza. La comparación de estas listas de variables más importantes entre el Modelo A y el Modelo B (Sección 5.2) es la primera aproximación a la pregunta de qué información no monetaria es más predictiva de la transición a la pobreza, antes de la incorporación de las variables geoespaciales (Sección 6.3). El uso de valores SHAP para una descomposición más fina y comparable entre algoritmos, contemplado en la propuesta original de este trabajo, queda como tarea pendiente.

5. Resultados

5.1. Dinámica de transiciones a la pobreza en la ELCO

Esta sección analiza la dinámica de la pobreza monetaria en el panel ELCA 2010–2013–2016 en dos niveles. Primero, la incidencia y las matrices de transición entre olas consecutivas, siguiendo la metodología oficial del DANE (ingreso per cápita nominal del hogar contra la línea de pobreza –LP– y la línea de pobreza extrema –LI– nominales de su año y zona) y la clasificación en cuatro categorías de transición de López-Calva y Ortiz-Juárez (2014) (nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza). Segundo, un conjunto de cinco ejercicios de robustez diseñados específicamente para evaluar qué tan sensible es la variable de resultado de esta tesis –la transición a la pobreza– a decisiones metodológicas de la construcción del ingreso y a la definición del panel. Los detalles de construcción de cada variable, verificados contra los diccionarios de la encuesta y los archivos crudos, están documentados exhaustivamente en el repositorio del proyecto (docs/decisions.md); aquí se presentan los resultados y su interpretación para la tesis.

5.1.1. Incidencia de pobreza y matrices de transición

La Figura 5 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más alta que la de ingreso en las tres olas (47.6 %, 40.9 % y 33.4 % en sentido estricto es más *baja*, no más alta, que la de ingreso en los tres puntos del panel: la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto). Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no es un artefacto

de la medida de bienestar elegida.




Figura 5: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 6 descompone la pobreza por ingreso en sus tres componentes de Foster-Greer-Thorbecke: incidencia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2% a 22.0% y a 16.1% entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3% a 12.4% y a 8.3%. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 6: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

Las matrices de transición cruzan el estado de pobreza inicial (filas) contra el estado final (columnas), en porcentaje de fila, únicamente para hogares con emparejamiento uno a uno vía **consecutivo** entre olas (los hogares que se dividen entre una ola y la siguiente –511 casos en 2010–2013 y 1,190 en 2013–2016, contando ambos lados del emparejamiento– se excluyen de la matriz por no tener un estado inicial y final inequívoco). La Tabla 6 presenta ambas matrices.

Cuadro 6: Matrices de transición de pobreza monetaria por ingreso (% de fila, panel emparejado 1 a 1)

Periodo	Estado inicial	No pobre (final)	Pobre (final)
2010 → 2013 ($n = 8,218$)	No pobre	76.6 %	23.4 %
	Pobre	29.7 %	70.3 %
2013 → 2016 ($n = 6,911$)	No pobre	80.1 %	19.9 %
	Pobre	38.2 %	61.8 %

Nota: n = hogares con emparejamiento 1 a 1; excluye 511 (2010–2013) y 1,190 (2013–2016) casos de hogares que se dividieron entre olas. Fuente: cálculos propios con base en ELCA 2010, 2013, 2016.

Dos patrones se destacan. Primero, la persistencia en la pobreza es alta pero decrece con el tiempo: 70.3 % de los hogares pobres en 2010 seguían pobres en 2013, y esa persistencia

baja a 61.8 % entre 2013 y 2016 –es decir, la probabilidad de salir de la pobreza condicional en ser pobre aumentó de 29.7 % a 38.2 % entre periodos–. Segundo, la persistencia en la no pobreza también mejora (de 76.6 % a 80.1 %), y el riesgo de entrar en pobreza condicional en no ser pobre cae de 23.4 % a 19.9 %. Ambos movimientos son consistentes con la caída de la incidencia agregada documentada en la Figura 5.

La Figura 7 traduce estas matrices a las cuatro categorías de López-Calva y Ortiz-Juárez (2014). En 2010–2013, 43.9 % de los hogares del panel emparejado son *siempre pobres*, 28.8 % *nunca pobres*, 18.6 % *salen* de la pobreza y 8.8 % *entran* en ella. En 2013–2016 el panorama cambia de categoría dominante: *nunca pobre* pasa a ser la categoría más grande (37.0 %, superando por primera vez a *siempre pobre*, que cae a 33.3 %), sale 20.6 % y entra 9.2 %. En los dos periodos la tasa de salida casi duplica a la tasa de entrada, consistente con una economía en la que la pobreza monetaria se redujo de manera neta, no solo se redistribuyó entre hogares.




Figura 7: Distribución de categorías de transición de pobreza monetaria (Lopez-Calva y Ortiz-Juarez, 2014) entre olas consecutivas.

5.1.2. Ejercicios de robustez

La variable de interés de esta tesis es precisamente la transición a la pobreza, por lo que conviene preguntarse qué tan sensibles son las cifras de la Sección 5.1.1 a decisiones de construcción del ingreso, a la representatividad muestral, y al error de medición cerca del umbral de pobreza. Se implementaron cinco ejercicios de robustez con este propósito.

Ponderación muestral. Ninguno de los resultados anteriores usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y

verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (*fexhog*, *fexhog_2013*, ambos transversales, y *fexhog_2010*, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % $\rightarrow$ 60.4 % en 2010, 52.4 % $\rightarrow$ 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % $\rightarrow$ 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 % a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorrateados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de esta tesis. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010 $\rightarrow$ 2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o

ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se repitieron las matrices de transición (Figura 8). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % ($LP - 10\%$) y 49.1 % ($LP + 10\%$) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 8: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 9 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 9: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo consecutivo no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 10). La atrición es de 11.4 % en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). La consistencia entre periodos es tranquilizadora en términos de diseño muestral, pero no se investigó si esta atrición es aleatoria o está concentrada en algún perfil de hogar (rural, más pobre, más móvil) —una limitación que se retoma más abajo.




Figura 10: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

5.2. Desempeño comparativo de modelos

La Tabla 7 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.3 y 4.4).

Cuadro 7: Desempeño de los cinco algoritmos, holdout temporal (train 2010→2013, test 2013→2016). Media $\pm$ intervalo de confianza al 95 % sobre 5 semillas del ajuste final

Algoritmo	Espec.	Balanceo	Umbral	AUC-ROC	IC95 %	Recall	F1
Random Forest	A	balanced	0.48	0.764	[0.763, 0.764]	0.732	0.473
XGBoost	A	ninguno	0.26	0.763	[0.761, 0.764]	0.710	0.467
HistGradientBoosting	A	ninguno	0.23	0.759	[0.759, 0.759]	0.741	0.462
LightGBM	A	balanced	0.53	0.758	[0.758, 0.758]	0.681	0.466
Logística regularizada	A	balanced	0.46	0.747	[0.747, 0.747]	0.752	0.438
HistGradientBoosting	B	balanced	0.47	0.740	[0.740, 0.740]	0.674	0.445
Logística regularizada	B	balanced	0.48	0.739	[0.739, 0.739]	0.697	0.435
Random Forest	B	balanced	0.48	0.739	[0.738, 0.740]	0.675	0.442
XGBoost	B	ninguno	0.27	0.734	[0.732, 0.735]	0.665	0.442
LightGBM	B	ninguno	0.25	0.727	[0.727, 0.727]	0.692	0.436

Nota: umbral elegido por validación cruzada maximizando F1 en cada semilla (Sección 4.4), no fijo en 0.5; se reporta el promedio de las 5 semillas. El IC95 % de AUC-ROC captura únicamente la aleatoriedad propia del procedimiento de ajuste (remuestreo interno del algoritmo) sobre el mismo conjunto de prueba, con balanceo e hiperparámetros ya fijados (Sección 5.2) – es nulo o casi nulo para HistGradientBoosting, LightGBM y la regresión logística porque, con los hiperparámetros elegidos, su ajuste es determinístico dado el conjunto de entrenamiento. Fuente: cálculos propios, `data/processed/benchmark_resultados/registro_modelos.csv`.




Figura 11: AUC-ROC medio (5 semillas) de los cinco algoritmos por especificación, conjunto de prueba 2013→2016. Barras de error: IC95 %.

Tres patrones se destacan. Primero, los cinco algoritmos quedan en un rango relativamente estrecho de AUC-ROC (0.727–0.764 en total, apenas 0.747–0.764 dentro del Modelo A), con los tres *gradient boosting* y Random Forest apenas por encima de la regresión logística regularizada (Figura 11). Reentrenar el modelo final de cada algoritmo con 5 semillas aleatorias (Sección 4.4) –manteniendo fijos el balanceo y los hiperparámetros ya elegidos– muestra que HistGradientBoosting, LightGBM y la regresión logística son prácticamente determinísticos bajo los hiperparámetros elegidos (desviación estándar del AUC-ROC ≈ 0 entre semillas), mientras que Random Forest y XGBoost sí tienen una variabilidad pequeña pero no nula (desviación estándar de 0.0005 y 0.0011, respectivamente), heredada del remuestreo *bootstrap* y del submuestreo de observaciones/columnas que sus hiperparámetros óptimos activan. Con esa variabilidad, la ventaja de Random Forest (AUC-ROC 0.764) sobre XGBoost (0.763) en el Modelo A es marginal y sus intervalos de confianza casi se traslapan; la de ambos sobre HistGradientBoosting (0.759) es algo más clara. Es importante notar que este intervalo de confianza mide únicamente la aleatoriedad del propio procedimiento de ajuste sobre el mismo conjunto de prueba, no la incertidumbre muestral de la estimación del AUC-ROC en sí –una comparación formal entre algoritmos requeriría una prueba pareada (por ejemplo, de DeLong) sobre las predicciones del mismo conjunto de prueba, no realizada en este documento–. Con esa salvedad, la evidencia sigue sin señalar un algoritmo que domine de forma inequívoca a los demás. Segundo, el ranking cambia según la métrica: la regresión logística tiene el mayor recall del Modelo A (0.752),

seguida de cerca por HistGradientBoosting (0.741), ambos a costa de más falsos positivos, mientras que Random Forest tiene el mayor F1 en ambas especificaciones (0.473 en A, 0.442 en B). Esto sugiere que, más que declarar un “mejor” algoritmo único, la elección final debería depender de las preferencias de la institución que use el modelo para focalización –priorizar recall implica aceptar más errores de inclusión a cambio de menos errores de exclusión–.

Tercero, y más relevante para la pregunta de investigación de esta tesis: la brecha de AUC-ROC entre el Modelo A (con ingreso/gasto) y el Modelo B (sin ellos) es de 0.008 a 0.031 según el algoritmo (mínima en la regresión logística, máxima en LightGBM), mucho menor de lo que predeciría un enfoque de vulnerabilidad puramente monetario (Chaudhuri et al., 2002). Esto indica que las covariables no monetarias –educación, activos del hogar, vivienda, choques, características de la comunidad– capturan una fracción sustancial del poder predictivo que aporta la brecha al umbral de pobreza, no son redundantes con ella. La Figura 12 muestra recall y precision (media, 5 semillas) al umbral elegido para el Modelo A: el patrón de mayor recall en la regresión logística y HistGradientBoosting frente a mayor precision en Random Forest y XGBoost se mantiene incluso tras corregir por el umbral de clasificación.




Figura 12: Recall y precision al umbral de clasificación elegido por validación cruzada, Modelo A (media e IC95 %, 5 semillas).

Las Figuras 13 y 14 muestran las variables más importantes de Random Forest y los mayores coeficientes –en valor absoluto, en unidades estandarizadas– de la regresión logística, ambos para el Modelo A. En Random Forest, el ingreso per cápita real y la

brecha a la LP dominan claramente (consistente con Chaudhuri et al. (2002)), seguidos por el índice de riqueza precalculado de la ELCA (`riqueza_pca_hogar`) y el número de bienes durables del hogar. En la regresión logística, en cambio, el nivel educativo máximo del hogar tiene el mayor coeficiente en valor absoluto, por encima incluso de la brecha a la LP y el ingreso real –con signo negativo, consistente con que más educación reduce la probabilidad de caer en pobreza–, seguido por el número de bienes durables y de servicios públicos del hogar. Esta diferencia entre algoritmos –qué variable “domina” según se mida por reducción de impureza o por magnitud de coeficiente estandarizado– es en sí misma evidencia de que la importancia de variables no es una propiedad única del problema sino que depende parcialmente de cómo cada algoritmo particiona la información, un matiz relevante para la interpretación de resultados de esta naturaleza.




Figura 13: Variables más importantes, Random Forest, Modelo A (reducción de impureza).




Figura 14: Mayores coeficientes en valor absoluto, regresión logística regularizada, Modelo A (unidades estandarizadas).

En el Modelo B (sin ingreso/gasto), tanto Random Forest como la regresión logística ubican el índice de riqueza precalculado y el nivel educativo máximo del hogar entre las dos variables más importantes, seguidos por el número de bienes durables, de servicios públicos y –solo en la regresión logística– la tasa de cotización a pensión del hogar, un proxy de formalidad laboral. Estas variables son consistentes con los determinantes de pobreza documentados en la literatura y no sugieren que el modelo esté capturando relaciones espurias.

5.3. Contribución marginal de las variables geoespaciales

Esta subsección –el corazón de la pregunta de investigación de la tesis– está pendiente de completarse.

5.4. Heterogeneidad territorial

Esta subsección también está pendiente. El diseño contempla reestimar el desempeño de los modelos de la Sección 5.2 por separado para zona urbana y rural, y –si el tamaño de muestra por región lo permite tras la partición temporal ya exigente en observaciones (3,089 hogares no pobres en la base de entrenamiento, Tabla 6)– por región geográfica.

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento reporta el avance de una tesis que busca evaluar si las variables geoespaciales públicas mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos no pobres, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Hasta el momento se ha completado la mitad “base” de esa comparación: la auditoría sistemática y no muestral de los cinco módulos de la ELCA (más de 4.000 columnas originales), la construcción rigurosa de la variable de resultado –transición a la pobreza entre olas, siguiendo el enfoque de López-Calva y Ortiz-Juárez (2011, 2014), con cinco ejercicios de robustez sobre su construcción–, y la estimación y comparación de cinco algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y HistGradientBoosting) bajo dos especificaciones de covariables.

Tres hallazgos se destacan de este avance. Primero, la dinámica de la pobreza en el panel ELCA 2010–2016 muestra una reducción sostenida de la incidencia (de 60.7 % a 42.4 % por ingreso) acompañada de una tasa de entrada a la pobreza –la variable de interés de esta tesis– de 23.4 % entre 2010–2013 y de 19.9 % entre 2013–2016, con una tasa de salida que casi duplica a la de entrada en ambos periodos. Segundo, los cinco algoritmos evaluados alcanzan un desempeño similar entre sí (AUC-ROC entre 0.727 y 0.764, con intervalos de confianza sobre 5 semillas del ajuste final que en la mayoría de los casos son nulos o casi nulos, ver Sección 5.2), sin que ninguno domine claramente a los demás. El patrón ni siquiera es consistente entre especificaciones: en el Modelo A los tres *gradient boosting* y Random Forest superan a la regresión logística regularizada, pero en el Modelo B XGBoost y LightGBM caen por debajo de ella, y solo HistGradientBoosting y Random Forest se mantienen al mismo nivel o por encima. Tercero, y más importante para el diseño de la etapa siguiente de esta tesis, la brecha de desempeño entre el modelo que incluye ingreso/gasto del hogar y el que no los incluye es sorprendentemente pequeña (0.008–0.031 en AUC-ROC según el algoritmo): las covariables no monetarias –educación, activos, vivienda, choques, características de la comunidad– explican una fracción sustancial del poder predictivo que, bajo el enfoque clásico de vulnerabilidad (Chaudhuri et al., 2002), se atribuiría casi exclusivamente al ingreso. Esto sugiere que existe margen real para que fuentes de información adicionales –geoespaciales o de otro tipo– aporten poder predictivo incremental, la pregunta central que este trabajo busca responder en su etapa final.

6.2. Implicaciones para la política pública

Aunque los resultados presentados en este documento son intermedios, ya insinúan implicaciones relevantes para el diseño de sistemas de focalización como el SISBEN. Primero, la evidencia de que las covariables no monetarias tienen un poder predictivo casi comparable al del ingreso sugiere que un sistema de alerta temprana no necesita esperar a observar directamente el ingreso de un hogar –la variable más costosa y menos frecuente de actualizar– para identificar candidatos a la vulnerabilidad; características más fáciles de observar o de actualizar administrativamente (educación, activos del hogar, formalidad laboral) ya capturan buena parte de esa señal. Segundo, la comparación entre algoritmos (Sección 5.2) muestra que la elección del algoritmo correcto depende de la función de pérdida que le importa al hacedor de política: HistGradientBoosting maximiza el recall –relevante si el costo de no detectar un hogar que va a caer en pobreza (error de exclusión) es mucho mayor que el de incluir por error a uno que no cae (error de inclusión)–, mientras que XGBoost y Random Forest ofrecen mejor precisión al mismo nivel de AUC-ROC. Un sistema real debería fijar explícitamente esa preferencia antes de elegir el modelo, en vez de optimizar únicamente por AUC-ROC. Estas implicaciones se profundizarán, y se contrastarán contra el aporte específico de las fuentes geoespaciales, una vez completada la Sección 5.3.

6.3. Limitaciones y agenda de investigación

Por completar la Sección 5.3, la agenda de investigación de esta tesis continúa con la construcción de variables geoespaciales a partir de fuentes públicas, la integración de esas variables al panel ELCA, y la reestimación de los cinco algoritmos bajo las mismas condiciones de validación y balanceo de clases ya descritas. La comparación de desempeño entre el Modelo A (con ingreso/gasto) y el Modelo B (sin ellos) frente a un Modelo C (con variables geoespaciales) permitirá evaluar si estas últimas aportan poder predictivo incremental, y si ese aporte es suficiente para compensar la ausencia de información monetaria directa. La agenda también contempla la reestimación de los modelos por zona urbana/rural y, si el tamaño de muestra lo permite, por región geográfica, para evaluar la robustez territorial de los hallazgos.

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (inf. téc.). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). Assessing Household Vulnerability to Poverty from Cross-Sectional Data. *Columbia University Department of Economics Discussion Papers*, (0102-52).
- Christiaensen, L., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/713600071>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2025). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of*

- Sustainable Development & World Ecology*. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). *Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature* (ADB Working Paper). Asian Development Bank Institute.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*. <https://doi.org/10.1002/jid.3751>
- Hofer, M., Sako, T., Martinez, A. J., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*. <https://doi.org/10.1111/asej.12349>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Economics*, 61(1), 99-111.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juárez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juárez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón, G., Escobar, D., López, F., Pérez, P., & Orozco, J. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>

- Newhouse, D., Merfeld, J., Ramakrishnan, A., Swartz, T., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

B. Detalles de construcción de variables geoespaciales