

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal Colombiana (ELCA)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización en Colombia, como el SISBEN y el Registro Social de Hogares, clasifican a los hogares según su situación actual y no anticipan qué hogares no pobres caerán en pobreza. Este trabajo evalúa si fuentes geospaciales públicas mejoran la predicción de la caída en pobreza, monetaria y multidimensional, frente a usar solo la Encuesta Longitudinal Colombiana (ELCA). Se entrenan modelos con cinco algoritmos de aprendizaje supervisado, con y sin ingreso y gasto del hogar, en las transiciones 2010–2013 del panel, y se evalúan en las de 2013–2016. Los modelos identifican a los vulnerables con una capacidad moderada (AUC-ROC de 0.73 a 0.77) que casi no depende del algoritmo ni del ingreso, y pocas variables de acumulación, como riqueza, educación, activos y vivienda, concentran la señal. Reconocen bien la precariedad, pero no quién caerá: los hogares marcados que no caen también son precarios, el que entra en pobreza se parece más al que acaba de salir que al que nunca fue pobre, y quienes caen reportan más choques posteriores a la predicción. La mayoría de quienes caen vuelve a salir; permanecen los que tenían menos activos financieros y cotización a pensión. La iluminación nocturna, la única fuente con cobertura suficiente, describe bien la geografía de la pobreza, pero no mejora la predicción monetaria cuando hay una encuesta vigente y aporta poco bajo pobreza multidimensional; su valor está en priorizar territorios donde no hay encuesta o está desactualizada, porque cubre todo el país y cambia poco en el tiempo.

Palabras clave: dinámica de la pobreza, aprendizaje automático, luces nocturnas, teledetección, datos de panel, focalización, Colombia.

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juarez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Potenciales Beneficiarios de Programas Sociales (SISBEN) es desde hace casi treinta años el principal instrumento de focalización del gasto social. La actualización de su información ha dependido sobre todo de operativos de barrido cada seis o siete años, lo que genera rezagos: en la evaluación del SISBEN III, el 75 % de la información socioeconómica seguía igual que en su recolección inicial (Pabón & Briceño, 2023). El SISBEN IV busca corregir en parte estas limitaciones: combina el estándar de vida con una presunción de la capacidad de generación de ingresos del hogar y se diseñó para interoperar con registros administrativos (Consejo Nacional de Política Económica y Social, 2016; Pabón & Briceño, 2023). Sobre esa base, el Decreto Ley 812 de 2020 creó el Registro Social de Hogares (RSH), que integra la información del SISBEN IV con 28 bases de datos nacionales y 1,832 territoriales para validarla y actualizarla, y permite por primera vez seguir la evolución de las condiciones de vida de los hogares (Pabón & Briceño, 2023). Aun así, el sistema clasifica a los hogares según su situación y capacidad actuales, y no estima la probabilidad de que un hogar hoy no pobre caiga en pobreza. La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y un ejercicio reciente de aproximación a la vulnerabilidad monetaria en Bogotá mediante paneles sintéticos confirma tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Gaitán, 2023).

Este artículo aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza, monetaria y multidimensional. Este abordaje se diferencia de la mayor parte de la literatura de aprendizaje automático aplicada a la pobreza, que predice la condición actual de un hogar y no su transición futura (Ferdausi et al., 2026; Muñetón-Santa et al., 2022).

La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de fuentes geoespaciales públicas mejora la predicción de caída en pobreza de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del hogar reportadas en encuestas?

Para responderla, el documento construye la variable de resultado que es la transición hacia la pobreza, audita las covariables socioeconómicas disponibles en la ELCA y estima modelos con cinco algoritmos de aprendizaje supervisado (regresión logística regularizada *Elastic Net*, Random Forest, XGBoost, LightGBM y HistGradientBoosting), en dos especificaciones: con y sin ingreso y gasto del hogar, bajo dos definiciones de pobreza, monetaria y multidimensional. Sobre esos modelos evalúa el aporte de cuatro fuentes geoespaciales públicas: la iluminación nocturna DMSP-OLS, el radar ALOS PALSAR, las imágenes Landsat 5 TM y las fotografías de Google Street View. Solo DMSP-OLS tiene datos en la ola de entrenamiento y en la de prueba, por lo que es la fuente de la evaluación principal; las demás se evalúan de forma exploratoria (Sección 3.1).

Los resultados muestran que los modelos identifican a los hogares vulnerables con una capacidad moderada (AUC-ROC de 0.73 a 0.77), similar entre algoritmos y casi igual sin el ingreso del hogar, y que un núcleo pequeño de variables de acumulación concentra la señal. Los modelos reconocen bien la precariedad, pero no quién caerá: los hogares que marcan sin que caigan también son precarios, el hogar vulnerable se parece más al que acaba de salir de la pobreza que al que nunca fue pobre, y quienes efectivamente caen reportan más choques posteriores a la predicción. El límite parece estar en la información disponible y no en el algoritmo. La mayoría de quienes caen en 2013 vuelve a salir antes de 2016; quedan atrapados los que tenían menos activos financieros y menos cotización a pensión. La iluminación nocturna no mejora la predicción cuando hay una encuesta vigente, porque su información ya está contenida en la encuesta, pero es más estable en el tiempo y su pequeño aporte bajo pobreza multidimensional se concentra en zonas rurales, lo que la hace útil para priorizar territorios y como respaldo entre rondas de encuesta. El radar y las imágenes ópticas reproducen el mismo gradiente sin agregar información, y las fotos a nivel de calle, aunque prometedoras, aún tienen poca cobertura. Para la focalización, los resultados sugieren fijar el umbral según el costo del instrumento, activar el apoyo con

choques verificados y graduar con seguimiento a quienes salen de la pobreza.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema que los trabajos previos sobre vulnerabilidad con la ELCA (Hernández & Zuluaga, 2022) no abordan.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje automático aplicada a su predicción. La Sección 3 describe la ELCA, las fuentes geoespaciales y la dinámica de la pobreza en el panel. La Sección 4 detalla la estrategia empírica: construcción de la variable de resultado, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados. La Sección 6 cierra con una síntesis, implicaciones de política, las limitaciones y la agenda de investigación.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria se origina en la variabilidad del consumo del hogar ante choques de ingreso, como la enfermedad de un miembro del hogar o la pérdida de una cosecha por plagas, y aumenta con la volatilidad de su patrimonio. Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo,

muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto para la Kenya rural: en 1994 los hogares enfrentaban en promedio una probabilidad del 39 % de caer en pobreza en el futuro, mayor en las zonas áridas expuestas a la volatilidad de las lluvias, y los choques idiosincráticos también generaban una volatilidad importante del consumo. Los hogares hoy no pobres pero expuestos a esos choques son precisamente los que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010). En la práctica, el enfoque clasifica como vulnerable a un hogar cuando dicha probabilidad supera 0.5, un umbral arbitrario cuya capacidad para anticipar la pobreza observada se ha evaluado poco; Hohberg et al. (2018) la evalúan con curvas ROC en un panel alemán y muestran que un umbral elegido según el objetivo de focalización predice mejor.

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juarez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 4.1 de este artículo. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado de pobreza.

En Colombia, la ausencia de un panel de hogares ha llevado a usar pseudo-paneles, tanto para estudiar trampas de pobreza (Castañeda Castrillón, 2012) como para aproximar la vulnerabilidad (Gaitán, 2023); Gaitán (2023) estima que cerca del 23 % de la población bogotana era vulnerable en 2021. La ELCA, con tres olas de seguimiento a los mismos

hogares, permite superar esa limitación. Con la misma ELCA, Hernández y Zuluaga (2022) estiman la vulnerabilidad a la pobreza multidimensional con el enfoque de pobreza esperada de Chaudhuri et al. (2002) y encuentran que la proporción de hogares vulnerables supera la de pobres, sobre todo en zona rural (70 % frente a 39 %). Este artículo se diferencia en que no infiere la vulnerabilidad de la media y la varianza esperadas del bienestar, sino que predice la transición observada con modelos validados fuera de muestra. Aun así, estos métodos dependen de encuestas detalladas, costosas y de levantamiento infrecuente, lo que motiva explorar fuentes alternativas de datos (Sección 2.3).

2.2. Aprendizaje automático en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su evolución ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar sustancialmente la exactitud fuera de muestra de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando su criterio de exactitud balanceada (BPAC) hasta en 17.5 % frente a los métodos tradicionales. Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2026) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de

hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema: sus modelos alcanzan una exactitud del 96 % e identifican siete variables como los principales factores de la pobreza extrema. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza a la mayor parte de la literatura. En Colombia, Muñetón-Santa et al. (2022) han aplicado aprendizaje automático a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada. Un ejemplo de otro contexto es Burger y van der Laan (2021), que predicen con *gradient boosting* la entrada y la salida de la pobreza al año siguiente a partir de más de 500 variables de registros administrativos de los Países Bajos, y usan valores SHAP para identificar los factores de riesgo; entre los hogares no pobres, el más importante es la propiedad de la vivienda. Sin embargo, ese ejercicio se hace en un país de ingreso alto, con registros administrativos completos y sin fuentes geoespaciales, condiciones muy distintas a las de un país en desarrollo que depende de encuestas.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital: en cinco países africanos, una red neuronal entrenada con imágenes satelitales diurnas, luz nocturna y datos de encuesta explica hasta el 75 % de la variación local del consumo o la riqueza, y predice mejor que la luz nocturna sola. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con exactitudes globales superiores al 82 %. Sin embargo, en regiones pobres y rurales la luz nocturna rinde menos que las imágenes diurnas, porque varía poco entre zonas (Hall et al., 2023).

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran, para un programa de transferencias de emergencia en Togo, que un modelo de aprendizaje automático entrenado con datos de telefonía móvil reduce los errores

de exclusión entre 4 % y 21 % frente a la focalización geográfica, aunque los aumenta frente a un registro social completo. Hall et al. (2023), en una revisión sistemática, documentan que el número de fuentes de datos está entre los factores más asociados con el poder predictivo y que combinar aprendizaje automático y profundo lo aumenta hasta en 15 puntos porcentuales; también encuentran que los estudios que predicen activos físicos superan en 17 puntos a los que predicen variables de flujo como ingreso o consumo, y que el desempeño depende del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que este artículo busca incorporar (Sección 3.1).

Esta evidencia sugiere que combinar variables geoespaciales con encuestas puede mejorar lo que cada fuente logra por separado, sobre todo donde la encuesta es escasa. Sin embargo, ninguno de estos trabajos, ni los pocos que predicen la entrada en pobreza (Burger & van der Laan, 2021; Hohberg et al., 2018), evalúa si las fuentes geoespaciales públicas mejoran esa predicción en un país en desarrollo, con datos longitudinales de encuesta y una partición temporal hacia adelante, un problema que exige una variable de resultado prospectiva, un horizonte explícito entre olas y predictores medidos antes de la transición. Este trabajo busca llenar ese vacío desde un enfoque predictivo y no causal: en política pública la predicción es valiosa aun sin interpretación causal (Kleinberg et al., 2015), porque el objetivo es mejorar la focalización *ex ante*.

3. Datos

3.1. Fuentes de datos

El estudio combina un panel de hogares con información geoespacial pública y gratuita. Qué datos se usan de cada fuente lo decide el diseño de evaluación: los modelos se entrenan en la transición 2010→2013 y se evalúan en 2013→2016, así que toda fuente necesita datos en 2010 y en 2013.

Panel de hogares. La fuente primaria es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares urbanos y rurales en 2010, 2013 y 2016. Se organiza en módulos temáticos (hogar, personas, niños, comunidades, choques, activos y gasto). Las olas de 2019 y 2022, administradas por el DANE, quedan fuera de esta ventana y se dejan como agenda futura. Se excluyen los hogares que se dividieron en dos o más sub-hogares en olas posteriores: 511 en la ventana 2010→2013 y

1,190 en la de 2013→2016 (los 511 anteriores y 679 que se dividieron hacia 2016), para no hacer supuestos sobre su trayectoria. Tras auditar los módulos (codificación de caracteres, cobertura por ola, columnas renombradas y preguntas filtro; Anexo A.9), el resultado es un panel hogar×ola de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas. El panel reúne las covariables de los módulos y las variables monetarias construidas: ingreso y gasto per cápita, nominales y reales, y la brecha frente a la línea de pobreza.

Información geoespacial. El supuesto es que el entorno físico y económico local afecta la vulnerabilidad del hogar de maneras que la encuesta no capta por completo. Se evaluaron siete fuentes (Anexo B.2), agrupadas según lo que miden. La actividad económica y la electrificación del entorno se aproximan con luces nocturnas (DMSP-OLS y VIIRS DNB). La densidad del área construida frente a la vegetación se aproxima con radar (ALOS PALSAR y Sentinel-1) y con reflectancia óptica (Landsat 5 TM y Sentinel-2). La infraestructura cartografiada se aproxima con OpenStreetMap. Además de su nivel, de cada fuente se mide si el entorno se venía densificando o perdiendo cobertura vegetal antes de cada ola (Tabla 24, Anexo B.1). Toda la información se consulta en Google Earth Engine a partir de las coordenadas de los hogares de la ELCA, cuyo acceso es restringido y controlado por la Universidad de los Andes. Sentinel-1, Sentinel-2 y VIIRS DNB empezaron a operar después de 2012, y OpenStreetMap estaba casi vacío en Colombia entre 2010 y 2013. Solo tres fuentes, una por cada tipo de medición, tienen cobertura anterior a 2014: DMSP-OLS cubre el 100 % de los hogares en 2010 y en 2013; ALOS PALSAR cubre 2010 pero no tiene datos entre 2011 y 2014; y Landsat 5 TM cubre solo el 65.5 % de los hogares en 2010, por nubosidad, y dejó de adquirir imágenes útiles antes de 2013. Por eso DMSP-OLS es la fuente de la evaluación principal y las otras dos se usan en una variante complementaria (Sección 3.2). Las imágenes de Google Street View se revisaron solo de forma exploratoria: para las coordenadas de los hogares, no hay fotos anteriores a 2012 y el 61 % de las que se encontraron son de 2023 en adelante (Anexo A.8).

3.2. Cobertura, atrición e inventario del panel

Los módulos de Hogar, Personas y Choques cubren todo el panel; Comunidades cubre entre 92 y 96 %, porque se mide por comunidad y no por hogar, y Niños el 55.4 %, la proporción de hogares con niños de 6 a 9 años. El panel pierde 11.4 % de los hogares entre 2010 y 2013 y otro 11.4 % entre 2013 y 2016 (17.9 % acumulado). La atrición no es aleatoria: se concentra en hogares urbanos (16.2 % frente a 5.8 % de los rurales en 2010–2013) y de estratos altos (Anexo A.10).

Las covariables finales suman 177: 164 de los módulos y 13 monetarias (cobertura y detalle por módulo, tipo y tema en el Anexo A.9). Se descartan los indicadores y las líneas de pobreza y el ingreso y gasto nominales, porque definen la variable de resultado. Con eso, el Modelo A usa 169 variables y el Modelo B, sin ingreso ni gasto, usa 165 (Sección 4.3). A cada especificación se le agregan las variables geoespaciales en dos variantes. La principal agrega las 23 variables de DMSP-OLS y se evalúa en 2013→2016 (Sección 5.3). La complementaria agrega las 127 variables de las tres fuentes (23 de DMSP-OLS, 52 de ALOS PALSAR y 52 de Landsat 5 TM) y se evalúa con validación cruzada dentro de 2010→2013.

3.3. Dinámica de la pobreza en el panel


Esta sección describe los cuatro grupos de la matriz de transición (*nunca pobre, siempre pobre, entra en pobreza y sale de pobreza*), definidos en la Sección 4.1.¹

Los paneles superiores de la Figura 1 traducen la matriz monetaria a flujos (los inferiores hacen lo mismo con la del IPM): en 2010–2013 dominan los *siempre pobres* (43.9 %) sobre los *nunca pobres* (28.8 %); en 2013–2016 el orden se invierte (37.0 % vs. 33.3 %), y en ambos periodos la salida casi duplica la entrada, es decir, la pobreza monetaria se redujo de forma neta, no solo se redistribuyó entre hogares. Bajo pobreza monetaria la persistencia es alta pero decrece: 70.3 % de los pobres en 2010 seguían pobres en 2013, cae a 61.8 % entre 2013 y 2016 (la salida de la pobreza, condicional a ser pobre en la ola base, sube de 29.7 % a 38.2 %); la persistencia en la no-pobreza mejora de 76.6 % a 80.1 %. Bajo IPM entrar es menos frecuente (12.1 % y 9.7 %, frente a 23.4 % y 19.9 % en monetaria) y salir es más frecuente (54.5 % y 52.3 %, frente a 29.7 % y 38.2 %), por lo que la persistencia en la pobreza es menor (45.5 % y 47.7 %, frente a 70.3 % y 61.8 %). La baja entrada es coherente con que el IPM mide privaciones estructurales (educación, materiales de la vivienda, acceso a servicios) que, una vez superadas, rara vez se revierten, a diferencia del ingreso corriente. La alta salida debe leerse con cautela en 2010→2013, porque coincide con un cambio en la medición del indicador de barreras de acceso a salud (Sección 6.3); no obstante, que se mantenga en 2013→2016, donde ese indicador se mide igual, sugiere que no solo se debe a la medición.

Un último ejercicio (Tabla 1) sigue a los mismos hogares no pobres en la ola base a lo largo de las tres olas para distinguir, dentro de quienes *entran* en pobreza, una entrada transitoria de una persistente. Bajo pobreza monetaria, 24.1 % de los no pobres en 2010 entra en pobreza en 2013: 14.0 % salen de nuevo antes de 2016 (“transitorio”) y 10.1 % se quedan (“persistente”). Bajo IPM la entrada total es menor (12.2 %) y se reparte parecido

¹Para establecer la robustez de las estimaciones de pobreza monetaria y sus clasificaciones, se realizó un análisis adicional de la incidencia agregada, FGT, y cinco ejercicios de estimaciones, incluyendo la atrición del panel por perfil de hogar, que se documentan en el Apéndice A.2

Figura 1: Transición de pobreza entre las categorías de López-Calva y Ortiz-Juarez (2014), pobreza monetaria e IPM, 2010→2013 y 2013→2016.



Nota: Arriba, pobreza monetaria por ingreso; abajo, pobreza multidimensional (IPM). Panel emparejado 1 a 1, con el mismo universo para las dos definiciones; excluye a los hogares que se dividieron entre olas: 511 en 2010→2013 y 1,190 en 2013→2016 (los 511 anteriores y 679 que se dividieron hacia 2016). Fuente: cálculos propios.

(8.2 transitoria, 4.0 persistente): en ambas definiciones, más de la mitad de quienes entran en pobreza no quedan atrapados dentro de la ventana de seis años observada.

Tabla 1: Trayectorias de los hogares no pobres en 2010 en las tres olas, pobreza monetaria e IPM, 2010→2013→2016.

Trayectoria	Monetaria		IPM	
	<i>n</i>	%	<i>n</i>	%
Nunca cae	1,700	67.2 %	4,381	81.2 %
Cae tarde (solo en 2016)	220	8.7 %	357	6.6 %
Entra y sale (transitorio)	355	14.0 %	445	8.2 %
Entra y se queda (persistente)	255	10.1 %	214	4.0 %

Nota: Panel emparejado 1 a 1. $n=2,530$ hogares no pobres en 2010 bajo pobreza monetaria y $n=5,397$ bajo IPM (universos distintos porque los hogares no pobres en 2010 no son los mismos en las dos definiciones). % sobre ese universo, sin ponderar. Fuente: cálculos propios.

4. Estrategia empírica

4.1. Construcción de la variable de resultado

Este estudio sigue la metodología de López-Calva y Ortiz-Juarez (2011, 2014), a partir de la cual se construyen matrices de transición de pobreza monetaria e IPM, cruzando el estado de un hogar en el período inicial t (filas), contra un periodo posterior $t + 1$ (columnas). Esta comparación permite observar cómo evoluciona la situación económica de los hogares a lo largo del tiempo y generar una taxonomía de cuatro categorías de acuerdo con la clasificación en dos momentos del tiempo: *nunca pobre*, *siempre pobre*, *entra en pobreza* y *sale de pobreza*.

La pobreza monetaria en este trabajo se estima a partir del cálculo del ingreso per cápita del hogar, de acuerdo con las preguntas correspondientes en la ELCA, y se compara contra la línea de pobreza (LP) oficial del DANE, específica por año y zona². De otro lado, la pobreza multidimensional se mide con un proxy del Índice de Pobreza Multidimensional (IPM) del DANE (Angulo Salazar et al., 2011), construido con los diez indicadores que la ELCA permite medir de forma comparable en las tres olas. Los indicadores se agrupan en cuatro dimensiones de igual peso (25 % cada una), con igual peso entre los indicadores de cada dimensión: educación (bajo logro educativo y analfabetismo), niñez y juventud (rezago escolar), salud (sin aseguramiento y barreras de acceso) y vivienda y servicios públicos (fuente de agua, eliminación de excretas, pisos, paredes y hacinamiento crítico).

²Se usa la serie MESEP (línea base ENIG 2006–2007, actualizada anualmente por IPC), la misma metodología para las tres olas (2010, 2013 y 2016), lo que las hace comparables entre sí. Deliberadamente no se usa la actualización metodológica ENPH 2016–2017 con la que el DANE recalculó la serie 2012–2018, porque esa serie no cubre 2010 y adoptarla habría introducido una inconsistencia metodológica justo entre las olas que este estudio compara.

Un hogar se clasifica como pobre si su puntaje ponderado de privaciones es de al menos 33.3 %, el mismo corte del IPM oficial.³

Los modelos predictivos de este estudio (Secciones 4.3 en adelante) se estiman sobre los hogares no pobres en t y predicen si caen en pobreza en $t + 1$, de acuerdo con la definición de vulnerabilidad (Ecuación 1):

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

Conviene precisar la terminología. En el sentido de Chaudhuri et al. (2002), la vulnerabilidad es una probabilidad *ex ante*; en este artículo corresponde a la probabilidad predicha por los modelos, $\hat{P}(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it})$. La entrada efectiva en pobreza es su realización observada, que se usa para entrenar y evaluar esos modelos. Por brevedad, el texto llama *hogares vulnerables* a los que efectivamente entran en pobreza, entendiendo que son la realización del riesgo y que otros hogares con una probabilidad predicha igual de alta no llegaron a caer.

4.2. Metodología de caracterización de los hogares vulnerables

Para caracterizar a los hogares vulnerables se combinan dos análisis. El principal usa los modelos de la Sección 4.3 para identificar qué variables anticipan la entrada en pobreza. El segundo compara a los hogares vulnerables (*entra en pobreza*) con los otros tres grupos de la matriz de transición, incluidos los que ya eran pobres, que los modelos iniciales no incluyen.

En el primer análisis se usan valores SHAP, que miden cuánto sube o baja cada variable la probabilidad predicha para cada hogar, con la ventaja de que se miden en la misma escala para los cinco algoritmos. Se calculan para los Modelos A y B (con y sin ingreso y gasto, Sección 4.3), lo que da diez combinaciones de algoritmo y especificación, en las dos definiciones de pobreza y en las dos ventanas. De ahí salen dos resultados. El *núcleo* son las variables que, en al menos cinco de las diez combinaciones, están entre las que suman el 80 % de la importancia total. La *dirección* indica si valores altos de una variable suben o bajan el riesgo, y se mide con la correlación de Spearman entre la variable y su valor SHAP. Se considera que la dirección de una variable es estable si su signo se mantiene

³El IPM oficial tiene cinco dimensiones y quince indicadores. Se excluyen cinco por falta de cobertura en la ola 2010: privación en primera infancia (no medible de forma consistente en ninguna ola); inasistencia escolar y trabajo infantil (0.4 %–35.3 % de cobertura en 2010, frente a cerca de 100 % en 2013 y 2016); y empleo informal y desempleo de larga duración (cerca de 20 % de cobertura en 2010, frente a 75–80 % en 2013 y 2016). Con ello la dimensión Trabajo queda sin indicadores y su peso se reparte entre las otras cuatro.

en las dos definiciones de pobreza y en las dos ventanas. Ambos criterios se prueban con umbrales alternativos en el Apéndice A.3 para validar los resultados.

Para el segundo análisis se estima un modelo multiclase sobre los cuatro grupos de la matriz de transición (*nunca pobre, entra en pobreza, sale de pobreza y siempre pobre*), con los mismos algoritmos y una red neuronal adicional, siguiendo el mismo esquema de validación que el modelo binario (entrenamiento en 2010→2013 y prueba en 2013→2016). Se estima sin ingreso ni gasto (Modelo B): con ellos la comparación sería trivial, porque el ingreso define la condición de pobreza en la ola base. Para medir qué tan parecidos son dos grupos se usa el AUC-ROC por par: se restringe la muestra a los hogares de esos dos grupos y se toma como puntaje la probabilidad que el modelo asigna al primero. Un AUC cercano a 0.5 indica que, con la información de la ola base, los dos grupos no se distinguen (o los modelos no logran diferenciarlos más allá de lo que haría el azar). Su incertidumbre se mide con un *bootstrap* por comunidad sobre la muestra de prueba. El modelo multiclase no reemplaza al binario: la pregunta de vulnerabilidad se refiere solo a los hogares no pobres hoy (t) que caen en pobreza en el siguiente periodo ($t + 1$), y este modelo multiclase al asignar a cada hogar su grupo más probable, casi nunca identifica a los que entran en pobreza. El modelo multiclase se estima solo bajo pobreza monetaria; su especificación y resultados completos están en el Apéndice A.12.

Finalmente, se separa a los hogares que entran en pobreza según sigan o no pobres en 2016 (transitorios y persistentes) y se comparan sus promedios en las variables del núcleo SHAP.

4.3. Especificación de modelos

La estrategia empírica se establece mediante la siguiente especificación de modelo:

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1), incluyendo las variables geoespaciales complementarias, y $F(\cdot)$ es una aproximación a la función que relaciona esas características con la probabilidad de transición, definida de manera distinta según el algoritmo. Se comparan cinco algoritmos de aprendizaje supervisado: una regresión logística regularizada (*elastic net*), cuya fuerza y mezcla de penalización se eligen por validación cruzada y que sirve de referencia por ser la más básica e interpretable; Random Forest, que McBride y Nichols (2018) emplean para mejorar la focalización fuera de muestra; y tres implementaciones de *gradient boosting* (XGBoost, LightGBM y HistGradientBoosting), que manejan de forma nativa los datos faltantes y las variables categóricas (descripción detallada en el Anexo A.13). El riesgo de multicolinealidad,

relevante sobre todo para la regresión logística, se analiza en el Apéndice A.1.

Se evalúa el aporte del nivel de ingreso/gasto del hogar, el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), con cada uno de los cinco algoritmos en dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante (se mantiene constante a lo largo del tiempo); el **Modelo B** excluye estas cuatro variables y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad).

Finalmente, se establecieron dos variables objetivo para evaluar la robustez de los hallazgos: la transición hacia la pobreza monetaria y la transición hacia la pobreza multidimensional bajo el proxy de IPM.

4.4. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, en el que solo existe la ola base al momento de predecir. Es además más exigente que la validación cruzada aleatoria que recomiendan McBride y Nichols (2018), quienes advierten que esta supone que el proceso generador de los datos no cambia entre el desarrollo y la aplicación de la herramienta; la partición temporal pone a prueba ese supuesto, porque evalúa el modelo en un periodo económico distinto al de entrenamiento.

Dentro del periodo de entrenamiento (2010 a 2013), los hiperparámetros de cada algoritmo, como la profundidad de los árboles o la tasa de aprendizaje, no se fijan a mano, sino que se eligen con una búsqueda aleatoria (*randomized search*). Se prueban 30 combinaciones elegidas al azar dentro de un rango razonable para cada hiperparámetro, en lugar de todas las combinaciones posibles (*grid search*), cuyo costo de cómputo habría sido prohibitivo para 5 algoritmos, 4 especificaciones, 3 estrategias de balanceo (Sección 4.5) y dos variables objetivo⁴. Cada combinación se evalúa con validación cruzada estratificada

⁴Con clases desbalanceadas, las probabilidades predichas tienden a concentrarse en valores bajos, de modo que el umbral convencional de 0.5 clasifica a muy pocos hogares como vulnerables. Por eso el umbral de cada modelo también se elige por validación cruzada: sobre las probabilidades *out-of-fold* se prueba una grilla de umbrales entre 0.02 y 0.98 y se elige el que maximiza F_2 . Para verificar que 30 iteraciones no se quedan cortas, se extendió la búsqueda a 50 iteraciones para el caso más ambiguo de la comparación de balanceo (HistGradientBoosting-A, Sección 4.5): el mejor puntaje acumulado ya no mejora entre las iteraciones 20 y 40 (0.7603 en ambas), y gana solo 0.0006 adicional hacia la iteración 50 –evidencia de que la búsqueda con 30 iteraciones ya opera cerca de su techo para este caso, no de que se haya interrumpido prematuramente.

de 10 particiones: el conjunto de entrenamiento se divide en 10 bloques que conservan la proporción de hogares que entran en pobreza, se entrena 10 veces dejando por fuera un bloque distinto y se evalúa sobre él. Promediar las 10 evaluaciones castiga a las combinaciones que memorizan particularidades de los datos en vez de aprender un patrón que generaliza. Los hiperparámetros encontrados para cada uno de los modelos reportados se presentan en la Tabla 23 del Anexo A.13.

La métrica que decide qué combinación gana esa búsqueda es el AUC-ROC: la probabilidad de que, al tomar al azar un hogar que entra en pobreza y uno que no, el modelo le asigne más riesgo al primero (0.5 equivale a adivinar al azar y 1 a ordenar a todos los hogares correctamente). Es apropiada porque lo que se busca es un modelo que ordene bien a los hogares según su riesgo, y el AUC-ROC mide justamente eso, sin depender del umbral a partir del cual se clasifica a un hogar como vulnerable, que se elige después (Sección 4.5).

El AUC-ROC es la métrica principal, pero con clases desbalanceadas puede dar una imagen optimista: premia una tasa *relativa* baja de falsos positivos, que puede esconder un número *absoluto* alto de falsos positivos cuando los hogares que entran en pobreza son pocos (Davis & Goadrich, 2006; Saito & Rehmsmeier, 2015). Esto no lo invalida como medida de ordenamiento, pero sí limita lo que dice, por sí solo, sobre la utilidad del modelo para una política social con recursos limitados. Por eso se reportan y analizan también el *recall*, la precisión y el F1 al umbral de clasificación elegido con F_2 (Sección 4.5), junto con la matriz de confusión completa; el F1 se incluye por ser la referencia más usada en la literatura, aunque no es el criterio que fija el umbral. Este se escoge para maximizar F_2 porque, en focalización, dejar sin detectar a una persona vulnerable es más perjudicial que detectar a una persona que no lo es y es más costoso en términos de impacto social. El F1 y el F_2 son promedios armónicos de precisión y *recall*, con pesos distintos: F1 los pondera igual y F_2 le da el doble de peso al *recall*.

El *recall* es la fracción de los hogares que efectivamente entran en pobreza que el modelo marca como en riesgo (cuánta de la pobreza futura se captura), y la precisión es la fracción de los hogares marcados que efectivamente entran (cuántas de las alertas son acertadas). Ambas dependen del umbral y se mueven en direcciones opuestas: con un mismo modelo, bajar el umbral sube el *recall* a costa de la precisión, y viceversa.

Se reporta también la precisión en el decil de mayor riesgo, que no depende de un umbral de clasificación y responde directamente la pregunta de un programa con presupuesto limitado: si solo puede atender al 10% de los hogares que el modelo considera de mayor riesgo, ¿qué proporción de ellos efectivamente entra en pobreza?

El análisis se centra en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo: como se

documenta en la Sección 5.1, las diferencias de AUC-ROC entre modelos son pequeñas frente a la variabilidad esperable por la aleatoriedad del ajuste.

4.5. Tratamiento del desbalance de clases y de los datos faltantes

Los datos faltantes de las covariables reciben un único tratamiento, que depende del algoritmo, y no se elimina ningún hogar por tenerlos. La regresión logística y Random Forest no aceptan valores faltantes: como en la ELCA provienen sobre todo de preguntas filtro (por ejemplo, el monto de una ayuda no se pregunta a quien no recibió ninguna), se rellenan con 0 y se agrega un indicador de faltante por variable, en vez de la mediana, que asignaría a esos hogares un valor típico que no tienen; las variables categóricas reciben la categoría “Sin dato”. XGBoost, LightGBM y HistGradientBoosting los manejan de forma nativa, sin imputación.

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4 % (Figura 1a), un desbalance que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.⁵

5. Resultados

Los resultados se presentan en tres partes comenzando por los aspectos más generales de los modelos y los perfiles de vulnerabilidad para abordar luego propiamente la pregunta de investigación de este estudio. La Sección 5.1 compara el desempeño fuera de muestra de los cinco algoritmos bajo las especificaciones A y B (con y sin ingreso/gasto) del hogar y analiza los errores de inclusión y exclusión de los modelos. La Sección 5.2 caracteriza a los hogares vulnerables a partir de los valores SHAP de esos modelos y usa un modelo multiclase para compararlos con los otros tres grupos de la matriz de transición, incluidos los que ya eran pobres. La Sección 5.3 analiza el efecto de las variables provenientes de

⁵No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La elección de la estrategia de balanceo es sensible al azar del particionado: para HistGradientBoosting con el Modelo A, repetir la comparación con cinco semillas distintas cambia la estrategia ganadora en tres de ellas, con diferencias de AUC-ROC entre estrategias de entre 0.001 y 0.004 dentro de cada semilla. Se usa siempre la semilla fijada de antemano (42); las diferencias entre estrategias están dentro del ruido del particionado.

fuentes geoespaciales públicas y evalúa si agregar DMSP-OLS mejora esa predicción, bajo pobreza monetaria e IPM (Secciones 5.3.1 y 5.3.2) y si ese efecto es igual en la población o se concentra en subgrupos específicos (Sección 5.3.2).

5.1. Desempeño comparativo de modelos

5.1.1. Desempeño de los modelos

Frente al desempeño de los modelos se encontraron dos hallazgos. **Primero**, el algoritmo elegido no cambia el poder de discriminación de los vulnerables (AUC-ROC 0.731–0.767 en los cinco, Tabla 2). Bajo IPM ocurre lo mismo, en un rango de AUC-ROC igual de estrecho (0.725–0.741; Tabla 9, Apéndice A.4). Un AUC-ROC de 0.75 significa que, si se toma al azar un hogar que entra en pobreza y uno que no, el modelo correctamente asigna mayor riesgo al primero solo 3 de cada 4 veces. Es un desempeño moderado frente a los pocos trabajos que evalúan la predicción de la entrada en pobreza. Con registros administrativos de los Países Bajos, más de 500 variables y un horizonte de un año, Burger y van der Laan (2021) obtienen un AUC normalizado de 0.90 (donde 0 equivale al azar y 1 a una clasificación perfecta), y con el panel alemán SOEP, Hohberg et al. (2018) identifican al 80 % de quienes caen al año siguiente con menos de 20 % de falsos positivos en la mayoría de los años, proporción que sube a cerca de 30 % con un horizonte de tres años. Aquí la predicción se hace a tres años y con una encuesta, no con registros administrativos, lo que hace esperable un techo más bajo.

Que incluso la regresión logística regularizada, el algoritmo más simple, quede cerca de los demás (AUC-ROC de 0.739 frente a 0.742 del Random Forest, el de mejor desempeño) y que los algoritmos de *boosting* elijan árboles poco profundos (profundidad 3 o 4) sugiere que las interacciones complejas entre variables aportan poco. El límite al desempeño parece estar en la información que contienen las covariables más que en la forma del modelo, lo que no implica afirmar ausencia de efectos no lineales, sino que modelarlos aporta poco a la discriminación. Lo que sí varía es la dirección de algunas variables según la definición de pobreza: la edad del jefe de hogar, por ejemplo, se asocia con menor riesgo bajo pobreza monetaria y con mayor riesgo bajo IPM (Sección 5.2).

Segundo, la capacidad de identificar vulnerables apenas cambia si se excluyen las variables de ingreso/gasto del hogar de las covariables que se utilizan en los modelos. La ganancia de incluir esa información, que es la más cara de levantar mediante encuesta, y la menos confiable, es marginal (brecha de AUC de 0.008 a 0.028 entre el Modelo A y B). La brecha es pequeña si se considera que, en el enfoque de Chaudhuri et al. (2002), la vulnerabilidad se deriva directamente de la media y la varianza esperadas del consumo. Esto no implica que el ingreso no importe (Sección 5.2), sino que su contenido informativo

Tabla 2: Desempeño de los cinco algoritmos en el conjunto de prueba, pobreza monetaria, 2013→2016.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precisión	Prec.-top10	Rec.-top10	F1
XGBoost	A	0.11	0.767	0.949	0.264	0.505	0.254	0.413
Random Forest	A	0.14	0.766	0.926	0.277	0.486	0.245	0.426
HistGradientBoosting	A	0.32	0.763	0.909	0.283	0.512	0.258	0.432
LightGBM	A	0.10	0.758	0.903	0.281	0.516	0.260	0.428
Logística regularizada	A	0.37	0.747	0.883	0.280	0.506	0.255	0.426
Random Forest	B	0.31	0.742	0.892	0.272	0.508	0.256	0.416
XGBoost	B	0.13	0.742	0.940	0.250	0.495	0.249	0.395
Logística regularizada	B	0.35	0.739	0.890	0.270	0.500	0.252	0.414
HistGradientBoosting	B	0.14	0.735	0.879	0.275	0.494	0.249	0.418
LightGBM	B	0.15	0.731	0.909	0.259	0.487	0.246	0.403

Nota: Promedio de 5 semillas. Espec.: especificación (A con ingreso y gasto del hogar, B sin ellos). Umbral: elegido por validación cruzada maximizando F_2 . Prec.-top10: precisión en el 10 % de hogares con mayor riesgo predicho; Rec.-top10: fracción de los hogares que entran en pobreza que queda dentro de ese 10 %. Fuente: cálculos propios.

ya está sustancialmente capturado por otras variables del núcleo del perfil (Ej. Riqueza, educación, bienes durables Sección 5.2).

El segundo resultado es coherente con dos líneas de la literatura. López-Calva y Ortiz-Juarez (2014) interpretan el ingreso observado como una medida resumen de los activos del hogar y, por eso, construyen un ingreso permanente a partir de esos activos y de características socioeconómicas; y los *proxy means tests* descansan en que un conjunto de características del hogar, fáciles de verificar, aproximan su bienestar sin medir el ingreso (McBride & Nichols, 2018). Bajo IPM la brecha es aún menor, y para Random Forest y XGBoost es negativa (el Modelo B (sin ingreso/gasto) supera al A), lo que descarta que la pequeña brecha en la capacidad discriminante de los modelos bajo la definición de pobreza monetaria se deba a la relación entre ingreso y la definición de pobreza. La implicación práctica sería mantener la estrategia de focalizar mediante el ingreso/gasto del hogar, pero cuando no sea posible obtener esa información, se encuentre desactualizada o poco confiable, se podría utilizar un instrumento alternativo y confiable: las mismas variables que ofrece la encuesta. Con un particular énfasis en las variables del núcleo del perfil (Sección 5.2), que son las que más contribuyen a la predicción de vulnerabilidad.

5.1.2. Análisis de los errores de inclusión y exclusión

Frente a los errores de inclusión y exclusión se encontraron tres hallazgos más. **Tercero**, un programa que no quiera dejar por fuera a los hogares vulnerables tendrá que atender a muchos que no lo necesitan, y cambiar de algoritmo o de umbral no lo evita sin dejar por fuera a más hogares vulnerables; lo que sí mejora su eficiencia sería concentrarse en el 10 % de hogares con mayor riesgo, a costa de cobertura. Con los datos disponibles para este estudio y de acuerdo con los modelos utilizados, se encontró que con cualquiera

de estos, una política pública para la vulnerabilidad atendería entre 2.4 y 3.1 hogares no vulnerables por cada hogar vulnerable identificado (Tabla 3). Asimismo, los modelos descartan correctamente los hogares no vulnerables solo entre el 26 % (XGBoost) y el 47 % (LightGBM). En términos de la Tabla 2, el *recall* es alto (0.88–0.95: casi todos los hogares verdaderamente vulnerables quedan marcados) y la precisión baja (0.25–0.28: uno de cada cuatro marcados como vulnerables lo es).

El umbral elegido por F_2 , que da el doble de peso a no dejar sin detectar a hogares verdaderamente vulnerables que a marcar de más a hogares que no caen, decide en qué punto de ese intercambio se ubica el modelo; pero con un AUC-ROC de 0.75 no es posible tener *recall* y precisión altos a la vez. Es el intercambio que la literatura de focalización llama errores de inclusión y de exclusión (*Type E* y *Type F*, Cornia y Stewart (1993)): para un instrumento dado, reducir uno aumenta el otro, y solo un instrumento con mayor poder de discriminación puede mover esa frontera. Por eso Hohberg et al. (2018) proponen elegir el umbral según el objetivo de focalización y no fijarlo en una probabilidad de 0.5: privilegiar la identificación de quienes caerán conduce a programas más amplios, y minimizar el total de errores, a programas más acotados. El umbral elegido por F_2 y el decil de mayor riesgo corresponden a esas dos opciones. En cambio, en el decil de mayor riesgo la precisión (0.49–0.52) casi duplica la del umbral completo: uno de cada dos hogares atendidos efectivamente cae. El costo es la cobertura: ese decil contiene solo entre el 25 % y el 26 % de los hogares vulnerables (Tabla 2), de modo que un programa así llegaría a uno de cada cuatro vulnerables.

Tabla 3: Matriz de confusión del Modelo A en el conjunto de prueba, pobreza monetaria e IPM, 2013→2016.

Algoritmo	Monetaria				IPM			
	VP	FP	FN	VN	VP	FP	FN	VN
XGBoost	617 (19 %)	1888 (59 %)	18 (1 %)	668 (21 %)	491 (9 %)	3297 (59 %)	51 (1 %)	1732 (31 %)
Random Forest	594 (19 %)	1572 (49 %)	41 (1 %)	984 (31 %)	343 (6 %)	1493 (27 %)	199 (4 %)	3536 (63 %)
HistGradientBoosting	584 (18 %)	1532 (48 %)	51 (2 %)	1024 (32 %)	301 (5 %)	1124 (20 %)	241 (4 %)	3905 (70 %)
LightGBM	561 (18 %)	1354 (42 %)	74 (2 %)	1202 (38 %)	415 (7 %)	2052 (37 %)	127 (2 %)	2977 (53 %)
Logística regularizada	561 (18 %)	1444 (45 %)	74 (2 %)	1112 (35 %)	379 (7 %)	1862 (33 %)	163 (3 %)	3167 (57 %)

Nota: VP, FP, FN y VN: hogares verdadero positivo, falso positivo, falso negativo y verdadero negativo.

Entre paréntesis, porcentaje sobre el total de la fila para cada definición de pobreza (monetaria, $n = 3,191$; IPM, $n = 5,571$). Modelos clasificados con los hiperparámetros y el umbral reportados en la Tabla 23 del Anexo A.13. La matriz del Modelo B se reporta en la Tabla 20 del Anexo A.11. Corresponde a una sola corrida de cada modelo, por lo que el *recall* y la precisión que se derivan de ella difieren levemente de los promedios de 5 semillas de la Tabla 2. Fuente: cálculos propios.

Cuarto, los falsos positivos no son errores aleatorios: son hogares que no cayeron en pobreza pero que en la ola base estaban en una situación más precaria que los verdaderos

negativos, y el modelo los marca no porque alguna variable suba su riesgo predicho, sino porque les falta la riqueza, la educación y el ingreso que bajan el riesgo de esos verdaderos negativos. Para mostrarlo se compararon, con el Modelo A, pobreza monetaria, y los cinco algoritmos, los hogares que no cayeron en pobreza y el modelo marca (falsos positivos) con los que no marca y no caen (verdaderos negativos): como ambos tuvieron el mismo desenlace (no caen), solo los separa la decisión del modelo. En los valores de las variables del núcleo SHAP (Sección 5.2), los falsos positivos tienen en los cinco algoritmos un índice de riqueza mucho menor (0.26–0.40 frente a 1.65–1.82), menor educación máxima en el hogar (3.2–3.4 frente a 5.4–5.8), menos bienes durables, servicios públicos e internet, menor estrato y más hacinamiento; solo se parecen en los choques y la edad del jefe. Como estas variables están correlacionadas entre sí (los hogares con más riqueza suelen tener también más educación, bienes y servicios), esta comparación no dice cuál de ellas usa el modelo para marcarlos.

Para saberlo se compararon los valores SHAP con signo, que miden cuánto sube (si son positivos) o baja (si son negativos) cada variable el riesgo de caída en pobreza predicho de cada hogar. Entre las seis variables que más separan a los dos grupos en cada algoritmo están, en los cinco, los bienes durables y el ingreso per cápita o el índice de riqueza (según el algoritmo), y en cuatro la educación máxima del hogar (séptima en Random Forest). En 25 de los 30 casos (seis variables por algoritmo), la brecha se debe sobre todo a que las variables reducen con fuerza el riesgo de caída en pobreza de los verdaderos negativos y modifican mucho menos el de los falsos positivos. Las excepciones son los bienes durables y los servicios públicos, que en algunos algoritmos suben el riesgo de los falsos positivos más de lo que bajan el de los verdaderos negativos. Así, los modelos distinguen bien a los hogares precarios de los que no lo son, pero solo en parte cuáles de ellos caerán.

Quinto, quienes efectivamente caen reportan más choques posteriores a la predicción que quienes no caen. Comparando choques reportados en la ola de destino (2016, posteriores al momento de la predicción y por tanto no usados por el modelo) entre verdaderos positivos y falsos positivos, los primeros reportaron más choques en la ola de 2016: 3.1–3.2 choques en promedio frente a 2.2–2.3 (en los cinco algoritmos), y 81–82 % tuvo al menos un choque frente a 71–73 % de los falsos positivos. Esto es consistente con el enfoque de vulnerabilidad de Chaudhuri et al. (2002): el modelo identifica correctamente al hogar en el margen, y parte de quién realiza el riesgo podría depender de choques que la ola base no permite anticipar. También coincide con la evidencia de que los choques idiosincráticos y comunes, como la pérdida de la cosecha de un hogar o la falta de lluvias, generan movimientos de corto plazo hacia dentro y fuera de la pobreza que una medición en un solo momento no captura (Dercon & Krishnan, 2000), y de que los choques idiosincráticos producen por sí

solos una volatilidad del consumo no despreciable (Christiaensen & Subbarao, 2005). La comparación es descriptiva: los choques se autorreportan en la misma ola en que se observa la caída, de modo que un hogar que cayó puede recordarlos o reportarlos más, o haberlos sufrido como consecuencia de la caída.

En suma, cualquier modelo, incluso el del algoritmo más simple y aun sin medir el ingreso del hogar, identifica con una capacidad moderada (AUC-ROC cercano a 0.75) a los hogares que están en el margen de la pobreza, pero distingue mal cuáles de ellos efectivamente caerán, un resultado asociado de forma descriptiva a choques posteriores a la predicción. Las implicaciones de este resultado para la focalización se discuten en la Sección 6.2.

5.2. Determinantes de la vulnerabilidad y comparación entre grupos

Esta sección responde quiénes son los hogares vulnerables, es decir, los que no son pobres en la ola base y entran en pobreza en la siguiente, y qué los distingue. La evidencia principal son los valores SHAP de los modelos de la Sección 5.1: solo se afirma como determinante lo que se sostiene en los cinco algoritmos, en las dos definiciones de pobreza (monetaria y multidimensional) y en las dos ventanas (2010→2013 y 2013→2016). El modelo multiclase compara a los hogares vulnerables con los otros tres grupos de la matriz de transición (Sección 3.3), incluidos los que ya eran pobres, que los modelos binarios no incluyen.

Hay cuatro hallazgos principales. **Primero**, unas pocas variables concentran casi toda la información para identificar a los hogares vulnerables. De las 165 a 169 covariables, entre 14 y 37 acumulan el 80 % de la importancia SHAP en cada combinación de algoritmo y especificación, y las diez primeras, entre el 44 % y el 72 % (Tabla 7, Apéndice A.3). Las 22 variables que están en ese grupo en al menos la mitad de las combinaciones forman el *núcleo del perfil vulnerable* (Tabla 4). Cuatro aparecen en todas las combinaciones: servicios públicos, estrato, bienes durables y personas por habitación. Siete se mantienen en el núcleo bajo las dos definiciones de pobreza y en las dos ventanas: riqueza, educación máxima del hogar, nivel educativo del jefe, personas por habitación, razón de dependencia, puntaje TVIP⁶ y material del piso. El núcleo tampoco depende de los criterios elegidos para definirlo: las 22 variables se conservan con criterios más laxos, y riqueza, educación máxima y razón de dependencia sobreviven incluso a los más estrictos (Tabla 8). Esto no

⁶Puntaje promedio de los niños del hogar en el Test de Vocabulario en Imágenes Peabody (TVIP), que mide el vocabulario receptivo como indicador del desarrollo cognitivo. Se usa el puntaje bruto, sin ajustar por edad, de modo que refleja en parte la edad de los niños evaluados.

implica que la información completa del hogar sobra, porque disponer de todas las variables sigue siendo el escenario preferible. Pero cuando esa información no está disponible, está desactualizada o es incompleta, por ejemplo entre rondas de una encuesta o para hogares con registros administrativos parciales, un conjunto reducido centrado en el núcleo podría servir como alternativa para identificar a los hogares vulnerables; queda como investigación futura evaluar un modelo restringido a esas variables.

Segundo, lo que protege a un hogar de caer en pobreza es lo que ha acumulado, y lo que lo expone es la presión sobre esos recursos. El núcleo tiene una dirección consistente entre algoritmos, definiciones de pobreza y ventanas (Tabla 4). Reducen el riesgo, con dirección estable bajo todos los criterios evaluados, el índice de riqueza, los activos financieros, el estrato, la educación máxima del hogar y el último grado aprobado por el jefe;⁷ y, con dirección moderada, el nivel educativo del jefe, el valor del arriendo y los controles médicos preventivos. Lo aumentan el hacinamiento, con dirección estable, y la razón de dependencia, con dirección moderada. Las demás variables del núcleo no tienen una dirección clara: los bienes durables, los servicios públicos y la cotización a pensión tienen signo mayoritariamente negativo pero no estable entre fuentes, y el acceso a internet, el puntaje TVIP, el choque económico, el porcentaje de niños con madre o padre vivo, la edad del jefe y la existencia de desplazados en la comunidad cambian de signo entre definiciones o ventanas; por eso se reportan como asociaciones, no como determinantes. Estas direcciones coinciden con las que encuentran Hernández y Zuluaga (2022) con la misma ELCA bajo pobreza multidimensional, donde los años de educación, el empleo asalariado y el acceso al crédito reducen la vulnerabilidad, y con la literatura que asocia el capital humano con la pobreza crónica y la riqueza con una menor pobreza transitoria (Jalan & Ravallion, 2000), o que identifica el ahorro como una forma de autoseguro de los hogares frente a los choques (Dercon, 2002). El signo describe cómo el modelo usa cada variable, no un efecto causal, pero indica dónde tendría más sentido enfocar la prevención: en fortalecer el patrimonio del hogar (ahorro y activos financieros, educación y vivienda) más que en compensar carencias una vez ocurren.

⁷Es el último grado aprobado dentro del nivel educativo alcanzado, no los años de escolaridad: va de 1 a 5 en primaria y de 6 a 13 en secundaria, y se reinicia en la educación técnica, universitaria y de posgrado. Por eso se lee como escolaridad sobre todo entre los jefes con primaria o secundaria, que son la gran mayoría de la muestra.

Tabla 4: Núcleo de variables del análisis SHAP y su dirección, pobreza monetaria e IPM, 2010→2013 y 2013→2016.


Variable	Comb.	Monetaria 2010→13	Monetaria 2013→16	IPM 2010→13	IPM 2013→16	Dirección
Activos del hogar						
Estrato (verificado)	10	− 10/10	− 10/10	− 5/5	− 10/10	Estable
N.º de servicios públicos	10	− 10/10	− 3/5	− 10/10	− 9/10	Inestable
N.º de bienes durables	10	− 10/10	− 10/10	− 7/8	− 7/9	Inestable
Tiene internet en el hogar	9	− 10/10	− 7/7	+ 3/5	+ 5/8	Inestable
Índice de riqueza (PCA)	8	− 10/10	− 10/10	− 8/8	− 10/10	Estable
N.º de activos financieros	6	− 9/9	− 9/10	− 10/10	− 10/10	Estable
Educación, empleo y seguridad social						
Máx. nivel educativo del hogar	9	− 10/10	− 10/10	− 9/9	− 9/10	Estable
Cotización a pensión (hogar)	7	− 8/9	− 9/9	− 7/9	− 8/8	Inestable
Último grado aprobado por el jefe	6	− 6/6	− 5/5	− 9/9	− 9/9	Estable
Nivel educativo del jefe (ordinal)	5	− 8/8	− 8/8	− 9/10	− 8/8	Moderada
Vivienda: materiales y servicios						
Material de piso del hogar	8	cat.	cat.	cat.	cat.	−
Vivienda: hacinamiento						
Personas por cuarto	10	+ 10/10	+ 9/9	+ 10/10	+ 10/10	Estable
Valor del arriendo pagado	6	− 9/10	− 7/8	− 10/10	− 8/8	Moderada
Composición del hogar						
% de niños con madre viva	8	+ 9/9	+ 6/6	+ 8/8	− 4/6	Inestable
Razón de dependencia demográfica	8	+ 8/9	+ 8/9	+ 8/10	+ 8/10	Moderada
Edad del jefe de hogar	7	− 8/8	− 6/7	+ 9/9	+ 7/7	Inestable
% de niños con padre vivo	7	− 4/6	+ 8/9	− 5/5	− 10/10	Inestable
Estado civil del jefe	6	cat.	cat.	cat.	cat.	−
Desarrollo infantil (6–9 años)						
Puntaje de vocabulario infantil (test TVIP)	6	− 4/7	− 4/6	− 10/10	− 8/9	Inestable
Salud						
Tasa de controles médicos preventivos (hogar)	6	− 9/9	− 8/8	− 10/10	− 8/9	Moderada
Choques y afrontamiento						
Tuvo un choque económico (hogar)	6	+ 8/9	+ 4/7	+ 8/8	+ 4/6	Inestable
Comunidad						
N.º de desplazados en la comunidad	5	− 6/9	− 7/8	+ 2/3	+ 4/6	Inestable

Nota: Comb.: combinaciones algoritmo/especificación (de 10) en que la variable está dentro del 80 % de la masa SHAP acumulada (Sección 5.2). Cada celda de signo indica el signo mayoritario y en cuántas (n) de las m combinaciones con dirección clara ($|\rho| \geq 0.10$) aparece: − significa que valores altos de la variable *reducen* el riesgo de entrar en pobreza; +, que lo *aumentan*. Dirección: Estable = mismo signo en las cuatro fuentes bajo las 12 combinaciones de umbrales evaluadas; Moderada = en al menos 8; Inestable = en menos. “cat.”: variable categórica, sin signo a nivel de variable. Fuente: cálculos propios.

Tercero, el hogar que cae en pobreza se parece más al que acaba de salir de ella que al que nunca ha sido pobre. El modelo multiclase sin ingreso, evaluado en 2013→2016, separa “entra” de “nunca pobre” con un AUC de 0.73 a 0.75 según el algoritmo, pero apenas separa “entra” de “sale” (0.53 a 0.56, apenas por encima del azar); los intervalos de confianza

de los dos pares no se superponen en ningún algoritmo (Tabla 22, Apéndice A.12). La Figura 2 muestra la misma cercanía variable por variable: en las diez variables del núcleo con dirección estable o moderada, el hogar que entra queda más cerca del que sale que del que nunca fue pobre en ambas ventanas, con una sola excepción (el último grado aprobado por el jefe en 2013→2016). Este resultado se establece bajo pobreza monetaria. “Entra” y “sale” son dos lados de una misma frontera, no dos tipos de hogar. Es la población que López-Calva y Ortiz-Juarez (2014) identifican en Chile, México y Perú: hogares que superaron la línea de pobreza sin alcanzar seguridad económica y que siguen expuestos a volver a caer; y es coherente con la pobreza transitoria de Jalan y Ravallion (2000), en la que hogares no pobres en tiempos normales pueden caer de repente en la pobreza. Parte de esa cercanía puede reflejar también error de medición del ingreso cerca de la línea, al que las transiciones son sensibles (Anexo A.2). El mismo modelo aporta dos matices. Frente a “nunca pobre”, el hogar que entra es algo más difícil de distinguir que el que sale (AUC de 0.73 a 0.75, frente a 0.81 a 0.83): aunque los dos están cerca entre sí, el que entra parte de una situación algo mejor, pues en la ola base todavía no era pobre. Adicionalmente, con la información de la ola base tampoco se distingue bien a quien sale de la pobreza de quien permanece en ella (0.60 a 0.63): ni la entrada ni la salida se anticipan bien con la información de la ola base. En el contexto de una potencial política pública de vulnerabilidad, esto implica que los hogares que acaban de salir de la pobreza son los siguientes candidatos a caer en ella: retirarlos de los programas en cuanto superan la línea podría devolverlos a la pobreza. Y como la salida tampoco se anticipa con la información de la ola base, las reglas de graduación basadas en características observadas serían menos confiables que un seguimiento periódico de la condición del hogar; una salida gradual, o mantenerlos en seguimiento, sería más coherente con este resultado.

Figura 2: Posición de los hogares que entran y que salen de la pobreza entre los grupos extremos, variables del núcleo SHAP, pobreza monetaria, 2010→2013 y 2013→2016.



Nota: Promedio de cada variable en cada grupo, expresado en relación con los promedios de los dos grupos extremos: 0 corresponde al promedio de los hogares “siempre pobres” y 1 al de los “nunca pobres” (por ejemplo, 0.5 indica un promedio a medio camino entre ambos). Se muestran las diez variables del núcleo SHAP con dirección estable o moderada. Grupos de López-Calva & Ortiz-Juarez (2014); $n = 8,218$ en 2010→2013 y $n = 6,911$ en 2013→2016. Fuente: cálculos propios.

Cuarto, entre los hogares que caen, quedan atrapados los que cayeron con menos recursos acumulados. La tercera ola permite distinguir dos trayectorias: pobres transitorios (355 hogares, 58 %), que vuelven a salir antes de 2016, y persistentes (255 hogares, 42 %), que siguen pobres en 2016 (Tabla 5). En las variables del núcleo SHAP, los persistentes tenían en 2010 menos activos financieros (0.25 frente a 0.63 en promedio), menor índice de riqueza, estrato y nivel educativo del hogar y del jefe, y más personas por cuarto: son las mismas variables que, con dirección estable, protegen frente a la caída (Segundo hallazgo). También cotizaban menos a pensión (11.6 % frente a 22.8 % de los integrantes del hogar) y tenían menos bienes durables, dos variables del núcleo cuyo signo no es estable. Otras diferencias grandes, como el estado civil del jefe o los desplazados en la comunidad, corresponden a variables sin dirección estable en SHAP y se reportan solo como asociaciones. Lo que protege de caer, el patrimonio acumulado, es también lo que distingue a quienes logran salir. El resultado es coherente con Dercon (2002), para quien el ahorro y los activos funcionan como autoseguro de los hogares frente a los choques, y con la evidencia de trampas de pobreza en Colombia (Castañeda Castrillón, 2012). Estas variables

podrían orientar la duración del apoyo: una vez un hogar cae, la falta de activos financieros y de cotización señalaría a quienes necesitan un apoyo más largo, lo que complementa la focalización en dos etapas (Sección 6.2).

Tabla 5: Hogares que entran en pobreza según su trayectoria posterior: transitorios frente a persistentes, pobreza monetaria, 2010→2013→2016.

Variable (ola 2010)	Siempre	Salí	Transitorio	Persistente	Nunca	Dif. estand.
N.º de activos financieros	0.10	0.42	0.63	0.25	0.86	−0.44
N.º de desplazados en la comunidad [‡]	187.6	125.1	82.2	173.4	144.3	+0.41
Material de piso del hogar: alfombra, mármol, parquet, madera pulida (%) [‡]	1.8	5.1	9.7	0.8	9.1	−0.41
Cotización a pensión (hogar) (%) [‡]	4.5	15.8	22.8	11.6	38.4	−0.38
% de niños con padre vivo (%) [‡]	60.4	62.0	66.9	50.6	63.5	−0.35
N.º de bienes durables [‡]	4.58	6.00	6.84	5.50	9.10	−0.34
Estado civil del jefe: separado(a) o divorciado(a) (%) [‡]	11.2	12.9	10.4	22.9	15.0	+0.34
Estrato (verificado)	1.59	2.06	2.15	1.89	2.63	−0.34
Estado civil del jefe: casado(a) (%) [‡]	27.7	33.7	37.5	22.9	38.2	−0.32
Máx. nivel educativo del hogar	2.28	2.79	2.89	2.57	4.22	−0.27
Personas por cuarto	2.13	1.65	1.40	1.62	1.11	+0.24
Nivel educativo del jefe (ordinal)	2.02	2.54	2.65	2.36	3.72	−0.24
Índice de riqueza (PCA)	−0.83	−0.02	0.48	−0.20	1.06	−0.23
Material de piso del hogar: cemento, gravilla (%) [‡]	52.7	47.8	43.9	54.0	25.3	+0.20

Nota: Transitorios ($n = 355$): entran en pobreza en 2010→2013 y vuelven a salir en 2016; persistentes ($n = 255$): siguen pobres. Promedios ponderados por el factor de expansión longitudinal. Se muestran los 14 de 31 indicadores del núcleo SHAP (las variables categóricas, un indicador por nivel) cuya diferencia estandarizada entre persistentes y transitorios es de al menos 0.20 en valor absoluto; el signo negativo indica un valor menor en los persistentes. [‡]: variable sin dirección estable o moderada en SHAP (o categórica, sin dirección medida), que se lee solo como asociación. De los 723 hogares que entran en pobreza entre 2010 y 2013, 610 tienen dato de 2016. Fuente: cálculos propios.

En conjunto, el hogar vulnerable es un hogar no pobre con poca riqueza y capital educativo, hacinado y con alta carga de dependencia, que se parece más a quien acaba de salir de la pobreza que a quien nunca la vivió. El núcleo y su dirección se sostienen entre algoritmos, definiciones de pobreza y ventanas; la cercanía con quienes salen, bajo pobreza monetaria.

5.3. Contribución marginal de las variables geoespaciales


Esta sección evalúa si la iluminación nocturna DMSP-OLS, la única fuente geoespacial con datos reales en la ola de entrenamiento y en la de prueba (Sección 3.1), mejora la identificación de los hogares vulnerables cuando se agrega a la encuesta. Primero se describe cómo se ubican los grupos de la matriz de transición en esta fuente y se evalúa su aporte bajo pobreza monetaria; luego se repite el ejercicio bajo pobreza multidimensional (IPM) y se examina si el efecto promedio esconde diferencias entre subgrupos.

5.3.1. Perfil geoespacial y aporte bajo pobreza monetaria

Frente a las variables geoespaciales se encontraron cuatro hallazgos. **Primero**, la luz nocturna ordena a los hogares según su trayectoria de pobreza y reproduce lo que muestra la encuesta. En 2010→2013 separa de forma monótona los cuatro grupos, en media y en mediana, bajo pobreza monetaria e IPM: de “siempre pobre” a “nunca pobre”, el valor de iluminación nocturna sube en cada paso (Figura 3). También reproduce el Tercer hallazgo de la Sección 5.2: el hogar que entra en pobreza queda más cerca del que sale que del que nunca fue pobre. Bajo IPM, su mediana (10.7) está a 2.9 puntos de “sale” y a 38.4 de “nunca pobre”; bajo pobreza monetaria el patrón es débil en 2010→2013, con “entra” casi a medio camino, pero se recupera en 2013→2016, donde queda a 8.9 puntos de “sale” y a 38.3 de “nunca pobre”. Por región, la pobreza persistente se concentra en las microrregiones rurales, con 64–66 % de hogares siempre pobres y luz nocturna muy baja, mientras Bogotá concentra los nunca pobres (70 %) con el valor máximo de luz (Figura 4).⁸ Las otras dos fuentes satelitales muestran el mismo orden en 2010: el radar de ALOS PALSAR, que capta el área construida, sube de “siempre pobre” a “nunca pobre” como la luz nocturna, y el índice de vegetación de Landsat (NDVI) baja, porque es mayor en las zonas rurales, donde se concentra la pobreza persistente. En ambas, “entra” queda más cerca de “sale” que de “nunca pobre”. Como solo tienen datos en 2010, no se pueden poner a prueba en 2013→2016. Es de resaltar que fuentes completamente independientes de la encuesta, medidas desde el espacio, reproduzcan el gradiente y la cercanía entre “entra” y “sale” es indicador de que ese patrón no depende de cómo se construyó el cuestionario. Para una eventual política pública, esto hace de la luz nocturna un indicador gratuito y de cobertura universal del gradiente socioeconómico, útil para priorizar territorios donde no hay encuesta (Hofer et al., 2025), aunque no para seleccionar hogares dentro de ellos, como muestra el siguiente hallazgo.


⁸La muestra de ELCA es urbana en unas regiones y rural en otras.

Figura 3: Iluminación nocturna (DMSP-OLS) por grupo de transición, pobreza monetaria e IPM, 2010→2013.



Nota: Barra: media ponderada por el factor de expansión longitudinal; línea vertical: mediana. Escala de DMSP-OLS de 0 a 63. Fuente: cálculos propios.

Figura 4: Grupo de transición dominante por región e iluminación nocturna (DMSP-OLS), pobreza monetaria, 2010→2013.



Nota: Las proporciones de cada grupo por región son reales; su ubicación dentro de cada región es simulada. Fondo: iluminación nocturna de 2010. Fuente: cálculos propios.


Segundo, bajo pobreza monetaria, agregar la luz nocturna a la encuesta no mejora la identificación de los hogares vulnerables. Al reentrenar los diez modelos con las 23 variables de DMSP-OLS, el AUC-ROC cambia entre -0.006 y $+0.006$ en las diez combinaciones de algoritmo y especificación, y la precisión en el decil de mayor riesgo cae o se mantiene en todas; el intervalo de confianza del cambio incluye el cero en las diez (Tablas 10 y 11, Apéndice A.5). No se debe a sobreajuste: la diferencia entre el AUC de validación cruzada y el de prueba prácticamente no cambia al agregar DMSP-OLS (a lo sumo 0.002 en ocho de las diez combinaciones, 0.008 en LightGBM con el Modelo A y una reducción de 0.005 en LightGBM con el Modelo B). El resultado se repite al agregar las tres fuentes geoespaciales juntas (DMSP-OLS, ALOS PALSAR y Landsat 5 TM): con validación cruzada dentro de 2010→2013, el AUC-ROC cambia entre -0.006 y 0.000 en los seis modelos estimados y no

mejora en ninguno (Tabla 14, Apéndice A.7).⁹ La razón es que la luz nocturna mide lo mismo que la encuesta ya captura. Su correlación con caer en pobreza ($r = -0.214$) es tan fuerte como la del estrato, pero cae a $r \approx 0.01$ al descontar cuatro variables del núcleo: servicios públicos, estrato, bienes durables y personas por cuarto (Figura 5). Tampoco ayuda a resolver el problema central de la Sección 5.1.2: en el modelo multiclase, agregar DMSP-OLS cambia el AUC de cada par de grupos en menos de 0.025, sin un patrón consistente entre algoritmos, y en la separación de “entra” frente a “sale” ningún cambio es distinguible de cero (entre -0.006 y $+0.011$; Tabla 22, Apéndice A.12).

La luz nocturna distingue, como la encuesta, a los hogares en situación precaria de los que no lo están, pero no a cuáles de esa situación caerán. Un sistema que ya cuenta con una encuesta vigente no ganaría precisión al integrarla. Es coherente con la evidencia previa: en Jean et al. (2016) la luz nocturna sola predice peor que un modelo que la combina con imágenes diurnas y datos de encuesta, y Hall et al. (2023) encuentran que los datos geoespaciales predicen peor variables de flujo, como el ingreso o el consumo, que los activos físicos. Hay, sin embargo, una diferencia práctica: la luz nocturna es mucho más estable en el tiempo que esas variables de la encuesta (correlación entre 2010 y 2013 de 0.958, frente a 0.600 de los bienes durables). Esa estabilidad es la que permite, como proponen Hofer et al. (2025), usar la luz nocturna para estimar entre encuestas.

⁹Se probó además si DMSP-OLS aporta más al eliminar de la encuesta las dos preguntas que la vuelven redundante (solo la regresión logística mejora de forma consistente) y si aporta más cerca de la línea de pobreza (sin evidencia en los tres terciles de cercanía).

Figura 5: Correlación de la iluminación nocturna (DMSP-OLS) con caer en pobreza antes y después de descontar cuatro variables del núcleo, pobreza monetaria, 2010→2013.



Nota: Las cuatro variables son servicios públicos, estrato, bienes durables y personas por cuarto. La correlación inicial (gris oscuro) es comparable a la de esas cuatro variables (gris claro), pero cae casi a cero al descontarlas (rojo). La barra roja es una correlación parcial: se residualizan tanto la luz nocturna como el resultado frente a las cuatro variables, y se correlacionan los residuos (teorema de Frisch-Waugh-Lovell). $n = 2,150$, restringido por datos faltantes de estrato. Fuente: cálculos propios.

5.3.2. Aporte bajo pobreza multidimensional y por subgrupos

Tercero, bajo IPM la luz nocturna sí mejora la predicción, pero poco y solo en dos algoritmos. XGBoost mejora en ambas especificaciones (+0.013 a +0.020 en AUC-ROC, $p \leq 0.006$) y LightGBM en el Modelo B (+0.017, $p < 0.001$); las otras siete combinaciones no son distinguibles de cero (Tabla 6; detalle de la significancia en la Tabla 11 del Apéndice A.5). El aporte existe, pero es demasiado pequeño para cambiar por sí solo una decisión de focalización. Una explicación posible de que aparezca bajo IPM y no bajo pobreza monetaria es que el IPM incluye privaciones de vivienda y de servicios públicos, más ligadas a la infraestructura que refleja la luz nocturna que el ingreso. Si un programa focaliza privaciones multidimensionales, la luz nocturna añade algo de información, aunque poca.

Tabla 6: Contribución marginal de DMSP-OLS en el conjunto de prueba, pobreza multidimensional (IPM), 2013→2016.

Algoritmo	Espec.	AUC base	AUC +DMSP	Δ AUC	Δ Prec.-top10
XGBoost	A	0.725	0.736	+0.013	+0.022
Random Forest	A	0.729	0.729	+0.001	+0.004
LightGBM	A	0.741	0.745	+0.004	+0.005
HistGradientBoosting	A	0.740	0.738	-0.002	+0.002
Logística regularizada	A	0.730	0.730	-0.000	+0.009
XGBoost	B	0.728	0.746	+0.020	+0.016
Random Forest	B	0.735	0.732	-0.004	+0.015
LightGBM	B	0.730	0.747	+0.017	+0.021
HistGradientBoosting	B	0.739	0.740	+0.002	-0.007
Logística regularizada	B	0.730	0.730	-0.000	+0.011

Nota: Entrenamiento en 2010→2013. AUC: promedio de 5 semillas. Δ AUC: *bootstrap* pareado sobre el conjunto de prueba (una semilla); en **negrita**, diferencias cuyo IC95 % no cruza cero. Intervalos, valores p y corrección por conglomerados de comunidad en la Tabla 11 del Anexo A.5. Fuente: cálculos propios.

Cuarto, en LightGBM, el algoritmo con el patrón más claro, ese aporte se concentra justo donde la encuesta es más débil. Bajo pobreza monetaria no hay diferencias entre subgrupos: solo 1 de 120 combinaciones de algoritmo, grupo y especificación cambia el AUC-ROC en 0.02 o más (Tabla 12, Apéndice A.6). Bajo IPM, LightGBM sin ingreso concentra su ganancia en zona rural (+0.032 frente a +0.008 en la urbana), en estrato 1 (+0.024 frente a -0.003 en estrato 3) y en el tercil de hogares con menos servicios públicos y bienes durables (+0.030 frente a +0.009 en el tercil alto) (Tabla 13, Apéndice A.6). En zona rural y en ese tercil, agregar la luz nocturna marca como en riesgo a 6 a 7 puntos porcentuales más de los hogares que efectivamente caen, sin reducir la precisión. XGBoost, en cambio, gana de forma más pareja entre grupos, y Random Forest no gana en casi ningún subgrupo. Son estimaciones exploratorias, con celdas de unos pocos cientos de hogares y sin intervalos propios por subgrupo. Este patrón contrasta con la evidencia de que la luz nocturna rinde peor en regiones pobres y rurales, donde varía poco (Hall et al., 2023). La diferencia puede estar en el uso: allí la luz nocturna es el único predictor del nivel de bienestar, mientras que aquí complementa una encuesta, de modo que incluso poca variación puede aportar donde las preguntas de la encuesta distinguen menos entre hogares; es una hipótesis que queda por verificar. Si el patrón se confirma, el complemento satelital tendría más sentido focalizado geográficamente, en las zonas rurales y de estratos bajos donde la encuesta es más débil, que como insumo nacional, en línea con Newhouse et al. (2025), para quienes la imagen satelital mejora las estimaciones de pobreza en las

áreas donde la encuesta tiene pocas observaciones.

En suma, la luz nocturna describe bien la geografía de la pobreza, pero no reemplaza a la encuesta.

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento evalúa si las fuentes geoespaciales públicas mejoran la predicción de la caída en pobreza de hogares colombianos no pobres, frente a modelos basados solo en la ELCA. Solo una de las cuatro fuentes consideradas, la iluminación nocturna DMSP-OLS, tiene datos en la ola de entrenamiento y en la de prueba, de modo que es la base de la evaluación principal. El ejercicio estima modelos con cinco algoritmos de aprendizaje supervisado, con y sin ingreso del hogar, bajo pobreza monetaria y multidimensional, con entrenamiento en 2010→2013 y prueba en 2013→2016. A diferencia de los trabajos que predicen la entrada en pobreza con registros administrativos y a un año (Burger & van der Laan, 2021; Hohberg et al., 2018), aquí la predicción se hace a tres años con una encuesta de panel y entrenando con el pasado para evaluar en el futuro, como lo haría un sistema de focalización.

Cinco hallazgos se destacan. **Primero**, la pobreza monetaria cae de 60.7 % a 42.4 % entre 2010 y 2016, pero con mucho movimiento en ambas direcciones: 23.4 % y 19.9 % de los hogares no pobres caen en pobreza en cada ventana, mientras más del doble de hogares sale de ella (Sección 3.3). La mayoría de quienes entran no queda atrapada: de los que caen en 2013, el 58 % vuelve a salir antes de 2016 bajo pobreza monetaria y el 67 % bajo IPM. Bajo IPM, además, la entrada es mucho menor (12.1 % y 9.7 %) y la salida mayor, coherente con que mide privaciones estructurales y no flujos de ingreso. **Segundo**, la capacidad de identificar a los vulnerables tiene un techo (AUC-ROC de 0.73 a 0.77) que no depende del algoritmo ni del ingreso; con un umbral ajustado para captar casi a todos los vulnerables posibles, un programa atendería entre 2.4 y 3.1 hogares no vulnerables por cada uno que sí es (Sección 5.1). **Tercero**, con la información de la ola base es difícil separar a quien cae en pobreza de quien no: los hogares marcados que no caen también son precarios, quienes caen reportan más choques posteriores, y la información de la ola base distingue a “entra” de “sale” apenas por encima del azar (Secciones 5.1.2 y 5.2). **Cuarto**, el hogar vulnerable se reconoce por lo que ha acumulado (riqueza, educación, activos y vivienda) y se parece más al que acaba de salir de la pobreza que al que nunca fue pobre; entre los que caen, quedan atrapados los que tenían menos activos financieros, riqueza y cotización a pensión (Sección 5.2). **Quinto**, y en respuesta a la pregunta de

investigación, las fuentes geoespaciales públicas describen bien la geografía de la pobreza, pero no mejoran la identificación de los hogares vulnerables cuando hay una encuesta robusta vigente. La iluminación nocturna es redundante con unas pocas preguntas de la encuesta bajo pobreza monetaria y aporta un poco bajo IPM, sobre todo en zonas rurales; su ventaja es su estabilidad en el tiempo. ALOS PALSAR y Landsat 5 TM reproducen el mismo gradiente y, como la luz nocturna, no agregan información a la encuesta; las fotos de Street View predicen bien la luz de su zona, pero su cobertura aún es limitada. Como solo pudieron evaluarse sensores con datos en 2010 y 2013, los actuales, de mayor resolución, son la frontera por explorar (Secciones 5.3 y 6.3).

En conjunto, estos hallazgos indican que los modelos identifican bien la precariedad, pero no quién caerá. La precariedad es condición necesaria pero no suficiente: los hogares marcados que no caen también son precarios, y el que entra en pobreza es casi indistinguible del que sale. El límite está en la información y no en el modelo. La regresión logística rinde casi igual que los algoritmos más flexibles, que además eligen árboles poco profundos; parte de quién cae depende de choques posteriores a la predicción; y la clasificación misma es sensible al umbral, pues mover la línea de pobreza un 10 % cambia en unos diez puntos la distribución de las transiciones (Anexo A.2). Que la luz nocturna, medida de forma independiente de la encuesta, reproduzca el mismo gradiente y la misma cercanía entre quien entra y quien sale indica que este resultado no depende de la encuesta. Esto sugiere que anticipar mejor la caída exige información más frecuente y más cercana a los choques, más que algoritmos más complejos.

6.2. Implicaciones para la política pública

Los resultados sugieren cinco implicaciones para sistemas de focalización como el SISBEN IV y el Registro Social de Hogares, que hoy clasifican a los hogares por su estándar de vida y su capacidad presunta de generar ingresos; los modelos de este artículo podrían complementarlos con una medida del riesgo de entrada en pobreza de los hogares que hoy no son pobres. **Primero**, la focalización puede apoyarse en variables no monetarias, que capturan casi toda la señal; cuando la información del hogar está desactualizada o incompleta, un conjunto reducido centrado en el núcleo podría servir como alternativa. **Segundo**, el umbral debe depender del costo del instrumento: amplio para intervenciones preventivas de bajo costo, donde los incluidos por error también son precarios, y concentrado en el decil de mayor riesgo para transferencias costosas. **Tercero**, si la asociación con los choques se confirma, la focalización podría hacerse en dos etapas, en las que el modelo define quién está en riesgo y un choque activa el apoyo, verificando el choque y no el perfil y actualizando la lista con frecuencia. Esto respondería a una limitación de la protección

social reactiva a choques en la región, que ha dependido sobre todo de ampliar los beneficios de quienes ya estaban en los programas y ha dejado por fuera a muchos hogares afectados (Costella et al., 2023). **Cuarto**, como la salida de la pobreza tampoco se anticipa con la información de la ola base, la graduación debería ser gradual y con seguimiento, y la falta de activos financieros y de cotización podría orientar la duración del apoyo. **Quinto**, la iluminación nocturna no se justifica como covariable de rutina con una encuesta vigente, pero sí para priorizar territorios y como alternativa a la desactualización entre rondas, sobre todo en zonas rurales. Lo mismo vale para el radar y las imágenes ópticas: no agregan información a la encuesta, pero reproducen el mismo gradiente que la luz nocturna y podrían cumplir esa misma función territorial. Las fotos de calle predicen bien la luz nocturna de su zona y su cobertura crece rápido: el 61 % de las encontradas para los hogares de la ELCA es de 2023 en adelante.

6.3. Limitaciones y agenda de investigación

Los principales límites son seis. En los determinantes, la importancia SHAP describe cómo el modelo usa cada variable, no un efecto causal ni un aporte fuera de muestra y reparte el efecto entre variables correlacionadas. En los errores del modelo, los choques se reportan en 2016 y su relación con la caída es descriptiva. En DMSP-OLS, la heterogeneidad por subgrupos es exploratoria. En la muestra, la separación entre pobres transitorios y persistentes se apoya en 610 de 723 hogares. En las fuentes geoespaciales, los resultados corresponden a los únicos sensores con datos en 2010 y 2013 (DMSP-OLS, ALOS PALSAR y Landsat 5 TM), que tienen menor resolución y frecuencia que los actuales. VIIRS DNB, Sentinel-1 y Sentinel-2 empezaron a operar después de 2012 y no pudieron evaluarse con el panel, y las fotos de Street View se concentran en años recientes (Anexo B.2). En la representatividad, la atrición no es aleatoria: se concentra en hogares urbanos y de estrato alto (16.2 % de los urbanos frente a 5.8 % de los rurales entre 2010 y 2013), y se excluyen los hogares que se dividieron entre olas.

Los resultados bajo IPM tienen además un límite de medición: el indicador de barreras de acceso a salud se mide en 2010 con un proxy distinto al de 2013 y 2016, y el 79 % de los hogares que salen de la pobreza IPM entre 2010 y 2013 lo hacen perdiendo justamente esa privación. Armonizarlo con la pregunta directa tampoco resuelve el problema, por diferencias en quiénes la responden. Por eso, los resultados IPM que dependen de 2010→2013 deben leerse como condicionales al proxy, y la ventana 2013→2016 es la comparación más limpia.

La agenda de investigación que se desprende de estos resultados tiene cinco frentes. Primero, pasar del perfil al choque. Quien cae se distingue sobre todo por choques famil-

iares posteriores a la predicción, que ni la encuesta ni los satélites observan. Registros administrativos de actualización frecuente, como el empleo formal, la afiliación y el uso de servicios de salud o las actualizaciones del SISBEN IV y del Registro Social de Hogares, podrían detectar el choque cuando ocurre; para los choques compartidos, como sequías o pérdidas de cosecha, servirían series de precipitación y de vegetación de alta frecuencia. La pregunta es cuánto del techo de desempeño se supera con señales del choque, frente a seguir refinando el perfil del hogar.

Segundo, pasar de la transición binaria a la trayectoria. Como la mayoría de quienes caen vuelve a salir y la clasificación es sensible a la ubicación de la línea, modelos de duración que estimen la probabilidad de caer y de permanecer en la pobreza, o que predigan el bienestar como variable continua con su incertidumbre, aprovecharían mejor la información. Permitirían además contrastar si las variables de acumulación indican quién es vulnerable y las de actividad económica reciente, cuánto dura esa condición. Las olas de 2019 y 2022 de la ELCA, administradas por el DANE y georreferenciadas, rodean la pandemia de COVID-19 y ofrecen una prueba poco común: verificar si los hogares que un modelo entrenado antes de 2020 marcó como vulnerables cayeron más ante un choque grande y no anticipado.

Tercero, evaluar la teledetección actual con una pregunta mejor planteada. Aquí solo pudieron usarse sensores con datos en 2010 y 2013, de menor resolución y frecuencia, y con índices contruidos a mano. VIIRS DNB, Sentinel-1 y Sentinel-2, sobre las olas recientes de la ELCA, permitirían aprender directamente de la imagen y medir el cambio del entorno en el tiempo, y no solo su nivel. Más que preguntar si el satélite mejora una encuesta vigente, conviene medir cuánto se degrada la predicción a medida que la encuesta envejece y si la imagen satelital puede actualizarla entre rondas. Es un campo reciente, cuyas fuentes mejoran rápido, y lo encontrado aquí es un piso, no un techo.

Cuarto, convertir las imágenes a nivel de calle en una fuente utilizable. Las fotos de Street View predicen bien la luz nocturna de su zona, la relación se mantiene con fotos tomadas más de diez años después y los modelos entrenados con escenas urbanas dan el mejor ajuste (Anexo A.8). Falta corregir su sesgo de cobertura hacia las zonas urbanas e iluminadas, extraer rasgos de la vivienda y de su entorno inmediato, y resolver las implicaciones de privacidad de usar imágenes de viviendas identificables.

Quinto, pasar de la predicción a la decisión de focalización. Las métricas estadísticas no dicen cuánto cuesta cada error: hace falta valorarlos según su costo social, verificar si se reparten igual entre zonas, grupos étnicos o según el sexo del jefe, y distinguir a quien va a caer de quien se beneficiaría de una intervención, que no son lo mismo. Un piloto de la focalización en dos etapas propuesta en la Sección 6.2, con el modelo para definir el riesgo

y un choque verificado para activar el apoyo, conectaría estos resultados con el diseño del SISBEN IV y del Registro Social de Hogares.

Disponibilidad de datos y código

[En construcción: el enlace al repositorio y su identificador permanente (DOI) se agregarán en la versión final.]

El código que reproduce todas las tablas, figuras y cifras de este documento se publicará en un repositorio de acceso abierto, archivado con un identificador permanente. El paquete permitirá reproducir los resultados en dos niveles. Con acceso a los datos originales, se podrá repetir todo el proceso, desde la construcción del panel hasta el entrenamiento de los modelos. Sin ese acceso, cualquier persona podrá regenerar todas las tablas y figuras a partir de los resultados agregados que se publican con el código, que no contienen información individual de los hogares.

Los microdatos de la ELCA se obtienen de la Universidad de los Andes, según sus condiciones de acceso. Las coordenadas de los hogares, necesarias para construir las variables geoespaciales, son de acceso restringido y solo pueden consultarse en la sala de procesamiento de datos de la Universidad de los Andes. Las fuentes satelitales (DMSP-OLS, ALOS PALSAR y Landsat 5 TM) son públicas y se obtienen con los scripts del repositorio a través de Google Earth Engine; las imágenes de Google Street View no se redistribuyen, por sus condiciones de uso.

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Angulo Salazar, R. C., Díaz Cuervo, Y., & Pardo Pinzón, R. (2011). *Índice de Pobreza Multidimensional para Colombia (IPM-Colombia) 1997-2010* (Archivos de Economía N.º 382). Departamento Nacional de Planeación, Dirección de Estudios Económicos. Bogotá.
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (CPRC Working Paper N.º 170). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Burger, J., & van der Laan, J. (2021). Predicting Transitions into and out of Poverty Using Machine Learning. *Proceedings of Statistics Canada Symposium 2021: Adopting Data Science in Official Statistics to Meet Society's Emerging Needs*.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). *Assessing Household Vulnerability to Poverty from Cross-Sectional Data: A Methodology and Estimates from Indonesia* (Discussion Paper N.º 0102-52). Department of Economics, Columbia University.
- Christiaensen, L. J., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Cornia, G. A., & Stewart, F. (1993). Two Errors of Targeting. *Journal of International Development*, 5(5), 459-496. <https://doi.org/10.1002/jid.3380050503>

- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Davis, J., & Goadrich, M. (2006). The Relationship Between Precision-Recall and ROC Curves. *Proceedings of the 23rd International Conference on Machine Learning*, 233-240. <https://doi.org/10.1145/1143844.1143874>
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/00220380008422653>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2026). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of Sustainable Development & World Ecology*, 33(1), 68-80. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature. En J. Silber & G. Wan (Eds.), *The Asian 'Poverty Miracle': Impressive Accomplishments or Incomplete Achievements?* (pp. 53-83). Edward Elgar.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*, 35, 1753-1768. <https://doi.org/10.1002/jid.3751>
- Hernández, J. E., & Zuluaga, B. (2022). Vulnerability to Multidimensional Poverty: An Application to Colombian Households. *Social Indicators Research*, 164, 345-371. <https://doi.org/10.1007/s11205-022-02961-2>
- Hofer, M., Sako, T., Martinez, A., Jr., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*, 39(1), 98-129. <https://doi.org/10.1111/asej.12349>
- Hohberg, M., Landau, K., Kneib, T., Klasen, S., & Zucchini, W. (2018). Vulnerability to Poverty Revisited: Flexible Modeling and Better Predictive Performance. *The*

- Journal of Economic Inequality*, 16(3), 439-454. <https://doi.org/10.1007/s10888-017-9374-6>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Studies*, 36(6), 82-99. <https://doi.org/10.1080/00220380008422655>
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juarez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juarez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón-Santa, G., Escobar-Grisales, D., López-Pabón, F. O., Pérez-Toro, P. A., & Orozco-Arroyave, J. R. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>
- Newhouse, D., Ramakrishnan, A., Swartz, T., Merfeld, J., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Pabón, L., & Briceño, G. D. (2023). El Registro Social de Hogares: un nuevo sistema de información para la política social. *Planeación & Desarrollo*. <https://colaboracion.dnp.gov.co/CDT/PublishingImages/Planeacion-y-desarrollo/2023/agosto/pdf/nota-registro-social.pdf>
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>

Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

A.1. Correlación entre covariables y riesgo de multicolinealidad

Complemento de la Sección 4.3: análisis de correlación de Pearson entre las 159 variables numéricas del dataset consolidado –incluidas las 4 geoespaciales–, motivado por el riesgo de multicolinealidad para el modelo de regresión logística regularizada.


Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 18), solo se reportan como “altas” los pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican los 35 pares de la Figura 6.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan 0.96 o más con su propia brecha a la LP; `lp` y `li` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal correlacionan -0.93 (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmsp_stable_lights` correlaciona 0.86 con la línea de pobreza `lp` y 0.87 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`), que a su vez correlacionan 0.81 entre sí. Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.1 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la

Sección 5.3.1.

Figura 6: Pares de covariables con correlación de Pearson mayor que 0.7 en valor absoluto, 2010, 2013 y 2016.



Nota: Correlaciones calculadas sobre al menos 500 observaciones conjuntas no nulas y ordenadas por magnitud; en rojo, las negativas. La mayoría corresponde a redundancias esperables (medidas nominal y real de un mismo concepto, o un indicador individual y su agregado a nivel de hogar); la más relevante para este trabajo es la de la iluminación nocturna con las líneas de pobreza e indigencia y con el número de servicios públicos, que se retoma en la Sección 5.3.1. Fuente: cálculos propios.


A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria

Complemento de la Sección 3.3: incidencia agregada de pobreza monetaria por ingreso y por gasto, su descomposición Foster-Greer-Thorbecke (FGT), y cinco ejercicios diseñados para evaluar qué tan sensible es la variable de transición a la pobreza –la variable de interés de este artículo– a decisiones de construcción del ingreso, a la representatividad muestral y al error de medición cerca del umbral de pobreza.

A.2.1. Incidencia y descomposición FGT

La Figura 7 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más *baja* que la de ingreso en los tres puntos del panel (47.6 %, 40.9 % y 33.4 %): la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto. Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no depende de la medida de bienestar elegida.

Figura 7: Incidencia de la pobreza monetaria por ingreso y por gasto, 2010, 2013 y 2016.




Nota: Incidencia (P0) frente a la línea de pobreza oficial. Fuente: cálculos propios.

La Figura 8 descompone la pobreza por ingreso en sus tres componentes FGT: incidencia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los

pobres respecto a la LP, como fracción de la LP— cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad —que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres— cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.

Figura 8: Indicadores FGT de la pobreza monetaria por ingreso, 2010, 2013 y 2016.



Nota: Incidencia (P0), brecha (P1) y severidad (P2) frente a la línea de pobreza oficial. Fuente: cálculos propios.

A.2.2. Ejercicios de robustez

Se implementaron cinco ejercicios de robustez sobre las cifras de transición de la Sección 3.3: ponderación muestral, dos reclasificaciones del ingreso, sensibilidad al umbral de pobreza, y atrición del panel.

Ponderación muestral. Ninguno de los resultados de la Sección 3.3 usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (*fexhog*, *fexhog_2013*, ambos transversales, y *fexhog_2010*, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % → 60.4 % en 2010, 52.4 % → 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % → 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 % a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos

periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.


Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorrateados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de este artículo. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010→2013. El efecto es el mayor de las dos reclasificaciones del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se repitieron las matrices de transición (Figura 9). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % ($LP - 10\%$) y

49.1 % (LP+10 %) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.


Figura 9: Sensibilidad de los grupos de transición a una banda de $\pm 10\%$ alrededor de la línea de pobreza, pobreza monetaria, 2010→2013 y 2013→2016.



Nota: Distribución de los hogares del panel emparejado entre los cuatro grupos con la línea de pobreza oficial (LP) y con líneas 10 % más baja y 10 % más alta. Fuente: cálculos propios.

La Figura 10 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.


Figura 10: Robustez de los grupos de transición a definiciones alternativas del ingreso del hogar, pobreza monetaria, 2010→2013 y 2013→2016.



Nota: Base: ingreso de la definición oficial, sin ponderar. Sin excepcional: sin los ingresos excepcionales (herencias, pólizas, venta de inmuebles o negocios y otros). Sin ing. ayudas: sin el ingreso por ayudas, solo disponible en 2010→2013. Fuente: cálculos propios.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 11). La atrición total es de 11.4% en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). Esa cifra agregada sí se desagregó por perfil de hogar: la atrición **no es aleatoria**, se concentra sistemáticamente en hogares urbanos y de estrato más alto. Por zona, la tasa de pérdida es 2.8 veces mayor en zona urbana que en zona rural en 2010–2013 (16.2% vs. 5.8%) y 1.7 veces mayor en 2013–2016 (14.1% vs. 8.2%); por estrato socioeconómico, la pérdida crece monótonamente de 8.9% en estrato 1 a 26.0% en estrato 4 en 2010–2013. Por región, Bogotá tiene la mayor pérdida (24.9%) y Centro-Oriente la menor (3.1%). El patrón es consistente con que los hogares urbanos y de mayor estrato son más móviles (cambian de vivienda con más frecuencia), lo que dificulta su relocalización entre olas del panel –no con una atrición concentrada en los hogares más pobres, que de hecho es la más baja de las cuatro categorías de estrato–. No se investigó si, controlando por zona/estrato/región, la atrición está además asociada al estado de pobreza mismo del hogar (una limitación que se retoma en la Sección 6.3).

Figura 11: Atrición total del panel entre olas consecutivas, 2010→2013 y 2013→2016.



Nota: Hogares de la ola inicial que no aparecen en absoluto en la ola siguiente. Fuente: cálculos propios.

A.3. Soporte del núcleo SHAP

Complemento de la Sección 5.2: concentración de la señal SHAP y sensibilidad del núcleo y de su dirección a los umbrales elegidos.

Tabla 7: Concentración de la importancia SHAP por algoritmo y especificación, pobreza monetaria, 2013→2016.

Algoritmo	Espec.	Variables (total)	% SHAP en las 10 primeras	Variables para el 80 % del SHAP
HistGradientBoosting	A	169	69.3 %	15
XGBoost	A	169	58.7 %	23
Logística regularizada	A	169	43.9 %	28
Random Forest	A	169	59.8 %	32
LightGBM	A	169	44.4 %	37
LightGBM	B	165	71.6 %	14
HistGradientBoosting	B	165	63.9 %	18
XGBoost	B	165	54.7 %	26
Logística regularizada	B	165	45.8 %	28
Random Forest	B	165	54.9 %	34

Nota: Importancia SHAP calculada sobre el conjunto de prueba. Variables originales: las *dummies one-hot* y los indicadores de faltante se suman a su variable de origen antes de calcular la masa acumulada. Espec.: especificación (A con ingreso y gasto del hogar, B sin ellos). Fuente: cálculos propios.

Tabla 8: Sensibilidad del núcleo SHAP y de su dirección a los umbrales elegidos, pobreza monetaria e IPM, 2010→2013 y 2013→2016.

<i>A. Núcleo: masa SHAP acumulada y mínimo de combinaciones (de 10)</i>				
Masa	Mín. comb.	Núcleo	Conserva de las 22	Universales en las 4 fuentes (de 7)
70 %	4	19	17	6
70 %	5	13	13	4
70 %	6	11	11	3
80 %	4	30	22	7
80 %	5	22 (base)	22	7
80 %	6	20	20	5
90 %	4	50	22	7
90 %	5	35	22	7
90 %	6	31	22	7
<i>B. Dirección: ρ mínimo y proporción mínima de signo</i>				
$ \rho $ mín.	Prop. mín.	Consistentes (de 20)		
0.05	0.70	12		
0.05	0.80	10		
0.05	0.90	7		
0.10	0.70	12		
0.10	0.80	10 (base)		
0.10	0.90	7		
0.15	0.70	12		
0.15	0.80	10		
0.15	0.90	6		
0.20	0.70	12		
0.20	0.80	10		
0.20	0.90	6		

Nota: “(base)”: criterio usado en el texto (Sección 5.2). El núcleo de 22 variables se conserva por completo con criterios más laxos; con los más estrictos queda un subconjunto. Las cuatro fuentes son las dos definiciones de pobreza en las dos ventanas. Fuente: cálculos propios.

A.4. Desempeño de los modelos bajo pobreza multidimensional (IPM)

Complemento de la Sección 5.1: mismo benchmark de cinco algoritmos y misma metodología robusta (holdout temporal, CV_FOLDS=10, N_ITER_BUSQUEDA=30, 5 semillas), con pobreza multidimensional (IPM) como variable de resultado en vez de

pobreza monetaria – covariables idénticas.¹⁰

Tabla 9: Desempeño de los cinco algoritmos en el conjunto de prueba, pobreza multidimensional (IPM), 2013→2016.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precisión	Prec.-top10	F1
LightGBM	A	0.11	0.741	0.670	0.184	0.263	0.288
HistGradientBoosting	A	0.11	0.740	0.603	0.197	0.271	0.295
Logística regularizada	A	0.10	0.730	0.726	0.166	0.258	0.269
Random Forest	A	0.31	0.729	0.645	0.183	0.253	0.285
XGBoost	A	0.11	0.725	0.844	0.139	0.251	0.239
HistGradientBoosting	B	0.10	0.739	0.620	0.189	0.265	0.289
Random Forest	B	0.26	0.735	0.753	0.165	0.260	0.270
LightGBM	B	0.08	0.730	0.721	0.167	0.251	0.270
Logística regularizada	B	0.11	0.730	0.716	0.167	0.255	0.270
XGBoost	B	0.09	0.728	0.901	0.130	0.258	0.228

Nota: Promedio de 5 semillas, entrenamiento en 2010→2013. Misma metodología y covariables que la Tabla 2; solo cambia la variable de resultado. Espec.: especificación (A con ingreso y gasto del hogar, B sin ellos). Prec.-top10: precisión en el 10 % de hogares con mayor riesgo predicho. Fuente: cálculos propios.

A.5. Aporte de DMSP-OLS: resultados detallados

Complemento de la Sección 5.3: desempeño de los cinco algoritmos con y sin las variables de DMSP-OLS bajo pobreza monetaria (Tabla 10) y significancia del cambio de AUC-ROC bajo IPM (Tabla 11).

¹⁰Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Random Forest (Aipm y Bipm), donde fue *balanced* (reponderación de clases).

Tabla 10: AUC-ROC y precisión en el decil de mayor riesgo con y sin DMSP-OLS en el conjunto de prueba, pobreza monetaria, 2013→2016.

Algoritmo	Especificación	AUC-ROC	IC95 %	Prec.-top10	IC95 %	Umbral	Recall	Precisión	F1	Brecha CV
Random Forest	A	0.766	[0.765, 0.767]	0.486	[0.476, 0.495]	0.138	0.926	0.277	0.426	+0.000
Random Forest	A + DMSP-OLS	0.763	[0.762, 0.764]	0.481	[0.470, 0.493]	0.264	0.938	0.271	0.420	+0.002
XGBoost	A	0.767	[0.766, 0.769]	0.505	[0.496, 0.514]	0.112	0.949	0.264	0.413	−0.001
XGBoost	A + DMSP-OLS	0.765	[0.764, 0.766]	0.501	[0.488, 0.515]	0.118	0.937	0.272	0.421	+0.000
LightGBM	A	0.758	[0.758, 0.758]	0.516	[0.516, 0.516]	0.096	0.903	0.281	0.428	+0.003
LightGBM	A + DMSP-OLS	0.752	[0.752, 0.752]	0.497	[0.497, 0.497]	0.102	0.902	0.277	0.424	+0.011
HistGradientBoosting	A	0.763	[0.763, 0.763]	0.512	[0.512, 0.512]	0.324	0.909	0.283	0.432	−0.003
HistGradientBoosting	A + DMSP-OLS	0.763	[0.763, 0.763]	0.500	[0.500, 0.500]	0.312	0.912	0.281	0.429	−0.002
Logística regularizada	A	0.747	[0.747, 0.747]	0.506	[0.506, 0.506]	0.372	0.883	0.280	0.426	+0.015
Logística regularizada	A + DMSP-OLS	0.746	[0.746, 0.746]	0.500	[0.500, 0.500]	0.370	0.883	0.281	0.426	+0.015
Random Forest	B	0.742	[0.741, 0.744]	0.508	[0.497, 0.520]	0.306	0.892	0.272	0.416	+0.013
Random Forest	B + DMSP-OLS	0.739	[0.737, 0.741]	0.492	[0.482, 0.502]	0.266	0.925	0.255	0.399	+0.015
XGBoost	B	0.742	[0.742, 0.743]	0.495	[0.487, 0.503]	0.126	0.940	0.250	0.395	+0.014
XGBoost	B + DMSP-OLS	0.740	[0.740, 0.741]	0.495	[0.491, 0.499]	0.128	0.929	0.254	0.399	+0.016
LightGBM	B	0.731	[0.731, 0.731]	0.487	[0.487, 0.487]	0.148	0.909	0.259	0.403	+0.024
LightGBM	B + DMSP-OLS	0.737	[0.737, 0.737]	0.481	[0.481, 0.481]	0.126	0.888	0.271	0.415	+0.019
HistGradientBoosting	B	0.735	[0.735, 0.735]	0.494	[0.494, 0.494]	0.142	0.879	0.275	0.418	+0.017
HistGradientBoosting	B + DMSP-OLS	0.736	[0.736, 0.736]	0.487	[0.487, 0.487]	0.142	0.880	0.275	0.419	+0.018
Logística regularizada	B	0.739	[0.739, 0.739]	0.500	[0.500, 0.500]	0.350	0.890	0.270	0.414	+0.018
Logística regularizada	B + DMSP-OLS	0.739	[0.739, 0.739]	0.494	[0.494, 0.494]	0.350	0.888	0.273	0.417	+0.018

Nota: Entrenamiento en 2010→2013. Promedio de 5 semillas; IC95 % sobre las semillas. Prec.-top10: precisión en el 10 % de hogares con mayor riesgo predicho. *Recall*, precisión y F1 se miden al umbral ya elegido para cada algoritmo y especificación por validación cruzada maximizando F_2 (Sección 4.5). Brecha CV: AUC de validación cruzada menos AUC en prueba; si agregar DMSP-OLS sobreajustara, se ensancharía frente a la especificación sin DMSP-OLS. Fuente: cálculos propios.

Tabla 11: Significancia del cambio en el AUC-ROC al agregar DMSP-OLS, pobreza monetaria e IPM, 2013→2016.

Algoritmo	Espec.	ΔAUC	IC95 %	p	p por comunidad
<i>Pobreza monetaria</i>					
XGBoost	A	−0.003	[−0.005, +0.001]	0.102	0.085
Random Forest	A	−0.002	[−0.006, +0.002]	0.258	—
LightGBM	A	−0.006	[−0.012, +0.001]	0.079	—
HistGradientBoosting	A	−0.000	[−0.003, +0.002]	0.800	0.802
Logística regularizada	A	−0.001	[−0.001, +0.000]	0.138	0.163
XGBoost	B	−0.002	[−0.005, +0.002]	0.266	0.308
Random Forest	B	−0.004	[−0.008, +0.000]	0.051	—
LightGBM	B	+0.006	[−0.001, +0.013]	0.078	—
HistGradientBoosting	B	+0.001	[−0.002, +0.003]	0.642	0.622
Logística regularizada	B	−0.001	[−0.001, +0.000]	0.138	0.154
<i>Pobreza multidimensional (IPM)</i>					
XGBoost	A	+0.013	[+0.004, +0.022]	0.006	0.004
Random Forest	A	+0.001	[−0.006, +0.008]	0.754	—
LightGBM	A	+0.004	[−0.001, +0.008]	0.091	—
HistGradientBoosting	A	−0.002	[−0.007, +0.004]	0.541	0.548
Logística regularizada	A	−0.000	[−0.001, +0.001]	0.934	0.954
XGBoost	B	+0.020	[+0.010, +0.030]	0.001	0.000
Random Forest	B	−0.004	[−0.012, +0.005]	0.429	—
LightGBM	B	+0.017	[+0.008, +0.026]	0.000	—
HistGradientBoosting	B	+0.002	[−0.004, +0.007]	0.595	0.569
Logística regularizada	B	−0.000	[−0.001, +0.001]	0.978	0.926

Nota: ΔAUC , IC95 % y p : *bootstrap* pareado sobre el conjunto de prueba (una semilla). p por comunidad: remuestreo agrupado por comunidad (1,696 comunidades), porque hogares de una misma comunidad comparten en buena medida el mismo píxel de luz nocturna (resolución de ~ 1 km); “—”: corrección no estimada. Fuente: cálculos propios.

A.6. Heterogeneidad del aporte de DMSP-OLS por subgrupos

Complemento de la Sección 5.3.2: cambio en el AUC-ROC al agregar DMSP-OLS por eje de heterogeneidad, grupo, especificación y algoritmo. Bajo pobreza monetaria el efecto nulo se mantiene parejo en los cuatro ejes explorados (Tabla 12); bajo IPM la ganancia se concentra en algunos subgrupos (Tabla 13).

Tabla 12: Cambio en el AUC-ROC al agregar DMSP-OLS por subgrupo, pobreza monetaria, 2013→2016.

Eje	Grupo	Espec.	<i>n</i>	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	1,170	-0.004	-0.008	-0.009	-0.003	-0.003
	Rural	B	1,170	-0.001	-0.007	+0.012	-0.000	-0.002
	Urbano	A	2,021	-0.003	+0.001	-0.006	+0.001	-0.000
	Urbano	B	2,021	-0.003	-0.004	+0.003	-0.001	-0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	798	-0.003	-0.006	+0.000	-0.002	-0.000
	Q1 (mas cerca de LP)	B	798	+0.002	-0.008	+0.004	+0.001	-0.000
	Q2	A	798	-0.001	+0.006	+0.006	+0.001	-0.001
	Q2	B	798	-0.001	-0.002	+0.011	+0.001	-0.001
	Q3	A	798	-0.007	-0.008	-0.019	-0.001	-0.002
	Q3	B	798	-0.006	-0.005	-0.000	-0.000	-0.002
	Q4 (mas lejos)	A	797	-0.005	+0.000	-0.022	-0.001	-0.001
	Q4 (mas lejos)	B	797	-0.011	-0.004	-0.011	-0.002	-0.000
Estrato	Estrato 1	A	903	-0.003	-0.001	-0.001	-0.005	-0.002
	Estrato 1	B	903	-0.002	-0.008	+0.018	+0.000	-0.002
	Estrato 2	A	1,390	-0.002	-0.002	-0.005	+0.004	+0.000
	Estrato 2	B	1,390	-0.004	+0.002	+0.004	+0.003	+0.000
	Estrato 3	A	741	-0.003	-0.001	-0.006	+0.000	-0.001
	Estrato 3	B	741	-0.007	-0.016	-0.009	-0.006	-0.001
Servicios y bienes	Tercil bajo	A	1,087	-0.005	-0.009	-0.007	-0.003	-0.003
	Tercil bajo	B	1,087	-0.004	-0.009	+0.013	-0.001	-0.003
	Tercil medio	A	1,121	+0.002	+0.002	-0.004	+0.001	+0.001
	Tercil medio	B	1,121	+0.004	-0.004	+0.008	+0.003	+0.001
	Tercil alto	A	983	-0.015	-0.005	-0.006	+0.001	-0.001
	Tercil alto	B	983	-0.017	-0.009	-0.005	-0.009	+0.000

Nota: Cambio en el AUC-ROC del conjunto de prueba al agregar DMSP-OLS, por subgrupo. En **negrita**: $|\Delta| \geq 0.02$. Se omiten los grupos con $n < 30$. Espec.: especificación (A con ingreso y gasto del hogar, B sin ellos). XGB: XGBoost; RF: Random Forest; LGBM: LightGBM; HGB: HistGradientBoosting; Log.: logística regularizada. Fuente: cálculos propios.

Tabla 13: Cambio en el AUC-ROC al agregar DMSP-OLS por subgrupo, pobreza multidimensional (IPM), 2013→2016.

Eje	Grupo	Espec.	<i>n</i>	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	2,452	+0.012	+0.006	+0.010	+0.005	+0.001
	Rural	B	2,452	+0.019	+0.004	+0.032	+0.009	+0.001
	Urbano	A	3,119	+0.013	-0.002	+0.000	-0.005	-0.000
	Urbano	B	3,119	+0.018	-0.015	+0.008	-0.004	+0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	1,393	+0.009	-0.005	+0.003	+0.003	-0.001
	Q1 (mas cerca de LP)	B	1,393	+0.015	+0.001	+0.012	+0.003	-0.001
	Q2	A	1,394	+0.024	-0.006	+0.010	-0.012	-0.000
	Q2	B	1,394	+0.039	-0.013	+0.032	-0.006	-0.000
	Q3	A	1,392	+0.025	+0.009	+0.002	+0.009	+0.003
	Q3	B	1,392	+0.025	-0.008	+0.030	+0.006	+0.003
	Q4 (mas lejos)	A	1,392	+0.013	+0.011	+0.003	-0.009	-0.004
	Q4 (mas lejos)	B	1,392	+0.019	-0.015	-0.008	+0.015	-0.003
Estrato	Estrato 1	A	2,046	+0.010	+0.002	+0.005	+0.004	-0.001
	Estrato 1	B	2,046	+0.018	+0.004	+0.024	-0.002	-0.001
	Estrato 2	A	2,439	+0.020	+0.003	+0.007	-0.008	+0.002
	Estrato 2	B	2,439	+0.027	-0.006	+0.015	+0.005	+0.002
	Estrato 3	A	889	-0.007	-0.006	-0.006	-0.005	+0.002
	Estrato 3	B	889	+0.005	-0.031	-0.003	+0.009	+0.003
Servicios y bienes	Tercil bajo	A	1,858	+0.014	+0.003	+0.008	+0.001	+0.001
	Tercil bajo	B	1,858	+0.021	-0.003	+0.030	+0.003	+0.000
	Tercil medio	A	1,977	+0.007	+0.004	+0.002	-0.006	+0.000
	Tercil medio	B	1,977	+0.018	-0.004	+0.019	-0.001	+0.000
	Tercil alto	A	1,736	+0.034	-0.001	+0.004	+0.001	+0.000
	Tercil alto	B	1,736	+0.033	-0.030	+0.009	+0.005	+0.000

Nota: Cambio en el AUC-ROC del conjunto de prueba al agregar DMSP-OLS, por subgrupo. En **negrita**: $|\Delta| \geq 0.02$. Se omiten los grupos con $n < 30$. Espec.: especificación (A con ingreso y gasto del hogar, B sin ellos). XGB: XGBoost; RF: Random Forest; LGBM: LightGBM; HGB: HistGradientBoosting; Log.: logística regularizada. Fuente: cálculos propios.

A.7. Aporte de las tres fuentes geoespaciales juntas bajo pobreza monetaria

Complemento de la Sección 5.3.1: desempeño de los Modelos A y B al agregar las 127 variables de DMSP-OLS, ALOS PALSAR y Landsat 5 TM juntas, frente a los mismos

modelos sin variables geoespaciales, bajo el mismo esquema de validación cruzada.

Tabla 14: AUC-ROC y precisión en el decil de mayor riesgo con y sin las tres fuentes geoespaciales en validación cruzada, pobreza monetaria, 2010→2013.

Algoritmo	Especificación	N.º var.	AUC-ROC	IC95 %	Δ AUC	Prec.-top10
XGBoost	A	169	0.766	[0.764, 0.767]	–	0.577
XGBoost	A + 3 fuentes	296	0.765	[0.763, 0.767]	–0.000	0.574
HistGradientBoosting	A	169	0.760	[0.757, 0.762]	–	0.583
HistGradientBoosting	A + 3 fuentes	296	0.757	[0.755, 0.759]	–0.003	0.560
Logística regularizada	A	169	0.760	[0.759, 0.761]	–	0.548
Logística regularizada	A + 3 fuentes	296	0.755	[0.753, 0.756]	–0.006	0.547
XGBoost	B	165	0.757	[0.755, 0.759]	–	0.563
XGBoost	B + 3 fuentes	292	0.756	[0.754, 0.757]	–0.001	0.581
HistGradientBoosting	B	165	0.753	[0.751, 0.755]	–	0.568
HistGradientBoosting	B + 3 fuentes	292	0.750	[0.749, 0.752]	–0.003	0.566
Logística regularizada	B	165	0.755	[0.753, 0.756]	–	0.544
Logística regularizada	B + 3 fuentes	292	0.751	[0.750, 0.753]	–0.004	0.557

Nota: Las tres fuentes suman 127 variables (DMSP-OLS, ALOS PALSAR y Landsat 5 TM). Validación cruzada de 10 particiones dentro de 2010→2013; media e IC95 % sobre 5 semillas. ALOS PALSAR y Landsat 5 TM no tienen dato en 2013, por lo que esta variante no admite la evaluación en el conjunto de prueba 2013→2016 de la Tabla 10: las métricas se calculan sobre probabilidades *out-of-fold* y son comparables entre sí, no contra esa tabla. Solo se estimaron modelos con los tres algoritmos mostrados. N.º var.: covariables que recibe el modelo. Prec.-top10: precisión en el 10 % de hogares con mayor riesgo predicho. Fuente: cálculos propios.

A.8. Google Street View (exploratorio)

Complemento de las Secciones 3.1 y 6.3: resultados del diagnóstico exploratorio de las fotografías de Google Street View. La Tabla 15 mide qué tan bien predicen las representaciones de las fotos la luz nocturna de su zona y qué tan estables son entre olas; la Tabla 16, su cobertura y su relación con la caída en pobreza; y la Tabla 17, si la relación con la luz se mantiene con fotos tomadas años después y si depende del modelo de imagen.

Tabla 15: Predicción de la luz nocturna a partir de las fotos de Google Street View y estabilidad en el tiempo, 2013 (exploratorio).

Modelo de imagen	R^2 , ventana 2011–2013	R^2 , ventana 2011–2015	Correlación entre olas
CLIP	0.699	0.737	+0.197
VGG19	0.634	0.709	−0.160
ResNet50	0.702	0.745	−0.152
Places365	0.738	0.771	+0.177

Nota: R^2 fuera de muestra de predecir la luz nocturna estable (DMSP-OLS) de la zona a partir de la representación de la foto ($n = 830$ hogares con la ventana original y $n = 1,280$ con la ampliada). Correlación entre olas: del primer componente de la representación para los mismos hogares ($n = 87$), comparable con 0.958 de la luz nocturna y 0.600 de los bienes durables. Fuente: cálculos propios.

Tabla 16: Cobertura de las fotos de Google Street View y su relación con la caída en pobreza, pobreza monetaria, 2013→2016 (exploratorio).

Indicador	Valor	n
<i>Luz nocturna media según cobertura de fotos</i>		
Sin foto	7.0	2,188
Con foto fuera de la ventana de fechas	42.0	5,407
Con foto dentro de la ventana (muestra usada)	42.3	830
<i>Caer en pobreza: regresión logística conjunta (IC95 %)</i>		
Primer componente de la foto (Places365)	+0.509 [+0.17, +0.86]	283
Luz nocturna	−0.049 [−0.35, +0.27]	283
<i>Caer en pobreza: AUC-ROC con validación cruzada</i>		
Solo fotos	0.619	443
Fotos y luz nocturna	0.612	443
Cambio (IC95 %)	−0.007 [−0.021, +0.006]	443

Nota: Hogares con foto dentro de la ventana de fechas: los que tienen una foto de Street View tomada cerca de la ola de 2013. No hay fotos anteriores a 2012, de modo que no es posible entrenar con 2010 y evaluar en 2016 como en el resto del documento: la regresión logística se estima sobre los hogares del conjunto de prueba con foto, y el AUC-ROC, con validación cruzada de 5 particiones dentro de esa muestra, con los primeros cinco componentes de Places365. Fuente: cálculos propios.

Tabla 17: Relación entre las fotos de Google Street View y la luz nocturna según el desfase de la foto y el modelo de imagen, 2013 (exploratorio).

<i>A. Correlación (valor absoluto) entre la foto y la luz nocturna de 2013, según el desfase de la foto</i>					
Desfase	<i>n</i>	CLIP	VGG19	ResNet50	Places365
Mismo año	706	0.52	0.00	0.51	0.56
1–2 años	574	0.71	0.05	0.63	0.70
3–5 años	126	0.80	0.34	0.69	0.81
6–10 años	1,499	0.77	0.03	0.68	0.76
11 o más años	2,816	0.65	0.01	0.61	0.68
<i>B. R^2 de Places365 menos R^2 de cada modelo al predecir la luz nocturna (IC95 %)</i>					
Ventana	<i>n</i>	R^2 Places365	CLIP	VGG19	ResNet50
2011–2013	830	0.738	+0.040 [−0.011, +0.089]	+0.103 [+0.045, +0.166]	+0.035 [−0.006, +0.078]
2011–2015	1,280	0.771	+0.034 [+0.006, +0.059]	+0.062 [+0.029, +0.098]	+0.026 [−0.000, +0.052]

Nota: Panel A: correlación de Pearson entre el primer componente de la representación de la foto (eje común a todos los desfases) y la luz nocturna media (DMSP-OLS) de 2013, para hogares con una sola foto, según cuántos años después de 2013 se tomó; se reporta el valor absoluto porque el signo del componente es arbitrario. Un solo componente no resume igual de bien todos los modelos: con la representación completa, VGG19 predice la luz con un R^2 de 0.64 a 0.71 (Tabla 15). Los grupos de desfase tienen hogares distintos, por lo que no son una curva de degradación de una misma muestra. Panel B: mismos hogares y particiones para los cuatro modelos; IC95 % por bootstrap pareado de hogares (2,000 remuestreos); la diferencia es positiva con las cinco semillas de validación cruzada probadas. Places365 y ResNet50 comparten arquitectura (ResNet-50) y solo difieren en el entrenamiento: escenas frente a objetos (ImageNet). Fuente: cálculos propios.

A.9. Cobertura de covariables por módulo

Complemento de las Secciones 3.1 y 3.2: auditoría de los módulos, reglas de agregación al nivel de hogar, candidatas auditadas, variables finalmente usadas en el modelo y cobertura sobre el panel para cada módulo de la ELCA.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta, replicada de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal ¿??" en lugar de vocales acentuadas y la letra ñ); (ii) clasificación de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información.

Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno” cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar. Las tasas de mercado laboral se calcularon restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones) porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares que cumplen esa condición. La Tabla 18 resume las variables candidatas auditadas, las usadas en el modelo y la cobertura por módulo.

Tabla 18: Cobertura de las covariables por módulo de la ELCA, 2010, 2013 y 2016.


Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (% del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	21	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría descrita arriba; “usadas en el modelo” es el subconjunto final tras la construcción de variables, excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (ver “Bloque de *features* de Hogar”). No incluye llaves de identidad (p. ej. el consecutivo del hogar en Comunidades). Fuente: cálculos propios.

El dataset consolidado de la ELCA (27,932 filas hogar×ola) reúne 177 variables finales: 164 provienen de los cinco módulos auditados en la Tabla 18, excluyendo de ese conteo `consecutivo_c`, que es la llave de unión al módulo Comunidades, no una covariable, y las

13 restantes forman un bloque monetario (ingreso, gasto, líneas de pobreza e indicadores de pobreza). Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario, consistente con que son los módulos que se preguntan a todo hogar sin condición previa (Tabla 18), mientras que Comunidades (21), Choques (17) y Niños (13) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra (Niños). De las 177, 155 (88 %) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas (los indicadores de pobreza monetaria). El desagregado por módulo y tipo de dato se muestra en la Figura 12, y por tema en la Tabla 19.

Figura 12: Variables de la ELCA usadas en los modelos por módulo temático y tipo de dato.



Nota: No incluye las variables geoespaciales. Fuente: cálculos propios.

Las mismas 177 variables, agrupadas por el tema que cubren en lugar del módulo de la ELCA del que provienen:

Tabla 19: Temas cubiertos por las 177 variables de la ELCA usadas en los modelos.

Tema	N.º	Ejemplos
Educación, empleo y seguridad social	27	nivel educativo y categoría ocupacional del jefe, cotización a pensión, tasa de ocupación del hogar
Comunidad	21	percepción de inseguridad, acceso a agua, puesto de salud, acciones del conflicto armado
Choques y afrontamiento	18	choques económicos, de salud o agropecuarios; afrontamiento erosivo; desastres naturales
Ayudas y redes de apoyo	18	ayudas de familiares en Colombia y el exterior, de ONG o de organizaciones religiosas; envío de ayudas
Vivienda: materiales y servicios	15	material de pisos y paredes, servicio sanitario, tenencia, escritura de la vivienda
Composición del hogar	14	niños menores de 12 años, adultos mayores, razón de dependencia, sexo, edad, etnia y estado civil del jefe
Ingreso y gasto	13	ingreso y gasto per cápita real, brechas frente a la LP, indicadores de pobreza
Activos del hogar	13	bienes durables, índice de riqueza (PCA), estrato, vehículo, ahorro
Desarrollo infantil (6–9 años)	12	vacunación, talla y peso, oficios y trabajo infantil, puntaje TVIP
Salud	10	afiliación a salud, hospitalización, discapacidad, controles preventivos
Programas sociales y deuda	8	Familias en Acción, Red Juntos, apoyo alimentario escolar, deuda formal e informal
Participación y capital social	5	participación en organizaciones, participación cívica, práctica religiosa
Vivienda: hacinamiento	3	personas por cuarto y por dormitorio, valor del arriendo
Total	177	

Nota: Clasificación temática propia, independiente del módulo de la ELCA del que proviene cada variable; los temas son los mismos que agrupan el núcleo SHAP (Tabla 4). No incluye las variables geoespaciales (Anexo B.1). Fuente: cálculos propios.

A.10. Composición del panel y atrición


Complemento de la Sección 3.2: evolución del número de hogares únicos por ola, tasas de pérdida de hogares entre olas y división de hogares.

El panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016. Esto es una atrición de 11.4% entre 2010 y 2013 y de 11.4% entre 2013 y 2016 (hogares presentes en una ola que no aparecen en la siguiente). La caída neta entre 2013 y 2016 es menor (7.4%) porque 351 hogares que no se encontraron en 2013 volvieron a ser encuestados en 2016. La pérdida acumulada entre 2010 y 2016 es de 17.9%

(Figura 13). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2% de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8% de los rurales), lo opuesto al posible supuesto de que la atrición rural sería mayor por dificultad de rastreo geográfico, probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales (desagregado por zona, estrato y región en el Anexo A.2).

Existe también un fenómeno de división de hogares: 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016. Esto ocurre porque un hijo formó su propio hogar en la misma vivienda o predio o en un predio diferente. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. Estos hogares divididos se excluyeron del análisis para no realizar supuestos adicionales sobre su composición, vulnerabilidad y covariables.

Figura 13: Hogares por ola y pérdida de hogares entre olas de la ELCA, 2010, 2013 y 2016.



Nota: Izquierda: hogares únicos por ola. Derecha: porcentaje de hogares de la ola inicial que no aparecen en la siguiente, entre olas consecutivas y acumulado 2010→2016. Fuente: cálculos propios.

A.11. Matriz de confusión del Modelo B

Complemento de la Sección 5.1.2: la misma matriz de confusión de la Tabla 3, para el Modelo B (sin ingreso ni gasto).

Tabla 20: Matriz de confusión del Modelo B en el conjunto de prueba, pobreza monetaria e IPM, 2013→2016.

Algoritmo	Monetaria				IPM			
	VP	FP	FN	VN	VP	FP	FN	VN
Random Forest	573 (18 %)	1559 (49 %)	62 (2 %)	997 (31 %)	414 (7 %)	2120 (38 %)	128 (2 %)	2909 (52 %)
XGBoost	594 (19 %)	1770 (55 %)	41 (1 %)	786 (25 %)	513 (9 %)	3690 (66 %)	29 (1 %)	1339 (24 %)
Logística regularizada	573 (18 %)	1575 (49 %)	62 (2 %)	981 (31 %)	399 (7 %)	2055 (37 %)	143 (3 %)	2974 (53 %)
HistGradientBoosting	541 (17 %)	1358 (43 %)	94 (3 %)	1198 (38 %)	342 (6 %)	1507 (27 %)	200 (4 %)	3522 (63 %)
LightGBM	576 (18 %)	1622 (51 %)	59 (2 %)	934 (29 %)	397 (7 %)	1982 (36 %)	145 (3 %)	3047 (55 %)

Nota: VP, FP, FN y VN: hogares verdadero positivo, falso positivo, falso negativo y verdadero negativo.

Entre paréntesis, porcentaje sobre el total de la fila para cada definición de pobreza (monetaria, $n = 3,191$; IPM, $n = 5,571$). Modelos clasificados con los hiperparámetros y el umbral reportados en la Tabla 23 del Anexo A.13. Corresponde a una sola corrida de cada modelo, por lo que el *recall* y la precisión que se derivan de ella difieren levemente de los promedios de 5 semillas de la Tabla 2.

Fuente: cálculos propios.

A.12. Modelo multiclase

Complemento de las Secciones 5.2 (Tercer hallazgo) y 5.3.1: especificación y desempeño del modelo multiclase mencionado en la Sección 4.2 y AUC-ROC por par de grupos de la matriz de transición, con y sin las variables de DMSP-OLS. Los hiperparámetros se reportan en la Tabla 23 del Anexo A.13.

Si bien se hizo un ejercicio de predicción multiclase con los cuatro grupos y todos los hogares del panel, este no es el principal por cuatro razones. Primero, la pregunta de vulnerabilidad se refiere a quiénes, entre los hogares hoy no pobres, caerán en pobreza. Segundo, con el ingreso entre las covariables, el modelo separa los grupos de forma trivial según la condición de pobreza en la ola base. Tercero, sin el ingreso, el modelo casi no identifica a quienes entran en pobreza: asigna a cada hogar su grupo más probable, sin un umbral que se pueda ajustar como en el modelo binario, y esta clase, la más pequeña, queda absorbida por las demás. Cuarto, se construyó con un propósito más acotado, como diagnóstico: comprobar si quienes entran en pobreza se distinguen de quienes salen, algo que el modelo binario no puede responder (Sección 5.2). El modelo multiclase se estima con los mismos cinco algoritmos y, además, con una red neuronal (perceptrón multicapa), sobre los cuatro grupos de la matriz de transición y sin ingreso ni gasto entre las covariables (Modelo B). Sigue el mismo esquema de validación que el modelo binario (Sección 4.4): entrenamiento en 2010→2013, prueba en 2013→2016 y búsqueda de hiperparámetros y de estrategia de balanceo por validación cruzada. Para medir si dos grupos se distinguen se usa el AUC-ROC por par: se restringe la muestra a los hogares de esos dos grupos y se toma como puntaje la probabilidad que el modelo asigna al primero.

Tabla 21: Desempeño del modelo multiclase (cuatro grupos) en el conjunto de prueba, pobreza monetaria, 2013→2016.

Algoritmo	Balanceo	Exactitud	Exactitud balanceada	F1 macro	AUC-ROC macro	AUC entra frente al resto	Recall entra	Prec.-top10 entra
XGBoost	ninguno	0.582	0.426	0.384	0.732	0.596	0.002	0.111
LightGBM	ninguno	0.573	0.422	0.385	0.730	0.593	0.002	0.116
HistGradientBoosting	ninguno	0.577	0.424	0.384	0.731	0.599	0.002	0.114
Random Forest	ninguno	0.574	0.412	0.344	0.727	0.601	0.000	0.119
Red neuronal (MLP)	ninguno	0.557	0.412	0.376	0.713	0.591	0.008	0.125
Logística regularizada	ninguno	0.545	0.398	0.348	0.703	0.576	0.005	0.127

Nota: Modelo B (sin ingreso ni gasto), entrenado en 2010→2013 y evaluado en 2013→2016 ($n = 6,911$ hogares de los cuatro grupos), promedio de 5 semillas. El modelo asigna a cada hogar el grupo más probable, sin umbral ajustable, de modo que casi nunca asigna “entra”, el grupo más pequeño (*recall* cercano a cero); por eso se usa como diagnóstico y no como modelo principal. Prec.-top10 entra: fracción de hogares que efectivamente entran en pobreza entre el 10 % con mayor probabilidad de “entra”. Hiperparámetros en la Tabla 23. Fuente: cálculos propios.

Tabla 22: AUC-ROC del modelo multiclase por par de grupos de la matriz de transición, pobreza monetaria, 2013→2016.

Algoritmo	Nunca frente a siempre	Nunca frente a entra	Nunca frente a sale	Entra frente a siempre	Sale frente a siempre	Entra frente a sale
<i>AUC-ROC, Modelo B</i>						
XGBoost	0.927 [0.919, 0.935]	0.752 [0.731, 0.773]	0.830 [0.816, 0.845]	0.676 [0.654, 0.698]	0.595 [0.574, 0.615]	0.534 [0.504, 0.564]
LightGBM	0.927 [0.919, 0.935]	0.754 [0.733, 0.775]	0.829 [0.813, 0.843]	0.685 [0.662, 0.708]	0.603 [0.582, 0.623]	0.543 [0.515, 0.575]
HistGradientBoosting	0.925 [0.917, 0.933]	0.752 [0.730, 0.772]	0.824 [0.808, 0.839]	0.675 [0.652, 0.697]	0.605 [0.584, 0.625]	0.545 [0.517, 0.573]
Random Forest	0.919 [0.910, 0.927]	0.749 [0.728, 0.770]	0.813 [0.797, 0.829]	0.702 [0.679, 0.724]	0.611 [0.591, 0.629]	0.541 [0.512, 0.573]
Red neuronal (MLP)	0.910 [0.901, 0.919]	0.743 [0.722, 0.764]	0.820 [0.804, 0.835]	0.685 [0.662, 0.708]	0.613 [0.594, 0.632]	0.554 [0.525, 0.582]
Logística regularizada	0.896 [0.885, 0.906]	0.734 [0.714, 0.756]	0.806 [0.789, 0.821]	0.688 [0.665, 0.710]	0.629 [0.608, 0.650]	0.562 [0.530, 0.593]
<i>Cambio al agregar DMSP-OLS</i>						
XGBoost	-0.001 [-0.002, +0.001]	+0.001 [-0.003, +0.005]	-0.001 [-0.004, +0.002]	+0.005 [-0.008, +0.018]	+0.013 [†] [+0.003, +0.023]	+0.011 [-0.006, +0.028]
LightGBM	+0.000 [-0.002, +0.002]	-0.004 [-0.008, +0.001]	+0.003 [-0.001, +0.005]	+0.013 [-0.000, +0.025]	+0.011 [†] [+0.000, +0.022]	+0.009 [-0.009, +0.026]
HistGradientBoosting	-0.000 [-0.003, +0.002]	-0.004 [-0.010, +0.003]	+0.004 [†] [+0.000, +0.009]	-0.008 [-0.023, +0.006]	-0.003 [-0.015, +0.009]	-0.006 [-0.026, +0.013]
Random Forest	-0.002 [†] [-0.004, -0.001]	-0.004 [†] [-0.008, -0.001]	-0.002 [-0.004, +0.000]	-0.009 [-0.018, +0.001]	-0.004 [-0.013, +0.004]	-0.006 [-0.019, +0.007]
Red neuronal (MLP)	-0.002 [-0.006, +0.003]	-0.004 [-0.013, +0.004]	-0.002 [-0.009, +0.004]	+0.024 [†] [+0.007, +0.040]	+0.010 [-0.007, +0.028]	+0.005 [-0.016, +0.027]
Logística regularizada	+0.001 [-0.000, +0.001]	-0.001 [-0.002, +0.001]	+0.001 [-0.000, +0.002]	-0.001 [-0.005, +0.003]	-0.003 [-0.008, +0.002]	+0.002 [-0.003, +0.006]

Nota: AUC-ROC de cada par de grupos: se restringe a los hogares de los dos grupos y se usa como puntaje la probabilidad que el modelo asigna al primero. Modelo B, conjunto de prueba 2013→2016 ($n = 6,911$ hogares), semilla 42; el promedio de 5 semillas difiere como máximo en 0.007. Entre corchetes, intervalo de confianza del 95 % por *bootstrap* por comunidad (2,000 remuestras de 1,889 comunidades; los hogares sin comunidad identificada cuentan cada uno como una), pareado entre especificaciones en el panel inferior. El panel inferior es la diferencia entre el mismo modelo con las 23 variables de DMSP-OLS y sin ellas; [†]: intervalo que excluye el cero. Fuente: cálculos propios.

A.13. Hiperparámetros de los modelos reportados

Complemento de las Secciones 4.3 y 4.4: descripción de los algoritmos y sus hiperparámetros finales.

Descripción de los algoritmos. Los cinco algoritmos se agrupan en dos familias según cómo tratan las variables categóricas y los datos faltantes (Sección 4.5):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los

coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla (l_1_ratio) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge. Es el algoritmo designado como referencia por ser interpretable y por servir de punto de comparación antes de justificar el uso de un modelo más complejo. Es también el más sensible a la multicolinealidad entre covariables; se evaluó explícitamente ese riesgo mediante un análisis de correlación de Pearson entre las 159 variables numéricas del consolidado, con 35 pares por encima de $|r| = 0.7$ (incluida una correlación fuerte de `dmsp_stable_lights` con `lp` y `n_servicios_publicos_hogar`, retomada en la Sección 5.3.1; detalle completo en el Apéndice A.1). La regularización ℓ_1/ℓ_2 mitiga, pero no elimina, la varianza inflada de coeficientes individuales cuando varias variables de un mismo grupo redundante entran juntas al modelo.

- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad. Los tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding*.

Hiperparámetros. La Tabla 23 reporta los hiperparámetros finales, estrategia de balanceo de clases y umbral de clasificación (promedio de las cinco semillas) elegidos por validación cruzada para todos los modelos cuyos resultados se reportan en el documento. Los análisis SHAP, de heterogeneidad y de *bootstrap* usan estos mismos modelos. Varias especificaciones de un mismo algoritmo comparten hiperparámetros porque la búsqueda aleatoria usa una semilla fija: prueba las mismas 30 combinaciones en cada especificación, y a menudo gana la misma.

Tabla 23: Hiperparámetros finales, estrategia de balanceo y umbral de clasificación de los modelos reportados.

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
<i>Pobreza monetaria, conjunto de prueba 2013→2016</i>				
Logística regularizada	A	balanced	0.37	$C = 0.00603$; $l_1_ratio = 0.156$
Logística regularizada	B	balanced	0.35	$C = 0.00603$; $l_1_ratio = 0.156$

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
Logística regularizada	A + DMSP	balanced	0.37	C = 0.00603; l1_ratio = 0.156
Logística regularizada	B + DMSP	balanced	0.35	C = 0.00603; l1_ratio = 0.156
Random Forest	A	ninguno	0.14	max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334
Random Forest	B	balanced	0.31	max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334
Random Forest	A + DMSP	balanced	0.26	max_depth = 8; max_features = 0.234; min_samples_leaf = 25; n_estimators = 493
Random Forest	B + DMSP	balanced	0.27	max_depth = 12; max_features = 0.259; min_samples_leaf = 21; n_estimators = 291
XGBoost	A	ninguno	0.11	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	A + DMSP	ninguno	0.12	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B + DMSP	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
LightGBM	A	ninguno	0.10	learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32
LightGBM	B	ninguno	0.15	learning_rate = 0.0111; max_depth = 4; min_child_samples = 30; n_estimators = 143; num_leaves = 48; reg_lambda = 0.617
LightGBM	A + DMSP	ninguno	0.10	learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
LightGBM	B + DMSP	ninguno	0.13	learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15
HistGradientBoosting	A	balanced	0.32	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	A + DMSP	balanced	0.31	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B + DMSP	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
<i>Pobreza multidimensional (IPM), conjunto de prueba 2013→2016</i>				
Logística regularizada	A	ninguno	0.10	C = 0.0362; l1_ratio = 0.52
Logística regularizada	B	ninguno	0.11	C = 0.0362; l1_ratio = 0.52
Logística regularizada	A + DMSP	ninguno	0.11	C = 0.0362; l1_ratio = 0.52
Logística regularizada	B + DMSP	ninguno	0.11	C = 0.0362; l1_ratio = 0.52
Random Forest	A	balanced	0.31	max_depth = 14; max_features = 0.567; min_samples_leaf = 13; n_estimators = 544
Random Forest	B	balanced	0.26	max_depth = 14; max_features = 0.273; min_samples_leaf = 9; n_estimators = 234
Random Forest	A + DMSP	ninguno	0.12	max_depth = 9; max_features = 0.387; min_samples_leaf = 25; n_estimators = 492
Random Forest	B + DMSP	ninguno	0.11	max_depth = 12; max_features = 0.259; min_samples_leaf = 21; n_estimators = 291
XGBoost	A	ninguno	0.11	colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
XGBoost	B	ninguno	0.09	colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658
XGBoost	A + DMSP	ninguno	0.10	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B + DMSP	ninguno	0.11	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
LightGBM	A	ninguno	0.11	learning_rate = 0.013; max_depth = 5; min_child_samples = 26; n_estimators = 383; num_leaves = 16; reg_lambda = 1.77
LightGBM	B	ninguno	0.08	learning_rate = 0.0357; max_depth = 7; min_child_samples = 19; n_estimators = 206; num_leaves = 22; reg_lambda = 1.58
LightGBM	A + DMSP	ninguno	0.10	learning_rate = 0.013; max_depth = 5; min_child_samples = 26; n_estimators = 383; num_leaves = 16; reg_lambda = 1.77
LightGBM	B + DMSP	ninguno	0.10	learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15
HistGradientBoosting	A	ninguno	0.11	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42
HistGradientBoosting	B	ninguno	0.10	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42
HistGradientBoosting	A + DMSP	ninguno	0.10	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
HistGradientBoosting	B + DMSP	ninguno	0.10	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42
<i>Tres fuentes geoespaciales, pobreza monetaria, validación cruzada en 2010→2013</i>				
Logística regularizada	A	balanced	0.37	C = 0.00603; l1_ratio = 0.156
Logística regularizada	B	balanced	0.35	C = 0.00603; l1_ratio = 0.156
Logística regularizada	A + 3 fuentes	oversampling	0.37	C = 0.00277; l1_ratio = 0.196
Logística regularizada	B + 3 fuentes	ninguno	0.14	C = 0.00811; l1_ratio = 0.183
XGBoost	A	ninguno	0.11	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	A + 3 fuentes	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B + 3 fuentes	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
HistGradientBoosting	A	balanced	0.32	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	A + 3 fuentes	balanced	0.32	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B + 3 fuentes	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
<i>Multiclase (cuatro grupos), pobreza monetaria, conjunto de prueba 2013→2016</i>				
Logística regularizada	A	ninguno	–	C = 0.0746; l1_ratio = 0.951
Logística regularizada	B	ninguno	–	C = 0.0746; l1_ratio = 0.951
Random Forest	A	ninguno	–	max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334
Random Forest	B	ninguno	–	max_depth = 12; max_features = 0.27; min_samples_leaf = 8; n_estimators = 400
XGBoost	A	ninguno	–	colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658
XGBoost	B	ninguno	–	colsample_bytree = 0.824; learning_rate = 0.0368; max_depth = 5; n_estimators = 356; reg_lambda = 2.78; subsample = 0.694
LightGBM	A	ninguno	–	learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15
LightGBM	B	ninguno	–	learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32
HistGradientBoosting	A	ninguno	–	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B	ninguno	–	l2_regularization = 2.58; learning_rate = 0.0189; max_depth = 5; max_iter = 227; max_leaf_nodes = 42
Red neuronal (MLP)	A	ninguno	–	alpha = 0.0207; hidden_layer_sizes = (64); learning_rate_init = 0.00852
Red neuronal (MLP)	B	ninguno	–	alpha = 3.08e-05; hidden_layer_sizes = (128, 64); learning_rate_init = 0.00464

Nota: Espec.: especificación (A con ingreso y gasto del hogar, B sin ellos). Umbral: promedio sobre las semillas del umbral elegido por validación cruzada maximizando F_2 ; “–”: sin umbral (el modelo multiclase asigna el grupo más probable) o no registrado. Fuente: cálculos propios.

B. Detalles de construcción de variables geoespaciales

B.1. Qué mide cada fuente geoespacial

Complemento de la Sección 3.1: para las tres fuentes incorporadas (DMSP-OLS, ALOS PALSAR y Landsat 5 TM), el mecanismo físico de medición, las variables principales construidas y la interpretación que se les da en este estudio.

Tabla 24: Mecanismo, variables construidas e interpretación de las tres fuentes geoespaciales.

Fuente	Mecanismo físico	Variables (estado / ventana acum.)	Qué aproxima
DMSP-OLS (23 var.: 5 estado + 18 acum.)	Radiancia visible nocturna captada por satélite (alumbrado público, vivienda, comercio)	Estado: nivel, log, saturación Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code>)	Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)
ALOS PALSAR (52 var.: 7 estado + 45 acum.)	Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación	Estado: HH, HV (dB), razón HH/HV, índice normalizado Acumulada: media, tendencia, crecimiento de cada una	Densidad y consolidación del entorno construido frente a la vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)
Landsat 5 TM (52 var.: 16 estado + 36 acum.)	Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta)	Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices) Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo	Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada)

Nota: Las especificaciones principales (Modelos A y B con DMSP-OLS, evaluados en el conjunto de prueba 2013→2016) agregan solo las 23 variables de DMSP-OLS; la variante con las tres fuentes agrega las 127, evaluada con validación cruzada dentro de 2010→2013 (Tabla 14). Cada variable de ventana acumulada se resume en nueve estadísticos: media, desviación estándar, mínimo, máximo, rango, coeficiente de variación, tendencia, crecimiento acumulado y número de años con dato. Se excluyen las variables de cambio entre olas (movimiento del hogar, crecimiento 2010–2013), que no están definidas en la ola base. Fuente: cálculos propios.

B.2. Cobertura temporal de las fuentes evaluadas

Complemento de la Sección 3.1: ventana de disponibilidad de las siete fuentes geoespaciales evaluadas frente a las tres olas de la ELCA, y criterios con los que se seleccionaron.

Se requirió obtener información geoespacial para al menos dos olas: la transición 2010→2013, que es la ola en la que se entrenan los modelos que predicen la transición a la pobreza, y la transición 2013→2016 que se usa posteriormente para probar el poder predictivo de esas mismas variables en una ola donde no se usaron para entrenar el modelo. Es decir, fuera de muestra (Sección 4.1).

Además de la disponibilidad de fotos de nivel de calle (Google Street View), se evaluaron seis fuentes satelitales: Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales todavía no operaban). Se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017). Por esta razón, las tres fuentes que finalmente se incluyeron en este artículo fueron: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura anterior a 2014.


La Figura 14 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA, JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los hogares en las tres olas de la ELCA (2010, 2013, 2016).

El resultado de la consulta de la información geoespacial sobre las tres fuentes disponibles es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013 y es la única de las tres con esa cobertura completa en dos olas. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014, es decir, no tiene ninguna cobertura de 2013. Landsat 5 TM cubre solo 65.5 % de los hogares en 2010 (6,269 de 9,573; del resto no se obtuvo información por nubosidad persistente, una limitación conocida del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría una cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth Engine confirmó que el sensor dejó de adquirir información utilizable antes de esa fecha. Por lo tanto, estas tres fuentes se incorporaron al

proyecto pero solo DMSP-OLS sirvió como fuente principal en el marco del análisis.

Se hizo un ejercicio adicional con Google Street View, que es la fuente de información geoespacial más cercana a la experiencia humana de observación del entorno, y que podría capturar información relevante para la predicción de vulnerabilidad a la pobreza. Sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente: no se encontró ninguna foto para los hogares de la ELCA que se hubiera tomado antes de 2012 y el 61 % de las fotos disponibles se habían tomado de 2023 en adelante. Por esta razón, se decidió no incluirla en el análisis principal, aunque se tuvo en cuenta para la construcción de variables geoespaciales complementarias y para la discusión de resultados (Anexo A.8).

Figura 14: Cobertura temporal de las fuentes geoespaciales evaluadas frente a las olas de la ELCA.



Nota: Franjas rojas verticales: olas de la ELCA con coordenadas disponibles. El patrón diagonal indica una corrida real y completa sobre los hogares del estudio; en el resto se revisó la cobertura según el catálogo. En la barra de Google Street View, la intensidad del color es proporcional a la densidad real de fotos por año; la gran mayoría son de 2023 en adelante. Fuente: cálculos propios.