

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal de Colombia (ELCO)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización de programas sociales en Colombia, como el SISBEN, identifican pobreza como un estado observado y no anticipan qué hogares no pobres tienen mayor riesgo de caer en esa condición. Este trabajo evalúa si información pública, particularmente, características del entorno físico y económico local, mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Usando tres olas del panel (2010, 2013, 2016), se construye la variable de resultado como la entrada en pobreza de hogares inicialmente no pobres y se estiman distintos algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting), evaluando su capacidad predictiva en un período posterior al utilizado para su estimación: los modelos se entrenan con las transiciones observadas entre 2010 y 2013 y se evalúan con las transiciones entre 2013 y 2016. Este esquema permite evaluar el desempeño de los modelos en datos temporalmente posteriores a aquellos utilizados para su entrenamiento, aproximándose a su capacidad para anticipar transiciones futuras hacia la pobreza. Los modelos se estiman con y sin variables monetarias del hogar. El modelo base, que es lo que se reporta en esta versión del documento, alcanza

un AUC-ROC entre 0.731 y 0.767 según el algoritmo, con una brecha de apenas 0.008–0.028 entre la especificación que incluye ingreso/gasto del hogar y la que no lo hace, lo que sugiere que las covariables no monetarias capturan una fracción sustancial del poder predictivo típicamente atribuido al ingreso. La incorporación de las variables geoespaciales, contribución central de esta tesis, está en construcción. De confirmarse un aporte incremental, los resultados podrían fortalecer instrumentos de focalización con información de mayor frecuencia y menor costo de actualización que las encuestas de hogares tradicionales.

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geoespaciales, ELCA, focalización, Colombia.

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juárez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Beneficiarios de Programas Sociales (SISBEN) opera a través de una encuesta cuya aplicación depende de la solicitud de los hogares y de los recursos de la entidad territorial responsable, lo que genera rezagos en la actualización de la información y dificulta contar con datos recientes sobre el efecto de choques (Consejo Nacional de Política Económica y Social, 2016). La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y ejercicios recientes de aproximación a la vulnerabilidad monetaria en Bogotá mediante pseudo-panel confirman tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Castañeda Castrillón, 2012; Gaitán, 2023).

Esta tesis aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza monetaria. Este abordaje es distinto al de la literatura de la pobreza contemporánea que predice la mayoría de la literatura de aprendizaje de máquinas aplicada a este problema (Ferdausi et al., 2025; Muñetón et al., 2022)–. La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View mejora la predicción de caída en pobreza monetaria de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del

hogar reportadas en encuestas?

El estado actual de este documento cubre la primera mitad de esa pregunta: la construcción rigurosa de la variable de resultado, la auditoría exhaustiva de las covariables socioeconómicas disponibles en la ELCA (más de 4.000 columnas originales revisadas variable por variable a través de cinco módulos), y la estimación y comparación de cinco algoritmos de aprendizaje supervisado: regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting— sobre el modelo *base* (sin variables geoespaciales). La incorporación de las fuentes geoespaciales y la comparación frente al modelo extendido, que es la contribución central de la pregunta de investigación, está en construcción y se documenta como trabajo en curso en la Sección 6.3.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema no abordado directamente por la literatura existente aplicada al país.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje de máquinas aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla la estrategia empírica: construcción del outcome, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados obtenidos hasta el momento. La Sección 6 cierra con una síntesis, implicaciones de política y la agenda de trabajo pendiente.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria suele originarse en fluctuaciones del ingreso asociadas con choques económicos (ej. pérdida de empleo, caídas en precios) o eventos adversos

(ej. desastres naturales, conflictos). Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto al mostrar que en muchos países en desarrollo existe una población significativa de hogares no pobres pero altamente expuestos: su situación actual los ubica por encima de la línea de pobreza, pero su fragilidad patrimonial los hace vulnerables a caer ante afectaciones moderadas. Esta población es precisamente la que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010; Costella et al., 2023).

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juárez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 4.1 de esta tesis. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado de pobreza.

En el contexto colombiano, la aplicación de estos enfoques ha enfrentado restricciones de datos que han limitado su alcance. Castañeda Castrillón (2012) estudió las trampas de pobreza mediante la construcción de un pseudo-panel, y Gaitán (2023) analizó la vulnerabilidad monetaria a nivel de localidades en Bogotá con el mismo enfoque, como una manera para superar la ausencia de un panel de hogares con representatividad y cobertura suficiente; sus resultados –cerca del 23 % de la población bogotana en situación de vulnerabilidad en 2021– confirman la relevancia del problema, pero también evidencian las restricciones que impone el uso de cortes transversales repetidos en lugar de datos longitudinales reales. La disponibilidad de la ELCA, con tres olas de seguimiento a los mismos hogares, ofrece una oportunidad inédita para superar esta limitación en el contexto colombiano. Incluso con datos longitudinales, sin embargo, esta literatura enfrenta una restricción operativa adicional: los métodos desarrollados dependen, casi sin excepción, de encuestas de hogares con información detallada sobre ingresos, activos y consumo, costosas, de levantamiento infrecuente y con rezagos significativos entre la recolección y la disponibilidad de los datos. Esta restricción informacional es la que motiva la exploración de fuentes alternativas de datos que puedan aproximar la vulnerabilidad con mayor frecuencia de actualización y menor costo de recolección (Sección 2.3).

2.2. Aprendizaje de máquinas en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su desarrollo ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar

sustancialmente la precisión de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando la precisión balanceada en hasta 17 puntos porcentuales frente a los métodos tradicionales. Siguiendo esta perspectiva, esta tesis evalúa el desempeño de los modelos fuera de la muestra mediante un *holdout* temporal hacia adelante: los modelos se entrenan con información de períodos anteriores y se evalúan con información de un período posterior. De esta manera, la validación permite aproximarse mejor a la situación en la que el modelo se utilizaría en la práctica, es decir, para predecir la vulnerabilidad de hogares en un período futuro (Sección 4.4). Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2025) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema, logrando una precisión del 96 % con un conjunto reducido de siete variables. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza al resto de la literatura. En Colombia, Muñetón et al. (2022) han aplicado aprendizaje de máquinas a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital, mostrando que la combinación de imágenes satelitales con datos de encuesta permite explicar hasta el 75 % de la variación en consumo o riqueza en contextos africanos, superando lo que cualquiera de las dos fuentes logra de manera aislada. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con precisiones superiores al 82 %, aunque advierten que su capacidad discriminatoria se reduce en contextos de pobreza muy extendida, donde la variabilidad espacial de las imágenes es insuficiente para

distinguir entre hogares con distintos niveles de privación.

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran que la combinación de datos satelitales y de telefonía móvil reduce los errores de exclusión en programas sociales entre 4 % y 21 % frente a los métodos tradicionales. Hall et al. (2023), en una revisión sistemática, documentan que la combinación de múltiples fuentes incrementa el poder predictivo hasta en 15 puntos porcentuales, pero identifican que los datos geoespaciales predicen mejor activos físicos que variables de flujo como ingreso o consumo, y que su desempeño depende críticamente del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que esta tesis busca incorporar (Sección 3.2).

2.4. Síntesis y vacío que llena este trabajo

La evidencia revisada muestra que los modelos que combinan variables geoespaciales con información socioeconómica de encuestas superan a los basados exclusivamente en cualquiera de las dos fuentes, con ventajas más pronunciadas cuando la validación se realiza fuera de muestra. Sin embargo, ninguno de los trabajos revisados aborda directamente el problema de predecir la probabilidad de caída en pobreza de hogares actualmente no pobres, y mucho menos en un contexto de datos longitudinales de hogar como el que ofrece la ELCA. Predecir transiciones hacia la pobreza es un problema conceptualmente distinto al de estimar pobreza contemporánea: requiere una variable de resultado definida en términos prospectivos, un horizonte temporal explícito entre olas de panel, y un conjunto de variables predictoras que capture tanto las condiciones del hogar como las del entorno en el momento previo a la transición.

Es en esta brecha donde esta investigación busca contribuir, evaluando si la incorporación de variables del entorno físico y económico local derivadas de fuentes geoespaciales públicas a los datos longitudinales de la ELCA permite mejorar la identificación de hogares en riesgo de caer en pobreza en Colombia. Es importante señalar que, en contextos de política pública, la predicción es valiosa incluso en ausencia de interpretación causal Kleinberg et al. (2015), especialmente porque el objetivo es mejorar la focalización *ex ante* de la política

social. Por esta razón, este trabajo se sitúa en un enfoque predictivo más que causal, donde el objetivo no es identificar efectos estructurales sino mejorar la capacidad de anticipar transiciones hacia la pobreza con miras a mejorar la focalización de políticas públicas de seguridad social.

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCA)

La fuente primaria de datos es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares en tres olas: 2010, 2013 y 2016, en zonas urbana y rural. La ELCA se organiza en en módulos temáticos: hogar, personas, niños, comunidades y choques, además de los módulos de activos y gasto. Existen dos olas más disponibles para 2019 y 2022, que administra el DANE. No obstante, por de tiempo no se utilizaron en el marco de esta investigación. Para los análisis realizados en este estudio, se excluyeron los hogares que se dividieron en dos o más sub-hogares en olas subsecuentes (511 casos entre 2010–2013 y 1,190 entre 2013–2016, ver Tabla 2), para no hacer supuestos sobre estos hogares en el tiempo.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta, replicadas de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal "???" en lugar de vocales acentuadas y la letra ñ); (ii) clasificación exhaustiva de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información evitable.

El resultado es un panel hogar x ola consolidado de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas, que combinan las covariables construidas a partir de los módulos con las variables monetarias (ingreso y gasto per cápita del hogar, nominal y real, y brecha frente a la línea de pobreza). Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas explícitas y documentadas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno” cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar cuando la literatura lo usa como proxy estándar. Las tasas de mercado laboral se calculan restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el

estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

3.2. Fuentes geoespaciales

Este trabajo utiliza información geoespacial disponible públicamente y de manera gratuita. La idea es que la información geoespacial de los hogares puede capturar características del entorno físico y económico local que afectan la vulnerabilidad de estos hogares a caer en pobreza, pero que no se refleja completamente en las encuestas tradicionales que realizan gobiernos y otras organizaciones. Para esto, a partir de las coordenadas de los hogares de la ELCA, que se encuentran para consulta de manera estrictamente controlada y restringida por parte de la Universidad de los Andes, se consolida la información geoespacial disponible a través de consultas a la API de Google Earth Engine. Esta información se anexa a la base de datos de la ELCA para cada hogar, y se utiliza como covariable adicional en los modelos predictivos de transición hacia la pobreza.

La necesidad era obtener información geoespacial para al menos dos olas: la transición 2010→2013 es en la que se entrenan los modelos que predicen la transición a la pobreza, mientras que la transición 2013→2016 se usa después para determinar el poder predictivo de esas mismas variables fuera de muestra (Sección 4.1).

Inicialmente, se priorizó la utilización de imágenes de Google Street View, sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente. Por esta razón, se evaluaron otras seis fuentes satelitales o aéreas públicas adicionales: —Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), y ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales todavía no operaban)— y se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017), por lo que no puede existir ninguna imagen real de ellas anterior a esas fechas, en ningún catálogo. Por eso se evaluaron específicamente en el marco de este proyecto: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura real anterior a 2014.

La Figura 1 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA,

JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los hogares en las tres olas de la ELCA (2010, 2013, 2016). El patrón diagonal marca cobertura real confirmada sobre hogares del estudio; el resto se revisó cobertura de catálogo sin realizar consultas de los hogares disponibles (Sentinel-2, VIIRS).




Figura 1: Cobertura temporal real de cada fuente geoespacial evaluada, frente a las tres olas de la ELCA con coordenadas disponibles. El patrón diagonal indica corrida real y completa sobre hogares del estudio; el resto se revisó cobertura según catálogo. En la barra de GSV, la intensidad del color es proporcional a la densidad real de fotos por año —la gran mayoría de las fotos son de 2023 en adelante.

El resultado de la consulta de la información geoespacial, ya completa sobre las tres disponibles, es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013; es la única de las tres con esa cobertura completa en dos olas, lo que permite usarla para la evaluación del poder predictivo en la transición 2013→2016. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014 —no tiene ninguna cobertura de 2013—. Landsat 5 TM cubre solo 65.5 % de los hogares en 2010 (6,269 de 9,573; del resto no se obtiene información por nubosidad persistente, una limitación del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth Engine confirmó que el sensor dejó de adquirir información utilizable antes de esa fecha, no hay ninguna imagen real de Landsat 5 en 2012 ni en 2013, en ningún punto del planeta. Las tres se incorporan al proyecto.

La Tabla 1 resume, para las tres fuentes nuevas, el mecanismo físico de medición, el nombre de las variables principales que se construyeron, y la interpretación que se les da

en este estudio.

Tabla 1: Qué mide cada fuente nueva, qué variables construye, y qué aproxima cada una.

Fuente	Mecanismo físico	Variables (estado / ventana acum.)	Qué aproxima
DMSP-OLS	Radiancia visible nocturna captada por satélite (aluminado público, vivienda, comercio)	Estado: nivel, log, saturación Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code>)	Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)
ALOS PALSAR	Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación	Estado: HH, HV (dB), razón HH/HV, índice normalizado Acumulada: media, tendencia, crecimiento de cada una	Densidad y consolidación del entorno construido vs. vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)
Landsat 5 TM	Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta)	Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices) Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo	Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada)

3.3. Cobertura, atrición e inventario del panel

Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones) porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares

que cumplen esa condición. El detalle de candidatas auditadas, variables usadas en el modelo y cobertura por módulo se reporta en la Tabla 24 del Anexo A.6.

3.3.1. Composición del panel y atrición

En la ELCA existe pérdida de datos (atrición) que se caracteriza de la siguiente manera: el panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016 (Figura 2, izquierda) —una atrición de 11.4 % entre 2010 y 2013, 11.4 % entre 2013 y 2016, y 17.9 % acumulada entre 2010 y 2016 (Figura 2, derecha). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2 % de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8 % de los rurales), lo opuesto a la intuición de que la atrición rural sería mayor por dificultad de rastreo geográfico, probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales. Por esta razón, en este estudio se utilizan técnicas de balanceo para compensar este sesgo.




Figura 2: Izquierda: hogares únicos por ola. Derecha: tasa de pérdida de hogares entre olas consecutivas y acumulada 2010–2016. Fuente: cálculos propios.

Existe también un fenómeno de división de hogares. 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016 —típicamente porque un hijo formó su propio hogar en la misma vivienda o predio—. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. Estos hogares divididos se excluyeron del análisis para no realizar ningún supuesto adicional. El número de personas cubiertas por el panel cae de forma más pronunciada que el de hogares: 43,202 personas en 2010, 39,920 en 2013, 35,722 en 2016 (18.7 % de caída acumulada, por encima del 17.9 % de hogares). Esto ocurre posiblemente porque los hogares perdidos tienden a ser, en promedio, ligeramente más grandes que los que permanecen en el panel.

3.3.2. Inventario temático de las variables finales

El dataset consolidado que alimenta el modelo (27,932 filas hogar×ola) reúne 181 variables finales: 177 provienen de los cinco módulos de la ELCA ya auditados en la Tabla 24, excluyendo de ese conteo `consecutivo_c`, que es la llave de unión al módulo Comunidades, no una covariable, y las 4 restantes son las variables geoespaciales. La Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario, consistente con que son los módulos que se preguntan a todo hogar sin condición previa (Tabla 24), mientras que Comunidades (21), Choques (17), Niños (13) y Geoespacial (4) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra o a una sola ola (Niños, Geoespacial). De las 181, 159 (88 %) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas (los indicadores de pobreza monetaria). El desagregado por módulo y tipo de dato se muestra en la Figura 14 del Anexo A.6.

4. Estrategia empírica

4.1. Construcción de la variable de resultado y dinámica de transiciones

Este estudio sigue la metodología de López-Calva y Ortiz-Juárez (2011, 2014), a partir de la cual se construyen matrices de transición de pobreza monetaria e IPM, cruzando el estado de un hogar en el período inicial t (filas), contra un periodo posterior $t + 1$ (columnas). Esta comparación permite observar cómo evoluciona la situación económica de los hogares a lo largo del tiempo y generar una taxonomía de cuatro categorías de acuerdo con la clasificación: *nunca pobre*, *siempre pobre*, *entra en pobreza* y *sale de pobreza*.

La pobreza monetaria se calcula a partir del cálculo del ingreso per cápita del hogar y se compara contra la línea de pobreza (LP) oficial del DANE, específica por año y zona¹. El Índice de Pobreza Multidimensional (IPM) y la construcción de la clasificación según el IPM se construye siguiendo la metodología oficial del DANE (Angulo Salazar et al., 2011), como un proxy del índice Alkire-Foster de cinco dimensiones (educación; niñez y juventud; trabajo; salud; vivienda y servicios públicos) y quince indicadores ponderados (20 % por dimensión, peso igual entre los indicadores de cada dimensión) y un punto de corte de

¹Se usa la serie MESEP (línea base ENIG 2006–2007, actualizada anualmente por IPC), la misma metodología para las tres olas (2010, 2013 y 2016), lo que las hace comparables entre sí. Deliberadamente no se usa la actualización metodológica ENPH 2016–2017 con la que el DANE recalculó la serie 2012–2018, porque esa serie no cubre 2010 y adoptarla habría introducido un quiebre metodológico justo entre las olas que este estudio compara.

pobreza de 33.3 % del puntaje ponderado.² Ambas variables de resultado se describen en la Sección 3—. El modelo predictivo de esta tesis (Secciones 4.3 en adelante) usa solo una de las cuatro celdas: restringido a hogares no pobres en t , que caen en pobreza en $t + 1$, de acuerdo con la (Ecuación 1):

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

A continuación se caracteriza las cuatro celdas completas. Se realizó un análisis adicional de la incidencia agregada, FGT, y cinco ejercicios de robustez de estas estimaciones, incluyendo la atrición del panel por perfil de hogar y se documentan en el Apéndice A.2.

Tabla 2: Matrices de transición de pobreza, monetaria por ingreso vs. IPM (% de fila, panel emparejado 1 a 1). Estado inicial en filas, estado final en columnas.

Periodo	Estado inicial	Monetaria		IPM	
		No pobre	Pobre	No pobre	Pobre
2010 → 2013	No pobre	76.6 %	23.4 %	87.9 %	12.1 %
	Pobre	29.7 %	70.3 %	54.5 %	45.5 %
2013 → 2016	No pobre	80.1 %	19.9 %	90.3 %	9.7 %
	Pobre	38.2 %	61.8 %	52.3 %	47.7 %

Nota: $n = 8,218$ (2010→2013) y $n = 6,911$ (2013→2016) hogares con emparejamiento 1 a 1 – idéntico universo para monetaria e IPM (mismo panel, solo cambia la clasificación de pobreza); excluye 511 (2010–2013) y 1,190 (2013–2016) casos de hogares que se dividieron entre olas. Fuente: cálculos propios con base en ELCA 2010, 2013 y 2016.

Bajo pobreza monetaria la persistencia es alta pero decrece: 70.3 % de los pobres en 2010 seguían pobres en 2013, cae a 61.8 % entre 2013 y 2016 (la salida condicional sube de 29.7 % a 38.2 %); la persistencia en la no-pobreza mejora de 76.6 % a 80.1 %. Bajo IPM entrar es menos frecuente (12.1 % y 9.7 %, frente a 23.4 % y 19.9 % en monetaria) pero también lo es salir (45.5 % y 47.7 %). Estas diferencias son posiblemente consistentes con que el IPM mide privaciones estructurales que cambian más lento que el ingreso corriente en cualquiera de las dos direcciones. Las Figuras 3 y 4 traducen la matriz monetaria a

²Es un proxy porque cinco de los quince indicadores se excluyen del puntaje final por huecos de cobertura irresolubles en la ola 2010 del panel: privación en primera infancia (no medible de forma consistente en ninguna ola); inasistencia escolar y trabajo infantil (`estudia/actividad_ppal` en niños con 0.4 %–35.3 % de cobertura en 2010, frente a 100 % en 2013/2016); y empleo informal y desempleo de larga duración (`actividad_ppal` en adultos con 20 % de cobertura en 2010, frente a 75–80 % en 2013/2016). Se calculan y reportan para auditoría, pero no entran en la clasificación `pobre_ipm`. Quedan diez indicadores activos; la dimensión Trabajo, que queda sin indicadores, redistribuye su 20 % entre las cuatro dimensiones restantes (25 % cada una). El punto de corte de pobreza se mantiene en 33.3 % del puntaje ponderado, independiente del número de indicadores activos.

flujos: en 2010–2013 dominan los *siempre pobres* (43.9 %) sobre los *nunca pobres* (28.8 %); en 2013–2016 el orden se invierte (37.0 % vs. 33.3 %), y en ambos periodos la salida casi duplica la entrada, es decir, la pobreza monetaria se redujo de forma neta, no solo se redistribuyó entre hogares.




Figura 3: 2010→2013 ($n = 8,218$).




Figura 4: 2013→2016 ($n = 6,911$).

Transición de pobreza monetaria por ingreso entre categorías de López-Calva y Ortiz-Juárez (2014), panel emparejado 1 a 1.

Un último ejercicio (Tabla 3) sigue a los mismos hogares no pobres en la ola base a lo largo de las tres olas para distinguir, dentro de quienes *entran* en pobreza, una entrada transitoria de una persistente. Bajo pobreza monetaria, 24.1 % de los no pobres en 2010 entra en pobreza en algún momento: 14.0 puntos salen de nuevo antes de 2016 (“transitorio”) y 10.1 se quedan (“persistente”). Bajo IPM la entrada total es menor (12.2 %) y se reparte parecido (8.2 transitoria, 4.0 persistente): en ambas definiciones, más de la mitad de quienes entran en pobreza no quedan atrapados dentro de la ventana de seis años observada.

Tabla 3: Trayectorias a 3 olas (2010→2013→2016) de hogares NO pobres en 2010, panel emparejado 1 a 1, monetaria vs. IPM.

Trayectoria	Monetaria		IPM	
	n	%	n	%
Nunca cae	1,700	67.2 %	4,381	81.2 %
Cae tarde (solo en 2016)	220	8.7 %	357	6.6 %
Entra y sale (transitorio)	355	14.0 %	445	8.2 %
Entra y se queda (persistente)	255	10.1 %	214	4.0 %

Nota: $n=2,530$ hogares no pobres en 2010 bajo pobreza monetaria; $n=5,397$ bajo IPM (universos distintos porque no-pobre-monetaria y no-pobre-IPM en 2010 no son el mismo conjunto de hogares). % sobre ese universo, sin ponderar. Fuente: cálculos propios.

4.2. Selección de covariables para el perfil univariado

La Sección 5.2.1 contrasta los cuatro grupos de la matriz de transición sobre cerca de 185 covariables candidatas de la encuesta. Describirlas todas sin ningún filtro sería demasiado confuso: con muestras muy desiguales entre grupos (723 hogares .^{entra}frente a 3.604 "siempre pobre".^{en} 2010–2013), una simple comparación de promedios o porcentajes no distingue una diferencia real entre grupos de una que aparece por azar de qué hogares fueron encuestados. Se necesita entonces una regla explícita para decidir qué variables merecen contarse, y qué tan fuerte es esa diferencia –no solo si existe–.

La regla, aplicada variable por variable, responde una pregunta simple: ¿qué tan bien predice el valor de esa única variable a cuál de los cuatro grupos pertenece un hogar, en una escala de 0 (no ayuda nada) a 1 (los distingue perfectamente)? Esa capacidad se mide con η^2 (variables numéricas) o V de Cramér (categóricas) –la misma pregunta, la fórmula adecuada según el tipo de dato–, en su versión corregida por sesgo (ambas medidas exageran la asociación en muestras pequeñas, y .^{entra}.^{es} el grupo más pequeño) y ponderada por los factores de expansión de la encuesta. Una variable entra al perfil solo si esa medida supera 0.05 de forma consistente en 300 remuestreos *bootstrap* de los datos, no solo en la muestra original: exige que la señal sea repetible, no una casualidad de qué hogares puntuales aparecen en la encuesta. De las 185 candidatas, 53 (monetaria) y 36 (IPM) pasan el filtro. A diferencia de un modelo predictivo, las variables que pasan no se colapsan aunque estén correlacionadas entre sí: el objetivo aquí es describir, no evitar redundancia, y cada variable retenida puede aportar información al perfil.

4.3. Especificación de modelos

La estrategia empírica se establece mediante la siguiente especificación de modelo:

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1) y $F(\cdot)$ es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se estiman y comparan cinco algoritmos, agrupados en dos familias según cómo tratan las variables categóricas y los datos faltantes (Sección 4.5):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla ($l1_ratio$) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge. Es el algoritmo

designado como referencia por ser interpretable, y por servir de punto de comparación antes de justificar el uso de un modelo más complejo. Es también el más sensible a la multicolinealidad entre covariables –se evaluó explícitamente ese riesgo mediante un análisis de correlación de Pearson entre las 159 variables numéricas del consolidado, con 35 pares por encima de $|r| = 0.7$ (incluida una correlación fuerte de `dmsp_stable_lights` con `lp` y `n_servicios_publicos_hogar`, retomada en la Sección 5.3.1; detalle completo en el Apéndice A.1)–: la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, la varianza inflada de coeficientes individuales cuando varias variables de un mismo grupo redundante entran juntas al modelo.

- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad, y uno de los más usados en la literatura de focalización de pobreza (McBride & Nichols, 2018)–. Los tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding* (Sección 4.5).

Para evaluar el aporte del nivel de ingreso/gasto del hogar –el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, se estima cada uno de los cinco algoritmos bajo dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante (se mantiene constante a lo largo del tiempo); el **Modelo B** excluye estas cuatro variables y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad).

Finalmente, se establecieron dos variables objetivo para evaluar la robustez de los hallazgos: la transición hacia la pobreza monetaria y la transición hacia la pobreza multidimensional (IPM).

4.4. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño

predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, solo existe la ola base al momento de predecir, y es, siguiendo a McBride y Nichols (2018), la validación más exigente para un modelo de este tipo porque prueba generalización ante un régimen económico distinto al de entrenamiento.

Dentro de ese periodo de entrenamiento (2010 a 2013) –nunca sobre el conjunto de prueba– cada algoritmo pasa por una búsqueda de hiperparámetros: en vez de fijar a mano valores como la profundidad de los árboles o la tasa de aprendizaje, `RandomizedSearchCV` propone 30 combinaciones aleatorias dentro de un rango razonable para cada hiperparámetro (Sección 4.3) y evalúa cada una con validación cruzada estratificada de 10 particiones: el conjunto de entrenamiento se divide en 10 bloques del mismo tamaño y manteniendo la proporción de hogares que entran a la pobreza en cada uno (*estratificada*), se entrena 10 veces dejando un bloque distinto por fuera cada vez y evaluando sobre ese bloque no visto, y se promedian las 10 evaluaciones. Ese promedio castiga a las combinaciones que memorizan particularidades del conjunto de entrenamiento en vez de aprender un patrón que generaliza, sin utilizar el conjunto de prueba, que solo se toca una vez, al final, para evaluar el desempeño del modelo. Se eligen los 30 hiperparámetros por costo computacional –evaluar más combinaciones exhaustivamente (*grid search*) sobre 5 algoritmos $\times$ 4 especificaciones $\times$ 3 estrategias de balanceo (Sección 4.5) y dos variables objetivo, con validación cruzada de 10 particiones, hubiera requerido un tiempo de cómputo prohibitivo, incluso con paralelización y optimizaciones de preprocesamiento. La métrica que decide qué combinación gana esa búsqueda es AUC-ROC. Para verificar que 30 iteraciones no se quedan cortas, se extendió la búsqueda a 50 iteraciones para el caso más ambiguo de la comparación de balanceo (HistGradientBoosting-A, Sección 4.5): el mejor puntaje acumulado ya no mejora entre las iteraciones 20 y 40 (0.7603 en ambas), y gana solo 0.0006 adicional hacia la iteración 50 –evidencia de que la búsqueda con 30 iteraciones ya opera cerca de su techo para este caso, no de que se haya interrumpido prematuramente.

Un desbalance de clases pronunciado puede hacer que el AUC-ROC dé una imagen optimista: premia una tasa *relativa* baja de falsos positivos, lo que puede esconder un número *absoluto* alto de falsos positivos cuando la clase positiva es escasa (Davis & Goadrich, 2006; Saito & Rehmsmeier, 2015). Esto no invalida al AUC-ROC como medida de *ranking* –su valor es independiente del umbral de clasificación y no cambia mecánicamente con la proporción de clases–, pero sí limita qué tan bien comunica, por sí solo, la utilidad práctica del modelo para una política con cobertura limitada. Por eso, además de AUC-ROC, se reporta `precision_top10` (Sección 5.3.1): la precisión en el decil de mayor riesgo no depende del balance de clases ni de un umbral de clasificación, y responde directamente la

pregunta relevante para un programa de focalización real.

El desempeño se reporta mediante AUC-ROC como métrica principal, principalmente porque no depende de un umbral de clasificación arbitrario (se evalúan múltiples umbrales), además, recall, precision y F1 como métricas de referencia al umbral de clasificación elegido por F_2 (Sección 4.5), junto con la matriz de confusión completa; F1 se sigue reportando por ser la referencia más estándar en la literatura, aunque no es la métrica que decide dónde queda el umbral que se elige mediante F_2 . El foco del análisis está en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo a partir de diferencias de AUC-ROC que, como se documenta en la Sección 5.1, resultan pequeños frente a la variabilidad esperable por aleatoriedad del ajuste.

4.5. Tratamiento del desbalance de clases

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4% (Tabla 2), un desbalance que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.

Esa selección, sin embargo, no siempre es robusta al azar del propio particionado de validación cruzada: para HistGradientBoosting-A, repetir la comparación de balanceo con 5 semillas distintas de `StratifiedKFold` cambia la estrategia ganadora en 3 de 5 corridas –“balanced” gana con dos semillas, “ninguno” con otras dos, y *oversampling* con la restante–, con un AUC-CV que varía apenas en el tercer decimal entre estrategias dentro de cada semilla (rango de 0.0013 a 0.0022). Esto no invalida el procedimiento –la estrategia elegida para cada algoritmo en el resto del documento es siempre la de la semilla base (`RANDOM_STATE=42`), fijada *ex ante*, no elegida *ex post* entre semillas–, pero sí indica que, al menos para este algoritmo y especificación, la diferencia entre estrategias de balanceo está dentro del margen de ruido del particionado, no es una preferencia robusta del algoritmo por una estrategia en particular.

Un hallazgo metodológico relevante de este ejercicio: en XGBoost y en LightGBM (Modelo B), la estrategia “sin ajuste” ganó la comparación por una diferencia de AUC-ROC frente a la reponderación de apenas 0.001 (estadísticamente indistinguible), pero el modelo resultante, sin corregir el desbalance de clases, produjo probabilidades tan comprimidas hacia valores bajos que casi ninguna observación cruzaba el umbral convencional de 0.5 (recall de 3%–4% en XGBoost, con precision superior a 60%: el modelo ordenaba razonablemente bien los hogares por riesgo, pero era inútil en la práctica al umbral estándar). Esto ilustra que el umbral 0.5 es arbitrario cuando la clase positiva no es 50% de la muestra, y que distintas estrategias de balanceo calibran las probabilidades de forma distinta, por lo que comparar recall/precision/F1 a un umbral fijo entre estrategias no es una comparación válida. La solución adoptada fue elegir el umbral de clasificación de cada modelo por validación cruzada, igual que los hiperparámetros: sobre las probabilidades *out-of-fold* (10 particiones) se evalúa una grilla de umbrales entre 0.02 y 0.98 y se elige el que maximiza una métrica que combina recall y precision –el AUC-ROC, que no depende de umbral, y sigue siendo el criterio que decide la estrategia de balanceo y los hiperparámetros en el paso anterior; el umbral solo determina cómo se reportan recall, precision y F1 una vez el modelo ya está fijo.

La métrica elegida para esa búsqueda de umbral es F_2 (F-beta con $\beta = 2$) en vez del F1 convencional. F1 es la media armónica de recall y precision con el mismo peso para ambos, una elección razonable cuando un falso negativo (un hogar que sí cae en pobreza y el modelo no lo marca como en riesgo) y un falso positivo (un hogar que el modelo marca como en riesgo y no cae) son igual de costosos. En un sistema de focalización de política social eso no es cierto: dejar sin detectar a un hogar que va a entrar en pobreza es muy costoso socialmente –no recibe el apoyo que necesitaría–, es un costo mucho mayor que incluir de más a un hogar que no cae, que en el peor caso implica un gasto de focalización mal dirigido pero no la ausencia de una protección que se necesita. F_2 formaliza esa prioridad ponderando el recall el doble que la precision al elegir el umbral, de modo que el modelo se ajusta para dejar pasar menos casos reales de entrada a la pobreza, a costa de marcar como riesgo a más hogares que finalmente no caen.

Para los algoritmos sin soporte de datos faltantes (regresión logística y Random Forest), la imputación de valores faltantes, que en esta base de datos son mayoritariamente por la estructura de la encuesta, es decir, causados por preguntas filtro del cuestionario (por ejemplo, el monto de una ayuda recibida no se pregunta a quien respondió que no recibió ninguna)– usa sistemáticamente el valor 0 combinado con una columna indicadora binaria de faltante por variable. Esta elección evita que la mediana –calculada únicamente sobre quienes pasaron el filtro y respondieron– le asigne a los hogares excluidos por el filtro

un valor “típico” que en realidad no tienen, y tiene además la propiedad de que, en un modelo lineal, el relleno no aporta ninguna contribución a la predicción más allá de la que capture el propio indicador de faltante. Las variables categóricas se imputan con una categoría explícita “Sin dato” en vez de la moda, para no disfrazar la ausencia estructural como el valor más común. XGBoost, LightGBM y HistGradientBoosting no requieren esta imputación: manejan los datos faltantes de forma nativa en la partición de los árboles, lo que convierte el propio patrón de *missingness* en una señal explotable por el modelo (por ejemplo, la ausencia de datos de vacunación infantil ya codifica indirectamente que el hogar no tiene hijos pequeños) en vez de forzar un supuesto de imputación potencialmente sesgado.

4.6. Importancia de variables e interpretabilidad

Para cada modelo se reporta una medida de importancia de variables acorde a su naturaleza: los coeficientes estandarizados (con signo) de la regresión logística; la importancia por reducción de impureza (`feature_importances_`) de Random Forest, XGBoost y LightGBM; y la importancia por permutación (*permutation importance*, AUC-ROC sobre el conjunto de prueba, 10 repeticiones) de HistGradientBoosting, más costosa computacionalmente pero más robusta a la correlación entre covariables que la importancia basada en impureza. La comparación de estas listas de variables más importantes entre el Modelo A y el Modelo B (Sección 5.1) es la primera aproximación a la pregunta de qué información no monetaria es más predictiva de la transición a la pobreza, antes de la incorporación de las variables geoespaciales (Sección 6.3). Como estas medidas no comparten unidad entre algoritmos (impureza vs. coeficiente estandarizado vs. caída de AUC-ROC), se complementan con valores SHAP (*SHapley Additive exPlanations*) para los cinco algoritmos sobre los Modelos A y B, que sí son comparables en una misma escala –la contribución promedio, en valor absoluto, de cada variable a la predicción de cada hogar– y que además satisfacen aditividad (la suma de los SHAP values de un hogar reconstruye exactamente su predicción) y consistencia (si un modelo pasa a depender más de una variable, su SHAP value nunca puede bajar). Los resultados se presentan en la Sección 5.1.

5. Resultados

A continuación se presentan los resultados en cinco partes, desde dos metodologías distintas, un análisis descriptivo (univariado) y un análisis predictivo (multivariado). La Sección 5.2.1 es un análisis **univariado e inicial**: perfila al hogar vulnerable –el que entra en pobreza– contra los otros tres grupos de la matriz de transición, variable por variable (sin controlar por las demás covariables), para las 53 (monetaria) y 36 (IPM) covariables

que se hallaron como las más robustas para discriminar entre los grupos. Su función es exploratoria y descriptiva: construir la intuición sobre quién es el hogar vulnerable antes de imponerle cualquier supuesto de modelo. La Sección 5.1 cambia de metodología –pasa a un enfoque **multivariado**– y de objetivo: ya no describe diferencias marginales entre grupos, sino que busca **predecir** la vulnerabilidad a partir del conjunto de covariables, con la mira puesta en generar insumos para una política pública diferenciada (focalización de programas de prevención hacia quienes el modelo señala en mayor riesgo, distinto de los programas de alivio dirigidos a quien ya es pobre). Compara el desempeño fuera de muestra de los cinco algoritmos bajo las especificaciones con y sin ingreso/gasto del hogar. Es de aclarar, que la importancia de las variables puede variar según el algoritmo utilizado, la especificación del modelo y frente al análisis univariado. Las Secciones 5.3.1 y 5.3.2 y 5.3.3 se mantienen en el mismo objetivo de informar posibles insumos para la política pública, pero revisan la utilidad metodológica de otras herramientas bajo ese mismo interés: evalúan si agregar DMSP-OLS mejora esa predicción, bajo pobreza monetaria e IPM respectivamente y por qué, y si ese efecto –nulo en promedio bajo monetaria, pequeño bajo IPM– es igual en la población o se concentra en subgrupos específicos.

5.1. Desempeño comparativo de modelos

Antes de comparar el desempeño de los cinco algoritmos, conviene fijar brevemente qué mide cada métrica y cómo se relacionan entre sí. El AUC-ROC resume la capacidad de un modelo para ordenar correctamente los hogares por riesgo, sin depender de ningún umbral de clasificación –es la métrica que compara algoritmos entre sí (Sección 4.4)–. *Recall* y *precision*, en cambio, sí dependen del umbral elegido: recall es la fracción de hogares que efectivamente entran en pobreza y el modelo marca como riesgo (cuánta pobreza real se captura), precision es la fracción de los hogares marcados que efectivamente entran (cuánta de la alarma es acertada). Las tres no son independientes entre sí: dado un AUC-ROC fijo, mover el umbral de clasificación permite subir recall solo a costa de precision, y viceversa –el AUC-ROC actúa como un techo que ninguna elección de umbral puede superar, solo desplazar el punto donde se cae dentro de esa restricción–. Esta sección se organiza en dos partes: primero el desempeño comparado de los cinco algoritmos, y luego, apoyándose en esa restricción, un análisis de los errores de inclusión y exclusión que resulta inevitable en cualquier instrumento de focalización con ese techo de discriminación.

5.1.1. Desempeño de los modelos

La Tabla 4 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de

clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.4 y 4.5).³

Tabla 4: Desempeño de los cinco algoritmos, holdout temporal (train 2010→2013, test 2013→2016). Media sobre 5 semillas del ajuste final. Umbral elegido por CV maximizando F-beta ($\beta = 2$), CV_FOLDS=10, N_ITER_BUSQUEDA=30. Precision-top10: precisión entre el 10 % de hogares de mayor riesgo.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precision	Prec.-top10	F1
XGBoost	A	0.11	0.767	0.949	0.264	0.505	0.413
Random Forest	A	0.14	0.766	0.926	0.277	0.486	0.426
HistGradientBoosting	A	0.32	0.763	0.909	0.283	0.512	0.432
LightGBM	A	0.10	0.758	0.903	0.281	0.516	0.428
Logística regularizada	A	0.37	0.747	0.883	0.280	0.506	0.426
Random Forest	B	0.31	0.742	0.892	0.272	0.508	0.416
XGBoost	B	0.13	0.742	0.940	0.250	0.495	0.395
Logística regularizada	B	0.35	0.739	0.890	0.270	0.500	0.414
HistGradientBoosting	B	0.14	0.735	0.879	0.275	0.494	0.418
LightGBM	B	0.15	0.731	0.909	0.259	0.487	0.403

Nota: umbral elegido por validación cruzada maximizando F_2 en cada semilla (Sección 4.5), no fijo en 0.5; se reporta el promedio de las 5 semillas. El umbral es considerablemente más bajo que en una búsqueda equivalente por F1 –al pesar el recall el doble, F_2 empuja el punto de corte hacia abajo para dejar pasar más casos de entrada a la pobreza, a costa de más falsos positivos (columna Recall, sistemáticamente sobre 0.88, frente a un F1 más moderado). Prec.-top10: precisión entre el 10 % de hogares que el modelo señala como de mayor riesgo, la cifra más relevante para un programa de focalización con capacidad fija (Sección 4.4).

Frente al desempeño de los modelos, se encontraron dos hallazgos a partir de las diferencias puntuales entre los desempeños de los algoritmos y las especificaciones (Tabla 4). **Primero**, el algoritmo elegido no cambia el poder de discriminación de los vulnerables (AUC-ROC 0.731–0.767 en los cinco). Bajo IPM el mismo techo aparece, en un rango de AUC-ROC igual de estrecho (0.725–0.747; Tabla 22, Apéndice A.4). Un AUC-ROC de 0.75 significa que, si se toma al azar un hogar que entra en pobreza y uno que no, el modelo correctamente asigna mayor riesgo al primero solo 3 de cada 4 veces. Esto es consistente con la literatura sobre predicción de pobreza –AUC-ROC de 0.70–0.80 en Chaudhuri et al. (2002), 0.73–0.77 en McBride y Nichols (2018)–.

Segundo, la capacidad de identificar vulnerables apenas cambia si se excluyen las variables de ingreso/gasto del hogar de las covariables que se utilizan en los modelos.

³Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Hist-GradientBoosting y la regresión logística en el Modelo A, y Random Forest y la regresión logística en el Modelo B, donde fue *balanced* (reponderación de clases).

La ganancia de incluir esa información, que valga mencionar es la más cara de levantar mediante encuesta, y la menos confiable, es marginal (brecha de AUC de 0.008 a 0.028 entre el Modelo A y B, mucho menor de lo que predeciría un enfoque de vulnerabilidad puramente monetario, Chaudhuri et al. (2002)). Esto no implica que el ingreso no importe, anteriormente se estableció que es de las variables que más separa a los cuatro grupos de la matriz de transición (Sección 5.2.1)–, sino que su contenido informativo ya está sustancialmente capturado por otras variables del núcleo del perfil (riqueza, educación, bienes durables; Hallazgo 4, Sección 5.2.1). Bajo IPM la brecha es aún menor, y para Random Forest y XGBoost es negativa –el Modelo B (sin ingreso/gasto) supera al A–, lo que descarta que la pequeña brecha en la capacidad discriminante de los modelos bajo la definición de pobreza monetaria se deba a la relación mecánica entre ingreso y la definición de pobreza. La implicación práctica sigue la misma lógica que sustenta focalizar con proxies observables del ingreso en vez de medirlo directamente (McBride & Nichols, 2018): un instrumento más barato, sin ingreso/gasto detallado, rendiría casi lo mismo.

5.1.2. Análisis de los errores de inclusión y exclusión

Aunque el poder de discriminación (AUC-ROC) es similar entre los cinco algoritmos (Sección 5.1.1), el algoritmo y la estrategia de elección del umbral sí determinan cuánta capacidad de cobertura necesita un eventual programa social que focalice vulnerables para no perder casos reales. En este estudio se encontró que ese costo, con cualquier algoritmo, ronda entre los 3–4 hogares atendidos por cada hogar que realmente lo necesitaba (Tabla 5): de los hogares que efectivamente no entran en pobreza, HistGradientBoosting identifica correctamente al 40 %, mientras XGBoost solo al 26 %. En términos de las métricas de la Tabla 4, esto corresponde a un recall alto (0.88–0.95: casi todos los hogares que efectivamente caen quedan marcados) pero una precisión baja (0.25–0.28: solo uno de cada 4 marcados efectivamente cae); la precisión en el 10 % de mayor riesgo (Prec.-top10, 0.49–0.52) casi duplica la precisión al umbral completo, lo que sugiere que concentrar la atención en ese decil sería una estrategia de focalización más eficiente que usar el umbral de clasificación completo. El comportamiento de recall y precision obedece no solo al modelo, sino en parte también a la decisión de diseño: el umbral elegido por F_2 , que pone el doble del peso en la importancia de los falsos positivos que en los falsos negativos, determina dónde se cae (vulnerable o no vulnerable) dentro del techo que impone el AUC. Lo que sí es una restricción, que ninguna combinación de modelo y umbral pueden resolver, es que con un AUC-ROC de 0.75 no es posible lograr recall y precision altos simultáneamente. Este intercambio es el mismo que la literatura de focalización de programas sociales llama errores de inclusión y de exclusión (*Type E* y *Type F*, Cornia y Stewart (1993)): para un instrumento de focalización dado, reducir uno necesariamente aumenta el otro; solo un

instrumento con mayor poder de discriminación –no un umbral distinto– puede mover esa frontera.

Tabla 5: Matriz de confusión, Modelo A, holdout temporal (test 2013→2016, semilla 42), pobreza monetaria ($n = 3,191$) e IPM ($n = 5,571$). VN/FP/FN/VP: hogares verdadero negativo, falso positivo, falso negativo y verdadero positivo, al umbral de clasificación de las Tablas 4 y 22 respectivamente.

Algoritmo	Monetaria				IPM			
	VP	FP	FN	VN	VP	FP	FN	VN
XGBoost	617	1888	18	668	491	3297	51	1732
Random Forest	594	1572	41	984	343	1493	199	3536
HistGradientBoosting	584	1532	51	1024	301	1124	241	3905
LightGBM	561	1354	74	1202	415	2052	127	2977
Logística regularizada	561	1444	74	1112	379	1862	163	3167

Se caracterizaron los falsos positivos (Modelo A, HistGradientBoosting y XGBoost) comparándolos, en las 22 variables del núcleo de importancia multivariada (Sección 5.2), contra los verdaderos negativos –hogares que en la realidad tampoco cayeron en pobreza, pero que el modelo sí acertó en no marcar–: aislar esta comparación, en vez de contrastar contra los verdaderos positivos, evita mezclar la pregunta de “qué dispara la alarma del modelo” con la de “qué tan parecidos son a quien sí cae”. Los falsos positivos ($n = 1,464$ en HistGradientBoosting, 1,695 en XGBoost) resultan sistemáticamente más parecidos a un hogar vulnerable que los verdaderos negativos ($n = 1,092$ y 861 respectivamente) en 18 de las 20 variables numéricas del núcleo: menos riqueza, menos bienes durables, menor nivel educativo, menos servicios públicos, menor estrato, más hacinamiento –no son errores aleatorios del modelo, son hogares genuinamente al borde de la línea de pobreza. Los valores SHAP confirman, además, que estas mismas variables –no otras correlacionadas de fondo– son las que efectivamente empujan la predicción hacia “riesgo”: para HistGradientBoosting, la brecha más grande entre falsos positivos y verdaderos negativos está en `riqueza_pca_hogar` y `nivel_educ_max_hogar`; para XGBoost, en `ingreso_percapita_hogar_real` (diferencia de SHAP de 0.44, el doble que la segunda variable) y `brecha_lp_ingreso` –consistente con que cada algoritmo distribuye el mismo núcleo de forma distinta (Sección 5.2).

Queda una pregunta: si los falsos positivos se ven igual de vulnerables que los verdaderos positivos a ojos del modelo, ¿qué distingue a quien efectivamente cae de quien no? Comparando choques reportados en la ola de destino (2016, posteriores al momento de la predicción y por tanto no usados por el modelo) entre verdaderos positivos y falsos positivos, los primeros vivieron sistemáticamente más choques durante esa ventana: 3.1 choques en promedio frente a 2.2 (ambos algoritmos), y 81–82 % tuvo al menos un choque

frente a 71–72 % de los falsos positivos –consistente con el enfoque de vulnerabilidad de Chaudhuri et al. (2002): el modelo identifica correctamente al hogar en el margen, pero quién realiza el riesgo depende de una exposición a choques que ningún dato de encuesta disponible al momento de la predicción puede anticipar.

5.2. Determinantes de la vulnerabilidad: perfil e importancia de variables

Esta sección aborda los determinantes de la vulnerabilidad a la pobreza desde dos perspectivas complementarias: el perfil univariado de los hogares que entran en pobreza –comparándolos con los otros tres grupos de la matriz de transición– y la importancia de esas mismas variables una vez se controla por el resto, dentro de los cinco algoritmos de la Sección 5.1.

5.2.1. Perfil univariado de los hogares vulnerables

Esta sección perfila los hogares que **entran en pobreza** entre 2010 y 2013 –no pobres en la ola inicial, pobres en la siguiente– contra los otros tres grupos de la matriz de transición (Sección 4.1), sobre las 53 covariables que distinguen de forma confiable a los cuatro grupos entre sí (criterio de selección en la Sección 4.2),⁴ sin colapsar las correlacionadas entre sí, en una sola tabla consolidada (Tabla 6).

Hay cuatro hallazgos principales de este análisis. **Primero**, el hogar vulnerable se parece mucho más al que *acaba de salir* de la pobreza que al que nunca fue pobre o al que nunca sale de ella: de las 53 variables, 47 lo ubican numéricamente más cerca de “sale de la pobreza” que de “nunca pobre” (en promedio, cerca de cuatro veces más cerca) –Tabla 6. El patrón se repite, y se refuerza, en la transición 2013→2016 (49 de 53 variables más cerca de “sale”): no depende de una sola ola del panel. Tampoco depende de cómo se mida la pobreza: el mismo ejercicio repetido bajo pobreza multidimensional (IPM, 36 variables robustas bajo el mismo criterio de la Sección 4.2, Apéndice A.3) confirma el mismo contraste (sale vs. nunca) en 29 de 36 variables en 2010→2013 y 31 de 35 en 2013→2016 –el patrón es robusto tanto a la ola como a la definición de pobreza. Esto es consistente con pensar “entra” y “sale” como las dos caras de una misma frontera –hogares que cruzan la línea de pobreza en direcciones opuestas, con un perfil similar por estar ambos cerca de ese umbral–, y no como dos tipos de hogar distintos. **Segundo**, cuatro variables (marcadas [†] en la tabla) rompen ese patrón, es decir, diferencian mejor a los hogares vulnerables de los demás grupos, todas en la misma dirección –el hogar vulnerable queda en el extremo

⁴40 de 53 superan 0.10; las 13 restantes cumplen efecto > 0.05 y robustez en *ambas* transiciones por separado. Las 40 originales no se sometieron a ese chequeo: 2 (`n_ninos_12`, `razon_dependencia_demografica`) caen bajo 0.10 en 2013→2016 (0.105→0.084 y 0.104→0.088), aunque siguen robustas.

más favorable, no en el segundo peor—. La más importante es la *formalidad laboral del jefe*, la señal que convencionalmente se usaría para descartar riesgo: 62.3 % de los jefes de hogar vulnerables son asalariados, más que quien sale (52.2 %) y más que quien nunca cae (57.9 %). En 2013→2016 esa ventaja frente a quien sale se mantiene (52.3 % frente a 46.9 %), pero deja de superar a quien nunca cae (55.3 %). Las otras tres son menores pero van en la misma dirección: *deuda informal* (26.0 % frente a 22.7 % de los que salen), *niños al cuidado de terceros* (98.9 % frente a 98.2 % de los que nunca son pobres) y *transporte público comunitario* (79.2 % frente a 78.2 % de los que nunca son pobres). Estas tres no se sostienen en 2013→2016: el vulnerable vuelve al orden esperado, entre “sale” y “siempre pobre”, en las tres —consistente con que su efecto (0.051–0.058) apenas superaba el umbral de robustez, un orden de magnitud por debajo del de formalidad laboral (0.393). Si una política de focalización usara solo la formalidad laboral del jefe en 2010, habría clasificado a los hogares vulnerables como los *menos* necesitados de los cuatro grupos —el ejemplo más concreto de por qué un estado socioeconómico observado no revela el riesgo futuro de un hogar, y en el caso del empleo formal, activamente lo oculta.

Tabla 6: Perfil por grupo de transición, pobreza monetaria (2010→2013), las 53 variables robustas. †variable donde el hogar vulnerable no queda entre “sale” y “siempre pobre”/“nunca pobre” como el resto (ver texto).

Variable	Siempre	Sale	Entra	Nunca	Variable	Siempre	Sale	Entra	Nunca
Educación y empleo del jefe					Geoespacial				
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %	Iluminación nocturna (DMSP)	21.6	32.6	36.4	50.1
Ocupación del jefe: Asalariado†	34 %	52 %	62 %	58 %	Activos del hogar				
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %	N.º de bienes durables	4.58	6.00	6.30	9.10
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %	N.º de servicios públicos	2.50	3.30	3.65	4.80
Negocio del jefe: De 20 a 49 personas	9 %	16 %	22 %	25 %	Estrato (verificado)	1.59	2.06	2.07	2.63
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22	Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %	Estrato (autorreportado)	1.60	2.07	2.05	2.58
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72	Tiene internet en el hogar	8 %	16 %	13 %	46 %
Etnia del jefe: Indígena	12 %	6 %	6 %	4 %	N.º de activos financieros	0.10	0.42	0.45	0.86
Jefe cotiza a pensión	6 %	21 %	24 %	43 %	Tiene vehículo	17 %	25 %	23 %	40 %
Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %	Vivienda: hacinamiento				
Afiliación a pensión (hogar)	27 %	51 %	48 %	57 %	Valor del arriendo pagado	144k	226k	240k	354k
Afiliación a salud laboral (hogar)	33 %	55 %	58 %	62 %	Personas por cuarto	2.13	1.65	1.49	1.11
Jefe afiliado a salud laboral	35 %	53 %	61 %	64 %	Personas por dormitorio	2.77	2.25	2.09	1.74
Jefe afiliado a pensión	29 %	49 %	51 %	58 %	Programas sociales y deuda				
Vivienda: materiales y servicios					Beneficiario de Familias en Acción	53 %	29 %	23 %	7 %
Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %	N.º de programas sociales	0.73	0.42	0.34	0.17
Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %	Beneficiario de algún programa social	60 %	37 %	31 %	15 %
Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %	Tiene deuda informal†	32 %	23 %	26 %	9 %
Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %	Tiene deuda formal	65 %	75 %	73 %	88 %
Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %	Composición del hogar				
Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %	N.º de niños en el hogar	1.45	0.92	0.79	0.57
Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %	Razón de dependencia demográfica	0.93	0.67	0.56	0.43
Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %	Niños al cuidado de terceros†	86 %	94 %	99 %	98 %
Financió la vivienda con crédito formal	13 %	26 %	22 %	43 %	Niños con apoyo alimentario escolar	81 %	72 %	70 %	54 %
Tiene escritura de la vivienda	67 %	81 %	80 %	90 %	Comunidad				
Zona de residencia					N.º de espacios públicos en la comunidad	1.57	1.98	2.13	2.32
Vive en zona rural	69 %	52 %	45 %	21 %	Comunidad con transporte público†	55 %	75 %	79 %	78 %
					Ingreso y gasto				
					Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26
					Ingreso per cápita	65k	93k	269k	633k
					Gasto per cápita	154k	210k	247k	662k
					Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36

Tercero, y no visible en el promedio agregado: el grupo “entra en pobreza” no es un solo tipo de hogar, sino dos trayectorias distintas que el análisis de dos olas (2010→2013) no alcanza a distinguir. Siguiendo a esos mismos 723 hogares que entran a probreza - los vulnerables - hasta la tercera ola (610 con dato en 2016), se pueden separar según qué pasa después: *pobre transitorio* –vuelve a salir antes de 2016– (355 hogares, 58 %) y *pobre persistente* –sigue pobre en 2016– (255 hogares, 42 %; Tabla 7). En ambos subgrupos se mantiene el patrón del primer hallazgo: transitorio se parece más a “sale” que a “nunca cae” en 39 de 53 variables, y persistente en 44 de 53. Pero el promedio de “entra” esconde un gradiente que solo aparece al separarlos: "pobre persistente" se acerca al extremo “siempre

pobre” en 11 de esas 53 variables, frente a solo 2 en “pobre transitorio”. Es decir, dentro de quienes entran a pobreza, quien va a quedar atrapados ya se parece un poco más al hogar crónicamente pobre, aunque el patrón dominante siga siendo el de la frontera con “sale”. Al revisar las variables que caracterizan a estos grupos, el caso más claro es la *deuda informal*: el promedio de “entra” (26.0 %) esconde que pobre transitorio (17.3 %) queda por *debajo* incluso de “sale” (22.7 %), mientras pobre persistente (41.9 %) supera a los cuatro grupos, incluido “siempre pobre” (31.6 %) –separa, dentro del propio grupo vulnerable, a quien va a recuperarse rápido de quien va a quedar atrapado-. Este patrón no es exclusivo de la deuda: *cotizar a pensión* y el *acceso a deuda formal* muestran la misma divergencia (Tabla 7) –la misma frontera de formalidad laboral y financiera que separa a “entra” de “sale” en el Hallazgo 2 reaparece dentro de “entra”(los vulnerables) para separar a quien se recupera (pobre transitorio) de quien queda atrapado (pobre persistente). Este gradiente también se confirma bajo IPM: pobre persistente queda más cerca de “siempre pobre” que de “sale” en 11 de 36 variables, frente a 5 de 36 en pobre transitorio – misma dirección, magnitud comparable.

Tabla 7: Perfil del hogar vulnerable (“entra en pobreza”, 2010→2013) desagregado por trayectoria a 2016: transitorio ($n = 355$, vuelve a salir) vs. persistente ($n = 255$, se queda pobre). Valores ponderados por grupo; filas superiores, resumen agregado sobre las 53 variables; filas inferiores, ejemplos puntuales donde el promedio agregado (Sección 5.2.1) ocultaba una divergencia entre subgrupos.

Variable	Siempre	Sale	Transitorio	Persistente	Nunca
Más cerca de “sale” que de “nunca” (de 53)	–		39/53	44/53	–
Más cerca de “siempre” que de “sale” (de 53)	–		2/53	11/53	–
Jefe asalariado	34.4 %	52.2 %	64.9 %	61.7 %	57.9 %
Jefe cotiza a pensión	6.4 %	21.3 %	33.0 %	12.0 %	42.8 %
Tiene deuda informal	31.6 %	22.7 %	17.3 %	41.9 %	9.4 %
Tiene deuda formal	65.2 %	74.6 %	81.4 %	57.5 %	88.3 %
Comunidad con transporte público	54.6 %	75.4 %	84.9 %	78.2 %	78.2 %

Nota: de los 723 hogares que entran en pobreza entre 2010 y 2013, 610 tienen dato de la ola 2016 (113 se pierden por atrición, misma tasa que el resto del panel); de esos 610, 355 (58 %) vuelven a salir de la pobreza para 2016 y 255 (42 %) se quedan pobres. Fuente: cálculos propios.

Cuarto, el núcleo del perfil no depende de cómo se mida la pobreza: de las 53 variables robustas bajo monetaria y las 36 bajo IPM, 28 son comunes a ambas definiciones –vivienda, ingreso/gasto, educación y ocupación del jefe, riqueza, bienes durables, servicios públicos, DMSP– (Tabla 8). Que más de la mitad de cada conjunto coincida, pese a partir de dos definiciones de pobreza y dos criterios de selección independientes, sugiere que el perfil del hogar vulnerable no es una casualidad de cómo se define “pobre”, sino una

estructura más estable detrás de ambas medidas. Las 25 variables exclusivas de monetaria son mayoritariamente financieras y comunitarias. Las 8 exclusivas de IPM incluyen, de forma reveladora, la pobreza monetaria del propio hogar en 2010 (**pobre_ingreso** y análogas): ser pobre por ingreso en la ola base es, en sí mismo, uno de los mejores predictores univariados de caer en pobreza multidimensional después, sin que la relación inversa se sostenga con la misma fuerza.

Tabla 8: Núcleo del perfil de vulnerabilidad: las 28 variables robustas comunes a pobreza monetaria (53 variables, Tabla 6) y a pobreza multidimensional –IPM– (36 variables, Anexo A.3). Valores bajo pobreza monetaria, transición 2010→2013.

Variable	Siempre	Sale	Entra	Nunca
Activos del hogar				
N.º de bienes durables	4.58	6.00	6.30	9.10
N.º de servicios públicos	2.50	3.30	3.65	4.80
Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06
Composición del hogar				
Niños al cuidado de terceros	86 %	94 %	99 %	98 %
Educación y empleo del jefe				
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %
Ocupación del jefe: Asalariado	34 %	52 %	62 %	58 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72
Etnia del jefe: Indígena	12 %	6 %	6 %	4 %
Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %
Geoespacial				
Iluminación nocturna (DMSP)	21.6	32.6	36.4	50.1
Ingreso y gasto				
Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26
Ingreso y gasto (cont.)				
Ingreso per cápita	65k	93k	269k	633k
Gasto per cápita	154k	210k	247k	662k
Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36
Vivienda: hacinamiento				
Personas por cuarto	2.13	1.65	1.49	1.11
Vivienda: materiales y servicios				
Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %
Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %
Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %
Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %
Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %
Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %
Zona de residencia				
Vive en zona rural	69 %	52 %	45 %	21 %

Fuentes geoespaciales públicas. La luz nocturna del hogar (DMSP-OLS, escala 0–63) separa monotónicamente los cuatro grupos de la matriz de transición, tanto en media como en mediana, bajo pobreza monetaria e IPM, en la transición 2010→2013 (Figura 5): de “siempre pobre” a “nunca pobre”, el valor típico sube en cada paso. Puesto a prueba contra el patrón del Hallazgo 1 (que “entra en pobreza” (vulnerable) se parece más a “sale de la pobreza” que a “nunca pobre”), el resultado depende de qué definición de pobreza y qué estadístico se use. Bajo IPM la mediana confirma el patrón con margen amplio: “entra en pobreza” (vulnerable) (10.7) queda a solo 2.9 puntos de “sale de la pobreza” (7.8) y a 38.4 de “nunca pobre” (49.1). Bajo monetaria, en cambio, la mediana en 2010→2013 es mucho más débil: “entra en pobreza” (vulnerable) (40.6) queda casi equidistante entre “sale de la pobreza” (19.9, distancia 20.7) y “nunca pobre” (61.5, distancia 20.9). Este

resultado débil, sin embargo, no se sostiene en la transición 2013→2016 –verificable porque DMSP-OLS, a diferencia de ALOS PALSAR y Landsat 5 TM, sí tiene cobertura real en ambas olas (Sección 3)–: ahí la mediana de “entra en pobreza” (vulnerable) (21.6) vuelve a quedar mucho más cerca de “sale de la pobreza” (12.7, distancia 8.9) que de “nunca pobre” (59.9, distancia 38.3), replicando el Hallazgo 1. La debilidad de 2010→2013 parece entonces ruido muestral de esa ola, no una excepción real al patrón. ALOS PALSAR (radar) sigue el mismo gradiente que DMSP-OLS y Landsat NDVI lo invierte (más verde en pobreza persistente, por ruralidad), pero ambas fuentes solo tienen datos reales en la ola 2010: a diferencia de DMSP-OLS, no es posible poner a prueba si esos patrones se sostienen en la transición 2013→2016, así que se reportan como exploratorios, con menor respaldo que el resto del perfil. Además, la Sección 5.3.1 muestra que la separación de DMSP-OLS es en gran parte redundante con servicios públicos y bienes durables ya en la encuesta. En otras palabras, DMSP-OLS separa bien y permite distinguir entre los grupos, pero aporta poca información nueva porque es información que ya se encuentra disponible en la encuesta.




Figura 5: Iluminación nocturna (DMSP-OLS) por grupo de transición, media y mediana, pobreza monetaria e IPM (2010→2013).

El mismo patrón se confirma por región: la pobreza persistente se concentra en microrregiones rurales andinas (Cundi-Boyacense, Centro-Oriente, Atlántica Media, 64–66 % siempre pobres, DMSP<9), mientras Bogotá concentra los nunca pobres (70 %, DMSP=63). La variable *region* de ELCA combina, sin embargo, dos muestras bajo el mismo nombre: Atlántica, Oriental, Central, Pacífica y Bogotá son exclusivamente urbanas; Atlántica Media, Cundi-Boyacense, Eje Cafetero y Centro-Oriente, exclusivamente rurales. *Pacífica* en la Figura 6 representa entonces solo su muestra urbana, y el diseño rural de ELCA no incluye al Chocó rural ni a La Guajira –las zonas de mayor pobreza persistente del país–: ELCA no permite caracterizar esos bolsones, y las etiquetas (*urbano*)/(*rural*) de la figura

hacen visible la limitación.




Figura 6: Grupo de transición dominante por región e iluminación nocturna (DMSP), pobreza monetaria, 2010→2013.

5.2.2. Importancia multivariada de las variables

Esta sección examina qué variables sostienen el poder predictivo documentado en la Sección 5.1, complementando el análisis univariado de la Sección 5.2.1 con la pregunta de qué aporta cada variable una vez controlando por las demás, usando la importancia por reducción de impureza de Random Forest, los coeficientes estandarizados de la regresión logística, y valores SHAP que permiten comparar los cinco algoritmos en una misma escala (medidas descritas en la Sección 4.6). Se destacan tres hallazgos.

Primero, el desempeño de los cinco algoritmos no depende de que todos coincidan en cuál variable individual “domina”, sino de que comparten un núcleo pequeño y estable de variables –la pregunta correcta no es qué variable gana en la figura de un solo algoritmo, sino qué perfil de variables se repite entre los cinco–. La Tabla 9 cuantifica qué tan pequeño es ese núcleo: agregando el SHAP medio de las columnas *one-hot* y de indicador de faltante

de vuelta a su variable original –de lo contrario Random Forest y Logística parecerían necesitar muchas más “variables” que los árboles nativos por un artefacto de codificación (332/328 columnas expandidas frente a 165/169 variables categóricas nativas), no por una diferencia real de concentración de la señal–, entre 14 y 37 variables (de un total de 165 a 169, mediana de 27) bastan para acumular el 80 % del SHAP total en cada una de las diez combinaciones algoritmo/especificación, y las diez variables más importantes por sí solas capturan entre 44 % y 72 % de esa señal.

Tabla 9: Concentración de la señal predictiva (SHAP), variables originales agregadas (dummies *one-hot* e indicadores de faltante sumados a su variable de origen antes de calcular la masa acumulada).

Algoritmo	Espec.	Variables (total)	% SHAP en top-10	Variables para 80 % del SHAP
HistGradientBoosting	A	169	69.3 %	15
XGBoost	A	169	58.7 %	23
Logística regularizada	A	169	43.9 %	28
Random Forest	A	169	59.8 %	32
LightGBM	A	169	44.4 %	37
LightGBM	B	165	71.6 %	14
HistGradientBoosting	B	165	63.9 %	18
XGBoost	B	165	54.7 %	26
Logística regularizada	B	165	45.8 %	28
Random Forest	B	165	54.9 %	34

Para delimitar ese núcleo de forma comparable entre los cinco algoritmos –sin apoyarse en cuál domina en uno en particular–, se cuenta, para cada variable, en cuántas de las diez combinaciones algoritmo/especificación queda dentro del 80 % de la masa SHAP acumulada; el núcleo se define como las variables que lo logran en al menos 5 de esas 10 combinaciones (mayoría simple), el mismo espíritu del umbral de robustez del perfil univariado de la Sección 5.2.1, aplicado aquí a consenso entre algoritmos en vez de a bootstrap de muestra. El resultado son 22 variables (Tabla 10), organizadas en las mismas categorías temáticas del perfil univariado: activos del hogar (6 variables), educación y empleo del jefe (6), composición del hogar (5), vivienda –hacinamiento y materiales– (3), y una cada una de programas sociales/deuda y comunidad. Cuatro variables aparecen en las 10 combinaciones sin excepción: número de servicios públicos, estrato verificado y número de bienes durables (activos del hogar), y personas por cuarto (hacinamiento). Este perfil es consistente con –y más completo que– cualquier figura de un solo algoritmo: confirma el papel central de riqueza, educación y activos del hogar, pero además revela un bloque de variables de composición del hogar (razón de dependencia demográfica, condición de los padres de los niños, vocabulario infantil) que ninguna figura de un solo algoritmo mostraba,

precisamente porque ninguno por separado la ubicaba entre sus primeras posiciones, pero sí lo hace de forma consistente entre varios algoritmos a la vez.

Tabla 10: Núcleo de variables del análisis de importancia multivariada: aparecen, en al menos 5 de las 10 combinaciones algoritmo/especificación, dentro del 80 % de la masa SHAP acumulada (Sección 5.2.2). [†]variable fuera del perfil univariado de 53 variables robustas de la Sección 5.2.1.

Variable	Combinaciones (de 10)
Activos del hogar	
N.º de servicios públicos	10/10
Estrato (verificado)	10/10
N.º de bienes durables	10/10
Tiene internet en el hogar	9/10
Índice de riqueza (PCA)	8/10
N.º de activos financieros	6/10
Educación y empleo del jefe	
Máx. nivel educativo del hogar	9/10
Cotización a pensión (hogar)	7/10
Edad del jefe de hogar [†]	7/10
Estado civil del jefe	6/10
Grado educativo del jefe (años) [†]	6/10
Nivel educativo del jefe (ordinal)	5/10
Vivienda: materiales y servicios	
Material de piso del hogar	8/10
Vivienda: hacinamiento	
Personas por cuarto	10/10
Valor del arriendo pagado	6/10
Composición del hogar	
% de niños con madre viva [†]	8/10
Razón de dependencia demográfica	8/10
% de niños con padre vivo [†]	7/10
Tasa de controles médicos preventivos (hogar) [†]	6/10
Puntaje de vocabulario infantil (test TVIP) [†]	6/10
Programas sociales y deuda	
Tuvo un choque económico (hogar) [†]	6/10
Comunidad	
N.º de desplazados en la comunidad [†]	5/10

Nota: 8 de las 22 variables del núcleo no forman parte del perfil univariado de 53 variables de la Sección 5.2.1 (marcadas [†]) –el criterio de selección de esa sección (robustez de η^2 /Cramér's V por bootstrap) es distinto del usado aquí (consenso de importancia SHAP entre algoritmos) y no tienen por qué coincidir.

Dos matrices sobre cómo leer este núcleo. El primero es de conteo: tres de las seis

variables de la categoría “Educación y empleo del jefe” (máximo nivel educativo del hogar, grado educativo del jefe, nivel educativo del jefe en escala ordinal) son distintas codificaciones de esencialmente la misma señal –nivel educativo–, no tres fuentes de información independientes; contarlas como tres filas del núcleo sobrestima cuántas variables sustantivas distintas hay detrás de esa categoría. El segundo es de clasificación: ninguna de las diez categorías del perfil univariado se ajusta bien a “tuvo un choque económico en el hogar” –se ubicó en “Programas sociales y deuda” por cercanía temática (ambas son formas de exposición o protección financiera), pero es conceptualmente distinta (un choque sufrido, no un instrumento de protección) de lo que esa categoría agrupaba originalmente. Ninguno de estos dos matices cambia la lectura general: las métricas de importancia usadas tampoco son directamente comparables entre sí –la reducción de impureza (Random Forest, XGBoost, LightGBM) tiende a favorecer variables continuas o de alta cardinalidad frente a las binarias, independientemente de su contenido informativo real, y de las métricas usadas aquí, SHAP es la más comparable entre algoritmos, pero ninguna es una vara neutral de importancia–, lo que reafirma por qué la lectura correcta para un hacedor de política es confiar en el perfil de variables que se repite entre algoritmos, no en el orden exacto de una figura particular.

Segundo, el hallazgo univariado más llamativo del perfil de vulnerabilidad –que la formalidad laboral del jefe de hogar señala más riesgo, no menos (Hallazgo 2, Sección 5.2.1)– no se refleja en las métricas de importancia multivariada estándar de ninguno de los cinco algoritmos: `categoria_ocupacional_jefe`, la variable con el mayor efecto univariado de las 53 (0.393), cae a un rango de importancia marginal o nula en los cinco algoritmos (posiciones 42 a 146, de 169 a 332 variables según el algoritmo), y es exactamente cero en Random Forest y en la regresión logística para casi todas sus categorías, en ambas especificaciones. El mismo patrón se repite con las otras tres variables “contraintuitivas” del Hallazgo 2: `pct_ninos_cuidado_terceros_hogar` es prácticamente nula en los cinco algoritmos y ambas especificaciones, `tiene_transporte_publico_comunidad` nunca entra al top 30, y `deuda_informal_hogar` es cero exacto en Random Forest y Logística y solo moderada (posiciones 36 a 61) en XGBoost y HistGradientBoosting bajo el Modelo B. En cambio, un proxy relacionado pero distinto –`tasa_cotizacion_pension_hogar`, formalidad medida a nivel de todo el hogar y no solo del jefe– sí sobrevive con fuerza en la mayoría de los algoritmos, aunque no de forma perfectamente consistente (HistGradientBoosting es la excepción, donde cae a las posiciones 61–64). Esta sustitución de un proxy de formalidad por otro es, además, específica de pobreza monetaria: al repetir el mismo ejercicio bajo IPM, el patrón se debilita y en parte se invierte – `categoria_ocupacional_jefe` mejora su posición de forma notable en varios algoritmos (hasta las posiciones 16–30, frente

a 42 en adelante bajo monetaria), mientras `tasa_cotizacion_pension_hogar` deja de ser un proxy confiable (su rango se amplía a 28–143 según el algoritmo). Qué proxy de formalidad “gana” el crédito predictivo no es, entonces, una regularidad general del análisis multivariado, sino algo que depende de qué definición de pobreza se use. Esto no contradice ni invalida el Hallazgo 2: la importancia multivariada mide contribución marginal dado todo lo demás en el modelo, no el efecto univariado bruto, así que si ambas variables miden formalidad y están correlacionadas entre sí, el modelo le otorga el crédito predictivo a una y deja a la otra sin margen adicional –el mismo fenómeno de multicolinealidad del Primer hallazgo, aquí entre dos proxies de formalidad–. La desventaja de las variables relacionales frente a las económicas tampoco es un accidente estadístico: por naturaleza se miden con preguntas binarias de baja varianza en la encuesta, de modo que compiten en desventaja estructural, en cualquier métrica de importancia basada en varianza explicada o en particiones, contra variables continuas de riqueza o ingreso –un sistema de focalización construido solo a partir de estos rankings invisibilizaría sistemáticamente la vulnerabilidad relacional, no por azar sino por cómo se mide–; vale la pena notar, además, que `pct_ninos_cuidado_terceros_hogar` es, indirectamente, una variable sobre carga de cuidado –típicamente asumida por mujeres–, y su práctica invisibilidad en la importancia multivariada tiene una lectura de equidad de género que el análisis cuantitativo por sí solo no captura. Para el diseño de política, la implicación no es una receta operacional única –dado que qué proxy de formalidad domina depende de la definición de pobreza, recomendar una sola variable para un sistema de alerta temprana sería prematuro sin antes fijar contra qué medida de pobreza se calibra, aunque ambos proxies comparten la ventaja de residir ya en registros administrativos de seguridad social, en el mismo espíritu de cruce de fuentes que plantea el CONPES 3877/SISBEN IV (Consejo Nacional de Política Económica y Social, 2016)–, sino, en un sentido más general, que un hallazgo univariado sustantivo y bien documentado puede resultar invisible en un gráfico de importancia de variables sin que eso signifique que el hallazgo sea falso.

Tercero, que una variable geoespacial aparezca entre las más “importantes” de un modelo no implica que aporte información nueva al conjunto de prueba, y la propia comparación entre esta sección y la de contribución marginal de DMSP-OLS lo demuestra con un caso concreto: en XGBoost sobre el Modelo A con DMSP-OLS, `dmsp_stable_lights_acum_minimo` es la séptima variable más importante de 192 por reducción de impureza, pese a que la Sección 5.3.1 ya estableció que agregar DMSP-OLS no mejora el AUC-ROC bajo pobreza monetaria en ninguna de las diez combinaciones algoritmo/especificación evaluadas (IC95 % cruza cero), precisamente por redundancia: la correlación de `dmsp_stable_lights` con el resultado cae de $r = -0.214$ a $r \approx +0.021$ al controlar por dos preguntas de la propia

encuesta (servicios públicos y bienes durables del hogar). No es una contradicción entre secciones sino el mismo fenómeno de multicolinealidad de los hallazgos anteriores visto desde otro ángulo: una variable puede ganarle particiones a otras porque mide algo parecido a lo que el modelo ya conoce, sin que eso se traduzca en una mejora del poder predictivo fuera de muestra. La advertencia metodológica es general, no específica de DMSP-OLS: un ranking de importancia –calculado, en el caso de la reducción de impureza y de SHAP, sobre el propio conjunto de ajuste– nunca equivale a una prueba de contribución marginal fuera de muestra; son dos preguntas distintas que este documento sí distingue por diseño (Secciones 5.1, 5.2.2 y 5.3), pero que resultan fáciles de confundir si solo se observa una figura de importancia sin la comparación de AUC-ROC que la acompaña.

Las dos miradas de esta sección –el perfil univariado y la importancia multivariada– convergen en lo esencial y se complementan en lo que cada una no puede ver por sí sola. Ambas identifican el mismo núcleo estructural (riqueza, educación, activos y condiciones de vivienda del hogar) como el determinante más robusto de la vulnerabilidad, sin importar si se mide por asociación univariada o por contribución a la predicción de cinco algoritmos distintos –esa coincidencia, lograda por dos métodos con supuestos y datos de entrada distintos, es la evidencia más fuerte de este documento a favor de ese núcleo–. Donde discrepan es igual de informativo: la formalidad laboral del jefe, la variable con el efecto univariado más llamativo de todo el perfil (Hallazgo 2), prácticamente no aporta a la predicción una vez el modelo ya cuenta con el resto de variables del núcleo (Segundo hallazgo de la Sección 5.2.2). Esto no es una contradicción sino una diferencia de propósito: el perfil univariado responde qué distingue a un hogar vulnerable en términos descriptivos –incluidas señales contraintuitivas valiosas para entender el fenómeno–, mientras que la importancia multivariada responde qué hace falta, de forma no redundante, para predecirlo –y una señal puede ser sustantivamente reveladora sin ser útil para ese segundo objetivo, precisamente porque otras variables ya la vuelven redundante–. Para el diseño de un instrumento de focalización, la implicación práctica es usar cada análisis para lo que sirve: el perfil univariado para entender y comunicar el fenómeno, y el núcleo de importancia multivariada (Sección 5.2.2) para decidir qué variables medir si el objetivo es predecir con la menor cantidad de información posible.

5.3. Contribución marginal de las variables geoespaciales

Esta sección evalúa, en tres pasos, el aporte de DMSP-OLS –la única de las tres fuentes geoespaciales nuevas con datos reales tanto en la ola de entrenamiento (2010) como en la de prueba (2013), Sección 3.2– al desempeño del benchmark: primero su efecto promedio bajo pobreza monetaria, luego el mismo ejercicio bajo pobreza multidimensional (IPM),

y finalmente si esos promedios esconden heterogeneidad relevante para el diseño de una política de focalización.

5.3.1. Bajo pobreza monetaria

Se reentrenaron los cinco algoritmos de la Sección 5.1 agregando a los Modelos A y B las 23 variables DMSP-OLS de estado y ventana acumulada (Sección 3.2), bajo el mismo holdout temporal, balanceo de clases y selección de umbral ya usados –en el código y en los archivos de resultados esta comparación se identifica como A/AgeoDMSP y B/BgeoDMSP; aquí se usa la forma expandida “A” / “A + DMSP-OLS” por legibilidad–.


Tabla 11: AUC-ROC y precisión en el decil de mayor riesgo, con y sin DMSP-OLS, holdout temporal (train 2010→2013, test 2013→2016). Umbral elegido por CV maximizando F-beta ($\beta = 2$), con CV_FOLDS=10 y N_ITER_BUSQUEDA=30.

Algoritmo	Especificación	AUC-ROC	Precision top-10 %	Umbral	Recall	Precision	F1
Random Forest	A	0.766	0.486	0.138	0.926	0.277	0.426
Random Forest	A + DMSP-OLS	0.763	0.481	0.264	0.938	0.271	0.420
XGBoost	A	0.767	0.505	0.112	0.949	0.264	0.413
XGBoost	A + DMSP-OLS	0.765	0.501	0.118	0.937	0.272	0.421
LightGBM	A	0.758	0.516	0.096	0.903	0.281	0.428
LightGBM	A + DMSP-OLS	0.752	0.497	0.102	0.902	0.277	0.424
HistGradientBoosting	A	0.763	0.512	0.324	0.909	0.283	0.432
HistGradientBoosting	A + DMSP-OLS	0.763	0.500	0.312	0.912	0.281	0.429
Logística regularizada	A	0.747	0.506	0.372	0.883	0.280	0.426
Logística regularizada	A + DMSP-OLS	0.746	0.500	0.370	0.883	0.281	0.426
Random Forest	B	0.742	0.508	0.306	0.892	0.272	0.416
Random Forest	B + DMSP-OLS	0.739	0.492	0.266	0.925	0.255	0.399
XGBoost	B	0.742	0.495	0.126	0.940	0.250	0.395
XGBoost	B + DMSP-OLS	0.740	0.495	0.128	0.929	0.254	0.399
LightGBM	B	0.731	0.487	0.148	0.909	0.259	0.403
LightGBM	B + DMSP-OLS	0.737	0.481	0.126	0.888	0.271	0.415
HistGradientBoosting	B	0.735	0.494	0.142	0.879	0.275	0.418
HistGradientBoosting	B + DMSP-OLS	0.736	0.487	0.142	0.880	0.275	0.419
Logística regularizada	B	0.739	0.500	0.350	0.890	0.270	0.414
Logística regularizada	B + DMSP-OLS	0.739	0.494	0.350	0.888	0.273	0.417

Nota: recall, precision y F1 se miden al umbral de clasificación ya elegido para cada algoritmo/especificación por validación cruzada maximizando F_2 (Sección 4.5, sin re-elegirlo al agregar DMSP-OLS). Los intervalos de confianza al 95 % (sobre las 5 semillas) no se muestran por espacio: son consistentemente angostos, hasta ± 0.004 en AUC-ROC y hasta ± 0.03 en precisión top-10 % en el peor caso –ninguno lo suficientemente ancho para cambiar la lectura de las diferencias reportadas. Fuente: cálculos propios.

Primero, agregar DMSP-OLS a las covariables de la encuesta no mejora el desempeño del benchmark en ningún algoritmo: el AUC-ROC cae o se mantiene igual en 8 de las 10 comparaciones algoritmo/especificación (Tabla 11), y `precision_top10` –la métrica más relevante para un programa de focalización de capacidad fija– cae o se mantiene igual en las 10, sin una sola excepción. Se descartó sobreajuste como explicación (la brecha entre el AUC de validación cruzada y el de prueba no se ensancha al agregar DMSP-OLS) y el mismo patrón, con correlaciones aún más débiles, se repite en ALOS PALSAR y Landsat 5 TM.⁵ La razón es redundancia, no ausencia de señal: `dmsp_stable_lights` correlaciona con el resultado tan fuerte como variables de riqueza ya en la encuesta ($r = -0.214$, comparable a `estrato_verificado_hogar`), pero esa correlación colapsa a $r \approx +0.010$ al controlar por las cuatro variables que dominan el núcleo de importancia multivariada (Sección 5.2.2): número de servicios públicos, estrato verificado, número de bienes durables y personas por cuarto (Figura 7).

⁵Se probó además si DMSP-OLS aporta más al eliminar de la encuesta las dos preguntas que la vuelven redundante (resultado mixto y débil: solo la regresión logística mejora de forma consistente, los modelos de árboles no) y si aporta más cerca de la línea de pobreza (sin evidencia de eso tampoco, en los tres terciles de cercanía).



*Controlando por las 4 variables de referencia (correlación parcial vía residuos, teorema de Frisch-Waugh-Lovell).

Figura 7: Correlación de Pearson de `dmsp_stable_lights` con caer en pobreza monetaria, cruda y residualizada, frente a las cuatro variables de encuesta que dominan el núcleo de importancia multivariada (Sección 5.2.2): número de servicios públicos, estrato verificado, número de bienes durables y personas por cuarto. La correlación bruta de DMSP-OLS (gris oscuro) es comparable en magnitud a la de las cuatro variables de referencia (gris claro), pero colapsa hacia cero al residualizar (rojo) tanto la variable geoespacial como el resultado contra esas mismas cuatro variables –correlación parcial vía residuos (teorema de Frisch–Waugh–Lovell); $n = 2,150$, restringido por valores faltantes en estrato verificado–. Fuente: cálculos propios.

Un matiz con implicación práctica: pese a ser redundante en poder predictivo, DMSP-OLS es marcadamente más estable en el tiempo que la variable de encuesta que la vuelve redundante (correlación test-retest 2010–2013 de 0.958, frente a 0.600 de bienes durables del hogar) –relevante si el argumento no es reemplazar una encuesta vigente sino sustituir información desactualizada entre rondas (Sección 6.2)–.

5.3.2. Bajo pobreza multidimensional (IPM)

El mismo ejercicio se repitió con `pobre_ipm` como variable de resultado en vez de la pobreza monetaria (mismas covariables X , solo cambia el *target*), evaluando la significancia del cambio de AUC-ROC con un bootstrap pareado sobre el conjunto de prueba, con una versión adicional que corrige por correlación intra-comunidad agrupando el remuestreo por `id_comunidad` (1,696 clusters) –el error estándar ingenuo por hogar puede subestimar la incertidumbre si hogares de una misma comunidad comparten exposición a la misma señal de iluminación–.

Tabla 12: Contribución marginal de DMSP-OLS bajo pobreza multidimensional (IPM), holdout temporal (train 2010→2013, test 2013→2016).

Algoritmo	Esp.	AUC base	AUC +DMSP	Δ AUC	Δ top-10 %
XGBoost	A	0.7254	0.7363	+0.0128	+0.022
Random Forest	A	0.7291	0.7291	+0.0012	+0.004
LightGBM	A	0.7414	0.7452	+0.0037	+0.005
HistGradientBoosting	A	0.7396	0.7378	-0.0018	+0.002
Logística regularizada	A	0.7300	0.7300	-0.0000	+0.009
XGBoost	B	0.7276	0.7455	+0.0198	+0.016
Random Forest	B	0.7350	0.7323	-0.0035	+0.015
LightGBM	B	0.7304	0.7471	+0.0167	+0.021
HistGradientBoosting	B	0.7385	0.7401	+0.0016	-0.007
Logística regularizada	B	0.7296	0.7295	-0.0000	+0.011

Nota: AUC base/+DMSP son la media de 5 semillas (Sección 5.1); Δ AUC viene de un bootstrap pareado sobre una sola semilla (42) del mismo conjunto de prueba, por eso puede diferir del AUC de 5 semillas en el tercer decimal. Filas en **negrita**: el IC95 % de Δ AUC no cruza cero – LightGBM-B (IC95 % [0.0076, 0.0258], $p = 0.000$ sin corregir por clustering (sin cobertura de bootstrap cluster-robusto)); XGBoost-A (IC95 % [0.0037, 0.0225], $p = 0.006$ sin corregir y $p = 0.004$ corrigiendo por clustering); XGBoost-B (IC95 % [0.0096, 0.0296], $p = 0.001$ sin corregir y $p = 0.000$ corrigiendo por clustering). La corrección por clustering comunitario (remuestreo agrupado por `id_comunidad`, 1,696 comunidades, disponible para XGBoost, HistGradientBoosting y Logística) es necesaria porque DMSP-OLS tiene una resolución espacial gruesa (30 arcosegundos, ~ 1 km) – la limitación que llevó al desarrollo de VIIRS (15 arcosegundos, ~ 500 m, con mejor calibración y menos saturación en zonas brillantes) como sucesor de DMSP-OLS– así que hogares de una misma comunidad comparten, en buena medida, el mismo píxel o uno adyacente de iluminación nocturna, y el error estándar ingenuo por hogar puede subestimar la incertidumbre si no se corrige por esa correlación compartida. Fuente: cálculos propios.

Segundo, bajo IPM el efecto de DMSP-OLS sí es estadísticamente significativo, aunque económicamente marginal, en 2 de los 5 algoritmos: XGBoost mejora en ambas especificaciones (+0.013 a +0.020 en AUC-ROC, $p \leq 0.006$) y LightGBM en el Modelo B (+0.017, $p < 0.001$), confirmado con bootstrap pareado y con una corrección por clustering comunitario que descarta que el resultado sea un artefacto de tratar como independientes a hogares que comparten señal espacial. Las siete combinaciones restantes no son distinguibles de cero. La lectura más defendible no es “no sirve” ni “mejora la predicción”: el aporte es

real bajo IPM, concentrado en un subconjunto de algoritmos, y demasiado pequeño para cambiar por sí solo una decisión de focalización.

5.3.3. Heterogeneidad del efecto de DMSP-OLS

Las Secciones 5.3.1 y 5.3.2 establecen el efecto *promedio* de agregar DMSP-OLS. Esta subsección pregunta si ese promedio esconde heterogeneidad –si DMSP-OLS ayuda más en subpoblaciones específicas– a lo largo de cuatro ejes: zona (urbano/rural), cercanía a la línea de pobreza en la ola base, estrato socioeconómico verificado, y terciles de un índice de riqueza construido con las dos variables de encuesta que hacen redundante a DMSP-OLS en el efecto agregado. Es un ejercicio exploratorio (estimaciones puntuales por celda, sin bootstrap específico de cada subgrupo).

Tabla 13: Δ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza multidimensional (IPM). En **negrita**: $|\Delta| \geq 0.02$. Grupos con $n < 30$ omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios.

Eje	Grupo	Esp.	n	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	2,452	+0.012	+0.006	+0.010	+0.005	+0.001
	Rural	B	2,452	+0.019	+0.004	+0.032	+0.009	+0.001
	Urbano	A	3,119	+0.013	-0.002	+0.000	-0.005	-0.000
	Urbano	B	3,119	+0.018	-0.015	+0.008	-0.004	+0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	1,393	+0.009	-0.005	+0.003	+0.003	-0.001
	Q1 (mas cerca de LP)	B	1,393	+0.015	+0.001	+0.012	+0.003	-0.001
	Q2	A	1,394	+0.024	-0.006	+0.010	-0.012	-0.000
	Q2	B	1,394	+0.039	-0.013	+0.032	-0.006	-0.000
	Q3	A	1,392	+0.025	+0.009	+0.002	+0.009	+0.003
	Q3	B	1,392	+0.025	-0.008	+0.030	+0.006	+0.003
	Q4 (mas lejos)	A	1,392	+0.013	+0.011	+0.003	-0.009	-0.004
	Q4 (mas lejos)	B	1,392	+0.019	-0.015	-0.008	+0.015	-0.003
Estrato	Estrato 1	A	2,046	+0.010	+0.002	+0.005	+0.004	-0.001
	Estrato 1	B	2,046	+0.018	+0.004	+0.024	-0.002	-0.001
	Estrato 2	A	2,439	+0.020	+0.003	+0.007	-0.008	+0.002
	Estrato 2	B	2,439	+0.027	-0.006	+0.015	+0.005	+0.002
	Estrato 3	A	889	-0.007	-0.006	-0.006	-0.005	+0.002
	Estrato 3	B	889	+0.005	-0.031	-0.003	+0.009	+0.003
Proxy de riqueza	Bajo (proxy menos discriminante)	A	1,858	+0.014	+0.003	+0.008	+0.001	+0.001
	Bajo (proxy menos discriminante)	B	1,858	+0.021	-0.003	+0.030	+0.003	+0.000
	Medio	A	1,977	+0.007	+0.004	+0.002	-0.006	+0.000
	Medio	B	1,977	+0.018	-0.004	+0.019	-0.001	+0.000
	Alto (proxy menos discriminante)	A	1,736	+0.034	-0.001	+0.004	+0.001	+0.000
	Alto (proxy menos discriminante)	B	1,736	+0.033	-0.030	+0.009	+0.005	+0.000

Tercero, y el hallazgo más concreto a favor del valor de DMSP-OLS: el efecto promedio nulo (monetaria) o pequeño (IPM) esconde heterogeneidad relevante. Bajo monetaria el nulo se sostiene en los cuatro ejes explorados (Tabla 23, Apéndice A.5): de 70 celdas algoritmo/grupo/especificación, solo 1 supera el umbral de cambio relevante ($|\Delta\text{AUC}| \geq 0.02$). Bajo IPM, en cambio (Tabla 13), el aporte se concentra sistemáticamente en zona rural, estratos bajos y hogares peor capturados por el proxy de riqueza de la encuesta—justo donde la información de encuesta es más débil—; LightGBM-B es el patrón más claro (+0.032 en zona rural frente a +0.008 urbano, +0.024 en Estrato 1 frente a -0.003 en Estrato 3). Random Forest es la única excepción sistemática, sin ganancia en casi ningún

subgrupo, consistente con no tener efecto agregado significativo en ninguna especificación IPM. Esto sugiere que el valor de DMSP-OLS no está en sustituir el poder predictivo que ya aporta la encuesta, sino en complementarla precisamente donde su cobertura es más débil o menos confiable en el tiempo –el escenario de un sistema de focalización con información administrativa incompleta o encuestas desactualizadas–. Es un ejercicio exploratorio (celdas de unos pocos cientos de hogares, sin bootstrap propio); confirmarlo con más rigor queda como agenda de investigación (Sección 6.3).

Traducido al lenguaje de errores de inclusión y exclusión de la Sección 5.1.2, esta heterogeneidad tiene una lectura más concreta: en LightGBM-Modelo B –el algoritmo con el patrón más claro– agregar DMSP-OLS sube el recall (menos errores de exclusión, hogares vulnerables que el modelo deja de marcar) en 6.4 puntos porcentuales en zona rural y 7.0 puntos en el tercil de riqueza-proxy menos discriminante, en ambos casos sin costo en precisión (cambio nulo o positivo, +0.003 a +0.004) –es decir, sin aumentar los errores de inclusión–; en las subpoblaciones opuestas (zona urbana, proxy de riqueza más discriminante) el recall cae en su lugar (−5.5 y −9.7 puntos respectivamente). El mecanismo no es idéntico en XGBoost, el otro algoritmo con efecto agregado significativo: ahí la ganancia de AUC-ROC no se traduce de forma consistente en más recall –en el Modelo B el recall cae en zona urbana y en el tercil de mayor riqueza pese a que el AUC sube en ambos, con la precisión subiendo en su lugar–, lo que sugiere que el mecanismo por el cual DMSP-OLS reduce el error de focalización (más cobertura vs. más precisión) depende del algoritmo, no solo de la subpoblación (Tabla 13).

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento evalúa si las variables geoespaciales públicas mejoran la predicción de la transición hacia la pobreza de hogares colombianos no pobres, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). El ejercicio completo cubre la auditoría sistemática y no muestral de los cinco módulos de la ELCA (más de 4.000 columnas originales), la construcción de la variable de resultado –siguiendo el enfoque de López-Calva y Ortiz-Juárez (2011, 2014), con cinco ejercicios de robustez sobre su construcción–, la estimación y comparación de cinco algoritmos de aprendizaje supervisado bajo dos especificaciones de covariables (monetaria e IPM), y la evaluación del aporte de DMSP-OLS –la única de las tres fuentes geoespaciales nuevas con cobertura temporal suficiente para un holdout real– tanto en su efecto promedio como en su heterogeneidad por subgrupo.

Cinco hallazgos se destacan. **Primero**, la dinámica de la pobreza en el panel ELCA 2010–2016 muestra una reducción sostenida de la incidencia (de 60.7 % a 42.4 % por ingreso) acompañada de una tasa de entrada a la pobreza de 23.4 % entre 2010–2013 y de 19.9 % entre 2013–2016, con una tasa de salida que casi duplica a la de entrada en ambos periodos; bajo IPM la entrada es menos frecuente pero también lo es la salida, consistente con que las privaciones estructurales cambian más lento que el ingreso corriente (Sección 4.1). **Segundo**, el perfil del hogar vulnerable –el que entra en pobreza– se parece mucho más, en la mayoría de sus características observables, al hogar que *acaba de salir* de la pobreza que al que nunca fue pobre (47 de 53 variables robustas lo ubican más cerca de “sale”), con una excepción sistemática y contraintuitiva: la formalidad laboral del jefe de hogar es *mayor* en quien está a punto de caer que en quien nunca fue pobre, justo la señal que convencionalmente se usaría para descartar el riesgo (Sección 5.2.1). **Tercero**, los cinco algoritmos evaluados alcanzan un desempeño similar entre sí (AUC-ROC entre 0.731 y 0.767), sin que ninguno domine claramente a los demás, y la brecha de desempeño entre el modelo que incluye ingreso/gasto del hogar y el que no los incluye es sorprendentemente pequeña (0.008–0.028 en AUC-ROC): las covariables no monetarias explican una fracción sustancial del poder predictivo que, bajo el enfoque clásico de vulnerabilidad (Chaudhuri et al., 2002), se atribuiría casi exclusivamente al ingreso (Sección 5.1).

Cuarto, y central para la pregunta de investigación: agregar DMSP-OLS al panel de covariables *no* mejora la predicción de pobreza monetaria (efecto nulo, IC95 % cruza cero, en las 10 combinaciones algoritmo/especificación evaluadas), pero sí lo hace bajo IPM, de forma estadísticamente significativa aunque económicamente pequeña, en 3 de 10 combinaciones (XGBoost en ambas especificaciones, LightGBM en el Modelo B; Δ AUC-ROC de 0.013 a 0.020, Sección 5.3.2). La correlación residualizada confirma que, bajo monetaria, esta ausencia de aporte es redundancia, no ausencia de señal: `dmsp_stable_lights` cae de $r = -0.214$ a $r = +0.021$ una vez se controla por dos preguntas de la propia encuesta (servicios públicos y bienes durables del hogar), que miden en esencia el mismo fenómeno de urbanización y consolidación del entorno (Sección 5.3.1). **Quinto**, ni el efecto nulo monetario ni el pequeño efecto IPM son parejos en la población: bajo IPM, el aporte de DMSP-OLS se concentra en zona rural, estratos bajos y hogares peor capturados por el proxy de riqueza de la encuesta –el escenario donde la información de encuesta es más débil– (Sección 5.3.3), y DMSP-OLS es además casi el doble de estable en el tiempo (correlación test-retest 2010–2013 de 0.958) que la variable de encuesta que compite con ella en poder predictivo (0.600 para bienes durables del hogar). En conjunto, estos dos últimos hallazgos matizan la conclusión de redundancia: DMSP-OLS no aporta poder predictivo incremental donde la ELCA ya tiene buena cobertura, pero sí –y de forma medible– donde esa cobertura

es más débil o menos confiable en el tiempo, precisamente el escenario de un sistema de focalización con información administrativa incompleta o encuestas desactualizadas entre rondas.

6.2. Implicaciones para la política pública

Los resultados de este documento sugieren tres implicaciones para el diseño de sistemas de focalización como el SISBEN. Primero, la evidencia de que las covariables no monetarias tienen un poder predictivo casi comparable al del ingreso sugiere que un sistema de alerta temprana no necesita esperar a observar directamente el ingreso de un hogar –la variable más costosa y menos frecuente de actualizar– para identificar candidatos a la vulnerabilidad; características más fáciles de observar o de actualizar administrativamente (educación, activos del hogar, formalidad laboral) ya capturan buena parte de esa señal –con la salvedad de que la formalidad laboral señala riesgo en la dirección *contraria* a la intuitiva (Sección 5.2.1)–. Segundo, la comparación entre algoritmos (Sección 5.1) muestra que la elección del algoritmo correcto depende de la función de pérdida que le importa al hacedor de política: XGBoost maximiza el recall –relevante si el costo de no detectar un hogar que va a caer en pobreza (error de exclusión) es mucho mayor que el de incluir por error a uno que no cae (error de inclusión)–, mientras que HistGradientBoosting ofrece mejor precisión y el mejor balance entre ambas (mayor F1) al mismo nivel de AUC-ROC. Un sistema real debería fijar explícitamente esa preferencia antes de elegir el modelo, en vez de optimizar únicamente por AUC-ROC. Tercero, DMSP-OLS no justifica su costo de integración como covariable adicional para un sistema que ya se apoya en una encuesta de hogares con buena cobertura –el efecto es nulo bajo pobreza monetaria y económicamente marginal bajo IPM (Secciones 5.3.1 y 5.3.2)–, pero la heterogeneidad de ese efecto sí ofrece un argumento de política más específico: su aporte se concentra en zona rural, estratos bajos y hogares peor capturados por los proxies de riqueza de la encuesta (Sección 5.3.3), y su mayor estabilidad temporal frente a esos mismos proxies (Sección 5.3.1) la hace más útil como respaldo en escenarios de datos administrativos incompletos o encuestas desactualizadas entre rondas que como insumo de rutina para una encuesta ya vigente y con buena cobertura.

6.3. Limitaciones y agenda de investigación

La agenda de investigación que deja esta tesis tiene tres frentes concretos. Primero, la heterogeneidad territorial del aporte de DMSP-OLS bajo IPM (Sección 5.3.3) se estableció con estimaciones puntuales por celda, sin bootstrap propio de cada subgrupo –el siguiente paso es exactamente ese bootstrap por celda (zona, estrato, tercil de riqueza) para poder afirmar con un intervalo de confianza, no solo con una estimación puntual, que el aporte se

concentra donde la Sección 5.3.3 sugiere. Segundo, la comparación por región geográfica (más allá de la partición urbano/rural ya explotada) quedó fuera por tamaño de muestra: con 3,089 hogares no pobres en la base de entrenamiento (Tabla 2), partir además por región deja celdas demasiado pequeñas para una estimación confiable bajo el holdout temporal principal. Tercero, ALOS PALSAR y Landsat 5 TM –evaluadas en esta tesis solo de forma exploratoria, sin holdout real por falta de cobertura temporal (Sección 3.2)– quedan pendientes de una evaluación con el mismo rigor que DMSP-OLS en cuanto existan más olas de estas fuentes con cobertura real.

Fotos de Google Street View como fuente alternativa (exploratorio). Un cuarto frente, más incipiente, es si fotografías a nivel de calle –en vez de una fuente satelital– podrían cumplir una función similar a DMSP-OLS. El diagnóstico disponible separa dos preguntas con calidad de evidencia muy distinta. La primera –¿el contenido visual de una foto de vivienda predice la luz nocturna de esa misma zona?– tiene una respuesta sólida: representaciones vectoriales (*embeddings*) de las fotos de Google Street View (GSV), extraídas con cuatro modelos preentrenados de visión por computador (CLIP, VGG19, ResNet50, Places365), predicen `dmsp_stable_lights` con R^2 fuera de muestra de 0.63 a 0.74 ($n = 830$, $p < 10^{-180}$ en los cuatro modelos; Places365 y ResNet50 son los de mejor ajuste). La muestra se restringió, tras una corrección metodológica –la etiqueta `ola` del pipeline de GSV indica la ola *asignada* a la foto, no su fecha real de captura; de las 6,788 fotos etiquetadas `ola=2013`, solo 13.8 % (939) fueron tomadas realmente en la ventana 2011–2013–, a fotos con fecha de captura verificada dentro de esa ventana. La segunda pregunta –¿esas fotos aportan poder predictivo de pobreza *más allá* de lo que ya aporta DMSP-OLS?– no tiene todavía una respuesta confiable: con $n = 283$ hogares (la intersección de fotos válidas y conjunto de prueba), el coeficiente del primer componente principal de los embeddings en una regresión logística junto con DMSP-OLS cambia de signo entre especificaciones y algoritmos, sin significancia consistente. La conclusión razonable no es que las fotos “no aportan” sino que la pregunta de aporte incremental exige un tamaño de muestra que la cobertura actual de GSV en Colombia –limitada por la disponibilidad histórica de Street View, no por el diseño de esta tesis– todavía no permite responder con rigor. Queda como agenda directa repetir este ejercicio cuando exista mayor cobertura temporal de fotos.

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Angulo Salazar, R. C., Díaz Cuervo, Y., & Pardo Pinzón, R. (2011). *Índice de Pobreza Multidimensional para Colombia (IPM-Colombia) 1997-2010* (Archivos de Economía N.º 382). Departamento Nacional de Planeación, Dirección de Estudios Económicos. Bogotá.
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (inf. téc.). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). Assessing Household Vulnerability to Poverty from Cross-Sectional Data. *Columbia University Department of Economics Discussion Papers*, (0102-52).
- Christiaensen, L., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Cornia, G. A., & Stewart, F. (1993). Two Errors of Targeting. *Journal of International Development*, 5(5), 459-496. <https://doi.org/10.1002/jid.3380050503>
- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.

- Davis, J., & Goadrich, M. (2006). The Relationship Between Precision-Recall and ROC Curves. *Proceedings of the 23rd International Conference on Machine Learning*, 233-240. <https://doi.org/10.1145/1143844.1143874>
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/713600071>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2025). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of Sustainable Development & World Ecology*. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). *Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature* (ADB Working Paper). Asian Development Bank Institute.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*. <https://doi.org/10.1002/jid.3751>
- Hofer, M., Sako, T., Martinez, A. J., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*. <https://doi.org/10.1111/asej.12349>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Economics*, 61(1), 99-111.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-

- SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juárez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juárez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón, G., Escobar, D., López, F., Pérez, P., & Orozco, J. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>
- Newhouse, D., Merfeld, J., Ramakrishnan, A., Swartz, T., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

A.1. Correlación entre covariables y riesgo de multicolinealidad

Complemento de la Sección 4.3: análisis de correlación de Pearson entre las 159 variables numéricas del dataset consolidado –incluidas las 4 geoespaciales–, motivado por el riesgo de multicolinealidad para el modelo de regresión logística regularizada.

Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 24), solo se reportan como “altas” los pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican los 35 pares de la Figura 8.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan sobre 0.97 con su propia brecha a la LP; `lp` y `li` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal correlacionan -0.93 (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmsp_stable_lights` correlaciona 0.87 con la línea de pobreza `lp` y 0.81 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`). Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.2 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la Sección 5.3.1.



Figura 8: Pares de variables con correlación de Pearson $|r| > 0.7$ (calculados sobre al menos 500 observaciones conjuntas no-nulas), ordenados por magnitud de la correlación. La mayoría corresponde a redundancias esperables (medidas nominal vs. real de un mismo concepto, o un indicador individual y su agregado a nivel de hogar); la más relevante para este trabajo es la de `dmsp_stableLights` con `lp`, `li` y `n_servicios_publicos_hogar`, que se retoma en la Sección 5.3.1. Fuente: cálculos propios.

A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria

Complemento de la Sección 4.1: incidencia agregada de pobreza monetaria por ingreso y por gasto, su descomposición Foster-Greer-Thorbecke (FGT), y cinco ejercicios diseñados para evaluar qué tan sensible es la variable de transición a la pobreza –la variable de interés de esta tesis– a decisiones de construcción del ingreso, a la representatividad muestral y al error de medición cerca del umbral de pobreza.

A.2.1. Incidencia y descomposición FGT

La Figura 9 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más *baja* que la de ingreso en los tres puntos del panel (47.6 %, 40.9 % y 33.4 %): la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto. Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no es un artefacto de la medida de bienestar elegida.




Figura 9: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 10 descompone la pobreza por ingreso en sus tres componentes FGT: inciden-

cia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 10: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

A.2.2. Ejercicios de robustez

Se implementaron cinco ejercicios de robustez sobre las cifras de transición de la Sección 4.1: ponderación muestral, dos reclasificaciones del ingreso, sensibilidad al umbral de pobreza, y atrición del panel.

Ponderación muestral. Ninguno de los resultados de la Sección 4.1 usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (`fexhog`, `fexhog_2013`, ambos transversales, y `fexhog_2010`, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % → 60.4 % en 2010, 52.4 % → 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % → 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 %

a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorrrateados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de esta tesis. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010→2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se

repite las matrices de transición (Figura 11). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % (LP−10 %) y 49.1 % (LP+10 %) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 11: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 12 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 12: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 13). La atrición total es de 11.4% en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). Esa cifra agregada sí se desagregó por perfil de hogar: la atrición **no es aleatoria**, se concentra sistemáticamente en hogares urbanos y de estrato más alto. Por zona, la tasa de pérdida es 2.8 veces mayor en zona urbana que en zona rural en 2010–2013 (16.2% vs. 5.8%) y 1.7 veces mayor en 2013–2016 (14.1% vs. 8.2%); por estrato socioeconómico, la pérdida crece monótonamente de 8.9% en estrato 1 a 26.0% en estrato 4 en 2010–2013. Por región, Bogotá tiene la mayor pérdida (24.9%) y Centro-Oriente la menor (3.1%). El patrón es consistente con que los hogares urbanos y de mayor estrato son más móviles (cambian de vivienda con más frecuencia), lo que dificulta su relocalización entre olas del panel –no con una atrición concentrada en los hogares más pobres, que de hecho es la más baja de las cuatro categorías de estrato–. No se investigó si, controlando por zona/estrato/región, la atrición está además asociada al estado de pobreza mismo del hogar (una limitación que se retoma en la Sección 6.3).




Figura 13: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

A.3. Perfil completo de covariables, pobreza multidimensional (IPM)

Complemento de la Sección 5.2.1: perfil completo de covariables robustas frente a la transición 2010→2013 bajo pobreza multidimensional (mismo criterio de inclusión que en pobreza monetaria – efecto > 0.10 con bootstrap, sin deduplicar por correlación), una tabla

por categoría temática.

Tabla 14: Ingreso y gasto – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Pobre extremo por ingreso (2010)	67 %	55 %	53 %	26 %
Pobre por ingreso (2010)	90 %	79 %	84 %	52 %
Pobre por gasto (2010)	74 %	58 %	68 %	40 %
Pobre extremo por gasto (2010)	31 %	21 %	27 %	8 %
Gasto per cápita	112k	148k	223k	400k
Ingreso per cápita	74k	101k	104k	332k
Línea de pobreza (referencia)	137k	140k	151k	177k
Línea de indigencia (referencia)	74k	75k	77k	82k
Ingreso (veces la línea de pobreza)	0.54	0.70	0.67	1.73
Gasto (veces la línea de pobreza)	0.83	1.07	1.33	2.12

Tabla 15: Zona de residencia – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Vive en zona rural	84 %	80 %	67 %	36 %

Tabla 16: Vivienda: materiales y servicios – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Material de piso: Tierra o arena	61 %	35 %	20 %	5 %
Servicio sanitario: Inodoro conectado a alcantarillado	12 %	16 %	30 %	62 %
Obtención de agua: Acueducto público	14 %	21 %	34 %	64 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	32 %	42 %	65 %	86 %
Combustible de cocina: Leña, madera, carbón de leña	83 %	71 %	60 %	28 %
Recolección de basura: La recogen los servicios de aseo	15 %	20 %	34 %	64 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	40 %	38 %	31 %	20 %
Tipo de vivienda: Apartamento	5 %	6 %	6 %	26 %

Tabla 17: Vivienda: hacinamiento – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Personas por cuarto	2.56	1.94	2.10	1.44

Tabla 18: Activos del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
N.º de servicios públicos	1.62	2.07	2.65	4.05
N.º de bienes durables	4.16	4.66	4.61	7.20
Índice de riqueza (PCA)	-0.93	-0.67	-0.87	0.33

Tabla 19: Educación y empleo del jefe – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Educación del jefe: Ninguno	42 %	17 %	8 %	2 %
Ocupación del jefe: Jornalero	45 %	31 %	25 %	6 %
Adultos alfabetizados en el hogar	53 %	79 %	92 %	98 %
Nivel educativo del jefe (ordinal)	1.21	1.90	2.11	3.10
Sexo del jefe: Hombre	83 %	83 %	71 %	69 %
Estado civil del jefe: En unión libre	60 %	55 %	42 %	35 %
Máx. nivel educativo del hogar	1.69	2.22	2.34	3.42
Registro mercantil del jefe: No lo necesita	72 %	55 %	62 %	49 %
Etnia del jefe: Indígena	15 %	12 %	11 %	6 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	78 %	67 %	63 %	59 %
Cotización a pensión (hogar)	1 %	3 %	6 %	25 %

Tabla 20: Composición del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Niños al cuidado de terceros	92 %	65 %	79 %	97 %

Tabla 21: Geoespacial – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Iluminación nocturna (DMSP)	13.8	16.7	23.0	40.7

A.4. Desempeño de los modelos bajo pobreza multidimensional (IPM)

Complemento de la Sección 5.1: mismo benchmark de cinco algoritmos y misma metodología robusta (holdout temporal, CV_FOLDS=10, N_ITER_BUSQUEDA=30, 5 semillas), con pobreza multidimensional (IPM) como variable de resultado en vez de pobreza monetaria – covariables idénticas.⁶

Tabla 22: Desempeño de los cinco algoritmos bajo pobreza multidimensional (IPM), holdout temporal (train 2010→2013, test 2013→2016). Misma metodología robusta que la Tabla 4 (monetaria), covariables idénticas – único factor que cambia es la variable de resultado. Prec.-top10: precisión entre el 10 % de hogares de mayor riesgo.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precision	Prec.-top10	F1
LightGBM	Aipm	0.11	0.741	0.670	0.184	0.263	0.288
HistGradientBoosting	Aipm	0.11	0.740	0.603	0.197	0.271	0.295
Logística regularizada	Aipm	0.10	0.730	0.726	0.166	0.258	0.269
Random Forest	Aipm	0.31	0.729	0.645	0.183	0.253	0.285
XGBoost	Aipm	0.11	0.725	0.844	0.139	0.251	0.239
HistGradientBoosting	Bipm	0.10	0.739	0.620	0.189	0.265	0.289
Random Forest	Bipm	0.26	0.735	0.753	0.165	0.260	0.270
LightGBM	Bipm	0.08	0.730	0.721	0.167	0.251	0.270
Logística regularizada	Bipm	0.11	0.730	0.716	0.167	0.255	0.270
XGBoost	Bipm	0.09	0.728	0.901	0.130	0.258	0.228

A.5. Heterogeneidad territorial del aporte de DMSP-OLS bajo pobreza monetaria

Complemento de la Sección 5.3.3: el detalle por celda (eje de heterogeneidad, grupo, especificación y algoritmo) que sostiene la afirmación de que el efecto nulo de DMSP-OLS bajo pobreza monetaria se mantiene parejo en los cuatro ejes explorados, sin subgrupos donde aporte de forma sistemática.

⁶Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Random Forest (Aipm y Bipm), donde fue *balanced* (reponderación de clases).

Tabla 23: Δ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza monetaria. En **negrita**: $|\Delta| \geq 0.02$. Grupos con $n < 30$ omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios.

Eje	Grupo	Esp.	n	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	1,170	-0.004	-0.008	-0.009	-0.003	-0.003
	Rural	B	1,170	-0.001	-0.007	+0.012	-0.000	-0.002
	Urbano	A	2,021	-0.003	+0.001	-0.006	+0.001	-0.000
	Urbano	B	2,021	-0.003	-0.004	+0.003	-0.001	-0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	798	-0.003	-0.006	+0.000	-0.002	-0.000
	Q1 (mas cerca de LP)	B	798	+0.002	-0.008	+0.004	+0.001	-0.000
	Q2	A	798	-0.001	+0.006	+0.006	+0.001	-0.001
	Q2	B	798	-0.001	-0.002	+0.011	+0.001	-0.001
	Q3	A	798	-0.007	-0.008	-0.019	-0.001	-0.002
	Q3	B	798	-0.006	-0.005	-0.000	-0.000	-0.002
	Q4 (mas lejos)	A	797	-0.005	+0.000	-0.022	-0.001	-0.001
	Q4 (mas lejos)	B	797	-0.011	-0.004	-0.011	-0.002	-0.000
Estrato	Estrato 1	A	903	-0.003	-0.001	-0.001	-0.005	-0.002
	Estrato 1	B	903	-0.002	-0.008	+0.018	+0.000	-0.002
	Estrato 2	A	1,390	-0.002	-0.002	-0.005	+0.004	+0.000
	Estrato 2	B	1,390	-0.004	+0.002	+0.004	+0.003	+0.000
	Estrato 3	A	741	-0.003	-0.001	-0.006	+0.000	-0.001
	Estrato 3	B	741	-0.007	-0.016	-0.009	-0.006	-0.001
Proxy de riqueza	Bajo (proxy menos discriminante)	A	1,087	-0.005	-0.009	-0.007	-0.003	-0.003
	Bajo (proxy menos discriminante)	B	1,087	-0.004	-0.009	+0.013	-0.001	-0.003
	Medio	A	1,121	+0.002	+0.002	-0.004	+0.001	+0.001
	Medio	B	1,121	+0.004	-0.004	+0.008	+0.003	+0.001
	Alto (proxy menos discriminante)	A	983	-0.015	-0.005	-0.006	+0.001	-0.001
	Alto (proxy menos discriminante)	B	983	-0.017	-0.009	-0.005	-0.009	+0.000

A.6. Cobertura de covariables por módulo

Complemento de la Sección 3.3: candidatas auditadas, variables finalmente usadas en el modelo y cobertura sobre el panel para cada módulo de la ELCA.

Tabla 24: Cobertura de covariables por módulo en el dataset consolidado

Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (% del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	21	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría (Sección 3.1); “usadas en el modelo” es el subconjunto final tras la construcción de *features* – excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (ver “Bloque de *features* de Hogar”). No incluye llaves de identidad (p. ej. el consecutivo del hogar en Comunidades). Fuente: cálculos propios con base en ELCA 2010, 2013 y 2016.

Complemento de la Sección 3.3.2: desagregado de las 181 variables finales del dataset consolidado por módulo temático y tipo de dato.




Figura 14: Inventario de las 181 variables finales del dataset consolidado, por módulo temático y tipo de dato. Fuente: cálculos propios.

B. Detalles de construcción de variables geoespaciales

Índice

1. Introducción	3
2. Marco conceptual y revisión de literatura	4
2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales	4
2.2. Aprendizaje de máquinas en la predicción de pobreza	6
2.3. Variables geoespaciales como fuente complementaria	7
2.4. Síntesis y vacío que llena este trabajo	8
3. Datos	9
3.1. Encuesta Longitudinal Colombiana (ELCA)	9
3.2. Fuentes geoespaciales	10
3.3. Cobertura, atrición e inventario del panel	12
3.3.1. Composición del panel y atrición	13
3.3.2. Inventario temático de las variables finales	14
4. Estrategia empírica	14
4.1. Construcción de la variable de resultado y dinámica de transiciones	14
4.2. Selección de covariables para el perfil univariado	17
4.3. Especificación de modelos	17
4.4. Validación fuera de muestra y métricas	18
4.5. Tratamiento del desbalance de clases	20
4.6. Importancia de variables e interpretabilidad	22
5. Resultados	22
5.1. Desempeño comparativo de modelos	23
5.1.1. Desempeño de los modelos	23
5.1.2. Análisis de los errores de inclusión y exclusión	25
5.2. Determinantes de la vulnerabilidad: perfil e importancia de variables	27
5.2.1. Perfil univariado de los hogares vulnerables	27
5.2.2. Importancia multivariada de las variables	33
5.3. Contribución marginal de las variables geoespaciales	39
5.3.1. Bajo pobreza monetaria	40
5.3.2. Bajo pobreza multidimensional (IPM)	42
5.3.3. Heterogeneidad del efecto de DMSP-OLS	44

6. Conclusiones	46
6.1. Síntesis de hallazgos	46
6.2. Implicaciones para la política pública	48
6.3. Limitaciones y agenda de investigación	48
Referencias	50
A. Tablas y figuras complementarias	53
A.1. Correlación entre covariables y riesgo de multicolinealidad	53
A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria . . .	55
A.2.1. Incidencia y descomposición FGT	55
A.2.2. Ejercicios de robustez	56
A.3. Perfil completo de covariables, pobreza multidimensional (IPM)	59
A.4. Desempeño de los modelos bajo pobreza multidimensional (IPM)	62
A.5. Heterogeneidad territorial del aporte de DMSP-OLS bajo pobreza monetaria	62
A.6. Cobertura de covariables por módulo	63
B. Detalles de construcción de variables geoespaciales	64