

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal Colombiana (ELCA)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización en Colombia, como el SISBEN, clasifican a los hogares según su situación actual y no anticipan qué hogares no pobres caerán en pobreza. Este trabajo evalúa si variables derivadas de fuentes geospaciales públicas mejoran la predicción de la caída en pobreza, monetaria y multidimensional, frente a modelos basados solo en la Encuesta Longitudinal Colombiana (ELCA). Con las tres olas del panel (2010, 2013 y 2016), se estiman cinco algoritmos de aprendizaje supervisado, con y sin ingreso del hogar, entrenados con las transiciones de 2010 a 2013 y evaluados con las de 2013 a 2016. Los modelos identifican a los hogares vulnerables con una capacidad moderada (AUC-ROC de 0.73 a 0.77) que casi no depende del algoritmo ni del ingreso: un núcleo pequeño de variables de acumulación, como riqueza, educación, activos y vivienda, concentra la señal, y el hogar vulnerable se parece más al que acaba de salir de la pobreza que al que nunca fue pobre. Quienes efectivamente caen reportan más choques posteriores a la predicción, lo que sugiere que parte del riesgo se realiza por eventos que la ola base no puede anticipar. La iluminación nocturna, la única fuente geoespacial con cobertura suficiente, describe bien la geografía de la pobreza, pero no mejora la predicción cuando hay una encuesta vigente; su valor está en priorizar territorios y servir de respaldo entre rondas de encuesta.

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geospaciales, ELCA, focalización, Colombia.

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juarez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Beneficiarios de Programas Sociales (SISBEN) opera a través de una encuesta cuya aplicación depende de la solicitud de los hogares y de los recursos de la entidad territorial responsable, lo que genera rezagos en la actualización de la información y dificulta contar con datos recientes sobre el efecto de choques (Consejo Nacional de Política Económica y Social, 2016). El SISBEN IV busca corregir en parte estas limitaciones: combina el estándar de vida con una presunción de la capacidad de generación de ingresos del hogar y se articula con registros administrativos (Consejo Nacional de Política Económica y Social, 2016). Aun así, clasifica a los hogares según su situación y capacidad actuales, y no estima la probabilidad de que un hogar hoy no pobre caiga en pobreza. La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y un ejercicio reciente de aproximación a la vulnerabilidad monetaria en Bogotá mediante paneles sintéticos confirma tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Gaitán, 2023).

Este artículo aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza, monetaria y multidimensional. Este abordaje se diferencia de la mayor parte de la literatura de aprendizaje de máquinas aplicada a la pobreza, que predice la condición actual de un hogar

y no su transición futura (Ferdausi et al., 2026; Muñetón-Santa et al., 2022).

La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de fuentes geoespaciales públicas mejora la predicción de caída en pobreza de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del hogar reportadas en encuestas?

Para responderla, el documento construye la variable de resultado que es la transición hacia la pobreza, audita las covariables socioeconómicas disponibles en la ELCA y estima cinco algoritmos de aprendizaje supervisado (regresión logística regularizada *Elastic Net*, Random Forest, XGBoost, LightGBM y HistGradientBoosting), en dos especificaciones: con y sin ingreso y gasto del hogar, bajo dos definiciones de pobreza, monetaria y multidimensional. Sobre esos modelos evalúa el aporte de cuatro fuentes geoespaciales públicas: la iluminación nocturna DMSP-OLS, el radar ALOS PALSAR, las imágenes Landsat 5 TM y las fotografías de Google Street View. Solo DMSP-OLS tiene datos en la ola de entrenamiento y en la de prueba, por lo que es la fuente de la evaluación principal; las demás se evalúan de forma exploratoria (Sección 3.2).

Los resultados muestran que los modelos identifican a los hogares vulnerables con una capacidad moderada (AUC-ROC de 0.73 a 0.77), similar entre algoritmos y casi igual sin el ingreso del hogar; que un núcleo pequeño de variables de acumulación concentra la señal, y que el hogar vulnerable se parece más al que acaba de salir de la pobreza que al que nunca fue pobre; además, que quienes efectivamente caen reportan más choques posteriores a la predicción. La iluminación nocturna no mejora la predicción cuando hay una encuesta vigente, porque su información ya está contenida en la encuesta, pero es más estable en el tiempo y su pequeño aporte bajo pobreza multidimensional se concentra en zonas rurales, lo que la hace útil para priorizar territorios y como respaldo entre rondas de encuesta.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema que los trabajos previos sobre vulnerabilidad con la ELCA (Hernández & Zuluaga, 2022) no abordan.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje de máquinas aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla

la estrategia empírica: construcción de la variable de resultado, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados. La Sección 6 cierra con una síntesis, implicaciones de política, las limitaciones y la agenda de investigación.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria se origina en la variabilidad del consumo del hogar ante choques de ingreso, como la enfermedad de un miembro del hogar o la pérdida de una cosecha por plagas, y aumenta con la volatilidad de su patrimonio. Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto para la Kenya rural: en 1994 los hogares enfrentaban en promedio una probabilidad del 39 % de caer en pobreza en el futuro, mayor en las zonas áridas expuestas a la volatilidad de las lluvias, y los choques idiosincráticos también generaban una volatilidad importante del consumo. Los hogares hoy no pobres pero expuestos a esos choques son precisamente los que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este

trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. En la práctica, ese enfoque clasifica como vulnerable a un hogar cuando dicha probabilidad supera 0.5, un umbral arbitrario cuya capacidad para anticipar la pobreza observada se ha evaluado poco; Hohberg et al. (2018) la evalúan con curvas ROC en un panel alemán y muestran que un umbral elegido según el objetivo de focalización predice mejor. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010).

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juarez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 4.1 de este artículo. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado de pobreza.

En Colombia, la ausencia de un panel de hogares ha llevado a usar pseudo-paneles, tanto para estudiar trampas de pobreza (Castañeda Castrillón, 2012) como para aproximar la vulnerabilidad (Gaitán, 2023); Gaitán (2023) estima que cerca del 23 % de la población bogotana era vulnerable en 2021. La ELCA, con tres olas de seguimiento a los mismos hogares, permite superar esa limitación. Con la misma ELCA, Hernández y Zuluaga (2022) estiman la vulnerabilidad a la pobreza multidimensional con el enfoque de pobreza esperada de Chaudhuri et al. (2002) y encuentran que la proporción de hogares vulnerables supera la de pobres, sobre todo en zona rural (70 % frente a 39 %). Este artículo se diferencia en que no infiere la vulnerabilidad de la media y la varianza esperadas del bienestar, sino que predice la transición observada con modelos validados fuera de muestra. Aun así, estos métodos dependen de encuestas detalladas, costosas y de levantamiento infrecuente, lo que motiva explorar fuentes alternativas de datos (Sección 2.3).

2.2. Aprendizaje de máquinas en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo*

de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su desarrollo ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar sustancialmente la exactitud fuera de muestra de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando su criterio de exactitud balanceada (BPAC) hasta en 17.5 % frente a los métodos tradicionales. Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2026) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema: sus modelos alcanzan una exactitud del 96 % e identifican siete variables como los principales factores de la pobreza extrema. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza a la mayor parte de la literatura. En Colombia, Muñetón-Santa et al. (2022) han aplicado aprendizaje de máquinas a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada. Una excepción es Burger y van der Laan (2021), que predicen con *gradient boosting* la entrada y la salida de la pobreza al año siguiente a partir de más de 500 variables de registros administrativos de los Países Bajos, y usan valores SHAP para identificar los factores de riesgo; entre los hogares no pobres, el más importante es la

propiedad de la vivienda. Ese ejercicio se hace en un país de ingreso alto, con registros administrativos completos y sin fuentes geoespaciales, condiciones muy distintas a las de un país en desarrollo que depende de encuestas.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital: en cinco países africanos, una red neuronal entrenada con imágenes satelitales diurnas, luz nocturna y datos de encuesta explica hasta el 75 % de la variación local del consumo o la riqueza, y predice mejor que la luz nocturna sola. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con exactitudes globales superiores al 82 %. Sin embargo, en regiones pobres y rurales la luz nocturna rinde menos que las imágenes diurnas, porque varía poco entre zonas (Hall et al., 2023).

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran, para un programa de transferencias de emergencia en Togo, que un modelo de aprendizaje de máquinas entrenado con datos de telefonía móvil reduce los errores de exclusión entre 4 % y 21 % frente a la focalización geográfica, aunque los aumenta frente a un registro social completo. Hall et al. (2023), en una revisión sistemática, documentan que el número de fuentes de datos está entre los factores más asociados con el poder predictivo y que combinar aprendizaje automático y profundo lo aumenta hasta en 15 puntos porcentuales; también encuentran que los estudios que predicen activos físicos superan en 17 puntos a los que predicen variables de flujo como ingreso o consumo, y que el desempeño depende del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que este artículo busca incorporar (Sección 3.2).

Esta evidencia sugiere que combinar variables geoespaciales con encuestas puede mejorar lo que cada fuente logra por separado, sobre todo donde la encuesta es escasa. Sin embargo,

ninguno de estos trabajos, ni los pocos que predicen la entrada en pobreza (Burger & van der Laan, 2021; Hohberg et al., 2018), evalúa si las fuentes geoespaciales públicas mejoran esa predicción en un país en desarrollo, con datos longitudinales de encuesta y una partición temporal hacia adelante, un problema que exige una variable de resultado prospectiva, un horizonte explícito entre olas y predictores medidos antes de la transición. Este trabajo busca llenar ese vacío desde un enfoque predictivo y no causal: en política pública la predicción es valiosa aun sin interpretación causal (Kleinberg et al., 2015), porque el objetivo es mejorar la focalización *ex ante*.

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCA)

La fuente primaria de datos es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares en tres olas: 2010, 2013 y 2016, en zonas urbana y rural. La ELCA se organiza en módulos temáticos: hogar, personas, niños, comunidades y choques, además de los módulos de activos y gasto. Existen dos olas más, de 2019 y 2022, administradas por el DANE, que no se incluyen en este análisis y quedan como extensión para trabajo futuro. Para los análisis realizados en este estudio, se excluyeron los hogares que se dividieron en dos o más sub-hogares en olas subsecuentes (511 casos entre 2010–2013 y 1,190 entre 2013–2016), para no hacer supuestos sobre estos hogares en el tiempo.

Antes de construir las covariables se auditaron sistemáticamente los módulos de la encuesta (codificación de caracteres, cobertura por ola, columnas renombradas y preguntas filtro; Anexo A.10). El resultado es un panel hogar×ola de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas, que combina las covariables de los módulos con las variables monetarias (ingreso y gasto per cápita, nominal y real, y brecha frente a la línea de pobreza).

3.2. Fuentes geoespaciales

Este trabajo utiliza información geoespacial pública y gratuita, bajo el supuesto de que captura características del entorno físico y económico local que las encuestas no reflejan por completo, pero que afectan la vulnerabilidad del hogar: la actividad económica y la electrificación del entorno (luces nocturnas), la densidad del área construida frente a la vegetación (radar y reflectancia óptica) y si el entorno se venía densificando o perdiendo cobertura vegetal antes de cada ola (Tabla 33, Anexo B.1). A partir de las coordenadas de los hogares de la ELCA, de acceso restringido y controlado por la Universidad de los

Andes, la información se consulta en Google Earth Engine y se anexa a cada hogar.

Como los modelos se entrenan en 2010→2013 y se evalúan en 2013→2016, cada fuente necesita datos en 2010 y en 2013. De las siete fuentes evaluadas (Anexo B.2), solo tres tienen cobertura anterior a 2014: DMSP-OLS, ALOS PALSAR y Landsat 5 TM. Sentinel-1, Sentinel-2 y VIIRS DNB empezaron a operar después de 2012, y OpenStreetMap estaba casi vacío en Colombia en 2010–2013. DMSP-OLS cubre el 100 % de los hogares en 2010 y en 2013. ALOS PALSAR cubre 2010, pero no tiene datos entre 2011 y 2014. Landsat 5 TM cubre solo el 65.5 % de los hogares en 2010, por nubosidad, y dejó de adquirir imágenes útiles antes de 2013. Por eso DMSP-OLS es la fuente de la evaluación principal. Google Street View se evaluó solo de forma exploratoria: no hay fotos anteriores a 2012 y el 61 % son posteriores a 2023 (Anexo A.9).

3.3. Cobertura, atrición e inventario del panel

Los módulos de Hogar, Personas y Choques cubren todo el panel; Comunidades cubre entre 92 y 96 %, porque se mide por comunidad y no por hogar, y Niños el 55.4 %, la proporción de hogares con niños de 6 a 9 años (Anexo A.10). El panel pierde 11.4 % de los hogares entre 2010 y 2013 y otro 11.4 % entre 2013 y 2016 (17.9 % acumulado). La atrición no es aleatoria: se concentra en hogares urbanos (16.2 % frente a 5.8 % de los rurales en 2010–2013) y de estratos altos (Anexo A.11).

Las covariables finales suman 177 variables: 164 de los módulos auditados y 13 monetarias (detalle por módulo, tipo y tema en el Anexo A.10). El Modelo A usa 169 y el Modelo B, sin ingreso ni gasto, 165 (Sección 4.3). En ambos se descartan los indicadores y líneas de pobreza y el ingreso y gasto nominales, porque definen la variable de resultado. Sobre cada especificación se evalúa el aporte geoespacial en dos variantes. La principal agrega las 23 variables de DMSP-OLS, la única fuente con datos en 2010 y 2013, y se evalúa en 2013→2016 (Sección 5.3). La segunda agrega las 127 variables de las tres fuentes (23 de DMSP-OLS, 52 de ALOS PALSAR y 52 de Landsat 5 TM) y, como las dos últimas solo tienen datos en 2010, se evalúa con validación cruzada dentro de 2010→2013 (Tabla 33, Anexo B.1).

3.4. Dinámica de la pobreza en el panel

Esta sección describe los cuatro grupos de la matriz de transición (*nunca pobre, siempre pobre, entra en pobreza y sale de pobreza*), definidos en la Sección 4.1.¹

¹Para establecer la robustez de las estimaciones de pobreza monetaria y sus clasificaciones, se realizó un análisis adicional de la incidencia agregada, FGT, y cinco ejercicios de estimaciones, incluyendo la atrición del panel por perfil de hogar, que se documentan en el Apéndice A.2




Figura 1: Transición de pobreza entre categorías de López-Calva y Ortiz-Juarez (2014), panel emparejado 1 a 1 (mismo universo para monetaria e IPM; excluye 511 hogares que se dividieron entre olas en 2010–2013 y 1,190 en 2013–2016). Arriba: pobreza monetaria por ingreso; abajo: pobreza multidimensional (IPM).

Bajo pobreza monetaria la persistencia es alta pero decrece: 70.3 % de los pobres en 2010 seguían pobres en 2013, cae a 61.8 % entre 2013 y 2016 (la salida condicional a no ser pobre sube de 29.7 % a 38.2 %); la persistencia en la no-pobreza mejora de 76.6 % a 80.1 %. Bajo IPM entrar es menos frecuente (12.1 % y 9.7 %, frente a 23.4 % y 19.9 % en monetaria) y salir es más frecuente (54.5 % y 52.3 %, frente a 29.7 % y 38.2 %), por lo que la persistencia en la pobreza es menor (45.5 % y 47.7 %, frente a 70.3 % y 61.8 %). La baja entrada es coherente con que el IPM mide privaciones estructurales (educación, materiales

de la vivienda, acceso a servicios) que, una vez superadas, rara vez se revierten, a diferencia del ingreso corriente. La alta salida debe leerse con cautela en 2010→2013, porque coincide con un cambio en la medición del indicador de barreras de acceso a salud (Sección 6.3); que se mantenga en 2013→2016, donde ese indicador se mide igual, sugiere que no solo se debe a la medición. Los paneles superiores de la Figura 1 traducen la matriz monetaria a flujos (los inferiores hacen lo mismo con la del IPM): en 2010–2013 dominan los *siempre pobres* (43.9 %) sobre los *nunca pobres* (28.8 %); en 2013–2016 el orden se invierte (37.0 % vs. 33.3 %), y en ambos periodos la salida casi duplica la entrada, es decir, la pobreza monetaria se redujo de forma neta, no solo se redistribuyó entre hogares.

Un último ejercicio (Tabla 1) sigue a los mismos hogares no pobres en la ola base a lo largo de las tres olas para distinguir, dentro de quienes *entran* en pobreza, una entrada transitoria de una persistente. Bajo pobreza monetaria, 24.1 % de los no pobres en 2010 entra en pobreza en algún momento: 14.0 % salen de nuevo antes de 2016 (“transitorio”) y 10.1 % se quedan (“persistente”). Bajo IPM la entrada total es menor (12.2 %) y se reparte parecido (8.2 transitoria, 4.0 persistente): en ambas definiciones, más de la mitad de quienes entran en pobreza no quedan atrapados dentro de la ventana de seis años observada.

Tabla 1: Trayectorias a 3 olas (2010→2013→2016) de hogares NO pobres en 2010, panel emparejado 1 a 1, monetaria vs. IPM.

Trayectoria	Monetaria		IPM	
	n	%	n	%
Nunca cae	1,700	67.2 %	4,381	81.2 %
Cae tarde (solo en 2016)	220	8.7 %	357	6.6 %
Entra y sale (transitorio)	355	14.0 %	445	8.2 %
Entra y se queda (persistente)	255	10.1 %	214	4.0 %

Nota: $n=2,530$ hogares no pobres en 2010 bajo pobreza monetaria; $n=5,397$ bajo IPM (universos distintos porque no-pobre-monetaria y no-pobre-IPM en 2010 no son el mismo conjunto de hogares). % sobre ese universo, sin ponderar. Fuente: cálculos propios.

4. Estrategia empírica

4.1. Construcción de la variable de resultado

Este estudio sigue la metodología de López-Calva y Ortiz-Juarez (2011, 2014), a partir de la cual se construyen matrices de transición de pobreza monetaria e IPM, cruzando el estado de un hogar en el período inicial t (filas), contra un periodo posterior $t + 1$ (columnas). Esta comparación permite observar cómo evoluciona la situación económica de los hogares a lo largo del tiempo y generar una taxonomía de cuatro categorías de acuerdo

con la clasificación en dos momentos del tiempo: *nunca pobre*, *siempre pobre*, *entra en pobreza* y *sale de pobreza*.

Ahora bien, la pobreza monetaria en este trabajo se estima a partir del cálculo del ingreso per cápita del hogar, de acuerdo con las preguntas correspondientes en la ELCA, y se compara contra la línea de pobreza (LP) oficial del DANE, específica por año y zona². De otro lado, este estudio utiliza un proxy del Índice de Pobreza Multidimensional (IPM) que se construye siguiendo la metodología oficial del DANE (Angulo Salazar et al., 2011), de cinco dimensiones (educación; niñez y juventud; trabajo; salud; vivienda y servicios públicos) y quince indicadores ponderados (20 % por dimensión, peso igual entre los indicadores de cada dimensión) y un punto de corte de pobreza de 33.3 % del puntaje ponderado.³

Los modelos predictivos de este estudio (Secciones 4.3 en adelante) se estiman sobre los hogares no pobres en t (los grupos *nunca pobre* y *entra en pobreza*) y predicen si caen en pobreza en $t + 1$, de acuerdo con la definición de vulnerabilidad (Ecuación 1):

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

Conviene precisar la terminología. En el sentido de Chaudhuri et al. (2002), la vulnerabilidad es una probabilidad *ex ante*; en este artículo corresponde a la probabilidad predicha por los modelos, $\hat{P}(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it})$. La entrada efectiva en pobreza es su realización observada, que se usa para entrenar y evaluar esos modelos. Por brevedad, el texto llama *hogares vulnerables* a los que efectivamente entran en pobreza, entendiendo que son la realización del riesgo y que otros hogares con una probabilidad predicha igual de alta no llegaron a caer.

Como diagnóstico complementario se estima además un modelo multiclase sobre los cuatro grupos de la matriz de transición, sin ingreso ni gasto, que permite comprobar si quienes entran en pobreza se distinguen de quienes salen, algo que el modelo binario

²Se usa la serie MESEP (línea base ENIG 2006–2007, actualizada anualmente por IPC), la misma metodología para las tres olas (2010, 2013 y 2016), lo que las hace comparables entre sí. Deliberadamente no se usa la actualización metodológica ENPH 2016–2017 con la que el DANE recalculó la serie 2012–2018, porque esa serie no cubre 2010 y adoptarla habría introducido una inconsistencia metodológica justo entre las olas que este estudio compara.

³Es un proxy porque cinco de los quince indicadores se excluyen del puntaje final por huecos de cobertura en la ola 2010 del panel: privación en primera infancia (no medible de forma consistente en ninguna ola); inasistencia escolar y trabajo infantil (**estudia/actividad_ppal** en niños con 0.4 %–35.3 % de cobertura en 2010, frente a 100 % en 2013/2016); y empleo informal y desempleo de larga duración (**actividad_ppal** en adultos con 20 % de cobertura en 2010, frente a 75–80 % en 2013/2016). Se calculan y reportan para auditoría, pero no entran en la clasificación **pobre_ipm**. Quedan diez indicadores activos; la dimensión Trabajo, que queda sin indicadores, redistribuye su 20 % entre las cuatro dimensiones restantes (25 % cada una). El punto de corte de pobreza se mantiene en 33.3 % del puntaje ponderado, independiente del número de indicadores activos.

no puede responder (Sección 5.2). No es el modelo principal, porque la pregunta de vulnerabilidad se refiere solo a los hogares hoy no pobres. Su especificación completa y sus resultados se reportan en el Apéndice A.13.

4.2. Metodología de caracterización de los hogares vulnerables

Para caracterizar a los hogares vulnerables se combinan dos análisis. El principal usa los modelos de la Sección 4.3 para identificar qué variables anticipan la entrada en pobreza. El segundo compara directamente las covariables de los cuatro grupos de la matriz de transición: comprueba qué tan bien esas variables separan a los grupos en los datos y permite ubicar al hogar vulnerable (*entra en pobreza*) respecto a los tres restantes, incluyendo a los que ya eran pobres, que los modelos no incluyen.

En el primer análisis se usan valores SHAP, que miden cuánto sube o baja cada variable la probabilidad predicha para cada hogar, con la ventaja de que se miden en la misma escala para los cinco algoritmos. Se calculan para los Modelos A y B (con y sin ingreso y gasto, Sección 4.3), lo que da diez combinaciones de algoritmo y especificación, en las dos definiciones de pobreza y en las dos ventanas. De ahí salen dos resultados. El *núcleo* son las variables que, en al menos cinco de las diez combinaciones, están entre las que suman el 80 % de la importancia total. La *dirección* indica si valores altos de una variable suben o bajan el riesgo, y se mide con la correlación de Spearman entre la variable y su valor SHAP. Se considera que la dirección de una variable es estable si su signo se mantiene en las dos definiciones de pobreza y en las dos ventanas. Ambos criterios se prueban con umbrales alternativos en el Apéndice A.3 para validar los resultados.

En el segundo análisis se mide, para cada variable, qué tan bien distingue a los cuatro grupos, con una medida entre 0 y 1. Para las variables numéricas es el η^2 de un análisis de varianza (ANOVA) de una vía sobre los rangos de la variable, equivalente no paramétrico que no se deja arrastrar por valores extremos. En otras palabras, la proporción de su variación que explica el grupo. Para las categóricas es la V de Cramér, basada en la prueba chi-cuadrado de independencia. Ambas se ponderan por los factores de expansión. Una variable entra al perfil si su medida supera 0.10 (o 0.05 en las dos ventanas, bajo pobreza monetaria) y si el resultado se sostiene en 300 remuestreos *bootstrap*, para descartar que la diferencia entre grupos se deba al azar de la muestra. Así quedan 53 variables bajo pobreza monetaria y 36 bajo IPM.

Los dos análisis se combinan de la siguiente manera. El análisis SHAP decide qué variables se reportan como determinantes: las del núcleo cuya dirección es estable. El análisis univariado no agrega variables a esa lista, sino que sirve para dos cosas. La primera es confirmar el resultado de SHAP sin usar ningún modelo. SHAP muestra en qué variables

se apoyan los modelos para predecir, pero un modelo puede apoyarse en una variable por razones propias de cómo se ajusta, por ejemplo, porque está correlacionada con otra. El análisis univariado compara directamente los valores de esas variables entre los cuatro grupos: si estas también muestran diferencias claras entre los grupos, la importancia de variables según SHAP no depende de la estructura de los modelos de predicción. La segunda es de comparación: como los modelos solo incluyen hogares que no eran pobres, no pueden decir a qué grupo se parece el hogar vulnerable, en particular si se parece más a quienes salen de la pobreza o a quienes nunca fueron pobres; el análisis univariado sí puede, porque incluye a los cuatro grupos.

Finalmente, dos ejercicios completan el análisis: se separa a los hogares que entran en pobreza según sigan o no pobres en 2016 (transitorios y persistentes), y el modelo multiclase descrito en la Sección 4.1 mide si es posible distinguir a quienes entran de quienes salen de la pobreza.

4.3. Especificación de modelos

La estrategia empírica se establece mediante la siguiente especificación de modelo:

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1), incluyendo las variables geoespaciales complementarias, y $F(\cdot)$ es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se estiman y comparan cinco algoritmos: una regresión logística regularizada (*elastic net*), cuya fuerza y mezcla de penalización se eligen por validación cruzada y que sirve de referencia por ser interpretable; Random Forest, que McBride y Nichols (2018) emplean para mejorar la focalización fuera de muestra; y tres implementaciones de *gradient boosting* (XGBoost, LightGBM y HistGradientBoosting), que manejan de forma nativa los datos faltantes y las variables categóricas (descripción detallada en el Anexo A.14). El riesgo de multicolinealidad, relevante sobre todo para la regresión logística, se analiza en el Apéndice A.1.

Para evaluar el aporte del nivel de ingreso/gasto del hogar, el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, se estima cada uno de los cinco algoritmos bajo dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante (se mantiene constante a lo largo del tiempo); el **Modelo B** excluye estas cuatro variables y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda,

choques, comunidad).

Finalmente, se establecieron dos variables objetivo para evaluar la robustez de los hallazgos: la transición hacia la pobreza monetaria y la transición hacia la pobreza multidimensional bajo el proxy de IPM.

4.4. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, en el que solo existe la ola base al momento de predecir. Es además más exigente que la validación cruzada aleatoria que recomiendan McBride y Nichols (2018), quienes advierten que esta supone que el proceso generador de los datos no cambia entre el desarrollo y la aplicación de la herramienta; la partición temporal pone a prueba ese supuesto, porque evalúa el modelo en un periodo económico distinto al de entrenamiento.

Dentro del periodo de entrenamiento (2010 a 2013), los hiperparámetros de cada algoritmo, como la profundidad de los árboles o la tasa de aprendizaje, no se fijan a mano, sino que se eligen con una búsqueda aleatoria (*randomized search*). Se prueban 30 combinaciones elegidas al azar dentro de un rango razonable para cada hiperparámetro, en lugar de todas las combinaciones posibles (*grid search*), cuyo costo de cómputo habría sido prohibitivo para 5 algoritmos, 4 especificaciones, 3 estrategias de balanceo (Sección 4.5) y dos variables objetivo. Cada combinación se evalúa con validación cruzada estratificada de 10 particiones: el conjunto de entrenamiento se divide en 10 bloques que conservan la proporción de hogares que entran en pobreza, se entrena 10 veces dejando por fuera un bloque distinto y se evalúa sobre él. Promediar las 10 evaluaciones castiga a las combinaciones que memorizan particularidades de los datos en vez de aprender un patrón que generaliza. Los hiperparámetros elegidos para cada uno de los modelos reportados se presentan en la Tabla 32 del Anexo A.14.

Para verificar que 30 iteraciones no se quedan cortas, se extendió la búsqueda a 50 iteraciones para el caso más ambiguo de la comparación de balanceo (HistGradientBoosting-A, Sección 4.5): el mejor puntaje acumulado ya no mejora entre las iteraciones 20 y 40 (0.7603 en ambas), y gana solo 0.0006 adicional hacia la iteración 50 –evidencia de que la búsqueda con 30 iteraciones ya opera cerca de su techo para este caso, no de que se haya interrumpido prematuramente.

La métrica que decide qué combinación gana esa búsqueda es el AUC-ROC: la proba-

bilidad de que, al tomar al azar un hogar que entra en pobreza y uno que no, el modelo le asigne más riesgo al primero (0.5 equivale a adivinar al azar y 1 a ordenar a todos los hogares correctamente). Es apropiada porque lo que se busca es un modelo que ordene bien a los hogares según su riesgo, y el AUC-ROC mide justamente eso, sin depender del umbral a partir del cual se clasifica a un hogar como vulnerable, que se elige después (Sección 4.5).

El AUC-ROC es la métrica principal, pero con clases desbalanceadas puede dar una imagen optimista: premia una tasa *relativa* baja de falsos positivos, que puede esconder un número *absoluto* alto de falsos positivos cuando los hogares que entran en pobreza son pocos (Davis & Goadrich, 2006; Saito & Rehmsmeier, 2015). Esto no lo invalida como medida de ordenamiento, pero sí limita lo que dice, por sí solo, sobre la utilidad del modelo para una política con cobertura limitada. Por eso se reportan también el *recall*, la precisión y el F1 al umbral de clasificación elegido con F_2 (Sección 4.5), junto con la matriz de confusión completa; el F1 se incluye por ser la referencia más usada en la literatura, aunque no es el criterio que fija el umbral. El *recall* es la fracción de los hogares que efectivamente entran en pobreza que el modelo marca como en riesgo (cuánta de la pobreza futura se captura), y la precisión es la fracción de los hogares marcados que efectivamente entran (cuántas de las alertas son acertadas). Ambas dependen del umbral y se mueven en direcciones opuestas: con un mismo modelo, bajar el umbral sube el *recall* a costa de la precisión, y viceversa. El umbral solo elige un punto dentro de lo que la capacidad de ordenamiento del modelo, medida por su AUC-ROC, permite. Además, se reporta la precisión en el decil de mayor riesgo, que no depende de un umbral de clasificación y responde directamente la pregunta de un programa con presupuesto limitado: si solo puede atender al 10 % de los hogares que el modelo considera de mayor riesgo, ¿qué proporción de ellos efectivamente entra en pobreza?

El análisis se centra en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo: como se documenta en la Sección 5.1, las diferencias de AUC-ROC entre modelos son pequeñas frente a la variabilidad esperable por la aleatoriedad del ajuste.

4.5. Tratamiento del desbalance de clases y de los datos faltantes

Los datos faltantes de las covariables reciben un único tratamiento, que depende del algoritmo, y no se elimina ningún hogar por tenerlos. La regresión logística y Random Forest no aceptan valores faltantes: como en la ELCA provienen sobre todo de preguntas filtro (por ejemplo, el monto de una ayuda no se pregunta a quien no recibió ninguna), se rellenan con 0 y se agrega un indicador de faltante por variable, en vez de la mediana, que asignaría a esos hogares un valor típico que no tienen; las variables categóricas reciben la

categoría “Sin dato”. XGBoost, LightGBM y HistGradientBoosting los manejan de forma nativa, sin imputación.

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4 % (Figura 1a), un desbalance que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.⁴

Con clases desbalanceadas, las probabilidades predichas tienden a concentrarse en valores bajos, de modo que el umbral convencional de 0.5 clasifica a muy pocos hogares como vulnerables. Por eso el umbral de cada modelo también se elige por validación cruzada: sobre las probabilidades *out-of-fold* se prueba una grilla de umbrales entre 0.02 y 0.98 y se elige el que maximiza F_2 . A diferencia del F_1 , que pesa igual el *recall* y la precisión, F_2 pesa el doble el *recall*, porque en focalización dejar sin detectar a un hogar que entrará en pobreza es más costoso que incluir a uno que no caerá. El umbral no cambia el modelo ni su AUC-ROC; solo determina cómo se reportan el *recall*, la precisión y el F_1 .

5. Resultados

Los resultados se presentan en tres partes comenzando por los aspectos más generales de los modelos y los perfiles de vulnerabilidad para abordar luego propiamente la pregunta de investigación de este estudio. La Sección 5.1 compara el desempeño fuera de muestra de los cinco algoritmos bajo las especificaciones A y B (con y sin ingreso/gasto) del hogar y analiza los errores de inclusión y exclusión de los modelos. La Sección 5.2 caracteriza a los hogares vulnerables a partir de los valores SHAP de esos modelos y usa el perfil univariado de los cuatro grupos de la matriz de transición como validación y para estudiar lo que el análisis multivariado no permite: comparar simultáneamente los perfiles de los cuatro grupos. La Sección 5.3 analiza el efecto de las variables provenientes de fuentes geoespaciales públicas y evalúa si agregar DMSP-OLS mejora esa predicción, bajo pobreza

⁴No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La elección de la estrategia de balanceo es sensible al azar del particionado: para HistGradientBoosting con el Modelo A, repetir la comparación con cinco semillas distintas cambia la estrategia ganadora en tres de ellas, con diferencias de AUC-ROC entre estrategias de entre 0.001 y 0.004 dentro de cada semilla. Se usa siempre la semilla fijada de antemano (42); las diferencias entre estrategias están dentro del ruido del particionado.

monetaria e IPM (Secciones 5.3.1 y 5.3.2) y si ese efecto es igual en la población o se concentra en subgrupos específicos (Sección 5.3.2).

5.1. Desempeño comparativo de modelos

5.1.1. Desempeño de los modelos

La Tabla 2 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.4 y 4.5; la estrategia de balanceo y los hiperparámetros elegidos para cada modelo se reportan en el Anexo A.14).

Tabla 2: Desempeño de los cinco algoritmos en el conjunto de prueba (2013→2016), promedio de 5 semillas. Prec.-top10: precisión en el 10 % de hogares con mayor riesgo predicho; Rec.-top10: fracción de los hogares que entran en pobreza que queda dentro de ese 10 %.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precision	Prec.-top10	Rec.-top10	F1
XGBoost	A	0.11	0.767	0.949	0.264	0.505	0.254	0.413
Random Forest	A	0.14	0.766	0.926	0.277	0.486	0.245	0.426
HistGradientBoosting	A	0.32	0.763	0.909	0.283	0.512	0.258	0.432
LightGBM	A	0.10	0.758	0.903	0.281	0.516	0.260	0.428
Logística regularizada	A	0.37	0.747	0.883	0.280	0.506	0.255	0.426
Random Forest	B	0.31	0.742	0.892	0.272	0.508	0.256	0.416
XGBoost	B	0.13	0.742	0.940	0.250	0.495	0.249	0.395
Logística regularizada	B	0.35	0.739	0.890	0.270	0.500	0.252	0.414
HistGradientBoosting	B	0.14	0.735	0.879	0.275	0.494	0.249	0.418
LightGBM	B	0.15	0.731	0.909	0.259	0.487	0.246	0.403

Frente al desempeño de los modelos se encontraron dos hallazgos. **Primero**, el algoritmo elegido no cambia el poder de discriminación de los vulnerables (AUC-ROC 0.731–0.767 en los cinco). Bajo IPM ocurre lo mismo, en un rango de AUC-ROC igual de estrecho (0.725–0.747; Tabla 19, Apéndice A.5). Un AUC-ROC de 0.75 significa que, si se toma al azar un hogar que entra en pobreza y uno que no, el modelo correctamente asigna mayor riesgo al primero solo 3 de cada 4 veces. Es un desempeño moderado frente a los pocos trabajos que evalúan la predicción de la entrada en pobreza. Con registros administrativos de los Países Bajos, más de 500 variables y un horizonte de un año, Burger y van der Laan (2021) obtienen un AUC normalizado de 0.90 (donde 0 equivale al azar y 1 a una clasificación perfecta), y con el panel alemán SOEP, Hohberg et al. (2018) identifican al 80 % de quienes caen al año siguiente con menos de 20 % de falsos positivos en la mayoría de los años, proporción que sube a cerca de 30 % con un horizonte de tres años. Aquí la predicción se hace a tres años y con una encuesta, no con registros administrativos, lo que hace esperable

un techo más bajo. Que incluso la regresión logística regularizada, el algoritmo más simple, quede cerca de los demás (prácticamente igual sin ingreso (0.739 frente a 0.742) y 0.02 por debajo con ingreso) y que los algoritmos de *boosting* elijan árboles poco profundos (profundidad 3 o 4) sugiere que las interacciones complejas entre variables aportan poco. El límite al desempeño parece estar en la información que contienen las covariables más que en la forma del modelo, lo que no implica afirmar ausencia de efectos no lineales, sino que modelarlos aporta poco a la discriminación. Lo que sí varía es la dirección de algunas variables según la definición de pobreza: la edad del jefe de hogar, por ejemplo, se asocia con menor riesgo bajo pobreza monetaria y con mayor riesgo bajo IPM (Sección 5.2).

Segundo, la capacidad de identificar vulnerables apenas cambia si se excluyen las variables de ingreso/gasto del hogar de las covariables que se utilizan en los modelos. La ganancia de incluir esa información, que es la más cara de levantar mediante encuesta, y la menos confiable, es marginal (brecha de AUC de 0.008 a 0.028 entre el Modelo A y B). La brecha es pequeña si se considera que, en el enfoque de Chaudhuri et al. (2002), la vulnerabilidad se deriva directamente de la media y la varianza esperadas del consumo. Esto no implica que el ingreso no importe (Sección 5.2), sino que su contenido informativo ya está sustancialmente capturado por otras variables del núcleo del perfil (Ej. Riqueza, educación, bienes durables Sección 5.2). Este resultado es coherente con dos líneas de la literatura. López-Calva y Ortiz-Juarez (2014) interpretan el ingreso observado como una medida resumen de los activos del hogar y, por eso, construyen un ingreso permanente a partir de esos activos y de características socioeconómicas; y los *proxy means tests* descansan en que un conjunto de características del hogar fáciles de verificar aproxima su bienestar sin medir el ingreso (McBride & Nichols, 2018). Bajo IPM la brecha es aún menor, y para Random Forest y XGBoost es negativa (el Modelo B (sin ingreso/gasto) supera al A), lo que descarta que la pequeña brecha en la capacidad discriminante de los modelos bajo la definición de pobreza monetaria se deba a la relación entre ingreso y la definición de pobreza. La implicación práctica sería mantener la estrategia de focalizar mediante el ingreso/gasto del hogar, pero cuando no sea posible obtener esa información, se encuentre desactualizada o poco confiable, se podría utilizar un instrumento alternativo y confiable: las mismas variables que ofrece la encuesta. Con un particular énfasis en las variables del núcleo del perfil (Sección 5.2), que son las que más contribuyen a la predicción de vulnerabilidad.

5.1.2. Análisis de los errores de inclusión y exclusión

Frente a los errores de inclusión y exclusión se encontraron tres hallazgos más. **Tercero**, un programa que no quiera dejar por fuera a los hogares vulnerables tendrá que atender a muchos que no lo necesitan, y cambiar de algoritmo o de umbral no lo evita sin dejar

por fuera a más hogares vulnerables; lo que sí mejora su eficiencia sería concentrarse en el 10 % de hogares con mayor riesgo, a costa de cobertura. Con los datos disponibles para este estudio y de acuerdo con los modelos utilizados, se encontró que con cualquiera de estos, una política pública para la vulnerabilidad atendería entre 2.4 y 3.1 hogares no vulnerables por cada hogar vulnerable identificado (Tabla 3). Asimismo, los modelos descartan correctamente los hogares no vulnerables solo entre el 26 % (XGBoost) y el 47 % (LightGBM). En términos de la Tabla 2, el *recall* es alto (0.88–0.95: casi todos los hogares verdaderamente vulnerables quedan marcados) y la precisión baja (0.25–0.28: uno de cada cuatro marcados como vulnerables lo es).

El umbral elegido por F_2 , que da el doble de peso a no dejar sin detectar a hogares verdaderamente vulnerables que a marcar de más a hogares que no caen, decide en qué punto de ese intercambio se ubica el modelo; pero con un AUC-ROC de 0.75 no es posible tener *recall* y precisión altos a la vez. Es el intercambio que la literatura de focalización llama errores de inclusión y de exclusión (*Type E* y *Type F*, Cornia y Stewart (1993)): para un instrumento dado, reducir uno aumenta el otro, y solo un instrumento con mayor poder de discriminación puede mover esa frontera. Por eso Hohberg et al. (2018) proponen elegir el umbral según el objetivo de focalización y no fijarlo en una probabilidad de 0.5: privilegiar la identificación de quienes caerán conduce a programas más amplios, y minimizar el total de errores, a programas más acotados. El umbral elegido por F_2 y el decil de mayor riesgo corresponden a esas dos opciones. En cambio, en el decil de mayor riesgo la precisión (0.49–0.52) casi duplica la del umbral completo: uno de cada dos hogares atendidos efectivamente cae. El costo es la cobertura: ese decil contiene solo entre el 25 % y el 26 % de los hogares vulnerables (Tabla 2), de modo que un programa así llegaría a uno de cada cuatro vulnerables.

Tabla 3: Matriz de confusión del Modelo A en el conjunto de prueba (2013→2016), pobreza monetaria e IPM.

Algoritmo	Monetaria				IPM			
	VP	FP	FN	VN	VP	FP	FN	VN
XGBoost	617 (19 %)	1888 (59 %)	18 (1 %)	668 (21 %)	491 (9 %)	3297 (59 %)	51 (1 %)	1732 (31 %)
Random Forest	594 (19 %)	1572 (49 %)	41 (1 %)	984 (31 %)	343 (6 %)	1493 (27 %)	199 (4 %)	3536 (63 %)
HistGradientBoosting	584 (18 %)	1532 (48 %)	51 (2 %)	1024 (32 %)	301 (5 %)	1124 (20 %)	241 (4 %)	3905 (70 %)
LightGBM	561 (18 %)	1354 (42 %)	74 (2 %)	1202 (38 %)	415 (7 %)	2052 (37 %)	127 (2 %)	2977 (53 %)
Logística regularizada	561 (18 %)	1444 (45 %)	74 (2 %)	1112 (35 %)	379 (7 %)	1862 (33 %)	163 (3 %)	3167 (57 %)

Nota: VP, FP, FN y VN: hogares verdadero positivo, falso positivo, falso negativo y verdadero negativo. Entre paréntesis, porcentaje sobre el total de la fila para cada definición de pobreza (monetaria, $n = 3,191$; IPM, $n = 5,571$). Modelos clasificados con los hiperparámetros y el umbral reportados en la Tabla 32 del Anexo A.14. La matriz del Modelo B se reporta en la Tabla 29 del Anexo A.12. Corresponde a una sola corrida de cada modelo, por lo que el *recall* y la precisión que se derivan de ella difieren levemente de los promedios de 5 semillas de la Tabla 2. Fuente: cálculos propios.

Cuarto, los falsos positivos no son errores aleatorios, son hogares que no cayeron en pobreza, pero cuya situación en la ola base es mucho más precaria que la de los hogares que el modelo acierta en no marcar. Para verlo, se compararon los hogares que los modelos marcan como vulnerables pero no caen en pobreza (falsos positivos) con los que tampoco caen y el modelo no marca (verdaderos negativos), para HistGradientBoosting y XGBoost con el Modelo A. Los dos grupos difieren en casi todas las variables del núcleo SHAP: en HistGradientBoosting, los falsos positivos tienen un índice de riqueza mucho menor (0.30 frente a 1.65), menor educación máxima en el hogar (3.2 frente a 5.5), menos bienes durables y servicios públicos, menor estrato, menos acceso a internet y más hacinamiento; solo se parecen en los choques y la edad del jefe. Sin embargo, lo que lleva al modelo a marcarlos se concentra en pocas variables. Según los valores SHAP, en HistGradientBoosting son el índice de riqueza, la educación máxima del hogar y los bienes durables; en XGBoost, el ingreso y el gasto per cápita y su brecha frente a la línea de pobreza, seguidos de la educación.

La riqueza y la educación no elevan el riesgo que los modelos asignan a los falsos positivos: en los verdaderos negativos, su nivel alto reduce con fuerza el riesgo predicho, mientras que en los falsos positivos casi no lo modifica. Es decir, los modelos no los marcan porque tengan una característica que los haga especialmente riesgosos, sino porque no tienen la riqueza y la educación que llevan a los verdaderos negativos a quedar por debajo del umbral. Solo algunas variables sí empujan su riesgo hacia arriba: en HistGradientBoosting, los bienes durables, los servicios públicos, el estrato y tener un jefe jornalero; en XGBoost, sobre todo el ingreso per cápita. Así, los modelos distinguen bien a los hogares precarios de los que no lo son; lo que distingue solo en parte es cuáles de los hogares precarios

efectivamente caerán.

Quinto, quienes efectivamente caen reportan más choques posteriores a la predicción que quienes no caen. Comparando choques reportados en la ola de destino (2016, posteriores al momento de la predicción y por tanto no usados por el modelo) entre verdaderos positivos y falsos positivos, los primeros reportaron más choques en la ola de 2016: 3.1 choques en promedio frente a 2.2 (ambos algoritmos), y 81–82 % tuvo al menos un choque frente a 71–72 % de los falsos positivos –consistente con el enfoque de vulnerabilidad de Chaudhuri et al. (2002): el modelo identifica correctamente al hogar en el margen, y parte de quién realiza el riesgo podría depender de choques que la ola base no permite anticipar. También coincide con la evidencia de que los choques idiosincráticos y comunes, como la pérdida de la cosecha de un hogar o la falta de lluvias, generan movimientos de corto plazo hacia dentro y fuera de la pobreza que una medición en un solo momento no captura (Dercon & Krishnan, 2000), y de que los choques idiosincráticos producen por sí solos una volatilidad del consumo no despreciable (Christiaensen & Subbarao, 2005). La comparación es descriptiva: los choques se autorreportan en la misma ola en que se observa la caída, de modo que un hogar que cayó puede recordarlos o reportarlos más, o haberlos sufrido como consecuencia de la caída.

En suma, cualquier algoritmo, incluso el más simple y aun sin medir el ingreso del hogar, identifica con una capacidad moderada (AUC-ROC cercano a 0.75) a los hogares que están en el margen de la pobreza, pero distingue mal cuáles de ellos efectivamente caerán, un resultado asociado de forma descriptiva a choques posteriores a la predicción. Las implicaciones de este resultado para la focalización se discuten en la Sección 6.2.

5.2. Determinantes de la vulnerabilidad: perfil e importancia de variables

Esta sección responde quiénes son los hogares vulnerables, es decir, los que no son pobres en la ola base y entran en pobreza en la siguiente, y qué los distingue. La evidencia principal son los valores SHAP de los cinco algoritmos de la Sección 5.1: solo se afirma como determinante lo que se sostiene en los cinco algoritmos, en las dos definiciones de pobreza (monetaria y multidimensional) y en las dos ventanas (2010→2013 y 2013→2016). El perfil univariado, que compara el promedio de cada variable entre los cuatro grupos de la matriz de transición (Sección 3.4), valida ese resultado con un método distinto y complementa el análisis de los valores de SHAP.

Hay cuatro hallazgos principales. **Primero**, unas pocas variables concentran casi toda la información para identificar a los hogares vulnerables. De las 165 a 169 covariables, entre 14 y 37 acumulan el 80 % de la importancia SHAP en cada combinación de algoritmo y especificación, y las diez primeras, entre el 44 % y el 72 % (Tabla 9, Apéndice A.3). Las

22 variables que están en ese grupo en al menos la mitad de las combinaciones forman el núcleo del perfil vulnerable (Tabla 4). Cuatro aparecen en todas las combinaciones: servicios públicos, estrato, bienes durables y personas por cuarto. Siete se mantienen en el núcleo bajo las dos definiciones de pobreza y en las dos ventanas: riqueza, educación máxima del hogar, nivel educativo del jefe, personas por cuarto, razón de dependencia, puntaje TVIP⁵ y material del piso. El núcleo tampoco depende de los criterios elegidos para definirlo: las 22 variables se conservan con criterios más laxos, y riqueza, educación máxima, razón de dependencia y personas por cuarto sobreviven incluso a los más estrictos (Tabla 10). Esto no implica que la información completa del hogar sobra, porque disponer de todas las variables sigue siendo el escenario preferible. Pero cuando esa información no está disponible, está desactualizada o es incompleta, por ejemplo entre rondas de una encuesta o para hogares con registros administrativos parciales, un conjunto reducido centrado en el núcleo podría servir como alternativa para identificar a los hogares vulnerables; queda como investigación futura evaluar un modelo restringido a esas variables.

Segundo, lo que protege a un hogar de caer en pobreza es lo que ha acumulado, y lo que lo expone es la presión sobre esos recursos. El núcleo tiene una dirección consistente entre algoritmos, definiciones de pobreza y ventanas (Tabla 4). Reducen el riesgo, con dirección estable bajo todos los criterios evaluados, el índice de riqueza, los activos financieros, el estrato, la educación máxima del hogar y el último grado aprobado por el jefe;⁶ y, con dirección moderada, el nivel educativo del jefe, el valor del arriendo y los controles médicos preventivos. Lo aumentan el hacinamiento, con dirección estable, y la razón de dependencia, con dirección moderada. Las demás variables del núcleo no tienen una dirección clara: los bienes durables, los servicios públicos y la cotización a pensión tienen signo mayoritariamente negativo pero no estable entre fuentes, y el acceso a internet, el puntaje TVIP, el choque económico, el porcentaje de niños con madre o padre vivo, la edad del jefe y los desplazados en la comunidad cambian de signo entre definiciones o ventanas; por eso se reportan como asociaciones, no como determinantes. Estas direcciones coinciden con las que encuentran Hernández y Zuluaga (2022) con la misma ELCA bajo pobreza multidimensional, donde los años de educación, el empleo asalariado y el acceso al crédito reducen la vulnerabilidad, y con la literatura que asocia el capital humano con la pobreza crónica y la riqueza con una menor pobreza transitoria (Jalan & Ravallion, 2000),

⁵Puntaje promedio de los niños del hogar en el Test de Vocabulario en Imágenes Peabody (TVIP), que mide el vocabulario receptivo como indicador del desarrollo cognitivo. Se usa el puntaje bruto, sin ajustar por edad, de modo que refleja en parte la edad de los niños evaluados.

⁶Es el último grado aprobado dentro del nivel educativo alcanzado, no los años de escolaridad: va de 1 a 5 en primaria y de 6 a 13 en secundaria, y se reinicia en la educación técnica, universitaria y de posgrado. Por eso se lee como escolaridad sobre todo entre los jefes con primaria o secundaria, que son la gran mayoría de la muestra.

y que identifica el ahorro como una forma de autoseguro de los hogares frente a los choques (Dercon, 2002). El signo describe cómo el modelo usa cada variable, no un efecto causal, pero indica dónde tendría más sentido enfocar la prevención: en fortalecer el patrimonio del hogar (ahorro y activos financieros, educación y vivienda) más que en compensar carencias una vez ocurren.

Tabla 4: Núcleo de variables del análisis SHAP y su dirección.

Variable	Comb.	Monetaria 2010→13	Monetaria 2013→16	IPM 2010→13	IPM 2013→16	Dirección
Activos del hogar						
Estrato (verificado)	10	− 10/10	− 10/10	− 5/5	− 10/10	Estable
N.º de servicios públicos	10	− 10/10	− 3/5	− 10/10	− 9/10	Inestable
N.º de bienes durables	10	− 10/10	− 10/10	− 7/8	− 7/9	Inestable
Tiene internet en el hogar	9	− 10/10	− 7/7	+ 3/5	+ 5/8	Inestable
Índice de riqueza (PCA)	8	− 10/10	− 10/10	− 8/8	− 10/10	Estable
N.º de activos financieros	6	− 9/9	− 9/10	− 10/10	− 10/10	Estable
Educación, empleo y seguridad social						
Máx. nivel educativo del hogar	9	− 10/10	− 10/10	− 9/9	− 9/10	Estable
Cotización a pensión (hogar)	7	− 8/9	− 9/9	− 7/9	− 8/8	Inestable
Último grado aprobado por el jefe [†]	6	− 6/6	− 5/5	− 9/9	− 9/9	Estable
Nivel educativo del jefe (ordinal)	5	− 8/8	− 8/8	− 9/10	− 8/8	Moderada
Vivienda: materiales y servicios						
Material de piso del hogar	8	cat.	cat.	cat.	cat.	−
Vivienda: hacinamiento						
Personas por cuarto	10	+ 10/10	+ 9/9	+ 10/10	+ 10/10	Estable
Valor del arriendo pagado	6	− 9/10	− 7/8	− 10/10	− 8/8	Moderada
Composición del hogar						
% de niños con madre viva [†]	8	+ 9/9	+ 6/6	+ 8/8	− 4/6	Inestable
Razón de dependencia demográfica	8	+ 8/9	+ 8/9	+ 8/10	+ 8/10	Moderada
Edad del jefe de hogar [†]	7	− 8/8	− 6/7	+ 9/9	+ 7/7	Inestable
% de niños con padre vivo [†]	7	− 4/6	+ 8/9	− 5/5	− 10/10	Inestable
Estado civil del jefe	6	cat.	cat.	cat.	cat.	−
Desarrollo infantil (6–9 años)						
Puntaje de vocabulario infantil (test TVIP) [†]	6	− 4/7	− 4/6	− 10/10	− 8/9	Inestable
Salud						
Tasa de controles médicos preventivos (hogar) [†]	6	− 9/9	− 8/8	− 10/10	− 8/9	Moderada
Choques y afrontamiento						
Tuvo un choque económico (hogar) [†]	6	+ 8/9	+ 4/7	+ 8/8	+ 4/6	Inestable
Comunidad						
N.º de desplazados en la comunidad [†]	5	− 6/9	− 7/8	+ 2/3	+ 4/6	Inestable

Nota: Comb.: combinaciones algoritmo/especificación (de 10) en que la variable está dentro del 80 % de la masa SHAP acumulada (Sección 5.2). Cada celda de signo indica el signo mayoritario y en cuántas (n) de las m combinaciones con dirección clara ($|\rho| \geq 0.10$) aparece: − significa que valores altos de la variable *reducen* el riesgo de entrar en pobreza; +, que lo *aumentan*. Dirección: Estable = mismo signo en las cuatro fuentes bajo las 12 combinaciones de umbrales evaluadas; Moderada = en al menos 8; Inestable = en menos. “cat.”: variable categórica, sin signo a nivel de variable. [†]Variable fuera del perfil univariado

de 53 variables robustas de la Sección 5.2. Fuente: cálculos propios.

Tercero, el hogar que cae en pobreza se parece más al que acaba de salir de ella que al que nunca ha sido pobre. El perfil univariado confirma primero la estructura del núcleo con un método distinto: 28 variables son comunes a pobreza monetaria e IPM, y se concentran en cuatro categorías de variables: vivienda (9 variables, entre materiales, servicios y hacinamiento), educación y empleo (7), ingreso y gasto (4) y activos del hogar (3) (Tabla 5). Además, a partir del perfil univariado se encuentra que el hogar que entra en pobreza queda más cerca del que sale que del que nunca fue pobre en 47 de 53 variables en 2010→2013 y en 49 de 53 en 2013→2016 (Tabla 8; 29 de 36 y 31 de 35 bajo IPM, Apéndice A.4), incluso en las variables de dirección estable del núcleo (Figura 2). Un modelo multiclase sin ingreso confirma esto de forma independiente: en 2013→2016 separa “entra” de “nunca pobre” con un AUC de 0.73 a 0.75, pero apenas separa “entra” de “sale” (0.53 a 0.56, casi azar; Apéndice A.13). “Entra” y “sale” son dos lados de una misma frontera, no dos tipos de hogar. Es la población que López-Calva y Ortiz-Juarez (2014) identifican en Chile, México y Perú: hogares que superaron la línea de pobreza sin alcanzar seguridad económica y que siguen expuestos a volver a caer; y es coherente con la pobreza transitoria de Jalan y Ravallion (2000), en la que hogares no pobres en tiempos normales pueden caer de repente en la pobreza. Parte de esa cercanía puede reflejar también error de medición del ingreso cerca de la línea, al que las transiciones son sensibles (Anexo A.2). El mismo modelo aporta dos matices. El hogar que entra se distingue de “nunca pobre” con más dificultad que el que sale (AUC de 0.73 a 0.75, frente a 0.81 a 0.83), consistente con que parte de una situación algo mejor. Y con la información de la ola base tampoco se distingue bien a quien sale de la pobreza de quien permanece en ella (0.60 a 0.63): ni la entrada ni la salida se anticipan bien desde el perfil. En el contexto de una potencial política pública de vulnerabilidad, esto implica que los hogares que acaban de salir de la pobreza son los siguientes candidatos a caer en ella: retirarlos de los programas en cuanto superan la línea podría devolverlos a la pobreza. Y como la salida tampoco se anticipa desde el perfil, las reglas de graduación basadas en características observadas serían menos confiables que un seguimiento periódico de la condición del hogar; una salida gradual, o mantenerlos en seguimiento, sería más coherente con este perfil.

Tabla 5: Núcleo del perfil de vulnerabilidad: las 28 variables robustas comunes a pobreza monetaria (53 variables, Tabla 8) y a pobreza multidimensional –IPM– (36 variables, Anexo A.4). Valores bajo pobreza monetaria, transición 2010→2013.

Variable	Siempre	Sale	Entra	Nunca	Variable	Siempre	Sale	Entra	Nunca
Activos del hogar					Ingreso y gasto (cont.)				
N.º de bienes durables	4.58	6.00	6.30	9.10	Ingreso per cápita	65k	93k	269k	633k
N.º de servicios públicos	2.50	3.30	3.65	4.80	Gasto per cápita	154k	210k	247k	662k
Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06	Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36
Composición del hogar					Vivienda: hacinamiento				
Etnia del jefe: Indígena	12 %	6 %	6 %	4 %	Personas por cuarto	2.13	1.65	1.49	1.11
Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %	Vivienda: materiales y servicios				
Niños al cuidado de terceros	86 %	94 %	99 %	98 %	Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %
Educación, empleo y seguridad social					Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %	Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %
Ocupación del jefe: Asalariado	34 %	52 %	62 %	58 %	Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %	Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %	Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22	Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %	Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72	Zona de residencia				
Geoespacial					Vive en zona rural	69 %	52 %	45 %	21 %
Iluminación nocturna (DMSP)	21.6	32.6	36.4	50.1					
Ingreso y gasto									
Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26					




Figura 2: Promedio de cada variable en los hogares que entran en pobreza y en los que salen de ella, expresado en relación con los promedios de los dos grupos extremos: 0 corresponde al promedio de los hogares “siempre pobres” y 1 al de los “nunca pobres” (por ejemplo, 0.5 indica un promedio a medio camino entre ambos). Se muestran las ocho variables del núcleo SHAP con dirección estable o moderada que forman parte del perfil univariado de 53 variables. Grupos de López-Calva y Ortiz-Juarez (2014), pobreza monetaria, transiciones 2010→2013 ($n = 8,218$) y 2013→2016 ($n = 6,911$). Fuente: cálculos propios.

Cuarto, entre los hogares que caen, el endeudamiento informal y la falta de protección laboral (informalidad laboral) separan a quienes quedan atrapados de quienes se recuperan. La tercera ola permite distinguir dos trayectorias: pobres transitorios (355 hogares, 58 %), que vuelven a salir antes de 2016, y persistentes (255 hogares, 42 %), que siguen pobres en 2016 (Tabla 6). Las diferencias entre ambos son sustantivas: 20 de las 52 variables comparadas difieren de forma significativa. La más marcada es la deuda informal (17.3 % de los transitorios frente a 41.9 % de los persistentes), y en la misma dirección los persistentes cotizan menos a pensión y tienen menos acceso a deuda formal. El resultado es coherente con Dercon (2002), para quien los mercados formales de crédito y seguros suelen estar ausentes o ser incompletos en los países en desarrollo, lo que dificulta suavizar el consumo cuando los choques persisten, y con Hernández y Zuluaga (2022), que encuentran con la ELCA que el acceso al crédito reduce la vulnerabilidad. Que una parte de quienes caen permanezca en la pobreza es consistente, además, con la evidencia de trampas de pobreza en Colombia (Castañeda Castrillón, 2012). Estas variables podrían orientar la duración del apoyo: una vez un hogar cae, el endeudamiento informal y la falta de cotización señalarían a quienes necesitan un apoyo más largo, lo que complementa la focalización en dos etapas (Sección 6.2).

Tabla 6: Perfil del hogar vulnerable (“entra en pobreza”, 2010→2013) desagregado por trayectoria a 2016: transitorio ($n = 355$, vuelve a salir) vs. persistente ($n = 255$, se queda pobre). Valores ponderados por grupo; filas superiores, resumen agregado sobre las 53 variables; filas inferiores, ejemplos puntuales donde el promedio agregado (Sección 5.2) ocultaba una divergencia entre subgrupos.

Variable	Siempre	Sale	Transitorio	Persistente	Nunca
Más cerca de “sale” que de “nunca” (de 53)	–		39/53	44/53	–
Más cerca de “siempre” que de “sale” (de 53)	–		2/53	11/53	–
Jefe asalariado	34.4 %	52.2 %	64.9 %	61.7 %	57.9 %
Jefe cotiza a pensión	6.4 %	21.3 %	33.0 %	12.0 %	42.8 %
Tiene deuda informal	31.6 %	22.7 %	17.3 %	41.9 %	9.4 %
Tiene deuda formal	65.2 %	74.6 %	81.4 %	57.5 %	88.3 %
Comunidad con transporte público	54.6 %	75.4 %	84.9 %	78.2 %	78.2 %

Nota: de los 723 hogares que entran en pobreza entre 2010 y 2013, 610 tienen dato de la ola 2016 (113 se pierden por atrición, misma tasa que el resto del panel); de esos 610, 355 (58 %) vuelven a salir de la pobreza para 2016 y 255 (42 %) se quedan pobres. Fuente: cálculos propios.

En conjunto, el hogar vulnerable es un hogar no pobre con poca riqueza y capital educativo, hacinado y con alta carga de dependencia, que se parece más a quien acaba de salir de la pobreza que a quien nunca la vivió; esa estructura se sostiene entre algoritmos, definiciones de pobreza y ventanas.

5.3. Contribución marginal de las variables geoespaciales

Esta sección evalúa si la iluminación nocturna DMSP-OLS, la única fuente geoespacial con datos reales en la ola de entrenamiento y en la de prueba (Sección 3.2), mejora la identificación de los hogares vulnerables cuando se agrega a la encuesta. Primero se describe cómo se ubican los grupos de la matriz de transición en esta fuente y se evalúa su aporte bajo pobreza monetaria; luego se repite el ejercicio bajo pobreza multidimensional (IPM) y se examina si el efecto promedio esconde diferencias entre subgrupos.

5.3.1. Perfil geoespacial y aporte bajo pobreza monetaria

Frente a las variables geoespaciales se encontraron cuatro hallazgos. **Primero**, la luz nocturna ordena a los hogares según su trayectoria de pobreza y reproduce el perfil de la encuesta. En 2010→2013 separa de forma monótona los cuatro grupos, en media y en mediana, bajo pobreza monetaria e IPM: de “siempre pobre” a “nunca pobre”, el valor de iluminación nocturna sube en cada paso (Figura 3). También reproduce el Tercer hallazgo de la Sección 5.2: el hogar que entra en pobreza queda más cerca del que sale que del que nunca fue pobre. Bajo IPM, su mediana (10.7) está a 2.9 puntos de “sale” y a 38.4 de “nunca pobre”; bajo pobreza monetaria el patrón es débil en 2010→2013, con “entra” casi a medio camino, pero se recupera en 2013→2016, donde queda a 8.9 puntos de “sale” y a 38.3 de “nunca pobre”. Por región, la pobreza persistente se concentra en las microrregiones rurales andinas, con 64–66 % de hogares siempre pobres y luz nocturna muy baja, mientras Bogotá concentra los nunca pobres (70 %) con el valor máximo de luz (Figura 4).⁷ Que una fuente completamente independiente de la encuesta, medida desde el espacio, reproduzca el gradiente y la cercanía entre “entra” y “sale” indica que ese patrón no depende de cómo se construyó el cuestionario. Para la política, esto hace de la luz nocturna un indicador gratuito y de cobertura universal del gradiente socioeconómico, útil para priorizar territorios donde no hay encuesta (Hofer et al., 2025), aunque no para seleccionar hogares dentro de ellos, como muestra el siguiente hallazgo.

⁷La muestra de ELCA es urbana en unas regiones y rural en otras, y no incluye el Chocó rural ni La Guajira (Sección 6.3). ALOS PALSAR sigue el mismo gradiente que DMSP-OLS y el NDVI de Landsat lo invierte, por ruralidad, pero ambas fuentes solo tienen datos en 2010 y no se pueden poner a prueba en 2013→2016.




Figura 3: Iluminación nocturna (DMSP-OLS) por grupo de transición, media y mediana, pobreza monetaria e IPM (2010→2013).




Figura 4: Grupo de transición dominante por región e iluminación nocturna (DMSP), pobreza monetaria, 2010→2013.

Segundo, bajo pobreza monetaria, agregar la luz nocturna a la encuesta no mejora la identificación de los hogares vulnerables. Al reentrenar los cinco algoritmos con las 23 variables de DMSP-OLS, el AUC-ROC cambia entre -0.006 y $+0.006$ en las diez combinaciones de algoritmo y especificación, y la precisión en el decil de mayor riesgo cae o se mantiene en todas; el intervalo de confianza del cambio incluye el cero en las diez (Tablas 20 y 21, Apéndice A.6). No se debe a sobreajuste: la diferencia entre el AUC de validación cruzada y el de prueba prácticamente no cambia al agregar DMSP-OLS (a lo sumo 0.002 en ocho de las diez combinaciones y 0.008 en LightGBM con el Modelo A). El resultado se repite al agregar las tres fuentes geoespaciales juntas (Tabla 24, Apéndice A.8).⁸ La razón es que la luz nocturna mide lo mismo que la encuesta ya captura. Su correlación con caer en pobreza ($r = -0.214$) es tan fuerte como la del estrato, pero cae a $r \approx 0.01$ al descontar cuatro variables del núcleo: servicios públicos, estrato, bienes durables y personas por cuarto (Figura 5). Tampoco ayuda a resolver el problema central de la Sección 5.1.2: en el modelo multiclase, agregar DMSP-OLS no mejora de forma apreciable la separación de ningún par de grupos, y la de “entra” frente a “sale” cambia apenas entre -0.006 y $+0.011$ (Tabla 31, Apéndice A.13). La luz nocturna distingue, como la encuesta, a los hogares precarios de los que no lo son, pero no a cuáles de los precarios caerán. Un sistema que ya cuenta con una encuesta vigente no ganaría precisión al integrarla. Es coherente con la evidencia previa: en Jean et al. (2016) la luz nocturna sola predice peor que un modelo que la combina con imágenes diurnas y datos de encuesta, y Hall et al. (2023) encuentran que los datos geoespaciales predicen peor variables de flujo, como el ingreso o el consumo, que los activos físicos. Hay, sin embargo, una diferencia práctica: la luz nocturna es mucho más estable en el tiempo que esas variables de la encuesta (correlación entre 2010 y 2013 de 0.958 , frente a 0.600 de los bienes durables). Esa estabilidad es la que permite, como proponen Hofer et al. (2025), usar la luz nocturna para estimar entre encuestas.

⁸Se probó además si DMSP-OLS aporta más al eliminar de la encuesta las dos preguntas que la vuelven redundante (solo la regresión logística mejora de forma consistente) y si aporta más cerca de la línea de pobreza (sin evidencia en los tres terciles de cercanía).




Figura 5: Correlación de la luz nocturna (DMSP-OLS) con caer en pobreza monetaria, antes y después de descontar cuatro variables del núcleo: servicios públicos, estrato, bienes durables y personas por cuarto. La correlación inicial (gris oscuro) es comparable a la de esas cuatro variables (gris claro), pero cae casi a cero al descontarlas (rojo). La barra roja es una correlación parcial: se residualizan tanto la luz nocturna como el resultado frente a las cuatro variables de referencia, y se correlacionan los residuos (teorema de Frisch–Waugh–Lovell). $n = 2,150$, restringido por datos faltantes de estrato. Fuente: cálculos propios.

5.3.2. Aporte bajo pobreza multidimensional y por subgrupos

Tercero, bajo IPM la luz nocturna sí mejora la predicción, pero poco y solo en dos algoritmos. XGBoost mejora en ambas especificaciones (+0.013 a +0.020 en AUC-ROC, $p \leq 0.006$) y LightGBM en el Modelo B (+0.017, $p < 0.001$); las otras siete combinaciones no son distinguibles de cero (Tabla 7; detalle de la significancia en la Tabla 21 del Apéndice A.6). El aporte es real, pero demasiado pequeño para cambiar por sí solo una decisión de focalización. Una explicación posible de que aparezca bajo IPM y no bajo pobreza monetaria es que el IPM incluye privaciones de vivienda y de servicios públicos, más ligadas a la infraestructura que refleja la luz nocturna que el ingreso. Si un programa focaliza privaciones multidimensionales, la luz nocturna añade algo de información, aunque poca.

Tabla 7: Contribución marginal de DMSP-OLS bajo pobreza multidimensional (IPM) (entrenamiento 2010→2013, prueba 2013→2016).

Algoritmo	Esp.	AUC base	AUC +DMSP	Δ AUC	Δ Prec.-top10
XGBoost	A	0.725	0.736	+0.013	+0.022
Random Forest	A	0.729	0.729	+0.001	+0.004
LightGBM	A	0.741	0.745	+0.004	+0.005
HistGradientBoosting	A	0.740	0.738	-0.002	+0.002
Logística regularizada	A	0.730	0.730	-0.000	+0.009
XGBoost	B	0.728	0.746	+0.020	+0.016
Random Forest	B	0.735	0.732	-0.004	+0.015
LightGBM	B	0.730	0.747	+0.017	+0.021
HistGradientBoosting	B	0.739	0.740	+0.002	-0.007
Logística regularizada	B	0.730	0.730	-0.000	+0.011

Nota: AUC: promedio de 5 semillas. Δ AUC: *bootstrap* pareado sobre el conjunto de prueba (una semilla); en **negrita**, diferencias cuyo IC95 % no cruza cero. Intervalos, valores p y corrección por conglomerados de comunidad en la Tabla 21 del Anexo A.6. Fuente: cálculos propios.

Cuarto, en LightGBM, el algoritmo con el patrón más claro, ese aporte se concentra justo donde la encuesta es más débil. Bajo pobreza monetaria no hay diferencias entre subgrupos: solo 1 de 70 combinaciones de algoritmo, grupo y especificación cambia el AUC-ROC en 0.02 o más (Tabla 22, Apéndice A.7). Bajo IPM, LightGBM sin ingreso concentra su ganancia en zona rural (+0.032 frente a +0.008 en la urbana), en estrato 1 (+0.024 frente a -0.003 en estrato 3) y en el tercil de hogares con menos servicios públicos y bienes durables (+0.030 frente a +0.009 en el tercil alto) (Tabla 23, Apéndice A.7). En zona rural y en ese tercil, agregar la luz nocturna marca como en riesgo a 6 a 7 puntos porcentuales más de los hogares que efectivamente caen, sin reducir la precisión. XGBoost, en cambio, gana de forma más pareja entre grupos, y Random Forest no gana en casi ningún subgrupo. Son estimaciones exploratorias, con celdas de unos pocos cientos de hogares y sin intervalos propios por subgrupo. Este patrón contrasta con la evidencia de que la luz nocturna rinde peor en regiones pobres y rurales, donde varía poco (Hall et al., 2023). La diferencia puede estar en el uso: allí la luz nocturna es el único predictor del nivel de bienestar, mientras que aquí complementa una encuesta, de modo que incluso poca variación puede aportar donde las preguntas de la encuesta distinguen menos entre hogares; es una hipótesis que queda por verificar. Si el patrón se confirma, el complemento satelital tendría más sentido focalizado geográficamente, en las zonas rurales y de estratos bajos donde la encuesta es más débil, que como insumo nacional, en línea con Newhouse et al. (2025), para quienes la imagen satelital mejora las estimaciones de pobreza justamente en las áreas donde la encuesta tiene pocas observaciones.

En suma, la luz nocturna describe bien la geografía de la pobreza, pero no reemplaza a la encuesta.

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento evalúa si las fuentes geoespaciales públicas mejoran la predicción de la caída en pobreza de hogares colombianos no pobres, frente a modelos basados solo en la ELCA. Solo una de las cuatro fuentes consideradas, la iluminación nocturna DMSP-OLS, tiene datos en la ola de entrenamiento y en la de prueba, de modo que es la base de la evaluación principal. El ejercicio estima cinco algoritmos, con y sin ingreso del hogar, bajo pobreza monetaria y multidimensional, con entrenamiento en 2010→2013 y prueba en 2013→2016.

Cinco hallazgos se destacan. **Primero**, la pobreza monetaria cae de 60.7 % a 42.4 % entre 2010 y 2016, pero con mucho movimiento en ambas direcciones: 23.4 % y 19.9 % de los hogares no pobres caen en pobreza en cada ventana, mientras casi el doble de hogares sale de ella (Sección 3.4). **Segundo**, la capacidad de identificar a los vulnerables tiene un techo (AUC-ROC de 0.73 a 0.77) que no depende del algoritmo ni del ingreso; con un umbral que capte casi a todos, un programa atendería entre 2.4 y 3.1 hogares que no caen por cada uno que sí (Sección 5.1). **Tercero**, con la información de la ola base es difícil separar a quien cae de quien no: los hogares marcados que no caen también son precarios, quienes caen reportan más choques posteriores, y la información de la ola base distingue a “entra” de “sale” casi al azar (Sección 5.1.2). **Cuarto**, el hogar vulnerable se reconoce por lo que ha acumulado (riqueza, educación, activos y vivienda) y se parece más al que acaba de salir de la pobreza que al que nunca fue pobre; entre los que caen, la deuda informal y la falta de cotización a pensión señalan a quienes quedan atrapados (Sección 5.2). **Quinto**, y en respuesta a la pregunta de investigación, las fuentes geoespaciales públicas describen bien la geografía de la pobreza, pero no mejoran la identificación de los hogares vulnerables cuando hay una encuesta vigente. La iluminación nocturna es redundante con unas pocas preguntas de la encuesta bajo pobreza monetaria y aporta poco bajo IPM, sobre todo en zonas rurales; su ventaja es su estabilidad en el tiempo. ALOS PALSAR, Landsat 5 TM y Street View no tienen cobertura suficiente para una conclusión firme (Sección 5.3).

6.2. Implicaciones para la política pública

Los resultados sugieren cinco implicaciones para sistemas de focalización como el SISBEN IV, que hoy clasifica a los hogares por su estándar de vida y su capacidad presunta

de generar ingresos; los modelos de este artículo podrían complementarlo con una medida del riesgo de entrada en pobreza de los hogares hoy no pobres. Primero, la focalización puede apoyarse en variables no monetarias, que capturan casi toda la señal; cuando la información del hogar está desactualizada o incompleta, un conjunto reducido centrado en el núcleo podría servir como alternativa. Segundo, el umbral debe depender del costo del instrumento: amplio para intervenciones preventivas de bajo costo, donde los incluidos por error también son precarios, y concentrado en el decil de mayor riesgo para transferencias costosas. Tercero, si la asociación con los choques se confirma, la focalización podría hacerse en dos etapas, en las que el modelo define quién está en riesgo y un choque activa el apoyo, verificando el choque y no el perfil y actualizando la lista con frecuencia. Esto respondería a una limitación de la protección social reactiva a choques en la región, que ha dependido sobre todo de ampliar los beneficios de quienes ya estaban en los programas y ha dejado por fuera a muchos hogares afectados (Costella et al., 2023). Cuarto, como la salida de la pobreza tampoco se anticipa desde el perfil, la graduación debería ser gradual y con seguimiento, y la deuda informal y la falta de cotización podrían orientar la duración del apoyo. Quinto, la iluminación nocturna no se justifica como covariable de rutina con una encuesta vigente, pero sí para priorizar territorios y como respaldo entre rondas, sobre todo en zonas rurales. Todas son asociaciones, no efectos causales, y requieren evaluación antes de convertirse en intervenciones.

6.3. Limitaciones y agenda de investigación

Los principales límites son cuatro. En los determinantes, la importancia SHAP describe cómo el modelo usa cada variable, no un efecto causal ni un aporte fuera de muestra; reparte el crédito entre variables correlacionadas, y el núcleo se eligió con información de ambas ventanas, incluida la de prueba. En los errores del modelo, los choques se reportan en 2016 y su relación con la caída es descriptiva. En DMSP-OLS, la heterogeneidad por subgrupos es exploratoria y la corrección por conglomerados de comunidad no se estimó para todos los algoritmos. En la muestra, la separación entre pobres transitorios y persistentes se apoya en 610 de 723 hogares, y ELCA no cubre el Chocó rural ni La Guajira.

Los resultados bajo IPM tienen además un límite de medición: el indicador de barreras de acceso a salud se mide en 2010 con un proxy distinto al de 2013 y 2016, y el 79% de los hogares que salen de la pobreza IPM entre 2010 y 2013 lo hacen perdiendo justamente esa privación. Armonizarlo con la pregunta directa tampoco resuelve el problema, por diferencias en quiénes la responden. Por eso, los resultados IPM que dependen de 2010→2013 deben leerse como condicionales al proxy, y la ventana 2013→2016 es la comparación más limpia.

La agenda de investigación tiene seis frentes. Primero, confirmar la heterogeneidad del aporte de DMSP-OLS bajo IPM con *bootstrap* por subgrupo y con la corrección por conglomerados para todos los algoritmos. Segundo, evaluar un modelo restringido al núcleo, seleccionado solo con 2010→2013 y probado en 2013→2016. Tercero, comparar por región, lo que no fue posible porque, con 3,089 hogares no pobres en entrenamiento, las celdas resultan demasiado pequeñas. Cuarto, evaluar si fuentes de alta frecuencia, como la precipitación o los índices de vegetación, anticipan los choques compartidos, dado que la luz nocturna es muy estable y los choques que más distinguen a quien cae son familiares. Quinto, contrastar si las variables de acumulación indican quién es vulnerable y las de actividad económica reciente cuánto dura esa condición. Sexto, evaluar ALOS PALSAR, Landsat 5 TM y Google Street View cuando exista cobertura temporal suficiente: las fotos de Street View predicen bien la luz nocturna de su zona y su señal se asocia con caer en pobreza, pero no hay fotos anteriores a 2012, se concentran en zonas urbanas y son poco estables entre olas (Anexo [A.9](#)).

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Angulo Salazar, R. C., Díaz Cuervo, Y., & Pardo Pinzón, R. (2011). *Índice de Pobreza Multidimensional para Colombia (IPM-Colombia) 1997-2010* (Archivos de Economía N.º 382). Departamento Nacional de Planeación, Dirección de Estudios Económicos. Bogotá.
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (CPRC Working Paper N.º 170). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Burger, J., & van der Laan, J. (2021). Predicting Transitions into and out of Poverty Using Machine Learning. *Proceedings of Statistics Canada Symposium 2021: Adopting Data Science in Official Statistics to Meet Society's Emerging Needs*.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). *Assessing Household Vulnerability to Poverty from Cross-Sectional Data: A Methodology and Estimates from Indonesia* (Discussion Paper N.º 0102-52). Department of Economics, Columbia University.
- Christiaensen, L. J., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Cornia, G. A., & Stewart, F. (1993). Two Errors of Targeting. *Journal of International Development*, 5(5), 459-496. <https://doi.org/10.1002/jid.3380050503>

- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Davis, J., & Goadrich, M. (2006). The Relationship Between Precision-Recall and ROC Curves. *Proceedings of the 23rd International Conference on Machine Learning*, 233-240. <https://doi.org/10.1145/1143844.1143874>
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/00220380008422653>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2026). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of Sustainable Development & World Ecology*, 33(1), 68-80. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature. En J. Silber & G. Wan (Eds.), *The Asian 'Poverty Miracle': Impressive Accomplishments or Incomplete Achievements?* (pp. 53-83). Edward Elgar.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*, 35, 1753-1768. <https://doi.org/10.1002/jid.3751>
- Hernández, J. E., & Zuluaga, B. (2022). Vulnerability to Multidimensional Poverty: An Application to Colombian Households. *Social Indicators Research*, 164, 345-371. <https://doi.org/10.1007/s11205-022-02961-2>
- Hofer, M., Sako, T., Martinez, A., Jr., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*, 39(1), 98-129. <https://doi.org/10.1111/asej.12349>
- Hohberg, M., Landau, K., Kneib, T., Klasen, S., & Zucchini, W. (2018). Vulnerability to Poverty Revisited: Flexible Modeling and Better Predictive Performance. *The*

- Journal of Economic Inequality*, 16(3), 439-454. <https://doi.org/10.1007/s10888-017-9374-6>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Studies*, 36(6), 82-99. <https://doi.org/10.1080/00220380008422655>
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juarez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juarez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón-Santa, G., Escobar-Grisales, D., López-Pabón, F. O., Pérez-Toro, P. A., & Orozco-Arroyave, J. R. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>
- Newhouse, D., Ramakrishnan, A., Swartz, T., Merfeld, J., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

A.1. Correlación entre covariables y riesgo de multicolinealidad

Complemento de la Sección 4.3: análisis de correlación de Pearson entre las 159 variables numéricas del dataset consolidado –incluidas las 4 geoespaciales–, motivado por el riesgo de multicolinealidad para el modelo de regresión logística regularizada.

Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 27), solo se reportan como “altas” los pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican los 35 pares de la Figura 6.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan sobre 0.97 con su propia brecha a la LP; `lp` y `li` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal correlacionan -0.93 (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmsp_stable_lights` correlaciona 0.87 con la línea de pobreza `lp` y 0.81 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`). Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.2 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la Sección 5.3.1.



Figura 6: Pares de variables con correlación de Pearson $|r| > 0.7$ (calculados sobre al menos 500 observaciones conjuntas no-nulas), ordenados por magnitud de la correlación. La mayoría corresponde a redundancias esperables (medidas nominal vs. real de un mismo concepto, o un indicador individual y su agregado a nivel de hogar); la más relevante para este trabajo es la de `dmsp_stable_lights` con `lp`, `li` y `n_servicios_publicos_hogar`, que se retoma en la Sección 5.3.1. Fuente: cálculos propios.

A.2. Incidencia, FGT y robustez de las transiciones de pobreza monetaria

Complemento de la Sección 3.4: incidencia agregada de pobreza monetaria por ingreso y por gasto, su descomposición Foster-Greer-Thorbecke (FGT), y cinco ejercicios diseñados para evaluar qué tan sensible es la variable de transición a la pobreza –la variable de interés de este artículo– a decisiones de construcción del ingreso, a la representatividad muestral y al error de medición cerca del umbral de pobreza.

A.2.1. Incidencia y descomposición FGT

La Figura 7 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más *baja* que la de ingreso en los tres puntos del panel (47.6 %, 40.9 % y 33.4 %): la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto. Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no depende de la medida de bienestar elegida.




Figura 7: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 8 descompone la pobreza por ingreso en sus tres componentes FGT: incidencia

(P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 8: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

A.2.2. Ejercicios de robustez

Se implementaron cinco ejercicios de robustez sobre las cifras de transición de la Sección 3.4: ponderación muestral, dos reclasificaciones del ingreso, sensibilidad al umbral de pobreza, y atrición del panel.

Ponderación muestral. Ninguno de los resultados de la Sección 3.4 usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (`fexhog`, `fexhog_2013`, ambos transversales, y `fexhog_2010`, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % → 60.4 % en 2010, 52.4 % → 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % → 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 %

a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorratedos como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de este artículo. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010→2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se

repitieron las matrices de transición (Figura 9). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % (LP−10 %) y 49.1 % (LP+10 %) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 9: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 10 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 10: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 11). La atrición total es de 11.4% en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). Esa cifra agregada sí se desagregó por perfil de hogar: la atrición **no es aleatoria**, se concentra sistemáticamente en hogares urbanos y de estrato más alto. Por zona, la tasa de pérdida es 2.8 veces mayor en zona urbana que en zona rural en 2010–2013 (16.2% vs. 5.8%) y 1.7 veces mayor en 2013–2016 (14.1% vs. 8.2%); por estrato socioeconómico, la pérdida crece monótonamente de 8.9% en estrato 1 a 26.0% en estrato 4 en 2010–2013. Por región, Bogotá tiene la mayor pérdida (24.9%) y Centro-Oriente la menor (3.1%). El patrón es consistente con que los hogares urbanos y de mayor estrato son más móviles (cambian de vivienda con más frecuencia), lo que dificulta su relocalización entre olas del panel –no con una atrición concentrada en los hogares más pobres, que de hecho es la más baja de las cuatro categorías de estrato–. No se investigó si, controlando por zona/estrato/región, la atrición está además asociada al estado de pobreza mismo del hogar (una limitación que se retoma en la Sección 6.3).




Figura 11: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

A.3. Soporte del perfil univariado y del núcleo SHAP

Complemento de la Sección 5.2: perfil de las 53 variables robustas por grupo de transición, concentración de la señal SHAP y sensibilidad del núcleo y de su dirección a los umbrales elegidos.

Tabla 8: Perfil por grupo de transición, pobreza monetaria (2010→2013), las 53 variables robustas. †variable donde el hogar vulnerable no queda entre “sale” y “siempre pobre”/“nunca pobre” como el resto (ver texto).

Variable	Siempre	Sale	Entra	Nunca	Variable	Siempre	Sale	Entra	Nunca
Educación, empleo y seguridad social					Activos del hogar				
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %	N.º de bienes durables	4.58	6.00	6.30	9.10
Ocupación del jefe: Asalariado†	34 %	52 %	62 %	58 %	N.º de servicios públicos	2.50	3.30	3.65	4.80
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %	Estrato (verificado)	1.59	2.06	2.07	2.63
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %	Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06
Negocio del jefe: De 20 a 49 personas	9 %	16 %	22 %	25 %	Estrato (autorreportado)	1.60	2.07	2.05	2.58
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22	Tiene internet en el hogar	8 %	16 %	13 %	46 %
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %	N.º de activos financieros	0.10	0.42	0.45	0.86
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72	Tiene vehículo	17 %	25 %	23 %	40 %
Jefe cotiza a pensión	6 %	21 %	24 %	43 %	Vivienda: hacinamiento				
Afiliación a pensión (hogar)	27 %	51 %	48 %	57 %	Valor del arriendo pagado	144k	226k	240k	354k
Afiliación a salud laboral (hogar)	33 %	55 %	58 %	62 %	Personas por cuarto	2.13	1.65	1.49	1.11
Jefe afiliado a salud laboral	35 %	53 %	61 %	64 %	Personas por dormitorio	2.77	2.25	2.09	1.74
Jefe afiliado a pensión	29 %	49 %	51 %	58 %	Programas sociales y deuda				
Vivienda: materiales y servicios					Beneficiario de Familias en Acción	53 %	29 %	23 %	7 %
Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %	N.º de programas sociales	0.73	0.42	0.34	0.17
Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %	Beneficiario de algún programa social	60 %	37 %	31 %	15 %
Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %	Tiene deuda informal†	32 %	23 %	26 %	9 %
Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %	Tiene deuda formal	65 %	75 %	73 %	88 %
Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %	Niños con apoyo alimentario escolar	81 %	72 %	70 %	54 %
Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %	Composición del hogar				
Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %	Etnia del jefe: Indígena	12 %	6 %	6 %	4 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %	Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %
Financió la vivienda con crédito formal	13 %	26 %	22 %	43 %	N.º de niños en el hogar	1.45	0.92	0.79	0.57
Tiene escritura de la vivienda	67 %	81 %	80 %	90 %	Razón de dependencia demográfica	0.93	0.67	0.56	0.43
Zona de residencia					Niños al cuidado de terceros†	86 %	94 %	99 %	98 %
Vive en zona rural	69 %	52 %	45 %	21 %	Comunidad				
Geoespacial					N.º de espacios públicos en la comunidad	1.57	1.98	2.13	2.32
Iluminación nocturna (DMSP)	21.6	32.6	36.4	50.1	Comunidad con transporte público†	55 %	75 %	79 %	78 %
					Ingreso y gasto				
					Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26
					Ingreso per cápita	65k	93k	269k	633k
					Gasto per cápita	154k	210k	247k	662k
					Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36

Tabla 9: Concentración de la señal predictiva (SHAP), variables originales agregadas (dummies *one-hot* e indicadores de faltante sumados a su variable de origen antes de calcular la masa acumulada).

Algoritmo	Espec.	Variables (total)	% SHAP en top-10	Variables para 80 % del SHAP
HistGradientBoosting	A	169	69.3 %	15
XGBoost	A	169	58.7 %	23
Logística regularizada	A	169	43.9 %	28
Random Forest	A	169	59.8 %	32
LightGBM	A	169	44.4 %	37
LightGBM	B	165	71.6 %	14
HistGradientBoosting	B	165	63.9 %	18
XGBoost	B	165	54.7 %	26
Logística regularizada	B	165	45.8 %	28
Random Forest	B	165	54.9 %	34

Tabla 10: Sensibilidad del núcleo SHAP y de su dirección a los umbrales elegidos (Sección 5.2). “(base)”: criterio usado en el texto. El núcleo de 22 variables se conserva por completo con criterios más laxos; con los más estrictos queda un subconjunto.

A. Núcleo: masa SHAP acumulada y mínimo de combinaciones (de 10)				
Masa	Mín. comb.	Núcleo	Conserva de las 22	Universales en las 4 fuentes (de 7)
70 %	4	19	17	6
70 %	5	13	13	4
70 %	6	11	11	3
80 %	4	30	22	7
80 %	5	22 (base)	22	7
80 %	6	20	20	5
90 %	4	50	22	7
90 %	5	35	22	7
90 %	6	31	22	7
B. Dirección: ρ mínimo y proporción mínima de signo				
$ \rho $ mín.	Prop. mín.	Consistentes (de 20)		
0.05	0.70	12		
0.05	0.80	10		
0.05	0.90	7		
0.10	0.70	12		
0.10	0.80	10 (base)		
0.10	0.90	7		
0.15	0.70	12		
0.15	0.80	10		
0.15	0.90	6		
0.20	0.70	12		
0.20	0.80	10		
0.20	0.90	6		

A.4. Perfil completo de covariables, pobreza multidimensional (IPM)

Complemento de la Sección 5.2: perfil completo de covariables robustas frente a la transición 2010→2013 bajo pobreza multidimensional (mismo criterio de inclusión que en pobreza monetaria – efecto >0.10 con bootstrap, sin deduplicar por correlación), una tabla por categoría temática.

Tabla 11: Ingreso y gasto – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Pobre extremo por ingreso (2010)	67 %	55 %	53 %	26 %
Pobre por ingreso (2010)	90 %	79 %	84 %	52 %
Pobre por gasto (2010)	74 %	58 %	68 %	40 %
Pobre extremo por gasto (2010)	31 %	21 %	27 %	8 %
Gasto per cápita	112k	148k	223k	400k
Ingreso per cápita	74k	101k	104k	332k
Línea de pobreza (referencia)	137k	140k	151k	177k
Línea de indigencia (referencia)	74k	75k	77k	82k
Ingreso (veces la línea de pobreza)	0.54	0.70	0.67	1.73
Gasto (veces la línea de pobreza)	0.83	1.07	1.33	2.12

Tabla 12: Zona de residencia – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Vive en zona rural	84 %	80 %	67 %	36 %

Tabla 13: Vivienda: materiales y servicios – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Material de piso: Tierra o arena	61 %	35 %	20 %	5 %
Servicio sanitario: Inodoro conectado a alcantarillado	12 %	16 %	30 %	62 %
Obtención de agua: Acueducto público	14 %	21 %	34 %	64 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	32 %	42 %	65 %	86 %
Combustible de cocina: Leña, madera, carbón de leña	83 %	71 %	60 %	28 %
Recolección de basura: La recogen los servicios de aseo	15 %	20 %	34 %	64 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	40 %	38 %	31 %	20 %
Tipo de vivienda: Apartamento	5 %	6 %	6 %	26 %

Tabla 14: Vivienda: hacinamiento – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Personas por cuarto	2.56	1.94	2.10	1.44

Tabla 15: Activos del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
N.º de servicios públicos	1.62	2.07	2.65	4.05
N.º de bienes durables	4.16	4.66	4.61	7.20
Índice de riqueza (PCA)	-0.93	-0.67	-0.87	0.33

Tabla 16: Educación, empleo y seguridad social – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Educación del jefe: Ninguno	42 %	17 %	8 %	2 %
Ocupación del jefe: Jornalero	45 %	31 %	25 %	6 %
Adultos alfabetizados en el hogar	53 %	79 %	92 %	98 %
Nivel educativo del jefe (ordinal)	1.21	1.90	2.11	3.10
Máx. nivel educativo del hogar	1.69	2.22	2.34	3.42
Registro mercantil del jefe: No lo necesita	72 %	55 %	62 %	49 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	78 %	67 %	63 %	59 %
Cotización a pensión (hogar)	1 %	3 %	6 %	25 %

Tabla 17: Composición del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Sexo del jefe: Hombre	83 %	83 %	71 %	69 %
Estado civil del jefe: En unión libre	60 %	55 %	42 %	35 %
Etnia del jefe: Indígena	15 %	12 %	11 %	6 %
Niños al cuidado de terceros	92 %	65 %	79 %	97 %

Tabla 18: Geoespacial – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Iluminación nocturna (DMSP)	13.8	16.7	23.0	40.7

A.5. Desempeño de los modelos bajo pobreza multidimensional (IPM)

Complemento de la Sección 5.1: mismo benchmark de cinco algoritmos y misma metodología robusta (holdout temporal, CV_FOLDS=10, N_ITER_BUSQUEDA=30, 5 semillas), con pobreza multidimensional (IPM) como variable de resultado en vez de pobreza monetaria – covariables idénticas.⁹

Tabla 19: Desempeño de los cinco algoritmos bajo pobreza multidimensional (IPM), holdout temporal (train 2010→2013, test 2013→2016). Misma metodología robusta que la Tabla 2 (monetaria), covariables idénticas – único factor que cambia es la variable de resultado. Prec.-top10: precisión entre el 10 % de hogares de mayor riesgo.

Algoritmo	Espec.	Umbral	AUC-ROC	Recall	Precision	Prec.-top10	F1
LightGBM	Aipm	0.11	0.741	0.670	0.184	0.263	0.288
HistGradientBoosting	Aipm	0.11	0.740	0.603	0.197	0.271	0.295
Logística regularizada	Aipm	0.10	0.730	0.726	0.166	0.258	0.269
Random Forest	Aipm	0.31	0.729	0.645	0.183	0.253	0.285
XGBoost	Aipm	0.11	0.725	0.844	0.139	0.251	0.239
HistGradientBoosting	Bipm	0.10	0.739	0.620	0.189	0.265	0.289
Random Forest	Bipm	0.26	0.735	0.753	0.165	0.260	0.270
LightGBM	Bipm	0.08	0.730	0.721	0.167	0.251	0.270
Logística regularizada	Bipm	0.11	0.730	0.716	0.167	0.255	0.270
XGBoost	Bipm	0.09	0.728	0.901	0.130	0.258	0.228

A.6. Aporte de DMSP-OLS: resultados detallados

Complemento de la Sección 5.3: desempeño de los cinco algoritmos con y sin las variables de DMSP-OLS bajo pobreza monetaria (Tabla 20) y significancia del cambio de AUC-ROC bajo IPM (Tabla 21).

⁹Balanceo elegido por validación cruzada: *ninguno* (sin reponderar) en todos los casos, excepto Random Forest (Aipm y Bipm), donde fue *balanced* (reponderación de clases).

Tabla 20: AUC-ROC y precisión en el decil de mayor riesgo, con y sin DMSP-OLS, pobreza monetaria (entrenamiento 2010→2013, prueba 2013→2016).

Algoritmo	Especificación	AUC-ROC	IC95 %	Precision top-10 %	IC95 %	Umbral	Recall	Precision	F1	Brecha CV
Random Forest	A	0.766	[0.765, 0.767]	0.486	[0.476, 0.495]	0.138	0.926	0.277	0.426	+0.000
Random Forest	A + DMSP-OLS	0.763	[0.762, 0.764]	0.481	[0.470, 0.493]	0.264	0.938	0.271	0.420	+0.002
XGBoost	A	0.767	[0.766, 0.769]	0.505	[0.496, 0.514]	0.112	0.949	0.264	0.413	-0.001
XGBoost	A + DMSP-OLS	0.765	[0.764, 0.766]	0.501	[0.488, 0.515]	0.118	0.937	0.272	0.421	+0.000
LightGBM	A	0.758	[0.758, 0.758]	0.516	[0.516, 0.516]	0.096	0.903	0.281	0.428	+0.003
LightGBM	A + DMSP-OLS	0.752	[0.752, 0.752]	0.497	[0.497, 0.497]	0.102	0.902	0.277	0.424	+0.011
HistGradientBoosting	A	0.763	[0.763, 0.763]	0.512	[0.512, 0.512]	0.324	0.909	0.283	0.432	-0.003
HistGradientBoosting	A + DMSP-OLS	0.763	[0.763, 0.763]	0.500	[0.500, 0.500]	0.312	0.912	0.281	0.429	-0.002
Logística regularizada	A	0.747	[0.747, 0.747]	0.506	[0.506, 0.506]	0.372	0.883	0.280	0.426	+0.015
Logística regularizada	A + DMSP-OLS	0.746	[0.746, 0.746]	0.500	[0.500, 0.500]	0.370	0.883	0.281	0.426	+0.015
Random Forest	B	0.742	[0.741, 0.744]	0.508	[0.497, 0.520]	0.306	0.892	0.272	0.416	+0.013
Random Forest	B + DMSP-OLS	0.739	[0.737, 0.741]	0.492	[0.482, 0.502]	0.266	0.925	0.255	0.399	+0.015
XGBoost	B	0.742	[0.742, 0.743]	0.495	[0.487, 0.503]	0.126	0.940	0.250	0.395	+0.014
XGBoost	B + DMSP-OLS	0.740	[0.740, 0.741]	0.495	[0.491, 0.499]	0.128	0.929	0.254	0.399	+0.016
LightGBM	B	0.731	[0.731, 0.731]	0.487	[0.487, 0.487]	0.148	0.909	0.259	0.403	+0.024
LightGBM	B + DMSP-OLS	0.737	[0.737, 0.737]	0.481	[0.481, 0.481]	0.126	0.888	0.271	0.415	+0.019
HistGradientBoosting	B	0.735	[0.735, 0.735]	0.494	[0.494, 0.494]	0.142	0.879	0.275	0.418	+0.017
HistGradientBoosting	B + DMSP-OLS	0.736	[0.736, 0.736]	0.487	[0.487, 0.487]	0.142	0.880	0.275	0.419	+0.018
Logística regularizada	B	0.739	[0.739, 0.739]	0.500	[0.500, 0.500]	0.350	0.890	0.270	0.414	+0.018
Logística regularizada	B + DMSP-OLS	0.739	[0.739, 0.739]	0.494	[0.494, 0.494]	0.350	0.888	0.273	0.417	+0.018

Nota: promedio de 5 semillas; IC95 % sobre las semillas. *Recall*, precisión y F1 se miden al umbral ya elegido para cada algoritmo y especificación por validación cruzada maximizando F_2 (Sección 4.5). Brecha CV: AUC de validación cruzada menos AUC en prueba; si agregar DMSP-OLS sobreajustara, se ensancharía frente a la especificación sin DMSP-OLS. Fuente: cálculos propios.

Tabla 21: Significancia del cambio de AUC-ROC al agregar DMSP-OLS, pobreza monetaria y multidimensional (IPM).

Algoritmo	Esp.	Δ AUC	IC95 %	p	p por comunidad
<i>Pobreza monetaria</i>					
XGBoost	A	-0.003	[-0.005, +0.001]	0.102	0.085
Random Forest	A	-0.002	[-0.006, +0.002]	0.258	—
LightGBM	A	-0.006	[-0.012, +0.001]	0.079	—
HistGradientBoosting	A	-0.000	[-0.003, +0.002]	0.800	0.802
Logística regularizada	A	-0.001	[-0.001, +0.000]	0.138	0.163
XGBoost	B	-0.002	[-0.005, +0.002]	0.266	0.308
Random Forest	B	-0.004	[-0.008, +0.000]	0.051	—
LightGBM	B	+0.006	[-0.001, +0.013]	0.078	—
HistGradientBoosting	B	+0.001	[-0.002, +0.003]	0.642	0.622
Logística regularizada	B	-0.001	[-0.001, +0.000]	0.138	0.154
<i>Pobreza multidimensional (IPM)</i>					
XGBoost	A	+0.013	[+0.004, +0.022]	0.006	0.004
Random Forest	A	+0.001	[-0.006, +0.008]	0.754	—
LightGBM	A	+0.004	[-0.001, +0.008]	0.091	—
HistGradientBoosting	A	-0.002	[-0.007, +0.004]	0.541	0.548
Logística regularizada	A	-0.000	[-0.001, +0.001]	0.934	0.954
XGBoost	B	+0.020	[+0.010, +0.030]	0.001	0.000
Random Forest	B	-0.004	[-0.012, +0.005]	0.429	—
LightGBM	B	+0.017	[+0.008, +0.026]	0.000	—
HistGradientBoosting	B	+0.002	[-0.004, +0.007]	0.595	0.569
Logística regularizada	B	-0.000	[-0.001, +0.001]	0.978	0.926

Nota: *bootstrap* pareado sobre el conjunto de prueba 2013→2016 (una semilla). p por comunidad: remuestreo agrupado por comunidad (1,696 comunidades), porque hogares de una misma comunidad comparten en buena medida el mismo píxel de luz nocturna (resolución de ~ 1 km); “—”: corrección no estimada. Fuente: cálculos propios.

A.7. Heterogeneidad del aporte de DMSP-OLS por subgrupos

Complemento de la Sección 5.3.2: cambio en el AUC-ROC al agregar DMSP-OLS por eje de heterogeneidad, grupo, especificación y algoritmo. Bajo pobreza monetaria el efecto nulo se mantiene parejo en los cuatro ejes explorados (Tabla 22); bajo IPM la ganancia se concentra en algunos subgrupos (Tabla 23).

Tabla 22: Δ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza monetaria. En **negrita**: $|\Delta| \geq 0.02$. Grupos con $n < 30$ omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios, `diagnostico_heterogeneidad_dmsp.csv` (`src/05_model/diagnostico_heterogeneidad_dmsp.py`).

Eje	Grupo	Esp.	n	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	1,170	-0.004	-0.008	-0.009	-0.003	-0.003
	Rural	B	1,170	-0.001	-0.007	+0.012	-0.000	-0.002
	Urbano	A	2,021	-0.003	+0.001	-0.006	+0.001	-0.000
	Urbano	B	2,021	-0.003	-0.004	+0.003	-0.001	-0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	798	-0.003	-0.006	+0.000	-0.002	-0.000
	Q1 (mas cerca de LP)	B	798	+0.002	-0.008	+0.004	+0.001	-0.000
	Q2	A	798	-0.001	+0.006	+0.006	+0.001	-0.001
	Q2	B	798	-0.001	-0.002	+0.011	+0.001	-0.001
	Q3	A	798	-0.007	-0.008	-0.019	-0.001	-0.002
	Q3	B	798	-0.006	-0.005	-0.000	-0.000	-0.002
	Q4 (mas lejos)	A	797	-0.005	+0.000	-0.022	-0.001	-0.001
	Q4 (mas lejos)	B	797	-0.011	-0.004	-0.011	-0.002	-0.000
Estrato	Estrato 1	A	903	-0.003	-0.001	-0.001	-0.005	-0.002
	Estrato 1	B	903	-0.002	-0.008	+0.018	+0.000	-0.002
	Estrato 2	A	1,390	-0.002	-0.002	-0.005	+0.004	+0.000
	Estrato 2	B	1,390	-0.004	+0.002	+0.004	+0.003	+0.000
	Estrato 3	A	741	-0.003	-0.001	-0.006	+0.000	-0.001
	Estrato 3	B	741	-0.007	-0.016	-0.009	-0.006	-0.001
Servicios y bienes	Tercil bajo	A	1,087	-0.005	-0.009	-0.007	-0.003	-0.003
	Tercil bajo	B	1,087	-0.004	-0.009	+0.013	-0.001	-0.003
	Tercil medio	A	1,121	+0.002	+0.002	-0.004	+0.001	+0.001
	Tercil medio	B	1,121	+0.004	-0.004	+0.008	+0.003	+0.001
	Tercil alto	A	983	-0.015	-0.005	-0.006	+0.001	-0.001
	Tercil alto	B	983	-0.017	-0.009	-0.005	-0.009	+0.000

Tabla 23: Δ AUC-ROC de agregar DMSP-OLS por subgrupo, pobreza multidimensional (IPM). En **negrita**: $|\Delta| \geq 0.02$. Grupos con $n < 30$ omitidos (no confiables). XGB=XGBoost, RF=Random Forest, LGBM=LightGBM, HGB=HistGradientBoosting, Log.=Logística regularizada. Fuente: cálculos propios, `diagnostico_heterogeneidad_ipm.csv` (`src/05_model/diagnostico_heterogeneidad_ipm.py`).

Eje	Grupo	Esp.	n	XGB	RF	LGBM	HGB	Log.
Zona	Rural	A	2,452	+0.012	+0.006	+0.010	+0.005	+0.001
	Rural	B	2,452	+0.019	+0.004	+0.032	+0.009	+0.001
	Urbano	A	3,119	+0.013	-0.002	+0.000	-0.005	-0.000
	Urbano	B	3,119	+0.018	-0.015	+0.008	-0.004	+0.000
Cercanía a LP	Q1 (mas cerca de LP)	A	1,393	+0.009	-0.005	+0.003	+0.003	-0.001
	Q1 (mas cerca de LP)	B	1,393	+0.015	+0.001	+0.012	+0.003	-0.001
	Q2	A	1,394	+0.024	-0.006	+0.010	-0.012	-0.000
	Q2	B	1,394	+0.039	-0.013	+0.032	-0.006	-0.000
	Q3	A	1,392	+0.025	+0.009	+0.002	+0.009	+0.003
	Q3	B	1,392	+0.025	-0.008	+0.030	+0.006	+0.003
	Q4 (mas lejos)	A	1,392	+0.013	+0.011	+0.003	-0.009	-0.004
	Q4 (mas lejos)	B	1,392	+0.019	-0.015	-0.008	+0.015	-0.003
Estrato	Estrato 1	A	2,046	+0.010	+0.002	+0.005	+0.004	-0.001
	Estrato 1	B	2,046	+0.018	+0.004	+0.024	-0.002	-0.001
	Estrato 2	A	2,439	+0.020	+0.003	+0.007	-0.008	+0.002
	Estrato 2	B	2,439	+0.027	-0.006	+0.015	+0.005	+0.002
	Estrato 3	A	889	-0.007	-0.006	-0.006	-0.005	+0.002
	Estrato 3	B	889	+0.005	-0.031	-0.003	+0.009	+0.003
Servicios y bienes	Tercil bajo	A	1,858	+0.014	+0.003	+0.008	+0.001	+0.001
	Tercil bajo	B	1,858	+0.021	-0.003	+0.030	+0.003	+0.000
	Tercil medio	A	1,977	+0.007	+0.004	+0.002	-0.006	+0.000
	Tercil medio	B	1,977	+0.018	-0.004	+0.019	-0.001	+0.000
	Tercil alto	A	1,736	+0.034	-0.001	+0.004	+0.001	+0.000
	Tercil alto	B	1,736	+0.033	-0.030	+0.009	+0.005	+0.000

A.8. Aporte de las tres fuentes geoespaciales juntas bajo pobreza monetaria

Complemento de la Sección 5.3.1: desempeño de los Modelos A y B al agregar las 127 variables de DMSP-OLS, ALOS PALSAR y Landsat 5 TM juntas, frente a los mismos

modelos sin variables geoespaciales, bajo el mismo esquema de validación cruzada.

Tabla 24: AUC-ROC y precisión en el decil de mayor riesgo, con y sin las 127 variables de las tres fuentes geoespaciales (DMSP-OLS, ALOS PALSAR y Landsat 5 TM), pobreza monetaria. Validación cruzada de 10 particiones dentro de la transición 2010→2013, media e IC95 % sobre 5 semillas.

Algoritmo	Especificación	N.º var.	AUC-ROC	IC95 %	Δ AUC	Precision top-10 %
XGBoost	A	169	0.766	[0.764, 0.767]	–	0.577
XGBoost	A + 3 fuentes	296	0.765	[0.763, 0.767]	-0.000	0.574
HistGradientBoosting	A	169	0.760	[0.757, 0.762]	–	0.583
HistGradientBoosting	A + 3 fuentes	296	0.757	[0.755, 0.759]	-0.003	0.560
Logística regularizada	A	169	0.760	[0.759, 0.761]	–	0.548
Logística regularizada	A + 3 fuentes	296	0.755	[0.753, 0.756]	-0.006	0.547
XGBoost	B	165	0.757	[0.755, 0.759]	–	0.563
XGBoost	B + 3 fuentes	292	0.756	[0.754, 0.757]	-0.001	0.581
HistGradientBoosting	B	165	0.753	[0.751, 0.755]	–	0.568
HistGradientBoosting	B + 3 fuentes	292	0.750	[0.749, 0.752]	-0.003	0.566
Logística regularizada	B	165	0.755	[0.753, 0.756]	–	0.544
Logística regularizada	B + 3 fuentes	292	0.751	[0.750, 0.753]	-0.004	0.557

Nota: ALOS PALSAR y Landsat 5 TM no tienen dato en 2013, por lo que esta variante no admite el holdout temporal de la Tabla 20: las métricas se calculan sobre probabilidades *out-of-fold* y son comparables entre sí, no contra esa tabla. Solo se estimaron los tres algoritmos mostrados. N.º var.: covariables que recibe el modelo. Fuente: cálculos propios.

A.9. Google Street View (exploratorio)

Complemento de las Secciones 3.2 y 6.3: resultados del diagnóstico exploratorio de las fotografías de Google Street View. La Tabla 25 mide qué tan bien predicen las representaciones de las fotos la luz nocturna de su zona y qué tan estables son entre olas; la Tabla 26, su cobertura y su relación con la caída en pobreza.

Tabla 25: Google Street View: predicción de la luz nocturna y estabilidad en el tiempo.

Modelo de imagen	R^2 , ventana 2011–2013	R^2 , ventana 2011–2015	Correlación entre olas
CLIP	0.699	0.737	+0.197
VGG19	0.634	0.709	-0.160
ResNet50	0.702	0.745	-0.152
Places365	0.738	0.771	+0.177

Nota: R^2 fuera de muestra de predecir la luz nocturna estable (DMSP-OLS) de la zona a partir de la representación de la foto ($n = 830$ hogares con la ventana original y $n = 1,280$ con la ampliada). Correlación entre olas: del primer componente de la representación para los mismos hogares ($n = 87$), comparable con 0.958 de la luz nocturna y 0.600 de los bienes durables. Fuente: cálculos propios.

Tabla 26: Google Street View: cobertura y relación con la caída en pobreza (exploratorio).

Indicador	Valor	n
<i>Luz nocturna media según cobertura de fotos</i>		
Sin foto	7.0	2,188
Con foto fuera de la ventana de fechas	42.0	5,407
Con foto dentro de la ventana (muestra usada)	42.3	830
<i>Caer en pobreza: regresión logística conjunta (IC95 %)</i>		
Primer componente de la foto (Places365)	+0.509 [+0.17, +0.86]	283
Luz nocturna	-0.049 [-0.35, +0.27]	283
<i>Caer en pobreza: AUC-ROC con validación cruzada</i>		
Solo fotos	0.619	443
Fotos y luz nocturna	0.612	443
Cambio (IC95 %)	-0.007 [-0.021, +0.006]	443

Nota: Hogares con foto dentro de la ventana de fechas: los que tienen una foto de Street View tomada cerca de la ola de 2013. No hay fotos anteriores a 2012, de modo que no es posible entrenar con 2010 y evaluar en 2016 como en el resto del documento: la regresión logística se estima sobre los hogares del conjunto de prueba con foto, y el AUC-ROC, con validación cruzada de 5 particiones dentro de esa muestra, con los primeros cinco componentes de Places365. Fuente: cálculos propios.

A.10. Cobertura de covariables por módulo

Complemento de las Secciones 3.1 y 3.3: auditoría de los módulos, reglas de agregación al nivel de hogar, candidatas auditadas, variables finalmente usadas en el modelo y cobertura sobre el panel para cada módulo de la ELCA.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta, replicada de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal ¿??" en lugar de vocales acentuadas y la letra ñ);

(ii) clasificación de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información.

Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno” cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar. Las tasas de mercado laboral se calcularon restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones) porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares que cumplen esa condición. La Tabla 27 resume las variables candidatas auditadas, las usadas en el modelo y la cobertura por módulo.

Tabla 27: Cobertura de covariables por módulo en el dataset consolidado

Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (%) del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	21	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría descrita arriba; “usadas en el modelo” es el subconjunto final tras la construcción de *features* – excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (ver “Bloque de *features* de Hogar”). No incluye llaves de identidad (p. ej. el consecutivo del hogar en Comunidades). Fuente: cálculos propios con base en ELCA 2010, 2013 y 2016.

El dataset consolidado de la ELCA (27,932 filas hogar×ola) reúne 177 variables finales: 164 provienen de los cinco módulos auditados en la Tabla 27, excluyendo de ese conteo *consecutivo_c*, que es la llave de unión al módulo Comunidades, no una covariable, y las 13 restantes forman un bloque monetario (ingreso, gasto, líneas de pobreza e indicadores de pobreza). Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario, consistente con que son los módulos que se preguntan a todo hogar sin condición previa (Tabla 27), mientras que Comunidades (21), Choques (17) y Niños (13) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra (Niños). De las 177, 155 (88 %) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas (los indicadores de pobreza monetaria). El desagregado por módulo y tipo de dato se muestra en la Figura 12, y por tema en la Tabla 28.




Figura 12: Inventario de las 177 variables finales del dataset consolidado de la ELCA, por módulo temático y tipo de dato. Fuente: cálculos propios.

Las mismas 177 variables, agrupadas por el tema que cubren en lugar del módulo de la ELCA del que provienen:

Tabla 28: Temas cubiertos por las 177 variables finales del dataset consolidado de la ELCA.

Tema	N.º	Ejemplos
Educación, empleo y seguridad social	27	nivel educativo y categoría ocupacional del jefe, cotización a pensión, tasa de ocupación del hogar
Comunidad	21	percepción de inseguridad, acceso a agua, puesto de salud, acciones del conflicto armado
Choques y afrontamiento	18	choques económicos, de salud o agropecuarios; afrontamiento erosivo; desastres naturales
Ayudas y redes de apoyo	18	ayudas de familiares en Colombia y el exterior, de ONG o de organizaciones religiosas; envío de ayudas
Vivienda: materiales y servicios	15	material de pisos y paredes, servicio sanitario, tenencia, escritura de la vivienda
Composición del hogar	14	niños menores de 12 años, adultos mayores, razón de dependencia, sexo, edad, etnia y estado civil del jefe
Ingreso y gasto	13	ingreso y gasto per cápita real, brechas frente a la LP, indicadores de pobreza
Activos del hogar	13	bienes durables, índice de riqueza (PCA), estrato, vehículo, ahorro
Desarrollo infantil (6–9 años)	12	vacunación, talla y peso, oficios y trabajo infantil, puntaje TVIP
Salud	10	afiliación a salud, hospitalización, discapacidad, controles preventivos
Programas sociales y deuda	8	Familias en Acción, Red Juntos, apoyo alimentario escolar, deuda formal e informal
Participación y capital social	5	participación en organizaciones, participación cívica, práctica religiosa
Vivienda: hacinamiento	3	personas por cuarto y por dormitorio, valor del arriendo
Total	177	

Nota: clasificación temática propia, independiente del módulo de la ELCA del que proviene cada variable; los temas son los mismos que agrupan las tablas de perfil. No incluye las variables geoespaciales (Anexo B.1). Fuente: cálculos propios con base en ELCA 2010, 2013 y 2016.

A.11. Composición del panel y atrición

Complemento de la Sección 3.3: evolución del número de hogares únicos por ola, tasas de pérdida de hogares entre olas y división de hogares.

El panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016. Esto es una atrición de 11.4% entre 2010 y 2013 y de 11.4% entre 2013 y 2016 (hogares presentes en una ola que no aparecen en la siguiente). La caída neta entre 2013 y 2016 es menor (7.4%) porque 351 hogares que no se encontraron en 2013 volvieron a ser encuestados en 2016. La pérdida acumulada entre 2010 y 2016 es de 17.9%

(Figura 13). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2% de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8% de los rurales), lo opuesto al posible supuesto de que la atrición rural sería mayor por dificultad de rastreo geográfico, probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales (desagregado por zona, estrato y región en el Anexo A.2).

Existe también un fenómeno de división de hogares: 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016. Esto ocurre porque un hijo formó su propio hogar en la misma vivienda o predio o en un predio diferente. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. Estos hogares divididos se excluyeron del análisis para no realizar supuestos adicionales sobre su composición, vulnerabilidad y covariables.




Figura 13: Izquierda: hogares únicos por ola. Derecha: tasa de pérdida de hogares entre olas consecutivas y acumulada 2010–2016. Fuente: cálculos propios.

A.12. Matriz de confusión del Modelo B

Complemento de la Sección 5.1.2: la misma matriz de confusión de la Tabla 3, para el Modelo B (sin ingreso ni gasto).

Tabla 29: Matriz de confusión del Modelo B en el conjunto de prueba (2013→2016), pobreza monetaria e IPM.

Algoritmo	Monetaria				IPM			
	VP	FP	FN	VN	VP	FP	FN	VN
Random Forest	573 (18 %)	1559 (49 %)	62 (2 %)	997 (31 %)	414 (7 %)	2120 (38 %)	128 (2 %)	2909 (52 %)
XGBoost	594 (19 %)	1770 (55 %)	41 (1 %)	786 (25 %)	513 (9 %)	3690 (66 %)	29 (1 %)	1339 (24 %)
Logística regularizada	573 (18 %)	1575 (49 %)	62 (2 %)	981 (31 %)	399 (7 %)	2055 (37 %)	143 (3 %)	2974 (53 %)
HistGradientBoosting	541 (17 %)	1358 (43 %)	94 (3 %)	1198 (38 %)	342 (6 %)	1507 (27 %)	200 (4 %)	3522 (63 %)
LightGBM	576 (18 %)	1622 (51 %)	59 (2 %)	934 (29 %)	397 (7 %)	1982 (36 %)	145 (3 %)	3047 (55 %)

Nota: VP, FP, FN y VN: hogares verdadero positivo, falso positivo, falso negativo y verdadero negativo.

Entre paréntesis, porcentaje sobre el total de la fila para cada definición de pobreza (monetaria, $n = 3,191$; IPM, $n = 5,571$). Modelos clasificados con los hiperparámetros y el umbral reportados en la Tabla 32 del Anexo A.14. Corresponde a una sola corrida de cada modelo, por lo que el *recall* y la precisión que se derivan de ella difieren levemente de los promedios de 5 semillas de la Tabla 2.

Fuente: cálculos propios.

A.13. Modelo multiclase

Complemento de las Secciones 5.2 (Tercer hallazgo) y 5.3.1: especificación y desempeño del modelo multiclase mencionado en la Sección 4.1 y AUC-ROC por par de grupos de la matriz de transición, con y sin las variables de DMSP-OLS. Los hiperparámetros se reportan en la Tabla 32 del Anexo A.14.

Si bien se hizo un ejercicio de predicción multiclase con los cuatro grupos y todos los hogares del panel, este no es el principal por cuatro razones. Primero, la pregunta de vulnerabilidad se refiere a quiénes, entre los hogares hoy no pobres, caerán en pobreza. Segundo, con el ingreso entre las covariables, el modelo separa los grupos de forma trivial según la condición de pobreza en la ola base. Tercero, sin el ingreso, el modelo casi no identifica a quienes entran en pobreza: asigna a cada hogar su grupo más probable, sin un umbral que se pueda ajustar como en el modelo binario, y esta clase, la más pequeña, queda absorbida por las demás. Cuarto, se construyó con un propósito más acotado, como diagnóstico: comprobar si quienes entran en pobreza se distinguen de quienes salen, algo que el modelo binario no puede responder (Sección 5.2). El modelo multiclase usa los mismos cinco algoritmos y, además, una red neuronal (perceptrón multicapa), sobre los cuatro grupos de la matriz de transición y sin ingreso ni gasto entre las covariables (Modelo B). Sigue el mismo esquema de validación que el modelo binario (Sección 4.4): entrenamiento en 2010→2013, prueba en 2013→2016 y búsqueda de hiperparámetros y de estrategia de balanceo por validación cruzada. Para medir si dos grupos se distinguen se usa el AUC-ROC por par: se restringe la muestra a los hogares de esos dos grupos y se toma como puntaje la probabilidad que el modelo asigna al primero.

Tabla 30: Desempeño del modelo multiclase (cuatro grupos) en el conjunto de prueba.

Algoritmo	Balanceo	Exactitud	Exactitud balanceada	F1 macro	AUC-ROC macro	AUC entra vs. resto	Recall entra	Prec.-top10 entra
XGBoost	ninguno	0.582	0.426	0.384	0.732	0.596	0.002	0.111
LightGBM	ninguno	0.573	0.422	0.385	0.730	0.593	0.002	0.116
HistGradientBoosting	ninguno	0.577	0.424	0.384	0.731	0.599	0.002	0.114
Random Forest	ninguno	0.574	0.412	0.344	0.727	0.601	0.000	0.119
Red neuronal (MLP)	ninguno	0.557	0.412	0.376	0.713	0.591	0.008	0.125
Logística regularizada	ninguno	0.545	0.398	0.348	0.703	0.576	0.005	0.127

Nota: Modelo B (sin ingreso ni gasto), entrenado en 2010→2013 y evaluado en 2013→2016 ($n = 6,911$ hogares de los cuatro grupos), promedio de 5 semillas. El modelo asigna a cada hogar el grupo más probable, sin umbral ajustable, de modo que casi nunca asigna “entra”, el grupo más pequeño (*recall* cercano a cero); por eso se usa como diagnóstico y no como modelo principal. Prec.-top10 entra: fracción de hogares que efectivamente entran en pobreza entre el 10 % con mayor probabilidad de “entra”. Hiperparámetros en la Tabla 32. Fuente: cálculos propios.

Tabla 31: AUC-ROC del modelo multiclase por par de grupos de la matriz de transición.

Algoritmo	Nunca vs. siempre	Nunca vs. entra	Nunca vs. sale	Entra vs. siempre	Sale vs. siempre	Entra vs. sale
<i>AUC-ROC, Modelo B</i>						
XGBoost	0.927	0.752	0.830	0.676	0.595	0.534
LightGBM	0.927	0.754	0.829	0.685	0.603	0.543
HistGradientBoosting	0.925	0.752	0.824	0.675	0.605	0.545
Random Forest	0.919	0.749	0.813	0.702	0.611	0.541
Red neuronal (MLP)	0.910	0.743	0.820	0.685	0.613	0.554
Logística regularizada	0.896	0.734	0.806	0.688	0.629	0.562
<i>Cambio al agregar DMSP-OLS</i>						
XGBoost	-0.000	+0.001	-0.001	+0.005	+0.013	+0.011
LightGBM	+0.000	-0.003	+0.003	+0.013	+0.011	+0.009
HistGradientBoosting	-0.000	-0.004	+0.004	-0.008	-0.003	-0.006
Random Forest	-0.002	-0.004	-0.002	-0.008	-0.004	-0.006
Red neuronal (MLP)	-0.002	-0.004	-0.002	+0.023	+0.010	+0.005
Logística regularizada	+0.000	-0.001	+0.001	-0.001	-0.003	+0.002

Nota: AUC-ROC de cada par de grupos: se restringe a los hogares de los dos grupos y se usa como puntaje la probabilidad que el modelo asigna al primero. Modelo B, conjunto de prueba 2013→2016, una sola corrida (semilla 42). El modelo separa bien los extremos (nunca frente a siempre pobre), pero casi no separa a quienes entran de quienes salen de la pobreza. El panel inferior es la diferencia entre el mismo modelo con las 23 variables de DMSP-OLS y sin ellas. Fuente: cálculos propios.

A.14. Hiperparámetros de los modelos reportados

Complemento de las Secciones 4.3 y 4.4: descripción de los algoritmos y sus hiperparámetros finales.

Descripción de los algoritmos. Los cinco algoritmos se agrupan en dos familias según cómo tratan las variables categóricas y los datos faltantes (Sección 4.5):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla (l_1_ratio) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge. Es el algoritmo designado como referencia por ser interpretable y por servir de punto de comparación antes de justificar el uso de un modelo más complejo. Es también el más sensible a la multicolinealidad entre covariables; se evaluó explícitamente ese riesgo mediante un análisis de correlación de Pearson entre las 159 variables numéricas del consolidado, con 35 pares por encima de $|r| = 0.7$ (incluida una correlación fuerte de `dmsp_stable_lights` con `lp` y `n_servicios_publicos_hogar`, retomada en la Sección 5.3.1; detalle completo en el Apéndice A.1). La regularización ℓ_1/ℓ_2 mitiga, pero no elimina, la varianza inflada de coeficientes individuales cuando varias variables de un mismo grupo redundante entran juntas al modelo.
- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad. Los tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding*.

Hiperparámetros. La Tabla 32 reporta los hiperparámetros finales, estrategia de balanceo de clases y umbral de clasificación (promedio de las cinco semillas) elegidos por validación cruzada para todos los modelos cuyos resultados se reportan en el documento. Los análisis SHAP, de heterogeneidad y de *bootstrap* usan estos mismos modelos. Varias especificaciones de un mismo algoritmo comparten hiperparámetros porque la búsqueda

aleatoria usa una semilla fija: prueba las mismas 30 combinaciones en cada especificación, y a menudo gana la misma.

Tabla 32: Hiperparámetros finales, estrategia de balanceo y umbral de clasificación de todos los modelos reportados.

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
Pobreza monetaria, holdout temporal				
Logística regularizada	A	balanced	0.37	$C = 0.00603$; $l1_ratio = 0.156$
Logística regularizada	B	balanced	0.35	$C = 0.00603$; $l1_ratio = 0.156$
Logística regularizada	A + DMSP	balanced	0.37	$C = 0.00603$; $l1_ratio = 0.156$
Logística regularizada	B + DMSP	balanced	0.35	$C = 0.00603$; $l1_ratio = 0.156$
Random Forest	A	ninguno	0.14	$max_depth = 11$; $max_features = 0.228$; $min_samples_leaf = 20$; $n_estimators = 334$
Random Forest	B	balanced	0.31	$max_depth = 11$; $max_features = 0.228$; $min_samples_leaf = 20$; $n_estimators = 334$
Random Forest	A + DMSP	balanced	0.26	$max_depth = 8$; $max_features = 0.234$; $min_samples_leaf = 25$; $n_estimators = 493$
Random Forest	B + DMSP	balanced	0.27	$max_depth = 12$; $max_features = 0.259$; $min_samples_leaf = 21$; $n_estimators = 291$
XGBoost	A	ninguno	0.11	$colsample_bytree = 0.885$; $learning_rate = 0.0165$; $max_depth = 3$; $n_estimators = 286$; $reg_lambda = 1.66$; $subsample = 0.801$
XGBoost	B	ninguno	0.13	$colsample_bytree = 0.885$; $learning_rate = 0.0165$; $max_depth = 3$; $n_estimators = 286$; $reg_lambda = 1.66$; $subsample = 0.801$
XGBoost	A + DMSP	ninguno	0.12	$colsample_bytree = 0.885$; $learning_rate = 0.0165$; $max_depth = 3$; $n_estimators = 286$; $reg_lambda = 1.66$; $subsample = 0.801$
XGBoost	B + DMSP	ninguno	0.13	$colsample_bytree = 0.885$; $learning_rate = 0.0165$; $max_depth = 3$; $n_estimators = 286$; $reg_lambda = 1.66$; $subsample = 0.801$

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
LightGBM	A	ninguno	0.10	learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32
LightGBM	B	ninguno	0.15	learning_rate = 0.0111; max_depth = 4; min_child_samples = 30; n_estimators = 143; num_leaves = 48; reg_lambda = 0.617
LightGBM	A + DMSP	ninguno	0.10	learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32
LightGBM	B + DMSP	ninguno	0.13	learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15
HistGradientBoosting	A	balanced	0.32	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	A + DMSP	balanced	0.31	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B + DMSP	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
IPM, holdout temporal				
Logística regularizada	A	ninguno	0.10	C = 0.0362; l1_ratio = 0.52
Logística regularizada	B	ninguno	0.11	C = 0.0362; l1_ratio = 0.52
Logística regularizada	A + DMSP	ninguno	0.11	C = 0.0362; l1_ratio = 0.52
Logística regularizada	B + DMSP	ninguno	0.11	C = 0.0362; l1_ratio = 0.52
Random Forest	A	balanced	0.31	max_depth = 14; max_features = 0.567; min_samples_leaf = 13; n_estimators = 544
Random Forest	B	balanced	0.26	max_depth = 14; max_features = 0.273; min_samples_leaf = 9; n_estimators = 234

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
Random Forest	A + DMSP	ninguno	0.12	max_depth = 9; max_features = 0.387; min_samples_leaf = 25; n_estimators = 492
Random Forest	B + DMSP	ninguno	0.11	max_depth = 12; max_features = 0.259; min_samples_leaf = 21; n_estimators = 291
XGBoost	A	ninguno	0.11	colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658
XGBoost	B	ninguno	0.09	colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658
XGBoost	A + DMSP	ninguno	0.10	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B + DMSP	ninguno	0.11	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
LightGBM	A	ninguno	0.11	learning_rate = 0.013; max_depth = 5; min_child_samples = 26; n_estimators = 383; num_leaves = 16; reg_lambda = 1.77
LightGBM	B	ninguno	0.08	learning_rate = 0.0357; max_depth = 7; min_child_samples = 19; n_estimators = 206; num_leaves = 22; reg_lambda = 1.58
LightGBM	A + DMSP	ninguno	0.10	learning_rate = 0.013; max_depth = 5; min_child_samples = 26; n_estimators = 383; num_leaves = 16; reg_lambda = 1.77
LightGBM	B + DMSP	ninguno	0.10	learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15
HistGradientBoosting	A	ninguno	0.11	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42
HistGradientBoosting	B	ninguno	0.10	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
HistGradientBoosting	A + DMSP	ninguno	0.10	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42
HistGradientBoosting	B + DMSP	ninguno	0.10	l2_regularization = 4.38; learning_rate = 0.0836; max_depth = 3; max_iter = 233; max_leaf_nodes = 42
Tres fuentes geoespaciales, validación cruzada (2010→2013)				
Logística regularizada	A	balanced	0.37	C = 0.00603; l1_ratio = 0.156
Logística regularizada	B	balanced	0.35	C = 0.00603; l1_ratio = 0.156
Logística regularizada	A + 3 fuentes	oversampling	0.37	C = 0.00277; l1_ratio = 0.196
Logística regularizada	B + 3 fuentes	ninguno	0.14	C = 0.00811; l1_ratio = 0.183
XGBoost	A	ninguno	0.11	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	A + 3 fuentes	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
XGBoost	B + 3 fuentes	ninguno	0.13	colsample_bytree = 0.885; learning_rate = 0.0165; max_depth = 3; n_estimators = 286; reg_lambda = 1.66; subsample = 0.801
HistGradientBoosting	A	balanced	0.32	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	A + 3 fuentes	balanced	0.32	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58

Algoritmo	Espec.	Balanceo	Umbral	Hiperparámetros
HistGradientBoosting	B + 3 fuentes	ninguno	0.14	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
Multiclase (cuatro grupos)				
Logística regularizada	A	ninguno	–	C = 0.0746; l1_ratio = 0.951
Logística regularizada	B	ninguno	–	C = 0.0746; l1_ratio = 0.951
Random Forest	A	ninguno	–	max_depth = 11; max_features = 0.228; min_samples_leaf = 20; n_estimators = 334
Random Forest	B	ninguno	–	max_depth = 12; max_features = 0.27; min_samples_leaf = 8; n_estimators = 400
XGBoost	A	ninguno	–	colsample_bytree = 0.621; learning_rate = 0.0258; max_depth = 3; n_estimators = 484; reg_lambda = 0.301; subsample = 0.658
XGBoost	B	ninguno	–	colsample_bytree = 0.824; learning_rate = 0.0368; max_depth = 5; n_estimators = 356; reg_lambda = 2.78; subsample = 0.694
LightGBM	A	ninguno	–	learning_rate = 0.0258; max_depth = 3; min_child_samples = 5; n_estimators = 225; num_leaves = 16; reg_lambda = 1.15
LightGBM	B	ninguno	–	learning_rate = 0.0785; max_depth = 4; min_child_samples = 43; n_estimators = 140; num_leaves = 42; reg_lambda = 5.32
HistGradientBoosting	A	ninguno	–	l2_regularization = 2.55; learning_rate = 0.0129; max_depth = 3; max_iter = 228; max_leaf_nodes = 58
HistGradientBoosting	B	ninguno	–	l2_regularization = 2.58; learning_rate = 0.0189; max_depth = 5; max_iter = 227; max_leaf_nodes = 42
Red neuronal (MLP)	A	ninguno	–	alpha = 0.0207; hidden_layer_sizes = (64); learning_rate_init = 0.00852
Red neuronal (MLP)	B	ninguno	–	alpha = 3.08e-05; hidden_layer_sizes = (128, 64); learning_rate_init = 0.00464

B. Detalles de construcción de variables geoespaciales

B.1. Qué mide cada fuente geoespacial

Complemento de la Sección 3.2: para las tres fuentes incorporadas (DMSP-OLS, ALOS PALSAR y Landsat 5 TM), el mecanismo físico de medición, las variables principales construidas y la interpretación que se les da en este estudio.

Tabla 33: Qué mide cada fuente nueva, qué variables construye, y qué aproxima cada una.

Fuente	Mecanismo físico	Variables (estado / ventana acum.)	Qué aproxima
DMSP-OLS (23 var.: 5 estado + 18 acum.)	Radiancia visible nocturna captada por satélite (alumbrado público, vivienda, comercio)	Estado: nivel, log, saturación Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code>)	Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)
ALOS PALSAR (52 var.: 7 estado + 45 acum.)	Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación	Estado: HH, HV (dB), razón HH/HV, índice normalizado Acumulada: media, tendencia, crecimiento de cada una	Densidad y consolidación del entorno construido vs. vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)
Landsat 5 TM (52 var.: 16 estado + 36 acum.)	Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta)	Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices) Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo	Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada)

Nota: las especificaciones principales (Modelos A y B con DMSP-OLS, holdout temporal) agregan solo las 23 variables de DMSP-OLS; la variante con las tres fuentes agrega las 127, evaluada con validación cruzada dentro de 2010→2013 (Tabla 24). Cada variable de ventana acumulada se resume en nueve estadísticos: media, desviación estándar, mínimo, máximo, rango, coeficiente de variación, tendencia, crecimiento acumulado y número de años con dato. Se excluyen las variables de cambio entre olas (movimiento del hogar, crecimiento 2010–2013), que no están definidas en la ola base. Fuente: cálculos propios.

B.2. Cobertura temporal de las fuentes evaluadas

Complemento de la Sección 3.2: ventana de disponibilidad de las siete fuentes geoespaciales evaluadas frente a las tres olas de la ELCA, y criterios con los que se seleccionaron.

Se requirió obtener información geoespacial para al menos dos olas: la transición 2010→2013, que es la ola en la que se entrenan los modelos que predicen la transición a la pobreza, y la transición 2013→2016 que se usa posteriormente para probar el poder predictivo de esas mismas variables en una ola donde no se usaron para entrenar el modelo. Es decir, fuera de muestra (Sección 4.1).

Además de la disponibilidad de fotos de nivel de calle (Google Street View), se evaluaron seis fuentes satelitales: Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales todavía no operaban). Se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017). Por esta razón, las tres fuentes que finalmente se incluyeron en este artículo fueron: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura anterior a 2014.

La Figura 14 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA, JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los hogares en las tres olas de la ELCA (2010, 2013, 2016).

El resultado de la consulta de la información geoespacial sobre las tres fuentes disponibles es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013 y es la única de las tres con esa cobertura completa en dos olas. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014, es decir, no tiene ninguna cobertura de 2013. Landsat 5 TM cubre solo 65.5 % de los hogares en 2010 (6,269 de 9,573; del resto no se obtuvo información por nubosidad persistente, una limitación conocida del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría una cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth Engine confirmó que el sensor dejó de adquirir información utilizable antes de esa fecha. Por lo tanto, estas tres fuentes se incorporaron al

proyecto pero solo DMSP-OLS sirvió como fuente principal en el marco del análisis.

Se hizo un ejercicio adicional con Google Street View, que es la fuente de información geoespacial más cercana a la experiencia humana de observación del entorno, y que podría capturar información relevante para la predicción de vulnerabilidad a la pobreza. Sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente: no se encontró ninguna foto para los hogares de la ELCA que se hubiera tomado antes de 2012 y el 61 % de las fotos disponibles se habían tomado posterior a 2023. Por esta razón, se decidió no incluirla en el análisis principal, aunque se tuvo en cuenta para la construcción de variables geoespaciales complementarias y para la discusión de resultados (Anexo A.9).




Figura 14: Cobertura temporal real de cada fuente geoespacial evaluada, frente a las tres olas de la ELCA con coordenadas disponibles. El patrón diagonal indica corrida real y completa sobre hogares del estudio; el resto se revisó cobertura según catálogo. En la barra de GSV, la intensidad del color es proporcional a la densidad real de fotos por año —la gran mayoría de las fotos son de 2023 en adelante.