

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal de Colombia (ELCO)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización de programas sociales en Colombia, como el SISBEN, identifican pobreza como un estado observado y no anticipan qué hogares no pobres tienen mayor riesgo de caer en esa condición. Este trabajo evalúa si información pública, particularmente, características del entorno físico y económico local, mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Usando tres olas del panel (2010, 2013, 2016), se construye la variable de resultado como la entrada en pobreza de hogares inicialmente no pobres y se estiman distintos algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting), evaluando su capacidad predictiva en un período posterior al utilizado para su estimación: los modelos se entrenan con las transiciones observadas entre 2010 y 2013 y se evalúan con las transiciones entre 2013 y 2016. Este esquema permite evaluar el desempeño de los modelos en datos temporalmente posteriores a aquellos utilizados para su entrenamiento, aproximándose a su capacidad para anticipar transiciones futuras hacia la pobreza. Los modelos se estiman con y sin variables monetarias del hogar. El modelo base, que es lo que se reporta en esta versión del documento, alcanza

un AUC-ROC entre 0.727 y 0.764 según el algoritmo, con una brecha de apenas 0.008–0.031 entre la especificación que incluye ingreso/gasto del hogar y la que no lo hace, lo que sugiere que las covariables no monetarias capturan una fracción sustancial del poder predictivo típicamente atribuido al ingreso. La incorporación de las variables geoespaciales, contribución central de esta tesis, está en construcción. De confirmarse un aporte incremental, los resultados podrían fortalecer instrumentos de focalización con información de mayor frecuencia y menor costo de actualización que las encuestas de hogares tradicionales.

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geoespaciales, ELCA, focalización, Colombia.

Índice

1. Introducción	5
2. Marco conceptual y revisión de literatura	6
2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales	6
2.2. Aprendizaje de máquinas en la predicción de pobreza	8
2.3. Variables geoespaciales como fuente complementaria	9
2.4. Síntesis y vacío que llena este trabajo	10
3. Datos	11
3.1. Encuesta Longitudinal Colombiana (ELCA)	11
3.2. Fuentes geoespaciales	12
3.2.1. Qué mide cada fuente y qué variables se construyen	14
3.3. Estadísticas descriptivas	17
3.3.1. Estadísticas descriptivas de las fuentes geoespaciales	18
3.3.2. Composición del panel y atrición	19
3.3.3. Inventario temático de las variables finales	20
3.3.4. Comportamiento por ola y cambios en el periodo	21
3.3.5. Perfil de los hogares analizados	24
3.3.6. Correlación entre covariables y riesgo de multicolinealidad	26
4. Estrategia empírica	27
4.1. Construcción de la variable de resultado	27
4.2. Especificación de modelos	28
4.3. Validación fuera de muestra y métricas	29
4.4. Tratamiento del desbalance de clases	30
4.5. Importancia de variables e interpretabilidad	31
5. Resultados	32
5.1. Dinámica de transiciones a la pobreza en la ELCO	32
5.1.1. Incidencia de pobreza y matrices de transición	32
5.1.2. Ejercicios de robustez	35
5.2. Desempeño comparativo de modelos	39
5.3. Contribución marginal de las variables geoespaciales	43
5.4. Heterogeneidad territorial	48

6. Conclusiones	48
6.1. Síntesis de hallazgos	48
6.2. Implicaciones para la política pública	49
6.3. Limitaciones y agenda de investigación	50
Referencias	51
A. Tablas y figuras complementarias	54
B. Detalles de construcción de variables geoespaciales	54

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juárez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Beneficiarios de Programas Sociales (SISBEN) opera a través de una encuesta cuya aplicación depende de la solicitud de los hogares y de los recursos de la entidad territorial responsable, lo que genera rezagos en la actualización de la información y dificulta contar con datos recientes sobre el efecto de choques (Consejo Nacional de Política Económica y Social, 2016). La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y ejercicios recientes de aproximación a la vulnerabilidad monetaria en Bogotá mediante pseudo-panel confirman tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Castañeda Castrillón, 2012; Gaitán, 2023).

Esta tesis aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza monetaria. Este abordaje es distinto al de la literatura de la pobreza contemporánea que predice la mayoría de la literatura de aprendizaje de máquinas aplicada a este problema (Ferdausi et al., 2025; Muñetón et al., 2022)–. La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View mejora la predicción de caída en pobreza monetaria de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del

hogar reportadas en encuestas?

El estado actual de este documento cubre la primera mitad de esa pregunta: la construcción rigurosa de la variable de resultado, la auditoría exhaustiva de las covariables socioeconómicas disponibles en la ELCA (más de 4.000 columnas originales revisadas variable por variable a través de cinco módulos), y la estimación y comparación de cinco algoritmos de aprendizaje supervisado: regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting– sobre el modelo *base* (sin variables geoespaciales). La incorporación de las fuentes geoespaciales y la comparación frente al modelo extendido, que es la contribución central de la pregunta de investigación, está en construcción y se documenta como trabajo en curso en la Sección 6.3.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema no abordado directamente por la literatura existente aplicada al país.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje de máquinas aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla la estrategia empírica: construcción del outcome, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados obtenidos hasta el momento. La Sección 6 cierra con una síntesis, implicaciones de política y la agenda de trabajo pendiente.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria suele originarse en fluctuaciones del ingreso asociadas

con choques económicos (ej. pérdida de empleo, caídas en precios) o eventos adversos (ej. desastres naturales, conflictos). Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto al mostrar que en muchos países en desarrollo existe una población significativa de hogares no pobres pero altamente expuestos: su situación actual los ubica por encima de la línea de pobreza, pero su fragilidad patrimonial los hace vulnerables a caer ante afectaciones moderadas. Esta población es precisamente la que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010; Costella et al., 2023).

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juárez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 5.1 de esta tesis. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado

de pobreza.

En el contexto colombiano, la aplicación de estos enfoques ha enfrentado restricciones de datos que han limitado su alcance. Castañeda Castrillón (2012) estudió las trampas de pobreza mediante la construcción de un pseudo-panel, y Gaitán (2023) analizó la vulnerabilidad monetaria a nivel de localidades en Bogotá con el mismo enfoque, como una manera para superar la ausencia de un panel de hogares con representatividad y cobertura suficiente; sus resultados –cerca del 23 % de la población bogotana en situación de vulnerabilidad en 2021– confirman la relevancia del problema, pero también evidencian las restricciones que impone el uso de cortes transversales repetidos en lugar de datos longitudinales reales. La disponibilidad de la ELCA, con tres olas de seguimiento a los mismos hogares, ofrece una oportunidad inédita para superar esta limitación en el contexto colombiano. Incluso con datos longitudinales, sin embargo, esta literatura enfrenta una restricción operativa adicional: los métodos desarrollados dependen, casi sin excepción, de encuestas de hogares con información detallada sobre ingresos, activos y consumo, costosas, de levantamiento infrecuente y con rezagos significativos entre la recolección y la disponibilidad de los datos. Esta restricción informacional es la que motiva la exploración de fuentes alternativas de datos que puedan aproximar la vulnerabilidad con mayor frecuencia de actualización y menor costo de recolección (Sección 2.3).

2.2. Aprendizaje de máquinas en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su desarrollo ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación

cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar sustancialmente la precisión de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando la precisión balanceada en hasta 17 puntos porcentuales frente a los métodos tradicionales. Siguiendo esta perspectiva, esta tesis evalúa el desempeño de los modelos fuera de la muestra mediante un *holdout* temporal hacia adelante: los modelos se entrenan con información de períodos anteriores y se evalúan con información de un período posterior. De esta manera, la validación permite aproximarse mejor a la situación en la que el modelo se utilizaría en la práctica, es decir, para predecir la vulnerabilidad de hogares en un período futuro (Sección 4.3). Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2025) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema, logrando una precisión del 96 % con un conjunto reducido de siete variables. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza al resto de la literatura. En Colombia, Muñetón et al. (2022) han aplicado aprendizaje de máquinas a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital, mostrando que la combinación de imágenes satelitales con datos de encuesta permite explicar hasta el 75 % de la variación en consumo o riqueza en contextos africanos, superando lo que cualquiera de las dos fuentes logra de manera aislada. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con precisiones superiores al 82 %, aunque advierten que su capacidad discriminatoria se reduce en contextos de

pobreza muy extendida, donde la variabilidad espacial de las imágenes es insuficiente para distinguir entre hogares con distintos niveles de privación.

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran que la combinación de datos satelitales y de telefonía móvil reduce los errores de exclusión en programas sociales entre 4 % y 21 % frente a los métodos tradicionales. Hall et al. (2023), en una revisión sistemática, documentan que la combinación de múltiples fuentes incrementa el poder predictivo hasta en 15 puntos porcentuales, pero identifican que los datos geoespaciales predicen mejor activos físicos que variables de flujo como ingreso o consumo, y que su desempeño depende críticamente del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que esta tesis busca incorporar (sección 3.2).

2.4. Síntesis y vacío que llena este trabajo

La evidencia revisada muestra que los modelos que combinan variables geoespaciales con información socioeconómica de encuestas superan a los basados exclusivamente en cualquiera de las dos fuentes, con ventajas más pronunciadas cuando la validación se realiza fuera de muestra. Sin embargo, ninguno de los trabajos revisados aborda directamente el problema de predecir la probabilidad de caída en pobreza de hogares actualmente no pobres, y mucho menos en un contexto de datos longitudinales de hogar como el que ofrece la ELCA. Predecir transiciones hacia la pobreza es un problema conceptualmente distinto al de estimar pobreza contemporánea: requiere una variable de resultado definida en términos prospectivos, un horizonte temporal explícito entre olas de panel, y un conjunto de variables predictoras que capture tanto las condiciones del hogar como las del entorno en el momento previo a la transición.

Es en esta brecha donde esta investigación busca contribuir, evaluando si la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View a los datos longitudinales de la ELCA permite mejorar la identificación de hogares en riesgo de caer en pobreza en Colombia. Es importante señalar que, en contextos de política pública, la predicción es valiosa incluso en ausencia de interpretación causal Kleinberg et al.

(2015), especialmente porque el objetivo es mejorar la focalización *ex ante* de la política social. Por esta razón, este trabajo se sitúa en un enfoque predictivo más que causal, donde el objetivo no es identificar efectos estructurales sino mejorar la capacidad de anticipar transiciones hacia la pobreza con miras a mejorar la focalización de políticas públicas de seguridad social.

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCA)

La fuente primaria de datos es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares en tres olas: 2010, 2013 y 2016, en zonas urbana y rural. La ELCA se organiza en en módulos temáticos: hogar, personas, niños, comunidades y choques, además de los módulos de activos y gasto. El identificador de hogar cambia de nombre entre olas (`consecutivo`→`llave`→`llave_n16`). Para los análisis realizados en esta tesis, se usan exclusivamente coincidencias uno a uno de este identificador entre olas consecutivas, excluyendo los hogares que se dividieron en dos o más sub-hogares (511 casos entre 2010–2013 y 1,190 entre 2013–2016, ver Tabla 4), para no hacer supuestos reespecto de su ubicación entre hogares divididos.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta. La auditoría tuvo cuatro capas, replicadas de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal `¿??`" en lugar de vocales acentuadas y la letra ñ); (ii) clasificación exhaustiva de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información evitable.

El resultado es un panel hogar x ola consolidado de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas, que combinan las covariables construidas a partir de los módulos con las variables monetarias (ingreso y gasto per cápita del hogar, nominal y real, y brecha frente a la línea de pobreza). Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas explícitas y documentadas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno” cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano

disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar cuando la literatura lo usa como proxy estándar. Las tasas de mercado laboral se calculan restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

3.2. Fuentes geoespaciales

Este trabajo utiliza información geoespacial disponible públicamente y de manera gratuita como proxy de las condiciones espaciales del entorno y la infraestructura. La idea es que la información geoespacial de los hogares puede capturar características del entorno físico y económico local que afectan la vulnerabilidad de estos hogares a caer en pobreza, pero que no se refleja completamente en las encuestas tradicionales que realizan gobiernos y otras organizaciones. Para esto, a partir de las coordenadas de los hogares de la ELCA, que se encuentran para consulta de manera estrictamente controlada y restringida por parte de la Universidad de los Andes, se consolida la información geoespacial disponible en línea a través de consultas a la API de Google Earth Engine. Esta información se anexa a la base de datos de la ELCA para cada hogar, y se utiliza como covariable adicional en los modelos predictivos de transición hacia la pobreza.

La necesidad fundamental de este proyecto es tener información geoespacial para al menos dos olas: 2010 es la ola para la que se entrenan los modelos que predicen la transición a la pobreza —el ejercicio central de esta tesis—, mientras que la transición 2013→2016 se usa después para determinar el poder predictivo de esas mismas variables fuera de muestra (Sección 4.1). Cualquier fuente que no ofrezca datos reales y contemporáneos a estas olas no sirve al propósito de esta investigación.

Inicialmente, se priorizó la utilización de imágenes de Google Street View, sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente. Por esta razón, se evaluaron otras seis fuentes satelitales o aéreas públicas adicionales: —Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), y ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales modernas todavía no operaban)— y se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017) —por

lo que no puede existir ninguna imagen real de ellas anterior a esas fechas, en ningún catálogo—. Por eso se evaluaron específicamente en el marco de este proyecto: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura real anterior a 2014.

La Figura 1 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA, JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los 9,573 hogares en las tres olas de la ELCA (2010, 2013, 2016). El patrón diagonal marca cobertura real confirmada sobre hogares del proyecto; el resto se revisó cobertura de catálogo sin realizar consultas de los hogares disponibles (Sentinel-2, VIIRS).




Figura 1: Cobertura temporal real de cada fuente geoespacial evaluada, frente a las tres olas de la ELCA con coordenadas disponibles. El patrón diagonal indica corrida real y completa sobre hogares del proyecto; el resto se revisó cobertura según catálogo. En la barra de GSV, la intensidad del color es proporcional a la densidad real de fotos por año —la gran mayoría de las fotos son de 2023 en adelante.

El resultado de la corrida de producción, ya completa sobre las tres, es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013; es la única de las tres con esa cobertura completa en dos olas, lo que además la deja lista para aportar directamente a la evaluación del poder predictivo en la transición 2013→2016. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014 —no tiene ninguna cobertura de 2013—. Landsat 5 TM cubre solo 65.5 % de los hogares en 2010 (6,269 de 9,573; el resto

pierde el año completo por nubosidad persistente, una limitación del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth Engine confirmó que el sensor dejó de adquirir escenas utilizables antes de esa fecha, no hay ninguna imagen real de Landsat 5 en 2012 ni en 2013, en ningún punto del planeta. Las tres se incorporan al proyecto porque, para la ola 2010, el objetivo de esta tesis, son las únicas fuentes que ofrecen información geoespacial real, no proxy.

3.2.1. Qué mide cada fuente y qué variables se construyen

La sección anterior explica *por qué* se añadieron DMSP-OLS, ALOS PALSAR y Landsat 5 TM al proyecto. Esta subsección explica *qué* miden físicamente estas tres fuentes, *qué* variables se construyen a partir de ellas, y *qué* representan esas variables como proxy de las condiciones del hogar y su entorno.

Cada fuente geoespacial de este proyecto entrega, para cada hogar y cada ola, un valor que describe el entorno en *un momento*: una fotografía, un panorama de radar, una imagen óptica, un mes de luz nocturna. Eso responde a la pregunta “¿cómo se ve el entorno de este hogar en la ola t ?”, pero no responde una pregunta distinta y potencialmente igual de relevante para predecir una *transición*: “¿el entorno de este hogar se venía deteriorando o mejorando en los años previos a la ola t ?”. Dos hogares pueden verse igual de urbanizados en el momento exacto de la encuesta y, sin embargo, tener trayectorias muy distintas —uno estable desde hace una década, otro en medio de una expansión reciente y desordenada— que una sola fotografía del momento no distingue, pero que sí sería visible si se compara ese momento contra los años inmediatamente anteriores. Por esta razón, con DMSP-OLS se construyen, para cada hogar, tres familias de variables, con tres preguntas distintas detrás de cada una:

- **Estado** — “¿cómo se ve el entorno justo en el año de la ola?” Un solo valor, del año exacto (2010).
- **Ventana acumulada** — “¿cómo venía cambiando el entorno en los tres años previos a la ola (incluido el año de la ola)?” Estadísticos —media, desviación estándar, mínimo, máximo, rango, coeficiente de variación, tendencia (pendiente de una recta ajustada a los 3 años), y el *crecimiento acumulado* (variación relativa entre el primer y el último año de la ventana)— calculados sobre 2008-2010.

La Figura 2 ilustra las tres olas sobre la misma línea de tiempo. Es importante no confundirlas: la ventana acumulada de la ola 2010 (2008-2010) y la de la ola 2013 (2011-2013) no se traslapan —cada una describe el proceso *previo a su propia ola*—, mientras que

el cambio entre olas es una comparación distinta, entre los dos puntos de estado. Un hogar puede tener, por ejemplo, una ventana acumulada con tendencia fuertemente positiva antes de 2010 (se venía iluminando/urbanizando rápido) y aun así un cambio entre olas pequeño si el nivel de 2013 no se alejó mucho del de 2010 —son preguntas distintas y las tres se conservan por separado en el panel final, nunca se promedian entre sí.




Figura 2: Las tres familias de variables construidas para DMSP-OLS, ilustradas sobre la línea de tiempo real de las ventanas usadas.

Es importante mencionar la siguiente limitación compartida por las tres familias de variables: el supuesto de que el hogar vivía en la misma dirección durante toda la ventana acumulada. Como no existe una coordenada del hogar anterior a la primera ola en que aparece en la ELCA, se usa la coordenada registrada en la ola correspondiente (2010 o 2013) para extraer *todos* los años de esa ventana —es decir, para un hogar que sí vivía ahí en 2008-2010, la ventana acumulada de la ola 2010 describe correctamente su entorno; si el hogar se mudó a esa dirección poco antes de la encuesta de 2010, la ventana acumulada describe el entorno de un lugar donde el hogar puede no haber vivido durante toda la ventana. Este supuesto no se puede verificar con los datos disponibles y se menciona como limitación explícita de estas variables.

La Tabla 1 resume, para las tres fuentes nuevas, el mecanismo físico de medición, el nombre de las variables principales que se construyeron, y la interpretación que se les da en este estudio.

Cuadro 1: Qué mide cada fuente nueva, qué variables construye, y qué aproxima cada una.

Fuente	Mecanismo físico	Variables (estado / ventana acum.)	Qué aproxima
DMSP-OLS	Radiancia visible nocturna captada por satélite (aluminado público, vivienda, comercio)	Estado: nivel, log, saturación Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code>)	Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)
ALOS PALSAR	Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación	Estado: HH, HV (dB), razón HH/HV, índice normalizado Acumulada: media, tendencia, crecimiento de cada una	Densidad y consolidación del entorno construido vs. vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)
Landsat 5 TM	Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta)	Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices) Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo	Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada)

A continuación se presenta un ejemplo numérico explicativo de las ideas expresadas en la tabla 1. Supóngase un hogar urbano cuyo entorno, medido por DMSP-OLS, tuvo `stable_lights` (en una escala de 0 a 63) de 10 en 2008, 12 en 2009 y 15 en 2010, y de 16, 18 y 20 en 2011, 2012 y 2013 respectivamente. Para la ola 2010: el *estado* es 15 (el valor de 2010); la *ventana acumulada* tiene media ≈ 12.3 , tendencia $+2.5$ unidades/año (el entorno se iluminaba de forma sostenida) y *crecimiento acumulado* de $(15 - 10)/10 = 50\%$ en los 3 años previos a la ola. Para la ola 2013: el estado es 20, y la ventana acumulada 2011-2013 tiene tendencia $+2.0$ unidades/año. El *cambio entre olas* es $(20 - 15)/15 \approx 33\%$ —un número distinto a cualquiera de los crecimientos acumulados anteriores, porque mide

el salto completo de 3 años entre dos puntos, no la tendencia dentro de la ventana de ninguna de las dos olas por separado—. Las tres cifras (50 %, 33 %, y las tendencias de +2.5 y +2.0) son consistentes entre sí en este ejemplo (todas indican iluminación creciente), pero no tienen por qué coincidir en magnitud, y en un hogar real perfectamente podrían apuntar en direcciones distintas —p. ej. una ventana acumulada con tendencia negativa justo antes de una ola, seguida de una recuperación fuerte hacia la ola siguiente—, lo cual es, precisamente, el tipo de información que una sola fotografía o un solo panorama no puede capturar.

3.3. Estadísticas descriptivas

La Tabla 2 resume la cobertura de covariables por módulo en el dataset consolidado. Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones) porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares que cumplen esa condición.

Cuadro 2: Cobertura de covariables por módulo en el dataset consolidado

Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (%) del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	21	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría (Sección 3.1); “usadas en el modelo” es el subconjunto final tras la construcción de *features* – excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (docs/decisions.md, “Bloque de features de Hogar”). No incluye llaves de identidad (p. ej. `consecutivo_c` en Comunidades). Fuente: cálculos propios con base en ELCA 2010, 2013, 2016 y docs/variable_audit/*_construccion.csv, generados por `src/tabla_cobertura_modulos.py`.

3.3.1. Estadísticas descriptivas de las fuentes geoespaciales

A diferencia de los módulos de la encuesta ELCA, las tres fuentes geoespaciales que sobrevivieron el análisis de cobertura (DMSP-OLS, ALOS PALSAR, Landsat 5 TM; Sección 3.2.1) no cubren las mismas olas entre sí (Sección 3.2): ALOS PALSAR y Landsat 5 TM no tienen ninguna observación real en 2013 ni 2016, y aunque DMSP-OLS sí tiene datos reales completos en 2013, esta tabla se restringe a la ola 2010, la única en la que las tres fuentes coexisten.

Para cada fuente se reporta su variable de *estado* insignia —la misma que cada pipeline identifica como variable clave en su propio reporte de control de calidad— y la *tendencia* de su ventana acumulada de 3 años (Sección 3.2.1). La Tabla 3 resume los resultados.

Cuadro 3: Estadísticas descriptivas de las variables insignia de DMSP-OLS, ALOS PALSAR y Landsat 5 TM, ola 2010 ($n = 9,573$ hogares con coordenada válida en esa ola).

Fuente	Variable	n	Cobertura (%)	Media	Std	Mín	Máx
DMSP-OLS	Estado (<code>stable_lights</code>)	9,573	100.0	33.74	25.76	0.00	63.00
DMSP-OLS	Ventana acum. (tendencia)	9,573	100.0	6.11	6.39	−4.49	18.07
ALOS PALSAR	Estado (<code>hh_db</code>)	9,573	100.0	−7.32	2.91	−15.42	5.94
ALOS PALSAR	Ventana acum. (tendencia)	9,573	100.0	0.04	0.37	−3.19	1.79
Landsat 5 TM	Estado (<code>ndvi</code>)	6,269	65.5	0.41	0.17	−0.08	1.12
Landsat 5 TM	Ventana acum. (tendencia)	3,660	38.2	−0.04	0.11	−0.66	0.38

Nota: “Estado” es el valor de la variable insignia en el año exacto de la ola (2010); “ventana acumulada (tendencia)” es la pendiente de esa misma variable sobre 2008–2010 (Sección 3.2.1). Fuente: cálculos propios con base en ELCA 2010 y consultas a Google Earth Engine.

Los cuatro histogramas de la Figura 3 muestran, para la ola 2010, la forma completa de la distribución detrás de las medias y desviaciones de la Tabla 3. `stable_lights` de DMSP-OLS es marcadamente bimodal: una masa grande de hogares saturados en el tope de la escala (63, típico de zonas urbanas densamente iluminadas) y una cola larga de valores bajos (entornos rurales u oscuros), consistente con que esta variable separa bien urbano/rural (Sección 3.3.5). La tendencia acumulada de DMSP-OLS también es bimodal, con un grupo concentrado cerca de cero (entorno estable en los tres años previos a 2010) y otro grupo alrededor de 15–18 (entornos que se iluminaban muy rápido). ALOS PALSAR (`hh_db`) y Landsat 5 (`ndvi`) tienen formas unimodales más suaves, sin la bimodalidad marcada de las luces nocturnas.




Figura 3: Distribución de las variables insignia de las tres fuentes geoespaciales, ola 2010. La cobertura reportada aquí (97.2 % para DMSP-OLS/ALOS PALSAR, 63.6 % para Landsat 5) se calcula sobre el total de 9,853 hogares del panel en esa ola, no solo sobre los 9,573 con coordenada válida —de ahí la diferencia frente al 100 %/65.5 % de la Tabla 3, que usa como base justamente esos 9,573—. Fuente: cálculos propios.

3.3.2. Composición del panel y atrición

Como en toda encuesta longitudinal existe algo de pérdida de datos (atrición) que se caracteriza de la siguiente manera: el panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016 (Figura 4, izquierda) —una atrición de 11.4 % entre 2010 y 2013, 11.4 % entre 2013 y 2016, y 17.9 % acumulada entre 2010 y 2016 (Figura 4, derecha). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2 % de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8 % de los rurales), lo opuesto a la intuición de que la atrición rural sería mayor por dificultad de rastreo geográfico —probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales, dado que son la población de interés original de la encuesta. Por esta razón, se utilizarán técnicas de balanceo para compensar este sesgo.




Figura 4: Izquierda: hogares únicos por ola. Derecha: tasa de pérdida de hogares entre olas consecutivas y acumulada 2010–2016. Fuente: cálculos propios.

Parte de la aparente estabilidad del panel esconde un fenómeno distinto: la división de hogares. 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016 —típicamente porque un hijo formó su propio hogar en la misma vivienda o predio—. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. El número de personas cubiertas por el panel cae de forma más pronunciada que el de hogares —43,202 personas en 2010, 39,920 en 2013, 35,722 en 2016 (18.7% de caída acumulada, por encima del 17.9% de hogares)— porque los hogares perdidos tienden a ser, en promedio, ligeramente más grandes que los que permanecen en el panel.

3.3.3. Inventario temático de las variables finales

El dataset consolidado que alimenta el modelo (27,932 filas hogar×ola) reúne 181 variables finales: 177 provienen de los cinco módulos de la ELCA ya auditados en la Tabla 2 —excluyendo de ese conteo `consecutivo_c`, que es la llave de unión al módulo Comunidades, no una covariable— y las 4 restantes son las variables geoespaciales (Sección 3.3.1). La Figura 5 desagrega ese total por módulo y por tipo de dato. Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario —consistente con que son los módulos que se preguntan a todo hogar sin condición previa (Tabla 2)—, mientras que Comunidades (21), Choques (17), Niños (13) y Geoespacial (4) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra o a una sola ola (Niños, Geoespacial). De las 181, 159 (88%) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas (los indicadores de pobreza monetaria).




Figura 5: Inventario de las 181 variables finales del dataset consolidado, por módulo temático y tipo de dato. Fuente: cálculos propios.

3.3.4. Comportamiento por ola y cambios en el periodo

Para ilustrar cómo se comportan estas variables en el tiempo, se seleccionó un indicador clave por tema (uno por módulo, más las dos variables DMSP-OLS con cobertura en más de una ola) y se calculó su media en cada ola. La Figura 6 muestra la distribución de cada uno, y la Figura 7 resume la evolución de esas medias indexando la ola 2010 a 100. El tipo de gráfico en la Figura 6 se elige según la forma de cada variable, no es el mismo para las 13: un boxplot sobre una variable binaria o sobre una tasa con más de la mitad de los hogares en el techo (afiliación a salud, asistencia escolar) colapsa en una caja plana o en un rectángulo sin información —por eso esas dos se muestran como barra con la media anotada, y las dos variables categóricas de pocas categorías (si tuvo algún choque, percepción de inseguridad) se muestran como barras apiladas con la participación de cada categoría—; el resto, con variación continua real, sí se beneficia del boxplot convencional.




Figura 6: Distribución de 13 indicadores clave por ola: boxplot (mediana, rango intercuartílico, sin atípicos) para las variables con variación continua; barra con la media anotada para las tasas concentradas en el techo (afiliación a salud, asistencia escolar); barras apiladas con la participación de cada categoría para las variables categóricas de pocas categorías (choque, percepción de inseguridad). *dmstp_stable_lights* y su tendencia acumulada solo tienen dato real en 2010 y 2013. Fuente: cálculos propios.




Figura 7: Evolución de la media de 13 indicadores clave a través de las olas, indexada a 2010 = 100. Fuente: cálculos propios.

Tres cambios se destacan como sustantivos, no ruido muestral. Primero, el ingreso real per cápita del hogar sube 37.2 % entre 2010 y 2016 (\$224,479 a \$308,042, pesos reales deflactados) y la brecha frente a la línea de pobreza (**brecha_lp_ingreso**) sube 41.9 % en el mismo periodo (de 1.24 a 1.75 veces la LP). Es decir, los hogares del panel se enriquecieron en términos absolutos y relativos a lo largo de la década, lo cual es consistente con la caída de la incidencia de pobreza documentada en la Sección 5.1. Segundo, el hacinamiento (**personas_por_cuarto_hogar**) cae 15.7 % (de 1.65 a 1.39 personas por cuarto) y la razón de dependencia demográfica cae 11.1 % (de 0.72 a 0.64) —ambos coherentes con una transición demográfica en curso (menos niños por adulto) y con mejoras en la vivienda—. Tercero, el índice de riqueza (**riqueza_pca_hogar**, un componente principal estandarizado sobre el panel completo) pasa de negativo (-0.19 en 2010) a positivo (0.14 en 2016), señal adicional de acumulación de activos del hogar en el periodo.

Un cuarto cambio requiere una advertencia metodológica: **tuvo_algun_choque_hogar** salta de 34.6 % en 2010 a 75.0 % en 2016 (+117 %). Este salto es causado por cambios en la encuesta y no un cambio real en la exposición de los hogares a choques negativos. El cuestionario de choques de 2010 enumera explícitamente 18 categorías posibles y *ninguna* corresponde a desastre natural —la categoría de inundación/avalancha/sequía/temblor se agregó en el cuestionario de 2013, probablemente porque el de 2010 ya estaba diseñado antes de que la Ola Invernal 2010–2011 se agravara—, y dos categorías de abandono del hogar que

sí existían en 2010 se eliminaron del cuestionario a partir de 2013. Ambos cambios inflan el conteo de tipos de choque disponibles en 2013 y 2016 frente a 2010, independientemente de la exposición real de los hogares. No toda la información de Choques es universal por diseño: los tipos de choque agropecuario (pérdida de animales, plagas/pérdida de cosecha) se preguntan exclusivamente a hogares rurales, y las variables de impacto económico y estrategia de afrontamiento solo aplican, correctamente, a hogares que reportaron al menos un choque. Con esas dos salvedades de la encuesta identificadas, el resto de indicadores (ocupación, afiliación a salud, asistencia escolar, percepción de inseguridad comunitaria, luces nocturnas DMSP-OLS) se mueven menos de 10 % en cualquiera de las dos subtransiciones, es decir, son relativamente estables en el periodo.

3.3.5. Perfil de los hogares analizados

La Figura 8 cruza los mismos indicadores clave —agregados sobre las tres olas— por zona (urbano/rural) y por condición de pobreza monetaria por ingreso, para caracterizar directamente a los hogares que entran al modelo. La brecha urbano/rural es amplia en ingreso (\$372,522 urbano vs. \$137,530 rural, 2.7 veces) y aún más marcada en la variable geoespacial insignia: `dmsp_stable_lights` promedia 54.0 en hogares urbanos frente a 8.2 en rurales —una razón de 6.6 veces, la brecha relativa más grande de todo el perfil, y evidencia de que esta variable geoespacial captura la división urbano/rural con más nitidez que cualquier variable de la encuesta—. Los hogares pobres (por ingreso) tienen en promedio \$89,277 de ingreso per cápita real frente a \$454,845 de los no pobres (5.1 veces), un índice de riqueza negativo (-0.77 vs. 0.69) y menor nivel educativo del jefe de hogar (2.18 vs. 3.21 en la escala ordinal) y menor tasa de ocupación (60.1 % vs. 71.5 %) —un perfil de privación consistente y no contradictorio entre las distintas fuentes de información (encuesta y satélite).




Figura 8: Perfil de hogares: media de 15 indicadores clave por zona (urbano/rural) y por condición de pobreza monetaria por ingreso, pooled sobre las tres olas. Fuente: cálculos propios.

3.3.6. Correlación entre covariables y riesgo de multicolinealidad

La Figura 9 muestra la matriz de correlación de Pearson de las 159 variables numéricas del consolidado —incluidas las 4 geoespaciales—, agrupadas por módulo. Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 2), solo se reportan como “altas” los pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican 35 pares.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan sobre 0.97 con su propia brecha a la LP; `lp` y `li` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal correlacionan -0.93 (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables de la Sección 4: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmsp_stable_lights` correlaciona 0.87 con la línea de pobreza `lp` y 0.81 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`). Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.2 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la Sección 5.3.




Figura 9: Matriz de correlación de Pearson de las 159 variables numéricas del dataset consolidado, agrupadas por módulo. Los círculos marcan pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas no-nulas. Fuente: cálculos propios.

4. Estrategia empírica

4.1. Construcción de la variable de resultado

Siguiendo a López-Calva y Ortiz-Juárez (2011, 2014), se construyen matrices de transición de pobreza monetaria cruzando el estado de pobreza de un hogar en la ola inicial t (filas) contra su estado en la ola siguiente $t + 1$ (columnas), usando el ingreso per cápita del hogar contra la línea de pobreza (LP) oficial del DANE, específica por año y zona (urbana/rural). El análisis empírico se restringe a la submuestra de hogares que se encuentran por encima de la LP en el periodo inicial t . Sobre esta población se define la variable

dependiente binaria:

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

El objetivo es estimar la probabilidad condicional de caer en pobreza en el periodo siguiente dada la información observada en t (Ecuación 2). El emparejamiento de hogares entre olas usa exclusivamente coincidencias uno a uno del identificador de hogar (Sección 3.1); los hogares que se dividieron entre olas se excluyen de la construcción de la variable de resultado por no tener un estado inicial y final únicos. Las matrices de transición resultantes, su interpretación, y los cinco ejercicios de robustez realizados sobre esta construcción (ponderación muestral, especificación del ingreso, sensibilidad al umbral de pobreza, atrición del panel) se presentan en la Sección 5.1.

4.2. Especificación de modelos

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1) y $F(\cdot)$ es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se estiman y comparan cinco algoritmos, agrupados en dos familias según cómo tratan las categóricas y los datos faltantes (Sección 4.4):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla (l_1_ratio) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge puro. Es el algoritmo designado como referencia por ser interpretable, con coeficientes de signo económicamente interpretable, y por servir de punto de comparación antes de justificar el uso de un modelo más complejo.
- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre

desempeño e interpretabilidad, y uno de los más usados en la literatura de focalización de pobreza (McBride & Nichols, 2018)–, que difieren en el algoritmo de construcción del histograma de particiones (*level-wise* en XGBoost y HistGradientBoosting, *leaf-wise* en LightGBM) y en el mecanismo de regularización. Las tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding* (Sección 4.4).

Para evaluar el aporte relativo del nivel de ingreso/gasto del hogar –el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, se estima cada uno de los cinco algoritmos bajo dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante por lo que se mantiene constante a lo largo del tiempo; el **Modelo B** excluye estas cuatro columnas y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad). Este ejercicio, diez modelos en total (cinco algoritmos por dos especificaciones) establece además el marco de referencia frente al cual se evaluará, en una etapa posterior de este proyecto, si las variables geoespaciales aportan más donde la brecha a la LP ya no distingue bien (hogares cerca del umbral) que en general.

4.3. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, solo existe la ola base al momento de predecir, y es, siguiendo a McBride y Nichols (2018), la validación más exigente para un modelo de este tipo porque prueba generalización ante un régimen económico distinto al de entrenamiento. El ajuste de hiperparámetros de cada algoritmo (mediante `RandomizedSearchCV`, 15 combinaciones aleatorias, validación cruzada estratificada de 3 particiones, optimizando AUC-ROC) se realiza estrictamente dentro del periodo de entrenamiento (2010 a 2013); el conjunto de prueba (2013 a 2016) no se toca hasta la evaluación final reportada en la Sección 5.2. Como ejercicios de robustez adicionales, planeados pero aún no ejecutados, se contempla invertir los roles de entrenamiento y prueba (*backtest*) y agrupar ambas transiciones con validación cruzada agrupada por hogar (Sección 6.3).

El desempeño se reporta mediante AUC-ROC como métrica principal, principalmente porque no depende de un umbral de clasificación arbitrario, además, recall, precision y F1 como métricas de referencia al umbral de clasificación elegido (Sección 4.4), junto con la matriz de confusión completa. El foco del análisis está en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo a partir de diferencias de AUC-ROC que, como se documenta en la Sección 5.2, resultan pequeñas frente a la variabilidad esperable por aleatoriedad del ajuste.

4.4. Tratamiento del desbalance de clases

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4% (Tabla 4), un desbalance moderado que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). No se usó SMOTE, que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.

Un hallazgo metodológico relevante de este ejercicio: en XGBoost y en LightGBM (Modelo B), la estrategia “sin ajuste” ganó la comparación por una diferencia de AUC-ROC frente a la reponderación de apenas 0.001 (estadísticamente indistinguible), pero el modelo resultante, sin corregir el desbalance de clases, produjo probabilidades tan comprimidas hacia valores bajos que casi ninguna observación cruzaba el umbral convencional de 0.5 (recall de 3%–4% en XGBoost, con precision superior a 60%: el modelo ordenaba razonablemente bien los hogares por riesgo, pero era inútil en la práctica al umbral estándar). Esto ilustra que el umbral 0.5 es arbitrario cuando la clase positiva no es 50% de la muestra, y que distintas estrategias de balanceo calibran las probabilidades de forma distinta, por lo que comparar recall/precision/F1 a un umbral fijo entre estrategias no es una comparación válida. La solución adoptada fue elegir el umbral de clasificación de cada modelo por validación cruzada (maximizando F1 sobre las probabilidades *out-of-fold*) en lugar de fijarlo en 0.5 —el AUC-ROC, que no depende de umbral, sigue siendo el criterio que decide la estrategia de balanceo y los hiperparámetros; el umbral solo determina cómo se reportan

las métricas restantes.

Para los algoritmos sin soporte de datos faltantes (regresión logística y Random Forest), la imputación de valores faltantes, que en esta base de datos son mayoritariamente por la estructura de la encuesta, es decir, causados por preguntas filtro del cuestionario (por ejemplo, el monto de una ayuda recibida no se pregunta a quien respondió que no recibió ninguna)– usa sistemáticamente el valor 0 combinado con una columna indicadora binaria de faltante por variable. Esta elección evita que la mediana –calculada únicamente sobre quienes pasaron el filtro y respondieron– le asigne a los hogares excluidos por el filtro un valor “típico” que en realidad no tienen, y tiene además la propiedad de que, en un modelo lineal, el relleno no aporta ninguna contribución a la predicción más allá de la que capture el propio indicador de faltante. Las variables categóricas se imputan con una categoría explícita “Sin dato” en vez de la moda, para no disfrazar la ausencia estructural como el valor más común. XGBoost, LightGBM y HistGradientBoosting no requieren esta imputación: manejan los datos faltantes de forma nativa en la partición de los árboles, lo que convierte el propio patrón de *missingness* en una señal explotable por el modelo (por ejemplo, la ausencia de datos de vacunación infantil ya codifica indirectamente que el hogar no tiene hijos pequeños) en vez de forzar un supuesto de imputación potencialmente sesgado.

4.5. Importancia de variables e interpretabilidad

Para cada modelo se reporta una medida de importancia de variables acorde a su naturaleza: los coeficientes estandarizados (con signo) de la regresión logística; la importancia por reducción de impureza (`feature_importances_`) de Random Forest, XGBoost y LightGBM; y la importancia por permutación (*permutation importance*, AUC-ROC sobre el conjunto de prueba, 10 repeticiones) de HistGradientBoosting, más costosa computacionalmente pero más robusta a la correlación entre covariables que la importancia basada en impureza. La comparación de estas listas de variables más importantes entre el Modelo A y el Modelo B (Sección 5.2) es la primera aproximación a la pregunta de qué información no monetaria es más predictiva de la transición a la pobreza, antes de la incorporación de las variables geoespaciales (Sección 6.3). El uso de valores SHAP para una descomposición más fina y comparable entre algoritmos, contemplado en la propuesta original de este trabajo, queda como tarea pendiente.

5. Resultados

5.1. Dinámica de transiciones a la pobreza en la ELCO

Esta sección analiza la dinámica de la pobreza monetaria en el panel ELCA 2010–2013–2016 en dos niveles. Primero, la incidencia y las matrices de transición entre olas consecutivas, siguiendo la metodología oficial del DANE (ingreso per cápita nominal del hogar contra la línea de pobreza –LP– y la línea de pobreza extrema –LI– nominales de su año y zona) y la clasificación en cuatro categorías de transición de López-Calva y Ortiz-Juárez (2014) (nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza). Segundo, un conjunto de cinco ejercicios de robustez diseñados específicamente para evaluar qué tan sensible es la variable de resultado de esta tesis –la transición a la pobreza– a decisiones metodológicas de la construcción del ingreso y a la definición del panel. Los detalles de construcción de cada variable, verificados contra los diccionarios de la encuesta y los archivos crudos, están documentados exhaustivamente en el repositorio del proyecto (`docs/decisions.md`); aquí se presentan los resultados y su interpretación para la tesis.

5.1.1. Incidencia de pobreza y matrices de transición

La Figura 10 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más alta que la de ingreso en las tres olas (47.6 %, 40.9 % y 33.4 % en sentido estricto es más *baja*, no más alta, que la de ingreso en los tres puntos del panel: la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto). Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no es un artefacto de la medida de bienestar elegida.




Figura 10: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 11 descompone la pobreza por ingreso en sus tres componentes de Foster-Greer-Thorbecke: incidencia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 11: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

Las matrices de transición cruzan el estado de pobreza inicial (filas) contra el estado final (columnas), en porcentaje de fila, únicamente para hogares con emparejamiento uno a uno vía **consecutivo** entre olas (los hogares que se dividen entre una ola y la siguiente –511 casos en 2010–2013 y 1,190 en 2013–2016, contando ambos lados del emparejamiento– se excluyen de la matriz por no tener un estado inicial y final inequívoco). La Tabla 4 presenta ambas matrices.

Cuadro 4: Matrices de transición de pobreza monetaria por ingreso (% de fila, panel emparejado 1 a 1)

Periodo	Estado inicial	No pobre (final)	Pobre (final)
2010 → 2013 ($n = 8,218$)	No pobre	76.6 %	23.4 %
	Pobre	29.7 %	70.3 %
2013 → 2016 ($n = 6,911$)	No pobre	80.1 %	19.9 %
	Pobre	38.2 %	61.8 %

Nota: n = hogares con emparejamiento 1 a 1; excluye 511 (2010–2013) y 1,190 (2013–2016) casos de hogares que se dividieron entre olas. Fuente: cálculos propios con base en ELCA 2010, 2013, 2016.

Dos patrones se destacan. Primero, la persistencia en la pobreza es alta pero decrece con el tiempo: 70.3 % de los hogares pobres en 2010 seguían pobres en 2013, y esa persistencia

baja a 61.8 % entre 2013 y 2016 –es decir, la probabilidad de salir de la pobreza condicional en ser pobre aumentó de 29.7 % a 38.2 % entre periodos–. Segundo, la persistencia en la no pobreza también mejora (de 76.6 % a 80.1 %), y el riesgo de entrar en pobreza condicional en no ser pobre cae de 23.4 % a 19.9 %. Ambos movimientos son consistentes con la caída de la incidencia agregada documentada en la Figura 10.

La Figura 12 traduce estas matrices a las cuatro categorías de López-Calva y Ortiz-Juárez (2014). En 2010–2013, 43.9 % de los hogares del panel emparejado son *siempre pobres*, 28.8 % *nunca pobres*, 18.6 % *salen de la pobreza* y 8.8 % *entran en ella*. En 2013–2016 el panorama cambia de categoría dominante: *nunca pobre* pasa a ser la categoría más grande (37.0 %, superando por primera vez a *siempre pobre*, que cae a 33.3 %), sale 20.6 % y entra 9.2 %. En los dos periodos la tasa de salida casi duplica a la tasa de entrada, consistente con una economía en la que la pobreza monetaria se redujo de manera neta, no solo se redistribuyó entre hogares.




Figura 12: Distribución de categorías de transición de pobreza monetaria (Lopez-Calva y Ortiz-Juarez, 2014) entre olas consecutivas.

5.1.2. Ejercicios de robustez

La variable de interés de esta tesis es precisamente la transición a la pobreza, por lo que conviene preguntarse qué tan sensibles son las cifras de la Sección 5.1.1 a decisiones de construcción del ingreso, a la representatividad muestral, y al error de medición cerca del umbral de pobreza. Se implementaron cinco ejercicios de robustez con este propósito.

Ponderación muestral. Ninguno de los resultados anteriores usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y

verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (*fexhog*, *fexhog_2013*, ambos transversales, y *fexhog_2010*, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % $\rightarrow$ 60.4 % en 2010, 52.4 % $\rightarrow$ 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % $\rightarrow$ 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 % a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorratados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de esta tesis. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010 $\rightarrow$ 2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o

ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se repitieron las matrices de transición (Figura 13). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % ($LP - 10\%$) y 49.1 % ($LP + 10\%$) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas en dinero–. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 13: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 14 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 14: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo **consecutivo** no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 15). La atrición es de 11.4 % en ambos periodos (1,124 de 9,853 hogares base entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). La consistencia entre periodos es tranquilizadora en términos de diseño muestral, pero no se investigó si esta atrición es aleatoria o está concentrada en algún perfil de hogar (rural, más pobre, más móvil) –una limitación que se retoma más abajo.




Figura 15: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

5.2. Desempeño comparativo de modelos

La Tabla 5 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.3 y 4.4).

Cuadro 5: Desempeño de los cinco algoritmos, holdout temporal (train 2010→2013, test 2013→2016). Media $\pm$ intervalo de confianza al 95 % sobre 5 semillas del ajuste final

Algoritmo	Espec.	Balanceo	Umbral	AUC-ROC	IC95 %	Recall	F1
Random Forest	A	balanced	0.48	0.764	[0.763, 0.764]	0.732	0.473
XGBoost	A	ninguno	0.26	0.763	[0.761, 0.764]	0.710	0.467
LightGBM	A	balanced	0.53	0.757	[0.757, 0.757]	0.681	0.466
HistGradientBoosting	A	ninguno	0.24	0.754	[0.754, 0.754]	0.736	0.457
Logística regularizada	A	balanced	0.46	0.747	[0.747, 0.747]	0.752	0.438
Logística regularizada	B	balanced	0.48	0.739	[0.739, 0.739]	0.697	0.435
Random Forest	B	balanced	0.48	0.739	[0.738, 0.740]	0.675	0.442
HistGradientBoosting	B	ninguno	0.23	0.734	[0.734, 0.734]	0.662	0.437
XGBoost	B	ninguno	0.27	0.734	[0.732, 0.735]	0.665	0.442
LightGBM	B	ninguno	0.25	0.727	[0.727, 0.727]	0.692	0.436

Nota: umbral elegido por validación cruzada maximizando F1 en cada semilla (Sección 4.4), no fijo en 0.5; se reporta el promedio de las 5 semillas. El IC95 % de AUC-ROC captura únicamente la aleatoriedad propia del procedimiento de ajuste (remuestreo interno del algoritmo) sobre el mismo conjunto de prueba, con balanceo e hiperparámetros ya fijados (Sección 5.2) – es nulo o casi nulo para HistGradientBoosting, LightGBM y la regresión logística porque, con los hiperparámetros elegidos, su ajuste es determinístico dado el conjunto de entrenamiento. HistGradientBoosting usa aquí `RandomizedSearchCV` con 8 iteraciones, el mismo presupuesto de búsqueda de la Sección 5.3 (reducido de 15 por costo computacional al ampliarse la comparación a las especificaciones geoespaciales) –una corrida anterior con 15 iteraciones había dado AUC-ROC 0.759 (Modelo A) y 0.740 (Modelo B), documentada en `docs/decisions.md` (entrada 2026-08-10); la diferencia frente a los valores aquí reportados (0.754/0.734) es ruido del procedimiento de ajuste, no un cambio en los datos ni en el modelo (ver discusión de magnitud comparable en la Sección 5.3). Fuente: cálculos propios, `data/processed/benchmark_resultados/registro_modelos.csv`, generados por `src/tabla_desempeno_modelos.py`.




Figura 16: AUC-ROC medio (5 semillas) de los cinco algoritmos por especificación, conjunto de prueba 2013→2016. Barras de error: IC95 %.

Tres patrones se destacan. Primero, los cinco algoritmos quedan en un rango relativamente estrecho de AUC-ROC (0.727–0.764 en total, apenas 0.747–0.764 dentro del Modelo A), con los tres *gradient boosting* y Random Forest apenas por encima de la regresión logística regularizada (Figura 16). Reentrenar el modelo final de cada algoritmo con 5 semillas aleatorias (Sección 4.4) –manteniendo fijos el balanceo y los hiperparámetros ya elegidos– muestra que HistGradientBoosting, LightGBM y la regresión logística son prácticamente determinísticos bajo los hiperparámetros elegidos (desviación estándar del AUC-ROC ≈ 0 entre semillas), mientras que Random Forest y XGBoost sí tienen una variabilidad pequeña pero no nula (desviación estándar de 0.0005 y 0.0011, respectivamente), heredada del remuestreo *bootstrap* y del submuestreo de observaciones/columnas que sus hiperparámetros óptimos activan. Con esa variabilidad, la ventaja de Random Forest (AUC-ROC 0.764) sobre XGBoost (0.763) en el Modelo A es marginal y sus intervalos de confianza casi se traslapan; la de ambos sobre LightGBM (0.757) y, más aún, sobre HistGradientBoosting (0.754) es algo más clara. Es importante notar que este intervalo de confianza mide únicamente la aleatoriedad del propio procedimiento de ajuste sobre el mismo conjunto de prueba, no la incertidumbre muestral de la estimación del AUC-ROC en sí –una comparación formal entre algoritmos requeriría una prueba pareada (por ejemplo, de DeLong) sobre las predicciones del mismo conjunto de prueba, no realizada en este documento–. Con esa salvedad, la evidencia sigue sin señalar un algoritmo que domine de forma inequívoca a los demás. Segundo, el ranking cambia según la métrica: la regresión

logística tiene el mayor recall del Modelo A (0.752), seguida por HistGradientBoosting (0.736), ambos a costa de más falsos positivos, mientras que Random Forest tiene el mayor F1 en ambas especificaciones (0.473 en A, 0.442 en B). Esto sugiere que, más que declarar un “mejor” algoritmo único, la elección final debería depender de las preferencias de la institución que use el modelo para focalización –priorizar recall implica aceptar más errores de inclusión a cambio de menos errores de exclusión–.

Tercero, y más relevante para la pregunta de investigación de esta tesis: la brecha de AUC-ROC entre el Modelo A (con ingreso/gasto) y el Modelo B (sin ellos) es de 0.008 a 0.031 según el algoritmo (mínima en la regresión logística, máxima en LightGBM), mucho menor de lo que predeciría un enfoque de vulnerabilidad puramente monetario (Chaudhuri et al., 2002). Esto indica que las covariables no monetarias –educación, activos del hogar, vivienda, choques, características de la comunidad– capturan una fracción sustancial del poder predictivo que aporta la brecha al umbral de pobreza, no son redundantes con ella. La Figura 17 muestra recall y precisión (media, 5 semillas) al umbral elegido para el Modelo A: el patrón de mayor recall en la regresión logística y HistGradientBoosting frente a mayor precisión en Random Forest y XGBoost se mantiene incluso tras corregir por el umbral de clasificación.




Figura 17: Recall y precision al umbral de clasificación elegido por validación cruzada, Modelo A (media e IC95 %, 5 semillas).

Las Figuras 18 y 19 muestran las variables más importantes de Random Forest y los mayores coeficientes –en valor absoluto, en unidades estandarizadas– de la regresión logística, ambos para el Modelo A. En Random Forest, el ingreso per cápita real y la

brecha a la LP dominan claramente (consistente con Chaudhuri et al. (2002)), seguidos por el índice de riqueza precalculado de la ELCA (`riqueza_pca_hogar`) y el número de bienes durables del hogar. En la regresión logística, en cambio, el nivel educativo máximo del hogar tiene el mayor coeficiente en valor absoluto, por encima incluso de la brecha a la LP y el ingreso real –con signo negativo, consistente con que más educación reduce la probabilidad de caer en pobreza–, seguido por el número de bienes durables y de servicios públicos del hogar. Esta diferencia entre algoritmos –qué variable “domina” según se mida por reducción de impureza o por magnitud de coeficiente estandarizado– es en sí misma evidencia de que la importancia de variables no es una propiedad única del problema sino que depende parcialmente de cómo cada algoritmo particiona la información, un matiz relevante para la interpretación de resultados de esta naturaleza.




Figura 18: Variables más importantes, Random Forest, Modelo A (reducción de impureza).

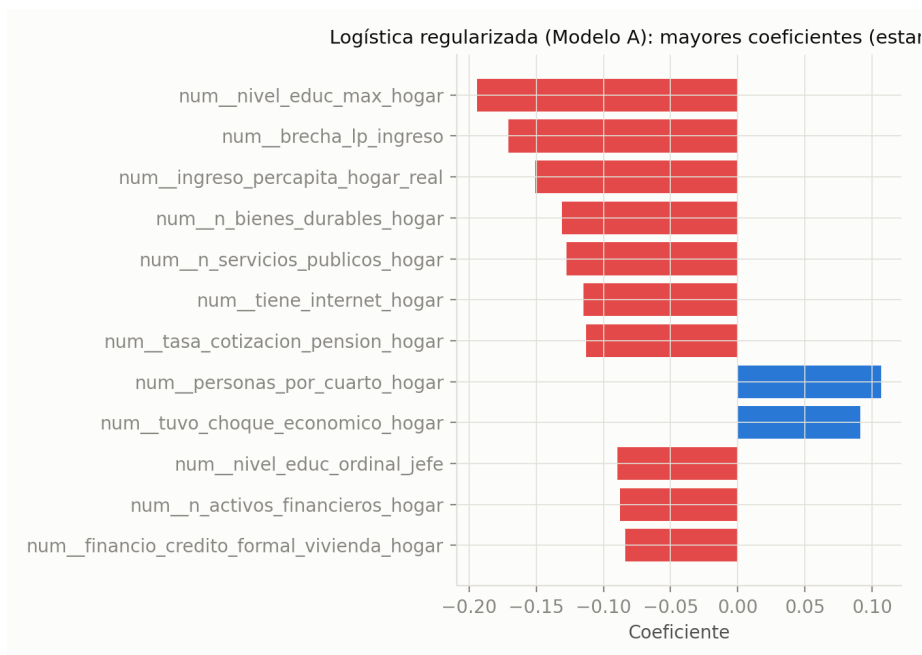


Figura 19: Mayores coeficientes en valor absoluto, regresión logística regularizada, Modelo A (unidades estandarizadas).

En el Modelo B (sin ingreso/gasto), tanto Random Forest como la regresión logística ubican el índice de riqueza precalculado y el nivel educativo máximo del hogar entre las dos variables más importantes, seguidos por el número de bienes durables, de servicios públicos y –solo en la regresión logística– la tasa de cotización a pensión del hogar, un proxy de formalidad laboral. Estas variables son consistentes con los determinantes de pobreza documentados en la literatura y no sugieren que el modelo esté capturando relaciones espurias.

5.3. Contribución marginal de las variables geoespaciales

Esta subsección evalúa si DMSP-OLS –la única de las tres fuentes nuevas con datos reales tanto en la ola de entrenamiento (2010) como en la de prueba (2013), Sección 3.2– mejora el desempeño del benchmark cuando se agrega a las covariables de la ELCA, bajo el mismo holdout temporal, balanceo de clases y selección de umbral ya usados en la Sección 5.2. Se reentrenaron los tres algoritmos con mejor desempeño en esa comparación (XGBoost, HistGradientBoosting, Logística regularizada) agregando a los Modelos A y B las 23 variables DMSP-OLS de estado y ventana acumulada (Sección 3.2.1) – en el código y en los archivos de resultados esta comparación se identifica como A/AgeoDMSP y B/BgeoDMSP; aquí se usa la forma expandida “A” / “A + DMSP-OLS” por legibilidad. Se agrega además `precision_top10` –la precisión entre el 10 % de hogares que el modelo

señala como de mayor riesgo— porque para un programa de focalización con capacidad fija esta cifra es más relevante que recall/precision/F1 a un umbral de probabilidad, que no reflejan ninguna restricción real de cobertura. Aun así, para no dejar una lectura incompleta, la Tabla 6 también reporta esas tres métricas al umbral de clasificación ya elegido por validación cruzada (Sección 4.4): *recall* es la fracción de hogares que sí cayeron en pobreza y el modelo efectivamente marcó como riesgo (cuánto de la pobreza real se captura); *precision* es la fracción de los hogares marcados como riesgo que efectivamente cayeron en pobreza (cuánta de la alarma es acertada, no falsa alarma); *F1* resume ambas en un solo número (su media armónica), útil para comparar sin tener que decidir de antemano si importa más no dejar pobres sin detectar (recall) o no gastar recursos de focalización en quien no los necesita (precision).

Cuadro 6: AUC-ROC, precisión en el decil de mayor riesgo, y métricas al umbral elegido por CV, con y sin DMSP-OLS, holdout temporal (train 2010→2013, test 2013→2016).

Algoritmo	Especificación	AUC-ROC	IC95 %	Precision top-10 %	IC95 %	Recall	Precision	F1
XGBoost	A	0.763	[0.761, 0.764]	0.485	[0.471, 0.499]	0.710	0.349	0.467
XGBoost	A + DMSP-OLS	0.762	[0.761, 0.762]	0.484	[0.479, 0.489]	0.718	0.344	0.465
HistGradientBoosting	A	0.754	[0.754, 0.754]	0.491	[0.491, 0.491]	0.736	0.332	0.457
HistGradientBoosting	A + DMSP-OLS	0.755	[0.755, 0.755]	0.491	[0.491, 0.491]	0.692	0.345	0.458
Logística regularizada	A	0.747	[0.747, 0.747]	0.506	[0.506, 0.506]	0.752	0.310	0.438
Logística regularizada	A + DMSP-OLS	0.746	[0.746, 0.746]	0.500	[0.500, 0.500]	0.753	0.311	0.439
XGBoost	B	0.734	[0.732, 0.735]	0.488	[0.482, 0.494]	0.665	0.332	0.442
XGBoost	B + DMSP-OLS	0.732	[0.729, 0.734]	0.475	[0.466, 0.484]	0.781	0.302	0.435
HistGradientBoosting	B	0.734	[0.734, 0.734]	0.484	[0.484, 0.484]	0.662	0.326	0.437
HistGradientBoosting	B + DMSP-OLS	0.735	[0.735, 0.735]	0.475	[0.475, 0.475]	0.663	0.340	0.449
Logística regularizada	B	0.739	[0.739, 0.739]	0.500	[0.500, 0.500]	0.697	0.317	0.435
Logística regularizada	B + DMSP-OLS	0.739	[0.739, 0.739]	0.494	[0.494, 0.494]	0.698	0.315	0.434

Nota: recall, precision y F1 se miden al umbral de clasificación ya elegido para cada algoritmo/especificación por validación cruzada (Sección 4.4, sin re-elegirlo al agregar DMSP-OLS). Fuente: cálculos propios, `data/processed/benchmark_resultados/registro_modelos.csv`, generados por `src/tabla_marginal_dmsp.py` sobre resultados de `src/05_model/modelo_{xgboost, histgradientboosting,logistica_regularizada}.py` corridos sobre `modelo_{A,B,AgeoDMSP,BgeoDMSP}_2010_2013/2013_2016.parquet` (construidos por `construir_pipeline_geo_dmsp.py`). RandomizedSearchCV con 8 iteraciones (reducido de 15 por costo computacional tras rehacer la búsqueda para 10 especificaciones distintas – ver ablation más abajo); se verificó que el resultado de XGBoost y Logística regularizada es prácticamente idéntico al obtenido con 15 iteraciones, y que el de HistGradientBoosting varía en el tercer decimal, dentro del orden de magnitud del efecto que se busca detectar (ver discusión siguiente).

Resultado: agregar DMSP-OLS no mejora de forma económicamente significativa el desempeño en ningún algoritmo. En XGBoost y Logística regularizada el AUC-ROC y `precision_top10` se mantienen iguales o caen ligeramente al agregar

DMSP-OLS, en las cuatro comparaciones de la Tabla 6. HistGradientBoosting es la única excepción –AUC-ROC sube de 0.754 a 0.755 (Modelo A) y de 0.734 a 0.735 (Modelo B)–, pero esa mejora (+0.001 y +0.0015) es del mismo orden de magnitud que la variación que produjo, por sí sola, reducir el presupuesto de búsqueda de hiperparámetros de 15 a 8 iteraciones (el AUC de HistGradientBoosting-A pasó de 0.759 a 0.754 solo por ese cambio, sin tocar los datos) – no es una mejora que se pueda distinguir del ruido propio del procedimiento de ajuste, y `precision_top10` no mejora en ninguno de los dos casos. Antes de interpretar la ausencia de mejora como ausencia de señal, se descartó explícitamente la explicación de sobreajuste: se comparó, para cada algoritmo, la brecha entre el AUC de validación cruzada (calculado solo sobre entrenamiento) y el AUC de prueba real, con y sin DMSP-OLS – si agregar columnas geoespaciales infla artificialmente el ajuste de entrenamiento sin generalizar, esa brecha debería ensancharse. No fue el caso: el mayor cambio observado fue de +0.004 (XGBoost, Modelo B), muy por debajo del umbral de alerta (0.03) definido *ex ante*. La ausencia de mejora no es, entonces, un problema de sobreajuste del modelo.

Recall, precision y F1 confirman la misma conclusión en 5 de las 6 comparaciones algoritmo/especificación: se mueven menos de 0.02 en cualquier dirección al agregar DMSP-OLS, ruido de ajuste más que señal. La excepción clara es **XGBoost, Modelo B**: el recall sube de 0.665 a 0.781 (+0.116, el mayor cambio de toda la tabla) y la precision cae de 0.332 a 0.302, con F1 prácticamente plano (0.442 $\rightarrow$ 0.435) porque ambos movimientos se compensan. La causa no es un cambio de comportamiento del modelo sino del umbral que la validación cruzada eligió para cada especificación: 0.268 sin DMSP-OLS vs. 0.216 con DMSP-OLS –el umbral más bajo hace que el modelo marque más hogares como riesgo, capturando más verdaderos positivos (sube recall) a costa de más falsos positivos (baja precision)–. Es, otra vez, una consecuencia del procedimiento de selección de umbral (Sección 4.4), no evidencia de que DMSP-OLS cambie la capacidad predictiva del modelo; el AUC-ROC de este mismo par (0.734 $\rightarrow$ 0.732), que no depende de umbral, se mantiene esencialmente igual. HistGradientBoosting-A muestra un patrón más pequeño en la misma dirección (recall 0.736 $\rightarrow$ 0.692, precision 0.332 $\rightarrow$ 0.345, F1 estable en 0.457–0.458), y HistGradientBoosting-B tiene el mayor cambio de F1 de la tabla (0.437 $\rightarrow$ 0.449, +0.012) aunque tampoco económicamente significativo. Ningún caso invierte la conclusión general: DMSP-OLS reordena marginalmente qué hogares específicos caen a cada lado del umbral, sin mejorar la capacidad de discriminación subyacente del modelo.

Por qué DMSP-OLS no aporta: redundancia, no ausencia de señal. Tomada sola, `dmsp_stable_lights` sí correlaciona con la entrada a pobreza ($r = -0.214$ sobre la

muestra de entrenamiento) –una magnitud comparable a `ingreso_percapita_hogar_real` ($r = -0.211$) o `estrato_verificado_hogar` ($r = -0.215$)–, así que no se trata de una variable sin contenido informativo. El problema es que esa misma señal ya está capturada, de forma más directa y con mayor correlación con el resultado, por variables que la ELCA ya pregunta al hogar: `n_servicios_publicos_hogar` (número de servicios públicos del hogar) correlaciona 0.865 con `dmsp_stable_lights` –ambas miden, en esencia, el mismo fenómeno de electrificación y consolidación urbana del entorno– y a la vez correlaciona más fuerte con el resultado ($r = -0.250$) que la propia variable satelital; `n_bienes_durables_hogar` muestra el mismo patrón ($r = 0.477$ con DMSP-OLS, $r = -0.256$ con el resultado). La correlación *residualizada* de `dmsp_stable_lights` contra el resultado –tras controlar por esas dos variables mediante regresión lineal, y correlacionar los residuos de ambas contra los residuos del resultado– confirma directamente la redundancia: cae de $r = -0.214$ (cruda) a $r = +0.021$ (parcial, verificado con dos implementaciones independientes, mínimos cuadrados manual y `sklearn.LinearRegression`) –prácticamente todo el poder predictivo de DMSP-OLS ya está contenido en esas dos preguntas de la encuesta. Esto no implica que la encuesta mida el fenómeno subyacente (electrificación y consolidación urbana del entorno) con menos error que el sensor satelital –ambas son medidas imperfectas de ese mismo constructo, y comparar su error de medición respectivo está fuera del alcance de este ejercicio–; lo que sí muestra la correlación residualizada es que, *para este modelo predictivo específico*, DMSP-OLS no aporta información incremental una vez que `n_servicios_publicos_hogar` y `n_bienes_durables_hogar` ya están en el panel de covariables. Esto es consistente con la regularización elastic net de la logística, que puso en cero 21 de las 23 variables DMSP-OLS agregadas (Sección 3.2.1), y con la importancia por permutación de HistGradientBoosting, donde las variables DMSP-OLS caen en un rango de -0.0009 a 0.0003 –indistinguible de ruido una vez controlado por el resto del panel.

ALOS PALSAR y Landsat 5 TM: mismo patrón, por un mecanismo distinto.

Estas dos fuentes no tienen datos reales en la ola de prueba (2013, Sección 3.2), así que no pueden evaluarse con el mismo holdout temporal –se probaron, junto con DMSP-OLS, en un ejercicio exploratorio aparte: Modelo A/B **con las tres fuentes juntas** (DMSP-OLS + ALOS PALSAR + Landsat 5 TM), restringido a la transición 2010→2013 y evaluado con validación cruzada agrupada por hogar en vez de un periodo de prueba separado (`construir_pipeline_geo3_cv.py`). Los resultados de ese ejercicio **no son comparables cifra a cifra** con la Tabla 6 –evaluar dentro del mismo periodo que el entrenamiento es una prueba más débil que un holdout a otro momento– pero la correlación bruta de sus variables contra el resultado confirma el mismo patrón de redundancia que DMSP-

OLS: `alos_hh_db` correlaciona apenas $r = -0.113$ con la entrada a pobreza (frente a $r = -0.250$ de `n_servicios_publicos_hogar`) y `l5_ndvi` $r = 0.160$ –ambas más débiles que cualquiera de los proxies de riqueza ya presentes en la ELCA. La misma correlación residualizada calculada para DMSP-OLS, aplicada a `alos_hh_db` y `l5_ndvi` controlando por las mismas dos variables, también colapsa a valores cercanos a cero ($r = +0.010$ y $r = +0.011$ respectivamente, frente a $r = -0.113$ y $r = +0.160$ crudos). Ninguna de las tres fuentes geoespaciales nuevas parece aportar, para este panel de encuesta específico, información que la propia ELCA no capture ya de forma más directa.

¿Ayuda DMSP-OLS cuando la encuesta no pregunta por servicios públicos ni bienes del hogar? Si la redundancia con `n_servicios_publicos_hogar` y `n_bienes_durables_hogar` explica la ausencia de mejora, DMSP-OLS debería aportar más en un escenario donde esas dos preguntas no estuvieran disponibles –el caso realista de datos administrativos sin encuesta de hogar rica, o de una ola de encuesta futura sin ese módulo–. Se reentrenaron los tres algoritmos eliminando esas dos columnas de los Modelos A y B (“A sin riqueza” / “B sin riqueza” en lo que sigue; `Anoriq/Bnoriq` en el código) y de sus versiones con DMSP-OLS agregado (“A sin riqueza + DMSP-OLS” / “B sin riqueza + DMSP-OLS”; `AnoriqGeo/BnoriqGeo`). El resultado es mixto y, en conjunto, no confirma la hipótesis con fuerza: Logística regularizada es el único algoritmo con una mejora consistente aunque pequeña (AUC-ROC: “A sin riqueza” $0.7457 \rightarrow$ “A sin riqueza + DMSP-OLS” 0.7469 ; `precision_top10`: “A sin riqueza” $0.497 \rightarrow$ “A sin riqueza + DMSP-OLS” 0.500 , y “B sin riqueza” $0.500 \rightarrow$ “B sin riqueza + DMSP-OLS” 0.503); XGBoost no mejora en ninguna de las dos comparaciones (“A sin riqueza” $0.7635 \rightarrow$ “A sin riqueza + DMSP-OLS” 0.7615 ; “B sin riqueza” $0.7350 \rightarrow$ “B sin riqueza + DMSP-OLS” 0.7341); HistGradientBoosting mejora en el Modelo B sin riqueza pero empeora en el Modelo A sin riqueza. Que el único algoritmo con mejora consistente sea el lineal –el que, por construcción, no puede aprender automáticamente combinaciones no lineales de otras variables que sustituyan a DMSP-OLS– es coherente con la explicación de redundancia: los modelos de árboles, más flexibles, encuentran sustitutos suficientes en el resto del panel incluso sin las dos preguntas eliminadas, mientras que el modelo lineal sí gana algo al no tener esa alternativa. El efecto es, en cualquier caso, demasiado pequeño y demasiado inconsistente entre algoritmos para sostener una recomendación de política a partir de él.

¿Ayuda DMSP-OLS más cerca del umbral de pobreza? Se dividió el conjunto de prueba de XGBoost (Modelo A) en terciles según la distancia absoluta a la línea de pobreza en la ola base (`|brecha_lp_ingreso|`, `heterogeneidad_cerca_umbral.py`),

usando los hiperparámetros ya elegidos (sin volver a tunear, para aislar el efecto de agregar DMSP-OLS). El cambio en AUC-ROC al agregar DMSP-OLS es de -0.0008 en el tercil más cercano al umbral ($n = 1,064$, tasa de entrada 32.7%), $+0.0011$ en el tercil medio ($n = 1,107$, 19.2 %) y -0.0038 en el tercil más lejano ($n = 1,020$, 7.3 %). Aunque la caída es técnicamente menor cerca del umbral que lejos de él, el cambio sigue siendo negativo o prácticamente nulo en los tres terciles –no hay evidencia de que DMSP-OLS ayude de forma sustantiva ni siquiera en el subgrupo de hogares donde el ingreso reportado discrimina peor–.

5.4. Heterogeneidad territorial

Esta subsección también está pendiente. El diseño contempla reestimar el desempeño de los modelos de la Sección 5.2 por separado para zona urbana y rural, y –si el tamaño de muestra por región lo permite tras la partición temporal ya exigente en observaciones (3,089 hogares no pobres en la base de entrenamiento, Tabla 4)– por región geográfica.

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento reporta el avance de una tesis que busca evaluar si las variables geoespaciales públicas mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos no pobres, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Hasta el momento se ha completado la mitad “base” de esa comparación: la auditoría sistemática y no muestral de los cinco módulos de la ELCA (más de 4.000 columnas originales), la construcción rigurosa de la variable de resultado –transición a la pobreza entre olas, siguiendo el enfoque de López-Calva y Ortiz-Juárez (2011, 2014), con cinco ejercicios de robustez sobre su construcción–, y la estimación y comparación de cinco algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y HistGradientBoosting) bajo dos especificaciones de covariables.

Tres hallazgos se destacan de este avance. Primero, la dinámica de la pobreza en el panel ELCA 2010–2016 muestra una reducción sostenida de la incidencia (de 60.7 % a 42.4 % por ingreso) acompañada de una tasa de entrada a la pobreza –la variable de interés de esta tesis– de 23.4 % entre 2010–2013 y de 19.9 % entre 2013–2016, con una tasa de salida que casi duplica a la de entrada en ambos periodos. Segundo, los cinco algoritmos evaluados alcanzan un desempeño similar entre sí (AUC-ROC entre 0.727 y 0.764, con

intervalos de confianza sobre 5 semillas del ajuste final que en la mayoría de los casos son nulos o casi nulos, ver Sección 5.2), sin que ninguno domine claramente a los demás. El patrón ni siquiera es consistente entre especificaciones: en el Modelo A los tres *gradient boosting* y Random Forest superan a la regresión logística regularizada, pero en el Modelo B XGBoost y LightGBM caen por debajo de ella, y solo HistGradientBoosting y Random Forest se mantienen al mismo nivel o por encima. Tercero, y más importante para el diseño de la etapa siguiente de esta tesis, la brecha de desempeño entre el modelo que incluye ingreso/gasto del hogar y el que no los incluye es sorprendentemente pequeña (0.008–0.031 en AUC-ROC según el algoritmo): las covariables no monetarias –educación, activos, vivienda, choques, características de la comunidad– explican una fracción sustancial del poder predictivo que, bajo el enfoque clásico de vulnerabilidad (Chaudhuri et al., 2002), se atribuiría casi exclusivamente al ingreso. Esto sugiere que existe margen real para que fuentes de información adicionales –geoespaciales o de otro tipo– aporten poder predictivo incremental, la pregunta central que este trabajo busca responder en su etapa final.

6.2. Implicaciones para la política pública

Aunque los resultados presentados en este documento son intermedios, ya insinúan implicaciones relevantes para el diseño de sistemas de focalización como el SISBEN. Primero, la evidencia de que las covariables no monetarias tienen un poder predictivo casi comparable al del ingreso sugiere que un sistema de alerta temprana no necesita esperar a observar directamente el ingreso de un hogar –la variable más costosa y menos frecuente de actualizar– para identificar candidatos a la vulnerabilidad; características más fáciles de observar o de actualizar administrativamente (educación, activos del hogar, formalidad laboral) ya capturan buena parte de esa señal. Segundo, la comparación entre algoritmos (Sección 5.2) muestra que la elección del algoritmo correcto depende de la función de pérdida que le importa al hacedor de política: HistGradientBoosting maximiza el recall –relevante si el costo de no detectar un hogar que va a caer en pobreza (error de exclusión) es mucho mayor que el de incluir por error a uno que no cae (error de inclusión)–, mientras que XGBoost y Random Forest ofrecen mejor precisión al mismo nivel de AUC-ROC. Un sistema real debería fijar explícitamente esa preferencia antes de elegir el modelo, en vez de optimizar únicamente por AUC-ROC. Estas implicaciones se profundizarán, y se contrastarán contra el aporte específico de las fuentes geoespaciales, una vez completada la Sección 5.3.

6.3. Limitaciones y agenda de investigación

Por completar la Sección 5.3, la agenda de investigación de esta tesis continúa con la construcción de variables geoespaciales a partir de fuentes públicas, la integración de esas variables al panel ELCA, y la reestimación de los cinco algoritmos bajo las mismas condiciones de validación y balanceo de clases ya descritas. La comparación de desempeño entre el Modelo A (con ingreso/gasto) y el Modelo B (sin ellos) frente a un Modelo C (con variables geoespaciales) permitirá evaluar si estas últimas aportan poder predictivo incremental, y si ese aporte es suficiente para compensar la ausencia de información monetaria directa. La agenda también contempla la reestimación de los modelos por zona urbana/rural y, si el tamaño de muestra lo permite, por región geográfica, para evaluar la robustez territorial de los hallazgos.

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (inf. téc.). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). Assessing Household Vulnerability to Poverty from Cross-Sectional Data. *Columbia University Department of Economics Discussion Papers*, (0102-52).
- Christiaensen, L., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/713600071>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2025). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of*

- Sustainable Development & World Ecology*. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). *Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature* (ADB Working Paper). Asian Development Bank Institute.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*. <https://doi.org/10.1002/jid.3751>
- Hofer, M., Sako, T., Martinez, A. J., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*. <https://doi.org/10.1111/asej.12349>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Economics*, 61(1), 99-111.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juárez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juárez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón, G., Escobar, D., López, F., Pérez, P., & Orozco, J. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>

- Newhouse, D., Merfeld, J., Ramakrishnan, A., Swartz, T., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

B. Detalles de construcción de variables geoespaciales