

¿Pueden los datos geospaciales públicos mejorar la predicción de la vulnerabilidad a la pobreza?

Evidencia para hogares colombianos con base en la Encuesta Longitudinal de Colombia (ELCO)

Jonathan Melo Sarta

Maestría en Economía Aplicada

Universidad de los Andes

j-melo@uniandes.edu.co

Bogotá, 2026

Resumen

Los sistemas de focalización de programas sociales en Colombia, como el SISBEN, identifican pobreza como un estado observado y no anticipan qué hogares no pobres tienen mayor riesgo de caer en esa condición. Este trabajo evalúa si información pública, particularmente, características del entorno físico y económico local, mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Usando tres olas del panel (2010, 2013, 2016), se construye la variable de resultado como la entrada en pobreza de hogares inicialmente no pobres y se estiman distintos algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting), evaluando su capacidad predictiva en un período posterior al utilizado para su estimación: los modelos se entrenan con las transiciones observadas entre 2010 y 2013 y se evalúan con las transiciones entre 2013 y 2016. Este esquema permite evaluar el desempeño de los modelos en datos temporalmente posteriores a aquellos utilizados para su entrenamiento, aproximándose a su capacidad para anticipar transiciones futuras hacia la pobreza. Los modelos se estiman con y sin variables monetarias del hogar. El modelo base, que es lo que se reporta en esta versión del documento, alcanza

un AUC-ROC entre 0.731 y 0.767 según el algoritmo, con una brecha de apenas 0.008–0.028 entre la especificación que incluye ingreso/gasto del hogar y la que no lo hace, lo que sugiere que las covariables no monetarias capturan una fracción sustancial del poder predictivo típicamente atribuido al ingreso. La incorporación de las variables geoespaciales, contribución central de esta tesis, está en construcción. De confirmarse un aporte incremental, los resultados podrían fortalecer instrumentos de focalización con información de mayor frecuencia y menor costo de actualización que las encuestas de hogares tradicionales.

Palabras clave: vulnerabilidad a la pobreza, aprendizaje de máquinas, datos geoespaciales, ELCA, focalización, Colombia.

Índice

1. Introducción	5
2. Marco conceptual y revisión de literatura	6
2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales	6
2.2. Aprendizaje de máquinas en la predicción de pobreza	8
2.3. Variables geoespaciales como fuente complementaria	9
2.4. Síntesis y vacío que llena este trabajo	10
3. Datos	11
3.1. Encuesta Longitudinal Colombiana (ELCA)	11
3.2. Fuentes geoespaciales	12
3.3. Estadísticas descriptivas	15
3.3.1. Composición del panel y atrición	15
3.3.2. Inventario temático de las variables finales	16
3.3.3. Correlación entre covariables y riesgo de multicolinealidad	17
4. Estrategia empírica	20
4.1. Construcción de la variable de resultado	20
4.2. Especificación de modelos	20
4.3. Validación fuera de muestra y métricas	21
4.4. Tratamiento del desbalance de clases	22
4.5. Importancia de variables e interpretabilidad	24
5. Resultados	25
5.1. Dinámica de transiciones a la pobreza en la ELCA	25
5.2. Perfil de los hogares vulnerables	27
5.3. Desempeño comparativo de modelos	37
5.4. Contribución marginal de las variables geoespaciales	45
5.5. Heterogeneidad territorial	51
6. Conclusiones	51
6.1. Síntesis de hallazgos	51
6.2. Implicaciones para la política pública	52
6.3. Limitaciones y agenda de investigación	53
Referencias	54

A. Tablas y figuras complementarias	57
A.1. Incidencia, FGT y robustez de las transiciones de pobreza monetaria . . .	57
A.1.1. Incidencia y descomposición FGT	57
A.1.2. Ejercicios de robustez	59
A.2. Perfil completo de covariables, pobreza multidimensional (IPM)	62
B. Detalles de construcción de variables geoespaciales	65

1. Introducción

La literatura sobre pobreza ha enfatizado tradicionalmente su medición como un estado observado en la situación de un hogar en un momento determinado del tiempo. Sin embargo, diversos trabajos han argumentado que la pobreza y el riesgo de caer en pobreza son fenómenos conceptualmente distintos que deben analizarse de manera diferenciada (Chaudhuri et al., 2002). En esta literatura, la vulnerabilidad, entendida como la probabilidad de experimentar pobreza en el futuro, se ha desarrollado como un concepto clave para superar el carácter estático de algunos diagnósticos tradicionales (Fujii, 2016). En particular, López-Calva y Ortiz-Juárez (2011) muestran que entre los hogares que superan la línea de pobreza existe una población significativa que enfrenta una alta probabilidad de caer en ella ante afectaciones moderadas, lo que hace necesario distinguir analítica y operativamente entre pobres, vulnerables y hogares con seguridad económica consolidada.

Identificar qué hogares son vulnerables a caer en pobreza, antes de que ocurra la caída, requiere información dinámica y actualizada sobre su situación, algo que los sistemas tradicionales de focalización no están diseñados para proveer. En Colombia, el Sistema de Identificación de Beneficiarios de Programas Sociales (SISBEN) opera a través de una encuesta cuya aplicación depende de la solicitud de los hogares y de los recursos de la entidad territorial responsable, lo que genera rezagos en la actualización de la información y dificulta contar con datos recientes sobre el efecto de choques (Consejo Nacional de Política Económica y Social, 2016). La pandemia de COVID-19 puso en evidencia las limitaciones de información sobre focalización de política pública con las que cuenta el país (Castañeda Castrillón, 2021), y ejercicios recientes de aproximación a la vulnerabilidad monetaria en Bogotá mediante pseudo-panel confirman tanto la relevancia del problema como las restricciones que impone la ausencia de datos longitudinales reales sobre los hogares (Castañeda Castrillón, 2012; Gaitán, 2023).

Esta tesis aprovecha la disponibilidad de la Encuesta Longitudinal Colombiana (ELCA), con tres olas de seguimiento a los mismos hogares (2010, 2013 y 2016), para construir y comparar modelos predictivos de *transición* hacia la pobreza monetaria. Este abordaje es distinto al de la literatura de la pobreza contemporánea que predice la mayoría de la literatura de aprendizaje de máquinas aplicada a este problema (Ferdausi et al., 2025; Muñetón et al., 2022)–. La pregunta de investigación que guía el trabajo es: ¿En qué medida la incorporación de variables del entorno físico y económico local derivadas de imágenes de Google Street View mejora la predicción de caída en pobreza monetaria de hogares no pobres, frente a modelos basados exclusivamente en características socioeconómicas del

hogar reportadas en encuestas?

El estado actual de este documento cubre la primera mitad de esa pregunta: la construcción rigurosa de la variable de resultado, la auditoría exhaustiva de las covariables socioeconómicas disponibles en la ELCA (más de 4.000 columnas originales revisadas variable por variable a través de cinco módulos), y la estimación y comparación de cinco algoritmos de aprendizaje supervisado: regresión logística regularizada, Random Forest, XGBoost, LightGBM y GradientBoosting– sobre el modelo *base* (sin variables geoespaciales). La incorporación de las fuentes geoespaciales y la comparación frente al modelo extendido, que es la contribución central de la pregunta de investigación, está en construcción y se documenta como trabajo en curso en la Sección 6.3.

La contribución de este trabajo es doble. Primero, metodológica: a diferencia de la literatura de predicción de pobreza contemporánea, este trabajo define explícitamente la variable de resultado en términos prospectivos (transición, no estado), usa una partición temporal hacia adelante fiel al caso de uso real de un sistema de focalización (entrenar con el pasado, evaluar en el futuro), y documenta de forma sistemática y verificable la calidad y cobertura de cada covariable utilizada. Segundo, empírica: genera evidencia novedosa para Colombia sobre el aporte relativo de información geoespacial pública en la predicción de transiciones a la pobreza, un problema no abordado directamente por la literatura existente aplicada al país.

El resto del documento se organiza así. La Sección 2 revisa el marco conceptual de vulnerabilidad a la pobreza y la literatura de aprendizaje de máquinas aplicada a su predicción. La Sección 3 describe la ELCA y las fuentes geoespaciales. La Sección 4 detalla la estrategia empírica: construcción del outcome, especificación de los modelos, validación fuera de muestra y tratamiento del desbalance de clases. La Sección 5 presenta los resultados obtenidos hasta el momento. La Sección 6 cierra con una síntesis, implicaciones de política y la agenda de trabajo pendiente.

2. Marco conceptual y revisión de literatura

2.1. Vulnerabilidad a la pobreza: fundamentos conceptuales

Uno de los aportes fundacionales de la literatura de pobreza es la distinción entre pobreza crónica y pobreza transitoria. Utilizando paneles de hogares rurales en China, Jalan y Ravallion (2000) muestran que la pobreza persistente se relaciona principalmente con limitaciones estructurales (bajos niveles de activos productivos o capital humano), mientras que la pobreza transitoria suele originarse en fluctuaciones del ingreso asociadas

con choques económicos (ej. pérdida de empleo, caídas en precios) o eventos adversos (ej. desastres naturales, conflictos). Esta distinción tiene implicaciones directas para el diseño de política: los hogares crónicamente pobres requieren intervenciones orientadas a la acumulación de activos y el acceso a servicios, mientras que los hogares transitoriamente pobres requieren mecanismos de protección ante choques y de recuperación rápida del ingreso.

La magnitud y persistencia de esas fluctuaciones depende no solo de la severidad del choque sino de la capacidad del hogar para absorberlo. Dercon y Krishnan (2000) documentan que los hogares en contextos rurales de bajos ingresos enfrentan variaciones sustanciales en bienestar ante choques idiosincráticos (enfermedad, pérdida de empleo, muerte de un activo productivo del hogar) y covariados (eventos climáticos extremos, caídas en precios agrícolas, crisis macroeconómicas compartidos por todos). Esa capacidad de resiliencia está determinada por los activos físicos, humanos y sociales del hogar y por el entorno institucional en que opera. Christiaensen y Subbarao (2005) refuerzan este punto al mostrar que en muchos países en desarrollo existe una población significativa de hogares no pobres pero altamente expuestos: su situación actual los ubica por encima de la línea de pobreza, pero su fragilidad patrimonial los hace vulnerables a caer ante afectaciones moderadas. Esta población es precisamente la que los sistemas tradicionales de focalización tienen mayor dificultad para identificar, dado que no son pobres bajo el criterio estático.

A partir de estos hallazgos se ha desarrollado la literatura sobre vulnerabilidad a la pobreza, que la conceptualiza como la probabilidad *ex ante* de que un hogar experimente pobreza en el futuro. El enfoque seminal de Chaudhuri et al. (2002) y del que parte este trabajo, propone estimar esa probabilidad a partir de la media y la varianza esperadas del consumo o ingreso del hogar, definiendo la vulnerabilidad como la probabilidad de que el bienestar futuro caiga por debajo de la línea de pobreza. Desarrollos posteriores han refinado esta definición incorporando la distinción entre vulnerabilidad ante choques idiosincráticos y covariados (Dercon, 2002), y aplicaciones específicas para contextos latinoamericanos (Bérgolo et al., 2010; Costella et al., 2023).

Un aporte particularmente relevante para este trabajo es el de López-Calva y Ortiz-Juárez (2011, 2014), quienes operacionalizan el concepto de vulnerabilidad en América Latina explotando datos longitudinales de Chile, México y Perú para estimar empíricamente el umbral de ingreso asociado a una probabilidad del 10 % de caer en pobreza, y proponen la clasificación en cuatro trayectorias –nunca pobre, siempre pobre, sale de la pobreza, entra en pobreza– que se adopta en la Sección 5.1 de esta tesis. Sus resultados muestran que la población vulnerable, cuantitativamente significativa en los tres países, no puede identificarse adecuadamente con métodos de focalización basados en el estado observado

de pobreza.

En el contexto colombiano, la aplicación de estos enfoques ha enfrentado restricciones de datos que han limitado su alcance. Castañeda Castrillón (2012) estudió las trampas de pobreza mediante la construcción de un pseudo-panel, y Gaitán (2023) analizó la vulnerabilidad monetaria a nivel de localidades en Bogotá con el mismo enfoque, como una manera para superar la ausencia de un panel de hogares con representatividad y cobertura suficiente; sus resultados –cerca del 23 % de la población bogotana en situación de vulnerabilidad en 2021– confirman la relevancia del problema, pero también evidencian las restricciones que impone el uso de cortes transversales repetidos en lugar de datos longitudinales reales. La disponibilidad de la ELCA, con tres olas de seguimiento a los mismos hogares, ofrece una oportunidad inédita para superar esta limitación en el contexto colombiano. Incluso con datos longitudinales, sin embargo, esta literatura enfrenta una restricción operativa adicional: los métodos desarrollados dependen, casi sin excepción, de encuestas de hogares con información detallada sobre ingresos, activos y consumo, costosas, de levantamiento infrecuente y con rezagos significativos entre la recolección y la disponibilidad de los datos. Esta restricción informacional es la que motiva la exploración de fuentes alternativas de datos que puedan aproximar la vulnerabilidad con mayor frecuencia de actualización y menor costo de recolección (Sección 2.3).

2.2. Aprendizaje de máquinas en la predicción de pobreza

La literatura sobre predicción de pobreza mediante algoritmos de aprendizaje automático ha avanzado de manera importante en los últimos años, pero es necesario señalar una distinción conceptual central: la mayoría de estos trabajos predice el estado *contemporáneo* de pobreza –si un hogar es pobre en un momento dado– y no la vulnerabilidad a la pobreza en el sentido de la Sección 2.1, es decir, la probabilidad *ex ante* de que un hogar no pobre caiga en esa situación en el futuro. Esta distinción no es menor: requiere datos longitudinales, un horizonte temporal prospectivo y una variable de resultado distinta a la pobreza observada. La literatura que se revisa a continuación constituye el antecedente metodológico más próximo disponible, pero no resuelve directamente el problema que aborda esta investigación.

Los modelos de prueba indirecta de medios (*proxy means tests*, PMT) han sido durante décadas el instrumento estándar para la focalización de programas sociales en países en desarrollo. Su desarrollo ha privilegiado históricamente la minimización del error *dentro* de la muestra de entrenamiento, lo cual no garantiza un buen desempeño cuando el modelo se aplica a poblaciones nuevas. McBride y Nichols (2018) documentan este problema en detalle y muestran que priorizar la validación fuera de muestra, mediante validación

cruzada y algoritmos como Random Forest y Quantile Regression Forest, puede mejorar sustancialmente la precisión de las herramientas de focalización, reduciendo la tasa de exclusión de hogares pobres y mejorando la precisión balanceada en hasta 17 puntos porcentuales frente a los métodos tradicionales. Siguiendo esta perspectiva, esta tesis evalúa el desempeño de los modelos fuera de la muestra mediante un *holdout* temporal hacia adelante: los modelos se entrenan con información de períodos anteriores y se evalúan con información de un período posterior. De esta manera, la validación permite aproximarse mejor a la situación en la que el modelo se utilizaría en la práctica, es decir, para predecir la vulnerabilidad de hogares en un período futuro (Sección 4.3). Este resultado debe matizarse con la advertencia de Usmanova et al. (2022): los métodos de aprendizaje automático tienden a mejorar la predicción en contextos de alta dimensionalidad y relaciones no lineales entre variables, pero un modelo entrenado en un país no necesariamente funciona bien en otro, debido a diferencias económicas, sociales y culturales que no captura.

El trabajo de Ferdausi et al. (2025) es el que más se aproxima conceptualmente al problema de la vulnerabilidad, al aplicar algoritmos de aprendizaje automático a datos de hogares en zonas costeras de Bangladesh para identificar predictores de pobreza extrema, logrando una precisión del 96 % con un conjunto reducido de siete variables. Sus resultados revelan heterogeneidad significativa en los factores de vulnerabilidad entre grupos demográficos, pero el trabajo predice también un estado observado –ser pobre extremo– y no la probabilidad de transición hacia la pobreza en un periodo futuro, lo que lo mantiene dentro de la misma limitación conceptual que caracteriza al resto de la literatura. En Colombia, Muñetón et al. (2022) han aplicado aprendizaje de máquinas a la clasificación de pobres, pero su aplicación en un contexto de datos longitudinales y para el análisis de la vulnerabilidad ha sido explorada de manera limitada.

2.3. Variables geoespaciales como fuente complementaria

Existe una literatura creciente que usa fuentes de datos no convencionales para aproximarse a perfiles de población en ausencia de datos confiables y pertinentes. Blumenstock et al. (2015) demuestran que los metadatos de telefonía móvil permiten predecir el nivel de bienestar económico de los hogares en Ruanda con precisión considerable. Jean et al. (2016) extendieron esta lógica al dominio satelital, mostrando que la combinación de imágenes satelitales con datos de encuesta permite explicar hasta el 75 % de la variación en consumo o riqueza en contextos africanos, superando lo que cualquiera de las dos fuentes logra de manera aislada. Li et al. (2019) muestran que a partir de imágenes de luminosidad nocturna es posible clasificar la pobreza a nivel de condados con precisiones superiores al 82 %, aunque advierten que su capacidad discriminatoria se reduce en contextos de

pobreza muy extendida, donde la variabilidad espacial de las imágenes es insuficiente para distinguir entre hogares con distintos niveles de privación.

Trabajos más recientes han avanzado hacia la evaluación sistemática del valor incremental de las fuentes geoespaciales, incluyendo aplicaciones en contextos latinoamericanos. Newhouse et al. (2025) muestran para México que combinar imágenes satelitales con encuestas de hogares mejora la precisión de las estimaciones de pobreza monetaria a nivel municipal, un nivel de desagregación en el que la encuesta sola no es representativa. Aiken et al. (2022) muestran que la combinación de datos satelitales y de telefonía móvil reduce los errores de exclusión en programas sociales entre 4 % y 21 % frente a los métodos tradicionales. Hall et al. (2023), en una revisión sistemática, documentan que la combinación de múltiples fuentes incrementa el poder predictivo hasta en 15 puntos porcentuales, pero identifican que los datos geoespaciales predicen mejor activos físicos que variables de flujo como ingreso o consumo, y que su desempeño depende críticamente del contexto geográfico. Hofer et al. (2025) añaden que la ventaja de estas fuentes reside tanto en la información nueva que aportan como en su mayor granularidad espacial y frecuencia de actualización, lo que las hace especialmente valiosas para actualizar sistemas de focalización entre levantamientos de encuestas – la motivación directa de las fuentes geoespaciales que esta tesis busca incorporar (sección 3.2).

2.4. Síntesis y vacío que llena este trabajo

La evidencia revisada muestra que los modelos que combinan variables geoespaciales con información socioeconómica de encuestas superan a los basados exclusivamente en cualquiera de las dos fuentes, con ventajas más pronunciadas cuando la validación se realiza fuera de muestra. Sin embargo, ninguno de los trabajos revisados aborda directamente el problema de predecir la probabilidad de caída en pobreza de hogares actualmente no pobres, y mucho menos en un contexto de datos longitudinales de hogar como el que ofrece la ELCA. Predecir transiciones hacia la pobreza es un problema conceptualmente distinto al de estimar pobreza contemporánea: requiere una variable de resultado definida en términos prospectivos, un horizonte temporal explícito entre olas de panel, y un conjunto de variables predictoras que capture tanto las condiciones del hogar como las del entorno en el momento previo a la transición.

Es en esta brecha donde esta investigación busca contribuir, evaluando si la incorporación de variables del entorno físico y económico local derivadas de fuentes geoespaciales públicas a los datos longitudinales de la ELCA permite mejorar la identificación de hogares en riesgo de caer en pobreza en Colombia. Es importante señalar que, en contextos de política pública, la predicción es valiosa incluso en ausencia de interpretación causal Kleinberg et al.

(2015), especialmente porque el objetivo es mejorar la focalización *ex ante* de la política social. Por esta razón, este trabajo se sitúa en un enfoque predictivo más que causal, donde el objetivo no es identificar efectos estructurales sino mejorar la capacidad de anticipar transiciones hacia la pobreza con miras a mejorar la focalización de políticas públicas de seguridad social.

3. Datos

3.1. Encuesta Longitudinal Colombiana (ELCA)

La fuente primaria de datos es la Encuesta Longitudinal Colombiana de la Universidad de los Andes (ELCA), que sigue a los mismos hogares en tres olas: 2010, 2013 y 2016, en zonas urbana y rural. La ELCA se organiza en en módulos temáticos: hogar, personas, niños, comunidades y choques, además de los módulos de activos y gasto. Existen dos olas más disponibles para 2019 y 2022, que administra el DANE. No obstante, por cuestiones de tiempo no se utilizaron en el marco de esta investigación. El identificador de hogar cambia de nombre entre olas (`consecutivo`→`llave`→`llave_n16`). Para los análisis realizados en esta tesis, se usan exclusivamente coincidencias uno a uno de este identificador entre olas consecutivas, excluyendo los hogares que se dividieron en dos o más sub-hogares (511 casos entre 2010–2013 y 1,190 entre 2013–2016, ver Tabla 3), para no hacer supuestos reespecto de su ubicación entre hogares divididos.

Antes de construir cualquier covariable se realizó una auditoría sistemática de los módulos de la encuesta. La auditoría tuvo cuatro capas, replicadas de forma idéntica en cada módulo: (i) detección y corrección de signos y símbolos de codificación de caracteres (por ej. el carácter Unicode de reemplazo U+FFFD y el literal `¿??`" en lugar de vocales acentuadas y la letra ñ); (ii) clasificación exhaustiva de cada columna según su cobertura en las tres olas; (iii) búsqueda de columnas renombradas entre olas; y (iv) verificación para toda columna con cobertura menor al 10 %, de si esa baja cobertura refleja una pregunta filtro (por ejemplo, solo se pregunta a hogares con niños) y no una pérdida de información evitable.

El resultado es un panel hogar x ola consolidado de 27,932 observaciones (9,853 en 2010, 9,261 en 2013 y 8,818 en 2016) y 184 columnas, que combinan las covariables construidas a partir de los módulos con las variables monetarias (ingreso y gasto per cápita del hogar, nominal y real, y brecha frente a la línea de pobreza). Para las variables de personas y niños agregadas al nivel de hogar se siguieron reglas explícitas y documentadas según el tipo de variable: conteos y proporciones para composición demográfica, conteo de “al menos uno”

cuando la presencia de un solo miembro con una característica ya cambia la vulnerabilidad del hogar (por ejemplo, algún miembro con discapacidad), máximo para capital humano disponible (ej. nivel educativo más alto del hogar), y el valor del jefe de hogar sin agregar cuando la literatura lo usa como proxy estándar. Las tasas de mercado laboral se calculan restringiendo el denominador a personas en edad de trabajar (15 años o más, siguiendo el estándar DANE/GEIH) antes de agregar, y los missings a nivel persona se excluyen del denominador en vez de contarse como si no cumplieran la condición.

3.2. Fuentes geoespaciales

Este trabajo utiliza información geoespacial disponible públicamente y de manera gratuita como proxy de las condiciones espaciales del entorno y la infraestructura. La idea es que la información geoespacial de los hogares puede capturar características del entorno físico y económico local que afectan la vulnerabilidad de estos hogares a caer en pobreza, pero que no se refleja completamente en las encuestas tradicionales que realizan gobiernos y otras organizaciones. Para esto, a partir de las coordenadas de los hogares de la ELCA, que se encuentran para consulta de manera estrictamente controlada y restringida por parte de la Universidad de los Andes, se consolida la información geoespacial disponible en línea a través de consultas a la API de Google Earth Engine. Esta información se anexa a la base de datos de la ELCA para cada hogar, y se utiliza como covariable adicional en los modelos predictivos de transición hacia la pobreza.

La necesidad fundamental de este proyecto es tener información geoespacial para al menos dos olas: 2010 es la ola para la que se entrenan los modelos que predicen la transición a la pobreza —el ejercicio central de esta tesis—, mientras que la transición 2013→2016 se usa después para determinar el poder predictivo de esas mismas variables fuera de muestra (Sección 4.1).

Inicialmente, se priorizó la utilización de imágenes de Google Street View, sin embargo, su cobertura es limitada en Colombia y no alcanza a cubrir ninguna de las olas suficientemente. Por esta razón, se evaluaron otras seis fuentes satelitales o aéreas públicas adicionales: —Sentinel-1 (radar), Sentinel-2 (óptico), VIIRS DNB y DMSP-OLS (luces nocturnas), y ALOS PALSAR y Landsat 5 TM (evaluadas específicamente por tener cobertura anterior a 2014, cuando las demás fuentes satelitales modernas todavía no operaban)— y se descartó OpenStreetMap porque el mapeo de Colombia apenas empezaba a poblarse en 2010–2013 (el Humanitarian OpenStreetMap Team se fundó en 2010), por lo que la información histórica de esos años estaría demasiado vacía para ser útil.

Sentinel-1, Sentinel-2 y VIIRS DNB se descartaron porque ninguna de las tres empezó a operar antes de 2012 (VIIRS, abril 2012), y las otras dos ni siquiera existían como satélites

lanzados (Sentinel-1, abril 2014; cobertura global L2A de Sentinel-2, marzo 2017) —por lo que no puede existir ninguna imagen real de ellas anterior a esas fechas, en ningún catálogo—. Por eso se evaluaron específicamente en el marco de este proyecto: DMSP-OLS, ALOS PALSAR y Landsat 5 TM, las tres únicas fuentes públicas con cobertura real anterior a 2014.

La Figura 1 resume, para las siete fuentes evaluadas, su ventana de disponibilidad, verificada contra la documentación oficial de cada catálogo: Copernicus/ESA, NOAA, JAXA, USGS, Google Earth Engine Data Catalog, y, para DMSP-OLS, ALOS PALSAR y Landsat 5 TM, contra consultas reales de las coordenadas de los hogares en las tres olas de la ELCA (2010, 2013, 2016). El patrón diagonal marca cobertura real confirmada sobre hogares del proyecto; el resto se revisó cobertura de catálogo sin realizar consultas de los hogares disponibles (Sentinel-2, VIIRS).




Figura 1: Cobertura temporal real de cada fuente geoespacial evaluada, frente a las tres olas de la ELCA con coordenadas disponibles. El patrón diagonal indica corrida real y completa sobre hogares del proyecto; el resto se revisó cobertura según catálogo. En la barra de GSV, la intensidad del color es proporcional a la densidad real de fotos por año —la gran mayoría de las fotos son de 2023 en adelante.

El resultado de la corrida de producción, ya completa sobre las tres, es asimétrico. DMSP-OLS cubre el 100 % de los hogares tanto en 2010 como en 2013; es la única de las tres con esa cobertura completa en dos olas, lo que permite usarla para la evaluación del poder predictivo en la transición 2013→2016. ALOS PALSAR cubre el 100 % de los hogares en 2010, pero tiene un hueco de información confirmado en el catálogo de JAXA entre 2011 y 2014 —no tiene ninguna cobertura de 2013—. Landsat 5 TM cubre solo 65.5 % de los

hogares en 2010 (6,269 de 9,573; el resto pierde el año completo por nubosidad persistente, una limitación del sensor óptico) y, pese a que su fecha formal de salida (junio de 2013) sugeriría cobertura parcial de esa ola, una consulta directa al catálogo de Google Earth Engine confirmó que el sensor dejó de adquirir información utilizable antes de esa fecha, no hay ninguna imagen real de Landsat 5 en 2012 ni en 2013, en ningún punto del planeta. Las tres se incorporan al proyecto.

La Tabla 1 resume, para las tres fuentes nuevas, el mecanismo físico de medición, el nombre de las variables principales que se construyeron, y la interpretación que se les da en este estudio.

Cuadro 1: Qué mide cada fuente nueva, qué variables construye, y qué aproxima cada una.

Fuente	Mecanismo físico	Variables (estado / ventana acum.)	Qué aproxima
DMSP-OLS	Radiancia visible nocturna captada por satélite (aluminado público, vivienda, comercio)	Estado: nivel, log, saturación Acumulada: media, tendencia, crecimiento (sobre <code>stable_lights</code>)	Actividad económica y electrificación agregada del entorno (nivel); si el entorno se venía electrificando/densificando antes de la ola (ventana acumulada)
ALOS PALSAR	Retrodispersión de radar en banda-L (HH, HV) sobre estructuras y vegetación	Estado: HH, HV (dB), razón HH/HV, índice normalizado Acumulada: media, tendencia, crecimiento de cada una	Densidad y consolidación del entorno construido vs. vegetación (nivel); si la zona se venía densificando/deforestando antes de 2010 (ventana acumulada)
Landsat 5 TM	Reflectancia óptica multiespectral (visible, infrarrojo cercano, infrarrojo de onda corta)	Estado: NDVI, NDBI, BSI, Tasseled Cap (10 índices) Acumulada: media, tendencia, crecimiento de NDVI/NDBI/BSI/brillo	Cobertura vegetal y densidad de construcción del entorno inmediato (nivel); pérdida de vegetación o expansión de área construida antes de la ola (ventana acumulada)

3.3. Estadísticas descriptivas

La Tabla 2 resume la cobertura de covariables por módulo en el dataset consolidado. Los módulos de Hogar, Personas y Choques cubren la totalidad del panel (27,932 observaciones) porque se preguntan a todo hogar, sin condición previa. Comunidades y Niños no llegan a 100 % porque comunidades se mide a un nivel de agregación distinto: es comunidad×ola, no hogar×ola, por lo que representa un 92–96 % de cobertura. Esta cobertura incompleta refleja hogares cuya comunidad no tuvo un registro correspondiente en esa ola; Niños, por construcción, solo aplica a hogares con al menos un niño de 6 a 9 años en el periodo, así que su 55.4 % de cobertura es exactamente la proporción de hogares que cumplen esa condición.

Cuadro 2: Cobertura de covariables por módulo en el dataset consolidado

Módulo	Candidatas auditadas	Usadas en el modelo	Cobertura (%) del panel)
Hogar	155	103	100 %
Personas (9 bloques)	139	57	100 %
Comunidades	212	21	91.9–96.4 %
Niños (6–9 años)	83	13	55.4 % (15,473 / 27,932)
Choques	–	17	100 %

Nota: “Candidatas auditadas” es el número de columnas del módulo que superaron los cuatro filtros de calidad de la auditoría (Sección 3.1); “usadas en el modelo” es el subconjunto final tras la construcción de *features* – excepto en Hogar, donde por la magnitud de la compresión hacia variables compuestas (61 columnas finales) se reporta en cambio el número de candidatas crudas absorbidas, directas o dentro de un compuesto (`docs/decisions.md`, “Bloque de features de Hogar”). No incluye llaves de identidad (p. ej. `consecutivo_c` en Comunidades). Fuente: cálculos propios con base en ELCA 2010, 2013, 2016 y `docs/variable_audit/*_construccion.csv`, generados por `src/tabla_cobertura_modulos.py`.

3.3.1. Composición del panel y atrición

Como en toda encuesta longitudinal existe algo de pérdida de datos (atrición) que se caracteriza de la siguiente manera: el panel comienza con 9,853 hogares únicos en 2010 y se reduce a 8,729 en 2013 y 8,086 en 2016 (Figura 2, izquierda) —una atrición de 11.4 % entre 2010 y 2013, 11.4 % entre 2013 y 2016, y 17.9 % acumulada entre 2010 y 2016 (Figura 2, derecha). Esta pérdida no es aleatoria: se concentra en zonas urbanas (16.2 % de los hogares urbanos de 2010 se pierden hacia 2013, frente a solo 5.8 % de los rurales), lo opuesto a la intuición de que la atrición rural sería mayor por dificultad de rastreo geográfico

—probablemente porque la ELCA invierte más esfuerzo de rastreo en hogares rurales, dado que son la población de interés original de la encuesta. Por esta razón, en este estudio se utilizan técnicas de balanceo para compensar este sesgo.




Figura 2: Izquierda: hogares únicos por ola. Derecha: tasa de pérdida de hogares entre olas consecutivas y acumulada 2010–2016. Fuente: cálculos propios.

Parte de la aparente estabilidad del panel esconde un fenómeno distinto: la división de hogares. 511 hogares originales de 2010 se dividieron en 1,043 sub-hogares hacia 2013, y 679 hogares se dividieron en 1,411 sub-hogares hacia 2016 —típicamente porque un hijo formó su propio hogar en la misma vivienda o predio—. Por eso el número de *filas* del panel hogar×ola (9,853 / 9,261 / 8,818, ola 1/2/3) no coincide con el número de hogares *únicos* por ola: un sub-hogar nuevo aporta una fila adicional sin ser, en sentido estricto, un hogar nuevo captado por primera vez. El número de personas cubiertas por el panel cae de forma más pronunciada que el de hogares —43,202 personas en 2010, 39,920 en 2013, 35,722 en 2016 (18.7% de caída acumulada, por encima del 17.9% de hogares)— porque los hogares perdidos tienden a ser, en promedio, ligeramente más grandes que los que permanecen en el panel.

3.3.2. Inventario temático de las variables finales

El dataset consolidado que alimenta el modelo (27,932 filas hogar×ola) reúne 181 variables finales: 177 provienen de los cinco módulos de la ELCA ya auditados en la Tabla 2 —excluyendo de ese conteo `consecutivo_c`, que es la llave de unión al módulo Comunidades, no una covariable— y las 4 restantes son las variables geoespaciales. La Figura 3 desagrega ese total por módulo y por tipo de dato. Personas (57) y Hogar/vivienda/activos (56) concentran más de la mitad del inventario —consistente con que son los módulos que se

preguntan a todo hogar sin condición previa (Tabla 2)—, mientras que Comunidades (21), Choques (17), Niños (13) y Geoespacial (4) son universos más acotados, ya sea por su nivel de agregación distinto (Comunidades) o por aplicar solo a una submuestra o a una sola ola (Niños, Geoespacial). De las 181, 159 (88 %) son numéricas continuas o de conteo, 17 categóricas (principalmente características del jefe de hogar y de la vivienda) y 5 booleanas (los indicadores de pobreza monetaria).




Figura 3: Inventario de las 181 variables finales del dataset consolidado, por módulo temático y tipo de dato. Fuente: cálculos propios.

3.3.3. Correlación entre covariables y riesgo de multicolinealidad

Para evaluar el riesgo de multicolinealidad se calculó la correlación de Pearson entre las 159 variables numéricas del consolidado —incluidas las 4 geoespaciales—. Para evitar correlaciones espurias por pocas observaciones conjuntas no-nulas (un riesgo real dado que varios módulos tienen cobertura parcial, Tabla 2), solo se reportan como “altas” los pares con $|r| > 0.7$ calculados sobre al menos 500 observaciones conjuntas; con ese filtro se identifican los 35 pares de la Figura 4.

La inmensa mayoría son redundancias esperadas por construcción, no hallazgos: la versión nominal y real del ingreso/gasto per cápita correlacionan sobre 0.97 con su propia brecha a la LP; `1p` y `1i` correlacionan 0.87 (ambas son la misma línea oficial del DANE, apenas escaladas distinto); `estrato_hogar` y su versión verificada correlacionan 0.95; afiliación/cotización a pensión y salud laboral del jefe correlacionan entre 0.83 y 0.92 entre sí (son proxies del mismo estatus de formalidad laboral); y deuda formal vs. informal

correlacionan -0.93 (son, casi por definición, alternativas mutuamente excluyentes de financiamiento). Estos grupos no deberían sorprender a quien especifique un modelo con todas estas variables simultáneamente, pero sí deberían pesar en la selección de variables de la Sección 4: para el modelo de regresión logística regularizada, incluir varias variables de un mismo grupo redundante no mejora el ajuste y sí infla la varianza de los coeficientes individuales —la regularización ℓ_1/ℓ_2 mitiga, pero no elimina, ese riesgo—, mientras que los modelos de árboles (Random Forest, XGBoost, LightGBM, HistGradientBoosting) son estructuralmente más robustos a esta colinealidad porque cada partición usa una sola variable a la vez.

Un hallazgo no trivial es que `dmisp_stable_lights` correlaciona 0.87 con la línea de pobreza `lp` y 0.81 con el número de servicios públicos del hogar (`n_servicios_publicos_hogar`). Esto se puede deber a que la LP oficial del DANE es distinta para zona urbana y rural (típicamente mayor en zona urbana), y el acceso a servicios públicos también está fuertemente urbanizado, de modo que la luz nocturna, un proxy remoto y no auto-reportado de urbanización, reproduce correctamente una división que la encuesta captura por otras vías. Esto respalda el argumento de fondo de la Sección 3.2 (las fuentes geoespaciales capturan información real del entorno), pero también implica que buena parte de lo que DMSP-OLS podría aportar como covariable nueva ya está parcialmente contenido en variables de la encuesta —la pregunta de si aporta poder predictivo *incremental*, más allá de esta correlación, se responde directamente en la Sección 5.4.



Figura 4: Pares de variables con correlación de Pearson $|r| > 0.7$ (calculados sobre al menos 500 observaciones conjuntas no-nulas), ordenados por magnitud de la correlación. La mayoría corresponde a redundancias esperables (medidas nominal vs. real de un mismo concepto, o un indicador individual y su agregado a nivel de hogar); la más relevante para este trabajo es la de `dmstp_stable_lights` con `lp`, `li` y `n_servicios_publicos_hogar`, que se retoma en la Sección 5.4. Fuente: cálculos propios.

4. Estrategia empírica

4.1. Construcción de la variable de resultado

Siguiendo a López-Calva y Ortiz-Juárez (2011, 2014), se construyen matrices de transición de pobreza monetaria e IPM cruzando el estado de pobreza de un hogar en la ola inicial t (filas) contra su estado en la ola siguiente $t + 1$ (columnas), usando el ingreso per cápita del hogar contra la línea de pobreza (LP) oficial del DANE, específica por año y zona (urbana/rural). El análisis empírico se restringe a la submuestra de hogares que se encuentran por encima de la LP en el periodo inicial t , es decir, los que inicialmente no eran pobres y que posteriormente caen en pobreza. Sobre esta población se define la variable dependiente binaria:

$$\text{CaidaPobreza}_{i,t+1} = \begin{cases} 1 & \text{si el hogar } i \text{ es pobre en } t + 1 \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

El objetivo entonces es estimar la probabilidad condicional de caer en pobreza en el periodo siguiente dada la información observada en t (Ecuación 2). El emparejamiento de hogares entre olas usa exclusivamente coincidencias uno a uno del identificador de hogar (Sección 3.1); los hogares que se dividieron entre olas se excluyen de la construcción de la variable de resultado por no tener un estado inicial y final únicos. Las matrices de transición resultantes, y su interpretación se presentan en la Sección 5.1.

4.2. Especificación de modelos

La estrategia empírica se establece mediante la siguiente especificación de modelo:

$$P(\text{CaidaPobreza}_{i,t+1} = 1 \mid X_{it}) = F(X_{it} \beta) \quad (2)$$

donde X_{it} es el vector de características del hogar i observadas en el periodo t (Sección 3.1) y $F(\cdot)$ es la función que relaciona esas características con la probabilidad de transición, aproximada de manera distinta según el algoritmo. Se estiman y comparan cinco algoritmos, agrupados en dos familias según cómo tratan las variables categóricas y los datos faltantes (Sección 4.4):

- **Regresión logística regularizada (benchmark).** $F(\cdot)$ es la función logística; los coeficientes β se estiman penalizando su magnitud con una combinación de regularización L1 y L2 (*elastic net*), cuya fuerza (C) y mezcla (l_1_ratio) se eligen por validación cruzada en vez de fijarse *a priori* como Lasso o Ridge. Es el algoritmo

designado como referencia por ser interpretable, y por servir de punto de comparación antes de justificar el uso de un modelo más complejo.

- **Random Forest.** Promedio de árboles de decisión entrenados sobre muestras *bootstrap* independientes del conjunto de entrenamiento; captura no linealidades e interacciones entre covariables sin necesidad de especificarlas manualmente, con menor varianza que un árbol individual.
- **XGBoost, LightGBM y HistGradientBoosting.** Tres implementaciones de *gradient boosting* de árboles. Este algoritmo es sobresaliente por su balance entre desempeño e interpretabilidad, y uno de los más usados en la literatura de focalización de pobreza (McBride & Nichols, 2018)–. Los tres manejan de forma nativa tanto los datos faltantes como las variables categóricas, sin necesidad de imputación ni de *one-hot encoding* (Sección 4.4).

Para evaluar el aporte del nivel de ingreso/gasto del hogar –el predictor más informativo bajo el enfoque de vulnerabilidad de Chaudhuri et al. (2002), que compara qué tan cerca está un hogar del umbral de pobreza, se estima cada uno de los cinco algoritmos bajo dos especificaciones de covariables: el **Modelo A** incluye el ingreso y gasto per cápita real del hogar en el periodo base y la brecha frente a la Línea de Pobreza (LP), de escala-invariante por lo que se mantiene constante a lo largo del tiempo; el **Modelo B** excluye estas cuatro variables y usa exclusivamente covariables no monetarias (ej. demografía, educación, activos, vivienda, choques, comunidad). Este ejercicio, diez modelos en total (cinco algoritmos por dos especificaciones) establece además el marco de referencia frente al cual se evaluará, en una etapa posterior de este proyecto, si las variables geoespaciales aportan más donde la brecha a la LP ya no distingue bien (hogares cerca del umbral) que en general.

Finalmente, se establecieron dos variables objetivo para evaluar la robustez de los hallazgos: la transición hacia la pobreza monetaria y la transición hacia la pobreza multidimensional (IPM).

4.3. Validación fuera de muestra y métricas

La estimación usa las dos primeras olas de la ELCA como base de entrenamiento (transición 2010 a 2013: covariables de 2010, resultado observado en 2013) y la tercera ola como conjunto de prueba, completamente independiente, para evaluar el desempeño predictivo fuera de muestra (transición 2013 a 2016: covariables de 2013, resultado observado en 2016). Este recurso temporal hacia adelante replica el caso de uso real de un sistema de focalización, solo existe la ola base al momento de predecir, y es, siguiendo a McBride

y Nichols (2018), la validación más exigente para un modelo de este tipo porque prueba generalización ante un régimen económico distinto al de entrenamiento.

Dentro de ese periodo de entrenamiento (2010 a 2013) –nunca sobre el conjunto de prueba– cada algoritmo pasa por una búsqueda de hiperparámetros: en vez de fijar a mano valores como la profundidad de los árboles o la tasa de aprendizaje, `RandomizedSearchCV` propone 30 combinaciones aleatorias dentro de un rango razonable para cada hiperparámetro (Sección 4.2) y evalúa cada una con validación cruzada estratificada de 10 particiones: el conjunto de entrenamiento se divide en 10 bloques del mismo tamaño y manteniendo la proporción de hogares que entran a la pobreza en cada uno (*estratificada*), se entrena 10 veces dejando un bloque distinto por fuera cada vez y evaluando sobre ese bloque no visto, y se promedian las 10 evaluaciones. Ese promedio castiga a las combinaciones que memorizan particularidades del conjunto de entrenamiento en vez de aprender un patrón que generaliza, sin gastar el conjunto de prueba, que solo se toca una vez, al final. Se eligen los 30 hiperparámetros por costo computacional –evaluar más combinaciones exhaustivamente (*grid search*) sobre 5 algoritmos $\times$ 4 especificaciones $\times$ 3 estrategias de balanceo (Sección 4.4) no era viable en tiempo razonable–; la métrica que decide qué combinación gana esa búsqueda es AUC-ROC, por la misma razón que se usa como métrica principal de desempeño (párrafo siguiente).

El desempeño se reporta mediante AUC-ROC como métrica principal, principalmente porque no depende de un umbral de clasificación arbitrario, además, recall, precision y F1 como métricas de referencia al umbral de clasificación elegido por F_2 (Sección 4.4), junto con la matriz de confusión completa; F1 se sigue reportando por ser la referencia más estándar en la literatura, aunque no es la métrica que decide dónde queda el umbral. El foco del análisis está en comparar el desempeño relativo entre los cinco algoritmos y entre las especificaciones A y B, más que en declarar un único “mejor” modelo a partir de diferencias de AUC-ROC que, como se documenta en la Sección 5.3, resultan pequeñas frente a la variabilidad esperable por aleatoriedad del ajuste.

4.4. Tratamiento del desbalance de clases

La tasa de entrada a la pobreza en la muestra de entrenamiento es de 23.4% (Tabla 3), un desbalance moderado que puede sesgar a los algoritmos hacia la clase mayoritaria. Se comparan tres estrategias de tratamiento del desbalance para cada algoritmo: reponderación de clases (`class_weight="balanced"` o su equivalente `scale_pos_weight` en XGBoost), ausencia de ajuste (línea base), y sobremuestreo aleatorio de la clase minoritaria (`RandomOverSampler`, aplicado únicamente dentro de cada partición de entrenamiento de la validación cruzada, nunca contaminando la partición de validación). No se usó SMOTE,

que interpola sintéticamente entre observaciones vecinas, porque no está bien definido cuando coexisten variables categóricas y datos faltantes estructurales, a diferencia del sobremuestreo aleatorio, que solo duplica filas existentes. La estrategia que gana para cada algoritmo y especificación es la que maximiza el AUC-ROC promedio en validación cruzada, no un criterio fijado *a priori*.

Un hallazgo metodológico relevante de este ejercicio: en XGBoost y en LightGBM (Modelo B), la estrategia “sin ajuste” ganó la comparación por una diferencia de AUC-ROC frente a la reponderación de apenas 0.001 (estadísticamente indistinguible), pero el modelo resultante, sin corregir el desbalance de clases, produjo probabilidades tan comprimidas hacia valores bajos que casi ninguna observación cruzaba el umbral convencional de 0.5 (recall de 3%–4% en XGBoost, con precision superior a 60%: el modelo ordenaba razonablemente bien los hogares por riesgo, pero era inútil en la práctica al umbral estándar). Esto ilustra que el umbral 0.5 es arbitrario cuando la clase positiva no es 50% de la muestra, y que distintas estrategias de balanceo calibran las probabilidades de forma distinta, por lo que comparar recall/precision/F1 a un umbral fijo entre estrategias no es una comparación válida. La solución adoptada fue elegir el umbral de clasificación de cada modelo por validación cruzada, igual que los hiperparámetros: sobre las probabilidades *out-of-fold* (10 particiones) se evalúa una grilla de umbrales entre 0.02 y 0.98 y se elige el que maximiza una métrica que combina recall y precision –el AUC-ROC, que no depende de umbral, y sigue siendo el criterio que decide la estrategia de balanceo y los hiperparámetros en el paso anterior; el umbral solo determina cómo se reportan recall, precision y F1 una vez el modelo ya está fijo.

La métrica elegida para esa búsqueda de umbral es F_2 (F-beta con $\beta = 2$) en vez del F1 convencional. F1 es la media armónica de recall y precision con el mismo peso para ambos, una elección razonable cuando un falso negativo (un hogar que sí cae en pobreza y el modelo no marca como riesgo) y un falso positivo (un hogar que el modelo marca como riesgo y no cae) son igual de costosos. En un sistema de focalización de política social eso no es cierto: dejar sin detectar a un hogar que va a entrar en pobreza tiene un costo –no recibe el apoyo que necesitaría– mayor que incluir de más a un hogar que no cae, que en el peor caso implica un gasto de focalización mal dirigido pero no la ausencia de una protección que sí hacía falta. F_2 formaliza esa prioridad ponderando el recall el doble que la precision al elegir el umbral, de modo que el modelo se ajusta para dejar pasar menos casos reales de entrada a la pobreza, a costa de marcar como riesgo a más hogares que finalmente no caen.

Para los algoritmos sin soporte de datos faltantes (regresión logística y Random Forest), la imputación de valores faltantes, que en esta base de datos son mayoritariamente por

la estructura de la encuesta, es decir, causados por preguntas filtro del cuestionario (por ejemplo, el monto de una ayuda recibida no se pregunta a quien respondió que no recibió ninguna)– usa sistemáticamente el valor 0 combinado con una columna indicadora binaria de faltante por variable. Esta elección evita que la mediana –calculada únicamente sobre quienes pasaron el filtro y respondieron– le asigne a los hogares excluidos por el filtro un valor “típico” que en realidad no tienen, y tiene además la propiedad de que, en un modelo lineal, el relleno no aporta ninguna contribución a la predicción más allá de la que capture el propio indicador de faltante. Las variables categóricas se imputan con una categoría explícita “Sin dato” en vez de la moda, para no disfrazar la ausencia estructural como el valor más común. XGBoost, LightGBM y HistGradientBoosting no requieren esta imputación: manejan los datos faltantes de forma nativa en la partición de los árboles, lo que convierte el propio patrón de *missingness* en una señal explotable por el modelo (por ejemplo, la ausencia de datos de vacunación infantil ya codifica indirectamente que el hogar no tiene hijos pequeños) en vez de forzar un supuesto de imputación potencialmente sesgado.

4.5. Importancia de variables e interpretabilidad

Para cada modelo se reporta una medida de importancia de variables acorde a su naturaleza: los coeficientes estandarizados (con signo) de la regresión logística; la importancia por reducción de impureza (`feature_importances_`) de Random Forest, XGBoost y LightGBM; y la importancia por permutación (*permutation importance*, AUC-ROC sobre el conjunto de prueba, 10 repeticiones) de HistGradientBoosting, más costosa computacionalmente pero más robusta a la correlación entre covariables que la importancia basada en impureza. La comparación de estas listas de variables más importantes entre el Modelo A y el Modelo B (Sección 5.3) es la primera aproximación a la pregunta de qué información no monetaria es más predictiva de la transición a la pobreza, antes de la incorporación de las variables geoespaciales (Sección 6.3). Como estas medidas no comparten unidad entre algoritmos (impureza vs. coeficiente estandarizado vs. caída de AUC-ROC), se complementan con valores SHAP (*SHapley Additive exPlanations*) para los cinco algoritmos sobre los Modelos A y B, que sí son comparables en una misma escala –la contribución promedio, en valor absoluto, de cada variable a la predicción de cada hogar– y que además satisfacen aditividad (la suma de los SHAP values de un hogar reconstruye exactamente su predicción) y consistencia (si un modelo pasa a depender más de una variable, su SHAP value nunca puede bajar). Los resultados se presentan en la Sección 5.3.

5. Resultados

5.1. Dinámica de transiciones a la pobreza en la ELCA

Esta sección caracteriza las transiciones entre estados de pobreza en el panel ELCA 2010–2013–2016, bajo las dos definiciones de esta tesis –monetaria por ingreso (LP del DANE) e IPM (Sección 4.1)–, según las cuatro categorías de López-Calva y Ortiz-Juárez (2014) (nunca/siempre pobre, sale/entra en pobreza). Incidencia, FGT y cinco ejercicios de robustez frente a decisiones de construcción del ingreso y representatividad muestral –incluida la atrición del panel por perfil de hogar– se documentan en el Apéndice A.1.

Las matrices de transición (Tabla 3) cruzan el estado inicial (filas) contra el final (columnas), en % de fila, para hogares con emparejamiento 1 a 1 entre olas (excluye 511 hogares divididos en 2010–2013 y 1,190 en 2013–2016).

Cuadro 3: Matrices de transición de pobreza, monetaria por ingreso vs. IPM (% de fila, panel emparejado 1 a 1). Estado inicial en filas, estado final en columnas.

Periodo	Estado inicial	Monetaria		IPM	
		No pobre	Pobre	No pobre	Pobre
2010 → 2013	No pobre	76.6 %	23.4 %	87.9 %	12.1 %
	Pobre	29.7 %	70.3 %	54.5 %	45.5 %
2013 → 2016	No pobre	80.1 %	19.9 %	90.3 %	9.7 %
	Pobre	38.2 %	61.8 %	52.3 %	47.7 %

Nota: $n = 8,218$ (2010→2013) y $n = 6,911$ (2013→2016) hogares con emparejamiento 1 a 1 – idéntico universo para monetaria e IPM (mismo panel, solo cambia la clasificación de pobreza); excluye 511 (2010–2013) y 1,190 (2013–2016) casos de hogares que se dividieron entre olas. Fuente: cálculos propios con base en ELCA 2010, 2013, 2016, generados por `src/tabla_matriz_transicion_combinada.py` sobre `outputs/tables/pobreza/transicion_{pct,conteo}_{ipm}_ola*.csv` (`src/04_features/build_pobreza_desagregaciones.py`, `build_matriz_transicion_ipm.py`).

Bajo pobreza monetaria la persistencia es alta pero decrece: 70.3 % de los pobres en 2010 seguían pobres en 2013, cae a 61.8 % entre 2013 y 2016 (la salida condicional sube de 29.7 % a 38.2 %); la persistencia en la no-pobreza mejora de 76.6 % a 80.1 %. Bajo IPM entrar es menos frecuente (12.1 % y 9.7 %, frente a 23.4 % y 19.9 % en monetaria) pero también lo es salir (45.5 % y 47.7 %, frente a 29.7 %–38.2 % en monetaria) –consistente con que el IPM mide privaciones estructurales (vivienda, educación, servicios) que cambian más lento que el ingreso corriente en cualquiera de las dos direcciones.

Las Figuras 5 y 6 traducen la matriz monetaria a flujos entre las cuatro categorías de López-Calva y Ortiz-Juárez (2014): en 2010–2013 dominan los *siempre pobres* (43.9 %)

sobre los *nunca pobres* (28.8 %); en 2013–2016 el orden se invierte (37.0 % vs. 33.3 %). En ambos periodos la salida (18.6 %, 20.6 %) casi duplica la entrada (8.8 %, 9.2 %): la pobreza monetaria se redujo de forma neta, no solo se redistribuyó entre hogares.




Figura 5: 2010→2013 ($n = 8,218$).




Figura 6: 2013→2016 ($n = 6,911$).

Transición de pobreza monetaria por ingreso entre categorías de López-Calva y Ortiz-Juárez (2014), panel emparejado 1 a 1.

Un ejercicio adicional sigue a los mismos hogares (no pobres en la ola base) a lo largo de las tres olas para distinguir entradas transitorias de persistentes (Tabla 4). Bajo pobreza monetaria, 24.1 % de los no pobres en 2010 entra en pobreza en algún momento; algo más de la mitad sale de nuevo antes de 2016 (14.0 puntos, “transitorio”) y el resto se queda (10.1 puntos, “persistente”). Bajo IPM la entrada total es menor (12.2 %) y se reparte parecido (8.2 transitoria, 4.0 persistente). En ambas definiciones, más de la mitad de quienes entran en pobreza no quedan atrapados dentro de la ventana de seis años observada.

Cuadro 4: Trayectorias a 3 olas (2010→2013→2016) de hogares NO pobres en 2010, panel emparejado 1 a 1, monetaria vs. IPM.

Trayectoria	Monetaria		IPM	
	n	%	n	%
Nunca cae	1,700	67.2 %	4,381	81.2 %
Cae tarde (solo en 2016)	220	8.7 %	357	6.6 %
Entra y sale (transitorio)	355	14.0 %	445	8.2 %
Entra y se queda (persistente)	255	10.1 %	214	4.0 %

Nota: $n=2,530$ hogares no pobres en 2010 bajo pobreza monetaria; $n=5,397$ bajo IPM (universos distintos porque no-pobre-monetaria y no-pobre-IPM en 2010 no son el mismo conjunto de hogares). % sobre ese universo, sin ponderar (ver también `pct_ponderado` en los CSV fuente). Fuente: cálculos propios, `outputs/tables/eda_transicion_covariables/trayectorias_3olas_{monetaria,ipm}.csv` (`src/02_build/eda_trayectorias_3olas.py`), generados por `src/tabla_trayectorias_3olas.py`.

5.2. Perfil de los hogares vulnerables

Esta sección construye un perfil detallado del grupo que define la vulnerabilidad estudiada en esta tesis: los hogares que **entran en pobreza** entre 2010 y 2013 –no pobres en la ola inicial, pobres en la siguiente–, contrastado contra los otros tres grupos de la matriz de transición (Sección 5.1). Se seleccionaron todas las covariables individualmente robustas frente a esta tipología de 4 grupos (tamaño de efecto $-\eta^2$ de rangos para variables numéricas, V de Cramér sesgo-correcta para categóricas/booleanas, ambos ponderados por el factor de expansión longitudinal– superior a 0.10, con intervalo de confianza bootstrap de 300 réplicas que no cruza cero), sin colapsar las que están correlacionadas entre sí –a diferencia de una versión preliminar de esta sección, aquí se opta por mostrar covariables redundantes juntas cuando miden el mismo fenómeno, en vez de ocultarlas–. El resultado son 40 variables para pobreza monetaria, organizadas en 9 categorías temáticas: las de mayor número de variables se presentan en tabla, y las de 1 a 3 variables en gráfico (línea y valor real por grupo de transición). Las categorías se presentan en orden de relevancia argumentativa, no de tamaño.

Dos conclusiones generales atraviesan las 9 categorías y se desarrollan en ese orden. **Primera:** según las variables que más separan a los cuatro grupos, el perfil del hogar vulnerable se parece mucho más al del hogar que *acaba de salir* de la pobreza que al del hogar que nunca fue pobre o al que nunca sale de ella –de las 40 variables, 37 ubican al hogar vulnerable numéricamente más cerca de “sale de la pobreza” que de “nunca pobre” (en promedio, tres veces más cerca)–. Esto es consistente con pensar “entra” y “sale” no como dos tipos de hogar distintos, sino como las dos caras de una misma frontera –hogares que cruzan la línea de pobreza en direcciones opuestas, con un perfil socioeconómico similar por estar ambos cerca de ese umbral–, mientras que “siempre pobre” y “nunca pobre” son los extremos alejados de ella. **Segunda,** y más importante para el argumento de esta tesis: la única excepción sistemática a ese patrón es la formalidad laboral del jefe de hogar –la señal que convencionalmente se usaría para decir “este hogar no está en riesgo”–, que resulta ser precisamente la que *más* tienen los hogares a punto de caer, por encima incluso del hogar que nunca fue pobre. Por eso esta sección empieza por la categoría de educación y empleo, no por ser la de mayor tamaño, sino por contener el hallazgo más directo a favor del argumento central de esta tesis: un estado socioeconómico observado en un punto del tiempo –¿tiene trabajo formal?, ¿tiene activos?– no revela el riesgo futuro de un hogar, y en el caso del empleo formal, activamente lo oculta.

Limitación de cobertura geográfica. La variable `region` de ELCA en realidad combina dos muestras distintas bajo el mismo nombre: Atlántica, Oriental, Central, Pacífica y

Bogotá son *exclusivamente urbanas* (cabeceras), mientras que Atlántica Media, Cundi-Boyacense, Eje Cafetero y Centro-Oriente son *exclusivamente rurales*, restringidas a cuatro microrregiones campesinas específicas (verificado por cruce `region`×`zona`, sin ningún caso mixto). En consecuencia, *Pacífica* en las Figuras 13 y 14 no representa a la región Pacífica del país sino solo a su muestra urbana (ej. Cali), y el diseño rural de ELCA no incluye en absoluto al Chocó rural ni a La Guajira –las zonas de mayor pobreza persistente del país–. Por eso el bajo nivel de pobreza y el DMSP relativamente alto que muestra *Pacífica* en ambas figuras no deben leerse como evidencia sobre el Pacífico rural: reflejan una muestra urbana no representativa de esa subregión, y los datos de ELCA simplemente no permiten caracterizar los bolsones de pobreza extrema del país. Las etiquetas de las figuras distinguen (*urbano*)/(*rural*) para hacer esta limitación visible.

Educación y empleo del jefe de hogar. De las 11 variables de esta categoría, 8 –nivel educativo, cotización a pensión, etnia, estado civil– siguen el patrón general: el hogar vulnerable se parece a quien sale de la pobreza (47.4 % con solo primaria básica, casi igual al 48.6 % de quien sale, frente a 25.2 % del nunca pobre; cotización a pensión del jefe 23.9 % frente a 21.3 % de quien sale y 42.8 % de quien nunca cae). Las 3 excepciones son precisamente las de *formalidad laboral*: 62.3 % de los jefes de hogar vulnerables son asalariados –más que el hogar que sale (52.2 %) y más que el que nunca cae (57.9 %)–, y su negocio (cuando lo tienen) es más grande y con más frecuencia registrado que el del hogar que sale. En estas tres variables, el hogar vulnerable no es el segundo peor de los cuatro grupos: es el *primero*. Si una política de focalización usara solo la formalidad laboral del jefe en 2010 para decidir a quién apoyar, habría clasificado a los hogares vulnerables como los *menos* necesitados de los cuatro grupos –el ejemplo más concreto, de todo este perfil, de por qué un estado socioeconómico observado no revela el riesgo futuro de un hogar.

Cuadro 5: Educación y empleo del jefe – perfil por grupo de transición, pobreza monetaria (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Educación del jefe: Básica primaria (1 a 5)	59 %	49 %	47 %	25 %
Ocupación del jefe: Asalariado	34 %	52 %	62 %	58 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	66 %	69 %	62 %	54 %
Registro mercantil del jefe: No lo necesita	63 %	49 %	42 %	45 %
Negocio del jefe: De 20 a 49 personas	9 %	16 %	22 %	25 %
Máx. nivel educativo del hogar	2.28	2.79	2.79	4.22
Cotización a pensión (hogar)	5 %	16 %	18 %	38 %
Nivel educativo del jefe (ordinal)	2.02	2.54	2.56	3.72
Etnia del jefe: Indígena	12 %	6 %	6 %	4 %
Jefe cotiza a pensión	6 %	21 %	24 %	43 %
Estado civil del jefe: En unión libre	46 %	39 %	43 %	33 %

Activos del hogar. Esta es la categoría donde el hogar vulnerable se parece más, de las 9, al que sale de la pobreza. El patrón más marcado es el acceso a internet: solo 13.4 % de los hogares vulnerables lo tiene, casi igual al 15.9 % de quien sale, muy lejos del 45.7 % de quien nunca cae. El índice de riqueza (PCA) del hogar vulnerable (0.21) está a solo 0.23 puntos del que sale (-0.02), frente a 0.85 puntos del que nunca cae (1.06); el número de bienes durables (6.3 frente a 6.0 en quien sale, 9.1 en quien nunca cae) y de servicios públicos (3.65 frente a 3.30, 4.80) muestran el mismo patrón.

Cuadro 6: Activos del hogar – perfil por grupo de transición, pobreza monetaria (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
N.º de bienes durables	4.58	6.00	6.30	9.10
N.º de servicios públicos	2.50	3.30	3.65	4.80
Estrato (verificado)	1.59	2.06	2.07	2.63
Índice de riqueza (PCA)	-0.83	-0.02	0.21	1.06
Estrato (autorreportado)	1.60	2.07	2.05	2.58
Tiene internet en el hogar	8 %	16 %	13 %	46 %
N.º de activos financieros	0.10	0.42	0.45	0.86

Vivienda: hacinamiento. El hogar vulnerable paga en promedio \$239.624 de arriendo –prácticamente igual a los \$225.767 de quien sale de la pobreza, y muy lejos de los \$354.234

de quien nunca cae– y tiene 1.49 personas por cuarto (1.65 en quien sale, 1.11 en quien nunca cae).




Figura 7: Hacinamiento y arriendo por grupo de transición, pobreza monetaria (2010→2013).

Vivienda: materiales y servicios. Las ocho variables de este grupo –material de piso, combustible de cocina, servicio sanitario, recolección de basura, obtención de agua, tipo de vivienda, material de paredes y tenencia– se mueven de forma casi idéntica entre los cuatro grupos, lo que confirma que miden un mismo fenómeno subyacente (calidad de la vivienda) desde ángulos distintos. El hogar vulnerable está mucho más cerca de quien sale de la pobreza que de quien nunca cae en casi todas: 35 % tiene piso de baldosa o similar (31 % en quien sale, 59 % en quien nunca cae), 55 % tiene inodoro conectado a alcantarillado (47 % frente a 79 %), y 58 % tiene acueducto público (49 % frente a 79 %). La excepción parcial es tenencia de vivienda: aunque el hogar vulnerable (27.6 % en usufructo) sigue más cerca de quien sale (23.8 %) que del nunca pobre (15.1 %), la distancia al hogar siempre pobre (33.2 %) es aquí mucho menor que en el resto de la categoría, sugiriendo una situación de tenencia menos consolidada que en las demás variables de vivienda.

Cuadro 7: Vivienda: materiales y servicios – perfil por grupo de transición, pobreza monetaria (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Material de piso: Baldosa, vinilo, tableta o ladrillo	14 %	31 %	35 %	59 %
Combustible de cocina: Leña, madera, carbón de leña	64 %	43 %	32 %	12 %
Servicio sanitario: Inodoro conectado a alcantarillado	26 %	47 %	55 %	79 %
Recolección de basura: La recogen los servicios de aseo	31 %	49 %	57 %	80 %
Obtención de agua: Acueducto público	31 %	49 %	58 %	79 %
Tipo de vivienda: Apartamento	8 %	18 %	20 %	38 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	59 %	75 %	81 %	91 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	33 %	24 %	28 %	15 %

Programas sociales y deuda. El hogar vulnerable recibe menos apoyo estatal que el hogar siempre pobre pero más que el que nunca cae, y está más cerca de quien sale de la pobreza en ambas variables: 22.8 % es beneficiario de Familias en Acción (29.0 % en quien sale, 7.5 % en quien nunca cae) y 31.2 % de algún programa social (36.7 % frente a 15.0 %) –coherente con una focalización que en 2010 ya identificaba correctamente a los hogares en riesgo, aunque no evitó que una parte de ellos cayera–.




Figura 8: Programas sociales por grupo de transición, pobreza monetaria (2010→2013).

Zona de residencia. El 44.7 % de los hogares vulnerables vive en zona rural, más cerca del 51.6 % de quien sale de la pobreza que del 20.9 % de quien nunca cae –la zona rural por sí sola no distingue con la misma fuerza que otras categorías a quien está en riesgo de quien no lo está, a diferencia de lo que ocurre bajo la definición multidimensional (ver más adelante, donde la cifra equivalente es 67.2 %)–.




Figura 9: Zona de residencia por grupo de transición, pobreza monetaria (2010→2013).

Composición del hogar. El hogar vulnerable tiene en promedio 0.79 niños menores de 12 años y una razón de dependencia demográfica de 0.56, cercano al 0.92 y 0.67 de quien sale de la pobreza y lejos del 0.57 y 0.43 de quien nunca cae –la categoría donde el patrón general es menos nítido, aunque la dirección se mantiene–.




Figura 10: Composición del hogar por grupo de transición, pobreza monetaria (2010→2013).

Ingreso y gasto. Esta es la categoría donde el patrón “se parece a quien sale” es más débil, aunque sigue sosteniéndose: el hogar vulnerable típico tenía en 2010 un ingreso per cápita de \$269.036 mensuales (1.58 veces la línea de pobreza), casi tres veces el de quien sale (\$93.296, 0.55 veces la LP) pero todavía menos de la mitad del que nunca cae (\$633.275, 3.26 veces la LP). El patrón en gasto es más plano: \$246.658 frente a \$209.691 en quien sale y \$661.906 en quien nunca cae –consistente con que el gasto amortigua mejor un choque transitorio que el ingreso reportado del mismo periodo, y con que el ingreso, la variable más obvia para pensar pobreza, es también la que menos distingue “entra” de “nunca cae” entre las nueve categorías de este perfil–.

Cuadro 8: Ingreso y gasto – perfil por grupo de transición, pobreza monetaria (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Ingreso (veces la línea de pobreza)	0.42	0.55	1.58	3.26
Ingreso per cápita	65k	93k	269k	633k
Gasto per cápita	154k	210k	247k	662k
Gasto (veces la línea de pobreza)	0.99	1.26	1.45	3.36

Geoespacial: iluminación nocturna. La luz nocturna del hogar vulnerable (36.4, escala DMSP-OLS 0-63) separa con más claridad del hogar que nunca cae (50.1) que la mayoría de las covariables de encuesta convencionales, pese a no depender de lo que el hogar

reporte de sí mismo –el argumento central para su inclusión como covariable geoespacial, desarrollado en la Sección 5.4–.




Figura 11: Iluminación nocturna (DMSP) por grupo de transición, pobreza monetaria (2010→2013).

Otras fuentes geoespaciales (exploratorio). ALOS PALSAR (radar) y Landsat 5 TM (NDVI) muestran el mismo gradiente que DMSP-OLS para el radar –el hogar vulnerable (-7.54 dB) queda entre el siempre pobre (-8.46) y el nunca pobre (-6.49)–, pero un patrón *invertido* para la vegetación: el NDVI es más alto en el hogar siempre pobre (0.46) que en el nunca pobre (0.32), con el vulnerable en un punto intermedio (0.41) –consistente con que las zonas de mayor pobreza en esta muestra son más rurales y, por tanto, más verdes, mientras que las zonas de mayor bienestar están más urbanizadas–. A diferencia de DMSP-OLS, estas dos variables no forman parte del universo de covariables sometido al filtro de robustez de esta sección (Sección 5.4 explica por qué se evaluaron con una metodología exploratoria distinta, sin holdout real en la ola de prueba); esta figura es puramente descriptiva.




Figura 12: ALOS PALSAR y Landsat 5 TM (NDVI) por grupo de transición, pobreza monetaria (2010→2013). Ejercicio exploratorio, no sometido al mismo filtro de robustez que DMSP-OLS.

Espacialmente, el mismo patrón se confirma a nivel de región: la pobreza persistente se concentra en las microrregiones rurales andinas (Cundi-Boyacense, Centro-Oriente y Atlántica Media, 64–66 % de hogares siempre pobres, DMSP por debajo de 9), mientras Bogotá concentra la mayor proporción de hogares nunca pobres (70 %, DMSP=63).




Figura 13: Grupo de transición dominante por región e iluminación nocturna (DMSP), pobreza monetaria, 2010→2013.

Síntesis: dos formas de estar cerca de la pobreza. El perfil completo matiza la primera conclusión de esta sección más que confirmarla de forma simple. No es que el hogar

vulnerable “sea” el hogar que sale de la pobreza con otro nombre: en la enorme mayoría de sus características observables –vivienda, activos, educación, programas sociales, geografía– ocupa la misma posición relativa que un hogar que apenas cruzó la línea hacia el lado seguro, sin que ningún rasgo lo señale de antemano como distinto. Pero esa misma cercanía es la que hace que la excepción del empleo formal importe tanto: si la vulnerabilidad fuera simplemente “parecerse a quien sale de la pobreza”, bastaría con monitorear a ese grupo. Lo que el hallazgo del empleo muestra es que, en la única dimensión donde el hogar vulnerable se separa del resto, lo hace en la dirección *opuesta* a la que una foto fija de su situación económica sugeriría –se ve, en ese aspecto puntual, más seguro que el hogar que nunca ha sido pobre–. La vulnerabilidad, en consecuencia, no es un perfil socioeconómico identificable por sus carencias en un punto del tiempo: es una posición relativa a un umbral que ningún indicador de estado, por sí solo, revela –y que en el caso del indicador que más se usa para descartar el riesgo, activamente esconde–.

Pobreza multidimensional (IPM): síntesis y comparación. El mismo ejercicio se repitió para pobreza multidimensional (36 variables robustas, Anexo A) y muestra un patrón cualitativamente distinto al monetario: bajo IPM, quien entra en pobreza sí muestra señales de privación claramente visibles *antes* de la transición –20 % vive en piso de tierra (frente a 5 % de los nunca pobres), solo 34 % tiene acceso a acueducto público (frente a 64 %), y 67.2 % vive en zona rural, más de 30 puntos por encima del 36.5 % del hogar nunca pobre–, más parecido al hogar siempre pobre que al que nunca cayó. Esto es consistente con la Sección 5.1: bajo la óptica multidimensional, la entrada a pobreza es menos un evento repentino y más la continuación de privaciones que ya venían acumulándose –el espejo, casi exacto, del patrón monetario: donde el ingreso ve un choque súbito sobre un hogar que se parecía al seguro, la privación multidimensional ve la continuación de un deterioro que ya se parecía al persistente–.

De las 40 variables del perfil monetario y las 36 del perfil IPM, 27 son **comunes a ambas definiciones** –zona, todas las variables de vivienda y materiales, ingreso y gasto per cápita, educación y ocupación del jefe, tenencia y hacinamiento, riqueza (PCA), bienes durables, servicios públicos e iluminación nocturna–: el núcleo estructural de la vulnerabilidad no depende de cómo se mida la pobreza. Las 13 variables **exclusivas de monetaria** son mayoritariamente financieras y de protección social específicas (activos financieros, beneficiario de programas, estrato, número de hijos, arriendo, acceso a internet). Las 11 **exclusivas de IPM** incluyen, de forma reveladora, la pobreza monetaria del propio hogar en 2010 (`pobre_ingreso`, `pobre_extremo_ingreso`, `pobre_gasto`, `pobre_extremo_gasto` figuran como covariables robustas para predecir la transición *multidimensional*), junto con

alfabetización de adultos y cuidado infantil por terceros –sugiere que la pobreza monetaria previa es, en sí misma, uno de los mejores predictores de caer en pobreza multidimensional, mientras que lo inverso no se sostiene con la misma fuerza–.




Figura 14: Grupo de transición dominante por región e iluminación nocturna (DMSP), pobreza multidimensional (IPM), 2010→2013.

5.3. Desempeño comparativo de modelos

La Tabla 9 presenta el desempeño de los cinco algoritmos bajo las dos especificaciones de covariables (Modelo A, con ingreso/gasto; Modelo B, sin ellos), evaluado sobre el conjunto de prueba completamente fuera de muestra (2013→2016), con la estrategia de balanceo de clases y el umbral de clasificación ya elegidos por validación cruzada dentro del periodo de entrenamiento (Secciones 4.3 y 4.4).

Cuadro 9: Desempeño de los cinco algoritmos, holdout temporal (train 2010→2013, test 2013→2016). Media $\pm$ intervalo de confianza al 95% sobre 5 semillas del ajuste final. Umbral elegido por CV maximizando F-beta ($\beta = 2$), CV_FOLDS=10, N_ITER_BUSQUEDA=30.

Algoritmo	Espec.	Balanceo	Umbral	AUC-ROC	IC95 %	Recall	F1
XGBoost	A	ninguno	0.11	0.767	[0.766, 0.769]	0.949	0.413
Random Forest	A	ninguno	0.14	0.766	[0.765, 0.767]	0.926	0.426
HistGradientBoosting	A	balanced	0.32	0.763	[0.763, 0.763]	0.909	0.432
LightGBM	A	ninguno	0.10	0.758	[0.758, 0.758]	0.903	0.428
Logística regularizada	A	balanced	0.37	0.747	[0.747, 0.747]	0.883	0.426
Random Forest	B	balanced	0.31	0.742	[0.741, 0.744]	0.892	0.416
XGBoost	B	ninguno	0.13	0.742	[0.742, 0.743]	0.940	0.395
Logística regularizada	B	balanced	0.35	0.739	[0.739, 0.739]	0.890	0.414
HistGradientBoosting	B	ninguno	0.14	0.735	[0.735, 0.735]	0.879	0.418
LightGBM	B	ninguno	0.15	0.731	[0.731, 0.731]	0.909	0.403

Nota: umbral elegido por validación cruzada maximizando F_2 en cada semilla (Sección 4.4), no fijo en 0.5; se reporta el promedio de las 5 semillas. El umbral es considerablemente más bajo que en una búsqueda equivalente por F1 –al pesar el recall el doble, F_2 empuja el punto de corte hacia abajo para dejar pasar más casos de entrada a la pobreza, a costa de más falsos positivos (columna Recall, sistemáticamente sobre 0.88, frente a un F1 más moderado). El IC95% de AUC-ROC captura únicamente la aleatoriedad propia del procedimiento de ajuste (remuestreo interno del algoritmo) sobre el mismo conjunto de prueba, con balanceo e hiperparámetros ya fijados – es nulo o casi nulo para HistGradientBoosting, LightGBM y la regresión logística porque, con los hiperparámetros elegidos, su ajuste es determinístico dado el conjunto de entrenamiento, mientras que Random Forest y XGBoost sí tienen una variabilidad pequeña pero no nula heredada de su remuestreo *bootstrap*/submuestreo interno. Fuente: cálculos propios, `data/processed/benchmark_resultados/registro_modelos_fbeta2_cv10.csv`, generados por `src/05_model/modelo_fbeta2_cv10_comparacion.py` y `src/tabla_desempeno_modelos_fbeta2_cv10.py`.




Figura 15: AUC-ROC medio (5 semillas) de los cinco algoritmos por especificación, conjunto de prueba 2013→2016. Barras de error: IC95 %.

Tres patrones se destacan. Primero, los cinco algoritmos quedan en un rango relativamente estrecho de AUC-ROC (0.731–0.767 en total, apenas 0.747–0.767 dentro del Modelo A), con XGBoost, Random Forest y HistGradientBoosting apenas por encima de LightGBM y de la regresión logística regularizada (Figura 15). Reentrenar el modelo final de cada algoritmo con 5 semillas aleatorias (Sección 4.4) –manteniendo fijos el balanceo y los hiperparámetros ya elegidos– muestra que HistGradientBoosting, LightGBM y la regresión logística son prácticamente determinísticos bajo los hiperparámetros elegidos (desviación estándar del AUC-ROC ≈ 0 entre semillas), mientras que Random Forest y XGBoost sí tienen una variabilidad pequeña pero no nula (desviación estándar entre 0.0006 y 0.0011 según especificación), heredada del remuestreo *bootstrap* y del submuestreo de observaciones/columnas que sus hiperparámetros óptimos activan. Con esa variabilidad, la ventaja de XGBoost (AUC-ROC 0.767) sobre Random Forest (0.766) en el Modelo A es marginal y sus intervalos de confianza se traslapan por completo; la de ambos sobre HistGradientBoosting (0.763) y LightGBM (0.758) es algo más clara. Es importante notar que este intervalo de confianza mide únicamente la aleatoriedad del propio procedimiento de ajuste sobre el mismo conjunto de prueba, no la incertidumbre muestral de la estimación del AUC-ROC en sí –una comparación formal entre algoritmos requeriría una prueba pareada (por ejemplo, de DeLong) sobre las predicciones del mismo conjunto de prueba, no realizada en este documento–. Con esa salvedad, la evidencia sigue sin señalar un algoritmo que domine de forma inequívoca a los demás. Segundo, el ranking cambia según la métrica

pero de forma más consistente que el AUC-ROC: XGBoost tiene el mayor recall en ambas especificaciones (0.949 en A, 0.940 en B), a costa de la menor precision de la tabla, mientras que HistGradientBoosting tiene el mayor F1 en ambas especificaciones (0.432 en A, 0.418 en B), el balance más favorable entre recall y precision bajo el umbral elegido por F_2 . Esto sugiere que, más que declarar un “mejor” algoritmo único, la elección final debería depender de las preferencias de la institución que use el modelo para focalización –priorizar recall implica aceptar más errores de inclusión a cambio de menos errores de exclusión–.

Tercero, y más relevante para la pregunta de investigación de esta tesis: la brecha de AUC-ROC entre el Modelo A (con ingreso/gasto) y el Modelo B (sin ellos) es de 0.008 a 0.028 según el algoritmo (mínima en la regresión logística, máxima en HistGradientBoosting), mucho menor de lo que predeciría un enfoque de vulnerabilidad puramente monetario (Chaudhuri et al., 2002). Esto indica que las covariables no monetarias –educación, activos del hogar, vivienda, choques, características de la comunidad– capturan una fracción sustancial del poder predictivo que aporta la brecha al umbral de pobreza, no son redundantes con ella. La Figura 16 muestra recall y precision (media, 5 semillas) al umbral elegido para el Modelo A: XGBoost y Random Forest destacan con el mayor recall (0.949 y 0.926) pero también la menor precision de los cinco (0.264 y 0.277), mientras que HistGradientBoosting, LightGBM y la regresión logística quedan más agrupados, con recall algo menor (0.883 a 0.909) y precision algo mayor (0.280 a 0.283) – el mismo patrón de intercambio entre recall y precision se mantiene incluso tras corregir por el umbral de clasificación.




Figura 16: Recall y precision al umbral de clasificación elegido por validación cruzada, Modelo A (media e IC95 %, 5 semillas).

Las Figuras 17 y 18 muestran las variables más importantes de Random Forest y los mayores coeficientes –en valor absoluto, en unidades estandarizadas– de la regresión logística, ambos para el Modelo A y ya bajo la metodología final (umbral por F_2 , `CV_FOLDS=10`, `N_ITER_BUSQUEDA=30`): en vez de repetir la búsqueda de hiperparámetros –ya decidida y registrada en `registro_modelos_fbeta2_cv10.csv`– `modelo_fbeta2_cv10_importancia.py` reconstruye el pipeline ganador exacto de cada algoritmo/especificación a partir de esa fila y lo reentrena una única vez sobre todo el conjunto de entrenamiento; el resultado es determinista (mismo `RANDOM_STATE=42`, sin búsqueda aleatoria de por medio) y el propio script verifica, cada vez que corre, que reproduce exactamente el CSV de la corrida anterior. En Random Forest, el índice de riqueza precalculado de la ELCA (`riqueza_pca_hogar`) y el ingreso per cápita real dominan claramente (consistente con Chaudhuri et al. (2002)), seguidos de cerca por la brecha a la LP, el gasto per cápita real y el número de bienes durables del hogar. En la regresión logística, en cambio, el nivel educativo máximo del hogar tiene el mayor coeficiente en valor absoluto, por encima incluso de la brecha a la LP y el ingreso real –con signo negativo, consistente con que más educación reduce la probabilidad de caer en pobreza–, seguido por el número de bienes durables y de servicios públicos del hogar. Esta diferencia entre algoritmos –qué variable “domina” según se mida por reducción de impureza o por magnitud de coeficiente estandarizado– es en sí misma evidencia de que la importancia de variables no es una propiedad única del problema sino que depende parcialmente de cómo cada algoritmo particiona la información, un matiz relevante para la interpretación de resultados de esta naturaleza.




Figura 17: Variables más importantes, Random Forest, Modelo A (reducción de impureza).




Figura 18: Mayores coeficientes en valor absoluto, regresión logística regularizada, Modelo A (unidades estandarizadas).

En el Modelo B (sin ingreso/gasto), Random Forest ubica el índice de riqueza precalculado y el número de bienes durables del hogar como las dos variables más importantes, seguidas por el nivel educativo máximo del hogar; la regresión logística, en cambio, ubica el

nivel educativo máximo del hogar primero, seguido por el número de bienes durables y de servicios públicos y –solo en la regresión logística– la tasa de cotización a pensión del hogar, un proxy de formalidad laboral. Estas variables son consistentes con los determinantes de pobreza documentados en la literatura y no sugieren que el modelo esté capturando relaciones espurias.

Los valores SHAP (`src/05_model/diagnostico_shap_ab.py`, reconstruyendo el pipeline ganador de cada algoritmo/especificación ya registrado, sin repetir la búsqueda de hiperparámetros) confirman el patrón anterior y permiten además compararlo en una misma escala entre los cinco algoritmos. En el Modelo B, `riqueza_pca_hogar` y `nivel_educ_max_hogar` quedan siempre entre las dos variables más importantes en los cinco algoritmos –la primera domina en HistGradientBoosting y Random Forest, la segunda en LightGBM, Logística y XGBoost–, seguidas casi siempre por `n_bienes_durables_hogar` en tercer lugar. En el Modelo A el acuerdo es más parcial: LightGBM, XGBoost, Logística y Random Forest coinciden en que `ingreso_percapita_hogar_real`, `nivel_educ_max_hogar`, `riqueza_pca_hogar` y `brecha_lp_ingreso` son las cuatro variables más importantes (en distinto orden entre sí), pero HistGradientBoosting es una excepción notable: su variable más importante es `pct_adultos_alfabetizados` (SHAP medio 0.394, más del doble que la segunda), que no aparece entre las 8 primeras de ningún otro algoritmo. Esto no invalida la lectura general –las variables de riqueza, ingreso y educación siguen dominando en 4 de 5 algoritmos–, pero es un recordatorio de que “la variable más importante” puede depender de cómo un algoritmo específico particiona la información, no solo del contenido informativo de la variable en sí.




Figura 19: Valores SHAP, XGBoost, Modelo A (holdout de prueba 2013→2016). Cada punto es un hogar; el color indica el valor de la variable (rojo = alto, azul = bajo) y la posición horizontal su contribución a la probabilidad predicha de entrar en pobreza.




Figura 20: Valores SHAP, XGBoost, Modelo B (sin ingreso/gasto), holdout de prueba 2013→2016.

5.4. Contribución marginal de las variables geoespaciales

Esta subsección evalúa si DMSP-OLS –la única de las tres fuentes nuevas con datos reales tanto en la ola de entrenamiento (2010) como en la de prueba (2013), Sección 3.2– mejora el desempeño del benchmark cuando se agrega a las covariables de la ELCA, bajo el mismo holdout temporal, balanceo de clases y selección de umbral ya usados en la Sección 5.3. Se reentrenaron los cinco algoritmos de esa comparación agregando a los

Modelos A y B las 23 variables DMSP-OLS de estado y ventana acumulada (Sección ??) – en el código y en los archivos de resultados esta comparación se identifica como A/AgeoDMSP y B/BgeoDMSP; aquí se usa la forma expandida “A” / “A + DMSP-OLS” por legibilidad. Se agrega además `precision_top10` –la precisión entre el 10 % de hogares que el modelo señala como de mayor riesgo– porque para un programa de focalización con capacidad fija esta cifra es más relevante que recall/precision/F1 a un umbral de probabilidad, que no reflejan ninguna restricción real de cobertura. Aun así, para no dejar una lectura incompleta, la Tabla 10 también reporta esas tres métricas al umbral de clasificación ya elegido por validación cruzada maximizando F_2 (Sección 4.4): *recall* es la fracción de hogares que sí cayeron en pobreza y el modelo efectivamente marcó como riesgo (cuánto de la pobreza real se captura); *precision* es la fracción de los hogares marcados como riesgo que efectivamente cayeron en pobreza (cuánta de la alarma es acertada, no falsa alarma); *F1* resume ambas en un solo número (su media armónica) y se reporta como referencia estándar, aunque –a diferencia del umbral, elegido por F_2 – no es la métrica que decide dónde queda el punto de corte.

Cuadro 10: AUC-ROC y precisión en el decil de mayor riesgo, con y sin DMSP-OLS, holdout temporal (train 2010→2013, test 2013→2016). Umbral elegido por CV maximizando F-beta ($\beta = 2$), con CV_FOLDS=10 y N_ITER_BUSQUEDA=30.

Algoritmo	Especificación	AUC-ROC	IC95 %	Precision top-10 %	IC95 %	Umbral	Recall	Precision	F1
Random Forest	A	0.766	[0.765, 0.767]	0.486	[0.476, 0.495]	0.138	0.926	0.277	0.426
Random Forest	A + DMSP-OLS	0.763	[0.762, 0.764]	0.481	[0.470, 0.493]	0.264	0.938	0.271	0.420
XGBoost	A	0.767	[0.766, 0.769]	0.505	[0.496, 0.514]	0.112	0.949	0.264	0.413
XGBoost	A + DMSP-OLS	0.765	[0.764, 0.766]	0.501	[0.488, 0.515]	0.118	0.937	0.272	0.421
LightGBM	A	0.758	[0.758, 0.758]	0.516	[0.516, 0.516]	0.096	0.903	0.281	0.428
LightGBM	A + DMSP-OLS	0.752	[0.752, 0.752]	0.497	[0.497, 0.497]	0.102	0.902	0.277	0.424
HistGradientBoosting	A	0.763	[0.763, 0.763]	0.512	[0.512, 0.512]	0.324	0.909	0.283	0.432
HistGradientBoosting	A + DMSP-OLS	0.763	[0.763, 0.763]	0.500	[0.500, 0.500]	0.312	0.912	0.281	0.429
Logística regularizada	A	0.747	[0.747, 0.747]	0.506	[0.506, 0.506]	0.372	0.883	0.280	0.426
Logística regularizada	A + DMSP-OLS	0.746	[0.746, 0.746]	0.500	[0.500, 0.500]	0.370	0.883	0.281	0.426
Random Forest	B	0.742	[0.741, 0.744]	0.508	[0.497, 0.520]	0.306	0.892	0.272	0.416
Random Forest	B + DMSP-OLS	0.739	[0.737, 0.741]	0.492	[0.482, 0.502]	0.266	0.925	0.255	0.399
XGBoost	B	0.742	[0.742, 0.743]	0.495	[0.487, 0.503]	0.126	0.940	0.250	0.395
XGBoost	B + DMSP-OLS	0.740	[0.740, 0.741]	0.495	[0.491, 0.499]	0.128	0.929	0.254	0.399
LightGBM	B	0.731	[0.731, 0.731]	0.487	[0.487, 0.487]	0.148	0.909	0.259	0.403
LightGBM	B + DMSP-OLS	0.737	[0.737, 0.737]	0.481	[0.481, 0.481]	0.126	0.888	0.271	0.415
HistGradientBoosting	B	0.735	[0.735, 0.735]	0.494	[0.494, 0.494]	0.142	0.879	0.275	0.418
HistGradientBoosting	B + DMSP-OLS	0.736	[0.736, 0.736]	0.487	[0.487, 0.487]	0.142	0.880	0.275	0.419
Logística regularizada	B	0.739	[0.739, 0.739]	0.500	[0.500, 0.500]	0.350	0.890	0.270	0.414
Logística regularizada	B + DMSP-OLS	0.739	[0.739, 0.739]	0.494	[0.494, 0.494]	0.350	0.888	0.273	0.417

Nota: recall, precision y F1 se miden al umbral de clasificación ya elegido para cada algoritmo/especificación por validación cruzada maximizando F_2 (Sección 4.4, sin re-elegirlo al agregar DMSP-OLS). Fuente: cálculos propios, `data/processed/benchmark_resultados/registro_modelos_fbeta2_cv10.csv`, generados por `src/05_model/modelo_fbeta2_cv10_comparacion.py` (XGBoost, HistGradientBoosting, Logística regularizada) y sus variantes `modelo_fbeta2_cv10_comparacion_rf_lgbm.py` (Random Forest, LightGBM) sobre `modelo_{A,B,AgeoDMSP,BgeoDMSP}_2010_2013/2013_2016.parquet` (construidos por `construir_pipeline_geo_dmosp.py`), y formateados por `src/tabla_marginal_dmosp_fbeta2_cv10.py`.

Resultado: agregar DMSP-OLS no mejora de forma económicamente significativa el desempeño en ningún algoritmo. El AUC-ROC se mantiene igual o cae ligeramente al agregar DMSP-OLS en 8 de las 10 comparaciones algoritmo/especificación de la Tabla 10 (caídas de 0.001 a 0.006). Las dos excepciones son cambios pequeños y en direcciones opuestas entre sí –HistGradientBoosting-B sube de 0.735 a 0.736 (+0.001) y LightGBM-B, el mayor cambio positivo de toda la tabla, sube de 0.731 a 0.737 (+0.006)–, del mismo orden de magnitud que la variabilidad entre semillas del propio ajuste (Tabla 9) y, sobre todo, sin acompañamiento en `precision_top10`: esta métrica, más relevante para un programa de focalización de capacidad fija, cae o se mantiene igual en las 10 comparaciones sin una sola excepción –incluida LightGBM-B (0.487 → 0.481)–, la señal más clara de que

agregar DMSP-OLS no mejora la capacidad de priorizar correctamente al grupo de mayor riesgo. Antes de interpretar la ausencia de mejora como ausencia de señal, se descartó explícitamente la explicación de sobreajuste: se comparó, para cada algoritmo, la brecha entre el AUC de validación cruzada (calculado solo sobre entrenamiento) y el AUC de prueba real, con y sin DMSP-OLS (`comparar_auc_cv_vs_test_fbeta2_cv10.py`) – si agregar columnas geoespaciales infla artificialmente el ajuste de entrenamiento sin generalizar, esa brecha debería ensancharse. No fue el caso: el mayor cambio observado fue de +0.008 (LightGBM, Modelo A, el mismo par con la mayor caída de AUC-ROC de toda la tabla), muy por debajo del umbral de alerta (0.03) definido *ex ante*. La ausencia de mejora no es, entonces, un problema de sobreajuste del modelo.

Recall, precision y F1 se mueven poco al agregar DMSP-OLS –menos de 0.02 en cualquier dirección en la inmensa mayoría de las comparaciones– porque el umbral elegido por F_2 ya empuja el recall a valores altos (0.88 a 0.95) en las diez filas de la tabla, dejando poco margen para que un cambio de umbral mueva mucho la aguja. El cambio más grande es en **Random Forest, Modelo B**: el recall sube de 0.892 a 0.925 (+0.033) y la precision cae de 0.272 a 0.255, con F1 cayendo de 0.416 a 0.399 –el umbral que la validación cruzada eligió también baja, de 0.306 sin DMSP-OLS a 0.266 con DMSP-OLS, el mecanismo habitual: un umbral más bajo marca más hogares como riesgo, sube el recall a costa de la precision–. Es, otra vez, una consecuencia del procedimiento de selección de umbral (Sección 4.4), no evidencia de que DMSP-OLS cambie la capacidad predictiva del modelo; el AUC-ROC de este mismo par (0.742 $\rightarrow$ 0.739), que no depende de umbral, apenas se mueve. Ningún caso invierte la conclusión general: DMSP-OLS reordena marginalmente qué hogares específicos caen a cada lado del umbral, sin mejorar la capacidad de discriminación subyacente del modelo.

Por qué DMSP-OLS no aporta: redundancia, no ausencia de señal. Tomada sola, `dmsp_stable_lights` sí correlaciona con la entrada a pobreza ($r = -0.214$ sobre la muestra de entrenamiento) –una magnitud comparable a `ingreso_percapita_hogar_real` ($r = -0.211$) o `estrato_verificado_hogar` ($r = -0.215$)–, así que no se trata de una variable sin contenido informativo. El problema es que esa misma señal ya está capturada, de forma más directa y con mayor correlación con el resultado, por variables que la ELCA ya pregunta al hogar: `n_servicios_publicos_hogar` (número de servicios públicos del hogar) correlaciona 0.865 con `dmsp_stable_lights` –ambas miden, en esencia, el mismo fenómeno de electrificación y consolidación urbana del entorno– y a la vez correlaciona más fuerte con el resultado ($r = -0.250$) que la propia variable satelital; `n_bienes_durables_hogar` muestra el mismo patrón ($r = 0.477$ con DMSP-OLS, $r = -0.256$ con el resultado).

La correlación *residualizada* de `dmsp_stable_lights` contra el resultado –tras controlar por esas dos variables mediante regresión lineal, y correlacionar los residuos de ambas contra los residuos del resultado– confirma directamente la redundancia: cae de $r = -0.214$ (cruda) a $r = +0.021$ (parcial, verificado con dos implementaciones independientes, mínimos cuadrados manual y `sklearn.LinearRegression`) –prácticamente todo el poder predictivo de DMSP-OLS ya está contenido en esas dos preguntas de la encuesta. Esto no implica que la encuesta mida el fenómeno subyacente (electrificación y consolidación urbana del entorno) con menos error que el sensor satelital –ambas son medidas imperfectas de ese mismo constructo, y comparar su error de medición respectivo está fuera del alcance de este ejercicio–; lo que sí muestra la correlación residualizada es que, *para este modelo predictivo específico*, DMSP-OLS no aporta información incremental una vez que `n_servicios_publicos_hogar` y `n_bienes_durables_hogar` ya están en el panel de covariables. Esto es consistente con la regularización elastic net de la logística, que puso en cero 21 de las 23 variables DMSP-OLS agregadas (Sección ??), y con la importancia por permutación de HistGradientBoosting, donde las variables DMSP-OLS caen en un rango de -0.0009 a 0.0003 –indistinguible de ruido una vez controlado por el resto del panel.

ALOS PALSAR y Landsat 5 TM: mismo patrón, por un mecanismo distinto.

Estas dos fuentes no tienen datos reales en la ola de prueba (2013, Sección 3.2), así que no pueden evaluarse con el mismo holdout temporal –se probaron, junto con DMSP-OLS, en un ejercicio exploratorio aparte: Modelo A/B **con las tres fuentes juntas** (DMSP-OLS + ALOS PALSAR + Landsat 5 TM), restringido a la transición 2010→2013 y evaluado con validación cruzada agrupada por hogar en vez de un periodo de prueba separado (`construir_pipeline_geo3_cv.py`). Los resultados de ese ejercicio **no son comparables cifra a cifra** con la Tabla 10 –evaluar dentro del mismo periodo que el entrenamiento es una prueba más débil que un holdout a otro momento– pero la correlación bruta de sus variables contra el resultado confirma el mismo patrón de redundancia que DMSP-OLS: `alos_hh_db` correlaciona apenas $r = -0.113$ con la entrada a pobreza (frente a $r = -0.250$ de `n_servicios_publicos_hogar`) y `15_ndvi` $r = 0.160$ –ambas más débiles que cualquiera de los proxies de riqueza ya presentes en la ELCA. La misma correlación residualizada calculada para DMSP-OLS, aplicada a `alos_hh_db` y `15_ndvi` controlando por las mismas dos variables, también colapsa a valores cercanos a cero ($r = +0.010$ y $r = +0.011$ respectivamente, frente a $r = -0.113$ y $r = +0.160$ crudos). Ninguna de las tres fuentes geoespaciales nuevas parece aportar, para este panel de encuesta específico, información que la propia ELCA no capture ya de forma más directa.

¿Ayuda DMSP-OLS cuando la encuesta no pregunta por servicios públicos ni bienes del hogar? Si la redundancia con `n_servicios_publicos_hogar` y `n_bienes_durables_hogar` explica la ausencia de mejora, DMSP-OLS debería aportar más en un escenario donde esas dos preguntas no estuvieran disponibles –el caso realista de datos administrativos sin encuesta de hogar rica, o de una ola de encuesta futura sin ese módulo–. Este ejercicio de *ablation* –a diferencia de la Tabla 10– todavía usa el umbral de clasificación por F_1 y la búsqueda de hiperparámetros con `CV_FOLDS=3/N_ITER_BUSQUEDA=8` de la corrida original (Sección 4.4), no la versión robusta por F_2 con `CV_FOLDS=10/N_ITER_BUSQUEDA=30` adoptada para las Tablas 9 y 10 –no se ha vuelto a correr bajo ese criterio–, así que sus cifras de AUC-ROC no son directamente comparables punto a punto con las de esas dos tablas, aunque la lógica del ejercicio (redundancia vs. aporte incremental) no depende de esa elección. Se reentrenaron los tres algoritmos eliminando esas dos columnas de los Modelos A y B (“A sin riqueza” / “B sin riqueza” en lo que sigue; `Anoriq/Bnoriq` en el código) y de sus versiones con DMSP-OLS agregado (“A sin riqueza + DMSP-OLS” / “B sin riqueza + DMSP-OLS”; `AnoriqGeo/BnoriqGeo`). El resultado es mixto y, en conjunto, no confirma la hipótesis con fuerza: Logística regularizada es el único algoritmo con una mejora consistente aunque pequeña (AUC-ROC: “A sin riqueza” 0.7457 $\rightarrow$ “A sin riqueza + DMSP-OLS” 0.7469; `precision_top10`: “A sin riqueza” 0.497 $\rightarrow$ “A sin riqueza + DMSP-OLS” 0.500, y “B sin riqueza” 0.500 $\rightarrow$ “B sin riqueza + DMSP-OLS” 0.503); XGBoost no mejora en ninguna de las dos comparaciones (“A sin riqueza” 0.7635 $\rightarrow$ “A sin riqueza + DMSP-OLS” 0.7615; “B sin riqueza” 0.7350 $\rightarrow$ “B sin riqueza + DMSP-OLS” 0.7341); HistGradientBoosting mejora en el Modelo B sin riqueza pero empeora en el Modelo A sin riqueza. Que el único algoritmo con mejora consistente sea el lineal –el que, por construcción, no puede aprender automáticamente combinaciones no lineales de otras variables que sustituyan a DMSP-OLS– es coherente con la explicación de redundancia: los modelos de árboles, más flexibles, encuentran sustitutos suficientes en el resto del panel incluso sin las dos preguntas eliminadas, mientras que el modelo lineal sí gana algo al no tener esa alternativa. El efecto es, en cualquier caso, demasiado pequeño y demasiado inconsistente entre algoritmos para sostener una recomendación de política a partir de él.

¿Ayuda DMSP-OLS más cerca del umbral de pobreza? Se dividió el conjunto de prueba de XGBoost (Modelo A) en terciles según la distancia absoluta a la línea de pobreza en la ola base (`|brecha_lp_ingreso|`, `heterogeneidad_cerca_umbral.py`), usando los hiperparámetros ya elegidos (sin volver a tunear, para aislar el efecto de agregar DMSP-OLS). El cambio en AUC-ROC al agregar DMSP-OLS es de -0.0008 en el tercil

más cercano al umbral ($n = 1,064$, tasa de entrada 32.7%), +0.0011 en el tercil medio ($n = 1,107$, 19.2 %) y -0.0038 en el tercil más lejano ($n = 1,020$, 7.3 %). Aunque la caída es técnicamente menor cerca del umbral que lejos de él, el cambio sigue siendo negativo o prácticamente nulo en los tres terciles –no hay evidencia de que DMSP-OLS ayude de forma sustantiva ni siquiera en el subgrupo de hogares donde el ingreso reportado discrimina peor–.

5.5. Heterogeneidad territorial

Esta subsección también está pendiente. El diseño contempla reestimar el desempeño de los modelos de la Sección 5.3 por separado para zona urbana y rural, y –si el tamaño de muestra por región lo permite tras la partición temporal ya exigente en observaciones (3,089 hogares no pobres en la base de entrenamiento, Tabla 3)– por región geográfica.

6. Conclusiones

6.1. Síntesis de hallazgos

Este documento reporta el avance de una tesis que busca evaluar si las variables geoespaciales públicas mejoran la predicción de la transición hacia la pobreza monetaria de hogares colombianos no pobres, frente a un modelo basado exclusivamente en la Encuesta Longitudinal Colombiana (ELCA). Hasta el momento se ha completado la mitad “base” de esa comparación: la auditoría sistemática y no muestral de los cinco módulos de la ELCA (más de 4.000 columnas originales), la construcción rigurosa de la variable de resultado –transición a la pobreza entre olas, siguiendo el enfoque de López-Calva y Ortiz-Juárez (2011, 2014), con cinco ejercicios de robustez sobre su construcción–, y la estimación y comparación de cinco algoritmos de aprendizaje supervisado (regresión logística regularizada, Random Forest, XGBoost, LightGBM y HistGradientBoosting) bajo dos especificaciones de covariables.

Tres hallazgos se destacan de este avance. Primero, la dinámica de la pobreza en el panel ELCA 2010–2016 muestra una reducción sostenida de la incidencia (de 60.7 % a 42.4 % por ingreso) acompañada de una tasa de entrada a la pobreza –la variable de interés de esta tesis– de 23.4 % entre 2010–2013 y de 19.9 % entre 2013–2016, con una tasa de salida que casi duplica a la de entrada en ambos periodos. Segundo, los cinco algoritmos evaluados alcanzan un desempeño similar entre sí (AUC-ROC entre 0.731 y 0.767, con intervalos de confianza sobre 5 semillas del ajuste final que en la mayoría de los casos son nulos o casi nulos, ver Sección 5.3), sin que ninguno domine claramente a los

demás. El patrón ni siquiera es consistente entre especificaciones: en el Modelo A los tres *gradient boosting* y Random Forest superan a la regresión logística regularizada, pero en el Modelo B ese orden se rompe a la mitad –Random Forest y XGBoost se mantienen por encima de la logística, mientras que HistGradientBoosting y LightGBM caen por debajo de ella–. Tercero, y más importante para el diseño de la etapa siguiente de esta tesis, la brecha de desempeño entre el modelo que incluye ingreso/gasto del hogar y el que no los incluye es sorprendentemente pequeña (0.008–0.028 en AUC-ROC según el algoritmo): las covariables no monetarias –educación, activos, vivienda, choques, características de la comunidad– explican una fracción sustancial del poder predictivo que, bajo el enfoque clásico de vulnerabilidad (Chaudhuri et al., 2002), se atribuiría casi exclusivamente al ingreso. Esto sugiere que existe margen real para que fuentes de información adicionales –geoespaciales o de otro tipo– aporten poder predictivo incremental, la pregunta central que este trabajo busca responder en su etapa final.

6.2. Implicaciones para la política pública

Aunque los resultados presentados en este documento son intermedios, ya insinúan implicaciones relevantes para el diseño de sistemas de focalización como el SISBEN. Primero, la evidencia de que las covariables no monetarias tienen un poder predictivo casi comparable al del ingreso sugiere que un sistema de alerta temprana no necesita esperar a observar directamente el ingreso de un hogar –la variable más costosa y menos frecuente de actualizar– para identificar candidatos a la vulnerabilidad; características más fáciles de observar o de actualizar administrativamente (educación, activos del hogar, formalidad laboral) ya capturan buena parte de esa señal. Segundo, la comparación entre algoritmos (Sección 5.3) muestra que la elección del algoritmo correcto depende de la función de pérdida que le importa al hacedor de política: XGBoost maximiza el recall –relevante si el costo de no detectar un hogar que va a caer en pobreza (error de exclusión) es mucho mayor que el de incluir por error a uno que no cae (error de inclusión)–, mientras que HistGradientBoosting ofrece mejor precisión y el mejor balance entre ambas (mayor F1) al mismo nivel de AUC-ROC. Un sistema real debería fijar explícitamente esa preferencia antes de elegir el modelo, en vez de optimizar únicamente por AUC-ROC. Estas implicaciones se profundizarán, y se contrastarán contra el aporte específico de las fuentes geoespaciales, una vez completada la Sección 5.4.

6.3. Limitaciones y agenda de investigación

Por completar la Sección 5.4, la agenda de investigación de esta tesis continúa con la construcción de variables geoespaciales a partir de fuentes públicas, la integración de esas variables al panel ELCA, y la reestimación de los cinco algoritmos bajo las mismas condiciones de validación y balanceo de clases ya descritas. La comparación de desempeño entre el Modelo A (con ingreso/gasto) y el Modelo B (sin ellos) frente a un Modelo C (con variables geoespaciales) permitirá evaluar si estas últimas aportan poder predictivo incremental, y si ese aporte es suficiente para compensar la ausencia de información monetaria directa. La agenda también contempla la reestimación de los modelos por zona urbana/rural y, si el tamaño de muestra lo permite, por región geográfica, para evaluar la robustez territorial de los hallazgos.

Referencias

- Aiken, E., Bellue, S., Karlan, D., Udry, C., & Blumenstock, J. E. (2022). Machine Learning and Phone Data Can Improve Targeting of Humanitarian Aid. *Nature*, 603, 864-870. <https://doi.org/10.1038/s41586-022-04484-9>
- Bérgolo, M., Cruces, G., Gasparini, L., & Ham, A. (2010). *Vulnerability to Poverty in Latin America: Empirical Evidence from Cross-Sectional Data and Robustness Analysis with Panel Data* (inf. téc.). Chronic Poverty Research Centre.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.
- Castañeda Castrillón, C. A. (2012). *Trampas de Pobreza en Colombia: Una Aproximación Empírica Mediante Pseudo Panel* [Tesis de maestría, Universidad de los Andes]. <https://hdl.handle.net/1992/62019>
- Castañeda Castrillón, C. A. (2021). *Nuevos Vulnerables en Colombia: Diagnóstico de los Efectos del COVID-19 en los Empleados del Sector Formal y Propuesta de Esquema de Protección* [Tesis de maestría, Barcelona School of Management].
- Chaudhuri, S., Jalan, J., & Suryahadi, A. (2002). Assessing Household Vulnerability to Poverty from Cross-Sectional Data. *Columbia University Department of Economics Discussion Papers*, (0102-52).
- Christiaensen, L., & Subbarao, K. (2005). Towards an Understanding of Household Vulnerability in Rural Kenya. *Journal of African Economies*, 14(4), 520-558. <https://doi.org/10.1093/jae/eji008>
- Consejo Nacional de Política Económica y Social. (2016). *Declaración de Importancia Estratégica del Sistema de Identificación de Potenciales Beneficiarios (Sisbén IV)* (Documento CONPES N.º 3877). Departamento Nacional de Planeación.
- Costella, C., Diez, A., Beazley, R., & Alfonso, M. (2023). *Shock-Responsive Social Protection and Climate Shocks in Latin America and the Caribbean: Lessons from COVID-19* (IDB Working Paper N.º IDB-WP-01428). Inter-American Development Bank.
- Dercon, S. (2002). Income Risk, Coping Strategies, and Safety Nets. *The World Bank Research Observer*, 17(2), 141-166.
- Dercon, S., & Krishnan, P. (2000). Vulnerability, Seasonality and Poverty in Ethiopia. *Journal of Development Studies*, 36(6), 25-53. <https://doi.org/10.1080/713600071>
- Ferdausi, M., Tarana, M. Y., Alam, M. S., Murshed, M. F., Ehsan, S. M. A., Elahi, M. M. L., Ahmed, S., Rahman, M. F., Khan, H. M., Badhon, M. A. A., Hossein, M. K., & Jakariya, M. (2025). Strengthening Resilience in Ultra-Poverty: Using Multilayered Indicators Approach in Climate-Induced Vulnerability. *International Journal of*

- Sustainable Development & World Ecology*. <https://doi.org/10.1080/13504509.2025.2590759>
- Fujii, T. (2016). *Concepts and Measurement of Vulnerability to Poverty and Other Issues: A Review of Literature* (ADB Working Paper). Asian Development Bank Institute.
- Gaitán, A. (2023). *Población en Condición de Vulnerabilidad Monetaria en Bogotá* (Documento de Trabajo N.º 10). Secretaría Distrital de Planeación, Bogotá.
- Hall, O., Dompae, F., Wahab, I., & Dzanku, F. M. (2023). A Review of Machine Learning and Satellite Imagery for Poverty Prediction: Implications for Development Research and Applications. *Journal of International Development*. <https://doi.org/10.1002/jid.3751>
- Hofer, M., Sako, T., Martinez, A. J., Bulan, J., Addawe, M., Durante, R. L., & Martillan, M. (2025). Exploring the Use of Satellite Imagery and Computer Vision-Based Machine Learning Method to Improve the Spatial Granularity of Poverty Statistics. *Asian Economic Journal*. <https://doi.org/10.1111/asej.12349>
- Jalan, J., & Ravallion, M. (2000). Is Transient Poverty Different? Evidence for Rural China. *Journal of Development Economics*, 61(1), 99-111.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790-794.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review*, 105(5), 491-495. <https://doi.org/10.1257/aer.p20151023>
- Li, G., Cai, Z., Liu, X., Liu, J., & Su, S. (2019). A Comparison of Machine Learning Approaches for Identifying High-Poverty Counties: Robust Features of DM-SP/OLS Night-Time Light Imagery. *International Journal of Remote Sensing*, 40(15), 5716-5736. <https://doi.org/10.1080/01431161.2019.1580820>
- López-Calva, L. F., & Ortiz-Juárez, E. (2011). A Vulnerability Approach to the Definition of the Middle Class. *World Bank Policy Research Working Paper*, (5902).
- López-Calva, L. F., & Ortiz-Juárez, E. (2014). A Vulnerability Approach to the Definition of the Middle Class. *The Journal of Economic Inequality*, 12(1), 23-47.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *The World Bank Economic Review*, 32(3), 531-550.
- Muñetón, G., Escobar, D., López, F., Pérez, P., & Orozco, J. (2022). Classification of Poverty Condition Using Natural Language Processing. *Social Indicators Research*, 162, 1413-1435. <https://doi.org/10.1007/s11205-022-02883-z>

- Newhouse, D., Merfeld, J., Ramakrishnan, A., Swartz, T., & Lahiri, P. (2025). Small Area Estimation of Monetary Poverty in Mexico Using Satellite Imagery and Machine Learning. *Oxford Bulletin of Economics and Statistics*, 87(6), 1158-1172.
- Usmanova, A., Aziz, A., Rakhmonov, D., & Osamy, W. (2022). Utilities of Artificial Intelligence in Poverty Prediction: A Review. *Sustainability*, 14(21), 14238. <https://doi.org/10.3390/su142114238>

A. Tablas y figuras complementarias

A.1. Incidencia, FGT y robustez de las transiciones de pobreza monetaria

Complemento de la Sección 5.1: incidencia agregada de pobreza monetaria por ingreso y por gasto, su descomposición Foster-Greer-Thorbecke (FGT), y cinco ejercicios diseñados para evaluar qué tan sensible es la variable de transición a la pobreza –la variable de interés de esta tesis– a decisiones de construcción del ingreso, a la representatividad muestral y al error de medición cerca del umbral de pobreza.

A.1.1. Incidencia y descomposición FGT

La Figura 21 muestra la incidencia de pobreza monetaria (P0) por ingreso y por gasto para las tres olas. La pobreza por ingreso –la medida oficial– cae de 60.7 % en 2010 a 52.4 % en 2013 y a 42.4 % en 2016, una reducción acumulada de 18.3 puntos porcentuales en seis años. La pobreza por gasto, construida como medida de robustez (Sección 3), es sistemáticamente más *baja* que la de ingreso en los tres puntos del panel (47.6 %, 40.9 % y 33.4 %): la brecha ingreso-gasto es de 13.1, 11.5 y 9.0 puntos porcentuales respectivamente, siempre a favor de una menor incidencia medida por gasto. Ambas series comparten la misma tendencia decreciente y la misma desaceleración del ritmo de reducción entre 2013–2016 frente a 2010–2013, lo que sugiere que la caída de la pobreza en el periodo no es un artefacto de la medida de bienestar elegida.




Figura 21: Incidencia de pobreza monetaria (P0) por ingreso y por gasto, contra la línea de pobreza (LP), 2010–2016.

La Figura 22 descompone la pobreza por ingreso en sus tres componentes FGT: incidencia (P0), brecha (P1) y severidad (P2). La brecha –qué tan lejos está el ingreso promedio de los pobres respecto a la LP, como fracción de la LP– cae de 32.2 % a 22.0 % y a 16.1 % entre 2010 y 2016; la severidad –que pondera más a los hogares más alejados de la LP, sensible a la desigualdad entre los pobres– cae de 22.3 % a 12.4 % y a 8.3 %. La caída proporcional de P1 y P2 es más rápida que la de P0 en ambos periodos, lo que indica que la reducción de la pobreza no solo trajo hogares desde justo debajo de la LP hacia arriba, sino que también mejoró la situación relativa de los hogares que permanecieron pobres.




Figura 22: Indicadores FGT de pobreza por ingreso contra la LP: incidencia (P0), brecha (P1) y severidad (P2), por ola.

A.1.2. Ejercicios de robustez

Se implementaron cinco ejercicios de robustez sobre las cifras de transición de la Sección 5.1: ponderación muestral, dos reclasificaciones del ingreso, sensibilidad al umbral de pobreza, y atrición del panel.

Ponderación muestral. Ninguno de los resultados de la Sección 5.1 usaba factores de expansión: son proporciones *muestrales*, no estimaciones poblacionales. Se identificaron y verificaron contra los diccionarios de cada ola los factores de expansión a nivel de hogar (`fexhog`, `fexhog_2013`, ambos transversales, y `fexhog_2010`, el factor longitudinal anclado a la muestra base de 2010, disponible en las olas 2 y 3). Ponderar cambia la incidencia agregada de forma moderada: 60.7 % $\rightarrow$ 60.4 % en 2010, 52.4 % $\rightarrow$ 48.6 % en 2013 (la brecha más grande de las tres olas, casi 4 puntos), y 42.4 % $\rightarrow$ 41.8 % en 2016. En las matrices de transición, ponderar por el factor longitudinal mueve la categoría *siempre pobre* de 43.9 % a 42.7 % en 2010–2013, y de 33.3 % a 32.9 % en 2013–2016, mientras que *nunca pobre* sube de 37.0 % a 38.6 % en el segundo periodo. La dirección del efecto es consistente en ambos periodos (la muestra sin ponderar sobrerrepresenta levemente la persistencia en la pobreza), pero la magnitud es pequeña frente a los otros ejercicios de robustez de esta sección.

Ingreso sin componentes excepcionales. Seis componentes del ingreso total del hogar (venta de inmueble, venta de negocio, herencias, pólizas, venta de otros activos, y otros ingresos no clasificados) son eventos retrospectivos de doce meses –no flujos mensuales sostenidos– prorrateados como ingreso mensual para sumarlos al resto del ingreso. Un hogar que vendió una propiedad puede aparecer como si hubiera *salido* de la pobreza sin que su capacidad de ingreso sostenible haya cambiado, lo cual es un riesgo directo para la variable de interés de esta tesis. Reclasificando la pobreza con el ingreso total menos estos seis componentes y repitiendo las matrices de transición, el efecto sobre la distribución de categorías es pequeño: *siempre pobre* pasa de 43.9 % a 44.4 % en 2010–2013 y de 33.3 % a 33.8 % en 2013–2016; *nunca pobre* se mueve menos de medio punto porcentual en ambos periodos. Se concluye que el ingreso excepcional no es, a nivel agregado, un motor importante de las transiciones observadas, aunque puede seguir siendo relevante para hogares individuales específicos.

Ingreso sin ayudas en dinero. La pregunta de ayudas en dinero (*ing_ayudas*) nunca se hizo a los hogares rurales en la ola 2010 –un hueco de diseño del cuestionario, no una no-respuesta al azar, según se verificó contra tres fuentes independientes (columnas del archivo crudo, diccionario específico rural, y comparación con el diccionario urbano)–, lo que subestima mecánicamente el ingreso rural de 2010 frente al de 2013 y 2016, donde la pregunta sí existe. Para dimensionar el efecto de esta fuente de ingreso sobre las transiciones, se reclasificó la pobreza excluyendo *ing_ayudas* de las tres olas y se repitió la matriz 2010→2013. El efecto es el más grande de los cuatro ejercicios de reclasificación del ingreso: *siempre pobre* sube de 43.9 % a 46.8 %, y *nunca pobre* baja de 28.8 % a 27.2 %. Esto es consistente con que las ayudas en dinero son una fuente de ingreso más extendida en la población (no un evento raro como el ingreso excepcional), por lo que su presencia o ausencia mueve la clasificación de más hogares.

Sensibilidad a la banda alrededor de la línea de pobreza. Clasificar pobre/no pobre con un corte estricto contra la LP puede generar “transiciones” que son, en realidad, ruido de muestreo o error de medición del ingreso cerca del umbral. Para cuantificar esta sensibilidad se reclasificó la pobreza usando $LP \times 0.9$ y $LP \times 1.1$ (una banda de $\pm 10\%$) y se repitieron las matrices de transición (Figura 23). El resultado es la fuente de variación más grande de todos los ejercicios de robustez: *siempre pobre* oscila entre 38.6 % ($LP - 10\%$) y 49.1 % ($LP + 10\%$) en 2010–2013 (frente a 43.9 % en la línea base), y entre 27.8 % y 38.6 % en 2013–2016 (frente a 33.3 %) –una banda de aproximadamente 10 puntos porcentuales en ambos periodos, más del doble del efecto de excluir el ingreso excepcional o las ayudas

en dinero—. Esta es evidencia de que una parte sustancial de la variación en los resultados de transición depende de la ubicación exacta del umbral oficial, algo que debe tenerse presente al interpretar el desempeño de los modelos predictivos de la Sección 5: un modelo que clasifica erróneamente a hogares cerca del umbral puede estar capturando ruido de medición del ingreso más que un patrón estructural de vulnerabilidad.




Figura 23: Sensibilidad de la distribución de categorías de transición a una banda $\pm 10\%$ alrededor de la línea de pobreza oficial.

La Figura 24 resume conjuntamente los tres ejercicios de reclasificación del ingreso (línea base, sin ingreso excepcional, sin ayudas en dinero) frente a la especificación oficial.




Figura 24: Robustez de la distribución de categorías de transición a especificaciones alternativas del ingreso del hogar.

Atrición del panel. Además de los hogares excluidos de las matrices de transición por dividirse entre olas, se midió la atrición *pura*: hogares de la ola inicial cuyo consecutivo no aparece en absoluto en la ola siguiente, ni como emparejamiento uno a uno ni como escisión (Figura 25). La atrición total es de 11.4% en ambos periodos (1,124 de 9,853 hogares base

entre 2010 y 2013; 994 de 8,729 entre 2013 y 2016). Esa cifra agregada sí se desagregó por perfil de hogar (`src/02_build/eda_hogares_panel.py`, `analizar_attrition()`): la atrición **no es aleatoria**, se concentra sistemáticamente en hogares urbanos y de estrato más alto. Por zona, la tasa de pérdida es 2.8 veces mayor en zona urbana que en zona rural en 2010–2013 (16.2 % vs. 5.8 %) y 1.7 veces mayor en 2013–2016 (14.1 % vs. 8.2 %); por estrato socioeconómico, la pérdida crece monótonamente de 8.9 % en estrato 1 a 26.0 % en estrato 4 en 2010–2013. Por región, Bogotá tiene la mayor pérdida (24.9 %) y Centro-Oriente la menor (3.1 %). El patrón es consistente con que los hogares urbanos y de mayor estrato son más móviles (cambian de vivienda con más frecuencia), lo que dificulta su relocalización entre olas del panel –no con una atrición concentrada en los hogares más pobres, que de hecho es la más baja de las cuatro categorías de estrato–. No se investigó si, controlando por zona/estrato/región, la atrición está además asociada al estado de pobreza mismo del hogar (una limitación que se retoma en la Sección 6.3).




Figura 25: Atrición total del panel entre olas consecutivas (hogares que no aparecen en absoluto en la ola siguiente).

A.2. Perfil completo de covariables, pobreza multidimensional (IPM)

Complemento de la Sección 5.2: perfil completo de covariables robustas frente a la transición 2010→2013 bajo pobreza multidimensional (mismo criterio de inclusión que en pobreza monetaria – efecto > 0.10 con bootstrap, sin deduplicar por correlación), una tabla por categoría temática.

Cuadro 11: Ingreso y gasto – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Pobre extremo por ingreso (2010)	67 %	55 %	53 %	26 %
Pobre por ingreso (2010)	90 %	79 %	84 %	52 %
Pobre por gasto (2010)	74 %	58 %	68 %	40 %
Pobre extremo por gasto (2010)	31 %	21 %	27 %	8 %
Gasto per cápita	112k	148k	223k	400k
Ingreso per cápita	74k	101k	104k	332k
Línea de pobreza (referencia)	137k	140k	151k	177k
Línea de indigencia (referencia)	74k	75k	77k	82k
Ingreso (veces la línea de pobreza)	0.54	0.70	0.67	1.73
Gasto (veces la línea de pobreza)	0.83	1.07	1.33	2.12

Cuadro 12: Zona de residencia – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Vive en zona rural	84 %	80 %	67 %	36 %

Cuadro 13: Vivienda: materiales y servicios – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Material de piso: Tierra o arena	61 %	35 %	20 %	5 %
Servicio sanitario: Inodoro conectado a alcantarillado	12 %	16 %	30 %	62 %
Obtención de agua: Acueducto público	14 %	21 %	34 %	64 %
Material de paredes: Bloque, ladrillo, piedra, madera pulida	32 %	42 %	65 %	86 %
Combustible de cocina: Leña, madera, carbón de leña	83 %	71 %	60 %	28 %
Recolección de basura: La recogen los servicios de aseo	15 %	20 %	34 %	64 %
Tenencia de vivienda: En usufructo u otro tipo de tenencia	40 %	38 %	31 %	20 %
Tipo de vivienda: Apartamento	5 %	6 %	6 %	26 %

Cuadro 14: Vivienda: hacinamiento – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Personas por cuarto	2.56	1.94	2.10	1.44

Cuadro 15: Activos del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
N.º de servicios públicos	1.62	2.07	2.65	4.05
N.º de bienes durables	4.16	4.66	4.61	7.20
Índice de riqueza (PCA)	-0.93	-0.67	-0.87	0.33

Cuadro 16: Educación y empleo del jefe – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Educación del jefe: Ninguno	42 %	17 %	8 %	2 %
Ocupación del jefe: Jornalero	45 %	31 %	25 %	6 %
Adultos alfabetizados en el hogar	53 %	79 %	92 %	98 %
Nivel educativo del jefe (ordinal)	1.21	1.90	2.11	3.10
Sexo del jefe: Hombre	83 %	83 %	71 %	69 %
Estado civil del jefe: En unión libre	60 %	55 %	42 %	35 %
Máx. nivel educativo del hogar	1.69	2.22	2.34	3.42
Registro mercantil del jefe: No lo necesita	72 %	55 %	62 %	49 %
Etnia del jefe: Indígena	15 %	12 %	11 %	6 %
Consiguió trabajo: Pidiendo ayuda a familiares, amigos o colegas	78 %	67 %	63 %	59 %
Cotización a pensión (hogar)	1 %	3 %	6 %	25 %

Cuadro 17: Composición del hogar – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Niños al cuidado de terceros	92 %	65 %	79 %	97 %

Cuadro 18: Geoespacial – perfil por grupo de transición, pobreza multidimensional (IPM) (2010→2013).

Variable	Siempre pobre	Sale	Entra	Nunca pobre
Iluminación nocturna (DMSP)	13.8	16.7	23.0	40.7

B. Detalles de construcción de variables geoespaciales